Modelo de transformación cuántica variacional de características de cáncer de mama para un sistema híbrido de prediagnóstico

Miguel Alexander Sánchez García[1], Jesús Yaljá Montiel Pérez, Ana María Winfield Reyes
Escuela Superior de Cómputo, Instituto Politécnico Nacional, Ciudad de México
Tel. 57-29-6000 ext. 52000 y 52021. E-mail: [1]msanchezg1904@alumno.ipn.mx

***Resumen*—Se evaluó si codificar características de mamografías en estados cuánticos mediante circuitos variacionales aumenta la separabilidad entre lesiones benignas y malignas. Los datos provienen del conjunto público CBIS-DDSM: 3 568 lesiones, con masas y calcificaciones analizadas por separado. De cada lesión se extrajeron 67 características radiómicas, de las que se seleccionaron 12 que alimentan cinco representaciones: tres clásicas y dos mapas cuánticos con entrelazamiento ZZ, simulados en Qiskit Aer. La separabilidad se midió con el alineamiento kernel-objetivo (KTA), la dimensión efectiva, la diferencia geométrica g, el índice de Davies-Bouldin, la razón de Fisher y el alineamiento lineal; la clasificación, con un mismo perceptrón multicapa. Los mapas cuánticos no aumentaron la separabilidad: su kernel se concentra (mediana de similitud de 0.003 o menos, frente a 0.61 del kernel gaussiano) y g, de 1.40 a 1.70, queda lejos del umbral de ventaja ($\sqrt{N} \approx 14.1$). Al clasificar, el AUC-ROC bajó entre 0.07 y 0.14, mientras que una máquina de vectores de soporte sobre el kernel cuántico igualó a la clásica. Con etiquetas diseñadas para favorecer al circuito, el kernel cuántico superó a los clásicos, lo que muestra que el método detecta la ventaja cuando existe.**

***Palabras clave*—aprendizaje automático cuántico, kernels cuánticos, separabilidad de clases, radiómica, CBIS-DDSM, cáncer de mama.**

I. Introducción

El cáncer de mama es la neoplasia diagnosticada con mayor frecuencia en mujeres y la primera causa de muerte por tumores malignos en mujeres, en el mundo y en México [1], [2]. El tamizaje mamográfico reduce la mortalidad, pero su lectura varía entre observadores, lo que ha impulsado los sistemas de diagnóstico asistido por computadora. Los modelos de aprendizaje profundo suelen perder desempeño fuera de la distribución con la que se entrenaron [3] y operan sobre representaciones sin interpretación morfológica directa. El enfoque radiómico, en cambio, extrae descriptores explícitos de intensidad, forma y textura de la región de interés, lo que permite auditar qué conserva cada transformación posterior.

En el aprendizaje automático cuántico, un circuito de codificación $U(\mathbf{x})$ asocia cada vector clásico $\mathbf{x} \in \mathbb{R}^k$ con un estado $|\phi(\mathbf{x})\rangle$ en un espacio de Hilbert de dimensión 2^k. La similitud entre dos entradas queda dada por el kernel de fidelidad $K_Q(\mathbf{x}, \mathbf{x}') = |\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$ [4], [5], y el circuito puede integrarse con capas clásicas en arquitecturas híbridas [6]. Los estudios comparativos recientes muestran que los clasificadores clásicos estándar suelen igualar o superar a los modelos cuánticos de pequeña escala [7]. Huang et al. [8] demostraron que, si la diferencia geométrica g entre el kernel cuántico y los clásicos es pequeña ($g \ll \sqrt{N}$, con N muestras), un modelo clásico predice igual o mejor con cualquier etiquetado, y Thanasilp et al. [9] probaron que la expresividad y el entrelazamiento pueden concentrar exponencialmente los valores del kernel, de modo que, estimado con un número polinomial de disparos, el modelo resulte insensible a las entradas.

En mamografía, el antecedente directo es el estudio de Azevedo et al. [10], quienes, entre otras líneas de trabajo futuro, propusieron procesar masas y calcificaciones por separado y analizar cómo se distribuyen las lesiones en el espacio de Hilbert. Este trabajo retoma esas dos líneas sobre el conjunto público CBIS-DDSM [11] y se pregunta: (i) si dos codificaciones cuánticas aumentan la separabilidad entre lesiones benignas y malignas respecto a representaciones clásicas del mismo vector; (ii) si esas diferencias se trasladan a un mismo clasificador; y (iii) qué restricciones impone la simulación y qué costaría el mismo protocolo en un procesador cuántico. El objetivo es evaluar la viabilidad de la codificación, no superar el desempeño de los clasificadores clásicos.

II. Metodología

Masas y calcificaciones se procesan como subproblemas independientes en todas las etapas, porque difieren en su presentación radiológica.

II-A. Datos y características

Se usaron los 3 568 registros del CBIS-DDSM [11], obtenidos del archivo público TCIA con cobertura completa de imágenes DICOM: 1 696 masas (1 318 de entrenamiento y 378 de prueba) y 1 872 calcificaciones (1 546 y 326), con la partición oficial. La patología se codifica como $0 =$ benigna y $1 =$ maligna. Cada mamografía se alineó con su máscara de la región de interés; las 80 máscaras con dimensiones distintas a la imagen se corrigieron según el tipo de desajuste, y cada máscara se redujo a su componente conexa mayor. El recorte conserva la resolución y las intensidades originales de 16 bits, sin redimensionar, para no destruir las características de tamaño.

Con PyRadiomics [13] se extrajeron 67 características por lesión: 18 de intensidad, 9 de forma, 24 de la matriz de coocurrencia (GLCM) y 16 de la de longitudes de racha (GLRLM), con 32 niveles de gris fijos, como recomienda la iniciativa IBSI para intensidades no calibradas [12]. En el entrenamiento se seleccionaron $k = 12$ características por el estadístico F de ANOVA, descartando las que tuvieran correlación $|r| > 0.95$ con una ya elegida [14], y cada una se llevó al intervalo angular $[0, \pi]$ mediante su distribución

acumulada empírica, $x_i = \pi \hat{F}_i(r_i)$, para que las colas pesadas no compriman los ángulos. El valor $k = 12$ resultó de un estudio previo de costo de simulación. La validación cruzada usa cinco particiones estratificadas y agrupadas por paciente.

II-B. Cinco representaciones del mismo vector

El mismo vector $\mathbf{x} \in [0, \pi]^{12}$ alimenta cinco condiciones:

- **C1, sin transformación:** línea base clásica.
- **C2, PCA lineal a 12 componentes:** una rotación que conserva las distancias; funciona como control nulo, porque no debe cambiar ninguna métrica.
- **C3, Kernel PCA con kernel gaussiano (RBF):** transformación clásica no lineal, con el ancho de banda por la heurística de la mediana.
- **C4, `zz_feature_map`:** rotaciones de un qubit en Z y acoplamiento ZZ entre los 66 pares de qubits, seguidos de un circuito variacional `real_amplitudes` con sus 24 parámetros $\boldsymbol{\theta}$ fijados con la semilla 42. Se lee el vector de valores esperados $\langle Z_i \rangle \in [-1, 1]^{12}$.
- **C5, `pauli_feature_map` con términos Y y ZZ:** igual que C4, pero la rotación de un qubit es en Y.

Se eligieron mapas con entrelazamiento porque una codificación angular sin él se reduce analíticamente a un kernel clásico de producto de cosenos. El circuito variacional es indispensable para esta lectura: en C4 todas las compuertas tras la capa de Hadamard son diagonales, así que sin él toda entrada daría $\langle Z_i \rangle = 0$. Para el análisis de kernels se usa el kernel de fidelidad del mapa solo, porque cualquier unitario común $V(\boldsymbol{\theta})$ se cancela en el producto interno. Todo se calcula con el vector de estado exacto en Qiskit Aer, sin ruido de dispositivo.

II-C. Métricas de separabilidad

La separabilidad se mide antes de clasificar, sobre 200 lesiones de entrenamiento por subconjunto, estratificadas. Ese tamaño corresponde al costo de medir la matriz de kernel en un procesador real: 19 900 circuitos, frente a cerca de un millón con todo el entrenamiento. Se usan dos familias de métricas.

Sobre los kernels (K, matriz de similitudes entre lesiones; para C3, el kernel RBF):

- **Exceso de KTA.** El alineamiento kernel-objetivo centrado [15], $\hat{A}(K, \mathbf{y}) = \langle K_c, (\mathbf{y}\mathbf{y}^\top)_c \rangle_F / (\|K_c\|_F \|(\mathbf{y}\mathbf{y}^\top)_c\|_F)$, mide cuánto se parece la similitud entre lesiones a la coincidencia de sus etiquetas. Como una matriz cercana a la identidad da $1/\sqrt{N-1}$ con cualquier etiquetado, se reporta el exceso sobre la media de 1 000 permutaciones de etiquetas.
- **Dimensión efectiva** d_{eff} [8]: cuántas direcciones usa el kernel, de 1 a N. Un valor cercano a N indica que cada lesión queda aislada de las demás.
- **Diferencia geométrica regularizada** [8]: $g = \sqrt{\| \sqrt{K_Q}\sqrt{K_C}(K_C + \lambda I)^{-2}\sqrt{K_C}\sqrt{K_Q} \|_\infty}$, el mínimo sobre una batería de kernels clásicos (lineal y gaussianos) y de valores de λ. Si $g \ll \sqrt{N}$, algún modelo clásico predice al menos tan bien como el cuántico con cualquier etiquetado.

Sobre las representaciones vectoriales (lo que recibe el clasificador):

- **Índice de Davies-Bouldin** [16]: cociente entre la dispersión dentro de cada clase y la distancia entre sus centros; menor es mejor.
- **Razón de Fisher** [17]: $J = \Delta\boldsymbol{\mu}^\top S_W^{-1} \Delta\boldsymbol{\mu}$, la distancia de Mahalanobis al cuadrado entre las medias de clase; mayor es mejor.
- **Alineamiento lineal**: el KTA centrado del kernel lineal de la representación.

Cada métrica se compara con su distribución bajo 1 000 permutaciones de etiquetas. Como ayuda visual, sin valor de métrica, se proyecta cada representación con t-SNE.

II-D. Clasificación y análisis complementarios

Un mismo perceptrón multicapa ($12 \to 32 \to 16 \to 1$, ReLU, salida sigmoide, entropía cruzada ponderada por clase, Adam con tasa 10^{-3}) se entrena sobre cada representación con el mismo protocolo, estandarización en cada partición y parada temprana. Se evalúa con validación cruzada y una sola vez en el conjunto de prueba oficial, con intervalos de confianza por *bootstrap* por paciente. La métrica principal es el AUC-ROC.

Para entender los resultados se añadieron análisis complementarios: (a) robustez ante la semilla, la red, el sorteo y el entrenamiento de $\boldsymbol{\theta}$, el número de qubits y el tamaño de muestra; (b) árboles de decisión, *random forest* y XGBoost sobre las mismas representaciones; (c) una máquina de vectores de soporte sobre el kernel cuántico completo (QSVM); (d) una búsqueda de ventaja con kernels cuánticos y clásicos ajustados con la misma búsqueda anidada; (e) un control positivo con el etiquetado diseñado de Huang et al. [8], que sigue la geometría del kernel cuántico, y su mezcla gradual con las etiquetas diagnósticas; y (f) el costo de simulación y de medición en función del número de qubits y de disparos (*shots*).

III. Resultados

III-A. Concentración del kernel cuántico

Los kernels cuánticos resultaron casi diagonales (Fig. 1). La mediana fuera de la diagonal fue de 0.0022 en masas y 0.0029 en calcificaciones con C4, y de 0.00003 con C5, donde entre el 26 y el 28 % de los pares queda por debajo de 10^{-6}; la del kernel RBF fue de 0.607. Es decir, casi todo par de lesiones queda casi ortogonal en el espacio de Hilbert de 2^{12} dimensiones, que es el caso que Thanasilp et al. [9] describen como concentración. Contraer los ángulos ($\mathbf{x} \to c\mathbf{x}$ con $c = 0.02$) sube la mediana a 0.54–0.59, pero entonces el kernel coincide (correlación ≥ 0.99997) con el de un circuito sin el término de interacción $x_i x_j$: la concentración solo desaparece al perder la interacción entre características.

III-B. Separabilidad

La Tabla I reúne las seis métricas. En la familia de kernels, el exceso de KTA de C4 y C5 (0.003 a 0.007) es entre el 4 y el 10 % del que alcanza el RBF (0.049 en masas y 0.151 en calcificaciones). La dimensión efectiva de los kernels cuánticos, de 168 a 188 sobre 200, confirma que tratan a casi

TABLA I
RESUMEN DE RESULTADOS POR CONDICIÓN: SEPARABILIDAD, CLASIFICACIÓN Y TIEMPO DE TRANSFORMACIÓN.

	Kernel			Representación		AUC-ROC		
Condición	Exceso KTA ↑	d_{eff}	g	DB ↓	Fisher ↑	VC	Prueba [IC 95 %]	Tiempo (s)
Masas								
C1	—	—	—	**4.301**	0.669	**0.652**	**0.651** [0.578, 0.724]	—
C2	—	—	—	**4.301**	0.669	0.641	0.641 [0.572, 0.710]	0.0002
C3	**0.049**	2.8	—	5.564	**0.781**	0.648	0.646 [0.572, 0.721]	0.14
C4	0.003	184.0	1.433	5.898	0.449	0.565	0.530 [0.473, 0.587]	13.3
C5	0.005	171.3	1.511	13.346	0.668	0.563	0.581 [0.521, 0.644]	14.3
SVM sobre el kernel RBF							0.649 [0.574, 0.726]	—
QSVM sobre el kernel de C4							0.628 [0.555, 0.703]	—
QSVM sobre el kernel de C5							0.599 [0.523, 0.675]	—
Calcificaciones								
C1	—	—	—	**2.387**	1.284	0.742	0.769 [0.694, 0.836]	—
C2	—	—	—	**2.387**	1.284	**0.758**	**0.788** [0.719, 0.851]	0.0002
C3	**0.151**	2.6	—	2.995	**1.390**	0.739	0.758 [0.685, 0.826]	0.20
C4	0.006	187.7	1.400	6.890	0.399	0.640	0.633 [0.558, 0.700]	13.9
C5	0.007	167.6	1.701	6.247	0.753	0.667	0.652 [0.571, 0.725]	16.1
SVM sobre el kernel RBF							0.769 [0.696, 0.834]	—
QSVM sobre el kernel de C4							0.759 [0.687, 0.827]	—
QSVM sobre el kernel de C5							0.701 [0.620, 0.775]	—

Separabilidad sobre 200 lesiones de entrenamiento por subconjunto, $c = 1$. Las columnas de kernel de C3 corresponden al kernel RBF; C1 y C2 no definen un kernel propio. g: mínimo de la diferencia geométrica regularizada ($\sqrt{N} \approx 14.1$). AUC: el mismo perceptrón multicapa en C1–C5 (VC: media de la validación cruzada); las tres últimas filas de cada bloque son clasificadores de vectores de soporte sobre el kernel. Tiempo: transformación de todas las lesiones del subconjunto (C1 es la identidad). En negritas, el mejor valor de cada columna con dirección en cada subconjunto; en el AUC de prueba se comparan también las filas de vectores de soporte.

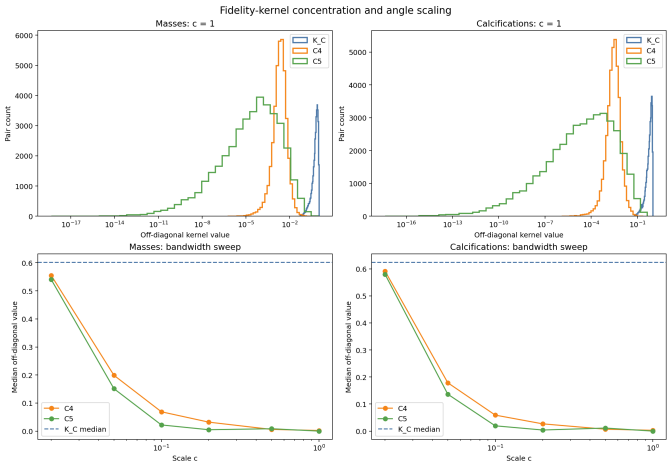


Fig. 1. Valores fuera de la diagonal de los kernels cuánticos (C4, C5) y del RBF a $c = 1$ (arriba) y su mediana en función de la escala angular c (abajo).

cada lesión como aislada, frente a menos de 3 del RBF. La diferencia geométrica, de 1.40 a 1.70, queda muy por debajo de $\sqrt{N} \approx 14.1$: según el criterio de Huang et al. [8], la ventaja que estos kernels cuánticos podrían tener sobre la batería clásica es pequeña con cualquier etiquetado de estas lesiones.

En las representaciones vectoriales (Fig. 2), las condiciones clásicas encabezan las tres métricas en los dos subconjuntos. El índice de Davies-Bouldin sube de 4.30 en C1 a 5.90 en C4 y 13.35 en C5 en masas, y de 2.39 a 6.89 y 6.25 en calcificaciones; la razón de Fisher es máxima en C3 y mínima en C4 (0.45 y 0.40); y el alineamiento lineal cae de 0.070 y 0.181 en C1 a entre 0.012 y 0.041 en C4 y C5. En masas, C5 no se distingue de etiquetas al azar en Davies-Bouldin ni en alineamiento lineal ($p = 0.41$), y en calcificaciones tampoco C4 en la razón de Fisher ($p = 0.15$). C1 y C2 coinciden en todas las métricas, como corresponde al control nulo. El t-SNE (Fig. 3) lo ilustra: con C1 y C2 las malignas tienden a agruparse hacia un extremo, y con C5 quedan mezcladas.

La conclusión se mantiene en 20 submuestras de 200 lesiones y en todo el entrenamiento, donde el RBF va por delante en todas, y al reducir el circuito a 8 qubits: el exceso de KTA cuántico crece de 1.7 a 4.6 veces y g sube a 1.71–3.23, sin alcanzar al RBF ni a $\sqrt{N}$.

III-C. Clasificación

La pérdida de separabilidad se trasladó al clasificador (Fig. 4 y Fig. 5). En el conjunto de prueba, el mismo perceptrón obtuvo frente a C1 diferencias de -0.122 $[-0.202, -0.044]$ con C4 y -0.070 $[-0.140, -0.004]$ con C5 en masas, y de -0.135 $[-0.208, -0.061]$ y -0.118 $[-0.182, -0.046]$ en calcificaciones; las cuatro son significativas tras la corrección de Holm. El control nulo C2 no difirió de C1 ($p = 0.66$ y $p = 0.38$). La brecha resistió cambios de semilla, de arquitectura, de escalado y de número de épocas; ningún sorteo de $\boldsymbol{\theta}$ alcanzó a C1, y entrenar $\boldsymbol{\theta}$ junto con la red mejoró a lo sumo 0.04, sin significancia. Con árboles de decisión, *random forest* y XGBoost, ninguna representación cuántica superó a C1: en calcificaciones la brecha siguió siendo significativa (-0.12 a -0.22), y en masas los ensambles la redujeron sin cerrarla. Separabilidad y clasificación ordenan las condiciones de forma parecida: los coeficientes de Spearman entre ambos órdenes van de 0.67 a 0.97, siempre con C1–C3 por delante de C4 y C5.

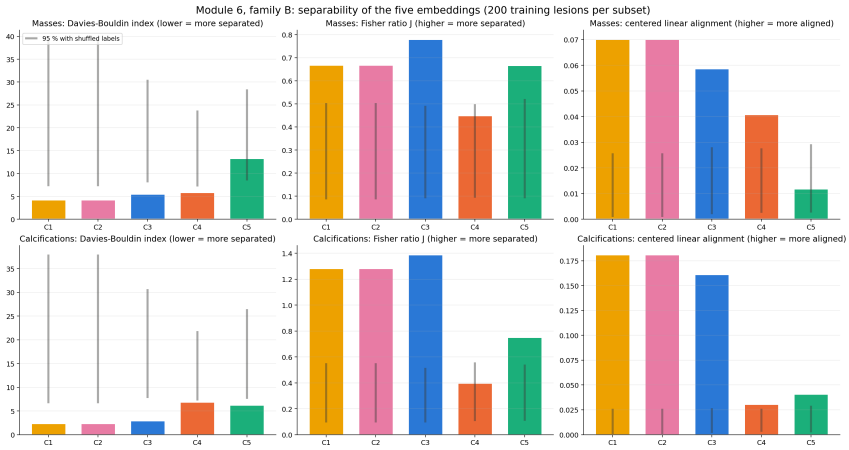


Fig. 2. Separabilidad de las cinco representaciones vectoriales en 200 lesiones de entrenamiento: índice de Davies-Bouldin (menor es mejor), razón de Fisher J y alineamiento lineal (mayor es mejor). La barra gris marca el intervalo del 95 % con etiquetas permutadas.

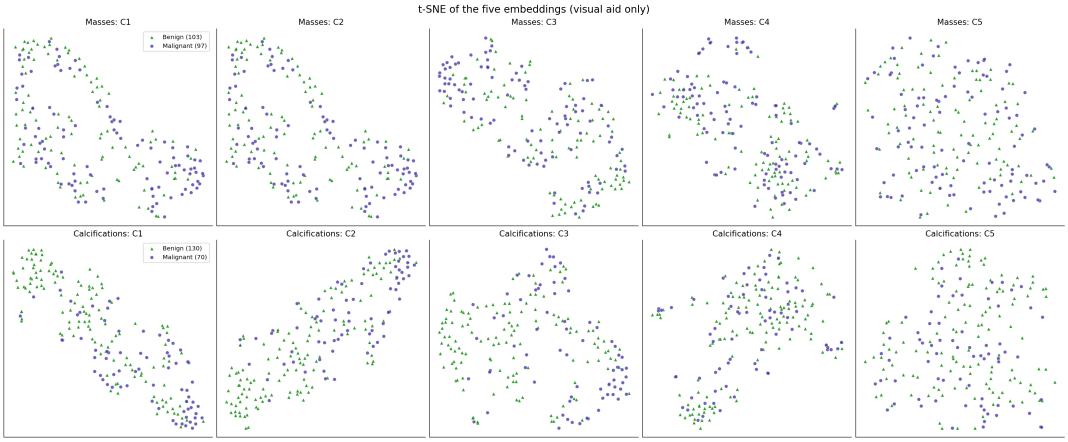


Fig. 3. Proyección t-SNE de las cinco representaciones para masas (arriba) y calcificaciones (abajo); triángulos verdes, benignas; círculos morados, malignas. Es solo una ayuda visual.

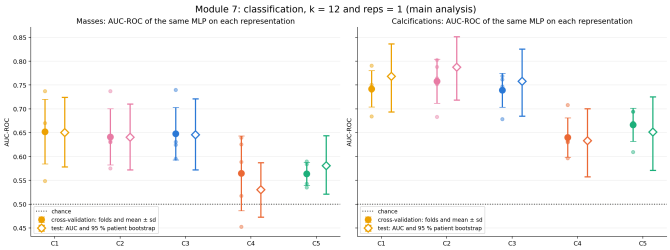


Fig. 4. AUC-ROC del mismo perceptrón multicapa sobre cada representación: validación cruzada (círculos, media ± desviación estándar) y prueba (rombos, IC del 95 % por *bootstrap* por paciente).

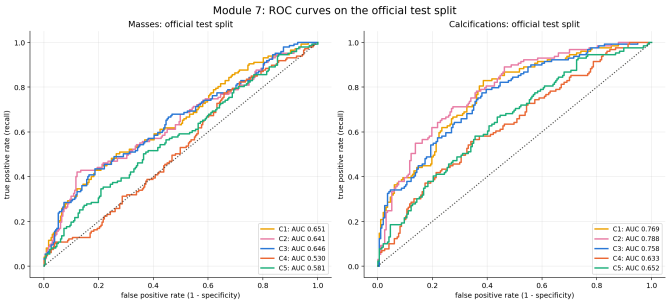


Fig. 5. Curvas ROC en el conjunto de prueba oficial bajo las cinco representaciones.

III-D. Dónde se pierde la información y cuándo hay ventaja

Una máquina de vectores de soporte sobre el kernel cuántico completo de C4 alcanzó en prueba 0.628 en masas y 0.759 en calcificaciones (Tabla I): empata con el SVM sobre el kernel RBF (0.649 y 0.769) y supera en $+0.10$ y $+0.13$ al perceptrón sobre los $\langle Z_i \rangle$ de C4. El estado de 2^{12} amplitudes conserva información diagnóstica comparable a la clásica; lo que se pierde es la lectura de solo 12 valores esperados. Con una búsqueda anidada simétrica entre 28 kernels cuánticos y 12 clásicos, el mejor cuántico empató con el clásico en prueba (0.656 frente a 0.652 en masas; 0.755 frente a 0.760 en calcificaciones).

El protocolo sí detecta una ventaja cuando existe. Con el

etiquetado diseñado de Huang et al. [8], un kernel cuántico proyectado alcanzó en validación cruzada 0.998 en masas y 0.994 en calcificaciones, frente a 0.800 y 0.824 del mejor clasificador clásico. Al mezclar gradualmente ese etiquetado con el diagnóstico, los kernels cuánticos superan al mejor clásico, elegido entre máquinas de vectores de soporte y XGBoost, solo cuando entre el 40 y el 70 % de las etiquetas sigue la geometría del circuito; con las etiquetas diagnósticas reales, que corresponden al 0 %, quedan por detrás.

III-E. Viabilidad en simulación y en hardware

En un procesador Apple M3 con 16 GiB, en 24 horas caben los valores esperados de todo el conjunto hasta 25–26 qubits y el kernel de 200×200 hasta 22–23. El límite práctico no es el número de qubits sino el gradiente: entrenar $\boldsymbol{\theta}$ con la regla de *parameter-shift*, la única aplicable en hardware, costaría unas 205 horas por mapa con 12 qubits. Al simular la medición con 1 024 disparos, el perceptrón conserva el AUC a menos de 0.02 del valor exacto, pero en el kernel la concentración se vuelve un problema de medición: entre el 16 y el 22 % de los pares con C4, y entre el 72 y el 75 % con C5, se leerían exactamente como cero.

IV. Conclusiones

Con el diseño fijado de antemano (12 qubits, una repetición y escala angular nominal), las codificaciones cuánticas evaluadas no aumentaron la separabilidad entre lesiones benignas y malignas del CBIS-DDSM: las seis métricas favorecen a las representaciones clásicas, y la diferencia se refleja en la clasificación con el mismo perceptrón y con árboles. Esto no significa que el enfoque fracase. Responde con evidencia cuantitativa la pregunta de investigación y explica por qué ocurre: (1) el kernel cuántico se concentra y aísla a cada lesión (g de 1.40 a 1.70, lejos de $\sqrt{N} \approx 14.1$), y contraer los ángulos solo lo evita a costa de la interacción entre características; (2) el estado cuántico conserva información comparable a la clásica, pero leer 12 valores esperados la pierde, como muestra el empate del QSVM con el SVM clásico; y (3) la ventaja aparece cuando las etiquetas siguen la geometría del circuito, como se reprodujo con el etiquetado de Huang et al., y el diagnóstico benigno/maligno a partir de características radiómicas no la sigue. El método, por tanto, distingue cuándo una codificación cuántica puede aportar y cuándo no.

En viabilidad, la simulación exacta es factible hasta unos 22 a 26 qubits, pero el mismo protocolo en hardware chocaría con el costo del gradiente y con kernels cuyos valores se leerían como cero. Los resultados se limitan a un conjunto de mamografías digitalizadas sin escala física, a 12 características seleccionadas de forma univariante y a simulación sin ruido. Quedan como trabajo futuro codificaciones que no se concentren sin perder la interacción, lecturas más ricas que los valores esperados locales y la validación en mamografía digital con escala conocida.

Referencias

[1] F. Bray, M. Laversanne, H. Sung, J. Ferlay, R. L. Siegel, I. Soerjomataram y A. Jemal, "Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries," *CA: A Cancer Journal for Clinicians*, vol. 74, no. 3, pp. 229–263, 2024, doi: https://doi.org/10.3322/caac.21834.

[2] Instituto Nacional de Estadística y Geografía, "Estadísticas de cáncer de mama," 2025. [En línea]. Disponible en: https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2025/EAP_CancerMama_25.pdf

[3] X. Wang, G. Liang, Y. Zhang, H. Blanton, Z. Bessinger y N. Jacobs, "Inconsistent performance of deep learning models on mammogram classification," *Journal of the American College of Radiology*, vol. 17, no. 6, pp. 796–803, 2020, doi: https://doi.org/10.1016/j.jacr.2020.01.006.

[4] V. Havlíček, A. D. Córcoles, K. Temme, A. W. Harrow, A. Kandala, J. M. Chow y J. M. Gambetta, "Supervised learning with quantum-enhanced feature spaces," *Nature*, vol. 567, pp. 209–212, 2019, doi: https://doi.org/10.1038/s41586-019-0980-2.

[5] M. Schuld y N. Killoran, "Quantum machine learning in feature Hilbert spaces," *Physical Review Letters*, vol. 122, no. 4, p. 040504, 2019, doi: https://doi.org/10.1103/PhysRevLett.122.040504.

[6] A. Mari, T. R. Bromley, J. Izaac, M. Schuld y N. Killoran, "Transfer learning in hybrid classical-quantum neural networks," *Quantum*, vol. 4, p. 340, 2020, doi: https://doi.org/10.22331/q-2020-10-09-340.

[7] J. Bowles, S. Ahmed y M. Schuld, "Better than classical? The subtle art of benchmarking quantum machine learning models," *arXiv preprint* arXiv:2403.07059, 2024, doi: https://doi.org/10.48550/arXiv.2403.07059.

[8] H.-Y. Huang, M. Broughton, M. Mohseni, R. Babbush, S. Boixo, H. Neven y J. R. McClean, "Power of data in quantum machine learning," *Nature Communications*, vol. 12, p. 2631, 2021, doi: https://doi.org/10.1038/s41467-021-22539-9.

[9] S. Thanasilp, S. Wang, M. Cerezo y Z. Holmes, "Exponential concentration in quantum kernel methods," *Nature Communications*, vol. 15, no. 1, p. 5200, 2024, doi: https://doi.org/10.1038/s41467-024-49287-w.

[10] V. Azevedo, C. Silva y I. Dutra, "Quantum transfer learning for breast cancer detection," *Quantum Machine Intelligence*, vol. 4, no. 1, p. 5, 2022, doi: https://doi.org/10.1007/s42484-022-00062-4.

[11] R. S. Lee, F. Gimenez, A. Hoogi, K. K. Miyake, M. Gorovoy y D. L. Rubin, "A curated mammography data set for use in computer-aided detection and diagnosis research," *Scientific Data*, vol. 4, no. 1, p. 170177, 2017, doi: https://doi.org/10.1038/sdata.2017.177.

[12] A. Zwanenburg, M. Vallières, M. A. Abdalah *et al.*, "The Image Biomarker Standardization Initiative: Standardized quantitative radiomics for high-throughput image-based phenotyping," *Radiology*, vol. 295, no. 2, pp. 328–338, 2020, doi: https://doi.org/10.1148/radiol.2020191145.

[13] J. J. M. van Griethuysen *et al.*, "Computational radiomics system to decode the radiographic phenotype," *Cancer Research*, vol. 77, no. 21, pp. e104–e107, 2017, doi: https://doi.org/10.1158/0008-5472.CAN-17-0339.

[14] I. Guyon y A. Elisseeff, "An introduction to variable and feature selection," *Journal of Machine Learning Research*, vol. 3, pp. 1157–1182, 2003. [En línea]. Disponible en: https://jmlr.org/papers/v3/guyon03a.html

[15] C. Cortes, M. Mohri y A. Rostamizadeh, "Algorithms for learning kernels based on centered alignment," *Journal of Machine Learning Research*, vol. 13, no. 28, pp. 795–828, 2012. [En línea]. Disponible en: https://jmlr.org/papers/v13/cortes12a.html

[16] D. L. Davies y D. W. Bouldin, "A cluster separation measure," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 1, no. 2, pp. 224–227, 1979, doi: https://doi.org/10.1109/TPAMI.1979.4766909.

[17] R. A. Fisher, "The use of multiple measurements in taxonomic problems," *Annals of Eugenics*, vol. 7, no. 2, pp. 179–188, 1936, doi: https://doi.org/10.1111/j.1469-1809.1936.tb02137.x.