

INSTITUTO POLITÉCNICO NACIONAL

Escuela Superior de Cómputo

Licenciatura en Ciencia de Datos

TT No. 2026 – B039

“Modelo de transformación cuántica variacional de características de cáncer de mama para un sistema híbrido de prediagnóstico”

Presenta:

Miguel Alexander Sánchez García

Directores:

Dra. Ana María Winfield Reyes

Dr. Jesús Yaljá Montiel Pérez

Índice

Resumen	3
Abstract	4
1. Panorama General	5
1.1. Introducción	5
1.1.1. Contexto clínico del cáncer de mama	5
1.1.2. Limitaciones de los métodos clásicos de diagnóstico asistido	7
1.1.3. Computación cuántica como alternativa	8
1.2. Planteamiento del problema	10
1.3. Justificación	12
1.4. Objetivos	14
1.4.1. Objetivo general	14
1.4.2. Objetivos específicos	14
1.5. Alcance y limitaciones	15
2. Antecedentes	18
2.1. Estado del arte	18
2.1.1. Machine Learning clásico en el diagnóstico mamográfico	18
2.1.2. Deep Learning en el diagnóstico mamográfico	19
2.1.3. Fundamentos de quantum machine learning y codificación cuántica de datos	21
2.1.4. Modelos híbridos-cuántico-clasico en el sector salud	24
2.1.5. Trabajos específicos sobre el dataset CBIS-DDSM	25
2.1.6. Tabla comparativa y brechas identificadas	25
3. Marco Teórico	28
4. Metodología	29
4.1. Requerimientos del sistema	29
4.1.1. Requerimientos funcionales	29
4.1.2. Requerimientos no funcionales	30
Bibliografía	31

Resumen

Abstract

1. Panorama General

1.1. Introducción

1.1.1. Contexto clínico del cáncer de mama


El cáncer de mama es una enfermedad caracterizada por la proliferación descontrolada de células en el tejido mamario, que forma tumores malignos con capacidad de expandirse sistemáticamente si no recibe tratamiento oportuno. A nivel mundial, constituye el cáncer más frecuente diagnosticado en mujeres y la principal causa de muerte por cáncer femenino, superando incluso el cáncer de pulmón en incidencia global.

Según los datos de GLOBOCAN 2022 de la Agencia Internacional para la Investigación sobre el Cáncer (IARC), en 2022 se registraron aproximadamente 2.3 millones casos nuevos de cáncer de mama y una mortalidad de alrededor de 670,000 mujeres a nivel mundial [2]. El cáncer de mama representa actualmente uno de cada cuatro cánceres en mujeres a nivel global, y desde 2008 la incidencia mundial ha aumentado más de 20 %, mientras que la mortalidad se ha incrementado en un 14 % [3]. Las proyecciones son igualmente preocupantes: si las tasas nacionales actuales se mantienen estables, para 2050 el número de casos nuevos y defunciones por cáncer de mama a nivel mundial aumentará más de 50 % y 70 % respectivamente, impulsando principalmente por el crecimiento y envejecimiento de la población [4]

Las disparidades regionales son significativas y tienen implicaciones directas para el desarrollo de herramientas de diagnóstico asistido. En países de bajos ingresos, la tasa de mortalidad por cáncer de mama puede ser el doble que en países más desarrollados, a pesar de tener una incidencia considerablemente menor, lo que refleja la falta o inadecuada infraestructura de servicios de detección temprana y tratamiento oportuno [5]. Esta brecha evidencia que el problema no es únicamente epidemiológico, sino también tecnológico y de acceso a herramientas diagnósticas.

Panorama en México

En el contexto nacional, la situación es igualmente urgente. Según datos del Instituto Nacional de Estadística y Geografía (INEGI), en 2024 el cáncer de mama fue la principal causa de muerte por tumores malignos en México, con aproximadamente 8,500 defunciones registradas, de las cuales el 99.2 % correspondieron a mujeres, con una tasa de mortalidad de 18.7 por cada 100,000 mujeres de 20 años o más [6]. Este indicador refleja un deterioro; durante



(a) Tasa de mortalidad en México (INEGI 2025) desde 2015 al 2024 [7]

(b) Incidencia y mortalidad por entidad federativa en México en 2025 (INEGI 2025) [7]

la última década, la tasa de defunciones por cáncer de mama se incrementó de 15.69 en 2015 a 18.68 en 2024 por cada 100,000 mujeres de 20 años o más como se muestra en la Figura 1.1.1a. [7]

La detección temprana como factor determinante

El elemento clínico más relevante para justificar el desarrollo de sistemas de prediagnóstico automatizado es el impacto radical de la detección temprana sobre la supervivencia. Según la American Cancer Society, cuando el cáncer de mama se detecta en etapa temprana y se encuentra en una fase localizada, la tasa de supervivencia relativa a cinco años es del 99 % [8]. Esta cifra contrasta drásticamente con los casos en etapa avanzada con metastásis, donde la supervivencia a cinco años cae a 30 %. Las mujeres que reciben tamizaje regular de cáncer de mama presentan una tasa de mortalidad de un 26 % menor que las que no se somete a cribado.

La mamografía es el instrumento central de detección temprana. Es el único método de tamizaje demostrado para reducir las muertes por cáncer de mama según el American College of Radiology, y las tasas de mortalidad por esta enfermedad disminuyeron un 42 % entre 1989 y 2021, en parte gracias a la detección temprana mediante cribado mamográfico. [10]. Sin embargo, la interpretación manual de mamografías presenta limitaciones inherentes: la variabilidad inter-observador entre radiólogos, la dificultad de detección en tejidos de alta densidad mamaria, y la carga de trabajo creciente en los sistemas de salud constituyen factores que motivan el desarrollo de sistemas de diagnóstico asistido por computadora (CADx).

En México, la disponibilidad de infraestructura diagnóstica sigue siendo un desafío. En 2021 se registraron 1,281 mastógrafos en el país, de los cuales 41.1 % se encontraba en instituciones de salud y seguridad social, 36.1 % en establecimientos particulares y 22.8 % en servicios para población sin derechohabencia [11]. Esta distribución limitada, combinada con el incremento sostenido en la mortalidad, subraya la necesidad de desarrollar herramientas tecnológicas que amplíen la capacidad diagnóstica del sistema de salud, haciendo más eficiente y accesible la interpretación de estudios mamográficos.

Es en este contexto donde el presente trabajo propone explorar el uso de transformaciones cuánticas variacionales sobre características extraídas de mamografías del dataset CBIS-DDSM, con el fin de evaluar si estas representaciones mejoran la separación de clases benigno/maligno cuando se integran como entrada de una red neuronal clásica, contribuyendo al desarrollo de herramientas de prediagnóstico asistido más robustas.

1.1.2. Limitaciones de los métodos clásicos de diagnóstico asistido

El diagnóstico asistido por computadora (CADx) en mamografía ha experimentado un notable desarrollo durante las últimas dos décadas, impulsado principalmente por el avance de las redes neuronales convolucionales (CNN) y las técnicas de deep learning. No obstante, a pesar de los resultados prometedores reportados en condiciones controladas, estos métodos presentan limitaciones estructurales que restringen su aplicabilidad clínica generalizada.

Variabilidad e inconsistencia diagnóstica

La interpretación manual de mamografías está sujeta a una variabilidad inherente entre radiólogos. La variabilidad entre lectores y la dificultad intrínseca de interpretar características radiográficas sutiles limitan con frecuencia la precisión del diagnóstico mamográfico [12], lo que motivó el desarrollo de sistemas CADx automatizados. Sin embargo, los modelos de deep learning han heredado parte de esta inconsistencia de una forma distinta: en lugar de variar entre observadores humanos, varían entre conjuntos de datos.

El estudio de Wang et al. (2020), publicado en el Journal of the American College of Radiology, es uno de los trabajos más citados al respecto. Los tres modelos publicados con alto rendimiento reportaron puntuaciones AUC-ROC de validación entre 0.88 y 0.95 en el conjunto de datos de entrenamiento; sin embargo, al evaluarse sobre tres conjuntos de datos externos, el rendimiento de los seis modelos disminuyó significativamente, obteniéndose valores de AUC-ROC de apenas entre 0.44 y 0.65. Este hallazgo es especialmente relevante para la presente investigación, ya que demuestra que el alto rendimiento de un modelo de deep learning en un dataset específico no garantiza su transferibilidad a datos con distribuciones

distintas, una condición inevitable en entornos clínicos reales donde los equipos de adquisición, las poblaciones de pacientes y los protocolos de imagen varían considerablemente.

Limitaciones de interpretabilidad

Es importante abordar los desafíos asociados a la implementación de deep learning en entornos clínicos; la investigación futura debe enfocarse en mejorar la interpretabilidad de los modelos y garantizar su generalización para integrar exitosamente el diagnóstico asistido por deep learning en programas rutinarios de tamizaje de cáncer de mama. [14]. La naturaleza de caja negra de las CNN profundas genera desconfianza clínica, ya que los radiólogos no pueden verificar el razonamiento que conlleva a una predicción, lo cual es un requisito indispensable para cualquier herramienta de apoyo a la decisión médica.

Alta dimensionalidad y representación de características

Desde una perspectiva de ciencia de datos, los métodos clásicos enfrentan el desafío de la alta dimensionalidad de las imágenes mamográficas. El sobreajuste ocurre cuando los modelos aprenden demasiado bien los detalles de los datos de entrenamiento pero no generalizan adecuadamente para realizar buenas predicciones sobre datos no vistos, lo que sucede típicamente cuando el tamaño del conjunto de entrenamiento es demasiado pequeño en comparación con el número de parámetros del modelo que deben aprenderse. Las técnicas de aumento de datos y regularización mitigan parcialmente este problema, pero no lo resuelven de forma fundamental, especialmente en datasets de tamaño moderado como el CBIS-DDSM.

En conjunto, estas limitaciones evidencian la necesidad de explorar nuevos paradigmas de representación de datos que superen las restricciones del aprendizaje clásico, particularmente en lo que respecta a la separabilidad de características en espacios de alta dimensión.

1.1.3. Computación cuántica como alternativa

Ante las limitaciones descritas, la computación cuántica emerge como un paradigma complementario que ofrece mecanismos cualitativamente distintos para la representación y transformación de datos clínicos. Su propuesta central no es sustituir a los métodos clásicos, sino enriquecer la representación de los datos en etapas específicas del pipeline de análisis, particularmente en la codificación de características.

El espacio de Hilbert como espacio de representación

El fundamento teórico de la ventaja cuántica en tareas de clasificación reside en la naturaleza del espacio en el que opera un circuito cuántico. Cuando los datos se mapean desde su

dimensión de entrada al espacio de Hilbert en una computadora cuántica, se proyectan a un espacio de mayor dimensión. La clasificación lineal de datos puede lograrse eficazmente mediante clasificadores cuánticos basados en kernel, y el circuito cuántico variacional encuentra la función de costo para un conjunto dado de parámetros, siendo el bloque de construcción fundamental de los modelos de quantum machine learning.

Este mecanismo tiene una implicación directa para el problema de separabilidad de clases en mamografía: características morfológicas de lesiones mamarias, que resultan difícilmente distinguibles en el espacio de representación clásico, pueden volverse linealmente separables al proyectarse en el espacio de Hilbert de dimensión exponencialmente mayor que genera un circuito cuántico de n qubits.

Modelos híbridos cuántico-clásicos para diagnósticos

La aplicación de QML para el diagnóstico clínico ha comenzado a consolidarse como una línea de investigación activa. Una revisión sistemática de aplicaciones oncológicas de QML identificó implementaciones en diferentes aspectos de la oncología, incluyendo reducción de ruido en imágenes mamográficas, detección de bordes en cáncer de mama, soporte a la decisión clínica en radioterapia y clasificación de cáncer. [10]. Aunque el campo se encuentra en etapas tempranas, la tendencia apunta hacia arquitecturas híbridas donde los circuitos cuánticos se integran como componentes especializados dentro de pipelines de procesamiento predominantemente clásicos.

El trabajo de Xiang et al. (2024), ilustra esta dirección. Se presenta un enfoque de diagnóstico de cáncer de mama basado en redes neuronales convolucionales híbridas cuántico-clásicas, con el objetivo de aprovechar la capacidad de procesamiento de datos de alta dimensión y el paralelismo de la computación cuántica para incrementar la eficiencia y precisión del diagnóstico; cuando se trabaja con conjuntos de datos a gran escala y complejos, las CNN clásicas generalmente demandan grandes recursos computacionales y tiempo, y su capacidad limitada de generalización dificulta mantener un rendimiento consistente entre múltiples conjuntos de datos.

Quantum embeddings como mecanismo de codificación

El enfoque específico explorado en el presente trabajo, los quantum embeddings mediante circuitos variacionales, ha sido validado en contextos de clasificación de imágenes médicas. El proceso de codificación de un vector real en un estado cuántico puede realizarse mediante una capa de embedding variacional aplicada a un estado de referencia; la red cuántica completa, incluyendo la capa de embedding inicial y la medición final, mapea un espacio vectorial clásico a otro espacio vectorial clásico dependiente de pesos clásicos, y aunque contiene un

cómputo cuántico oculto en el circuito cuántico, es funcionalmente análoga a una red clásica profunda.

Estado actual y expectativas

Es importante reconocer el estado emergente del campo. Los algoritmos de QML han demostrado el poder de la computación cuántica para resolver problemas complejos en ciertas tareas; comparando los resultados de clasificación obtenidos con algoritmos cuánticos frente a enfoques clásicos, los algoritmos QML logran resultados comparables y confiables, e identifican biomarcadores novedosos que contribuyen a la comprensión de la biología del cáncer. Sin embargo, como señala el propio protocolo del presente trabajo, no es posible aún demostrar con métricas concluyentes el desempeño real de los modelos cuánticos debido a las restricciones tecnológicas de los dispositivos y simuladores disponibles. El valor de esta investigación reside precisamente en explorar y documentar estas posibilidades y limitaciones en un dominio de alto impacto como el diagnóstico de cáncer de mama.

1.2. Planteamiento del problema

El problema de representación en el diagnóstico asistido por mamografía

El diagnóstico asistido por computadora en mamografía enfrenta un problema estructural de representación: las características morfológicas que distinguen lesiones benignas de malignas (forma, margen, textura y distribución espacial) existen en un espacio de alta dimensionalidad cuyas relaciones internas son no lineales y difícilmente separables mediante los métodos de codificación clásicos. Como se documentó en la sección anterior, los modelos de deep learning entrenados sobre un dataset específico presentan caídas de AUC-ROC de hasta 0.44 puntos al evaluarse sobre datos externos, evidenciando que el problema no reside únicamente en la arquitectura del clasificador, sino en la calidad de la representación que este recibe como entrada.

La brecha en quantum machine learning aplicado a imágenes mamográficas reales

La computación cuántica ofrece un mecanismo alternativo de representación mediante la proyección de datos clásicos en espacios de Hilbert de dimensionalidad exponencialmente mayor. El fundamento de los kernels cuánticos es que los circuitos cuánticos pueden calcular eficientemente productos internos en espacios de Hilbert exponencialmente grandes, capturando potencialmente relaciones entre datos que resultan intratables para los métodos clásicos. Sin embargo, la evidencia experimental de esta ventaja sobre datos médicos reales es aún escasa. La aplicabilidad práctica de estos métodos sigue siendo una pregunta abierta,

particularmente más allá del contexto de problemas de juguete específicamente contruidos, y dadas las limitaciones actuales del hardware cuántico.

Los trabajos existentes que aplican QML en clasificación de cáncer de mama operan predominantemente sobre datasets tabulares de características clínicas numéricas, como Wisconsin (WDBC), SEER o GBSG, y no sobre imágenes mamográficas reales en formato DICOM. Azevedo et al. (2022), en uno de los pocos trabajos que aplica quantum transfer learning directamente sobre el dataset CBIS-DDSM, identifica explícitamente como trabajo futuro pendiente tanto la separación del análisis por tipo de hallazgo (masas vs. calcificaciones) como la evaluación de la distribución de los datos en el espacio de Hilbert resultante. A la fecha de este trabajo, ningún estudio publicado reporta la implementación y evaluación de quantum embeddings mediante Qiskit sobre imágenes mamográficas DICOM del CBIS-DDSM con análisis explícito de separabilidad de clases.

El problema de la elección del feature map y su impacto en la separabilidad

Un problema adicional que la literatura identifica pero no ha resuelto en el contexto mamográfico es la sensibilidad del rendimiento al diseño del circuito cuántico de codificación. A pesar de superar a los métodos clásicos, se obtienen resultados mixtos para el caso general entre benchmarks clásicos; los experimentos cuestionan el valor añadido general de aplicar optimización cuántica de kernels, para la cual el costo computacional adicional no necesariamente se traduce en mejor desempeño de clasificación. En cambio, se sugiere que una elección cuidadosa del feature map cuántico en conexión con una hiperparametrización apropiada puede resultar más efectiva. Esta observación implica que la elección entre ZZ-FeatureMap y PauliFeatureMap no es trivial y requiere evaluación empírica sobre el dominio específico de aplicación, en este caso las características morfológicas de mamografías.

Formulación del problema de investigación

A partir de lo anterior, el problema de investigación del presente trabajo se formula de la siguiente manera:

¿En qué medida las transformaciones cuánticas variacionales implementadas mediante ZZFeatureMap y PauliFeatureMap en Qiskit mejoran la separabilidad de características morfológicas extraídas de imágenes mamográficas del dataset CBIS-DDSM, y qué impacto tiene dicha mejora en la capacidad de clasificación binaria (benigno/maligno) de una red neuronal clásica entrenada con estos quantum embeddings, en comparación con una red entrenada con representaciones clásicas equivalentes?

Esta pregunta de investigación reconoce tres dimensiones del problema que deben abordarse

de forma integrada: la dimensión de representación (¿el espacio de Hilbert ofrece mayor separabilidad?), la dimensión de clasificación (¿esa separabilidad se traduce en mejor desempeño del clasificador?), y la dimensión de viabilidad práctica (¿las restricciones del simulador cuántico permiten una implementación reproducible sobre datos reales?). Estas tres dimensiones se corresponden directamente con los objetivos específicos 3, 5 y 6 del presente trabajo.

1.3. Justificación

Relevancia científica

El campo del quantum machine learning atraviesa una etapa crítica de consolidación en la que la comunidad científica demanda evidencia empírica rigurosa sobre dominios de aplicación reales. La mayoría de los estudios que evalúan quantum embeddings y circuitos variacionales lo hacen sobre datasets sintéticos o tabulares de baja dimensionalidad, diseñados específicamente para ilustrar propiedades teóricas del modelo. La transferencia de estos resultados a dominios de imagen médica de alta complejidad, como la mamografía digital, permanece como una brecha experimental documentada en la literatura.

El presente trabajo contribuye a cerrar esta brecha de tres formas concretas. Primero, genera evidencia empírica sobre el comportamiento de `ZZFeatureMap` y `PauliFeatureMap` de Qiskit aplicados a características extraídas de imágenes mamográficas reales en formato DICOM, un dominio que no ha sido abordado con este nivel de especificidad en la literatura consultada. Segundo, introduce el análisis de separabilidad de clases en el espacio de Hilbert —mediante kernel alignment y distancias inter e intra-clase— como métrica de evaluación intermedia en el pipeline, a diferencia de los trabajos existentes que reportan únicamente métricas de clasificación final. Tercero, retoma y ejecuta las dos líneas de trabajo futuro identificadas por Azevedo et al. (2022) como pendientes: la separación del análisis por tipo de hallazgo mamográfico y la evaluación de la distribución de datos en el espacio cuántico resultante. De esta forma, el trabajo no solo produce resultados experimentales sino que los sitúa en una trayectoria acumulativa de investigación en QML para diagnóstico médico.

Relevancia social

Como se documentó en la sección 1.1.1, el cáncer de mama constituye la principal causa de muerte por tumores malignos en mujeres en México, con 8,451 defunciones registradas en 2024 y una tasa de mortalidad que ha incrementado sostenidamente durante la última década. La detección en etapa localizada eleva la tasa de supervivencia a cinco años hasta el 99 %, mientras que los casos diagnosticados en etapa avanzada presentan tasas de apenas 30 %. Esta diferencia radical subraya que el problema central no es únicamente terapéutico

sino diagnóstico: la capacidad de identificar lesiones malignas de forma temprana, precisa y accesible determina en gran medida el desenlace clínico. En este contexto, el desarrollo de herramientas de prediagnóstico asistido más robustas tiene una justificación social directa. Si las representaciones cuánticas variacionales demuestran mejorar la separabilidad de características morfológicas mamográficas, abre una línea de investigación hacia clasificadores más generalizables entre instituciones y equipos de adquisición, atacando precisamente la limitación estructural que los métodos clásicos no han podido resolver. Aunque el presente trabajo es un prototipo académico y no un dispositivo clínico, sus resultados contribuyen al cuerpo de conocimiento que eventualmente informará el desarrollo de herramientas diagnósticas accesibles para sistemas de salud con recursos limitados como el mexicano, donde la disponibilidad de mastógrafos y especialistas en radiología mamaria sigue siendo insuficiente para cubrir la demanda poblacional.

Viabilidad técnica

La factibilidad del presente trabajo está garantizada por tres recursos disponibles desde el inicio del proyecto. El dataset CBIS-DDSM, curado y validado patológicamente, está disponible públicamente bajo licencia CC BY 3.0 en The Cancer Imaging Archive, eliminando la necesidad de procesos de adquisición, anonimización o validación clínica propios. Sus 1,566 participantes, partición train/test por categoría BI-RADS, y metadatos clínicos estructurados en archivos CSV representan una base de datos suficientemente robusta para los experimentos planteados. Para la etapa de simulación cuántica se garantiza la capacidad computacional necesaria para ejecutar el simulador Qiskit Aer con circuitos de hasta 16 qubits, rango suficiente para los experimentos planteados en los objetivos específicos. La naturaleza simulada de la implementación, lejos de ser una limitación, es una condición deliberada del diseño experimental: permite aislar el efecto de la transformación cuántica sobre la representación de los datos sin la interferencia del ruido cuántico físico, produciendo resultados interpretables y reproducibles sobre hardware estándar. Finalmente, el ecosistema tecnológico seleccionado (Qiskit, PyTorch, PyRadiomics, scikit-learn) es de código abierto, ampliamente documentado y activamente mantenido, lo que garantiza la reproducibilidad del trabajo por parte de otros investigadores.

Novedad y posicionamiento frente a trabajos previos

El posicionamiento del presente trabajo puede definirse en tres diferenciadores que, en conjunto, constituyen su aportación original. El primero es el dominio de datos, operar sobre imágenes mamográficas DICOM del CBIS-DDSM en lugar de datos tabulares clínicos como Wisconsin, SEER o GBSG, que son los datasets predominantes en la literatura de QML oncológico. El segundo es el rol del componente cuántico, utilizar el circuito variacional

exclusivamente como capa de embedding (cuya función es transformar el espacio de representación) y no como sustituto de una capa de procesamiento dentro de una CNN, lo que permite analizar de forma aislada la contribución cuántica a la separabilidad de clases. El tercero es el análisis de viabilidad, convertir las restricciones prácticas del simulador en un objetivo de investigación explícito y medible, produciendo datos cuantitativos sobre tiempo de ejecución, estabilidad de expectativas y costo del entrenamiento que la literatura existente menciona pero no sistematiza. En conjunto, estos tres diferenciadores posicionan el presente trabajo como una contribución experimental concreta a una línea de investigación activa, con potencial de servir como referencia metodológica para futuros trabajos que busquen aplicar quantum embeddings en dominios de imagen médica de alta dimensionalidad.

1.4. Objetivos

1.4.1. Objetivo general

Analizar la capacidad de las transformaciones cuánticas variacionales, implementadas mediante ZZFeatureMap y PauliFeatureMap en Qiskit sobre características morfológicas extraídas de imágenes mamográficas del dataset CBIS-DDSM, para generar espacios de representación con mayor separabilidad de clases benigno/maligno, cuantificando dicha separabilidad mediante métricas como kernel alignment, índice Davies-Bouldin y distancia Fisher, comparando contra representaciones clásicas de referencia como PCA lineal, Kernel PCA con kernel RBF y LDA, e integrando todos los embeddings resultantes como entrada de un mismo clasificador MLP para determinar si la mejora en separabilidad se traduce en una mejora en la capacidad de clasificación binaria.

1.4.2. Objetivos específicos

1. Construir un pipeline de preprocesamiento sobre el dataset CBIS-DDSM que comprenda la lectura de imágenes en formato DICOM, normalización, recorte de regiones de interés (ROI), y extracción de un vector de características compacto, diferenciando el procesamiento de casos de masas y calcificaciones.
2. Implementar y comparar al menos dos métodos de codificación cuántica de datos mediante Qiskit y el simulador Qiskit Aer, combinados con una capa variacional parametrizada, para generar quantum embeddings a partir de los vectores de características extraídos.

3. Analizar la separabilidad de las representaciones cuánticas generadas mediante métricas cuantitativas de distancia, complementadas con visualizaciones en baja dimensión del espacio de embeddings, evaluando por separado los subconjuntos de masas y calcificaciones del CBIS-DDSM.
4. Integrar los quantum embeddings generados como vector de entrada de una red neuronal clásica, para la clasificación binaria de casos benignos y malignos.
5. Comparar el desempeño del modelo híbrido cuántico-clásico frente a un modelo base-line puramente clásico de arquitectura equivalente, utilizando las métricas AUC-ROC, F1-Score, Accuracy, Precision y Recall, reportadas de forma separada para masas y calcificaciones.
6. Evaluar o analizar los beneficios o limitaciones prácticas, incluyendo restricciones computacionales y características del simulador cuántico, para determinar la viabilidad real de aplicar estas técnicas en un contexto de salud.

1.5. Alcance y limitaciones

El presente trabajo tiene como propósito central evaluar la viabilidad de las transformaciones cuánticas variacionales como mecanismo de codificación de características morfológicas extraídas de imágenes mamográficas, determinando si los quantum embeddings generados en el espacio de Hilbert mejoran la separabilidad de clases benigno/maligno frente a representaciones clásicas equivalentes. El sistema desarrollado constituye un prototipo de investigación académica, no un sistema de diagnóstico clínico, y su alcance está delimitado por los siguientes criterios:

El sistema opera exclusivamente sobre el subconjunto de imágenes del dataset CBIS-DDSM que corresponden a masas y calcificaciones con diagnóstico patológico confirmado, procesadas como imágenes recortadas de región de interés (ROI). El problema abordado es la clasificación binaria benigno/maligno; la detección de lesiones, la localización espacial y la segmentación precisa de tumores quedan explícitamente fuera del alcance. La totalidad de los experimentos cuánticos se ejecuta en simulación clásica mediante el backend Qiskit Aer, sin acceso a hardware cuántico real. Los resultados, por tanto, corresponden a condiciones ideales libres de ruido cuántico físico, lo cual es una condición deliberada del diseño experimental y no una deficiencia metodológica.

El objetivo no es superar lo existente, sino explorar lo posible

Un error frecuente en la evaluación de trabajos de QML aplicado consiste en juzgar su validez en función de si el modelo cuántico supera en precisión a los mejores modelos clásicos disponibles. Este criterio, aunque pertinente para trabajos en etapas más avanzadas de madurez tecnológica, resulta inapropiado para el momento histórico en que se encuentra la computación cuántica.

El objetivo del presente trabajo no es demostrar que los quantum embeddings superan a una CNN de última generación en AUC-ROC. El objetivo es responder una pregunta anterior y más fundamental: ¿las transformaciones cuánticas variacionales generan representaciones con mayor separabilidad intrínseca de clases cuando se aplican a características morfológicas mamográficas reales?. Un resultado positivo en separabilidad, incluso sin mejora en la métrica de clasificación final, constituye evidencia científica válida y valiosa sobre el comportamiento de estos circuitos en un dominio de alta complejidad clínica.

La analogía del ENIAC: dónde estamos en el tiempo

Para situar correctamente el alcance de este trabajo, resulta útil mencionar a un referente histórico. La primera contribución del ENIAC, más allá de su capacidad operativa, fue demostrar que era posible construir una computadora. Había muchos detractores de las tecnologías de cómputo, pero el éxito del ENIAC inspiró a otros a construir computadoras mejorando las limitaciones existentes. Como resultado, a lo largo de los años las computadoras se desarrollaron para ser más pequeñas, más capaces y más asequibles.

Completada en 1945, la ENIAC fue aclamada como un cerebro gigante por la prensa. Sin embargo, reprogramar la máquina para un nuevo problema requería días de recableado, lo que la hacía difícilmente útil para distintas tareas. No obstante, era el dispositivo de cálculo más poderoso construido hasta esa fecha.

La computación cuántica se encuentra hoy en un momento análogo al de la ENIAC en 1946. Ya existen máquinas con capacidades cuánticas reales: el procesador IBM Osprey de 433 qubits demostró progreso significativo en control de coherencia y uniformidad de fabricación; IBM, Rigetti, IonQ y Microsoft continúan avanzando en sus respectivas rutas hacia sistemas modulares y con corrección de errores. Sin embargo, al igual que en 1946 nadie sabía todavía cómo aprovechar la ENIAC para resolver problemas generales de ingeniería, hoy la comunidad científica está en el proceso de descubrir cómo formular correctamente los problemas computacionales en el lenguaje de los circuitos cuánticos, qué tipos de datos se benefician de la proyección al espacio de Hilbert, y bajo qué condiciones los embeddings cuánticos ofrecen ventajas reales sobre sus contrapartes clásicas. El presente trabajo es una contribución a ese proceso de descubrimiento, no una afirmación de superioridad tecnológica.

Las limitaciones inherentes al paradigma NISQ

La era actual de la computación cuántica está definida por los dispositivos NISQ (Noisy Intermediate-Scale Quantum), caracterizados por un número limitado de qubits, alta tasa de errores de compuerta, tiempos de coherencia cortos y conectividad restringida entre qubits. Las limitaciones inherentes del hardware NISQ (número restringido de qubits, fidelidad imperfecta de compuertas y conectividad limitada entre qubits) imponen obstáculos fundamentales, y lograr una ventaja cuántica definitiva sobre los métodos clásicos para problemas prácticos permanece sin resolver.

Una limitación teórica particularmente relevante para este trabajo es el comportamiento de los dispositivos NISQ frente a algoritmos de búsqueda. El algoritmo de Grover, considerado uno de los algoritmos cuánticos fundamentales, ofrece una aceleración cuadrática sobre la búsqueda clásica no estructurada: encuentra un elemento en una base de datos de N entradas en $O(\sqrt{N})$ operaciones frente a $O(N)$ clásico. Esta aceleración, que se extiende a problemas de optimización, representa el tipo de ventaja cuántica más prometedor para tareas de búsqueda, clasificación y optimización de hiperparámetros. Sin embargo, para la búsqueda no estructurada, se ha demostrado que los dispositivos NISQ no pueden lograr la aceleración cuadrática tipo Grover sobre las computadoras clásicas.

2. Antecedentes

2.1. Estado del arte

2.1.1. Machine Learning clásico en el diagnóstico mamográfico

El diagnóstico asistido por computadora en mamografía tiene sus orígenes en los sistemas CAD (Computer-Aided Detection/Diagnosis) desarrollados desde la década de 1990, cuyo objetivo era reducir la variabilidad inter-observador en la interpretación radiológica y apoyar la detección temprana de lesiones. Estos sistemas clásicos se estructuran en dos etapas fundamentales: la extracción manual de características y la clasificación mediante algoritmos de aprendizaje supervisado.

Extracción de características en mamografía

La extracción de características ha constituido históricamente el núcleo de los sistemas CAD clásicos. Las características derivadas de la Matriz de Co-ocurrencia de Niveles de Grises (GLCM, por sus siglas en inglés) han sido las más ampliamente utilizadas en la literatura. La técnica GLCM presenta la tasa superior de uso en extracción de características según los trabajos revisados en la literatura de sistemas CAD para detección de cáncer de mama. En clasificación, tanto los métodos de machine learning tradicionales como de deep learning se emplean para clasificar las características extraídas en diferentes clases. Además, se han utilizado descriptores de forma y margen para masas (como la excentricidad, el área y el perímetro del contorno de la lesión) y características de distribución espacial para calcificaciones, como la densidad del cluster y la varianza morfológica entre puntos. [19]

Clasificadores clásicos predominantes

El clasificador de mayor uso en este dominio ha sido la Máquina de Vectores de Soporte (SVM). Aproximadamente el 44 % de los estudios publicados entre 2020 y 2025 emplearon SVM como clasificador para la detección de cáncer de mama; SVM fue el más frecuente con imágenes de mamografía, aunque algunos estudios también lo utilizaron con ultrasonido y termografía. La preferencia por SVM se explica por su capacidad para manejar datos de alta dimensionalidad, encontrar hiperplanos de separación óptimos en espacios de características transformados mediante funciones kernel, y su robustez frente al sobreajuste en conjuntos de entrenamiento pequeños. [21]

El Random Forest (RF) ha constituido la segunda alternativa más frecuente, seguido de redes neuronales artificiales poco profundas (ANN/MLP), k-Nearest Neighbors (k-NN) y

Naive Bayes. Al comparar el desempeño de SVM, RF, ANN, NB y DT para clasificación benigno/maligno en imágenes mamográficas con características GLCM y GLRLM, los métodos SVM, RF y ANN mostraron el mejor desempeño en métricas de accuracy, sensibilidad y AUC; el rendimiento de los modelos fue sensible a la combinación de algoritmos de pre-procesamiento aplicados antes de la extracción de características. [22]

Alcances y limitaciones del enfoque clásico

El ML clásico en mamografía ha alcanzado resultados notables en condiciones controladas. Una evaluación sistemática de pipelines CNN, SVM y XGBoost sobre el dataset CBIS-DDSM reportó que una CNN (ResNet-50) alcanzó el mejor desempeño con AUC-ROC de 0.95 y sensibilidad de 89 %, seguido de XGBoost con AUC-ROC de 0.90, mientras que SVM obtuvo AUC-ROC de 0.84. [23]

Sin embargo, la limitación de estos métodos se encuentra en que la capacidad discriminativa del clasificador está completamente delimitada por la riqueza de las características extraídas manualmente. Las relaciones no lineales y de alto orden entre características morfológicas (que son precisamente las que distinguen lesiones malignas de bordes sutiles de lesiones benignas similares) resultan difícilmente capturables mediante descriptores diseñados por expertos. Esta limitación fue la que dio lugar a enfoques basados en deep learning, que aprenden representaciones directamente desde los píxeles de la imagen, y posteriormente el interés en representaciones cuánticas, que proyectan estas características en espacios de Hilbert de dimensionalidad aun mayor. El ML se ha convertido en una herramienta de imprescindible para el análisis de patrones en datos clínicos de cáncer, permitiendo identificar relaciones difícilmente detectables por métodos estadísticos convencionales; sin embargo, la eficacia de los modelos depende directamente de la calidad de la representación de los datos de entrada.

2.1.2. Deep Learning en el diagnóstico mamográfico

El avance de las CNN en mamografías

La aplicación de redes neuronales convolucionales (CNN) en el análisis de mamografías marcó un nuevo paradigma respecto a los sistemas CAD clásicos. A diferencia de los enfoques basados en features manuales, las CNN aprenden representaciones jerárquicas directamente desde los píxeles de la imagen, eliminando la dependencia de descriptores diseñados por expertos. Las CNN poco profundas fueron utilizadas para investigar el cáncer de mama desde 1995; sin embargo, fue a partir de 2012, con el surgimiento de Alex-Net y el aumento de la capacidad computacional, la disponibilidad de hardware de menor costo, los algoritmos de

código abierto y el auge del big data, cuando las CNN se volvieron predominantes en el procesamiento de imágenes médicas. Arquitecturas como VGG, ResNet, DenseNet e InceptionV3 se convirtieron en la base de la mayoría de los sistemas CAD modernos para mamografía. [24]

Resultados reportados en distintos datasets

Los modelos de deep learning han alcanzado resultados notables en condiciones controladas sobre los datasets más utilizados en la comunidad. Shen et. al [25] desarrollaron un sistema de CNN de extremo a extremo sobre CBIS-DDSM con un enfoque que aprovecha tanto anotaciones de lesiones como etiquetas de imagen completa, el mejor modelo individual alcanzó un AUC por imagen de 0.88 sobre el conjunto de prueba del CBIS-DDSM, y el promedio de cuatro modelos mejoró este resultado a un AUC de 0.91, con una especificidad de 80.1 % a una sensibilidad de 86.1 %, comparable al promedio estimado de radiólogos en Estados Unidos.

En el dominio específico de las calcificaciones, la comparación entre arquitecturas evidencia diferencias significativas según el tipo de lesión. Al evaluar modelos ResNet-50, ResNet-101 y cinco variantes de EfficientNet (B0 a B4) para clasificación de microcalcificaciones benignas y malignas usando validación cruzada de cinco pliegues sobre imágenes mamográficas con etiquetas BI-RADS confirmadas, todos los modelos EfficientNet superaron significativamente a las variantes ResNet en F1-score; adicionalmente, bajo validación externa con CBIS-DDSM, EfficientNet-B3 mantuvo su superioridad con mayor recall tanto para clases benignas como malignas. Este hallazgo nos muestra que el performace de un modelo es sensible no solo al dataset de entrenamiento sino al tipo de hallazgo mamográfico analizado, lo que refuerza la necesidad de evaluar masas y calcificaciones de forma separada. [27]

El problema de la generalización

A pesar de los resultados prometedores reportados en validación interna, existe un problema estructural que la literatura ha mencionado de manera consistente, los modelos de deep learning no generalizan entre datasets con distribuciones distintas. Wang et al. (2020) realizaron el análisis más sistemático de este fenómeno, evaluando seis modelos sobre cuatro datasets diferentes. Como se señaló en la sección 1.1.2, los modelos que reportaron AUC de validación entre 0.88 y 0.95 mostraron caídas hasta el rango de 0.44–0.65 al evaluarse sobre datos externos. La variabilidad entre lectores y la dificultad intrínseca de interpretar características radiográficas sutiles limitan frecuentemente la precisión del diagnóstico; el impacto del cambio de dominio queda evidenciado en pruebas de generalización, que marcan la necesidad de conjuntos de datos diversos durante el entrenamiento para construir herramientas de tamizaje confiables y ampliamente aplicables.

Este problema tiene raíces más profundas que la simple escasez de datos. La investigación futura debe enfocarse en enriquecer los algoritmos de deep learning, garantizar la privacidad de los datos, mejorar la interpretabilidad de los modelos y establecer la generalización para integrar exitosamente el diagnóstico asistido por deep learning en programas rutinarios de tamizaje de cáncer de mama.

La representación como problema central

El análisis de la literatura permite identificar que el problema no es la arquitectura del clasificador sino la calidad de la representación que este recibe. Los modelos de deep learning operan en el espacio de píxeles o en espacios de features aprendidos mediante backpropagation, cuya geometría está determinada por la función de pérdida de clasificación y el conjunto de entrenamiento disponible. Esta representación puede ser altamente efectiva dentro del dominio de entrenamiento pero frágil ante cambios de distribución. La pregunta que motiva el presente trabajo es si la proyección de estas características al espacio de Hilbert mediante transformaciones cuánticas variacionales puede generar representaciones con mayor separabilidad intrínseca de clases, abordando el problema desde la etapa de codificación y no desde la arquitectura del clasificador.

2.1.3. Fundamentos de quantum machine learning y codificación cuántica de datos

El origen teórico, QML como extensión de kernerls

El quantum machine learning (QML) surge de una observación fundamental establecida por Schuld y Killoran en 2019, la idea básica de la computación cuántica es sorprendentemente similar a la de los métodos kernel en machine learning, es decir, realizar eficientemente cálculos en un espacio de Hilbert de tamaño intratable. El proceso de codificar entradas en un estado cuántico se interpreta como un mapa de características no lineal que mapea datos al espacio de Hilbert cuántico; en este espacio de características, el dispositivo cuántico puede estimar productos internos de estados cuánticos para computar un kernel clásicamente intratable, el cual puede alimentar cualquier modelo clásico como una máquina de vectores de soporte. Esta formalización sentó las bases teóricas de todo el campo del QML moderno y es la justificación fundamental del presente trabajo: si el espacio de Hilbert de 2^n dimensiones generado por n qubits ofrece una geometría más favorable para la separación de clases morfológicas mamográficas, entonces la proyección cuántica aporta valor real al pipeline de clasificación. [28]

El trabajo de Havlíček et al. (2019) en IBM Nature formalizó esta idea operacionalmente,

demostrando dos algoritmos de clasificación que usan el espacio de estados cuánticos para producir mapas de características, probados en procesadores superconductores. Esto estableció el ZZFeatureMap como referencia estándar en la comunidad y demostró la posibilidad de ventaja cuántica cuando el espacio de características es grande y las funciones kernel son computacionalmente costosas de estimar clásicamente.

Circuitos cuánticos variacionales

Los circuitos cuánticos variacionales (VQC) son la arquitectura predominante en QML para el régimen NISQ actual. Los VQC son un tipo específico de circuito cuántico parametrizado (PQC) que combina circuitos cuánticos con optimizadores clásicos; son ampliamente utilizados en algoritmos cuánticos y, entre los distintos tipos de PQC, son el enfoque que típicamente optimiza sus parámetros mediante métodos variacionales, minimizando una función de costo mediante optimización híbrida cuántico-clásica. [29]

Un VQC está estructurado en tres bloques consecutivos que corresponden directamente a la arquitectura a implementar en el presente trabajo. El primero es el mapa de características $U(x)$, que codifica el vector clásico x en el estado cuántico inicial $|\phi(x)\rangle = U(x)|0\rangle^{\otimes n}$. El segundo es el ansatz variacional $W(\theta)$, que aplica rotaciones parametrizadas y compuertas de entrelazamiento entrenables, generando el estado final $|\psi(x, \theta)\rangle = W(\theta)|\phi(x)\rangle$. El tercero es la medición, que extrae el vector de valores de expectativa $\langle Z_i \rangle$ de cada qubit como salida clásica del circuito.

Los parámetros θ se optimizan mediante el método de parameter-shift, que calcula el gradiente exacto del circuito evaluándolo en dos puntos desplazados: $\nabla_{\theta} \langle O \rangle = \frac{1}{2}[\langle O \rangle_{\theta+\pi/2} - \langle O \rangle_{\theta-\pi/2}]$. Este método es diferenciable durante el proceso de entrenamiento y compatible con back-propagation clásico, lo que habilita el entrenamiento conjunto del circuito cuántico y la red neuronal clásica downstream mediante optimizadores estándar de PyTorch.

Los métodos de codificación cuántica

La elección del método de codificación es la decisión de diseño más importante en un sistema QML, ya que determina la geometría del espacio de Hilbert donde los datos quedan representados. La integración de técnicas de codificación cuántica de datos en algoritmos de machine learning clásicos contribuye a mejorar la precisión de clasificación y los valores F1, de manera particularmente notable en modelos que se benefician intrínsecamente de una representación de características enriquecida.

Los tres tipos de codificación más utilizados en la literatura son:

- **Angle encoding:** codifica cada componente del vector de características como un án-

gulo de rotación en un qubit, por ejemplo, x_i se codifica como una rotación $R_y(x_i)$ en el qubit i . Es simple pero puede requerir muchos qubits para vectores de alta dimensionalidad. Su principal ventaja es la simplicidad y la diferenciabilidad directa; su limitación es que las relaciones entre características solo se pueden expresar a través de las capas variacionales posteriores, no en la etapa de codificación.

- **ZZFeatureMap**: construido sobre el mapa angular, agrega compuertas de entrelazamiento entre pares de qubits que codifican productos de features: $e^{ix_i x_j Z_i Z_j}$. El ZZFeatureMap captura interacciones de features por pares, pero algunos datasets requieren interacciones de orden superior.
- **PauliFeatureMap**: generaliza el ZZFeatureMap agregando rotaciones alrededor de los tres ejes de Pauli (X, Y, Z) y operaciones de entrelazamiento más complejas. El PauliFeatureMap extiende la codificación utilizando rotaciones multi-eje y entrelazamiento cuántico complejo para codificar dependencias de características más profundas; es altamente expresivo, capaz de capturar interacciones de orden superior y patrones ocultos dentro de los datos, siendo particularmente poderoso para datasets donde las relaciones entre características son complejas y no lineales. Su mayor expresividad tiene como contrapartida una mayor sensibilidad al ruido cuántico, relevante incluso en simulación cuando el número de shots es limitado.

La elección entre estos métodos de codificación no es trivial y depende de la estructura de correlación de los datos de entrada. Un estudio reciente aplicó los tres métodos a la clasificación de cáncer de pulmón con QSVM, obteniendo que ZZFeatureMap alcanzó una accuracy de 0.91 y F1-score de 0.91, mientras que PauliFeatureMap logró un rendimiento consistente de 0.96 en todas las métricas incluyendo accuracy, precisión, recall y F1-score; la elección del mapa apropiado depende de dos factores principales, la naturaleza de los datos y la resiliencia al ruido del dispositivo cuántico. Estos resultados motivan la estrategia del presente trabajo de comparar ambos métodos de codificación sobre características morfológicas mamográficas.

El problema "barren plateau"

Una limitación teórica importante de los VQC profundos es el fenómeno del "barren plateau". A medida que el circuito aumenta en número de qubits y capas, la optimización se vuelve exponencialmente plana, con gradientes que convergen a cero. Esto hace el entrenamiento prácticamente imposible para circuitos de gran profundidad con una inicialización aleatoria de parámetros. Esta limitación tiene implicaciones directas para el diseño del experimento, justifica el uso de circuitos de profundidad moderada y la estrategia de inicialización cuidadosa de los parámetros θ .

El uso de Qiskit como plataforma de desarrollo

Qiskit, es el framework de código abierto de IBM para computación cuántica, provee la infraestructura completa para implementar el pipeline descrito. Su ecosistema de machine learning (qiskit-machine-learning) ofrece EstimatorQNN, que encapsula un VQC y devuelve vectores de valores de expectativa diferenciables; TorchConnector, que envuelve el QNN como una capa nn.Module de PyTorch habilitando backpropagation a través del circuito; y el simulador Qiskit Aer con backend AerSimulator, que permite ejecutar circuitos de hasta 20–30 qubits con simulación de alta fidelidad en hardware estándar. La disponibilidad de estos componentes maduros y bien documentados, combinados con el acceso a los servidores del CIC del IPN, garantiza la viabilidad técnica del prototipo experimental.

2.1.4. Modelos híbridos-cuántico-clásico en el sector salud

La aplicación de arquitecturas híbridas cuántico-clásicas en diagnóstico médico por imagen es una línea de investigación activa. Una revisión sistemática de 28 estudios publicados entre 2018 y 2024 reporta el uso prevalente de QSVM, QCNN y modelos híbridos cuántico-clásicos en aplicaciones que incluyen clasificación de tumores cerebrales, lesiones cutáneas y detección de COVID-19, demostrando resultados prometedores en accuracy, sensibilidad y especificidad; sin embargo, se identifican retos constantes en la codificación de imágenes médicas para procesamiento cuántico, la escalabilidad limitada del hardware actual y la necesidad de modelos con una mejor interpretación. [30]

Aplicaciones específicas en cáncer de mama

En el dominio de la mamografía, Xiang et al. (2024) propusieron el modelo QCCNN evaluado sobre datasets tabulares (GBSG, SEER, WDBC), reportando mejoras de hasta 5 % en accuracy respecto a CNN y regresión logística clásicas. Un trabajo más reciente aplicó un modelo ResNet50 como extractor de características y una QNN downstream sobre el dataset BreastMNIST, alcanzando 69 % de accuracy frente a 67 % de métodos híbridos comparables, reconociendo explícitamente las restricciones del hardware cuántico actual como limitante de la precisión del modelo. Estos resultados son consistentes con la propuesta del presente trabajo, la ventaja cuántica en este dominio no debe medirse en precisión final sino en la calidad de la representación generada.

Limitaciones comunes reportados

La literatura identifica tres limitaciones en la mayor parte de los trabajos revisados, los experimentos se ejecutan en simulación clásica sin ruido cuántico real; los datasets utilizados

son tabulares o imágenes muy reducidas (28×28), lejos de las mamografías DICOM de alta resolución; y ninguno analiza explícitamente la separabilidad de clases en el espacio de Hilbert como métrica de evaluación intermedia. Estas tres brechas son precisamente las que el presente trabajo aborda.

2.1.5. Trabajos específicos sobre el dataset CBIS-DDSM

El CBIS-DDSM se ha convertido como el dataset de referencia más utilizado en investigación de CADx mamográfico, precisamente por su partición train-test previamente definida, sus máscaras ROI validadas patológicamente y su licencia pública CC BY 3.0.

Trabajos clásicos en CBIS-DDSM

El trabajo de Shen et al. (2019) estableció una línea base de rendimiento con CNN sobre este dataset, alcanzando AUC de 0.91 con un ensemble de modelos ResNet y VGG. Baccouche et al. (2022) propusieron un ensemble de modelos ResNet (ResNet50V2, ResNet101V2, ResNet152V2) que alcanzó una accuracy de 95.13 % en clasificación de patología y 90.02 % en clasificación de forma sobre CBIS-DDSM, demostrando la ventaja del aprendizaje por ensemble para superar las metodologías de deep learning individuales más recientes.

Trabajos de QML en CBIS-DDSM

La revisión de la literatura no ha identificado ningún trabajo publicado que aplique circuitos cuánticos variacionales reales (con codificación de datos en estados cuánticos mediante compuertas cuánticas) directamente sobre imágenes del dataset CBIS-DDSM. El trabajo más cercano en el dominio del QML aplicado a mamografías es el de Azevedo et al. (2022), que implementa quantum transfer learning mediante redes neuronales híbridas clásico-cuánticas con angle embedding sobre el dataset BCDR (Barcelona Digital Breast Cancer Dataset), obteniendo 84 % de accuracy y señalando como trabajo futuro explícito la necesidad de evaluar la distribución de los datos en el espacio de Hilbert resultante para verificar la separabilidad de clases. Este trabajo, aunque no usa CBIS-DDSM, establece el único precedente de QML con circuitos reales en imagen mamográfica y define las brechas metodológicas que el presente trabajo aborda.

2.1.6. Tabla comparativa y brechas identificadas

Cuadro 1: Comparativa de trabajos relacionados en el estado del arte

Trabajo	Dataset	Circuito cuántico real	Framework QML	Feature map	CBIS-DDSM DICOM	Análisis separabilidad	Masas/calcs. por separado	AUC-ROC
ML clásico en mamografía								
Shen et al. (2019)	CBIS-DDSM	✗	ResNet / VGG	—	✓	✗	✗	0.91
Wang et al. (2020)	DDSM / INbreast / MIAS / UKy	✗	CNN (6 modelos)	—	Parcial	✗	✗	0.44–0.95
Baccouche et al. (2022)	CBIS-DDSM / INbreast	✗	Ensemble ResNet	—	✓	✗	✗	0.95
Optimización cuántico-inspirada en mamografía								
Bilal et al. (2025)	CBIS-DDSM / MIAS / INbreast / DDSM	Inspirado	Q-BGWO SqueezeNet SVM	+ — +	✓	✗	✗	—
Singh et al. (2025)	CBIS-DDSM	Inspirado	SeQTLBOGA SVM	+ —	✓	✗	✗	—
QML real en imagen médica (no mamografía)								
Ajlouni et al. (2023)	Kaggle Brain MRI	✓	Hybrid QCNN	PQC	✗	✗	—	—
Xiang et al. (2024)	GBSG / SEER / WDBC	✓	QCCNN (PennyLane)	Capa cuántica conv.	✗	✗	—	—
QML real en mamografía								
Azevedo et al. (2022)	BCDR	✓	QTL (PennyLane)	Angle embedding	✗	✗	✗	—
Presente trabajo								
Sánchez García (2026)	CBIS-DDSM	✓	VQC (Qiskit)	ZZFeatureMap / PauliFeatureMap	✓	✓	✓	Por det.

Notas: ✓ = cumple la condición; ✗ = no cumple; Inspirado = algoritmo cuántico-inspirado sin circuitos cuánticos reales; — = no reportado o no aplica.

La tabla anterior resume los trabajos revisados en las secciones 2.1.1 a 2.1.5 a lo largo de ocho características relevantes para el presente trabajo. La intersección de tres condiciones simultáneas (circuito cuántico variacional real, dataset CBIS-DDSM con imágenes DICOM, y análisis explícito de separabilidad diferenciado por tipo de hallazgo) no está cubierta por ningún trabajo publicado en la literatura revisada. Esta triple intersección define la contribución del presente trabajo. Adicionalmente, el presente trabajo introduce una cuarta característica no presente en ninguno de los trabajos anteriores, el uso de Qiskit con ZZ-FeatureMap y PauliFeatureMap como componente de embedding, en contraste con el uso exclusivo de PennyLane con angle embedding en los únicos trabajos de QML real en imagen médica disponibles. Esto aporta evidencia comparativa sobre el comportamiento de distintos frameworks y feature maps en este dominio clínico específico.

3. Marco Teórico

4. Metodología

4.1. Requerimientos del sistema

El sistema desarrollado en el presente trabajo constituye un prototipo de investigación cuyo diseño responde a restricciones tanto técnicas como experimentales. Los requerimientos aquí presentados fueron definidos en concordancia con los objetivos específicos del proyecto y con las características del dataset CBIS-DDSM, y se organizan en requerimientos funcionales, que describen las capacidades que el sistema debe proveer, y requerimientos no funcionales, que establecen las condiciones de calidad, reproducibilidad y viabilidad bajo las cuales el sistema debe operar.

4.1.1. Requerimientos funcionales

Cuadro 2: Requerimientos funcionales del sistema

ID	Descripción	OE	Prioridad
RF-01	Lectura de archivos DICOM mediante pydicom, extrayendo píxeles y metadatos clínicos relevantes.	OE-1	Alta
RF-02	Unificación de los cuatro archivos CSV en un DataFrame consolidado con etiqueta binaria (BENIGN / MALIGNANT).	OE-1	Media
RF-03	Tratamiento independiente de masas y calcificaciones por sus características morfológicas distintas.	OE-1, OE-3	Alta
RF-04	Normalización [0,1], CLAHE y recorte de ROI usando máscaras binarias del dataset.	OE-1	Alta
RF-05	Extracción de vector compacto (8-32 componentes) mediante PyRadiomics o CNN encoder, seguido de PCA.	OE-1	Alta
RF-06	Implementación y comparación de ZZFeatureMap y PauliFeatureMap con capa variacional en Qiskit Aer.	OE-2	Alta
RF-07	Retorno de vector de expectativas $\langle Z_i \rangle \in [-1, 1]^n$ como quantum embedding de entrada a la red clásica.	OE-2, OE-3	Alta

Cuadro 2: Requerimientos funcionales del sistema (*continuación*)

ID	Descripción	OE	Prioridad
RF-08	Medición de separabilidad mediante kernel alignment, distancias inter/intra-clase y PCA 2D.	OE-3	Alta
RF-09	Red neuronal MLP en PyTorch entrenada con embeddings cuánticos.	OE-4	Alta
RF-10	Modelo baseline clásico de arquitectura equivalente para comparación directa de desempeño.	OE-5	Media
RF-11	Reporte de AUC-ROC, F1, Accuracy, Precision y Recall separado por tipo de hallazgo y por modelo.	OE-5	Alta
RF-12	Documentación cuantitativa de restricciones del simulador: tiempo, qubits, shots y costo.	OE-6	Media

4.1.2. Requerimientos no funcionales

Cuadro 3: Requerimientos no funcionales del sistema

ID	Categoría	Descripción
RNF-01	Reproducibilidad	Semillas aleatorias fijas en numpy, PyTorch y Qiskit por experimento.
RNF-02	Reproducibilidad	Hiperparámetros centralizados en archivo de configuración con control de versiones.
RNF-03	Reproducibilidad	Partición train/test estándar del CBIS-DDSM.
RNF-04	Rendimiento	Simulador configurado con ≥ 1024 shots para estabilidad de $\langle Z_i \rangle$.
RNF-05	Escalabilidad	Circuito parametrizable: qubits (4–16), reps (1–6), shots (512–8192).
RNF-06	Portabilidad	Ejecutable en Google Colab T4, sin hardware cuántico real.
RNF-07	Propiedad intelectual	Registro del código fuente en INDAUTOR.

Bibliografía

Referencias

- [1] World Health Organization. (2025, August 14). *World Health Organization*. Retrieved from WHO Web site: <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>
- [2] Freihat, O., Sipos, D., & Kovacs, A. (2025). Global burden and projections of breast cancer incidence and mortality to 2050: a comprehensive analysis of GLOBOCAN data. *Frontiers in Public Health*, 13, 1622954. <https://doi.org/10.3389/fpubh.2025.1622954>
- [3] Breast Cancer Research Foundation. (2025). Breast cancer statistics and resources. Retrieved from <https://www.bcrf.org/breast-cancer-statistics-and-resources/>
- [4] Stop Breast Cancer. (2025). Facts & figures. Retrieved from <https://www.stopbreastcancer.org/information-center/facts-figures/>
- [5] American Cancer Society. (2024). Global cancer statistics. Retrieved from <https://pressroom.cancer.org/GlobalCancerStatistics2024>
- [6] Consultores Salud. (2025). Cáncer de mama en México. Retrieved from <https://consultorsalud.com.mx/cancer-de-mama-en-mexico/>
- [7] Instituto Nacional de Estadística y Geografía. (2025). Estadísticas de cáncer de mama. Retrieved from https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2025/EAP_CancerMama_25.pdf
- [8] National Breast Cancer Foundation. (2026). Early detection of breast cancer. Retrieved from <https://www.nationalbreastcancer.org/early-detection-of-breast-cancer/>
- [9] National Breast Cancer Foundation. (2026). Breast cancer facts & statistics. Retrieved from <https://www.nationalbreastcancer.org/breast-cancer-facts/>
- [10] Windsong Radiology. (2026). How early detection affects breast cancer survival rates. Retrieved from <https://windsongwny.com/breast-health/how-early-detection-affects-breast-cancer-survival-rates/>
- [11] Instituto Nacional de Estadística y Geografía. (2023). Estadísticas de cáncer

- de mama. Retrieved from https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2023/EAP_CMAMA23.pdf
- [12] American Cancer Society. (2024, April). Global cancer statistics 2024. Retrieved from <https://pressroom.cancer.org/GlobalCancerStatistics2024>
 - [13] Wang, X., Liang, G., Zhang, Y., Blanton, H., Bessinger, Z., & Jacobs, N. (2020). Inconsistent performance of deep learning models on mammogram classification. *Journal of the American College of Radiology*, 17(6), 796-803. <https://doi.org/10.1016/j.jacr.2020.01.006>
 - [14] Kim, J., Harper, A., McCormack, V., Sung, H., Houssami, N., Morgan, E., Mutebi, M., et al. (2025). Global patterns and trends in breast cancer incidence and mortality across 185 countries. *Nature Medicine*, 31(4), 1154-1162. <https://doi.org/10.1038/s41591-025-03502-3>
 - [15] Xiang, Q., Li, D., Hu, Z., Yuan, Y., Sun, Y., Zhu, Y., Fu, Y., Jiang, Y., et al. (2024). Quantum classical hybrid convolutional neural networks for breast cancer diagnosis. *Scientific Reports*, 14(1), 24699. <https://doi.org/10.1038/s41598-024-74778-7>
 - [16] Azevedo, V., Silva, C., & Dutra, I. (2022). Quantum transfer learning for breast cancer detection. *Quantum Machine Intelligence*, 4(1), 5. <https://doi.org/10.1007/s42484-022-00062-4>
 - [17] Sáez Ortuño, L., Forgas Coll, S., & Ferrara, M. (2026). Quantum kernel methods for marketing analytics with convergence theory and separation bounds. *Scientific Reports*, 16(1), 6645. <https://doi.org/10.1038/s41598-026-35793-y>
 - [18] Alvarez-Estevez, D. (2024). Benchmarking quantum machine learning kernel training for classification tasks. arXiv preprint arXiv:2408.10274. <https://doi.org/10.48550/arXiv.2408.10274>
 - [19] Author(s). (2021). [Article title]. *AI Magazine*, 42(4), [pages]. <https://doi.org/10.1080/08839514.2021.2001177>
 - [20] Gao, Y., Lin, J., Zhou, Y., & Lin, R. (2023). The application of traditional machine learning and deep learning techniques in mammography: a review. *Frontiers in Oncology*, 13, 1213045. <https://doi.org/10.3389/fonc.2023.1213045>
 - [21] Mashekova, A., Zhao, M. Y., Zarikas, V., Mukhmetov, O., Aidossov, N., Ng, E. Y. K., & Wang, D. (2025). Review of artificial intelligence techniques for breast cancer detec-

- tion with different modalities: Mammography, ultrasound, and thermography images. *Bioengineering*, 12(10), 1110. <https://doi.org/10.3390/bioengineering12101110>
- [22] Avci, H., & Karakaya, J. (2023). A novel medical image enhancement algorithm for breast cancer detection on mammography images using machine learning. *Diagnostics*, 13(3), 348. <https://doi.org/10.3390/diagnostics13030348>
- [23] Añez, D., Conti, G., Uriarte, J. J., Serrano-Olmedo, J.-J., Martínez-Murillo, R., & Casanova-Carvajal, O. (2025). Artificial intelligence pipeline for mammography-based breast cancer detection: An integrated systematic review and large-scale experimental validation. *Medicina*, 61(12), 2237. <https://doi.org/10.3390/medicina61122237>
- [24] Abdelhafiz, D., Yang, C., Ammar, R., et al. (2019). Deep convolutional neural networks for mammography: advances, challenges and applications. *BMC Bioinformatics*, 20(Suppl 11), 281. <https://doi.org/10.1186/s12859-019-2823-4>
- [25] Shen, L., Margolies, L. R., Rothstein, J. H., et al. (2019). Deep learning to improve breast cancer detection on screening mammography. *Scientific Reports*, 9, 12495. <https://doi.org/10.1038/s41598-019-48995-4>
- [26] Baccouche, A., Garcia-Zapirain, B., & Elmaghraby, A. S. (2022). An integrated framework for breast mass classification and diagnosis using stacked ensemble of residual neural networks. *Scientific Reports*, 12, 12259. <https://doi.org/10.1038/s41598-022-15632-6>
- [27] Shia, W. C. (2025). Deep learning-based classification of benign and malignant breast microcalcifications in mammography. *Scientific Reports*, 15, 42768. <https://doi.org/10.1038/s41598-025-27149-9>
- [28] Schuld, M., & Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504. <https://doi.org/10.1103/PhysRevLett.122.040504>
- [29] Long, C., Huang, M., Ye, X., et al. (2025). Hybrid quantum-classical-quantum convolutional neural networks. *Scientific Reports*, 15, 31780. <https://doi.org/10.1038/s41598-025-13417-1>
- [30] Radhi, E. A., Kamil, M. Y., & Mohammed, M. A. (2025). Quantum machine and deep learning for medical image classification: A systematic review of trends, methodologies, and future directions. *Iraqi Journal for Computer Science and Mathematics*, 6(2), Article 9. <https://doi.org/10.52866/2788-7421.1252>