



**INSTITUTO POLITÉCNICO
NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO**

**“Modelo de transformación cuántica variacional
de características de cáncer de mama para un
sistema híbrido de prediagnóstico”**

Trabajo Terminal

TT No. 2026 – B039

Presenta

Miguel Alexander Sánchez García

Directores

Dra. Ana María Winfield Reyes

Dr. Jesús Yaljá Montiel Pérez



19 Mayo de 2026



**INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA**



No. de TT 2026 – B039

19 de Mayo de 2026

Documento Técnico

**“Modelo de Transformación Cuántica Variacional para
un Sistema Híbrido de Prediagnóstico de Cáncer de Mama”**

Presenta

Sánchez García Miguel Alexander¹

Directores

Dra. Winfield Reyes Ana María

Dr. Montiel Pérez Jesús Yaljá

¹msanchezg1904@alumno.ipn.mx

Índice

Resumen	6
Abstract	7
1. Panorama General	8
1.1. Introducción	8
1.1.1. Contexto clínico del cáncer de mama	8
1.1.2. Limitaciones de los métodos clásicos de diagnóstico asistido	10
1.1.3. Computación cuántica como alternativa	11
1.2. Planteamiento del problema	13
1.3. Justificación	14
1.4. Objetivos	16
1.4.1. Objetivo general	16
1.4.2. Objetivos específicos	17
1.5. Alcance y limitaciones	17
2. Antecedentes	20
2.1. Estado del arte	20
2.1.1. Machine Learning clásico en el diagnóstico mamográfico	20
2.1.2. Deep Learning en el diagnóstico mamográfico	21
2.1.3. Fundamentos de quantum machine learning y codificación cuántica de datos	23
2.1.4. Modelos híbridos-cuántico-clásico en el sector salud	25
2.1.5. Trabajos específicos sobre el dataset CBIS-DDSM	26
2.1.6. Tabla comparativa y brechas identificadas	27
3. Marco Teórico	30
3.1. Fundamentos de computación cuántica	30
3.1.1. El qubit como unidad de información cuántica	30
3.1.2. Compuertas cuánticas de un qubit	31
3.1.3. Sistemas de múltiples qubits y entrelazamiento	32
3.1.4. Medición y valores de expectativa	33
3.2. Circuitos cuánticos variacionales y <i>quantum embeddings</i>	33
3.2.1. Circuitos cuánticos parametrizados (PQC)	33
3.2.2. El <i>feature map</i> como mapeo no lineal al espacio de Hilbert	34

3.2.3.	<i>ZZFeatureMap</i> : evolución de Pauli-Z de segundo orden	34
3.2.4.	<i>PauliFeatureMap</i> : generalización multi-eje	35
3.2.5.	El <i>ansatz</i> variacional: RealAmplitudes	36
3.2.6.	El <i>quantum embedding</i> : vector de salida del circuito	36
3.2.7.	El método <i>parameter-shift</i> para el cálculo del gradiente	37
3.3.	Red neuronal clásica e integración Qiskit–PyTorch	37
3.3.1.	Perceptrón multicapa (MLP)	37
3.3.2.	Ponderación de clases para datos desbalanceados	38
3.3.3.	Integración Qiskit–PyTorch mediante TorchConnector	39
3.3.4.	Implementación en Qiskit 2.x	39
3.4.	Métricas de separabilidad y evaluación	40
3.4.1.	<i>Kernel-Target Alignment</i> (KTA)	40
3.4.2.	<i>Geometric difference</i>	41
3.4.3.	Índice Davies-Bouldin	41
3.4.4.	Distancia Fisher	42
3.4.5.	Visualización <i>t-SNE</i>	42
3.4.6.	Métricas de clasificación	43
3.4.7.	Análisis de correlación separabilidad–clasificación	43
4.	Metodología	45
4.1.	Requerimientos del sistema	45
4.1.1.	Requerimientos funcionales	45
4.1.2.	Requerimientos no funcionales	47
4.2.	Descripción general del proceso	48
4.3.	Módulo 1: Lectura de datos	50
4.4.	Módulo 2: Preprocesamiento de imagen	51
4.5.	Módulo 3: Extracción de características	51
4.6.	Módulo 4: Selección y escalado	52
4.7.	Módulo 5: Transformación	53
4.8.	Módulo 6: Clasificación	54
4.9.	Módulo 7: Evaluación comparativa	54
5.	Análisis Exploratorio de Datos	55
5.1.	Validación y limpieza de los datos	55
5.2.	Análisis de la variable objetivo	56

5.2.1.	Distribución de clases y balance	56
5.2.2.	Distribución BI-RADS	57
5.2.3.	Análisis de subtlety	58
5.3.	Análisis de variables clínicas	58
5.3.1.	Densidad mamaria	58
5.3.2.	Lateralidad y vista mamográfica	59
5.3.3.	Morfología de masas	60
5.3.4.	Morfología de calcificaciones	60
5.3.5.	Correlaciones entre variables clínicas	61
5.4.	Análisis de imágenes DICOM	62
5.4.1.	Dimensiones y características técnicas	62
5.4.2.	Variabilidad inter-escáner	63
5.4.3.	Distribución de intensidades de píxeles	64
5.4.4.	Galería de casos representativos	65
5.5.	Hallazgos principales y consideraciones para el modelado	67
Bibliografía		69

Resumen

El cáncer de mama representa la principal causa de muerte por tumores malignos en mujeres en México, con 8,451 defunciones registradas en 2024. La detección temprana mediante mamografía es el factor determinante para incrementar las tasas de supervivencia; sin embargo, los modelos de diagnóstico asistido por computadora basados en *deep learning* presentan caídas de hasta 0.44 puntos en AUC-ROC al evaluarse sobre datos externos, evidenciando limitaciones estructurales en la calidad de las representaciones clásicas de características morfológicas mamográficas.

El presente trabajo evalúa la viabilidad de las transformaciones cuánticas variacionales como mecanismo de codificación alternativo. Se implementan dos *feature maps* cuánticos — *ZZFeatureMap* y *PauliFeatureMap*— sobre características radiómicas extraídas de imágenes mamográficas del dataset CBIS-DDSM (1,566 pacientes, formato DICOM) mediante Qiskit y el simulador Qiskit Aer. Los *quantum embeddings* generados —vectores de valores de expectativa $\langle Z_i \rangle \in [-1, 1]^n$ — se integran como entrada de un clasificador MLP en PyTorch mediante TorchConnector. El sistema se evalúa bajo cinco condiciones experimentales: *baseline* crudo, PCA lineal, Kernel PCA con kernel RBF, *ZZFeatureMap* y *PauliFeatureMap*, todas sobre el mismo vector de entrada y el mismo clasificador, garantizando que la única variable independiente sea la transformación aplicada.

La separabilidad de cada representación se cuantifica mediante *kernel-target alignment*, *geometric difference* respecto al kernel RBF clásico, índice Davies-Bouldin y distancia Fisher; el desempeño clasificatorio se reporta mediante AUC-ROC y F1-Score, diferenciados por tipo de hallazgo (masas y calcificaciones). El objetivo central no es superar la precisión del estado del arte clásico, sino determinar si el espacio de Hilbert inducido por los circuitos variacionales ofrece mayor separabilidad intrínseca de clases y documentar la viabilidad práctica de estas técnicas sobre datos médicos reales en el régimen NISQ actual.

Keywords: Variational quantum circuits, quantum embeddings, *ZZFeatureMap*, *PauliFeatureMap*, breast cancer diagnosis, CBIS-DDSM, kernel-target alignment, geometric difference, hybrid quantum-classical systems.

Abstract

Breast cancer represents the leading cause of death from malignant tumors in women in Mexico, with 8,451 registered deaths in 2024. Early detection through mammography is the determining factor for improving survival rates; however, computer-aided diagnosis models based on deep learning exhibit AUC-ROC drops of up to 0.44 points when evaluated on external data, revealing structural limitations in the quality of classical representations of mammographic morphological features.

This work evaluates the viability of variational quantum transformations as an alternative encoding mechanism. Two quantum feature maps, *ZZFeatureMap* and *PauliFeatureMap*, are implemented over radiomic features extracted from mammographic images of the CBIS-DDSM dataset (1,566 patients, DICOM format) using Qiskit and the Qiskit Aer simulator. The generated quantum embeddings, expectation value vectors $\langle Z_i \rangle \in [-1, 1]^n$, are integrated as input to a PyTorch MLP classifier via TorchConnector. The system is evaluated under five experimental conditions: raw baseline, linear PCA, Kernel PCA with RBF kernel, *ZZFeatureMap*, and *PauliFeatureMap*, all sharing the same input vector and the same classifier, ensuring that the only independent variable is the applied transformation.

The separability of each representation is quantified through kernel-target alignment, geometric difference with respect to the classical RBF kernel, Davies-Bouldin index, and Fisher distance; classification performance is reported through AUC-ROC and F1-Score, differentiated by finding type (masses and calcifications). The central objective is not to surpass state-of-the-art classical accuracy, but to determine whether the Hilbert space induced by variational circuits offers greater intrinsic class separability and to document the practical viability of these techniques on real medical data in the current NISQ era.

1. Panorama General

1.1. Introducción

1.1.1. Contexto clínico del cáncer de mama

El cáncer de mama es una enfermedad caracterizada por la proliferación descontrolada de células en el tejido mamario, que forma tumores malignos con capacidad de expandirse sistemáticamente si no recibe tratamiento oportuno. A nivel mundial, constituye el cáncer más frecuente diagnosticado en mujeres y la principal causa de muerte por cáncer femenino, superando incluso el cáncer de pulmón en incidencia global.


Según los datos de GLOBOCAN 2022 de la Agencia Internacional para la Investigación sobre el Cáncer (IARC), en 2022 se registraron aproximadamente 2.3 millones casos nuevos de cáncer de mama y una mortalidad de alrededor de 670,000 mujeres a nivel mundial [2]. El cáncer de mama representa actualmente uno de cada cuatro cánceres en mujeres a nivel global, y desde 2008 la incidencia mundial ha aumentado más de 20%, mientras que la mortalidad se ha incrementado en un 14% [3]. Las proyecciones son igualmente preocupantes: si las tasas nacionales actuales se mantienen estables, para 2050 el número de casos nuevos y defunciones por cáncer de mama a nivel mundial aumentará más de 50% y 70% respectivamente, impulsando principalmente por el crecimiento y envejecimiento de la población [4]

Las disparidades regionales son significativas y tienen implicaciones directas para el desarrollo de herramientas de diagnóstico asistido. En países de bajos ingresos, la tasa de mortalidad por cáncer de mama puede ser el doble que en países más desarrollados, a pesar de tener una incidencia considerablemente menor, lo que refleja la falta o inadecuada infraestructura de servicios de detección temprana y tratamiento oportuno [5]. Esta brecha evidencia que el problema no es únicamente epidemiológico, sino también tecnológico y de acceso a herramientas diagnósticas.


Panorama en México

En el contexto nacional, la situación es igualmente urgente. Según datos del Instituto Nacional de Estadística y Geografía (INEGI), en 2024 el cáncer de mama fue la principal causa de muerte por tumores malignos en México, con aproximadamente 8,500 defunciones registradas, de los cuales el 99.2% correspondieron a mujeres, con una tasa de mortalidad de 18.7 por cada 100,000 mujeres de 20 años o más [6]. Este indicador refleja un deterioro; durante la última década, la tasa de defunciones por cáncer de mama se incrementó de 15.69 en 2015 a 18.68 en 2024 por cada 100,000 mujeres de 20 años o más como se muestra en la Figura 1.1.1a. [7]

La detección temprana como factor determinante



(a) Tasa de mortalidad en México (INEGI 2025) desde 2015 al 2024 [7]



(b) Incidencia y mortalidad por entidad federativa en México en 2025 (INEGI 2025) [7]

El elemento clínico más relevante para justificar el desarrollo de sistemas de prediagnóstico automatizado es el impacto radical de la detección temprana sobre la supervivencia. Según la American Cancer Society, cuando el cáncer de mama se detecta en etapa temprana y se encuentra en una fase localizada, la tasa de supervivencia relativa a cinco años es del 99 % [8]. Esta cifra contrasta drásticamente con los casos en etapa avanzada con metastásis, donde la supervivencia a cinco años cae a 30 %. Las mujeres que reciben tamizaje regular de cáncer de mama presentan una tasa de mortalidad de un 26 % menor que las que no se someten a cribado.

La mamografía es el instrumento central de detección temprana. Es el único método de tamizaje demostrado para reducir las muertes por cáncer de mama según el American College of Radiology, y las tasas de mortalidad por esta enfermedad disminuyeron un 42 % entre 1989 y 2021, en parte gracias a la detección temprana mediante cribado mamográfico. [10]. Sin embargo, la interpretación manual de mamografías presenta limitaciones inherentes: la variabilidad inter-observador entre radiólogos, la dificultad de detección en tejidos de alta densidad mamaria, y la carga de trabajo creciente en los sistemas de salud constituyen factores que motivan el desarrollo de sistemas de diagnóstico asistido por computadora (CADx).

En México, la disponibilidad de infraestructura diagnóstica sigue siendo un desafío. En 2021 se registraron 1,281 mastógrafos en el país, de los cuales 41.1 % se encontraba en instituciones de salud y seguridad social, 36.1 % en establecimientos particulares y 22.8 % en servicios para población sin derechohabencia [11]. Esta distribución limitada, combinada con el incremento sostenido en la mortalidad, subraya la necesidad de desarrollar herramientas tecnológicas que amplíen la capacidad diagnóstica del sistema de salud, haciendo más eficiente y accesible la interpretación de estudios mamográficos.

Es en este contexto donde el presente trabajo propone explorar el uso de transformaciones cuánticas variacionales sobre características extraídas de mamografías del dataset CBIS-DDSM, con el fin de evaluar si estas representaciones mejoran la separación de clases benigno/maligno cuando se integran como entrada de una red neuronal clásica, contribuyendo al desarrollo de herramientas de prediagnóstico asistido más robustas.

1.1.2. Limitaciones de los métodos clásicos de diagnóstico asistido

El diagnóstico asistido por computadora (CADx) en mamografía ha experimentado un notable desarrollo durante las últimas dos décadas, impulsado principalmente por el avance de las redes neuronales convolucionales (CNN) y las técnicas de deep learning. No obstante, a pesar de los resultados prometedores reportados en condiciones controladas, estos métodos presentan limitaciones estructurales que restringen su aplicabilidad clínica generalizada.

Variabilidad e inconsistencia diagnóstica

La interpretación manual de mamografías está sujeta a una variabilidad inherente entre radiólogos. La variabilidad entre lectores y la dificultad intrínseca de interpretar características radiográficas sutiles limitan con frecuencia la precisión del diagnóstico mamográfico [12], lo que motivó el desarrollo de sistemas CADx automatizados. Sin embargo, los modelos de deep learning han heredado parte de esta inconsistencia de una forma distinta: en lugar de variar entre observadores humanos, varían entre conjuntos de datos.

El estudio de Wang et al. (2020), publicado en el Journal of the American College of Radiology, es uno de los trabajos más citados al respecto. Los tres modelos publicados con alto rendimiento reportaron puntuaciones AUC-ROC de validación entre 0.88 y 0.95 en el conjunto de datos de entrenamiento; sin embargo, al evaluarse sobre tres conjuntos de datos externos, el rendimiento de los seis modelos disminuyó significativamente, obteniéndose valores de AUC-ROC de apenas entre 0.44 y 0.65. Este hallazgo es especialmente relevante para la presente investigación, ya que demuestra que el alto rendimiento de un modelo de deep learning en un dataset específico no garantiza su transferibilidad a datos con distribuciones distintas, una condición inevitable en entornos clínicos reales donde los equipos de adquisición, las poblaciones de pacientes y los protocolos de imagen varían considerablemente.

Limitaciones de interpretabilidad

Es importante abordar los desafíos asociados a la implementación de deep learning en entornos clínicos; la investigación futura debe enfocarse en mejorar la interpretabilidad de los modelos y garantizar su generalización para integrar exitosamente el diagnóstico asistido por deep learning en programas rutinarios de tamizaje de cáncer de mama. [14]. La naturaleza de caja negra de las CNN profundas genera desconfianza clínica, ya que los radiólogos no pueden verificar el razonamiento que conlleva a una predicción, lo cual es un requisito indispensable para cualquier herramienta de

apoyo a la decisión médica.

Alta dimensionalidad y representación de características

Desde una perspectiva de ciencia de datos, los métodos clásicos enfrentan el desafío de la alta dimensionalidad de las imágenes mamográficas. El sobreajuste ocurre cuando los modelos aprenden demasiado bien los detalles de los datos de entrenamiento pero no generalizan adecuadamente para realizar buenas predicciones sobre datos no vistos, lo que sucede típicamente cuando el tamaño del conjunto de entrenamiento es demasiado pequeño en comparación con el número de parámetros del modelo que deben aprenderse. Las técnicas de aumento de datos y regularización mitigan parcialmente este problema, pero no lo resuelven de forma fundamental, especialmente en datasets de tamaño moderado como el CBIS-DDSM.

En conjunto, estas limitaciones evidencian la necesidad de explorar nuevos paradigmas de representación de datos que superen las restricciones del aprendizaje clásico, particularmente en lo que respecta a la separabilidad de características en espacios de alta dimensión.

1.1.3. Computación cuántica como alternativa

Ante las limitaciones descritas, la computación cuántica emerge como un paradigma complementario que ofrece mecanismos cualitativamente distintos para la representación y transformación de datos clínicos. Su propuesta central no es sustituir a los métodos clásicos, sino enriquecer la representación de los datos en etapas específicas del pipeline de análisis, particularmente en la codificación de características.

El espacio de Hilbert como espacio de representación

El fundamento teórico de la ventaja cuántica en tareas de clasificación reside en la naturaleza del espacio en el que opera un circuito cuántico. Un circuito de codificación $U(\mathbf{x})$ define un mapeo no lineal $\phi : \mathbb{R}^n \rightarrow \mathcal{H}$ que transforma un vector de características clásico $\mathbf{x} \in \mathbb{R}^n$ en un estado cuántico $|\phi(\mathbf{x})\rangle$ en el espacio de Hilbert $\mathcal{H}$. Este espacio no es simplemente una versión de mayor dimensión del espacio clásico de entrada: es un espacio de representación cualitativamente distinto, cuya geometría está determinada por los productos internos cuánticos $|\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$ entre estados, y no por distancias euclidianas entre vectores; asimismo la estructura de este espacio depende directamente del diseño del circuito de codificación.

Este mecanismo tiene una implicación directa para el problema de separabilidad de clases en mamografía. Características morfológicas de lesiones mamarias que resultan difícilmente distinguibles en el espacios de representación clásicos pueden adquirir una representación más favorable en el espacio de Hilbert inducido por el circuito cuántico, no porque ese espacio sea necesariamente de mayor dimensión, sino porque el mapeo ϕ introduce correlaciones de

orden superior entre características que los métodos de codificación clásicos no capturan. Determinar si esta propiedad se cumple para las características morfológicas del dataset CBIS-DDSM, y bajo qué condiciones de diseño del circuito, es precisamente el objeto de estudio del presente trabajo.

Modelos híbridos cuántico-clásicos para diagnósticos

La aplicación de QML para el diagnóstico clínico ha comenzado a consolidarse como una línea de investigación activa. Una revisión sistemática de aplicaciones oncológicas de QML identificó implementaciones en diferentes aspectos de la oncología, incluyendo reducción de ruido en imágenes mamográficas, detección de bordes en cáncer de mama, soporte a la decisión clínica en radioterapia y clasificación de cáncer. [10]. Aunque el campo se encuentra en etapas tempranas, la tendencia apunta hacia arquitecturas híbridas donde los circuitos cuánticos se integran como componentes especializados dentro de pipelines de procesamiento predominantemente clásicos.

El trabajo de Xiang et al. (2024), ilustra esta dirección. Se presenta un enfoque de diagnóstico de cáncer de mama basado en redes neuronales convolucionales híbridas cuántico-clásicas, con el objetivo de aprovechar la capacidad de procesamiento de datos de alta dimensión y el paralelismo de la computación cuántica para incrementar la eficiencia y precisión del diagnóstico; cuando se trabaja con conjuntos de datos a gran escala y complejos, las CNN clásicas generalmente demandan grandes recursos computacionales y tiempo, y su capacidad limitada de generalización dificulta mantener un rendimiento consistente entre múltiples conjuntos de datos.

Quantum embeddings como mecanismo de codificación

El enfoque específico explorado en el presente trabajo, los quantum embeddings mediante circuitos variacionales, ha sido validado en contextos de clasificación de imágenes médicas. El proceso de codificación de un vector real en un estado cuántico puede realizarse mediante una capa de embedding variacional aplicada a un estado de referencia; la red cuántica completa, incluyendo la capa de embedding inicial y la medición final, mapea un espacio vectorial clásico a otro espacio vectorial clásico dependiente de pesos clásicos, y aunque contiene un cómputo cuántico oculto en el circuito cuántico, es funcionalmente análoga a una red clásica profunda.

Estado actual y expectativas

Es importante reconocer el estado emergente del campo. Los algoritmos de QML han demostrado el poder de la computación cuántica para resolver problemas complejos en ciertas tareas; comparando los resultados de clasificación obtenidos con algoritmos cuánticos frente a enfoques clásicos, los algoritmos QML logran resultados comparables y confiables, e identifican biomarcadores novedosos que contribuyen a la comprensión de la biología del cáncer. Sin embargo, como señala el propio protocolo del presente trabajo, no es posible aún demostrar con métricas concluyentes el desempeño real de los modelos cuánticos debido a las restricciones tecnológicas de los dispositivos y simuladores disponibles. El valor de esta investigación reside precisamente en explorar y documentar estas posibilidades y limitaciones

en un dominio de alto impacto como el diagnóstico de cáncer de mama.

1.2. Planteamiento del problema

El problema de representación en el diagnóstico asistido por mamografía

El diagnóstico asistido por computadora en mamografía enfrenta un problema estructural de representación: las características morfológicas que distinguen lesiones benignas de malignas (forma, margen, textura y distribución espacial) existen en un espacio de alta dimensionalidad cuyas relaciones internas son no lineales. Los métodos de codificación clásicos predominantes, como la normalización de píxeles, la extracción de descriptores texturales (GLCM, LBP) o la proyección lineal mediante PCA, representan los datos en espacios euclidianos donde la similitud entre puntos se mide por distancias lineales. Esta geometría euclidiana es insuficiente para capturar correlaciones de orden superior entre características morfológicas: dos lesiones con descriptores individualmente similares pueden tener patrones de co-ocurrencia entre características cualitativamente distintos, diferencia que una representación lineal no puede resolver. Como consecuencia, las clases benigna y maligna permanecen entremezcladas en el espacio de representación clásico, dificultando la tarea del clasificador. Este resultado se manifiesta en la falta de generalización de los modelos, como se documentó en la sección anterior, modelos de deep learning entrenados sobre un dataset específico presentan caídas de AUC-ROC de hasta 0.44 puntos al evaluarse sobre datos externos, evidenciando que el problema no reside únicamente en la arquitectura del clasificador, sino en la calidad de la representación que este recibe como entrada.

La brecha en quantum machine learning aplicado a imágenes mamográficas reales

La computación cuántica ofrece un mecanismo alternativo de representación cualitativamente distinto al clásico. Un circuito de codificación $U(\mathbf{x})$ define un mapeo no lineal $\phi : \mathbb{R}^n \rightarrow \mathcal{H}$ que transforma un vector de características clásico $\mathbf{x}$ en un estado cuántico $|\phi(\mathbf{x})\rangle$ en el espacio de Hilbert $\mathcal{H}$. Este espacio no es una versión ampliada del espacio clásico de entrada, es un espacio de representación con una geometría fundamentalmente diferente, en la que la similitud entre puntos está determinada por productos internos cuánticos $|\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$ y no por distancias euclidianas. El mapeo ϕ introduce correlaciones de orden superior entre características que los métodos de codificación clásicos no capturan, lo que puede sugerir una representación más favorable de las clases en ese espacio de representación. Esta propiedad es la que motiva el uso de circuitos cuánticos variacionales como mecanismo de codificación en el presente trabajo, no se busca un espacio más grande, sino un espacio con una estructura geométrica distinta que potencialmente mejore la separabilidad intrínseca de las clases benigna y maligna. Sin embargo, la evidencia experimental de esta ventaja sobre datos médicos reales es aún escasa. La aplicación práctica de estos métodos sigue siendo una pregunta abierta, particularmente más allá de problemas de prueba específicamente contruidos y dadas las limitaciones actuales del hardware cuántico.

El problema de la elección del feature map y su impacto en la separabilidad

Un problema adicional que la literatura identifica pero no ha resuelto en el contexto mamográfico es la sensibilidad del rendimiento al diseño del circuito cuántico de codificación. A pesar de superar a los métodos clásicos, se obtienen resultados mixtos para el caso general entre benchmarks clásicos; los experimentos cuestionan el valor añadido general de aplicar optimización cuántica de kernels, para la cual el costo computacional adicional no necesariamente se traduce en mejor desempeño de clasificación. En cambio, se sugiere que una elección cuidadosa del feature map cuántico en conexión con una hiperparametrización apropiada puede resultar más efectiva. Esta observación implica que la elección entre `ZZFeatureMap` y `PauliFeatureMap` no es trivial y requiere evaluación empírica sobre el dominio específico de aplicación, en este caso las características morfológicas de mamografías.

Formulación del problema de investigación

A partir de lo anterior, el problema de investigación del presente trabajo se formula de la siguiente manera:

¿En qué medida las transformaciones cuánticas variacionales implementadas mediante `ZZFeatureMap` y `PauliFeatureMap` en Qiskit mejoran la separabilidad de características morfológicas extraídas de imágenes mamográficas del dataset CBIS-DDSM, y qué impacto tiene dicha mejora en la capacidad de clasificación binaria (benigno/maligno) de una red neuronal clásica entrenada con estos quantum embeddings, en comparación con una red entrenada con representaciones clásicas equivalentes?

Esta pregunta de investigación reconoce tres dimensiones del problema que deben abordarse de forma integrada: la dimensión de representación (¿el espacio de Hilbert ofrece mayor separabilidad?), la dimensión de clasificación (¿esa separabilidad se traduce en mejor desempeño del clasificador?), y la dimensión de viabilidad práctica (¿las restricciones del simulador cuántico permiten una implementación reproducible sobre datos reales?). Estas tres dimensiones se corresponden directamente con los objetivos específicos 3, 5 y 6 del presente trabajo.

1.3. Justificación

Relevancia científica

El campo del quantum machine learning atraviesa una etapa crítica de consolidación en la que la comunidad científica demanda evidencia empírica rigurosa sobre dominios de aplicación reales. La mayoría de los estudios que evalúan quantum embeddings y circuitos variacionales lo hacen sobre datasets sintéticos o tabulares de baja dimensionalidad, diseñados específicamente para ilustrar propiedades teóricas del modelo. La transferencia de estos resultados a dominios de imagen médica de alta complejidad, como la mamografía digital, permanece como una brecha experimental documentada en la literatura.

El presente trabajo contribuye a cerrar esta brecha de tres formas concretas. Primero, genera evidencia empírica sobre el comportamiento de ZZFeatureMap y PauliFeatureMap de Qiskit aplicados a características extraídas de imágenes mamográficas reales en formato DICOM. Segundo, introduce el análisis de separabilidad de clases en el espacio de Hilbert, mediante kernel alignment y distancias inter e intra-clase, como métricas de evaluación en el pipeline, a diferencia de los trabajos existentes que reportan únicamente métricas de clasificación final. Tercero, retoma y ejecuta las dos líneas de trabajo futuro identificadas por Azevedo et al. (2022) como pendientes: la separación del análisis por tipo de hallazgo mamográfico y la evaluación de la distribución de datos en el espacio cuántico resultante. De esta forma, el trabajo no solo produce resultados experimentales sino que los sitúa en una trayectoria acumulativa de investigación en QML para diagnóstico médico.

Relevancia social

Como se documentó en la sección 1.1.1, el cáncer de mama constituye la principal causa de muerte por tumores malignos en mujeres en México, con 8,451 defunciones registradas en 2024 y una tasa de mortalidad que ha incrementado sostenidamente durante la última década. La detección en etapa localizada eleva la tasa de supervivencia a cinco años hasta el 99 %, mientras que los casos diagnosticados en etapa avanzada presentan tasas de apenas 30 %. Esta diferencia radical subraya que el problema central no es únicamente terapéutico sino diagnóstico: la capacidad de identificar lesiones malignas de forma temprana, precisa y accesible determina en gran medida el desenlace clínico. En este contexto, el desarrollo de herramientas de prediagnóstico asistido más robustas tiene una justificación social directa. Si las representaciones cuánticas variacionales demuestran mejorar la separabilidad de características morfológicas mamográficas, abre una línea de investigación hacia clasificadores más generalizables entre instituciones y equipos de adquisición, atacando precisamente la limitación estructural que los métodos clásicos no han podido resolver. Aunque el presente trabajo es un prototipo académico y no un dispositivo clínico, sus resultados contribuyen al cuerpo de conocimiento que eventualmente informará el desarrollo de herramientas diagnósticas accesibles para sistemas de salud con recursos limitados como el mexicano, donde la disponibilidad de mastógrafos y especialistas en radiología mamaria sigue siendo insuficiente para cubrir la demanda poblacional.

Viabilidad técnica

La factibilidad del presente trabajo está garantizada por tres recursos disponibles desde el inicio del proyecto. El dataset CBIS-DDSM, curado y validado patológicamente, está disponible públicamente bajo licencia CC BY 3.0 en The Cancer Imaging Archive, eliminando la necesidad de procesos de adquisición, anonimización o validación clínica propios. Sus 1,566 participantes, partición train/test por categoría BI-RADS, y metadatos clínicos estructurados en archivos CSV representan una base de datos suficientemente robusta para los experimentos planteados. Para la etapa de simulación cuántica se garantiza la capacidad computacional necesaria para ejecutar el simulador Qiskit Aer con circuitos de hasta 16 qubits, rango suficiente para los experimentos planteados en los objetivos específicos. La naturaleza simu-

lada de la implementación, lejos de ser una limitación, es una condición deliberada del diseño experimental: permite aislar el efecto de la transformación cuántica sobre la representación de los datos sin la interferencia del ruido cuántico físico, produciendo resultados interpretables y reproducibles sobre hardware estándar. Finalmente, el ecosistema tecnológico seleccionado (Qiskit, PyTorch, PyRadiomics, scikit-learn) es de código abierto, ampliamente documentado y activamente mantenido, lo que garantiza la reproducibilidad del trabajo por parte de otros investigadores.

Novedad y posicionamiento frente a trabajos previos

El posicionamiento del presente trabajo puede definirse en tres diferenciadores que, en conjunto, constituyen su aportación original. El primero es el dominio de datos, operar sobre imágenes mamográficas DICOM del CBIS-DDSM en lugar de datos tabulares clínicos como Wisconsin, SEER o GBSG, que son los datasets predominantes en la literatura de QML oncológico. El segundo es el rol del componente cuántico, utilizar el circuito variacional exclusivamente como capa de embedding y no como sustituto de una capa de procesamiento dentro de una CNN, lo que permite analizar de forma aislada la contribución cuántica a la separabilidad de clases. El tercero es el análisis de viabilidad, convertir las restricciones prácticas del simulador en un objetivo de investigación explícito y medible, produciendo datos cuantitativos sobre tiempo de ejecución, estabilidad de expectativas y costo del entrenamiento que la literatura existente menciona pero no sistematiza. En conjunto, estos tres diferenciadores posicionan el presente trabajo como una contribución experimental concreta a una línea de investigación activa, con potencial de servir como referencia metodológica para futuros trabajos que busquen aplicar quantum embeddings en dominios de imagen médica de alta dimensionalidad.

1.4. Objetivos

1.4.1. Objetivo general

Analizar la capacidad de las transformaciones cuánticas variacionales implementadas mediante *ZZFeatureMap* y *PauliFeatureMap* en Qiskit, sobre características morfológicas extraídas de imágenes mamográficas del dataset CBIS-DDSM, para generar espacios de representación con mayor separabilidad de clases benigno/maligno, cuantificando dicha separabilidad mediante *kernel-target alignment*, *geometric difference* respecto al kernel RBF clásico, índice Davies-Bouldin y distancia Fisher, comparando contra representaciones clásicas de referencia (sin transformación, PCA lineal y Kernel PCA con kernel RBF) sobre el mismo vector de características seleccionadas y escaladas, e integrando todos los embeddings resultantes como entrada de un mismo clasificador MLP para determinar si la mejora en separabilidad se traduce en una mejora en la capacidad de clasificación binaria.

1.4.2. Objetivos específicos

1. Construir un pipeline de preprocesamiento sobre el dataset CBIS-DDSM que comprenda la lectura de imágenes en formato DICOM, normalización, recorte de región de interés (ROI), extracción de un vector de características mediante features radiómicas (PyRadiomics) o un encoder CNN preentrenado, y selección de las k características más discriminativas mediante SelectKBest con escalado angular al rango $[0, \pi]$, diferenciando el procesamiento de casos de masas y calcificaciones como subproblemas independientes.
2. Implementar las cinco condiciones de transformación del experimento sobre el mismo vector de entrada: (a) sin transformación como *baseline* crudo; (b) PCA lineal como *baseline* lineal; (c) Kernel PCA con kernel RBF como *baseline* no lineal; (d) circuito cuántico variacional con ZZFeatureMap implementado en Qiskit Aer con capa variacional RealAmplitudes; y (e) circuito cuántico variacional con PauliFeatureMap, asegurando que todas las condiciones produzcan vectores de representación de dimensión k como entrada al clasificador MLP.
3. Analizar y comparar la separabilidad de clases benigno/maligno en los espacios de representación generados por las cinco condiciones experimentales mediante: *kernel-target alignment* (KTA) respecto al kernel ideal de clasificación; *geometric difference* entre el kernel cuántico y el kernel RBF clásico para cuantificar si el espacio cuántico captura estructura inaccesible para métodos clásicos; índice Davies-Bouldin como medida de compacidad y separación de *clusters*; y distancia Fisher como razón de dispersión inter-clase sobre intra-clase; aplicando el análisis de forma independiente para masas y calcificaciones.
4. Entrenar un mismo clasificador MLP sobre cada uno de los cinco vectores de representación generados en OE-2, manteniendo idéntica arquitectura, hiperparámetros y protocolo de entrenamiento en todas las condiciones.
5. Evaluar si la mejora en separabilidad observada en OE-3 se traduce en una mejora en la capacidad de clasificación binaria, comparando las métricas AUC-ROC, F1-Score, Accuracy, Precision y Recall obtenidas por el MLP en las cinco condiciones, analizando la correlación entre el ranking de separabilidad y el ranking de clasificación, reportando todos los resultados de forma separada para masas y calcificaciones del CBIS-DDSM.
6. Evaluar o analizar los beneficios o limitaciones prácticas, incluyendo restricciones computacionales y características del simulador cuántico, para determinar la viabilidad real de aplicar estas técnicas en un contexto de salud.

1.5. Alcance y limitaciones

El presente trabajo tiene como propósito central evaluar la viabilidad de las transformaciones cuánticas variacionales como mecanismo de codificación de características morfológicas extraídas de imágenes mamográficas, determinando si los quantum embeddings generados en el espacio de Hilbert mejoran la separabilidad de clases benigno/maligno frente

a representaciones clásicas equivalentes. El sistema desarrollado constituye un prototipo de investigación académica, no un sistema de diagnóstico clínico, y su alcance está delimitado por los siguientes criterios:

El sistema opera exclusivamente sobre el subconjunto de imágenes del dataset CBIS-DDSM que corresponden a masas y calcificaciones con diagnóstico patológico confirmado, procesadas como imágenes recortadas de región de interés (ROI). El problema abordado es la clasificación binaria benigno/maligno; la detección de lesiones, la localización espacial y la segmentación precisa de tumores quedan explícitamente fuera del alcance. La totalidad de los experimentos cuánticos se ejecuta en simulación clásica mediante el backend Qiskit Aer, sin acceso a hardware cuántico real. Los resultados, por tanto, corresponden a condiciones ideales libres de ruido cuántico físico, lo cual es una condición deliberada del diseño experimental y no una deficiencia metodológica.

El objetivo no es superar lo existente, sino explorar lo posible

Un error frecuente en la evaluación de trabajos de QML aplicado consiste en juzgar su validez en función de si el modelo cuántico supera en precisión a los mejores modelos clásicos disponibles. Este criterio, aunque pertinente para trabajos en etapas más avanzadas de madurez tecnológica, resulta inapropiado para el momento histórico en que se encuentra la computación cuántica.

El objetivo del presente trabajo no es demostrar que los quantum embeddings superan a una CNN de última generación en AUC-ROC. El objetivo es responder una pregunta anterior y más fundamental: ¿las transformaciones cuánticas variacionales generan representaciones con mayor separabilidad intrínseca de clases cuando se aplican a características morfológicas mamográficas reales?. Un resultado positivo en separabilidad, incluso sin mejora en la métrica de clasificación final, constituye evidencia científica válida y valiosa sobre el comportamiento de estos circuitos en un dominio de alta complejidad clínica.

La analogía del ENIAC: dónde estamos en el tiempo

Para situar correctamente el alcance de este trabajo, resulta útil mencionar a un referente histórico. La primera contribución del ENIAC, más allá de su capacidad operativa, fue demostrar que era posible construir una computadora. Había muchos detractores de las tecnologías de cómputo, pero el éxito del ENIAC inspiró a otros a construir computadoras mejorando las limitaciones existentes. Como resultado, a lo largo de los años las computadoras se desarrollaron para ser más pequeñas, más capaces y más asequibles.

Completada en 1945, la ENIAC fue aclamada como un cerebro gigante por la prensa. Sin embargo, reprogramar la máquina para un nuevo problema requería días de recableado, lo que la hacía difícilmente útil para distintas tareas. No obstante, era el dispositivo de cálculo más poderoso construido hasta esa fecha.

La computación cuántica se encuentra hoy en un momento análogo al de la ENIAC en 1946. Ya existen máquinas con

capacidades cuánticas reales: el procesador IBM Osprey de 433 qubits demostró progreso significativo en control de coherencia y uniformidad de fabricación; IBM, Rigetti, IonQ y Microsoft continúan avanzando en sus respectivas rutas hacia sistemas modulares y con corrección de errores. Sin embargo, al igual que en 1946 nadie sabía todavía cómo aprovechar la ENIAC para resolver problemas generales de ingeniería, hoy la comunidad científica está en el proceso de descubrir cómo formular correctamente los problemas computacionales en el lenguaje de los circuitos cuánticos, qué tipos de datos se benefician de la proyección al espacio de Hilbert, y bajo qué condiciones los embeddings cuánticos ofrecen ventajas reales sobre sus contrapartes clásicas. El presente trabajo es una contribución a ese proceso de descubrimiento, no una afirmación de superioridad tecnológica.

Las limitaciones inherentes al paradigma NISQ

La era actual de la computación cuántica está definida por los dispositivos NISQ (Noisy Intermediate-Scale Quantum), caracterizados por un número limitado de qubits, alta tasa de errores de compuerta, tiempos de coherencia cortos y conectividad restringida entre qubits. Las limitaciones inherentes del hardware NISQ (número restringido de qubits, fidelidad imperfecta de compuertas y conectividad limitada entre qubits) imponen obstáculos fundamentales, y lograr una ventaja cuántica definitiva sobre los métodos clásicos para problemas prácticos permanece sin resolver.

Una limitación teórica particularmente relevante para este trabajo es el comportamiento de los dispositivos NISQ frente a algoritmos de búsqueda. El algoritmo de Grover, considerado uno de los algoritmos cuánticos fundamentales, ofrece una aceleración cuadrática sobre la búsqueda clásica no estructurada: encuentra un elemento en una base de datos de N entradas en $O(\sqrt{N})$ operaciones frente a $O(N)$ clásico. Esta aceleración, que se extiende a problemas de optimización, representa el tipo de ventaja cuántica más prometedor para tareas de búsqueda, clasificación y optimización de hiperparámetros. Sin embargo, para la búsqueda no estructurada, se ha demostrado que los dispositivos NISQ no pueden lograr la aceleración cuadrática tipo Grover sobre las computadoras clásicas.

2. Antecedentes

2.1. Estado del arte

2.1.1. Machine Learning clásico en el diagnóstico mamográfico

El diagnóstico asistido por computadora en mamografía tiene sus orígenes en los sistemas CAD (Computer-Aided Detection/Diagnosis) desarrollados desde la década de 1990, cuyo objetivo era reducir la variabilidad inter-observador en la interpretación radiológica y apoyar la detección temprana de lesiones. Estos sistemas clásicos se estructuran en dos etapas fundamentales: la extracción manual de características y la clasificación mediante algoritmos de aprendizaje supervisado.

Extracción de características en mamografía

La extracción de características ha constituido históricamente el núcleo de los sistemas CAD clásicos. Las características derivadas de la Matriz de Co-ocurrencia de Niveles de Grises (GLCM, por sus siglas en inglés) han sido las más ampliamente utilizadas en la literatura. La técnica GLCM presenta la tasa superior de uso en extracción de características según los trabajos revisados en la literatura de sistemas CAD para detección de cáncer de mama. En clasificación, tanto los métodos de machine learning tradicionales como de deep learning se emplean para clasificar las características extraídas en diferentes clases. Además, se han utilizado descriptores de forma y margen para masas (como la excentricidad, el área y el perímetro del contorno de la lesión) y características de distribución espacial para calcificaciones, como la densidad del cluster y la varianza morfológica entre puntos. [19]

Clasificadores clásicos predominantes

El clasificador de mayor uso en este dominio ha sido la Máquina de Vectores de Soporte (SVM). Aproximadamente el 44 % de los estudios publicados entre 2020 y 2025 emplearon SVM como clasificador para la detección de cáncer de mama; SVM fue el más frecuente con imágenes de mamografía, aunque algunos estudios también lo utilizaron con ultrasonido y termografía. La preferencia por SVM se explica por su capacidad para manejar datos de alta dimensionalidad, encontrar hiperplanos de separación óptimos en espacios de características transformados mediante funciones kernel, y su robustez frente al sobreajuste en conjuntos de entrenamiento pequeños. [21]

El Random Forest (RF) ha constituido la segunda alternativa más frecuente, seguido de redes neuronales artificiales poco profundas (ANN/MLP), k-Nearest Neighbors (k-NN) y Naive Bayes. Al comparar el desempeño de SVM, RF, ANN, NB y DT para clasificación benigno/maligno en imágenes mamográficas con características GLCM y GLRLM, los métodos SVM, RF y ANN mostraron el mejor desempeño en métricas de accuracy, sensibilidad y AUC; el rendimiento

de los modelos fue sensible a la combinación de algoritmos de preprocesamiento aplicados antes de la extracción de características. [22]

Alcances y limitaciones del enfoque clásico

El ML clásico en mamografía ha alcanzado resultados notables en condiciones controladas. Una evaluación sistemática de pipelines CNN, SVM y XGBoost sobre el dataset CBIS-DDSM reportó que una CNN (ResNet-50) alcanzó el mejor desempeño con AUC-ROC de 0.95 y sensibilidad de 89 %, seguido de XGBoost con AUC-ROC de 0.90, mientras que SVM obtuvo AUC-ROC de 0.84. [23]

Sin embargo, la limitación de estos métodos se encuentra en que la capacidad discriminativa del clasificador está completamente delimitada por la riqueza de las características extraídas manualmente. Las relaciones no lineales y de alto orden entre características morfológicas (que son precisamente las que distinguen lesiones malignas de bordes sutiles de lesiones benignas similares) resultan difícilmente capturables mediante descriptores diseñados por expertos. Esta limitación fue la que dio lugar a enfoques basados en deep learning, que aprenden representaciones directamente desde los píxeles de la imagen, y posteriormente el interés en representaciones cuánticas, que proyectan estas características en espacios de Hilbert de dimensionalidad aun mayor. El ML se ha convertido en una herramienta de imprescindible para el análisis de patrones en datos clínicos de cáncer, permitiendo identificar relaciones difícilmente detectables por métodos estadísticos convencionales; sin embargo, la eficacia de los modelos depende directamente de la calidad de la representación de los datos de entrada.

2.1.2. Deep Learning en el diagnóstico mamográfico

El avance de las CNN en mamografías

La aplicación de redes neuronales convolucionales (CNN) en el análisis de mamografías marcó un nuevo paradigma respecto a los sistemas CAD clásicos. A diferencia de los enfoques basados en features manuales, las CNN aprenden representaciones jerárquicas directamente desde los píxeles de la imagen, eliminando la dependencia de descriptores diseñados por expertos. Las CNN poco profundas fueron utilizadas para investigar el cáncer de mama desde 1995; sin embargo, fue a partir de 2012, con el surgimiento de Alex-Net y el aumento de la capacidad computacional, la disponibilidad de hardware de menor costo, los algoritmos de código abierto y el auge del big data, cuando las CNN se volvieron predominantes en el procesamiento de imágenes médicas. Arquitecturas como VGG, ResNet, DenseNet e InceptionV3 se convirtieron en la base de la mayoría de los sistemas CAD modernos para mamografía. [24]

Resultados reportados en distintos datasets

Los modelos de deep learning han alcanzado resultados notables en condiciones controladas sobre los datasets más

utilizados en la comunidad. Shen et. al [25] desarrollaron un sistema de CNN de extremo a extremo sobre CBIS-DDSM con un enfoque que aprovecha tanto anotaciones de lesiones como etiquetas de imagen completa, el mejor modelo individual alcanzó un AUC por imagen de 0.88 sobre el conjunto de prueba del CBIS-DDSM, y el promedio de cuatro modelos mejoró este resultado a un AUC de 0.91, con una especificidad de 80.1 % a una sensibilidad de 86.1 %, comparable al promedio estimado de radiólogos en Estados Unidos.

En el dominio específico de las calcificaciones, la comparación entre arquitecturas evidencia diferencias significativas según el tipo de lesión. Al evaluar modelos ResNet-50, ResNet-101 y cinco variantes de EfficientNet (B0 a B4) para clasificación de microcalcificaciones benignas y malignas usando validación cruzada de cinco pliegues sobre imágenes mamográficas con etiquetas BI-RADS confirmadas, todos los modelos EfficientNet superaron significativamente a las variantes ResNet en F1-score; adicionalmente, bajo validación externa con CBIS-DDSM, EfficientNet-B3 mantuvo su superioridad con mayor recall tanto para clases benignas como malignas. Este hallazgo nos muestra que el performance de un modelo es sensible no solo al dataset de entrenamiento sino al tipo de hallazgo mamográfico analizado, lo que refuerza la necesidad de evaluar masas y calcificaciones de forma separada. [27]

El problema de la generalización

A pesar de los resultados prometedores reportados en validación interna, existe un problema estructural que la literatura ha mencionado de manera consistente, los modelos de deep learning no generalizan entre datasets con distribuciones distintas. Wang et al. (2020) realizaron el análisis más sistemático de este fenómeno, evaluando seis modelos sobre cuatro datasets diferentes. Como se señaló en la sección 1.1.2, los modelos que reportaron AUC de validación entre 0.88 y 0.95 mostraron caídas hasta el rango de 0.44–0.65 al evaluarse sobre datos externos. La variabilidad entre lectores y la dificultad intrínseca de interpretar características radiográficas sutiles limitan frecuentemente la precisión del diagnóstico; el impacto del cambio de dominio queda evidenciado en pruebas de generalización, que marcan la necesidad de conjuntos de datos diversos durante el entrenamiento para construir herramientas de tamizaje confiables y ampliamente aplicables.

Este problema tiene raíces más profundas que la simple escasez de datos. La investigación futura debe enfocarse en enriquecer los algoritmos de deep learning, garantizar la privacidad de los datos, mejorar la interpretabilidad de los modelos y establecer la generalización para integrar exitosamente el diagnóstico asistido por deep learning en programas rutinarios de tamizaje de cáncer de mama.

La representación como problema central

El análisis de la literatura permite identificar que el problema no es la arquitectura del clasificador sino la calidad de la representación que este recibe. Los modelos de deep learning operan en el espacio de píxeles o en espacios de features aprendidos mediante backpropagation, cuya geometría está determinada por la función de pérdida de clasificación y el

conjunto de entrenamiento disponible. Esta representación puede ser altamente efectiva dentro del dominio de entrenamiento pero frágil ante cambios de distribución. La pregunta que motiva el presente trabajo es si la proyección de estas características al espacio de Hilbert mediante transformaciones cuánticas variacionales puede generar representaciones con mayor separabilidad intrínseca de clases, abordando el problema desde la etapa de codificación y no desde la arquitectura del clasificador.

2.1.3. Fundamentos de quantum machine learning y codificación cuántica de datos

El origen teórico, QML como extensión de kernerls

El quantum machine learning (QML) surge de una observación fundamental establecida por Schuld y Killoran en 2019, la idea básica de la computación cuántica es sorprendentemente similar a la de los métodos kernel en machine learning, es decir, realizar eficientemente cómputos en un espacio de Hilbert de tamaño intratable. El proceso de codificar entradas en un estado cuántico se interpreta como un mapa de características no lineal que mapea datos al espacio de Hilbert cuántico; en este espacio de características, el dispositivo cuántico puede estimar productos internos de estados cuánticos para computar un kernel clásicamente intratable, el cual puede alimentar cualquier modelo clásico como una máquina de vectores de soporte. Esta formalización sentó las bases teóricas de todo el campo del QML moderno y es la justificación fundamental del presente trabajo: si el espacio de Hilbert de 2^n dimensiones generado por n qubits ofrece una geometría más favorable para la separación de clases morfológicas mamográficas, entonces la proyección cuántica aporta valor real al pipeline de clasificación. [28]

El trabajo de Havlíček et al. (2019) en IBM Nature formalizó esta idea operacionalmente, demostrando dos algoritmos de clasificación que usan el espacio de estados cuánticos para producir mapas de características, probados en procesadores superconductores. Esto estableció el ZZFeatureMap como referencia estándar en la comunidad y demostró la posibilidad de ventaja cuántica cuando el espacio de características es grande y las funciones kernel son computacionalmente costosas de estimar clásicamente.

Circuitos cuánticos variacionales

Los circuitos cuánticos variacionales (VQC) son la arquitectura predominante en QML para el régimen NISQ actual. Los VQC son un tipo específico de circuito cuántico parametrizado (PQC) que combina circuitos cuánticos con optimizadores clásicos; son ampliamente utilizados en algoritmos cuánticos y, entre los distintos tipos de PQC, son el enfoque que típicamente optimiza sus parámetros mediante métodos variacionales, minimizando una función de costo mediante optimización híbrida cuántico-clásica. [29]

Un VQC está estructurado en tres bloques consecutivos que corresponden directamente a la arquitectura a implementar en el presente trabajo. El primero es el mapa de características $U(x)$, que codifica el vector clásico x en el estado

cuántico inicial $|\phi(x)\rangle = U(x)|0\rangle^{\otimes n}$. El segundo es el ansatz variacional $W(\theta)$, que aplica rotaciones parametrizadas y compuertas de entrelazamiento entrenables, generando el estado final $|\psi(x, \theta)\rangle = W(\theta)|\phi(x)\rangle$. El tercero es la medición, que extrae el vector de valores de expectativa $\langle Z_i \rangle$ de cada qubit como salida clásica del circuito.

Los parámetros θ se optimizan mediante el método de parameter-shift, que calcula el gradiente exacto del circuito evaluándolo en dos puntos desplazados: $\nabla_{\theta} \langle O \rangle = \frac{1}{2} [\langle O \rangle_{\theta+\pi/2} - \langle O \rangle_{\theta-\pi/2}]$. Este método es diferenciable durante el proceso de entrenamiento y compatible con backpropagation clásico, lo que habilita el entrenamiento conjunto del circuito cuántico y la red neuronal clásica downstream mediante optimizadores estándar de PyTorch.

Los métodos de codificación cuántica

La elección del método de codificación es la decisión de diseño más importante en un sistema QML, ya que determina la geometría del espacio de Hilbert donde los datos quedan representados. La integración de técnicas de codificación cuántica de datos en algoritmos de machine learning clásicos contribuye a mejorar la precisión de clasificación y los valores F1, de manera particularmente notable en modelos que se benefician intrínsecamente de una representación de características enriquecida.

Los tres tipos de codificación más utilizados en la literatura son:

- **Angle encoding:** codifica cada componente del vector de características como un ángulo de rotación en un qubit, por ejemplo, x_i se codifica como una rotación $R_y(x_i)$ en el qubit i . Es simple pero puede requerir muchos qubits para vectores de alta dimensionalidad. Su principal ventaja es la simplicidad y la diferenciabilidad directa; su limitación es que las relaciones entre características solo se pueden expresar a través de las capas variacionales posteriores, no en la etapa de codificación.
- **ZZFeatureMap:** construido sobre el mapa angular, agrega compuertas de entrelazamiento entre pares de qubits que codifican productos de features: $e^{ix_i x_j Z_i Z_j}$. El ZZFeatureMap captura interacciones de features por pares, pero algunos datasets requieren interacciones de orden superior.
- **PauliFeatureMap:** generaliza el ZZFeatureMap agregando rotaciones alrededor de los tres ejes de Pauli (X, Y, Z) y operaciones de entrelazamiento más complejas. El PauliFeatureMap extiende la codificación utilizando rotaciones multi-eje y entrelazamiento cuántico complejo para codificar dependencias de características más profundas; es altamente expresivo, capaz de capturar interacciones de orden superior y patrones ocultos dentro de los datos, siendo particularmente poderoso para datasets donde las relaciones entre características son complejas y no lineales. Su mayor expresividad tiene como contrapartida una mayor sensibilidad al ruido cuántico, relevante incluso en simulación cuando el número de shots es limitado.

La elección entre estos métodos de codificación no es trivial y depende de la estructura de correlación de los datos de entrada. Un estudio reciente aplicó los tres métodos a la clasificación de cáncer de pulmón con QSVM, obteniendo

que ZZFeatureMap alcanzó una accuracy de 0.91 y F1-score de 0.91, mientras que PauliFeatureMap logró un rendimiento consistente de 0.96 en todas las métricas incluyendo accuracy, precisión, recall y F1-score; la elección del mapa apropiado depende de dos factores principales, la naturaleza de los datos y la resiliencia al ruido del dispositivo cuántico. Estos resultados motivan la estrategia del presente trabajo de comparar ambos métodos de codificación sobre características morfológicas mamográficas.

El problema "barren plateau"

Una limitación teórica importante de los VQC profundos es el fenómeno del *barren plateau*. A medida que el circuito aumenta en número de qubits y capas, la optimización se vuelve exponencialmente plana, con gradientes que convergen a cero. Esto hace el entrenamiento prácticamente imposible para circuitos de gran profundidad con una inicialización aleatoria de parámetros. Esta limitación tiene implicaciones directas para el diseño del experimento, justifica el uso de circuitos de profundidad moderada y la estrategia de inicialización cuidadosa de los parámetros θ .

El uso de Qiskit como plataforma de desarrollo

Qiskit, es el framework de código abierto de IBM para computación cuántica, provee la infraestructura completa para implementar el pipeline descrito. Su ecosistema de machine learning (qiskit-machine-learning) ofrece EstimatorQNN, que encapsula un VQC y devuelve vectores de valores de expectativa diferenciables; TorchConnector, que envuelve el QNN como una capa nn.Module de PyTorch habilitando backpropagation a través del circuito; y el simulador Qiskit Aer con backend AerSimulator, que permite ejecutar circuitos de hasta 20–30 qubits con simulación de alta fidelidad en hardware estándar. La disponibilidad de estos componentes maduros y bien documentados, combinados con el acceso a los servidores del CIC del IPN, garantiza la viabilidad técnica del prototipo experimental.

2.1.4. Modelos híbridos-cuántico-clásico en el sector salud

La aplicación de arquitecturas híbridas cuántico-clásicas en diagnóstico médico por imagen es una línea de investigación activa. Una revisión sistemática de 28 estudios publicados entre 2018 y 2024 reporta el uso prevalente de QSVM, QCNN y modelos híbridos cuántico-clásicos en aplicaciones que incluyen clasificación de tumores cerebrales, lesiones cutáneas y detección de COVID-19, demostrando resultados prometedores en accuracy, sensibilidad y especificidad; sin embargo, se identifican retos constantes en la codificación de imágenes médicas para procesamiento cuántico, la escalabilidad limitada del hardware actual y la necesidad de modelos con una mejor interpretación. [30]

Aplicaciones específicas en cáncer de mama

En el dominio de la mamografía, Xiang et al. (2024) propusieron el modelo QCCNN evaluado sobre datasets tabulares (GBSG, SEER, WDBC), reportando mejoras de hasta 5 % en accuracy respecto a CNN y regresión logística clásicas.

Un trabajo más reciente aplicó un modelo ResNet50 como extractor de características y una QNN downstream sobre el dataset BreastMNIST, alcanzando 69 % de accuracy frente a 67 % de métodos híbridos comparables, reconociendo explícitamente las restricciones del hardware cuántico actual como limitante de la precisión del modelo. Estos resultados son consistentes con la propuesta del presente trabajo, la ventaja cuántica en este dominio no debe medirse en precisión final sino en la calidad de la representación generada.

Limitaciones comunes reportados

La literatura identifica tres limitaciones en la mayor parte de los trabajos revisados, los experimentos se ejecutan en simulación clásica sin ruido cuántico real; los datasets utilizados son tabulares o imágenes muy reducidas (28×28), lejos de las mamografías DICOM de alta resolución; y ninguno analiza explícitamente la separabilidad de clases en el espacio de Hilbert como métrica de evaluación intermedia. Estas tres brechas son precisamente las que el presente trabajo aborda.

2.1.5. Trabajos específicos sobre el dataset CBIS-DDSM

El CBIS-DDSM se ha convertido como el dataset de referencia más utilizado en investigación de CADx mamográfico, precisamente por su partición train-test previamente definida, sus máscaras ROI validadas patológicamente y su licencia pública CC BY 3.0.

Trabajos clásicos en CBIS-DDSM

El trabajo de Shen et al. (2019) estableció una línea base de rendimiento con CNN sobre este dataset, alcanzando AUC de 0.91 con un ensemble de modelos ResNet y VGG. Baccouche et al. (2022) propusieron un ensemble de modelos ResNet (ResNet50V2, ResNet101V2, ResNet152V2) que alcanzó una accuracy de 95.13 % en clasificación de patología y 90.02 % en clasificación de forma sobre CBIS-DDSM, demostrando la ventaja del aprendizaje por ensemble para superar las metodologías de deep learning individuales más recientes.

Trabajos de QML en CBIS-DDSM

La revisión de la literatura no ha identificado ningún trabajo publicado que aplique circuitos cuánticos variacionales reales (con codificación de datos en estados cuánticos mediante compuertas cuánticas) directamente sobre imágenes del dataset CBIS-DDSM. El trabajo más cercano en el dominio del QML aplicado a mamografías es el de Azevedo et al. (2022), que implementa quantum transfer learning mediante redes neuronales híbridas clásico-cuánticas con angle embedding sobre el dataset BCDR (Barcelona Digital Breast Cancer Dataset), obteniendo 84 % de accuracy y señalando como trabajo futuro explícito la necesidad de evaluar la distribución de los datos en el espacio de Hilbert resultante para verificar la separabilidad de clases. Este trabajo, aunque no usa CBIS-DDSM, establece el único precedente de

QML con circuitos reales en imagen mamográfica y define las brechas metodológicas que el presente trabajo aborda.

2.1.6. Tabla comparativa y brechas identificadas

Cuadro 1: Comparativa de trabajos relacionados en el estado del arte

Trabajo	Dataset	Circuito cuántico real	Framework QML	Feature map	CBIS-DDSM DICOM	Análisis separabilidad	Masas/calcs. por separado	AUC-ROC
<i>ML clásico en mamografía</i>								
Shen et al. (2019)	CBIS-DDSM	✗	ResNet / VGG	—	✓	✗	✗	0.91
Wang et al. (2020)	DDSM / INbreast / MIAS / UKy	✗	CNN (6 modelos)	—	Parcial	✗	✗	0.44–0.95
Baccouche et al. (2022)	CBIS-DDSM / INbreast	✗	Ensemble ResNet	—	✓	✗	✗	0.95
<i>Optimización cuántico-inspirada en mamografía</i>								
Bilal et al. (2025)	CBIS-DDSM / MIAS / INbreast / DDSM	Inspirado	Q-BGWO SqueezeNet SVM	+ — +	✓	✗	✗	—
Singh et al. (2025)	CBIS-DDSM	Inspirado	SeQTLBOGA SVM	+ —	✓	✗	✗	—
<i>QML real en imagen médica (no mamografía)</i>								
Ajlouni et al. (2023)	Kaggle Brain MRI	✓	Hybrid QCNN	PQC	✗	✗	—	—
Xiang et al. (2024)	GBSG / SEER / WDBC	✓	QCCNN (PennyLane)	Capa cuántica conv.	✗	✗	—	—
<i>QML real en mamografía</i>								
Azevedo et al. (2022)	BCDR	✓	QTL (PennyLane)	Angle embedding	✗	✗	✗	—
<i>Presente trabajo</i>								
Sánchez García (2026)	CBIS-DDSM	✓	VQC (Qiskit)	ZZFeatureMap / PauliFeatureMa	✓	✓	✓	Por det.

Notas: ✓ = cumple la condición; ✗ = no cumple; Inspirado = algoritmo cuántico-inspirado sin circuitos cuánticos reales; — = no reportado o no aplica.

La tabla anterior resume los trabajos revisados en las secciones 2.1.1 a 2.1.5 a lo largo de ocho características relevantes para el presente trabajo. La intersección de tres condiciones simultáneas (circuito cuántico variacional real, dataset CBIS-DDSM con imágenes DICOM, y análisis explícito de separabilidad diferenciado por tipo de hallazgo) no está cubierta por ningún trabajo publicado en la literatura revisada. Esta triple intersección define la contribución del presente trabajo. Adicionalmente, el presente trabajo introduce una cuarta característica no presente en ninguno de los trabajos anteriores, el uso de Qiskit con *ZZFeatureMap* y *PauliFeatureMap* como componente de embedding, en contraste con el uso exclusivo de PennyLane con *angle embedding* en los únicos trabajos de QML real en imagen médica disponibles. Esto aporta evidencia comparativa sobre el comportamiento de distintos frameworks y feature maps en este dominio clínico específico.

3. Marco Teórico

3.1. Fundamentos de computación cuántica

El presente bloque introduce los conceptos y formalismos matemáticos de la computación cuántica que sustentan la implementación del circuito variacional desarrollado en este trabajo. La referencia estándar para esta sección es Nielsen y Chuang [31].

3.1.1. El qubit como unidad de información cuántica

La unidad fundamental de información en la computación cuántica es el *qubit* (quantum bit). A diferencia de un bit clásico, que solo puede tomar los valores 0 o 1, un qubit puede encontrarse en una *superposición* de ambos estados simultáneamente. Formalmente, el estado de un qubit se representa como un vector unitario en un espacio de Hilbert bidimensional $\mathcal{H} = \mathbb{C}^2$:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad \alpha, \beta \in \mathbb{C}, \quad |\alpha|^2 + |\beta|^2 = 1 \quad (1)$$

donde $|0\rangle$ y $|1\rangle$ son los vectores de la base computacional estándar, análogos a los estados 0 y 1 clásicos:

$$|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \quad |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad (2)$$

Los coeficientes α y β son *amplitudes de probabilidad*: al medir el qubit, se obtiene el estado $|0\rangle$ con probabilidad $|\alpha|^2$ y el estado $|1\rangle$ con probabilidad $|\beta|^2$. La medición es irreversible y colapsa el estado a uno de los dos valores de la base.

La representación geométrica estándar de un qubit es la *esfera de Bloch*, que parametriza el estado general de un qubit (salvo fase global) mediante dos ángulos reales:

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right)|0\rangle + e^{i\varphi}\sin\left(\frac{\theta}{2}\right)|1\rangle, \quad \theta \in [0, \pi], \quad \varphi \in [0, 2\pi) \quad (3)$$

donde θ determina la mezcla entre $|0\rangle$ y $|1\rangle$, y φ es la fase relativa entre ambos. Esta parametrización es fundamental para entender las compuertas de rotación que conforman los circuitos variacionales del presente trabajo [31].




Figura 3.1.1: Esfera de Bloch: representación geométrica de un qubit. El estado $|\psi\rangle$ se representa como un punto en la superficie de la esfera, determinado por los ángulos θ y ϕ .

3.1.2. Compuertas cuánticas de un qubit

Las operaciones sobre qubits se realizan mediante *compuertas cuánticas*, representadas por matrices unitarias $U \in \mathbb{C}^{2 \times 2}$ que satisfacen $UU^\dagger = I$. La unitariedad garantiza la reversibilidad de la operación y la conservación de la norma del estado. Las compuertas más relevantes para los circuitos variacionales son las rotaciones parametrizadas alrededor de los ejes de la esfera de Bloch [31]:

$$R_X(\theta) = e^{-i\frac{\theta}{2}X} = \begin{pmatrix} \cos \frac{\theta}{2} & -i \sin \frac{\theta}{2} \\ -i \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{pmatrix} \quad (4)$$

$$R_Y(\theta) = e^{-i\frac{\theta}{2}Y} = \begin{pmatrix} \cos \frac{\theta}{2} & -\sin \frac{\theta}{2} \\ \sin \frac{\theta}{2} & \cos \frac{\theta}{2} \end{pmatrix} \quad (5)$$

$$R_Z(\theta) = e^{-i\frac{\theta}{2}Z} = \begin{pmatrix} e^{-i\frac{\theta}{2}} & 0 \\ 0 & e^{i\frac{\theta}{2}} \end{pmatrix} \quad (6)$$

donde X , Y y Z son las matrices de Pauli:

$$X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad Y = \begin{pmatrix} 0 & -i \\ i & 0 \end{pmatrix}, \quad Z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \quad (7)$$

Estas compuertas de rotación son los bloques de construcción del ansatz variacional implementado en Qiskit, donde los ángulos θ son los parámetros entrenables del circuito. La compuerta de Hadamard, definida como:

$$H = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \quad (8)$$

transforma el estado base $|0\rangle$ en la superposición uniforme $\frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$, y es ampliamente utilizada como compuerta de inicialización en circuitos cuánticos.

3.1.3. Sistemas de múltiples qubits y entrelazamiento

El estado de un sistema de n qubits se describe mediante el producto tensorial de los espacios de Hilbert individuales:

$$\mathcal{H}^{\otimes n} = \underbrace{\mathbb{C}^2 \otimes \mathbb{C}^2 \otimes \dots \otimes \mathbb{C}^2}_n, \quad \dim(\mathcal{H}^{\otimes n}) = 2^n \quad (9)$$

El estado general de n qubits es una superposición de los 2^n estados de la base computacional $\{|0 \dots 0\rangle, |0 \dots 1\rangle, \dots, |1 \dots 1\rangle\}$:

$$|\Psi\rangle = \sum_{k=0}^{2^n-1} c_k |k\rangle, \quad c_k \in \mathbb{C}, \quad \sum_{k=0}^{2^n-1} |c_k|^2 = 1 \quad (10)$$

El *entrelazamiento cuántico* es la propiedad por la cual el estado de un sistema de múltiples qubits no puede factorizarse como el producto tensorial de estados individuales. Un estado entrelazado no tiene representación separable y exhibe correlaciones entre qubits que no tienen análogo clásico [31]. La compuerta estándar para generar entrelazamiento es la *compuerta CNOT* (Controlled-NOT), que opera sobre dos qubits: un qubit de control c y un qubit objetivo t , aplicando una negación al objetivo condicionada al estado del control:

$$\text{CNOT} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix} \quad (11)$$

La combinación de compuertas de rotación de un qubit y compuertas CNOT es suficiente para aproximar cualquier operación unitaria sobre n qubits, propiedad conocida como *universalidad* [31]. Esta combinación es precisamente la que estructura el ansatz variacional RealAmplitudes utilizado en el presente trabajo.

3.1.4. Medición y valores de expectativa

La medición en computación cuántica extrae información clásica del estado cuántico al precio de colapsar la superposición. Para un observable $\hat{O}$ representado por un operador hermítico, el *valor de expectativa* cuantifica el valor promedio que se obtendría al medir ese observable repetidamente sobre el estado $|\psi\rangle$:

$$\langle \hat{O} \rangle = \langle \psi | \hat{O} | \psi \rangle \quad (12)$$

En el presente trabajo, el observable utilizado es el operador de Pauli Z aplicado a cada qubit individualmente. Su valor de expectativa para el qubit i en el estado $|\psi\rangle$ está en el rango:

$$\langle Z_i \rangle = \langle \psi | Z_i | \psi \rangle \in [-1, 1] \quad (13)$$

donde $\langle Z_i \rangle = +1$ corresponde al estado $|0\rangle$ y $\langle Z_i \rangle = -1$ al estado $|1\rangle$. El vector de valores de expectativa:

$$\mathbf{e} = (\langle Z_1 \rangle, \langle Z_2 \rangle, \dots, \langle Z_n \rangle) \in [-1, 1]^n \quad (14)$$

constituye el *quantum embedding*: la representación clásica extraída del estado cuántico que sirve como vector de entrada a la red neuronal clásica en el pipeline del presente trabajo. La estimación de $\langle Z_i \rangle$ en el simulador Qiskit Aer se realiza mediante el promedio de resultados de medición sobre un número configurable de ejecuciones del circuito (*shots*), de modo que a mayor número de shots, menor es la varianza estadística de la estimación.

3.2. Circuitos cuánticos variacionales y *quantum embeddings*

3.2.1. Circuitos cuánticos parametrizados (PQC)

Un *circuito cuántico parametrizado* (PQC, por sus siglas en inglés) es un circuito cuántico cuyas compuertas dependen de un conjunto de parámetros reales $\theta \in \mathbb{R}^m$ que pueden ajustarse mediante optimización clásica [32]. Un *circuito cuántico variacional* (VQC) es un tipo específico de PQC que combina un bloque de codificación de datos $U(\mathbf{x})$ con un bloque variacional entrenable $W(\theta)$, produciendo el estado cuántico:

$$|\psi(\mathbf{x}, \theta)\rangle = W(\theta) U(\mathbf{x}) |0\rangle^{\otimes n} \quad (15)$$

donde n es el número de qubits, $U(\mathbf{x})$ es el *feature map* cuántico que codifica el vector de características clásico $\mathbf{x} \in \mathbb{R}^k$ en el estado cuántico inicial, y $W(\theta)$ es el *ansatz* variacional que introduce correlaciones entre qubits mediante compuertas entrenables [42].

La arquitectura VQC es la más adecuada para el régimen NISQ actual porque mantiene profundidades de circuito moderadas y es diferenciable de extremo a extremo mediante el método de *parameter-shift*, descrito en la sección 3.2.7.

3.2.2. El *feature map* como mapeo no lineal al espacio de Hilbert

El bloque $U(\mathbf{x})$ define un mapeo no lineal:

$$\phi : \mathbb{R}^k \rightarrow \mathcal{H}, \quad \mathbf{x} \mapsto |\phi(\mathbf{x})\rangle = U(\mathbf{x})|0\rangle^{\otimes n} \quad (16)$$

donde $\mathcal{H} = \mathbb{C}^{2^n}$ es el espacio de Hilbert del sistema de n qubits, de dimensión 2^n . Como se argumentó en la sección del planteamiento del problema, este espacio no es simplemente una versión ampliada del espacio clásico de entrada: su geometría está determinada por productos internos cuánticos $\langle \phi(\mathbf{x}) | \phi(\mathbf{x}') \rangle$, no por distancias euclidianas. El mapeo ϕ introduce correlaciones de orden superior entre las componentes de $\mathbf{x}$ que los métodos de codificación clásicos no capturan [42, 43].

Este mapeo define implícitamente un *kernel* cuántico:

$$k_Q(\mathbf{x}, \mathbf{x}') = |\langle \phi(\mathbf{x}) | \phi(\mathbf{x}') \rangle|^2 = |\langle 0|^{\otimes n} U^\dagger(\mathbf{x}') U(\mathbf{x}) |0\rangle^{\otimes n}|^2 \quad (17)$$

La elección del *feature map* $U(\mathbf{x})$ determina completamente la geometría del espacio de representación y, con ello, la capacidad del sistema para separar las clases en ese espacio. En el presente trabajo se comparan dos diseños de *feature map*: *ZZFeatureMap* y *PauliFeatureMap*, descritos a continuación.

3.2.3. *ZZFeatureMap*: evolución de Pauli-Z de segundo orden

El *ZZFeatureMap* es un circuito de evolución de Pauli-Z de segundo orden introducido por Havlíček et al. [43] y disponible en Qiskit como `qiskit.circuit.library.zz_feature_map`. Para n qubits y r repeticiones (*reps*), el circuito implementa el unitario:

$$U_{ZZ}(\mathbf{x}) = [\mathcal{U}_\Phi(\mathbf{x}) H^{\otimes n}]^r \quad (18)$$

donde $H^{\otimes n}$ es la capa de compuertas de Hadamard que inicializa la superposición uniforme, y $\mathcal{U}_\Phi(\mathbf{x})$ es el bloque de codificación de datos definido por:

$$\mathcal{U}_\Phi(\mathbf{x}) = \exp\left(i \sum_{S \subseteq [n], |S| \leq 2} \phi_S(\mathbf{x}) \bigotimes_{j \in S} Z_j\right) \quad (19)$$

Los coeficientes $\phi_S(\mathbf{x})$ codifican los datos clásicos en el hamiltoniano de evolución:

$$\phi_{\{i\}}(\mathbf{x}) = x_i, \quad \phi_{\{i,j\}}(\mathbf{x}) = (\pi - x_i)(\pi - x_j) \quad (20)$$

El término de un qubit $\phi_{\{i\}}$ codifica cada característica x_i como una rotación alrededor del eje Z. El término de dos qubits $\phi_{\{i,j\}}$ introduce *entrelazamiento* entre pares de qubits que codifica las interacciones de segundo orden entre características, operando mediante la compuerta:

$$e^{i\phi_{\{i,j\}}(\mathbf{x})Z_iZ_j} = \text{CNOT}_{i \rightarrow j} e^{i\phi_{\{i,j\}}(\mathbf{x})Z_j} \text{CNOT}_{i \rightarrow j} \quad (21)$$

Esta capacidad de capturar interacciones de segundo orden entre pares de características es la razón por la que el ZZFeatureMap es uno de los métodos de codificación de datos más utilizados en tareas de clasificación cuántica, dada su capacidad para enriquecer la expresividad del espacio de características cuántico y la dificultad de simularlo clásicamente.

Es importante señalar que en Qiskit 2.x el uso de la clase ZZFeatureMap está marcado como obsoleto (*deprecated*) a favor de la función `zz_feature_map()`, que retorna un QuantumCircuit estándar [34]. En el presente trabajo se utiliza la función actualizada compatible con Qiskit 2.x.

3.2.4. *PauliFeatureMap*: generalización multi-eje

El *PauliFeatureMap* es la generalización del ZZFeatureMap que permite incorporar operadores de Pauli arbitrarios (X , Y , Z) en el bloque de codificación, aumentando la expresividad del mapeo al capturar interacciones de orden superior [34]. El unitario general tiene la forma:

$$U_{\text{Pauli}}(\mathbf{x}) = \left[\mathcal{U}_\Phi^{(P)}(\mathbf{x}) H^{\otimes n} \right]^r \quad (22)$$

donde el bloque de codificación es:

$$\mathcal{U}_{\Phi}^{(P)}(\mathbf{x}) = \exp\left(i \sum_{S \subseteq [n]} \phi_S(\mathbf{x}) \bigotimes_{j \in S} P_j\right), \quad P_j \in \{X, Y, Z\} \quad (23)$$

La elección del conjunto de operadores de Pauli $\{P_j\}$ y del orden máximo $|S|$ de las interacciones define distintas variantes del mapa. El PauliFeatureMap es la forma general que permite órdenes de interacción superiores, codificando dependencias más intrincadas entre características; es altamente expresivo y particularmente poderoso para datasets donde las relaciones entre características son complejas y no lineales.

En el presente trabajo se evalúa el PauliFeatureMap con operadores $\{Z, ZZ\}$ como configuración de referencia, lo que lo hace directamente comparable con el ZZFeatureMap al compartir la misma estructura de entrelazamiento pero con un espacio de hiperparámetros de codificación más amplio.

3.2.5. El *ansatz* variacional: RealAmplitudes

El bloque variacional $W(\theta)$ introduce capas de rotaciones parametrizadas y compuertas de entrelazamiento cuyo propósito es transformar el estado codificado $|\phi(\mathbf{x})\rangle$ en una representación más discriminativa. En el presente trabajo se utiliza el *ansatz RealAmplitudes* disponible en Qiskit, que alterna capas de rotaciones $R_Y(\theta_i)$ con patrones de compuertas CNOT entre qubits adyacentes:

$$W(\theta) = \prod_{\ell=1}^L \left[\text{CNOT-layer}_{\ell} \bigotimes_{i=1}^n R_Y(\theta_{\ell,i}) \right] \quad (24)$$

donde L es el número de capas (reps) y $\theta \in \mathbb{R}^{n \times L}$ son los parámetros entrenables. La elección de R_Y en lugar de rotaciones complejas garantiza que las amplitudes del estado final sean reales, lo que reduce el número de parámetros y facilita la optimización en simulación [34].

3.2.6. El *quantum embedding*: vector de salida del circuito

Dado el estado final $|\psi(\mathbf{x}, \theta)\rangle = W(\theta) U(\mathbf{x}) |0\rangle^{\otimes n}$, el circuito extrae información clásica mediante la medición del valor de expectativa del operador de Pauli Z sobre cada qubit i :

$$\langle Z_i \rangle = \langle \psi(\mathbf{x}, \theta) | Z_i | \psi(\mathbf{x}, \theta) \rangle \in [-1, 1] \quad (25)$$

El *quantum embedding* de la muestra $\mathbf{x}$ se define como el vector de n valores de expectativa:

$$\mathbf{e}(\mathbf{x}, \theta) = (\langle Z_1 \rangle, \langle Z_2 \rangle, \dots, \langle Z_n \rangle) \in [-1, 1]^n \quad (26)$$

Este vector constituye la representación cuántica de $\mathbf{x}$ y es la entrada al clasificador MLP en el pipeline del presente trabajo. En Qiskit, la estimación de $\langle Z_i \rangle$ se realiza mediante el primitivo `Estimator` del simulador `AerSimulator`, promediando los resultados de medición sobre un número configurable de ejecuciones del circuito (*shots* ≥ 1024).

3.2.7. El método *parameter-shift* para el cálculo del gradiente

El entrenamiento del VQC requiere calcular el gradiente del valor de expectativa respecto a los parámetros θ . A diferencia de las redes neuronales clásicas donde el gradiente se obtiene por *backpropagation*, los circuitos cuánticos requieren el método de *parameter-shift* [33], que calcula el gradiente exacto evaluando el circuito en dos puntos desplazados:

$$\frac{\partial \langle Z_i \rangle}{\partial \theta_j} = \frac{1}{2} \left[\langle Z_i \rangle_{\theta_j + \frac{\pi}{2}} - \langle Z_i \rangle_{\theta_j - \frac{\pi}{2}} \right] \quad (27)$$

donde $\langle Z_i \rangle_{\theta_j \pm \pi/2}$ denota el valor de expectativa del circuito con el parámetro θ_j desplazado en $\pm \pi/2$. Este método tiene dos implicaciones prácticas directas para el presente trabajo:

La primera es que cada paso de gradiente requiere $2m$ evaluaciones del circuito, donde m es el número de parámetros entrenables ($m = n \times L$). Para un circuito de 8 qubits y 3 capas, esto implica 48 evaluaciones por paso, lo que hace el entrenamiento considerablemente más lento que una red puramente clásica. Este costo computacional se documenta explícitamente como parte del objetivo OE-6.

La segunda es que el método *parameter-shift* es exacto (no aproximado) y compatible con *backpropagation* clásico, lo que permite integrar el circuito cuántico como una capa de PyTorch mediante `TorchConnector` y optimizar conjuntamente los parámetros cuánticos θ y los pesos del MLP con el mismo optimizador [35].

3.3. Red neuronal clásica e integración Qiskit–PyTorch

3.3.1. Perceptrón multicapa (MLP)

La red neuronal clásica utilizada como clasificador *downstream* en el pipeline del presente trabajo es un perceptrón multicapa (MLP, *Multi-Layer Perceptron*), una arquitectura de aprendizaje supervisado compuesta por capas de neuro-

nas totalmente conectadas [36].

Formalmente, dado un vector de entrada $\mathbf{z} \in \mathbb{R}^n$ —que puede ser el *quantum embedding* $\mathbf{e}(\mathbf{x}, \theta)$ o cualquiera de los vectores de las condiciones clásicas— la transformación de la capa ℓ se define como:

$$\mathbf{h}^{(\ell)} = \sigma\left(W^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}\right), \quad \ell = 1, \dots, L \quad (28)$$

donde $W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ es la matriz de pesos, $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_\ell}$ es el vector de sesgos, y $\sigma(\cdot)$ es la función de activación no lineal. La capa de salida produce una probabilidad de clasificación binaria mediante la función sigmoide:

$$\hat{y} = \sigma_{\text{sig}}\left(W^{(L)} \mathbf{h}^{(L-1)} + b^{(L)}\right) = \frac{1}{1 + e^{-(W^{(L)} \mathbf{h}^{(L-1)} + b^{(L)})}} \in [0, 1] \quad (29)$$

El modelo se entrena minimizando la función de pérdida de entropía cruzada binaria (*Binary Cross-Entropy*, BCE):

$$\mathcal{L}_{\text{BCE}}(\hat{y}, y) = -[y \log \hat{y} + (1 - y) \log(1 - \hat{y})] \quad (30)$$

donde $y \in \{0, 1\}$ es la etiqueta real (0=benigno, 1=maligno). Los parámetros $\{W^{(\ell)}, \mathbf{b}^{(\ell)}\}$ se optimizan mediante descenso de gradiente estocástico (*Adam* o equivalente) a través del algoritmo de *backpropagation* [36].

La arquitectura del MLP se mantiene idéntica para las cinco condiciones experimentales: mismo número de capas ocultas, mismas dimensiones, misma función de activación, mismos hiperparámetros y misma semilla aleatoria. Esta invarianza es el principio metodológico central que garantiza que las diferencias de rendimiento entre condiciones sean atribuibles únicamente a la transformación aplicada en M5, y no a diferencias en el clasificador.

3.3.2. Ponderación de clases para datos desbalanceados

Dado el desbalance de clases observado en el análisis exploratorio del dataset CBIS-DDSM (ratio 1.78:1 en calcificaciones), se aplica ponderación de clases durante el entrenamiento del MLP. La pérdida ponderada se define como:

$$\mathcal{L}_w = -[w_1 y \log \hat{y} + w_0 (1 - y) \log(1 - \hat{y})] \quad (31)$$

donde los pesos w_0 y w_1 se calculan inversamente proporcionales a la frecuencia de cada clase en el conjunto de entrenamiento:

$$w_c = \frac{N}{C \cdot N_c}, \quad c \in \{0, 1\} \quad (32)$$

siendo N el número total de muestras, $C = 2$ el número de clases y N_c el número de muestras de la clase c . Este ajuste se aplica de forma independiente para los subconjuntos de masas y calcificaciones.

3.3.3. Integración Qiskit–PyTorch mediante TorchConnector

La integración del circuito cuántico VQC con el clasificador MLP de PyTorch se realiza mediante la clase `TorchConnector` del paquete `qiskit-machine-learning` [35]. Esta clase envuelve un objeto `EstimatorQNN` —que encapsula el VQC y la medición de valores de expectativa— como una capa `nn.Module` de PyTorch, habilitando el flujo de gradientes a través del circuito cuántico mediante el método *parameter-shift*.

El flujo de cómputo en el sistema híbrido durante el entrenamiento es el siguiente:

1. El vector de características escalado $\mathbf{x} \in [0, \pi]^k$ se pasa al `EstimatorQNN`, que construye y ejecuta el circuito $U(\mathbf{x})W(\theta)$ en el simulador `AerSimulator`.
2. El `EstimatorQNN` retorna el vector de embeddings cuánticos $\mathbf{e} = (\langle Z_1 \rangle, \dots, \langle Z_n \rangle) \in [-1, 1]^n$.
3. El vector $\mathbf{e}$ pasa por las capas del MLP y produce la probabilidad $\hat{y}$.
4. La pérdida $\mathcal{L}$ se propaga hacia atrás: los gradientes respecto a los pesos del MLP se calculan por *backpropagation* clásico, y los gradientes respecto a θ se calculan por *parameter-shift* a través del `TorchConnector`.
5. El optimizador de PyTorch actualiza conjuntamente $\{W^{(\ell)}, \mathbf{b}^{(\ell)}\}$ y θ en un solo paso.

Este entrenamiento *end-to-end* garantiza que los parámetros del circuito cuántico se optimicen en función del objetivo de clasificación, y no de forma independiente. La figura 4.2.1 ilustra la posición de esta integración dentro del pipeline completo del sistema.

3.3.4. Implementación en Qiskit 2.x

En Qiskit 2.x, la implementación del sistema híbrido sigue el patrón estándar documentado en [35]:

1. Construir el *feature map* con `zz_feature_map()` o `pauli_feature_map()`.
2. Construir el *ansatz* con `RealAmplitudes(n_qubits, reps=L)`.

3. Componer el circuito VQC: `qc = feature_map.compose(ansatz)`.
4. Crear el `EstimatorQNN` con el circuito compuesto y los observables `SparsePauliOp('Z' * n_qubits)`.
5. Envolver con `TorchConnector` e insertar como primera capa del `nn.Sequential` del MLP en PyTorch.

Es importante señalar que las clases `ZZFeatureMap` y `PauliFeatureMap` están marcadas como obsoletas en Qiskit 2.1 a favor de las funciones `zz_feature_map()` y `pauli_feature_map()`, que retornan un `QuantumCircuit` estándar en lugar de un `BlueprintCircuit` [34]. El presente trabajo utiliza las funciones actualizadas para garantizar compatibilidad con Qiskit 2.x.

3.4. Métricas de separabilidad y evaluación

Este bloque formaliza las métricas utilizadas para evaluar las representaciones generadas por cada condición experimental. Se organizan en dos grupos: métricas de separabilidad, que miden la calidad del espacio de representación con independencia del clasificador; y métricas de clasificación, que miden el desempeño del MLP sobre cada representación.

3.4.1. *Kernel-Target Alignment (KTA)*

El *kernel-target alignment* (KTA) es una medida de la alineación entre un kernel K y el kernel ideal de clasificación $K^* = \mathbf{y}\mathbf{y}^\top$, donde $\mathbf{y} \in \{-1, +1\}^N$ es el vector de etiquetas de clase [37]. Un valor elevado de KTA indica que el kernel captura eficientemente la estructura de clases de los datos.

Dada una muestra de N puntos, la matriz de kernel $K \in \mathbb{R}^{N \times N}$ tiene entradas $K_{ij} = k(\mathbf{z}_i, \mathbf{z}_j)$, donde $k(\cdot, \cdot)$ es la función kernel correspondiente a la condición experimental. El KTA se define como:

$$\widehat{\text{KTA}}(K, \mathbf{y}) = \frac{\langle K, \mathbf{y}\mathbf{y}^\top \rangle_F}{\|K\|_F \cdot \|\mathbf{y}\mathbf{y}^\top\|_F} \quad (33)$$

donde $\langle A, B \rangle_F = \sum_{i,j} A_{ij}B_{ij}$ es el producto de Frobenius y $\|\cdot\|_F$ es la norma de Frobenius. El KTA toma valores en $[-1, 1]$, donde 1 indica alineación perfecta con las etiquetas de clase y 0 indica ausencia de estructura discriminativa.

Para las condiciones cuánticas, el kernel es el kernel cuántico definido en la ecuación (17). Para las condiciones clásicas, el kernel es la matriz de productos internos (baseline crudo), el kernel lineal de PCA, o el kernel RBF, según corresponda. Esto permite una comparación directa de la alineación de cada condición con la estructura de clases del dataset.

3.4.2. Geometric difference

La *geometric difference* fue introducida por Huang et al. [44] como una métrica para cuantificar si un kernel cuántico captura estructura en los datos que el mejor kernel clásico de referencia no puede capturar. Dados el kernel cuántico K_Q y el kernel clásico de referencia K_C (kernel RBF en el presente trabajo), la *geometric difference* se define como:

$$g(K_C, K_Q) = \sqrt{\left\| \sqrt{K_C} K_Q^{-1} \sqrt{K_C} \right\|_{\infty}} \quad (34)$$

donde $\|\cdot\|_{\infty}$ es la norma espectral (eigenvalor máximo) y $\sqrt{K_C}$ es la raíz cuadrada matricial de K_C obtenida por descomposición de Cholesky.

La interpretación de $g(K_C, K_Q)$ es la siguiente. Si $g \approx 1$, ambos kernels capturan la misma estructura geométrica en los datos, lo que implica que existe un modelo clásico con kernel K_C que puede igualar o superar al modelo cuántico. Si $g \gg 1$, el kernel cuántico captura estructura que el kernel RBF no ve, lo que es condición necesaria (aunque no suficiente) para la existencia de ventaja cuántica en ese dominio [44]. Si $g < 1$, el kernel clásico captura estructura que el cuántico no, indicando una limitación del *feature map* seleccionado.

Dado el costo computacional $O(N^2)$ de construir las matrices de kernel, el cálculo de la *geometric difference* se realiza sobre una submuestra representativa de 150–200 casos por subconjunto (masas y calcificaciones).

3.4.3. Índice Davies-Bouldin

El índice Davies-Bouldin (DB) [38] mide la calidad de la separación entre clusters en un espacio de representación, combinando la dispersión intra-clase con la separación inter-clase. Para el problema de clasificación binaria (benigno / maligno), el índice se define como:

$$DB = \frac{1}{C} \sum_{i=1}^C \max_{j \neq i} \left\{ \frac{s_i + s_j}{d(c_i, c_j)} \right\} \quad (35)$$

donde $C = 2$ es el número de clases, s_i es la dispersión promedio de los puntos de la clase i respecto a su centroide c_i :

$$s_i = \frac{1}{|C_i|} \sum_{\mathbf{z} \in C_i} \|\mathbf{z} - c_i\|_2 \quad (36)$$

y $d(c_i, c_j) = \|c_i - c_j\|_2$ es la distancia euclidiana entre los centroides de las clases i y j . Valores bajos del índice DB indican clusters compactos y bien separados; el valor óptimo es 0. Esta métrica es independiente del clasificador y

puede aplicarse directamente sobre el vector de embeddings $\mathbf{e}(\mathbf{x}, \theta)$ de las condiciones cuánticas o sobre los vectores transformados de las condiciones clásicas.

3.4.4. Distancia Fisher

La distancia Fisher (o razón de Fisher) cuantifica la separabilidad entre dos clases como la razón entre la dispersión inter-clase y la dispersión intra-clase en el espacio de representación [39]. Para el caso binario, se define como:

$$J_F = \frac{(\mu_{\text{maligno}} - \mu_{\text{benigno}})^2}{\sigma_{\text{maligno}}^2 + \sigma_{\text{benigno}}^2} \quad (37)$$

donde μ_c y σ_c^2 son la media y varianza del espacio de representación para la clase c . Cuando el espacio de representación es multidimensional ($\mathbb{R}^n$ con $n > 1$), la distancia Fisher se calcula por dimensión y se reporta como el promedio sobre las n dimensiones del embedding.

Valores elevados de J_F indican mayor separabilidad, las clases tienen medias muy diferentes en relación con su varianza interna. Esta métrica cuantifica directamente el principio geométrico de separación lineal entre clases, una representación con J_F elevado tiene clases bien separadas en términos de sus distribuciones marginales, lo que facilita la tarea del clasificador MLP independientemente de la complejidad de la frontera de decisión. En el presente trabajo, J_F se calcula por dimensión sobre el vector de embeddings de cada condición experimental y se reporta como el promedio sobre las n dimensiones, permitiendo comparar directamente la separabilidad lineal inducida por cada transformación sobre el mismo vector de entrada..

3.4.5. Visualización *t*-SNE

El algoritmo *t-Distributed Stochastic Neighbor Embedding* (t-SNE) [40] proyecta vectores de alta dimensionalidad a un espacio de dos dimensiones preservando la estructura de vecindad local. Se utiliza como herramienta de visualización cualitativa de la separabilidad de clases en el espacio de embeddings: si la proyección t-SNE muestra clusters compactos y bien separados por clase, el espacio de representación tiene estructura discriminativa.

A diferencia de las métricas anteriores, t-SNE no produce un valor escalar comparable entre condiciones sino una visualización. Su función en el análisis es complementar las métricas cuantitativas (KTA, DB, J_F , geometric difference) con una inspección visual de la geometría del espacio de representación, facilitando la interpretación de los resultados para el informe final del Trabajo Terminal.

3.4.6. Métricas de clasificación

El desempeño del clasificador MLP sobre cada condición experimental se evalúa mediante cinco métricas estándar de clasificación binaria [41], calculadas sobre el conjunto de prueba:

Exactitud (*Accuracy*):

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN} \quad (38)$$

Precisión (*Precision*):

$$\text{Prec} = \frac{TP}{TP + FP} \quad (39)$$

Exhaustividad (*Recall*):

$$\text{Rec} = \frac{TP}{TP + FN} \quad (40)$$

F1-Score:

$$F_1 = \frac{2 \cdot \text{Prec} \cdot \text{Rec}}{\text{Prec} + \text{Rec}} \quad (41)$$

Área bajo la curva ROC (AUC-ROC):

$$\text{AUC} = \int_0^1 \text{TPR}(t) d\text{FPR}(t) \quad (42)$$

donde TP , TN , FP y FN son los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos respectivamente; $\text{TPR}(t) = TP/(TP + FN)$ es la tasa de verdaderos positivos y $\text{FPR}(t) = FP/(FP + TN)$ es la tasa de falsos positivos, ambas evaluadas al umbral de decisión t .

El AUC-ROC es la métrica principal de comparación porque es insensible al desbalance de clases y mide la capacidad discriminativa del modelo independientemente del umbral de decisión, lo que la hace más robusta que la exactitud para el dataset CBIS-DDSM donde las proporciones de clase varían entre masas y calcificaciones.

3.4.7. Análisis de correlación separabilidad–clasificación

Un objetivo específico del presente trabajo (OE-5) es determinar si la mejora en separabilidad observada en el espacio de representación se traduce en una mejora en el desempeño del clasificador. Para cuantificar esta relación, se calcula el coeficiente de correlación de Spearman ρ_s entre el ranking de las cinco condiciones según las métricas de separabilidad y su ranking según AUC-ROC:

$$\rho_s = 1 - \frac{6 \sum_{i=1}^5 d_i^2}{5(5^2 - 1)} \quad (43)$$

donde d_i es la diferencia de rangos de la condición i entre ambos rankings. Un valor $\rho_s \approx 1$ indicaría que las condiciones con mayor separabilidad también producen mejor clasificación, validando la hipótesis central del trabajo. Un valor $\rho_s \approx 0$ indicaría que la separabilidad en el espacio de representación no predice el desempeño clasificatorio, lo que constituiría un hallazgo igualmente relevante sobre las limitaciones del paradigma de quantum embeddings en el régimen NISQ actual.

Se utiliza la correlación de Spearman en lugar de la de Pearson porque evalúa la monotonía de la relación entre rankings sin asumir linealidad, lo que es apropiado para comparar un número pequeño de condiciones ($n = 5$).

4. Metodología

4.1. Requerimientos del sistema

El sistema desarrollado en el presente trabajo constituye un prototipo de investigación cuyo diseño responde a restricciones tanto técnicas como experimentales. Los requerimientos aquí presentados fueron definidos en concordancia con los objetivos específicos del proyecto y con las características del dataset CBIS-DDSM, y se organizan en requerimientos funcionales, que describen las capacidades que el sistema debe proveer, y requerimientos no funcionales, que establecen las condiciones de calidad, reproducibilidad y viabilidad bajo las cuales el sistema debe operar.

4.1.1. Requerimientos funcionales

Se presentan los requerimientos funcionales de mayor relevancia para justificar las decisiones de diseño del pipeline, organizados por las etapas que determinan la arquitectura del sistema. Cada requerimiento está identificado con un código RF-XX y vinculado al objetivo específico que lo origina.

Cuadro 2: Requerimientos funcionales del sistema

ID	Descripción	OE	Prior.
<i>Módulo 1 – Lectura de datos</i>			
RF-01	Leer archivos DICOM del dataset CBIS-DDSM mediante <code>pydicom</code> , extrayendo el arreglo de píxeles en 16 bits y los metadatos clínicos.	OE-1	Alta
RF-02	Unificar los cuatro archivos CSV del dataset en un <code>DataFrame</code> consolidado con etiqueta binaria (<code>BENIGN=0</code> / <code>MALIGNANT=1</code>).	OE-1	Alta
RF-03	Tratar de forma independiente masas y calcificaciones como subproblemas de clasificación independientes.	OE-1, OE-3	Alta
<i>Módulo 2 – Preprocesamiento</i>			
RF-04	Normalizar los arreglos de píxeles DICOM de 16 bits al rango $[0,0,1,0]$ en <code>float32</code> .	OE-1	Alta
RF-05	Aplicar CLAHE mediante <code>OpenCV</code> para mejorar la visibilidad de estructuras en tejidos de alta densidad.	OE-1	Alta

Continúa en la siguiente página

Tabla 2 – continuación

ID	Descripción	OE	Prior.
RF-06	Recortar la ROI usando las máscaras binarias del dataset y redimensionar a 224×224 píxeles.	OE-1	Alta
<i>Módulo 3 – Extracción de características</i>			
RF-07	Extraer features mediante: (a) PyRadiomics; o (b) CNN encoder pre-entrenado (ResNet-18 / EfficientNet-B0).	OE-1	Alta
<i>Módulo 4 – Selección y escalado</i>			
RF-08	Seleccionar las k características más discriminativas mediante SelectKBest ($k = n_{\text{qubits}} \in [8, 16]$).	OE-1, OE-2	Alta
RF-09	Escalar al rango $[0, \pi]$ mediante MinMaxScaler para compatibilidad con los ángulos del circuito cuántico.	OE-1, OE-2	Alta
<i>Módulo 5 – Transformación (5 condiciones)</i>			
RF-10	<i>Baseline</i> crudo: vector seleccionado y escalado directo al MLP sin transformación adicional.	OE-2	Alta
RF-11	<i>Baseline</i> lineal: PCA sobre el vector seleccionado y escalado, conservando k componentes.	OE-2	Alta
RF-12	<i>Baseline</i> no lineal: Kernel PCA con kernel RBF sobre el vector seleccionado.	OE-2	Alta
RF-13	Condición cuántica ZZFeatureMap: VQC con ZZFeatureMap de segundo orden + RealAmplitudes en Qiskit Aer, retornando $\langle Z_i \rangle \in [-1, 1]^k$.	OE-2	Alta
RF-14	Condición cuántica PauliFeatureMap: VQC con PauliFeatureMap (operadores X, Y, Z) + RealAmplitudes en Qiskit Aer, evaluado independientemente de RF-13.	OE-2	Alta
<i>Análisis de separabilidad</i>			
RF-15	Calcular la matriz de kernel cuántico sobre submuestra de 150–200 casos y computar KTA respecto al kernel ideal.	OE-3	Alta
RF-16	Calcular <i>geometric difference</i> $g(K_C, K_Q) = \sqrt{\ \sqrt{K_C} K_Q^{-1} \sqrt{K_C}\ _\infty}$ entre kernel cuántico y kernel RBF clásico.	OE-3	Alta
RF-17	Medir Davies-Bouldin y distancia Fisher por condición, separado para masas y calcificaciones.	OE-3	Alta

Continúa en la siguiente página

Tabla 2 – continuación

ID	Descripción	OE	Prior.
<i>Módulo 6 – Clasificación</i>			
RF-18	Entrenar el mismo MLP (mínimo 2 capas ocultas) en las 5 condiciones con idéntica arquitectura e hiperparámetros	OE-4	Alta
RF-19	Entrenar con ponderación de clases (<code>class_weight='balanced'</code>) para compensar el desbalance observado (ratio 1.78:1 en calcificaciones).	OE-4	Alta
<i>Módulo 7 – Evaluación comparativa</i>			
RF-20	Reportar AUC-ROC, F1-Score, Accuracy, Precision y Recall por condición, separado para masas y calcificaciones.	OE-5	Alta
RF-21	Analizar la correlación entre ranking de separabilidad (OE-3) y ranking de clasificación (OE-5).	OE-5	Alta
RF-22	Documentar restricciones del simulador: tiempo por muestra, qubits máximos, impacto de <i>shots</i> y costo del <i>parameter-shift</i> .	OE-6	Alta

4.1.2. Requerimientos no funcionales

Los requerimientos no funcionales establecen las condiciones bajo las cuales el sistema debe operar para garantizar la validez científica y reproducibilidad de los resultados.

Cuadro 3: Requerimientos no funcionales del sistema

ID	Categoría	Descripción
RNF-01	Reproducibilidad	Fijar semillas aleatorias en <code>numpy</code> , <code>PyTorch</code> y <code>Qiskit</code> al inicio de cada experimento para garantizar resultados idénticos entre ejecuciones.
RNF-02	Reproducibilidad	Centralizar hiperparámetros en <code>config.yaml</code> con control de versiones.
RNF-03	Reproducibilidad	Usar la partición train/test estándar del CBIS-DDSM (80 %/20 %, estratificada por BI-RADS) sin reordenamiento, aplicada idénticamente a las 5 condiciones.

Continúa en la siguiente página

Tabla 3 – continuación

ID	Categoría	Descripción
RNF-04	Reproducibilidad	Aplicar SelectKBest entrenado solo sobre el conjunto de entrenamiento para transformar el conjunto de prueba, previniendo <i>data leakage</i> .
RNF-05	Rendimiento	Configurar Qiskit Aer con $shots \geq 1024$ para estabilidad de $\langle Z_i \rangle$, documentando el impacto de distintas configuraciones.
RNF-06	Rendimiento	Calcular la matriz de kernel cuántico sobre submuestra de 150–200 casos por subconjunto para viabilidad computacional del cálculo $O(N^2)$ de <i>geometric difference</i> y KTA.
RNF-07	Escalabilidad	Circuito parametrizable: $k \in [8, 16]$, feature map (ZZFeatureMap / PauliFeatureMap), $reps \in [1, 6]$, $shots \in [512, 8192]$.
RNF-08	Mantenibilidad	Código PEP 8 con <i>docstrings</i> por función, organizado en módulos M1–M7 independientes.
RNF- 9	Propiedad intelectual	Registro del trabajo en INDAUTOR.

4.2. Descripción general del proceso

La metodología adoptada en el presente trabajo es **CRISP-DM** (*Cross Industry Standard Process for Data Mining*), adaptada al contexto de cómputo cuántico. Esta metodología fue seleccionada por proporcionar un flujo estructurado que permite integrar de forma natural tanto las etapas clásicas de análisis de datos como las etapas cuánticas de codificación y transformación, manteniendo trazabilidad entre los objetivos de negocio y las decisiones técnicas de implementación.

La correspondencia entre las fases de CRISP-DM y los módulos del sistema se describe en la Tabla 4, y el diagrama completo del pipeline se presenta en la Figura 4.2.1.




Figura 4.2.1: Pipeline del sistema híbrido cuántico-clásico para prediagnóstico de cáncer de mama. El módulo M4 aplica selección de características supervisada (SelectKBest) y escalado angular (MinMaxScaler $\rightarrow [0, \pi]^k$) como preprocesamiento estándar compartido por las 5 condiciones experimentales. ZZFeatureMap y PauliFeatureMap se evalúan como condiciones independientes para comparar el impacto del diseño del *feature map* cuántico.

Cuadro 4: Correspondencia entre fases CRISP-DM y módulos del sistema

Fase CRISP-DM	Módulo	Actividad principal
1. Comprensión del negocio	—	Definición del problema de prediagnóstico, formulación de la pregunta de investigación y criterios de separabilidad.
2. Comprensión de los datos	M1	Lectura DICOM, análisis exploratorio del dataset CBIS-DDSM (EDA).
3. Preparación de los datos	M2, M3, M4	Preprocesamiento de imagen, extracción de features y selección/escalado.
4. Modelado	M5, M6	Implementación de las 5 condiciones de transformación y entrenamiento del MLP.
5. Evaluación	M7	Análisis de separabilidad, métricas de clasificación y comparación clásico vs. cuántico.
6. Despliegue	—	Documentación de hallazgos, reporte técnico y registro INDAUTOR.

4.3. Módulo 1: Lectura de datos

El primer módulo gestiona la adquisición y unificación de los datos del dataset CBIS-DDSM, disponible públicamente en The Cancer Imaging Archive (TCIA). El dataset comprende 1,566 pacientes con imágenes mamográficas digitalizadas en formato DICOM y cuatro archivos CSV con metadatos clínicos y anotaciones patológicas validadas.

La lectura de los archivos DICOM se realiza mediante la librería `pydicom`, extrayendo el arreglo de píxeles en formato de 16 bits y los metadatos clínicos relevantes: `PatientID`, `Modality`, `Rows`, `Columns`, `BitsStored` y `PhotometricInterpretation`. El análisis exploratorio confirmó que la totalidad de las imágenes del dataset utilizan la convención fotométrica `MONOCHROME2`, donde los valores altos corresponden al blanco (tejido denso) y los valores bajos al negro (fondo), lo que elimina la necesidad de inversión de píxeles en el preprocesamiento.

Los cuatro archivos CSV del dataset (`mass_case_description_train_set`, `mass_case_description_test_set`, `calc_case_description_train_set`, `calc_case_description_test_set`) se unifican en un `DataFrame` mediante `pandas`, agregando las columnas `finding_type` (masa / calcificación) y `split` (train / test). La etiqueta objetivo `pathology` se normaliza a una variable binaria: `BENIGN_WITHOUT_CALLBACK` se trata equivalente a `BENIGN`,

resultando en la codificación 0 = benigno y 1 = maligno.

El enlace entre los registros CSV y los archivos DICOM en disco se resuelve mediante un índice construido recursivamente sobre la estructura de carpetas del NBIA Data Retriever, identificando para cada caso el archivo de mamografía completa, la máscara ROI binaria y la imagen recortada. La clasificación entre máscara y recorte se realiza leyendo el contenido de píxeles: las máscaras presentan exactamente dos valores únicos (0 y 255) mientras que las imágenes recortadas presentan cientos de valores distintos.

La salida de este módulo es un DataFrame unificado con 3,568 registros, con rutas resueltas a los archivos DICOM correspondientes y etiquetas binarias validadas, que sirve como base para todos los módulos posteriores.

4.4. Módulo 2: Preprocesamiento de imagen

El módulo de preprocesamiento transforma las imágenes DICOM crudas en representaciones visuales normalizadas y centradas en la región de interés (ROI), adecuadas para la extracción de características del módulo siguiente.

La primera etapa aplica **ecualización de histograma adaptativa con limitación de contraste** (CLAHE, *Contrast Limited Adaptive Histogram Equalization*) mediante OpenCV. CLAHE divide la imagen en bloques locales y ecualiza el histograma de cada bloque con un límite de contraste configurable, mejorando la visibilidad de estructuras finas en tejidos de alta densidad mamaria sin amplificar el ruido en regiones homogéneas [45].

La segunda etapa realiza el **recorte de la región de interés**: la máscara binaria asociada a cada caso se usa para identificar los píxeles de la lesión, y se extrae el recorte cuadrado mínimo que contiene la región activa de la máscara.

Las imágenes de masas y calcificaciones se procesan por separado a lo largo de todo el pipeline, dado que sus características morfológicas relevantes son cualitativamente distintas: las masas requieren capturar geometría global y márgenes, mientras que las calcificaciones requieren capturar patrones texturales finos y distribución espacial de los depósitos de calcio.

4.5. Módulo 3: Extracción de características

El módulo de extracción de características transforma la imagen recortada y normalizada de 224×224 píxeles en un vector numérico compacto $\mathbf{x} \in \mathbb{R}^n$ que captura la información morfológica relevante para la clasificación. Este módulo soporta dos estrategias de extracción:

Estrategia A: Features radiómicas con PyRadiomics. PyRadiomics [46] extrae un conjunto de características cuantitativas estandarizadas directamente desde la imagen y su máscara ROI, organizadas en las siguientes categorías:

- *First-order statistics*: estadísticas de la distribución de intensidades de píxeles (media, varianza, asimetría, curtosis, energía).
- *Shape features*: descriptores geométricos de la forma de la lesión (volumen, superficie, esfericidad, elongación, diámetro máximo).
- *GLCM (Gray Level Co-occurrence Matrix)*: descriptores de textura basados en la co-ocurrencia de pares de intensidades (contraste, correlación, energía, homogeneidad).
- *GLRLM (Gray Level Run Length Matrix)*: descriptores de la longitud de secuencias de píxeles con igual intensidad.

Esta estrategia produce típicamente entre 100 y 300 características por imagen, dependiendo de la configuración de PyRadiomics.

Estrategia B: CNN encoder preentrenado. Como alternativa, se utiliza una red ResNet-18 o EfficientNet-B0 preentrenada en ImageNet como extractor de características, reemplazando su capa de clasificación final por una capa lineal de dimensión k (igual al número de qubits del circuito cuántico). Esta estrategia produce directamente un vector de dimensión k sin necesidad del módulo de selección posterior, capturando representaciones jerárquicas aprendidas desde los datos de imagen.

La estrategia seleccionada para los experimentos reportados en el presente trabajo es la **Estrategia A** (PyRadiomics), dado que produce características con interpretabilidad clínica directa, cada feature tiene un significado morfológico definido, lo que facilita el análisis de los resultados en términos de qué propiedades de la lesión son más discriminativas en el espacio cuántico.

4.6. Módulo 4: Selección y escalado

El módulo de selección y escalado prepara el vector de características para su entrada al circuito cuántico, resolviendo dos requisitos técnicos: reducir la dimensionalidad al número de qubits disponibles y garantizar que los valores sean compatibles con los ángulos de rotación del *feature map*.

Selección de características. Se aplica SelectKBest con criterio F -test de ANOVA, que selecciona las k características con mayor capacidad discriminativa entre clases, medida por la razón de varianza inter-clase sobre varianza intra-clase. El valor de k se fija igual al número de qubits del circuito cuántico ($k \in [8, 16]$), de forma que cada qubit recibe exactamente una característica. El selector se entrena exclusivamente sobre el conjunto de entrenamiento y se aplica al conjunto de prueba para prevenir *data leakage*.

Escalado angular. El vector seleccionado se escala al rango $[0, \pi]$ mediante MinMaxScaler:

$$x_i^{\text{scaled}} = \pi \cdot \frac{x_i - x_i^{\text{mín}}}{x_i^{\text{máx}} - x_i^{\text{mín}}} \quad (44)$$

Este escalado es necesario porque el ZZFeatureMap codifica cada característica x_i como el ángulo de una rotación cuántica $R_Z(x_i)$, que tiene significado físico solo en el rango $[0, 2\pi]$. Escalar a $[0, \pi]$ garantiza que el circuito explore la mitad superior del espacio de fases, evitando redundancias por periodicidad y haciendo los términos de entrelazamiento $(\pi - x_i)(\pi - x_j)$ numéricamente estables.

El vector resultante $\mathbf{x} \in [0, \pi]^k$ es compartido por las cinco condiciones experimentales del módulo M5, garantizando que el único elemento variable entre condiciones sea la transformación aplicada.

4.7. Módulo 5: Transformación

El módulo de transformación implementa las cinco condiciones experimentales del estudio. Todas parten del mismo vector $\mathbf{x} \in [0, \pi]^k$ producido por M4 y producen un vector de representación de dimensión k que alimenta el mismo clasificador MLP en M6. La Tabla 5 resume las cinco condiciones.

Cuadro 5: Cinco condiciones experimentales del Módulo 5

ID	Nombre	Transformación	Tipo
C1	Baseline crudo	Sin transformación. El vector $\mathbf{x}$ pasa directamente al MLP.	Clásico
C2	PCA lineal	Proyección a los k componentes principales de mayor varianza explicada.	Clásico
C3	Kernel PCA (RBF)	Kernel PCA con kernel RBF ($\gamma = 1/k$), proyección no lineal a k dimensiones.	Clásico
C4	ZZFeatureMap	VQC con ZZFeatureMap de segundo orden + RealAmplitudes en Qiskit Aer. Salida: $\langle Z_i \rangle \in [-1, 1]^k$.	Cuántico
C5	PauliFeatureMap	VQC con PauliFeatureMap (operadores Z, ZZ) + RealAmplitudes en Qiskit Aer. Salida: $\langle Z_i \rangle \in [-1, 1]^k$.	Cuántico

Las condiciones C1, C2 y C3 constituyen los *baselines* clásicos y permiten establecer el nivel de referencia de separabilidad y clasificación alcanzable sin componentes cuánticos. La condición C1 sirve como piso mínimo; C2 como

referencia de la mejor transformación lineal posible; y C3 como referencia de la mejor transformación no lineal clásica mediante kernels.

Las condiciones C4 y C5 implementan las transformaciones cuánticas variacionales y se evalúan de forma independiente para comparar el impacto del diseño del *feature map*: ZZFeatureMap captura interacciones de segundo orden entre pares de características mediante el término $(\pi - x_i)(\pi - x_j)$, mientras que PauliFeatureMap generaliza esta codificación con operadores de Pauli multi-eje. El circuito VQC se ejecuta en el simulador AerSimulator de Qiskit con un número de *shots* ≥ 1024 para garantizar estimaciones estadísticamente estables de los valores de expectativa $\langle Z_i \rangle$.

4.8. Módulo 6: Clasificación

El módulo de clasificación entrena y evalúa un mismo clasificador MLP en PyTorch sobre los cinco vectores de representación producidos por M5. La arquitectura del MLP consiste en una capa de entrada de dimensión k , dos capas ocultas con activación ReLU, y una capa de salida con activación sigmoide que produce la probabilidad $\hat{y} \in [0, 1]$ de malignidad.

El entrenamiento se realiza minimizando la función de pérdida de entropía cruzada binaria ponderada (ecuación (31)), con pesos de clase calculados según la ecuación (32) para compensar el desbalance observado en el EDA (ratio 1.78:1 en calcificaciones). Se aplica la misma semilla aleatoria en todas las condiciones para garantizar inicialización idéntica de los pesos del MLP.

Para las condiciones cuánticas C4 y C5, la integración del VQC con el MLP se realiza mediante TorchConnector, que permite la optimización conjunta de los parámetros cuánticos θ y los pesos del MLP en un solo ciclo de entrenamiento.

4.9. Módulo 7: Evaluación comparativa

El módulo de evaluación cuantifica el desempeño de cada condición experimental en dos dimensiones complementarias: la calidad del espacio de representación (separabilidad) y el desempeño del clasificador (clasificación).

Análisis de separabilidad. Para cada condición experimental se calculan las métricas formalizadas en la sección ?? KTA respecto al kernel ideal de clasificación, *geometric difference* $g(K_C, K_Q)$ para las condiciones cuánticas respecto al kernel RBF, índice Davies-Bouldin e índice Fisher, complementados con visualizaciones t-SNE 2D. El análisis se realiza de forma independiente para los subconjuntos de masas y calcificaciones del CBIS-DDSM.

Análisis de clasificación. Se reportan AUC-ROC, F1-Score, Accuracy, Precision y Recall sobre el conjunto de prueba para cada condición, separado por tipo de hallazgo. El AUC-ROC es la métrica principal de comparación por su

robustez ante el desbalance de clases y su independencia del umbral de decisión.

Análisis de correlación separabilidad–clasificación. Se calcula el coeficiente de correlación de Spearman ρ_s entre el ranking de las cinco condiciones según las métricas de separabilidad y su ranking según AUC-ROC (ecuación (43)), para determinar si la mejora en separabilidad en el espacio de representación predice el desempeño clasificatorio. Este análisis responde directamente la pregunta de investigación del presente trabajo.

Documentación de restricciones del simulador. Como parte del objetivo OE-6, se documentan cuantitativamente las restricciones prácticas del simulador Qiskit Aer: tiempo de ejecución por muestra, número máximo viable de qubits, impacto del número de *shots* en la estabilidad de $\langle Z_i \rangle$, y costo computacional del entrenamiento por *parameter-shift*. Estos datos constituyen una contribución metodológica sobre la viabilidad práctica de las técnicas cuánticas en dominios de imagen médica de alta complejidad.

5. Análisis Exploratorio de Datos

El análisis exploratorio de datos (EDA) se realizó sobre el dataset CBIS-DDSM completo, procesando los cuatro archivos CSV y enlazándolos con los 3,568 archivos DICOM descargados mediante el NBIA Data Retriever. El análisis se organiza en cuatro bloques: validación y saneamiento de los datos, análisis de la variable objetivo, análisis de variables clínicas, y análisis de las imágenes DICOM. Todos los resultados descritos en esta sección fueron obtenidos mediante el notebook `modulo1_EDA.ipynb` disponible en el repositorio del proyecto.

5.1. Validación y limpieza de los datos

La carga y unificación de los cuatro archivos CSV produjo un DataFrame consolidado de 3,568 registros, con las columnas `finding_type` (masa / calcificación) y `split` (train / test) agregadas para facilitar el análisis por subconjunto. La Tabla 6 presenta el resumen de la composición del dataset.

Cuadro 6: Composición del dataset CBIS-DDSM unificado

Subconjunto	Train	Test
Masas (mass)	1,318	378
Calcificaciones (calc)	1,546	326
Total	2,864	704

La etiqueta objetivo `pathology` presentó tres valores distintos en los datos originales: BENIGN (1,548 casos), MALIGNANT (1,457 casos) y BENIGN_WITHOUT_CALLBACK (563 casos). Los casos BENIGN_WITHOUT_CALLBACK fueron normalizados a BENIGN por equivalencia clínica, resultando en la codificación binaria 0=benigno (2,111 casos, 59.2 %) y 1 = maligno (1,457 casos, 40.8 %).

La validación de nulos confirmó que las columnas `mass_shape`, `mass_margins`, `calc_type` y `calc_distribution` presentan valores faltantes de naturaleza estructural: los registros de calcificaciones no tienen valores en las columnas de masas y viceversa, por diseño del dataset. No se identificaron errores de datos que requirieran corrección.

La verificación del enlace entre registros CSV y archivos DICOM en disco arrojó una cobertura del 100 % (3,568/3,568 registros con archivo DICOM encontrado), confirmando la integridad de la descarga del dataset.

5.2. Análisis de la variable objetivo

5.2.1. Distribución de clases y balance

La Figura 5.2.1 presenta la distribución de la variable objetivo a nivel global, por tipo de hallazgo y por split.




Figura 5.2.1: Distribución de clases global, por tipo de hallazgo y por split train/test.

El dataset presenta un desbalance global moderado de 1.45:1 (benigno/maligno), que se distribuye de forma heterogénea entre los dos tipos de hallazgo. La Figura 5.2.2 ilustra esta asimetría mediante gráficas de pastel por subconjunto.




Figura 5.2.2: Desbalance de clases por tipo de hallazgo.

Las masas presentan un balance casi simétrico (ratio 1.16:1), con 912 casos benignos y 784 malignos. Las calcificaciones muestran un desbalance más pronunciado (ratio 1.78:1), con 1,199 casos benignos frente a 673 malignos. Esta asimetría tiene una implicación metodológica directa: se requiere ponderación de clases (`class_weight=balanced`) durante el entrenamiento del MLP, aplicada de forma independiente para cada subconjunto, como se especifica en el requerimiento RF-19.

5.2.2. Distribución BI-RADS

La Figura 5.2.3 muestra la distribución de la categoría BI-RADS por patología y tipo de hallazgo.




Figura 5.2.3: Distribución de categorías BI-RADS por patología y tipo de hallazgo.

Se observa una concentración de casos malignos en las categorías BI-RADS 4 y 5 (sospechoso y altamente sospechoso), mientras que los casos benignos se distribuyen predominantemente en las categorías 2 y 3. Esta distribución valida la

coherencia clínica del dataset: la categoría BI-RADS refleja directamente el nivel de sospecha de malignidad asignado por el radiólogo.

5.2.3. Análisis de subtlety

La Figura 5.2.4 presenta la distribución de la puntuación de dificultad de detección (*subtlety*) por patología y tipo de hallazgo.




Figura 5.2.4: Distribución de *subtlety* por patología y tipo de hallazgo. (1 = muy sutil, 5 = obvio).

La media de *subtlety* en casos malignos (3.1 para masas, 2.8 para calcificaciones) es ligeramente inferior a la de casos benignos (3.4 y 3.2 respectivamente), aunque la diferencia es pequeña. Este hallazgo refuta la intuición de que las lesiones malignas son necesariamente más difíciles de detectar visualmente: la dificultad de detección es aproximadamente ortogonal a la patología, lo que explica parcialmente por qué los modelos de deep learning enfrentan dificultades de generalización al no poder apoyarse en la obviedad visual como señal discriminativa.

5.3. Análisis de variables clínicas

5.3.1. Densidad mamaria

La Figura 5.3.1 muestra la distribución de densidad mamaria por patología y tipo de hallazgo.




Figura 5.3.1: Distribución de densidad mamaria (1 = grasa, 4 = extremadamente densa) por patología y tipo de hallazgo.

La densidad mamaria más frecuente en el dataset es la categoría 2 (tejido disperso). El análisis de correlación confirmó que la densidad mamaria tiene una correlación casi nula con la etiqueta de patología ($r = -0,03$ para masas, $r = +0,09$ para calcificaciones), lo que indica que la densidad no predice la malignidad de la lesión. Sin embargo, se observó una correlación negativa moderada entre densidad y *subtlety* ($r = -0,31$ para masas), confirmando que las lesiones son más difíciles de detectar visualmente en tejidos más densos, donde el tejido glandular camufla las estructuras anómalas.

5.3.2. Lateralidad y vista mamográfica

La Figura 5.3.2 presenta la distribución de lateralidad (izquierda / derecha) y vista mamográfica (CC / MLO).




Figura 5.3.2: Distribución de lateralidad y vista mamográfica en el dataset.

La distribución de lateralidad es prácticamente simétrica (1,819 casos izquierdos vs. 1,749 derechos, ratio 1.04:1), lo que indica ausencia de sesgo de adquisición por lado. El ligero predominio de la vista MLO sobre la CC (1,896 vs. 1,672) es esperado clínicamente, dado que la vista MLO captura mayor volumen de tejido mamario incluyendo la región axilar.

5.3.3. Morfología de masas

La Figura 5.3.3 muestra la distribución de forma y margen de las masas por patología.




Figura 5.3.3: Distribución de forma y margen de masas por patología (benigno / maligno).

X

Los resultados revelan una separación morfológica marcada entre clases. Las masas malignas se asocian predominantemente con formas *IRREGULAR* y márgenes *SPICULATED*, patrón clínico clásico del carcinoma invasivo, donde el tumor crece desordenadamente con extensiones hacia el tejido circundante. Las masas benignas presentan formas *OVAL* con bordes *CIRCUMSCRIBED*, patrón típico de fibroadenomas o quistes encapsulados. Esta separación morfológica sugiere que las características extraídas de masas deberían ser intrínsecamente más separables en cualquier espacio de representación, incluyendo el espacio de Hilbert cuántico generado por los *feature maps*.

5.3.4. Morfología de calcificaciones

La Figura 5.3.4 presenta la distribución de tipo y distribución de las calcificaciones por patología.




Figura 5.3.4: Distribución de tipo y distribución espacial de calcificaciones por patología.

A diferencia de las masas, las calcificaciones presentan el tipo morfológico más frecuente (*PLEOMORPHIC*) compartido entre ambas clases. Este solapamiento morfológico implica que las calcificaciones constituyen un problema de clasificación intrínsecamente más complejo, donde la separabilidad en el espacio de representación clásico es menor. Este escenario es particularmente relevante para el presente trabajo: es precisamente en estos casos de baja separabilidad clásica donde las transformaciones cuánticas variacionales tienen mayor potencial de aporte, al proyectar los datos en un espacio de Hilbert con geometría cualitativamente distinta que puede revelar estructura discriminativa no accesible para los métodos clásicos.

5.3.5. Correlaciones entre variables clínicas

La Figura 5.3.5 presenta la matriz de correlación de las variables clínicas numéricas del dataset.




Figura 5.3.5: Matriz de correlación de variables clínicas numéricas por tipo de hallazgo.

La variable `assessment` (categoría BI-RADS) presenta la correlación más alta con la etiqueta de patología ($r = +0,51$ para masas, $r = +0,43$ para calcificaciones), lo cual es esperado dado que el BI-RADS fue diseñado precisamente como escala de sospecha de malignidad. Sin embargo, esta variable no puede utilizarse como *feature* de entrada al modelo porque constituye *data leakage*: es una etiqueta clínica derivada de la imagen, no una característica morfológica independiente.

Las variables `breast_density` y `subtlety` presentan correlaciones prácticamente nulas con la etiqueta de patología ($|r| < 0,12$ en todos los casos), confirmando que el poder predictivo reside en las características morfológicas de la imagen y no en los metadatos clínicos del CSV. Este resultado valida la decisión metodológica de extraer *features* directamente de las imágenes DICOM mediante PyRadiomics.

5.4. Análisis de imágenes DICOM

5.4.1. Dimensiones y características técnicas

La Figura 5.4.1 muestra la distribución de dimensiones de las mamografías completas en la muestra analizada.




Figura 5.4.1: Distribución de dimensiones (altura y anchura en píxeles) de las mamografías completas (muestra $n = 300$).

Las mamografías completas presentan dimensiones medianas de $5,037 \times 2,960$ píxeles con profundidad de 16 bits, lo que confirma que su tamaño es incompatible con la entrada directa a un circuito cuántico. Este hallazgo valida la decisión de diseño de trabajar con las imágenes recortadas de ROI (224×224 píxeles) en lugar de las mamografías completas.

La inspección de los metadatos DICOM reveló que las imágenes del dataset son de tipo *Secondary Capture* (SOPClassUID: 1.2.840.10008.5.1.4.1.1.7), generadas mediante MATLAB (SecondaryCaptureDeviceManufacturer: MathWorks) como parte del proceso de digitalización y curaduría del CBIS-DDSM. La convención fotométrica es MONOCHROME2 de forma uniforme en todo el dataset, lo que elimina la necesidad de inversión de píxeles en el preprocesamiento.

5.4.2. Variabilidad inter-escáner

La Figura 5.4.2 presenta la distribución de fabricantes de escáner en la muestra.




Figura 5.4.2: Distribución de fabricantes de escáner en la muestra analizada.

El campo *Manufacturer* del estándar DICOM reporta UNKNOWN de forma uniforme, dado que las imágenes son *Secondary Capture* procesadas por MATLAB y no retienen los metadatos del escáner original. Esta uniformidad implica que no es posible realizar un análisis de variabilidad inter-escáner mediante metadatos.

5.4.3. Distribución de intensidades de píxeles

La Figura 5.4.3 compara las distribuciones de estadísticas de intensidad de píxeles entre casos benignos y malignos en las imágenes recortadas de ROI.




Figura 5.4.3: Distribución de estadísticas de intensidad de píxeles (media, desviación estándar y máximo) en imágenes recortadas de ROI, por patología.

Las imágenes recortadas presentan valores de intensidad media en el rango de 45,000–50,000 sobre un máximo posible de 65,535 (16 bits), con máximos frecuentemente en el límite superior. Las distribuciones de casos benignos y malignos


muestran solapamiento considerable en las tres estadísticas analizadas, confirmando que la información discriminativa no reside en estadísticas globales de intensidad sino en patrones texturales y morfológicos de orden superior, que son precisamente los que capturan las *features* radiómicas de PyRadiomics.

5.4.4. Galería de casos representativos

La Figura 5.4.4 presenta una galería de casos representativos del dataset, mostrando para cada caso la mamografía completa, la máscara binaria ROI y la imagen recortada centrada en la lesión.

Sample Cases: Full Mammogram | ROI Mask | Cropped ROI


Full
5491x2986




ROI Mask



Cropped
466x423



Full
5491x3046




ROI Mask



Cropped
427x422




Full
4808x3024




ROI Mask




Cropped
515x431




Full
4800x2656




ROI Mask




Cropped
292x256




Full
5356x2986




ROI Mask



Cropped
681x577




Full
5491x3166



ROI Mask



Cropped
689x761



La galería ilustra visualmente las diferencias morfológicas descritas en el análisis de variables clínicas: las masas malignas muestran bordes irregulares y espiculados, mientras que las masas benignas presentan contornos lisos y bien definidos. En las calcificaciones, la distinción visual entre clases es menos evidente, consistente con el hallazgo de que PLEOMORPHIC es el tipo morfológico más frecuente en ambas clases.

La Figura 5.4.5 muestra la superposición de la máscara ROI sobre la mamografía completa para cuatro casos seleccionados.




Figura 5.4.5: Superposición de la máscara ROI (región en rojo) sobre la mamografía completa para cuatro casos representativos.

La visualización confirma que las máscaras ROI delimitan con precisión la región de la lesión dentro de la mamografía completa, validando su uso como guía para el recorte en el preprocesamiento.

5.5. Hallazgos principales y consideraciones para el modelado

El análisis exploratorio permite identificar los siguientes hallazgos de mayor relevancia para el diseño del pipeline experimental:

1. **Desbalance de clases diferenciado.** El ratio benigno/maligno es 1.16:1 para masas y 1.78:1 para calcificaciones. La ponderación de clases durante el entrenamiento del MLP es necesaria para calcificaciones pero opcional para masas. Los modelos se evalúan con AUC-ROC como métrica principal por su robustez ante este desbalance.
2. **Asimetría de separabilidad esperada.** Las masas presentan patrones morfológicos claramente diferenciados entre clases (IRREGULAR/SPICULATED vs. OVAL/CIRCUMSCRIBED), prediciendo mayor separabilidad en el espacio de representación. Las calcificaciones comparten el tipo morfológico más frecuente (PLEO-

MORPHIC) entre ambas clases, prediciendo menor separabilidad y constituyendo el caso de prueba más exigente para los quantum embeddings.

3. **Variables clínicas no predictivas.** La densidad mamaria y el *subtlety* tienen correlación prácticamente nula con la patología. La información discriminativa reside en los patrones morfológicos de la imagen, validando el uso de PyRadiomics como extractor de características.
4. **Imágenes de alta dimensionalidad.** Las mamografías completas tienen dimensiones medianas de $5,037 \times 2,960$ píxeles, incompatibles con entrada directa al circuito cuántico. El trabajo con imágenes recortadas de ROI (224×224 píxeles) seguido de extracción de características y selección de k features es la única estrategia viable para el régimen de simulación cuántica disponible.
5. **Convención fotométrica uniforme.** La totalidad del dataset utiliza MONOCHROME2, eliminando la necesidad de inversión de píxeles en el preprocesamiento y simplificando la normalización de intensidades.

Bibliografía

Referencias

- [1] World Health Organization. (2025, August 14). *World Health Organization*. Retrieved from WHO Web site: <https://www.who.int/news-room/fact-sheets/detail/breast-cancer>
- [2] Freihat, O., Sipos, D., & Kovacs, A. (2025). Global burden and projections of breast cancer incidence and mortality to 2050: a comprehensive analysis of GLOBOCAN data. *Frontiers in Public Health*, 13, 1622954. <https://doi.org/10.3389/fpubh.2025.1622954>
- [3] Breast Cancer Research Foundation. (2025). Breast cancer statistics and resources. Retrieved from <https://www.bcrf.org/breast-cancer-statistics-and-resources/>
- [4] Stop Breast Cancer. (2025). Facts & figures. Retrieved from <https://www.stopbreastcancer.org/information-center/facts-figures/>
- [5] American Cancer Society. (2024). Global cancer statistics. Retrieved from <https://pressroom.cancer.org/GlobalCancerStatistics2024>
- [6] Consultores Salud. (2025). Cáncer de mama en México. Retrieved from <https://consultorsalud.com.mx/cancer-de-mama-en-mexico/>
- [7] Instituto Nacional de Estadística y Geografía. (2025). Estadísticas de cáncer de mama. Retrieved from https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2025/EAP_CancerMama_25.pdf
- [8] National Breast Cancer Foundation. (2026). Early detection of breast cancer. Retrieved from <https://www.nationalbreastcancer.org/early-detection-of-breast-cancer/>
- [9] National Breast Cancer Foundation. (2026). Breast cancer facts & statistics. Retrieved from <https://www.nationalbreastcancer.org/breast-cancer-facts/>
- [10] Windsong Radiology. (2026). How early detection affects breast cancer survival rates. Retrieved from <https://windsongwny.com/breast-health/how-early-detection-affects-breast-cancer-survival-rates/>
- [11] Instituto Nacional de Estadística y Geografía. (2023). Estadísticas de cáncer de mama. Retrieved from https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2023/EAP_CMAMA23.pdf

- [12] American Cancer Society. (2024, April). Global cancer statistics 2024. Retrieved from <https://pressroom.cancer.org/GlobalCancerStatistics2024>
- [13] Wang, X., Liang, G., Zhang, Y., Blanton, H., Bessinger, Z., & Jacobs, N. (2020). Inconsistent performance of deep learning models on mammogram classification. *Journal of the American College of Radiology*, 17(6), 796-803. <https://doi.org/10.1016/j.jacr.2020.01.006>
- [14] Kim, J., Harper, A., McCormack, V., Sung, H., Houssami, N., Morgan, E., Mutebi, M., et al. (2025). Global patterns and trends in breast cancer incidence and mortality across 185 countries. *Nature Medicine*, 31(4), 1154-1162. <https://doi.org/10.1038/s41591-025-03502-3>
- [15] Xiang, Q., Li, D., Hu, Z., Yuan, Y., Sun, Y., Zhu, Y., Fu, Y., Jiang, Y., et al. (2024). Quantum classical hybrid convolutional neural networks for breast cancer diagnosis. *Scientific Reports*, 14(1), 24699. <https://doi.org/10.1038/s41598-024-74778-7>
- [16] Azevedo, V., Silva, C., & Dutra, I. (2022). Quantum transfer learning for breast cancer detection. *Quantum Machine Intelligence*, 4(1), 5. <https://doi.org/10.1007/s42484-022-00062-4>
- [17] Sáez Ortuño, L., Forgas Coll, S., & Ferrara, M. (2026). Quantum kernel methods for marketing analytics with convergence theory and separation bounds. *Scientific Reports*, 16(1), 6645. <https://doi.org/10.1038/s41598-026-35793-y>
- [18] Alvarez-Estevez, D. (2024). Benchmarking quantum machine learning kernel training for classification tasks. arXiv preprint arXiv:2408.10274. <https://doi.org/10.48550/arXiv.2408.10274>
- [19] Author(s). (2021). [Article title]. *AI Magazine*, 42(4), [pages]. <https://doi.org/10.1080/08839514.2021.2001177>
- [20] Gao, Y., Lin, J., Zhou, Y., & Lin, R. (2023). The application of traditional machine learning and deep learning techniques in mammography: a review. *Frontiers in Oncology*, 13, 1213045. <https://doi.org/10.3389/fonc.2023.1213045>
- [21] Mashekova, A., Zhao, M. Y., Zarikas, V., Mukhmetov, O., Aidossov, N., Ng, E. Y. K., & Wang, D. (2025). Review of artificial intelligence techniques for breast cancer detection with different modalities: Mammography, ultrasound, and thermography images. *Bioengineering*, 12(10), 1110. <https://doi.org/10.3390/bioengineering12101110>
- [22] Avci, H., & Karakaya, J. (2023). A novel medical image enhancement algorithm for breast cancer detec-

- tion on mammography images using machine learning. *Diagnostics*, 13(3), 348. <https://doi.org/10.3390/diagnostics13030348>
- [23] Añez, D., Conti, G., Uriarte, J. J., Serrano-Olmedo, J.-J., Martínez-Murillo, R., & Casanova-Carvajal, O. (2025). Artificial intelligence pipeline for mammography-based breast cancer detection: An integrated systematic review and large-scale experimental validation. *Medicina*, 61(12), 2237. <https://doi.org/10.3390/medicina61122237>
- [24] Abdelhafiz, D., Yang, C., Ammar, R., et al. (2019). Deep convolutional neural networks for mammography: advances, challenges and applications. *BMC Bioinformatics*, 20(Suppl 11), 281. <https://doi.org/10.1186/s12859-019-2823-4>
- [25] Shen, L., Margolies, L. R., Rothstein, J. H., et al. (2019). Deep learning to improve breast cancer detection on screening mammography. *Scientific Reports*, 9, 12495. <https://doi.org/10.1038/s41598-019-48995-4>
- [26] Baccouche, A., Garcia-Zapirain, B., & Elmaghraby, A. S. (2022). An integrated framework for breast mass classification and diagnosis using stacked ensemble of residual neural networks. *Scientific Reports*, 12, 12259. <https://doi.org/10.1038/s41598-022-15632-6>
- [27] Shia, W. C. (2025). Deep learning-based classification of benign and malignant breast microcalcifications in mammography. *Scientific Reports*, 15, 42768. <https://doi.org/10.1038/s41598-025-27149-9>
- [28] Schuld, M., & Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504. <https://doi.org/10.1103/PhysRevLett.122.040504>
- [29] Long, C., Huang, M., Ye, X., et al. (2025). Hybrid quantum-classical-quantum convolutional neural networks. *Scientific Reports*, 15, 31780. <https://doi.org/10.1038/s41598-025-13417-1>
- [30] Radhi, E. A., Kamil, M. Y., & Mohammed, M. A. (2025). Quantum machine and deep learning for medical image classification: A systematic review of trends, methodologies, and future directions. *Iraqi Journal for Computer Science and Mathematics*, 6(2), Article 9. <https://doi.org/10.52866/2788-7421.1252>
- [31] Nielsen, M. A., & Chuang, I. L. (2010). *Quantum computation and quantum information: 10th anniversary edition*. Cambridge University Press. <https://doi.org/10.1017/CB09780511976667>
- [32] Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., McClean, J. R., Mitarai, K., Yuan, X., Cincio, L., & Coles, P. J. (2021). Variational quantum algorithms. *Nature Reviews Physics*, 3, 625–644. <https://doi.org/10.1038/s42254-021-00348-9>

- [33] Mitarai, K., Negoro, M., Kitagawa, M., & Fujii, K. (2018). Quantum circuit learning. *Physical Review A*, 98(3), 032309. <https://doi.org/10.1103/PhysRevA.98.032309>
- [34] IBM Quantum. (2024). Qiskit Circuit Library: `zz_feature_map` and `PauliFeatureMap`. IBM Quantum Documentation. https://docs.quantum.ibm.com/api/qiskit/qiskit.circuit.library.zz_feature_map
- [35] IBM Quantum. (2024). Qiskit Machine Learning: `EstimatorQNN` and `TorchConnector`. Qiskit Machine Learning Documentation. <https://qiskit-community.github.io/qiskit-machine-learning/>
- [36] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. <https://www.deeplearningbook.org>
- [37] Cristianini, N., Shawe-Taylor, J., Elisseeff, A., & Kandola, J. (2002). On kernel-target alignment. In *Advances in Neural Information Processing Systems (NeurIPS)*, 14. <https://proceedings.neurips.cc/paper/2001/hash/1f71e393b3809197ed66df836fe833e5-Abstract.html>
- [38] Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1(2), 224–227. <https://doi.org/10.1109/TPAMI.1979.4766909>
- [39] Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188. <https://doi.org/10.1111/j.1469-1809.1936.tb02137.x>
- [40] van der Maaten, L., & Hinton, G. (2008). Visualizing data using *t*-SNE. *Journal of Machine Learning Research*, 9, 2579–2605. <https://jmlr.org/papers/v9/vandermaten08a.html>
- [41] Powers, D. M. W. (2011). Evaluation: from precision, recall and *F*-measure to ROC, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63. <https://arxiv.org/abs/2010.16061>
- [42] Schuld, M., & Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504. <https://doi.org/10.1103/PhysRevLett.122.040504>
- [43] Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., & Gambetta, J. M. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567, 209–212. <https://doi.org/10.1038/s41586-019-0980-2>
- [44] Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). Power of data in quantum machine learning. *Nature Communications*, 12, 2631. <https://doi.org/10.1038/s41467-021-22539-9>

- [45] Reza, A. M. (2004). Realization of the contrast limited adaptive histogram equalization (CLAHE) for real-time image enhancement. *Journal of VLSI Signal Processing*, 38, 35–44. <https://doi.org/10.1023/B:VLSI.0000028532.53893.82>
- [46] van Griethuysen, J. J. M., et al. (2017). Computational radiomics system to decode the radiographic phenotype. *Cancer Research*, 77(21), e104–e107. <https://doi.org/10.1158/0008-5472.CAN-17-0339>