INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
ESCOM

Trabajo Terminal

“Modelo de transformación cuántica variacional de características de cáncer de mama para un sistema híbrido de prediagnóstico”

2026-B039

Presenta

Miguel Alexander Sánchez García

Directores

Dr. Jesús Yaljá Montiel Pérez ***Dra. Ana María Winfield Reyes***

Noviembre de 2026

INSTITUTO POLITÉCNICO NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO
SUBDIRECCIÓN ACADÉMICA

No. de TT 2026-B039 Noviembre de 2026

Documento Técnico

"Modelo de transformación cuántica variacional de características de cáncer de mama para un sistema híbrido de prediagnóstico"

Presenta

Miguel Alexander Sánchez García[1]

Directores

Dr. Jesús Yaljá Montiel Pérez ***Dra. Ana María Winfield Reyes***

RESUMEN

En este reporte se evalúa la viabilidad de las transformaciones cuánticas variacionales como mecanismo de codificación de características morfológicas de mamografías reales. Sobre las 3,568 lesiones del CBIS-DDSM, con masas y calcificaciones como subproblemas independientes, se extraen 67 características radiómicas con PyRadiomics, se seleccionan 12 y se escalan al intervalo $[0, \pi]$. El mismo vector alimenta cinco condiciones: sin transformación, PCA, Kernel PCA con kernel RBF y dos *feature maps* cuánticos (ZZ y Pauli con términos Y y ZZ) seguidos de un *ansatz* de parámetros fijos, simulados con Qiskit Aer. La separabilidad se mide con el *kernel-target alignment*, la *geometric difference* regularizada, la dimensión efectiva, el índice de Davies-Bouldin y la distancia de Fisher; la clasificación, con un mismo perceptrón multicapa y validación cruzada agrupada por paciente.

Las representaciones cuánticas no muestran mayor separabilidad en ninguna métrica. El kernel cuántico está concentrado (mediana fuera de la diagonal cercana a 0.003, frente a 0.61 del RBF) y la *geometric difference* (1.40 a 1.70) queda muy por debajo del umbral $\sqrt{N} \approx 14$. El perceptrón pierde entre 0.07 y 0.14 de AUC-ROC sobre los *embeddings* cuánticos, mientras que una SVM sobre el kernel cuántico iguala a la clásica, lo que sitúa la pérdida en la lectura de los valores esperados y no en la codificación. Se cuantifican además las restricciones del simulador: con 1,024 disparos, entre el 16 y el 74 % de los valores del kernel se leerían exactamente como cero.

Palabras clave: aprendizaje automático cuántico, *quantum embeddings*, kernels cuánticos, separabilidad de clases, radiómica, CBIS-DDSM, cáncer de mama.

[1] msanchezg1904@alumno.ipn.mx

CARTA RESPONSIVA

Aquí se integra escaneada, con las firmas de los directores.

Archivo: `Docs/preliminares/carta_responsiva.pdf`

Advertencia

"Este documento contiene información desarrollada por la Escuela Superior de Cómputo del Instituto Politécnico Nacional, a partir de datos y documentos con derecho de propiedad y por lo tanto, su uso quedará restringido a las aplicaciones que explícitamente se convengan."

La aplicación no convenida exime a la escuela su responsabilidad técnica y da lugar a las consecuencias legales que para tal efecto se determinen.

Información adicional sobre este reporte técnico podrá obtenerse en:

La Subdirección Académica de la Escuela Superior de Cómputo del Instituto Politécnico Nacional, situada en Av. Juan de Dios Bátiz s/n Teléfono: 57296000, extensión 52000.

CARTA DE AUTORIZACIÓN DE DIFUSIÓN EN EL REPOSITORIO INSTITUCIONAL DE TESIS

Aquí se integra escaneada y firmada en tinta azul.

Archivo: `Docs/preliminares/carta_difusion.pdf`

Índice

Índice de tablas **11**

Índice de figuras **13**

Índice de listados **17**

Abstract **18**

1. Panorama General **19**

1.1. Introducción 19

1.1.1. Contexto clínico del cáncer de mama 19

1.1.2. Limitaciones de los métodos clásicos de diagnóstico asistido 21

1.1.3. Computación cuántica como alternativa 22

1.2. Planteamiento del problema 23

1.3. Justificación 25

1.4. Objetivos 27

1.4.1. Objetivo general 27

1.4.2. Objetivos específicos 27

1.5. Alcance y limitaciones 28

2. Antecedentes **30**

2.1. Estado del arte 30

2.1.1. Aprendizaje automático clásico en el diagnóstico mamográfico 30

2.1.2. Aprendizaje profundo en el diagnóstico mamográfico 31

2.1.3. Fundamentos de *quantum machine learning* y codificación cuántica de datos 32

2.1.4. Modelos híbridos cuántico-clásicos en el sector salud 34

2.1.5. Trabajos específicos sobre el CBIS-DDSM 35

2.1.6. Límites de la ventaja cuántica con datos clásicos 36

2.1.7. Representaciones cuánticas de imágenes 39

2.1.8. Revisión crítica de los trabajos que reportan ventaja 42

2.1.9. Tabla comparativa y brechas identificadas 45

3. Marco Teórico **47**

3.1. Fundamentos de computación cuántica 47

3.1.1. El qubit como unidad de información cuántica 47

3.1.2. Compuertas cuánticas de un qubit 48
3.1.3. Sistemas de múltiples qubits y entrelazamiento 49
3.1.4. Medición y valores de expectativa 50
3.2. Circuitos cuánticos variacionales y *quantum embeddings* 51
3.2.1. Circuitos cuánticos parametrizados (PQC) 51
3.2.2. El *feature map* como mapeo no lineal al espacio de Hilbert 51
3.2.3. *ZZFeatureMap*: evolución de Pauli-Z de segundo orden 52
3.2.4. *PauliFeatureMap*: generalización por elección de los operadores de Pauli . 53
3.2.5. El *ansatz* variacional: RealAmplitudes 54
3.2.6. El *quantum embedding*: vector de salida del circuito 55
3.2.7. El método *parameter-shift* para el cálculo del gradiente 56
3.3. Red neuronal clásica e integración Qiskit–PyTorch 57
3.3.1. Perceptrón multicapa (MLP) 57
3.3.2. Ponderación de clases para datos desbalanceados 58
3.3.3. Integración cuántico-clásica: *embeddings* precomputados 58
3.3.4. Implementación en Qiskit 2.x 59
3.4. Métricas de separabilidad y evaluación 60
3.4.1. *Kernel-Target Alignment* (KTA) 60
3.4.2. *Geometric difference* 62
3.4.3. Dimensión efectiva 65
3.4.4. Índice Davies-Bouldin 65
3.4.5. Razón multivariante de Fisher 66
3.4.6. Visualización *t-SNE* 67
3.4.7. Métricas de clasificación 67
3.4.8. Análisis de correlación separabilidad–clasificación 69
3.5. Representaciones clásicas y modelos de kernel 70
3.5.1. Características radiómicas 70
3.5.2. Análisis de componentes principales (PCA) 71
3.5.3. Análisis de componentes principales con kernel (Kernel PCA) 72
3.5.4. Máquina de vectores de soporte (SVM) 73
3.5.5. Máquina de vectores de soporte cuántica (QSVM) 73
3.5.6. Kernel cuántico proyectado 74

4. Análisis Exploratorio de Datos **75**
4.1. Validación y limpieza de los datos 75
4.2. Análisis de la variable objetivo 76

4.2.1. Distribución de clases y balance . . . 76
4.2.2. Distribución BI-RADS . . . 77
4.2.3. Análisis de subtlety . . . 77
4.3. Análisis de variables clínicas . . . 78
4.3.1. Densidad mamaria . . . 78
4.3.2. Lateralidad y vista mamográfica . . . 78
4.3.3. Morfología de masas . . . 78
4.3.4. Morfología de calcificaciones . . . 79
4.3.5. Correlaciones entre variables clínicas . . . 80
4.4. Análisis de imágenes DICOM . . . 80
4.4.1. Dimensiones y características técnicas . . . 80
4.4.2. Variabilidad inter-escáner . . . 81
4.4.3. Distribución de intensidades de píxeles . . . 81
4.4.4. Galería de casos representativos . . . 82
4.5. Implicaciones para el diseño . . . 83

5. Metodología **85**
5.1. Descripción general del proceso . . . 86
5.2. Requerimientos del sistema . . . 87
5.2.1. Requerimientos funcionales . . . 87
5.2.2. Requerimientos no funcionales . . . 90
5.3. Módulo 1: Lectura de datos . . . 92
5.4. Módulo 2: Preprocesamiento de imagen . . . 93
5.5. Módulo 3: Extracción de características . . . 95
5.6. Módulo 4: Selección y escalado . . . 96
5.7. Módulo 5: Transformación . . . 97
5.8. Módulo 6: Análisis de separabilidad . . . 99
5.9. Módulo 7: Clasificación . . . 101
5.10. Módulo 8: Evaluación comparativa . . . 102
5.11. Experimentos complementarios . . . 103

6. Resultados **108**
6.1. Datos, características y selección . . . 108
6.2. Separabilidad de las representaciones . . . 113
6.3. Clasificación . . . 122
6.4. Clasificadores de kernel y búsqueda de ventaja . . . 130
6.5. Evaluación comparativa . . . 134

6.6. Restricciones del simulador (OE-6) . . . 137
6.7. Hallazgos de implementación . . . 139
6.8. Síntesis por objetivo específico . . . 141

7. Conclusiones **145**
7.1. Respuesta a la pregunta de investigación . . . 145
7.2. Cumplimiento de los objetivos . . . 146
7.3. Por qué la codificación cuántica no aumentó la separabilidad . . . 146
7.4. Viabilidad práctica . . . 148
7.5. Aportaciones . . . 148
7.6. Limitaciones . . . 149

8. Trabajo a Futuro **151**
8.1. Codificaciones que eviten la concentración . . . 151
8.2. Lecturas más ricas del estado codificado . . . 152
8.3. Ejecución en procesadores cuánticos . . . 152
8.4. Datos y características . . . 152
8.5. Refinamientos metodológicos . . . 153

Referencias **154**

Glosario **162**

A. Código de los módulos **163**
A.1. Módulo 2: Preprocesamiento y alineación de máscaras . . . 163
A.2. Módulo 3: Extracción de características radiómicas . . . 164
A.3. Módulo 4: Selección y escalado angular . . . 165
A.4. Módulo 5: Transformaciones cuánticas y kernels . . . 166
A.5. Módulo 6: Separabilidad geométrica . . . 167
A.6. Módulo 7: Clasificación supervisada . . . 168
A.7. Módulo 8: Evaluación comparativa y muestreo . . . 170

B. Salidas y resultados complementarios **171**
B.1. Preprocesamiento y auditoría de máscaras (Módulo 2) . . . 171
B.2. Selección y redundancia de características (Módulo 4) . . . 172
B.3. Estratificación de pliegues en validación cruzada (Módulo 4) . . . 173
B.4. Costes computacionales de simulación cuántica (Módulos 5, 8 y X8) . . . 174
B.5. Verificaciones automáticas y control metodológico (Módulos 5 a 8 y X5) . . . 175

C. Figuras complementarias **178**
C.1. Preprocesamiento e imágenes de entrada 178
C.2. Circuitos cuánticos y mapas de características 181
C.3. Complejidad, costes y muestreo de estados cuánticos 182
C.4. Experimentos complementarios de kernels, dimensionalidad y QSVM 184
C.5. Figuras del análisis exploratorio 186

D. Entorno de ejecución y reproducibilidad **186**
D.1. Paquetes y dependencias del sistema 190
D.2. Procedimiento de compilación de PyRadiomics 190
D.3. Especificaciones de hardware y plataforma 191
D.4. Semillas aleatorias y verificación de reproducción determinista 191

E. Índice de decisiones metodológicas **192**

Índice de cuadros

1. Comparativa de trabajos relacionados en el estado del arte 46
2. Composición del dataset CBIS-DDSM unificado 76
3. Correspondencia entre hallazgos del EDA y decisiones de diseño del pipeline . . . 84
4. Requerimientos funcionales del sistema 87
5. Requerimientos no funcionales del sistema 90
6. Correspondencia entre fases CRISP-DM y módulos del sistema 92
7. Cinco condiciones experimentales del Módulo 5 97
8. Resumen de diseño de los experimentos complementarios X1 a X9. 104
9. Las 12 características seleccionadas en cada subconjunto (M4): F-test ANOVA sobre el entrenamiento con restricción de redundancia $|r| \leq 0.95$. 111
10. Separabilidad en la familia de kernels (M6), $c = 1$, 200 lesiones de entrenamiento por subconjunto. 116
11. Separabilidad en la familia de embeddings (M6): 200 lesiones de entrenamiento por subconjunto. 118
12. Comparación de métricas de separabilidad entre las configuraciones con $k = 12$ y $k = 8$ qubits ($c = 1$, submuestra de 200 lesiones por subconjunto). 122
13. Clasificación con el mismo MLP sobre las cinco representaciones (M7, $k = 12$). . . 124
14. Diferencias pareadas de AUC en el conjunto de prueba (M7). 125
15. Dependencia del AUC de C4 y C5 respecto al sorteo de θ: 10 sorteos, mismo MLP y mismos folds que el M7. 127
16. Efecto de entrenar θ junto con el MLP: de θ fijo (M7) a θ entrenado. 128
17. Correlación de Spearman entre el orden de separabilidad y el de clasificación de las cinco condiciones (M8). 134
18. Síntesis de resultados y evidencia empírica por objetivo específico. 143
19. Resumen del preprocesamiento, alineación de máscaras y control de calidad (Módulo 2). 171
20. Conjunto completo de características radiómicas seleccionadas por subconjunto (Módulo 4). 172
21. Características radiómicas descartadas por restricción de redundancia (Módulo 4). . 173
22. Balance de lesiones, pacientes y proporción de malignidad por fold (Módulo 4). . . 174
23. Costes computacionales de evaluación de kernels cuánticos (Módulo 5). 174
24. Escalamiento computacional con el número de qubits en simulación por vector de estado (OE-6). 175

25. Coste computacional del cálculo de gradientes variacionales (Experimento X8). . . 175
26. Resumen de la suite de verificaciones automáticas de consistencia y correctitud. . . 176
27. Auditoría metodológica independiente de consistencia, datos y modelos (Experimento X5). 177
28. Versiones de los paquetes de software fundamentales en los entornos de ejecución. 190
29. Índice cronológico de decisiones metodológicas documentadas en la bitácora. . . . 192

Índice de figuras

3.1.1. Esfera de Bloch: representación geométrica de un qubit. El estado $|\psi\rangle$ se representa como un punto en la superficie de la esfera, determinado por los ángulos θ y φ. . . 48

3.4.1. Geometría (función kernel) definida por modelos clásicos y cuánticos. Las letras representan datos y las flechas, la similitud entre ellos; la *geometric difference* g mide cuánto difieren esas similitudes entre modelos, y d es la dimensión efectiva del conjunto de entrenamiento en el espacio de Hilbert. Reproducida de Huang et al. (2021), *Nat. Commun.* 12, 2631, bajo licencia CC BY 4.0 (https://creativecommons.org/licenses/by/4.0/). 64

4.2.1. Desbalance de clases por tipo de hallazgo. 77

4.3.1. Distribución de forma y margen de masas por patología (benigno / maligno). 79

4.3.2. Distribución de tipo y distribución espacial de calcificaciones por patología. 79

4.3.3. Matriz de correlación de variables clínicas numéricas por tipo de hallazgo. 80

4.4.1. Distribución de dimensiones (altura y anchura en píxeles) de las mamografías completas (muestra n = 300). 81

4.4.2. Superposición de la máscara ROI (región en rojo) sobre la mamografía completa para cuatro casos representativos. 82

5.1.1. Pipeline del sistema híbrido cuántico-clásico para prediagnóstico de cáncer de mama. Masas y calcificaciones recorren el pipeline como subproblemas independientes. El módulo M4 selecciona 12 características por F-test con una restricción de redundancia y las transforma en ángulos en $[0, \pi]$ mediante una transformación por cuantiles, ajustada solo sobre el conjunto de entrenamiento; el mismo vector alimenta las cinco condiciones. En C4 y C5 los parámetros del *ansatz* se fijan con una semilla y no se entrenan, y el kernel de fidelidad K_Q se calcula con el *feature map* solo. C4 combina una codificación de primer orden en Z con el acoplamiento ZZ, y C5 una codificación de primer orden en Y con el mismo acoplamiento. La salida de M5 alimenta en paralelo el análisis de separabilidad (M6) y la clasificación (M7), que el módulo M8 compara. 86

5.7.1. Circuitos de C4 y C5 dibujados para $k = 4$; el análisis usa $k = 12$, con 66 bloques de pares en lugar de 6; la barrera separa el *feature map* del *ansatz* fijo. 100

6.1.1. Tamaños de efecto de Cohen ($|d|$) para las características radiómicas evaluadas en el conjunto de entrenamiento de masas y calcificaciones. 110

6.1.2. Efecto de la ecualización CLAHE sobre la capacidad discriminativa y el reordenamiento de características radiómicas por familia. 110

6.1.3. Distribución angular tras la selección de características y comparación entre escalado por valores extremos y transformación por cuantiles. 112
6.1.4. Evolución del área bajo la curva ROC en función del número de características k para modelos clásicos en entrenamiento. 113
6.2.1. Distribución de los valores fuera de la diagonal en las matrices de kernel cuántico para C4 y C5 frente al kernel clásico RBF. 115
6.2.2. Métricas de separabilidad en la familia de kernels: alineamiento KTA y dimensión efectiva normalizada. 117
6.2.3. Diferencia geométrica regularizada g respecto a la batería de modelos clásicos frente al límite $\sqrt{N}$. 118
6.2.4. Métricas de separabilidad sobre las representaciones vectoriales: índice de Davies–Bouldin, razón de Fisher y alineamiento lineal. 119
6.2.5. Proyecciones bidimensionales mediante t-SNE para las representaciones generadas en las cinco condiciones. 120
6.2.6. Métricas de la familia de kernels a $c = 1$ en 20 submuestras de 200 lesiones (puntos), la submuestra del análisis principal (círculo) y todo el conjunto de entrenamiento (rombo). 121
6.2.7. Evolución del AUC de pares en función del factor de escala angular c para kernels cuánticos y clásico. 121
6.2.8. Comparación de métricas de separabilidad en kernels cuánticos entre configuraciones con 12 y 8 qubits. 123
6.3.1. Comparación de AUC-ROC entre las cinco condiciones evaluadas en validación cruzada y en el conjunto de prueba para masas y calcificaciones. 125
6.3.2. Curvas ROC sobre el conjunto de prueba oficial para masas y calcificaciones bajo las cinco condiciones de representación. 126
6.3.3. Análisis de sensibilidad del rendimiento de clasificación frente a cambios de semilla, arquitectura de red, escalado, épocas fijas, profundidad de circuito (`reps` = 2) y dimensión de entrada ($k = 8$). 127
6.3.4. Distribución del AUC en validación cruzada a lo largo de diez sorteos aleatorios independientes de θ para C4 y C5 en masas y calcificaciones. 128
6.3.5. Desempeño de clasificación al entrenar los parámetros variacionales θ junto con la red neuronal en comparación con θ fijo, la referencia clásica C1 y el clasificador de kernel cuántico. 129
6.4.1. Comparación entre el clasificador de kernel cuántico (QSVM), el clasificador de vectores de soporte clásico (SVM RBF) y la lectura mediante expectativas locales $\langle Z_i \rangle$ con red neuronal. 131

6.4.2. Rendimiento de clasificación en el conjunto de prueba al emplear las 67 características radiómicas bajo kernels clásicos, codificación en amplitudes y mapas angulares. 131
6.4.3. Búsqueda anidada sistemática de ventaja computacional cuántica: curvas de rendimiento en validación cruzada interna y evaluación pareada en el conjunto de prueba oficial. 133
6.4.4. Desempeño clasificatorio con el etiquetado diseñado según Huang et al. a partir del kernel cuántico, en comparación con las etiquetas diagnósticas reales del CBIS-DDSM (validación cruzada sobre el entrenamiento). 134
6.5.1. Correlación de Spearman entre los ordenamientos de separabilidad del espacio de estados y el desempeño de clasificación en el conjunto de prueba oficial. 135
6.5.2. Dispersión bivariada y contraste pareado de métricas de separabilidad frente al AUC de clasificación entre condiciones clásicas y cuánticas. 136
6.6.1. Escalabilidad computacional del simulador de vectores de estado en función del número de qubits (k) y proyección de límites temporales y de memoria para tareas del pipeline. 138
6.6.2. Efecto del número de disparos (*shots*) sobre la reconstrucción de expectativas en el espacio de estados y sobre la resolución empírica de matrices de kernel cuántico. . 139
C.1.1. Diagnóstico de desajuste dimensional y verificación de alineación espacial de máscaras en el Módulo 2. Se ilustran los dos casos identificados: discordancia por factor de escala (0,870) y desajuste por traslación de origen, contrastados con el recorte oficial. 178
C.1.2. Ejemplos ilustrativos de las etapas de preprocesamiento sobre mamografías del CBIS-DDSM (Módulo 2). Se muestra la mamografía completa, la máscara binarizada depurada, la región de interés recortada con margen de seguridad y su correspondiente versión procesada mediante ecualización CLAHE. 179
C.2.1. Diagrama esquemático completo del circuito cuántico variacional implementado para $k = 12$ qubits (Módulo 5). Incluye la codificación angular de características, el entrelazamiento completo de dos qubits y la capa variacional con *ansatz* `RealAmplitudes` de una repetición parametrizada con vector θ fijo. 181
C.2.2. Distribución empírica de los valores esperados de Pauli locales $\langle Z_i \rangle$ generados por los mapas cuánticos C4 y C5 para cada dimensión del embedding en masas y calcificaciones (Módulo 5). 182
C.3.1. Complejidad estructural de los circuitos cuánticos evaluados en función del número de qubits k. Se reporta la profundidad total del circuito y el número de compuertas de dos cúbits requeridas para distintas configuraciones. 182

C.3.2 Coste computacional del entrenamiento variacional medido en segundos por época y muestra en simuladores cuánticos para diversas topologías de circuito y números de qubits. 183
C.3.3 Sensibilidad del error de estimación al número de disparos finitos (*shots*). El aparente estancamiento en precisión observado en la versión preliminar de este análisis respondió a ruido numérico en la referencia de evaluación, según se documentó y subsanó posteriormente en el cuaderno B3 con cálculos exactos. 183
C.3.4 Efecto de concentración de medida en el espacio de Hilbert al incrementar el número de qubits k. La dispersión entre estados para diferentes lesiones decae exponencialmente conforme aumenta la dimensionalidad cuántica. 184
C.4.1 Distribución de valores de similitud en matrices de kernel intraclase e interclase (Experimento X2). Se compara la discriminación obtenida por el kernel clásico RBF frente a los mapas cuánticos C4 y C5 bajo distintos factores de escala angular c. 184
C.4.2 Comparativa de métricas de separabilidad geométrica (Davies–Bouldin, Fisher J y alineamiento KTA) entre la configuración reducida de $k = 8$ qubits y el diseño principal de $k = 12$ qubits (Experimento X3). 185
C.4.3 Desempeño en clasificación del algoritmo QSVM frente a variaciones en el factor de escala angular c (Experimento X4), contrastado con la referencia clásica de SVM con kernel gaussiano RBF. 185
C.4.4 Distribución nula exacta del estadístico de correlación de Spearman ρ_s generada a partir de las 120 permutaciones exhaustivas de las cinco condiciones experimentales con rangos promedio por empates (Módulo 8). 186
C.5.1 Distribución de clases global, por tipo de hallazgo y por split train/test. 186
C.5.2 Distribución de categorías BI-RADS por patología y tipo de hallazgo. 187
C.5.3 Distribución de *subtlety* por patología y tipo de hallazgo (1 = muy sutil, 5 = obvio). 187
C.5.4 Distribución de densidad mamaria (1 = grasa, 4 = extremadamente densa) por patología y tipo de hallazgo. 187
C.5.5 Distribución de lateralidad y vista mamográfica en el dataset. 188
C.5.6 Distribución de fabricantes de escáner en la muestra analizada. 188
C.5.7 Distribución de estadísticas de intensidad de píxeles (media, desviación estándar y máximo) en imágenes recortadas de ROI, por patología. 188
C.5.8 Galería de casos representativos: mamografía completa, máscara ROI e imagen recortada, para masas y calcificaciones benignas y malignas. 189

Índice de listados

1. Función de alineación espacial de máscaras (`Code/2_Preprocessing.ipynb`, celda de código 5). 163
2. Depuración y selección de componente conexa mayor (`Code/2_Preprocessing.ipynb`, celda de código 11). 163
3. Recorte de región de interés con margen y exportación (`Code/2_Preprocessing.ipynb`, celda de código 13). 164
4. Configuración del extractor PyRadiomics y activación de familias (`Code/3_Feature_Extraction.i`, celda de código 3). 165
5. Selección voraz por F-test con restricción de redundancia lineal (`Code/4_Selection_and_Scaling.`, celda de código 5). 165
6. Transformación angular por cuantiles acotada a $[0, \pi]$ (`Code/4_Selection_and_Scaling.ipynb`, celda de código 8). 166
7. Generación y balanceo de folds agrupados por paciente (`Code/4_Selection_and_Scaling.ipynb`, celda de código 9). 166
8. Construcción de mapas cuánticos, ansatz con θ fijo y cálculo de $\langle Z_i \rangle$ (`Code/5a_Embeddings.ipynb`, celda de código 2). 166
9. Evaluación de matrices de kernel clásico y cuántico (`Code/5b_Quantum_Kernels.ipynb`, celda de código 4). 167
10. Centrado matricial y alineamiento kernel-objetivo con prueba de permutación (`Code/6_Separabilit`, celda de código 3). 167
11. Cálculo de la diferencia geométrica regularizada de Huang et al. (`Code/6_Separability.ipynb`, celda de código 3). 168
12. Definición del perceptrón multicapa para clasificación supervisada (`Code/7_Classification.ipynb`, celda de código 3). 169
13. Bucle de entrenamiento con parada temprana y restauración de pesos (`Code/7_Classification.ipy`, celda de código 3). 169
14. Cálculo del coeficiente de Spearman con empates y distribución nula exacta (`Code/8_Comparison.ip`, celda de código 6). 170
15. Muestreo multinomial de mediciones finitas y ley de dispersión (`Code/8_Comparison.ipynb`, celda de código 17). 170

Abstract

This report evaluates the viability of variational quantum transformations as an encoding mechanism for morphological features of real mammograms. On the 3,568 lesions of CBIS-DDSM, with masses and calcifications treated as independent subproblems, 67 radiomic features are extracted with PyRadiomics, 12 are selected and scaled to $[0, \pi]$. The same vector feeds five conditions: no transformation, PCA, RBF Kernel PCA, and two quantum feature maps (ZZ, and Pauli with Y and ZZ terms) followed by a fixed-parameter ansatz, simulated with Qiskit Aer. Separability is measured with kernel-target alignment, regularized geometric difference, effective dimension, the Davies-Bouldin index and the Fisher distance; classification, with the same multilayer perceptron and patient-grouped cross-validation.

The quantum representations show no greater separability in any metric. The quantum kernel is concentrated (off-diagonal median close to 0.003, against 0.61 for the RBF kernel) and the geometric difference (1.40 to 1.70) stays well below the $\sqrt{N} \approx 14$ threshold. The perceptron loses between 0.07 and 0.14 AUC-ROC on the quantum embeddings, while an SVM on the quantum kernel matches the classical one, which places the loss in the expectation-value readout rather than in the encoding. The simulator constraints are also quantified: with 1,024 shots, between 16 and 74 % of the kernel entries would read exactly zero.

Keywords: quantum machine learning, quantum embeddings, quantum kernels, class separability, radiomics, CBIS-DDSM, breast cancer.

1. Panorama General

1.1. Introducción

1.1.1. Contexto clínico del cáncer de mama

El cáncer de mama es una enfermedad que se caracteriza por la proliferación descontrolada de células en el tejido mamario, que forma tumores malignos con capacidad de propagarse si no reciben tratamiento temprano. A nivel mundial es el cáncer diagnosticado con más frecuencia en las mujeres y la principal causa de muerte por cáncer en ellas [46].

Según las estimaciones de GLOBOCAN 2022 de la Agencia Internacional de Investigación sobre el Cáncer (IARC), en 2022 se registraron alrededor de 2.3 millones de casos nuevos de cáncer de mama y unas 670 000 defunciones en el mundo [46, 2]. Para 2050 se proyecta que los casos nuevos aumenten un 38 % y las defunciones un 68 %, con un impacto desproporcionado en los países de menor índice de desarrollo humano [13].

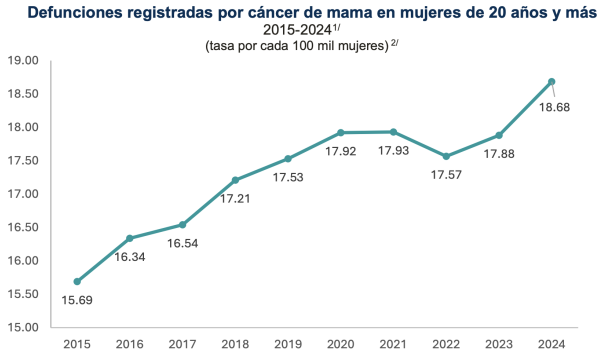
Las diferencias regionales tienen implicaciones directas para el desarrollo de herramientas de diagnóstico asistido. En muchos países de bajos ingresos, la mortalidad por cáncer es alta pese a una incidencia baja, por la falta de servicios de detección temprana y tratamiento oportuno: la mortalidad por cáncer de mama es el doble en Etiopía que en Estados Unidos, con una incidencia un 60 % menor [5]. El problema, por tanto, no es solo la frecuencia de la enfermedad, sino también la capacidad de los sistemas de salud para detectarla y tratarla a tiempo. Esto subraya la importancia de desarrollar herramientas que amplíen la capacidad diagnóstica, especialmente en regiones con recursos limitados.

Panorama en México

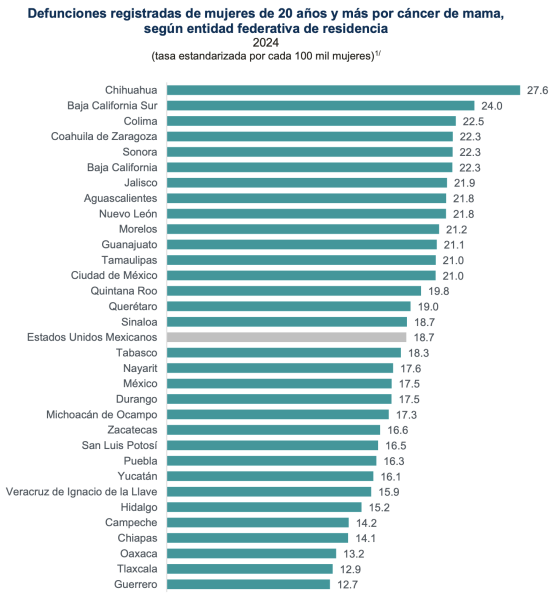
Según el Instituto Nacional de Estadística y Geografía (INEGI), en 2024 el cáncer de mama fue la primera causa de muerte por tumores malignos en México, con 8 451 defunciones, el 99.2 % de ellas en mujeres, y una tasa de 18.7 por cada 100 000 mujeres de 20 años o más [7]. Durante la última década, esa tasa pasó de 15.7 en 2015 a 18.7 en 2024 (Figura 1.1.1a).

La detección temprana como factor determinante

La detección temprana es el factor clínico que más justifica el desarrollo de sistemas de prediagnóstico. Según la American Cancer Society, cuando el cáncer de mama se detecta en una etapa temprana, la supervivencia relativa a cinco años supera el 99 %; con metástasis a distancia, según



(a) Tasa de mortalidad por cáncer de mama en México de 2015 a 2024 [7].



(b) Incidencia y mortalidad por entidad federativa en México [7].

los datos del programa SEER del National Cancer Institute, es del 33 % [8, 9].

La mamografía es el instrumento central de la detección temprana: el American College of Radiology señala que el tamizaje mamográfico reduce las muertes por cáncer de mama en mujeres de 40 años o más, y que con un tamizaje regular es posible una reducción de la mortalidad del 40 % [77]. Sin embargo, su interpretación manual tiene limitaciones. Los radiólogos pueden diferir, a veces de forma sustancial, en su interpretación de una misma mamografía y en la conducta que recomiendan [76]; a ello se suman la dificultad de detectar lesiones en tejido mamario denso y la carga de trabajo creciente de los sistemas de salud. Estos factores motivan el desarrollo de sistemas de diagnóstico asistido por computadora (CADx).

En México, la infraestructura diagnóstica sigue siendo un desafío. En 2021 se registraron 1 281 mastógrafos en el país: el 41.1 % en instituciones de salud y seguridad social, el 36.1 % en establecimientos particulares y el 22.8 % en servicios para población sin derechohabiencia [11]. Esta distribución, junto con el aumento sostenido de la mortalidad, marca la necesidad de herramientas que amplíen la capacidad diagnóstica del sistema de salud.

En este contexto, el presente trabajo explora el uso de transformaciones cuánticas variacionales sobre características extraídas de mamografías del dataset CBIS-DDSM, con el fin de evaluar en qué medida estas representaciones modifican la separación de las clases benigna y maligna cuando se integran como entrada de una red neuronal clásica.

1.1.2. Limitaciones de los métodos clásicos de diagnóstico asistido

El diagnóstico asistido por computadora en mamografía se ha desarrollado notablemente en las últimas dos décadas, impulsado por las redes neuronales convolucionales (CNN) y el aprendizaje profundo [18]. Pese a los resultados reportados en condiciones controladas, estos métodos presentan limitaciones que restringen su aplicación clínica generalizada.

Variabilidad entre conjuntos de datos

Los modelos de aprendizaje profundo no eliminan la inconsistencia de la interpretación humana: la trasladan a otro plano. En lugar de variar entre observadores, su desempeño varía entre conjuntos de datos. Wang et al. [12] evaluaron seis modelos de aprendizaje profundo, tres publicados con alto desempeño y tres propios, sobre cuatro conjuntos de mamografías. Los tres modelos publicados reportaban un AUC-ROC de validación de entre 0.88 y 0.95; sobre los tres conjuntos de prueba externos, los seis modelos obtuvieron valores de apenas entre 0.44 y 0.65. Un alto desempeño de un sistema CADx en el conjunto de datos con el que se desarrolló no garantiza la misma efectividad en datos con otra distribución, condición inevitable en la práctica clínica, donde los equipos de adquisición, las poblaciones y los protocolos de imagen varían.

Interpretabilidad

Una red convolucional profunda aprende sus propias representaciones internas de la imagen, que no tienen un significado clínico directo. Este trabajo usa, en cambio, características radiómicas, cuyo significado es explícito: cada una mide una propiedad definida de la intensidad, la textura o la forma de la lesión. Así es posible saber qué información recibe cada representación y, por tanto, interpretar qué cambia cuando se le aplica una transformación cuántica.

Dimensionalidad y tamaño de los datos

Las imágenes mamográficas tienen una dimensionalidad muy alta en relación con el número de casos disponibles. Cuando el conjunto de entrenamiento es pequeño frente al número de parámetros de un modelo, este tiende a sobreajustarse: aprende los detalles de los datos de entrenamiento y no generaliza a datos nuevos. El aumento de datos y la regularización mitigan el problema sin resolverlo, especialmente en conjuntos de tamaño moderado como el CBIS-DDSM.

Estas limitaciones motivan la búsqueda de representaciones alternativas de los datos, entre ellas las cuánticas, y la evaluación rigurosa de si aportan algo a la separabilidad de las clases.

1.1.3. Computación cuántica como alternativa

La computación cuántica ofrece mecanismos distintos para representar y transformar datos. En el aprendizaje automático, su propuesta no es sustituir a los métodos clásicos, sino intervenir en etapas específicas del procesamiento, en particular en la codificación de las características.

El espacio de Hilbert como espacio de representación

Un circuito de codificación $U(\mathbf{x})$ define un mapeo no lineal $\phi : \mathbb{R}^n \to \mathscr{H}$ que lleva un vector de características clásico $\mathbf{x}$ a un estado cuántico $|\phi(\mathbf{x})\rangle$ del espacio de Hilbert $\mathscr{H}$. La geometría de ese espacio la determinan las fidelidades $|\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$ entre estados, y no las distancias euclidianas entre vectores, y depende directamente del diseño del circuito. Cuando el circuito entrelaza los qubits, la representación puede incorporar dependencias entre pares de características (sección 3.2.2). Si esa geometría resulta más favorable para separar lesiones benignas y malignas que las representaciones clásicas es una pregunta empírica, y es el objeto de estudio de este trabajo (sección 1.2).

Modelos híbridos cuántico-clásicos para el diagnóstico

La aplicación del aprendizaje automático cuántico al diagnóstico clínico es una línea de investigación activa, en la que predominan las arquitecturas híbridas: los circuitos cuánticos se integran como componentes especializados dentro de un procesamiento mayoritariamente clásico. Xiang et al. [14] proponen, por ejemplo, una red convolucional híbrida para el diagnóstico de cáncer de mama con el objetivo de aprovechar el procesamiento de datos de alta dimensión de la computación cuántica. Mari et al. [67] formalizan este tipo de modelos: la red completa, incluida la capa de codificación cuántica y la medición final, es una función de un espacio vectorial clásico a otro que depende de pesos clásicos y que, vista desde fuera, es análoga a una red clásica profunda. Este trabajo usa el circuito de la misma manera, como una transformación entre representaciones clásicas, pero sin entrenarlo: sus parámetros se fijan para poder medir su efecto sobre la separabilidad de forma aislada.

Estado actual y expectativas

El campo se encuentra en una etapa temprana. En un estudio comparativo a gran escala, Bowles et al. [72] encontraron que, en conjunto, los modelos clásicos estándar, sin ajustes especiales, superan a los clasificadores cuánticos en las tareas pequeñas que evaluaron, y que eliminar el entrelazamiento de un modelo cuántico a menudo da un desempeño igual o mejor. Con los dispositivos y simuladores disponibles no es posible aún demostrar con métricas concluyentes una ventaja de los modelos cuánticos en problemas prácticos. El valor de una investigación como esta reside en explorar y documentar, con un protocolo riguroso, sus posibilidades y sus limitaciones en un dominio

de alto impacto como el diagnóstico de cáncer de mama.

1.2. Planteamiento del problema

La representación como problema

En el prediagnóstico asistido por computadora, el clasificador no trabaja con la mamografía, sino con una representación de cada lesión: un vector de descriptores cuantitativos de intensidad, textura y forma extraídos de la región de interés. La calidad de esa representación limita lo que cualquier clasificador puede aprender de ella. En el CBIS-DDSM, además, las clases no se distinguen con la misma facilidad en los dos tipos de hallazgo: en las masas, los descriptores del radiólogo separan bien las formas irregulares y espiculadas de las ovaladas y circunscritas, mientras que en las calcificaciones el tipo más frecuente, el pleomórfico, aparece en ambas clases (capítulo 4). Cabe preguntarse, entonces, si una transformación de esos descriptores puede reorganizarlos de modo que las lesiones benignas y malignas queden mejor separadas, y si esa reorganización ayuda a clasificarlas.

La propuesta de las codificaciones cuánticas

Un circuito de codificación $U(\mathbf{x})$ asocia a cada vector de características $\mathbf{x}$ un estado $|\phi(\mathbf{x})\rangle$ en un espacio de Hilbert de dimensión 2^n para n qubits, y la similitud entre dos lesiones pasa a medirse por la fidelidad $|\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$ entre sus estados (sección 3.2.2). Los mapas que incluyen compuertas de entrelazamiento, como el mapa ZZ introducido por Havlíček et al. [41], generan términos que dependen de pares de características y se han propuesto bajo la conjetura de una posible ventaja cuántica a corto plazo [17]. Esa es la motivación de emplearlos como transformación de los descriptores: no buscar un espacio más grande por sí mismo, sino una geometría de similitud distinta de la que inducen las transformaciones clásicas.

La teoría, sin embargo, no garantiza que esa geometría sea más útil. Huang et al. [42] muestran que, si la diferencia geométrica entre un kernel cuántico y los clásicos es pequeña, un método clásico ofrece un desempeño similar o mejor con cualquier etiquetado, y observan que en los modelos cuánticos habituales esa diferencia es pequeña porque, en un espacio de Hilbert exponencialmente grande, todas las entradas quedan demasiado lejos entre sí. Thanasilp et al. [48] demuestran que, bajo ciertas condiciones, los valores de un kernel cuántico se concentran exponencialmente en el número de qubits, de modo que estimarlos con un número polinomial de mediciones produce un modelo cuyas predicciones no dependen de los datos. Que una codificación cuántica separe mejor las clases sobre datos clínicos reales es, por tanto, una pregunta empírica: la aplicabilidad práctica

de estos métodos más allá de problemas de prueba construidos a propósito, y con las limitaciones actuales del *hardware*, sigue abierta [17].

La brecha en mamografía

En mamografía, el antecedente más cercano con circuitos cuánticos es el trabajo de Azevedo et al. [15], que emplean una red híbrida con codificación angular sobre el BCDR. Sus autores dejan como trabajo futuro dos líneas que este trabajo retoma: separar masas y calcificaciones antes de clasificar, y observar cómo se distribuyen los datos en el espacio de Hilbert, idealmente como conglomerados compactos y separados. La revisión del capítulo 2 no identificó trabajos que evalúen ninguna de las dos sobre el CBIS-DDSM.

La elección del mapa de características

El desempeño de los métodos de kernel cuánticos depende del mapa de características. En una comparación sobre conjuntos de datos de referencia, Álvarez-Estévez obtiene resultados mixtos frente a los métodos clásicos y sugiere que una elección cuidadosa del mapa, con una hiperparametrización adecuada, puede ser más efectiva que optimizar el kernel [17]. Este trabajo compara dos mapas que comparten el acoplamiento ZZ entre pares de características y difieren solo en el eje de la codificación de primer orden: *ZZFeatureMap*, que gira cada qubit alrededor del eje Z, y *PauliFeatureMap* con los términos Y y ZZ, que lo gira alrededor del eje Y (sección 5.7).

Formulación del problema de investigación

A partir de lo anterior, el problema de investigación del presente trabajo se formula de la siguiente manera:

> ¿En qué medida las transformaciones cuánticas variacionales implementadas mediante *ZZFeatureMap* y *PauliFeatureMap* en Qiskit modifican la separabilidad de clases benigno/maligno de características radiómicas extraídas de mamografías del CBIS-DDSM, y hasta qué punto esa diferencia se refleja en la capacidad de clasificación de una misma red neuronal clásica, en comparación con representaciones clásicas construidas a partir del mismo vector de características?

La pregunta tiene tres dimensiones, que se abordan de forma integrada. La primera es la de la representación: si la separabilidad de clases cambia al pasar de las representaciones clásicas a las cuánticas, medida con métricas geométricas y de kernel (objetivo específico 3). La segunda es la de la clasificación: si las diferencias de separabilidad se reflejan en el desempeño de un mismo clasificador y en el orden en que quedan las condiciones (objetivo específico 5). La tercera acompaña a las dos anteriores y es la de la viabilidad: qué restricciones impone simular estos circuitos

en una computadora clásica y qué implicarían en un procesador cuántico (objetivo específico 6). La pregunta no presupone el sentido de la respuesta: una separabilidad igual o menor que la de las representaciones clásicas es también un resultado válido. Los criterios con que se responde cada dimensión se fijan en el capítulo 5.

1.3. Justificación

Relevancia científica

El aprendizaje automático cuántico necesita evidencia empírica sobre datos reales. Una parte importante de su evaluación se ha hecho sobre problemas de prueba construidos para ilustrar propiedades teóricas [17], y los resultados obtenidos con conjuntos de datos pequeños no permiten razonar sobre conjuntos mayores [72]. Llevar estas técnicas a un dominio de imagen médica, con miles de lesiones y la variabilidad propia de las mamografías digitalizadas, es la forma de saber cómo se comportan fuera de esas condiciones.

El presente trabajo contribuye a esa evidencia de tres formas. Primero, documenta el comportamiento de *ZZFeatureMap* y *PauliFeatureMap* de Qiskit aplicados a características radiómicas extraídas de mamografías reales en formato DICOM. Segundo, evalúa las representaciones por su separabilidad de clases, y no solo por el desempeño del clasificador final, con métricas definidas sobre los kernels y sobre los propios vectores de representación: el alineamiento kernel-objetivo, la diferencia geométrica, el índice de Davies-Bouldin y la razón de Fisher (sección 3.4). Tercero, retoma las dos líneas de trabajo futuro que dejan Azevedo et al. [15]: analizar por separado masas y calcificaciones, y observar cómo se distribuyen los datos en el espacio de Hilbert. Así, los resultados se sitúan en una línea de investigación acumulativa en aprendizaje automático cuántico para el diagnóstico médico.

Relevancia social

El cáncer de mama es la principal causa de muerte por tumores malignos en las mujeres de México, y su detección temprana determina en gran medida el desenlace clínico (sección 1.1). Las herramientas de prediagnóstico asistido pueden ampliar la capacidad de un sistema de salud en el que la disponibilidad de mastógrafos y de especialistas en radiología mamaria no cubre la demanda. Para orientar ese desarrollo es necesario saber qué técnicas aportan y cuáles no: si las representaciones cuánticas no mejoran la separabilidad de las lesiones, ese resultado, medido con rigor, también indica dónde no conviene invertir el esfuerzo de investigación. Aunque el presente trabajo es un prototipo académico y no un dispositivo clínico, sus resultados se suman al conocimiento

que eventualmente informará el desarrollo de herramientas diagnósticas para sistemas de salud con recursos limitados, como el mexicano.

Viabilidad técnica

La viabilidad del trabajo descansa en tres recursos. El primero es el dataset CBIS-DDSM, una versión curada del DDSM con diagnóstico confirmado por patología, disponible públicamente en The Cancer Imaging Archive [62, 63]. Reúne 3 568 lesiones de 1 566 pacientes, con una partición oficial de entrenamiento y prueba estratificada por categoría BI-RADS y metadatos clínicos estructurados, lo que evita procesos propios de adquisición, anonimización o validación clínica. El segundo es la simulación clásica de los circuitos en el equipo de desarrollo, un procesador Apple M3 con 16 GiB de memoria. El número de qubits se fijó en 12 tras un estudio de costos: con la implementación inicial, que evaluaba cada valor del kernel con un circuito propio, la etapa cuántica completa pasaba de unas 3 h con 12 qubits a unas 41 h con 16, y el diseño requiere decenas de kernels. Después se adoptó una implementación que calcula el vector de estado de cada lesión una sola vez y obtiene el kernel de sus productos internos; con ella se comprobó que el límite físico de la máquina está más arriba, pues se simularon estados de hasta 28 qubits (sección 6). Estas cifras corresponden a la simulación ideal del vector de estado, sin ruido, que además permite aislar el efecto de la transformación cuántica sin la interferencia del ruido de los dispositivos físicos. El tercero es un ecosistema de programación de código abierto, documentado y mantenido (Qiskit, PyTorch, PyRadiomics, scikit-learn), que permite a otros investigadores reproducir el trabajo.

Novedad y posicionamiento frente a trabajos previos

La aportación del trabajo se define por tres diferenciadores. El primero es el dominio de datos: opera sobre mamografías DICOM del CBIS-DDSM y no sobre datos clínicos tabulares, como Wisconsin, SEER o GBSG, empleados en otros trabajos de aprendizaje automático cuántico en oncología (cuadro 1). El segundo es el papel del componente cuántico: el circuito se usa exclusivamente como transformación de la representación, con parámetros fijos, y no como una capa que se entrena dentro de una red, lo que permite analizar de forma aislada su efecto sobre la separabilidad de las clases. El tercero es el análisis de viabilidad: las restricciones prácticas del simulador se convierten en un objetivo de investigación explícito y medible, con datos cuantitativos sobre el tiempo de ejecución, el número de qubits simulables, el número de mediciones que requeriría un procesador real y el costo de entrenar el circuito. En conjunto, estos diferenciadores sitúan el trabajo como una contribución experimental a una línea de investigación activa y como una referencia metodológica para aplicar codificaciones cuánticas a la imagen médica.

1.4. Objetivos

1.4.1. Objetivo general

Analizar el efecto de las transformaciones cuánticas variacionales implementadas mediante *ZZFeatureMap* y *PauliFeatureMap* en Qiskit, sobre características radiómicas extraídas de imágenes mamográficas del dataset CBIS-DDSM, en la separabilidad de clases benigno/maligno, cuantificando dicha separabilidad mediante *kernel-target alignment*, *geometric difference* respecto a kernels clásicos de referencia, índice de Davies-Bouldin y razón de Fisher, comparando contra representaciones clásicas de referencia (sin transformación, PCA lineal y Kernel PCA con kernel RBF) construidas a partir del mismo vector de características seleccionadas y escaladas, e integrando todas las representaciones resultantes como entrada de un mismo clasificador MLP para determinar si las diferencias en separabilidad se reflejan en la capacidad de clasificación binaria.

1.4.2. Objetivos específicos

1. Construir un *pipeline* de preprocesamiento sobre el dataset CBIS-DDSM que comprenda la lectura de imágenes en formato DICOM, el recorte de la región de interés (ROI) a resolución original, la extracción de un vector de características radiómicas mediante PyRadiomics y la selección de las k características más discriminativas mediante SelectKBest con escalado angular al rango $[0, \pi]$, diferenciando el procesamiento de casos de masas y calcificaciones como subproblemas independientes.

2. Implementar las cinco condiciones de transformación del experimento sobre el mismo vector de entrada: (a) sin transformación, como referencia sin procesar; (b) PCA lineal, como referencia lineal; (c) Kernel PCA con kernel RBF, como referencia no lineal; (d) circuito cuántico variacional con *ZZFeatureMap*, implementado en Qiskit Aer con una capa variacional RealAmplitudes de parámetros fijos; y (e) circuito cuántico variacional con *PauliFeatureMap* con los términos Y y ZZ, con la misma capa variacional, asegurando que todas las condiciones produzcan vectores de representación de dimensión k como entrada al clasificador MLP.

3. Analizar y comparar la separabilidad de clases benigno/maligno en los espacios de representación generados por las cinco condiciones experimentales mediante: *kernel-target alignment* (KTA) respecto al kernel ideal de clasificación; *geometric difference* entre el kernel cuántico y un conjunto de kernels clásicos de referencia, como indicador de si el espacio cuántico induce una geometría que los métodos clásicos no reproducen; índice de Davies-Bouldin, como medida de compacidad y separación de los grupos; y razón de Fisher, como cociente

de la dispersión entre clases sobre la dispersión dentro de cada clase; aplicando el análisis de forma independiente para masas y calcificaciones.

4. Entrenar un mismo clasificador MLP sobre cada uno de los cinco vectores de representación generados en el objetivo específico 2, manteniendo idéntica arquitectura, hiperparámetros y protocolo de entrenamiento en todas las condiciones.

5. Evaluar si las diferencias de separabilidad observadas en el objetivo específico 3 se reflejan en la capacidad de clasificación binaria, comparando las métricas AUC-ROC, F1-Score, Accuracy, Precision y Recall obtenidas por el MLP en las cinco condiciones y analizando la correlación entre el ordenamiento de separabilidad y el de clasificación, con todos los resultados reportados por separado para masas y calcificaciones del CBIS-DDSM.

6. Analizar los beneficios y las limitaciones prácticas, incluidas las restricciones computacionales del simulador cuántico y el número de mediciones que requeriría un procesador real, para valorar la viabilidad de aplicar estas técnicas en un contexto de salud.

1.5. Alcance y limitaciones

El presente trabajo tiene como propósito central evaluar la viabilidad de las transformaciones cuánticas variacionales como mecanismo de codificación de características radiómicas extraídas de imágenes mamográficas, determinando en qué medida modifican la separabilidad de clases benigno/-maligno frente a representaciones clásicas construidas a partir del mismo vector de características. El sistema desarrollado constituye un prototipo de investigación académica, no un sistema de diagnóstico clínico, y su alcance está delimitado por los criterios siguientes.

Datos y tarea

El sistema opera exclusivamente sobre las lesiones del dataset CBIS-DDSM que corresponden a masas y calcificaciones con diagnóstico patológico confirmado, a partir de la región de interés que delimita la máscara de cada lesión. Masas y calcificaciones se tratan como subproblemas independientes en todo el *pipeline*. El problema abordado es la clasificación binaria benigno/maligno; la detección de lesiones, su localización espacial y la segmentación quedan fuera del alcance.

Simulación clásica

La totalidad de los experimentos cuánticos se ejecuta en simulación clásica con Qiskit Aer, sin acceso a *hardware* cuántico. Los resultados corresponden, por tanto, a condiciones ideales, libres del ruido de los dispositivos físicos, lo cual es una condición deliberada del diseño experimental y

no una deficiencia metodológica: permite atribuir lo observado a la codificación y no al ruido. Los dispositivos actuales, de escala intermedia y con ruido (NISQ), tienen un control imperfecto de sus qubits, y ese ruido limita lo que pueden lograr a corto plazo [65]. Lo que este trabajo dice sobre la ejecución en un procesador real se basa en proyecciones: el número de mediciones se estudia con un muestreo ideal de las probabilidades exactas, sin modelar el ruido del dispositivo.

Codificaciones evaluadas

El estudio se limita a dos mapas de características con entrelazamiento entre todos los pares de qubits, *ZZFeatureMap* y *PauliFeatureMap* con los términos Y y ZZ, con una repetición y $k = 12$ qubits. El número de qubits se fijó por el costo de simulación y por la diversidad de familias de características que conserva la selección, y obliga a descartar parte de la información de las 67 características extraídas. Quedan fuera las codificaciones sin entrelazamiento, como la angular producto o la codificación en amplitudes, porque su kernel es por construcción un kernel clásico (sección 5.7). Los parámetros de la capa variacional se fijan con una semilla y no se entrenan, para que la separabilidad se mida sobre una representación no supervisada; entrenarlos se explora solo como experimento complementario.

Datos de imagen

Las mamografías del CBIS-DDSM son películas digitalizadas sin escala física de intensidad ni espaciado de píxel en sus metadatos, de modo que las características de primer orden se calculan sobre intensidades no calibradas y las de forma se expresan en píxeles. Todos los resultados provienen de un único conjunto de datos, sin validación externa, y el conjunto de prueba oficial se usa una sola vez por modelo.

El objetivo no es superar lo existente, sino explorar lo posible

Un error frecuente en la evaluación de trabajos de aprendizaje automático cuántico aplicado consiste en juzgar su validez en función de si el modelo cuántico supera en precisión a los mejores modelos clásicos disponibles. Este criterio, pertinente para tecnologías maduras, resulta inapropiado para el estado actual de la computación cuántica. El objetivo del presente trabajo no es demostrar que las representaciones cuánticas superan a una CNN de última generación en AUC-ROC, sino responder la pregunta planteada en la sección 1.2: en qué medida estas transformaciones modifican la separabilidad intrínseca de las clases sobre datos mamográficos reales, y si esa diferencia se refleja en la clasificación. Una mejora en separabilidad sin mejora en la clasificación constituiría evidencia válida sobre el comportamiento de estos circuitos, y también lo es una separabilidad igual o menor que la clásica, siempre que esté medida con el mismo rigor y que se documenten las restricciones que la explican.

2. Antecedentes

2.1. Estado del arte

Este capítulo revisa los trabajos sobre los que se construye el presente. Las secciones 2.1.1 y 2.1.2 resumen el aprendizaje automático clásico y el aprendizaje profundo en mamografía. Las secciones 2.1.3 y 2.1.4 presentan los fundamentos del aprendizaje automático cuántico y sus aplicaciones híbridas en salud, y la sección 2.1.5 los trabajos sobre el CBIS-DDSM. Las secciones 2.1.6 y 2.1.7 recogen los límites conocidos de la ventaja cuántica con datos clásicos y las razones para no codificar directamente los píxeles. La sección 2.1.8 aplica a los trabajos que reportan una ventaja las mismas preguntas de control que este trabajo se aplica a sí mismo, y la sección 2.1.9 resume todo en una tabla comparativa.

2.1.1. Aprendizaje automático clásico en el diagnóstico mamográfico

Los sistemas de detección y diagnóstico asistidos por computadora (CAD, *Computer-Aided Detection/Diagnosis*) en mamografía buscan apoyar la interpretación radiológica y la detección temprana de lesiones. Los sistemas clásicos se organizan en dos etapas: la extracción de características diseñadas a partir de la imagen y su clasificación con un algoritmo de aprendizaje supervisado.

Extracción de características

Entre las características más usadas están las de textura derivadas de la matriz de co-ocurrencia de niveles de gris (GLCM) [18], junto con descriptores de forma y margen para las masas y de distribución espacial para las calcificaciones. Las matrices GLCM y GLRLM (*Gray Level Run Length Matrix*) son de uso extendido en el análisis de textura [21], y son dos de las familias de características que este trabajo extrae con PyRadiomics.

Clasificadores

La máquina de vectores de soporte (SVM) es el clasificador clásico más usado en este dominio: según la revisión de Mashekova et al., cerca del 44 % de los estudios publicados entre 2020 y 2025 sobre detección de cáncer de mama la emplearon, sobre todo con mamografías [20]. Los mismos autores señalan que estos métodos dependen de características diseñadas a mano, lo que limita su generalización pero los hace transparentes e interpretables [20].

Avcı y Karakaya compararon SVM, bosques aleatorios (RF), redes neuronales (ANN), k vecinos

más cercanos, Naive Bayes y árboles de decisión sobre características GLCM y GLRLM de la base mini-MIAS. SVM, RF y ANN rindieron en general mejor que el resto, y el desempeño dependió de la combinación de preprocesamiento aplicada antes de extraer las características [21].

Alcances y limitaciones

Las comparaciones entre enfoques dependen de lo que recibe cada clasificador. En la evaluación de Añez et al. sobre el CBIS-DDSM, una ResNet-50 alcanzó un AUC-ROC de 0.95, frente a 0.90 de XGBoost y 0.84 de una SVM [22]; pero los dos modelos clásicos recibieron solo rasgos globales de la mamografía completa, como la intensidad media, su desviación, el ancho y el alto [22]. La diferencia mide, sobre todo, la distancia entre esos rasgos y lo que la red aprende de los píxeles.

La capacidad discriminativa de un clasificador clásico está acotada por la información que contienen las características que recibe. Esa limitación motivó los enfoques de aprendizaje profundo, que aprenden la representación desde los píxeles (sección siguiente), y más tarde el interés por las representaciones cuánticas. Pero las características radiómicas siguen siendo una referencia exigente: en el presente trabajo, las mismas características con un clasificador clásico son la condición contra la que se comparan las transformaciones cuánticas.

2.1.2. Aprendizaje profundo en el diagnóstico mamográfico

El avance de las redes convolucionales

Las redes neuronales convolucionales (CNN) cambiaron el enfoque de los sistemas CAD clásicos: en lugar de clasificar descriptores diseñados por expertos, aprenden representaciones jerárquicas directamente de los píxeles. Ya en 1995 se usaron CNN poco profundas para estudiar el cáncer de mama, pero fue a partir de 2012 cuando ganaron popularidad, por el aumento de la capacidad de cómputo, el abaratamiento del hardware, los algoritmos de código abierto y el auge de los grandes volúmenes de datos [23]. Arquitecturas como AlexNet, ZF-Net, GoogLeNet, VGG y ResNet marcaron avances en el procesamiento de imágenes, y AlexNet se ha usado ampliamente en la detección de cáncer de mama [23].

Resultados reportados

Sobre el CBIS-DDSM, Shen et al., con redes entrenadas de extremo a extremo sobre mamografías completas alcanzaron un AUC por imagen de 0.91 [24] (sección 2.1.5).

En calcificaciones, Shia comparó ResNet-50, ResNet-101 y cinco variantes de EfficientNet (B0 a B4) con validación cruzada de cinco pliegues, sobre mamografías de un hospital con 869 casos

benignos y 660 malignos [26]. La prueba *t* indica una diferencia significativa en F1 a favor de todas las EfficientNet, pero la prueba de Wilcoxon no la confirma ($p > 0{,}05$) [26]. En una validación externa con el CBIS-DDSM, EfficientNet-B3 obtuvo la mayor sensibilidad en ambas clases [26]. El ejemplo ilustra, además, una práctica que este trabajo comparte: estudiar las calcificaciones como un problema propio.

El problema de la generalización

Los buenos resultados en validación interna no garantizan el mismo desempeño con datos de otra procedencia. Wang et al. evaluaron seis modelos sobre cuatro conjuntos de mamografías (DDSM, INbreast, MIAS y uno privado): los tres modelos publicados reportaban un AUC de validación entre 0.88 y 0.95, pero sobre los conjuntos externos el AUC de los seis modelos bajó a valores de entre 0.44 y 0.65 [12].

La representación como objeto de estudio

Estos antecedentes sitúan una parte del problema en la representación con la que trabaja el clasificador, además de en su arquitectura. El presente trabajo aborda esa cuestión desde otra etapa: no propone un nuevo clasificador, sino que compara, con un mismo clasificador, representaciones clásicas y cuánticas construidas a partir del mismo vector de características radiómicas, y mide si las transformaciones cuánticas modifican la separabilidad de las clases. Si lo hacen o no es la pregunta empírica del trabajo; las razones teóricas para no darlo por supuesto se recogen en la sección 2.1.6.

2.1.3. Fundamentos de *quantum machine learning* y codificación cuántica de datos

El origen teórico: QML y métodos kernel

Schuld y Killoran observaron que la idea básica de la computación cuántica se parece a la de los métodos kernel en aprendizaje automático: hacer cálculos de forma eficiente en un espacio de Hilbert de tamaño intratable. Interpretan la codificación de las entradas en un estado cuántico como un mapa de características (*feature map*) no lineal que lleva los datos al espacio de Hilbert [27]. En una de las dos estrategias que proponen, el dispositivo cuántico estima productos internos entre estados para calcular un kernel clásicamente intratable, que puede usarse en cualquier método kernel clásico, como una máquina de vectores de soporte [27]. Esta lectura es el punto de partida del presente trabajo: si el espacio de Hilbert de 2^n dimensiones que generan n qubits ofreciera una geometría más favorable para separar las clases, la codificación cuántica aportaría algo al clasificador. Que lo haga o no es una pregunta empírica, y la sección 2.1.6 recoge las razones teóricas para no darlo por supuesto.

Havlíček et al. llevaron la idea a la práctica: propusieron dos métodos de clasificación, un clasificador variacional y un estimador de kernel cuántico, y los ejecutaron en un procesador superconductor, usando dos de sus qubits [41]. El circuito de codificación que propusieron es la base del ZZFeatureMap de Qiskit (sección 3.2.3). Sobre la ventaja cuántica, los autores no la afirman: la plantean como una condición. Un mapa que solo genera estados producto puede implementarse clásicamente de inmediato, y para obtener una ventaja haría falta un mapa basado en circuitos difíciles de simular; conjeturan que los de su construcción lo son [41].

Circuitos cuánticos variacionales

Los circuitos cuánticos variacionales (VQC) son un tipo de circuito cuántico parametrizado (PQC) que suele combinarse con optimizadores clásicos y que se usa ampliamente en algoritmos cuánticos [28]. Un modelo de este tipo tiene tres bloques. El primero es el mapa de características $U(\mathbf{x})$, que codifica el vector clásico $\mathbf{x}$ en el estado $|\phi(\mathbf{x})\rangle = U(\mathbf{x})|0\rangle^{\otimes n}$. El segundo es el *ansatz* $W(\theta)$, con rotaciones parametrizadas y compuertas de entrelazamiento, que produce $|\psi(\mathbf{x},\theta)\rangle = W(\theta)|\phi(\mathbf{x})\rangle$. El tercero es la medición, que extrae los valores esperados $\langle Z_i\rangle$ de cada qubit como salida clásica.

Lo habitual es entrenar θ junto con el resto del modelo, con gradientes que en hardware se obtienen con la regla de desplazamiento de parámetros (*parameter-shift*, sección 3.2.7). En el presente trabajo, θ se fija con una semilla y no se entrena: los vectores $\langle Z_i\rangle$ se calculan una sola vez y el clasificador clásico se entrena sobre ellos (sección 3.2.6). Así las cinco condiciones experimentales son transformaciones que no ven las etiquetas, y la comparación aísla el efecto de la codificación.

Métodos de codificación

La codificación determina el espacio en el que quedan representados los datos. Schuld et al. mostraron que un modelo cuántico variacional puede escribirse como una serie de Fourier parcial en los datos: las frecuencias accesibles dependen solo de las compuertas de codificación, y el resto del circuito fija los coeficientes [49]. Las tres familias de codificación relevantes para este trabajo son las siguientes.

- **Codificación angular** (*angle encoding*): cada componente del vector se codifica como el ángulo de una rotación en un qubit, por ejemplo $R_Y(x_i)$ en el qubit i. Es simple, pero las relaciones entre variables solo pueden aparecer en las capas posteriores, no en la codificación. Como produce estados producto, su kernel puede calcularse clásicamente [41].
- **ZZFeatureMap**: añade a la codificación angular fases que dependen de pares de variables, mediante términos Z_iZ_j que entrelazan los qubits. La fase de cada par, $(\pi - x_i)(\pi - x_j)$, es la que usaron Havlíček et al. [41] y la que implementa Qiskit por defecto (sección 3.2.3).

- **PauliFeatureMap**: es una familia de circuitos definida por una lista de cadenas de Pauli, que fija sobre qué ejes actúan los términos de primer orden y de interacción. Con la lista por defecto de Qiskit, Z y ZZ, coincide con el ZZFeatureMap. En este trabajo se usa la lista Y, ZZ: mismo acoplamiento que el ZZFeatureMap, pero con la codificación de primer orden en el eje Y (sección 3.2.4). Con interacciones de dos cuerpos como máximo, ninguno de los dos mapas codifica interacciones de orden superior.

El Hafidi et al. compararon ZFeatureMap, ZZFeatureMap y PauliFeatureMap en una QSVM para cáncer de pulmón, y concluyen que la elección del mapa depende de la naturaleza de los datos y de la resistencia al ruido del dispositivo [55]. Sus resultados y sus límites se discuten en la sección 2.1.8.

Mesetas estériles y concentración del kernel

McClean et al. demostraron que, para una clase amplia de circuitos parametrizados, la probabilidad de que el gradiente en cualquier dirección razonable sea distinto de cero, con una precisión fija, decrece exponencialmente con el número de qubits [66]. Este fenómeno, la meseta estéril (*barren plateau*), vuelve impracticable entrenar circuitos grandes inicializados al azar. Arrasmith et al. mostraron que los optimizadores sin gradiente tampoco resuelven el problema [56].

Como en el presente trabajo θ no se entrena, la meseta estéril no es el obstáculo principal. El fenómeno que sí lo afecta es su equivalente para los métodos kernel. Thanasilp et al. demostraron que los valores de un kernel cuántico pueden concentrarse exponencialmente en torno a un valor fijo, y señalan que cada una de sus cotas de concentración tiene un análogo para las redes neuronales cuánticas [48]. Un kernel concentrado no distingue entre entradas, y lo que en un circuito entrenable es un gradiente nulo, en un kernel es una matriz casi igual a la identidad (sección 2.1.6).

2.1.4. Modelos híbridos cuántico-clásicos en el sector salud

Las arquitecturas híbridas, en las que una parte clásica extrae o reduce las características y un circuito cuántico participa en la clasificación, son una línea de investigación activa en diagnóstico médico. En cáncer de mama, los trabajos revisados presentan dos rasgos comunes: evalúan sobre datos tabulares o imágenes muy reducidas, y reportan la mejora en exactitud final.

Aplicaciones en cáncer de mama

Xiang et al. propusieron una red convolucional híbrida (QCCNN) y la evaluaron sobre tres conjuntos tabulares de cáncer de mama, GBSG, SEER y WDBC, no sobre imágenes. Frente a una CNN

y una regresión logística, la exactitud media en validación mejoró entre 1 y 10 puntos porcentuales según el conjunto [14]. Su diseño experimental se examina en la sección 2.1.8.

Rifat et al. combinaron una ResNet50 modificada como extractor de características con una red neuronal cuántica, y reportan una exactitud del 69 % sobre BreastMNIST [57]. Aunque el resumen del trabajo describe ese conjunto como mamografías, BreastMNIST procede de 780 imágenes de ultrasonido de mama, reducidas a 28×28 píxeles [57, 58]. Los propios autores reconocen que la computación cuántica aún no ha mostrado una mejora significativa en aprendizaje automático, por lo limitado de sus recursos y su complejidad [57].

Limitaciones comunes

Los trabajos revisados comparten tres limitaciones. Primero, los experimentos se ejecutan en simulación clásica o en procesadores de pocos qubits. Segundo, los datos son tabulares o imágenes muy reducidas, lejos de las mamografías de alta resolución. Tercero, ninguno de los trabajos aplicados a cáncer de mama analiza explícitamente la separabilidad de clases en el espacio inducido por el circuito; la miden por su efecto en la exactitud final.

El presente trabajo aborda las dos últimas: extrae las características de las regiones de interés a la resolución original del CBIS-DDSM y mide la separabilidad antes de la clasificación. La primera no la resuelve, porque también trabaja en simulación; en su lugar, cuantifica lo que la simulación exacta oculta, como el número de mediciones que haría falta en un procesador real.

2.1.5. Trabajos específicos sobre el CBIS-DDSM

El CBIS-DDSM es una versión actualizada y estandarizada del DDSM, publicada para que los sistemas de detección y diagnóstico asistidos puedan evaluarse y compararse sobre los mismos datos [62]. Hereda del DDSM la patología verificada de cada caso, y su partición en entrenamiento y prueba se hizo según la categoría BI-RADS [62]. Las regiones de interés de las masas se obtuvieron con un algoritmo de segmentación inicializado con los contornos originales del DDSM, más precisos que estos [62].

Trabajos clásicos sobre el CBIS-DDSM

Shen et al. entrenaron redes convolucionales de extremo a extremo sobre mamografías completas: en el conjunto de prueba del CBIS-DDSM, el mejor modelo individual alcanzó un AUC por imagen de 0.88, y el promedio de cuatro modelos, de 0.91, con una sensibilidad del 86.1 % y una especificidad del 80.1 % [24]. Baccouche et al. propusieron, para masas, un *ensemble* apilado de redes residuales, con una exactitud del 95.13 % en la clasificación de patología y del 90.02 % en la de for-

ma sobre el CBIS-DDSM [25]. Estos resultados se obtienen con redes profundas entrenadas sobre los píxeles y no son directamente comparables con los del presente trabajo, que clasifica lesiones a partir de 12 características radiómicas y no busca superar a una red convolucional (sección 2.1.6).

Aprendizaje automático cuántico en mamografía

Entre los trabajos revisados no se encontró ninguno que aplique circuitos cuánticos de codificación de datos a imágenes o características del CBIS-DDSM. El más cercano en mamografía es el de Azevedo et al., que clasifica mamografías completas del BCDR (*Breast Cancer Digital Repository*) como benignas o malignas con redes híbridas: una ResNet18 preentrenada extrae las características, una capa clásica las reduce a cuatro y un circuito variacional de cuatro qubits con codificación angular hace la clasificación [15]. En el conjunto de prueba, el modelo híbrido alcanzó una exactitud del 84 %, la misma que el modelo clásico con transferencia de aprendizaje; la diferencia estuvo en el AUC, de 0.77 frente a 0.58. Los autores consideran prematuro decir si el QML puede ser una ventaja [15]. Su diseño experimental se examina en la sección 2.1.8.

Como trabajo futuro, Azevedo et al. proponen dos líneas: separar el conjunto de datos en masas y calcificaciones antes de clasificar, y examinar cómo se distribuyen los datos en el espacio de Hilbert, donde idealmente las dos clases aparecerían como grupos compactos y separados [15]. El presente trabajo retoma ambas: trata masas y calcificaciones como subproblemas independientes y mide la separabilidad de clases en los espacios inducidos por los circuitos, sobre el CBIS-DDSM.

2.1.6. Límites de la ventaja cuántica con datos clásicos

La búsqueda de una aceleración cuántica (*quantum speed-up*) en aprendizaje supervisado ha producido demostraciones formales, pero restringidas a familias de problemas con una estructura matemática muy particular. Conocer esas demostraciones y sus límites es necesario para valorar qué cabe esperar del aprendizaje automático cuántico sobre datos clásicos genéricos, como las características radiómicas extraídas de mamografías.

Ventaja cuántica a partir de una estructura algebraica en la tarea

Las demostraciones más rigurosas de ventaja cuántica en aprendizaje supervisado con datos clásicos provienen de tareas construidas para que la regla de clasificación esconda una estructura matemática. Liu et al. demostraron una aceleración cuántica rigurosa para clasificación supervisada con un algoritmo que solo requiere acceso clásico a los datos [50]. Su clasificador es una máquina de vectores de soporte convencional que usa una computadora cuántica tolerante a fallos para estimar la función kernel [50]. Bajo el supuesto de que el problema del logaritmo discreto es difícil para

las computadoras clásicas, construyeron una familia de conjuntos de datos en la que ningún clasificador clásico eficiente supera al azar por más que un margen inverso-polinomial [50]. La dificultad está en la estructura algebraica de la tarea: vistos a través del logaritmo discreto, los datos de cada clase forman dos intervalos [50]. Los propios autores aclaran que su problema no tiene motivación práctica y que su resultado es un fundamento teórico para buscar ventajas prácticas [50].

Glick et al. parten de que encontrar kernels cuánticos que den una ventaja en la clasificación de datos reales es un reto importante [51]. Para avanzar en esa dirección introducen una clase de kernels cuánticos, llamados covariantes, para datos con estructura de grupo [51]. El problema que evalúan experimentalmente es la clasificación de datos cercanos a las clases laterales (*cosets*) de un grupo [51]. Lo implementaron con 27 qubits en un procesador superconductor, y señalan que el circuito es lo bastante poco profundo como para que puedan aplicarse métodos de simulación clásica [51].

Ventaja cuántica con datos que ya son estados cuánticos

Una segunda clase de resultados con ventaja exponencial corresponde a escenarios en los que las entradas no son datos clásicos, sino estados de un sistema cuántico. Huang et al. muestran que un experimento que transfiere los datos de un sistema físico a una memoria cuántica estable y los procesa en una computadora cuántica puede tener ventajas significativas sobre uno en el que el sistema se mide y los resultados se procesan en una computadora clásica [52]. La ventaja exponencial se da en la predicción de propiedades de sistemas físicos, en el análisis cuántico de componentes principales sobre estados ruidosos y en el aprendizaje de modelos aproximados de dinámicas físicas [52]. Para alcanzarla hace falta una memoria cuántica suficientemente grande [52]. Este resultado no se extiende a los datos del presente trabajo: una mamografía digitalizada y los descriptores radiómicos que se extraen de ella son registros clásicos de una medición ya realizada, no estados cuánticos que puedan cargarse en una memoria cuántica.

Datos clásicos codificados en ángulos

Para datos clásicos arbitrarios codificados mediante rotaciones, la literatura reciente describe limitaciones que condicionan la posibilidad de una ventaja. Huang et al. muestran que, con ayuda de datos de entrenamiento, los modelos clásicos pueden competir con los cuánticos incluso en problemas diseñados para estos últimos [42]. En sus experimentos numéricos, varios modelos cuánticos habituales rinden igual o peor que los clásicos por tener una diferencia geométrica g pequeña, que atribuyen a que en un espacio de Hilbert exponencialmente grande todas las entradas quedan demasiado lejos entre sí [42]. Solo cuando g fue grande, con un kernel proyectado, observaron una ventaja leve sobre el mejor método clásico [42].

Thanasilp et al. demostraron que, bajo ciertas condiciones, los valores de un kernel cuántico sobre entradas distintas se concentran exponencialmente, con el número de qubits, en torno a un valor fijo [48]. Identifican cuatro fuentes de esta concentración: la expresividad del *embedding*, las mediciones globales, el entrelazamiento y el ruido [48]. En esos casos, el número de mediciones (*shots*) necesario para resolver los valores del kernel con suficiente precisión crece exponencialmente [48]. Con un número polinomial de mediciones, el modelo entrenado resulta trivial: sus predicciones sobre entradas nuevas no dependen de esas entradas [48].

Desde el análisis del sesgo inductivo, Kübler et al. señalan que un espacio de características exponencialmente grande vuelve difícil la generalización [71]. Poder evaluar eficientemente productos internos en espacios de dimensión alta no garantiza, por sí solo, una ventaja cuántica [71]. Para que el aprendizaje sea viable no puede usarse toda la expresividad del espacio de Hilbert, sino solo *embeddings* muy restringidos [71]. Concluyen que no hay indicios de que el aprendizaje automático cuántico vaya a mejorar sustancialmente el aprendizaje supervisado sobre conjuntos de datos clásicos [71].

El ancho de banda y la evidencia empírica

Entre los dos extremos de un kernel (uno cercano a la identidad, en el que cada entrada solo se parece a sí misma, y uno casi constante, en el que todas se parecen) la literatura ha propuesto controlar el ancho de banda como hiperparámetro. Shaydulin y Wild introdujeron el hiperparámetro de ancho de banda (*bandwidth*) de un kernel cuántico y mostraron que controla la expresividad del modelo [69]. En los mapas que estudian, el ancho de banda se controla reescalando los datos: un factor de escala grande hace el kernel demasiado estrecho, es decir, de ancho de banda pequeño, y el aprendizaje se vuelve imposible [69]. En sus experimentos numéricos, el modelo pasa del subajuste, con un ancho de banda demasiado grande, al sobreajuste, con uno demasiado pequeño, y generaliza mejor en un punto intermedio [69]. Al reproducir los resultados negativos de Huang et al., observaron que con el ancho de banda optimizado el rendimiento mejora con el número de qubits y se vuelve competitivo con los mejores métodos clásicos [69].

Canatar et al. muestran que cambiar el ancho de banda puede llevar a un modelo desde no poder generalizar a ninguna función objetivo, de forma demostrable, hasta generalizar bien para objetivos alineados con el kernel [70]. Su análisis explica el mecanismo: el ancho de banda controla el espectro del operador integral del kernel y, con él, el sesgo inductivo del modelo [70]. Con un ancho de banda adecuado, el espectro decae lo suficiente como para que baste un número de muestras polinomial en el número de qubits [70].

En el presente trabajo, el factor de escala que multiplica los ángulos de codificación desempeña el

papel del factor de Shaydulin y Wild. Con el valor del diseño, igual a uno, el kernel cuántico queda en el extremo estrecho; reducirlo equivale a ensanchar el ancho de banda.

Las evaluaciones comparativas recientes insisten en contrastar los modelos cuánticos con métodos clásicos convencionales. En un estudio que evaluó 12 modelos cuánticos sobre 160 conjuntos de datos, Bowles et al. encontraron que, en conjunto, los modelos clásicos estándar, sin ajustes específicos, superan a los clasificadores cuánticos [72]. En las tres familias examinadas (redes neuronales cuánticas, métodos de kernel cuánticos y redes convolucionales cuánticas), el modelo clásico de referencia quedó en primer lugar [72]. Además, quitar el entrelazamiento de un modelo cuántico dio a menudo un rendimiento igual o mejor, lo que sugiere que lo "cuántico" quizá no sea el ingrediente decisivo en las tareas pequeñas que consideraron [72].

Ante estas dificultades, Schuld y Killoran proponen debatir si la ventaja cuántica y la narrativa de "vencer" al aprendizaje clásico deben seguir dominando la literatura como lo hacen [68]. En su diagnóstico, la investigación en QML intenta superar algoritmos grandes y de alto rendimiento en problemas conceptualmente difíciles de estudiar [68]. Entre las preguntas alternativas que plantean está cómo preparar el software cuántico para aplicaciones de aprendizaje automático [68].

Conexión con el diseño del presente trabajo

Las ventajas demostradas hasta ahora se apoyan en tareas con estructura algebraica o en entradas que ya son estados cuánticos. Para datos clásicos codificados en ángulos, la literatura revisada asocia la concentración del kernel y una diferencia geométrica pequeña con modelos clásicos que igualan o superan a los cuánticos, y ninguna de las obras revisadas da razones para anticipar una superioridad cuántica en ese régimen.

Por eso, el presente trabajo no parte de la hipótesis de una ventaja cuántica ni plantea el experimento como una competencia de rendimiento. La separabilidad de clases en los espacios inducidos por los circuitos se mide con métricas que usan las etiquetas (sección 3.4). La diferencia geométrica de Huang et al., que no usa las etiquetas, se emplea como indicador de si el kernel cuántico induce una geometría que un conjunto de kernels clásicos no reproduce. El efecto del ancho de banda se examina con un barrido del factor de escala angular.

2.1.7. Representaciones cuánticas de imágenes

Procesar imágenes en un dispositivo cuántico exige codificar la matriz de píxeles en un estado cuántico. La literatura ha propuesto varias representaciones cuánticas de imágenes (*Quantum Image Representations*, QImRs), cuya viabilidad depende del número de qubits que requieren y del costo

del circuito que prepara el estado.

Representación FRQI

Le et al. introdujeron FRQI (*Flexible Representation of Quantum Images*), que representa una imagen como un estado normalizado que reúne los colores y las posiciones que les corresponden [73]. Para una imagen de $2^n \times 2^n$ píxeles, FRQI usa $2n$ qubits para indexar las posiciones $|i\rangle$ y un qubit de color, $2n+1$ qubits en total. La intensidad de cada píxel se codifica en las amplitudes del qubit de color mediante un ángulo $\theta_i \in [0, \pi/2]$ [73]:

$$|\psi_{\text{FRQI}}\rangle = \frac{1}{2^n} \sum_{i=0}^{2^{2n}-1} (\cos\theta_i|0\rangle + \sin\theta_i|1\rangle) \otimes |i\rangle. \tag{1}$$

Los autores enuncian un teorema de preparación: existe una transformación unitaria, construida con compuertas Hadamard y rotaciones controladas, que lleva el estado inicial $|0\rangle^{\otimes 2n+1}$ al estado FRQI [73]. Esa preparación usa $2^{4n} - 3 \cdot 2^{2n} + 2n$ operaciones elementales [73]. Los autores la llaman preparación polinomial [73]. Con $N = 2^{2n}$ píxeles, el término dominante 2^{4n} es igual a N^2: el costo es cuadrático en el número de píxeles y, por lo tanto, exponencial en el número de qubits de posición. Como ejemplo, una imagen de 2^{16} posiciones (256×256 píxeles) requiere 2^{32} compuertas elementales [73].

Representación NEQR

Zhang et al. propusieron NEQR (*Novel Enhanced Quantum Representation*) como una mejora de FRQI [74]. A diferencia de FRQI, NEQR guarda el nivel de gris de cada píxel en un estado de la base computacional de una secuencia de qubits, y no en la amplitud de un solo qubit [74]. Para una imagen de $2^n \times 2^n$ píxeles con 2^q niveles de gris necesita $q+2n$ qubits: $2n$ para la posición y q para la intensidad [74]. El estado es

$$|\psi_{\text{NEQR}}\rangle = \frac{1}{2^n} \sum_{Y=0}^{2^n-1} \sum_{X=0}^{2^n-1} |f(Y,X)\rangle|Y\rangle|X\rangle, \tag{2}$$

donde $|f(Y,X)\rangle = |C_0 C_1 \cdots C_{q-1}\rangle$ es la codificación binaria del nivel de gris.

Según los autores, la preparación completa de NEQR cuesta a lo sumo $O(qn2^{2n})$ operaciones, con ayuda de suficientes qubits auxiliares, lo que equivale a una reducción aproximadamente cuadrática respecto a FRQI [74]. Además, la imagen original puede recuperarse con exactitud mediante mediciones, y no de forma probabilística como en FRQI [74]. Aun así, los autores reconocen que, con imágenes grandes, la preparación sigue tomando un tiempo inaceptable [74]. El costo $O(qn2^{2n})$ es lineal en el número de píxeles, pero sigue siendo exponencial en el número $2n$ de qubits de

posición.

Comparación de representaciones

Parigi et al. compararon las propiedades de compresión de cuatro representaciones: TNR (*Tensor Network Representation*), FRQI, NEQR y QPIE (*Quantum Probability Image Encoding*) [75]. En sus simulaciones, FRQI y QPIE comprimen más la información de la imagen que TNR y NEQR [75]. La diferencia se ve en las matrices de Gram de los kernels que inducen: la mayoría de los elementos fuera de la diagonal están en $[0{,}8, 1]$ con FRQI y QPIE, es decir, las imágenes resultan muy parecidas entre sí; en $[0, 0{,}4]$ con NEQR, y en $[0{,}4, 0{,}7]$ con TNR [75].

Usados en una SVM, estos kernels alcanzaron en promedio la misma exactitud de clasificación binaria que un kernel lineal clásico, con un costo de almacenamiento exponencialmente menor [75]. Los autores advierten que los mejores protocolos conocidos para cargar una representación exacta de los datos en un estado de n qubits requieren $O(2^n)$ compuertas, costo que domina la complejidad del algoritmo y compromete su posible ventaja cuántica [75]. La carga eficiente de datos clásicos en un estado cuántico sigue siendo una pregunta abierta [75].

Por qué se codifican características radiómicas y no píxeles

Estas limitaciones explican una decisión de diseño de este trabajo: no codificar la matriz de píxeles de la mamografía, sino un vector reducido de características radiómicas.

Las mamografías completas del CBIS-DDSM miden en mediana unos $5\,037 \times 2\,960$ píxeles, con 16 bits por píxel (capítulo 4). Como estimación propia: para codificarlas con NEQR habría que completarlas a $2^{13} \times 2^{13}$ posiciones ($n = 13$, $q = 16$), lo que exige $16 + 2 \cdot 13 = 42$ qubits y, con la cota de Zhang et al., del orden de $16 \cdot 13 \cdot 2^{26} \approx 1{,}4 \times 10^{10}$ operaciones de preparación. Eso queda fuera del alcance del hardware actual y de la simulación de vector de estado. Incluso con imágenes reducidas a 16×16, los experimentos de Parigi et al. muestran kernels de imagen con una exactitud comparable, no superior, a la de un kernel lineal clásico, y el costo de carga sigue siendo el factor dominante.

Por estos motivos, el presente trabajo separa el procesamiento espacial del cómputo cuántico. El recorte de la región de interés, a partir de las máscaras que acompañan al CBIS-DDSM, y la extracción de descriptores de forma, textura e intensidad con PyRadiomics [44] se hacen de forma clásica, y solo el vector de características resultante se codifica en los circuitos cuánticos.

2.1.8. Revisión crítica de los trabajos que reportan ventaja

Varios trabajos de aprendizaje automático cuántico aplicado a oncología reportan mejoras frente a clasificadores clásicos. Para valorar esas afirmaciones con el mismo criterio que este trabajo aplica a sus propios resultados, se plantean cuatro preguntas de control:

1. **Paridad**: ¿el clasificador clásico de referencia recibió las mismas variables de entrada, el mismo preprocesamiento y un ajuste de hiperparámetros comparable al del modelo cuántico?
2. **Incertidumbre**: ¿la diferencia reportada supera la variabilidad experimental, con desviaciones, intervalos de confianza o pruebas de significación?
3. **Partición de prueba**: ¿el conjunto de prueba se usó una sola vez, sin seleccionar modelos ni configuraciones sobre él?
4. **Simulabilidad**: ¿el circuito o kernel cuántico evaluado es difícil de simular en una computadora clásica?

La cuarta pregunta tiene un carácter distinto. La dificultad de simulación es una propiedad de una familia de circuitos cuando crece el número de qubits, no de un experimento concreto: con una docena de qubits, el vector de estado tiene unos pocos miles de amplitudes y cualquier circuito se simula de forma exacta. Ningún experimento a esta escala, incluido el presente, puede responderla afirmativamente; se incluye para dejar claro que una ventaja observada a esa escala no se debe a una dificultad de cómputo clásica.

Xiang et al. (2024): QCCNN sobre datos tabulares de cáncer de mama

Xiang et al. propusieron una red neuronal convolucional híbrida cuántico-clásica (QCCNN) para el diagnóstico del cáncer de mama, con el objetivo de aprovechar el procesamiento en alta dimensión y el paralelismo de la computación cuántica [14].

- *Paridad*: parcial. El estudio no usa mamografías, sino tres conjuntos tabulares descargados de Kaggle: GBSG, SEER y WDBC [14]. Los comparadores son una CNN y una regresión logística [14]; no se incluyen otros clasificadores habituales para datos tabulares, como una SVM con kernel RBF o los métodos basados en árboles.
- *Incertidumbre*: no. El artículo afirma que QCCNN supera significativamente a ambos modelos en todos los casos [14], pero sus tablas no reportan desviaciones, intervalos de confianza ni valores p. La diferencia de exactitud media en validación frente al mejor comparador varía mucho entre conjuntos: 9.9 puntos porcentuales en GBSG (70.5 frente a 60.6 %), 1.0 en

SEER (90.1 frente a 89.1 %) y 3.3 en WDBC (96.2 frente a 92.8 %) [14]. Sin una medida de la variabilidad no puede saberse cuáles de esas diferencias superan el ruido muestral.

- *Partición de prueba*: no. Cada conjunto se divide en entrenamiento y validación, sin un conjunto de prueba independiente. Además del promedio, el artículo destaca la exactitud más alta alcanzada en validación a lo largo de las iteraciones [14]; el máximo sobre la misma partición que se reporta es una estimación optimista.

- *Simulabilidad*: no. La capa cuántica se simuló con PennyLane sobre PyTorch, en una computadora convencional; los autores dejan el uso de procesadores cuánticos para trabajos futuros [14].

El Hafidi et al. (2025): QSVM en cáncer de pulmón

El Hafidi et al. implementaron máquinas de vectores de soporte cuánticas (QSVM) en Qiskit, ejecutadas en el simulador `qasm_simulator`, con tres mapas de características: ZFeatureMap, ZZFeatureMap y PauliFeatureMap [55].

- *Paridad*: sí. Sobre un conjunto clínico de 309 pacientes, con 39 casos sin cáncer y 270 con cáncer, construyeron seis subconjuntos balanceados y evaluaron los modelos cuánticos y clásicos sobre los mismos subconjuntos [55]. Los hiperparámetros de la SVM clásica se optimizaron [55].

- *Incertidumbre*: no. La QSVM alcanzó una exactitud media de 0.96 con PauliFeatureMap y de 0.91 con ZZFeatureMap; la SVM clásica, 0.95 con kernel RBF y 0.94 con kernel polinomial [55]. El mejor modelo cuántico queda 0.01 por encima del mejor clásico, y ZZFeatureMap queda por debajo de ambos kernels clásicos. No se reportan desviaciones ni intervalos. Los valores por subconjunto de su tabla de resultados son 0.875, 0.937 y 1.000 [55]. Son múltiplos de 1/16, lo que es consistente con unas 16 muestras de evaluación por subconjunto: un solo error cambiaría la exactitud en 0.0625, más de seis veces la diferencia entre el mejor modelo cuántico y el mejor clásico. Esta lectura es una inferencia a partir de la tabla; el artículo no declara el tamaño de la partición de evaluación.

- *Partición de prueba*: no lo dice. Las métricas se promedian sobre los seis subconjuntos, pero el artículo no describe cómo se separaron entrenamiento y evaluación dentro de cada uno.

- *Simulabilidad*: no. Con 15 variables de entrada, los mapas de Qiskit usan un qubit por variable, y un circuito de ese tamaño se simula de forma exacta. Los autores describen PauliFeatureMap como una combinación de compuertas X, Y y Z, más expresiva en teoría pero más sensible al ruido de volteo de bit [55]. En el texto no se indica qué cadenas de Pauli se usaron.

En Qiskit, PauliFeatureMap es una familia de circuitos definida por esa lista (sección 3.2.4), y con la lista por defecto, *Z* y *ZZ*, el circuito coincide con el de ZZFeatureMap; sin la lista, el circuito evaluado no queda definido.

Azevedo et al. (2022): transferencia de aprendizaje clásico-cuántica en mamografía

Azevedo et al. entrenaron redes híbridas clásico-cuánticas mediante transferencia de aprendizaje (*transfer learning*) para clasificar mamografías completas en benignas y malignas, con imágenes del BCDR (*Breast Cancer Digital Repository*) [15].

- *Paridad*: parcial. Todos los modelos se evaluaron sobre el mismo conjunto de datos, con la misma partición y una semilla fija [15]. Los modelos con transferencia comparten una ResNet18 preentrenada que extrae 512 variables; el modelo clásico sin transferencia se entrenó desde cero. Con transferencia, el clasificador clásico es una transformación lineal, mientras que en el híbrido se ajustó además la profundidad del circuito [15].

- *Incertidumbre*: no. En el conjunto de prueba, el modelo clásico con transferencia y los híbridos de profundidad 1 y 4 alcanzan la misma exactitud, 0.84. El AUC pasa de 0.58 en el clásico con transferencia a 0.77 en el híbrido de profundidad 1; el modelo clásico entrenado desde cero tiene un AUC de 0.70 [15]. Los autores interpretan esa diferencia de AUC como un indicio de alguna ventaja del circuito híbrido [15], pero no reportan intervalos de confianza ni pruebas estadísticas. En sus conclusiones son prudentes: consideran prematuro decir si el QML puede ser una ventaja [15].

- *Partición de prueba*: no. La profundidad del circuito se eligió comparando las métricas del conjunto de prueba, y la búsqueda se detuvo cuando el AUC empezó a empeorar [15]; el artículo no describe un conjunto de validación separado. En el procesador `ibm_lagos`, la prueba se repitió 20 veces sobre el mismo conjunto, y la exactitud reportada, 0.81, es la mejor de esas 20 repeticiones [15]. Además, el desbalance se corrigió añadiendo copias rotadas de cada mamografía maligna [15], y el artículo no aclara si esas copias se generaron antes o después de separar entrenamiento y prueba.

- *Simulabilidad*: no. El circuito variacional tiene 4 qubits y entre 1 y 4 capas [15], un tamaño que cualquier computadora simula de forma exacta.

Ninguno de los tres trabajos responde afirmativamente a las cuatro preguntas. Esto no invalida sus resultados, pero indica que las mejoras que reportan no bastan para atribuir una ventaja a la componente cuántica.

2.1.9. Tabla comparativa y brechas identificadas

La tabla 1 resume los trabajos revisados en este capítulo. Las columnas P1 a P4 recogen la respuesta de cada trabajo a las cuatro preguntas de control de la sección 2.1.8 (paridad, incertidumbre, partición de prueba y simulabilidad); no se agregan en una sola valoración, porque responden a cuestiones distintas y la cuarta no la satisface ningún experimento a esta escala.

Entre los trabajos revisados, ninguno reúne a la vez un circuito cuántico de codificación, el CBIS-DDSM como conjunto de datos, un análisis explícito de la separabilidad de clases en el espacio inducido por el circuito y el tratamiento de masas y calcificaciones como subproblemas separados. Esa combinación define el lugar del presente trabajo. Las dos últimas condiciones corresponden a las líneas de trabajo futuro que señalan Azevedo et al. (sección 2.1.5).

Cuadro 1: Comparativa de trabajos relacionados en el estado del arte

Trabajo	Datos	Circuito cuántico	Modelo / framework	Feature map	CBIS-DDSM	Análisis separab.	Masas/ calcs. sep.	P1	P2	P3	P4	Desempeño reportado
Aprendizaje profundo en mamografía												
Shen et al. (2019) [24]	CBIS-DDSM	✗	ResNet / VGG	—	✓	✗	✗	—	—	—	—	AUC: 0.91
Wang et al. (2020) [12]	DDSM / INbreast / MIAS / UKy	✗	CNN (6 modelos)	—	Parcial	✗	✗	—	—	—	—	AUC: 0.88–0.95 (valid.), 0.44–0.65 (externos)
Baccouche et al. (2022) [25]	CBIS-DDSM / INbreast	✗	Ensemble ResNet	—	✓	✗	✗	—	—	—	—	Acc.: 0.95 (patología)
Aprendizaje automático cuántico fuera de la mamografía												
Xiang et al. (2024) [14]	GBSG / SEER / WDBC (tabulares)	✓ (sim.)	QCCNN (PennyLane)	Capa cuántica conv.	✗	✗	—	Parc.	No	No	No	Acc. valid.: 0.70–0.96 (clás.: 0.61–0.93)
El Hafidi et al. (2025) [55]	Cáncer de pulmón (tabular)	✓ (sim.)	QSVM (Qiskit)	Z / ZZ / Pauli (sin cadenas)	✗	✗	—	Sí	No	ND	No	Acc.: 0.91–0.96 (RBF: 0.95)
Parigi et al. (2026) [75]	MNIST / F-MNIST (16×16)	✓ (sim.)	Kernels cuánticos / SVM	TNR / FRQI / NEQR / QPIE	✗	✓ (Gram)	—	Sí	Sí	Sí	No	Acc.: 0.94–0.99 (lineal: 0.96–0.99)
Aprendizaje automático cuántico en mamografía												
Azevedo et al. (2022) [15]	BCDR	✓ (sim. + QPU)	QTL (PennyLane)	Angle embedding	✗	✗	✗	Parc.	No	No	No	AUC: 0.77 (clás. TL: 0.58); acc.: 0.84 en ambos
Presente trabajo												
Presente trabajo	**CBIS-DDSM**	**✓ (sim. statevector)**	**MLP sobre $\langle Z_i \rangle$ (Qiskit)**	**C4: ZZ / C5: Pauli (Y, ZZ)**	✓	✓	✓	Sí	Sí	Sí	No	AUC masas: 0.530 / 0.581 (C1: 0.651); calcs.: 0.633 / 0.652 (C1: 0.769)

Notas: ✓ = cumple la condición; ✗ = no la cumple; — = no aplica; ND = el trabajo no lo dice; Parc. = parcialmente. P1–P4: paridad, incertidumbre, partición de prueba y simulabilidad (sección 2.1.8); no aplican a los trabajos sin componente cuántica. En el presente trabajo, los valores de C4 y C5 van separados por una barra; C1 es la condición sin transformación, con el mismo clasificador.

3. Marco Teórico

3.1. Fundamentos de computación cuántica

El presente bloque introduce los conceptos y formalismos matemáticos de la computación cuántica que sustentan la implementación del circuito variacional desarrollado en este trabajo. La referencia estándar para esta sección es Nielsen y Chuang [30].

3.1.1. El qubit como unidad de información cuántica

La unidad fundamental de información en la computación cuántica es el *qubit* (quantum bit). A diferencia de un bit clásico, que solo puede tomar los valores 0 o 1, un qubit puede encontrarse en una *superposición* de ambos estados simultáneamente. Formalmente, el estado de un qubit se representa como un vector unitario en un espacio de Hilbert bidimensional $\mathscr{H} = \mathbb{C}^2$:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad \alpha,\beta \in \mathbb{C}, \quad |\alpha|^2 + |\beta|^2 = 1 \tag{3}$$

donde $|0\rangle$ y $|1\rangle$ son los vectores de la base computacional estándar, análogos a los estados 0 y 1 clásicos:

$$|0\rangle = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \qquad |1\rangle = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \tag{4}$$

Los coeficientes α y β son *amplitudes de probabilidad*: al medir el qubit, se obtiene el estado $|0\rangle$ con probabilidad $|\alpha|^2$ y el estado $|1\rangle$ con probabilidad $|\beta|^2$. La medición es irreversible y colapsa el estado a uno de los dos valores de la base.

La representación geométrica estándar de un qubit es la *esfera de Bloch*, que parametriza el estado general de un qubit (salvo fase global) mediante dos ángulos reales:

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right)|0\rangle + e^{i\varphi}\sin\left(\frac{\theta}{2}\right)|1\rangle, \quad \theta \in [0,\pi],\ \varphi \in [0,2\pi) \tag{5}$$

donde θ determina la mezcla entre $|0\rangle$ y $|1\rangle$, y φ es la fase relativa entre ambos. Esta parametrización es fundamental para entender las compuertas de rotación que conforman los circuitos

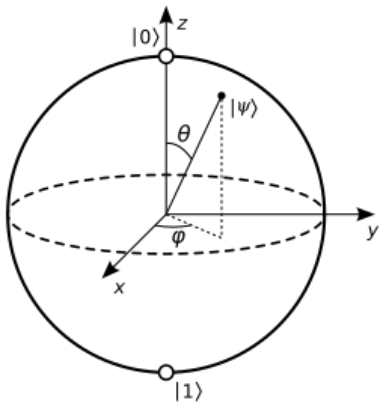


Figura 3.1.1: Esfera de Bloch: representación geométrica de un qubit. El estado $|\psi\rangle$ se representa como un punto en la superficie de la esfera, determinado por los ángulos θ y φ.

variacionales del presente trabajo [30].

3.1.2. Compuertas cuánticas de un qubit

Las operaciones sobre qubits se realizan mediante *compuertas cuánticas*, representadas por matrices unitarias $U \in \mathbb{C}^{2\times 2}$ que satisfacen $UU^\dagger = I$. La unitariedad garantiza la reversibilidad de la operación y la conservación de la norma del estado. Las compuertas más relevantes para los circuitos variacionales son las rotaciones parametrizadas alrededor de los ejes de la esfera de Bloch [30]:

$$R_X(\theta) = e^{-i\frac{\theta}{2}X} = \begin{pmatrix} \cos\frac{\theta}{2} & -i\sin\frac{\theta}{2} \\ -i\sin\frac{\theta}{2} & \cos\frac{\theta}{2} \end{pmatrix} \tag{6}$$

$$R_Y(\theta) = e^{-i\frac{\theta}{2}Y} = \begin{pmatrix} \cos\frac{\theta}{2} & -\sin\frac{\theta}{2} \\ \sin\frac{\theta}{2} & \cos\frac{\theta}{2} \end{pmatrix} \tag{7}$$

$$R_Z(\theta) = e^{-i\frac{\theta}{2}Z} = \begin{pmatrix} e^{-i\frac{\theta}{2}} & 0 \\ 0 & e^{i\frac{\theta}{2}} \end{pmatrix} \tag{8}$$

donde X, Y y Z son las matrices de Pauli:

$$X = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, \quad Y = \begin{pmatrix} 0 & -i \\ i & 0 \end{pmatrix}, \quad Z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \tag{9}$$

Estas compuertas de rotación son los bloques de construcción del ansatz variacional implementado en Qiskit, donde los ángulos θ son los parámetros entrenables del circuito. La compuerta de Hadamard, definida como:

$$H = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \tag{10}$$

transforma el estado base $|0\rangle$ en la superposición uniforme $\frac{1}{\sqrt{2}}(|0\rangle + |1\rangle)$, y es ampliamente utilizada como compuerta de inicialización en circuitos cuánticos.

3.1.3. Sistemas de múltiples qubits y entrelazamiento

El estado de un sistema de n qubits se describe mediante el producto tensorial de los espacios de Hilbert individuales:

$$\mathscr{H}^{\otimes n} = \underbrace{\mathbb{C}^2 \otimes \mathbb{C}^2 \otimes \cdots \otimes \mathbb{C}^2}_{n}, \quad \dim(\mathscr{H}^{\otimes n}) = 2^n \tag{11}$$

El estado general de n qubits es una superposición de los 2^n estados de la base computacional $\{|0\cdots0\rangle, |0\cdots1\rangle, \ldots, |1\cdots1\rangle\}$:

$$|\Psi\rangle = \sum_{k=0}^{2^n-1} c_k |k\rangle, \quad c_k \in \mathbb{C}, \quad \sum_{k=0}^{2^n-1} |c_k|^2 = 1 \tag{12}$$

El *entrelazamiento cuántico* es la propiedad por la cual el estado de un sistema de múltiples qubits no puede factorizarse como el producto tensorial de estados individuales. Un estado entrelazado no tiene representación separable y exhibe correlaciones entre qubits que no tienen análogo clásico [30]. La compuerta estándar para generar entrelazamiento es la *compuerta CNOT* (Controlled-NOT), que opera sobre dos qubits: un qubit de control c y un qubit objetivo t, aplicando una negación al objetivo condicionada al estado del control:

$$\text{CNOT} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix} \tag{13}$$

La combinación de compuertas de rotación de un qubit y compuertas CNOT es suficiente para aproximar cualquier operación unitaria sobre n qubits, propiedad conocida como *universalidad* [30]. Esta combinación es precisamente la que estructura el ansatz variacional RealAmplitudes utilizado en el presente trabajo.

3.1.4. Medición y valores de expectativa

La medición en computación cuántica extrae información clásica del estado cuántico al precio de colapsar la superposición. Para un observable $\hat{O}$ representado por un operador hermítico, el valor de expectativa cuantifica el promedio estadístico obtenido al medir dicho observable sobre un ensamble de estados idénticos $|\psi\rangle$:

$$\langle \hat{O} \rangle = \langle \psi | \hat{O} | \psi \rangle. \tag{14}$$

En el presente trabajo, los observables corresponden a las matrices de Pauli Z aplicadas a cada qubit individual $i \in \{1, \ldots, n\}$. Su valor de expectativa está en el intervalo $[-1, 1]$:

$$\langle Z_i \rangle = \langle \psi | Z_i | \psi \rangle \in [-1, 1], \tag{15}$$

donde $\langle Z_i \rangle = +1$ denota el estado computacional $|0\rangle$, $\langle Z_i \rangle = -1$ denota el estado $|1\rangle$, y valores intermedios describen superposiciones coherentes o mezclas estadísticas. El vector ordenado de expectativas:

$$\mathbf{e}_Z = \big(\langle Z_1 \rangle, \langle Z_2 \rangle, \ldots, \langle Z_n \rangle \big)^\top \in [-1, 1]^n \tag{16}$$

resume la proyección del estado cuántico sobre cada qubit.

En un dispositivo físico cuántico, $\langle Z_i \rangle$ no se mide de forma directa sino que se estima mediante el promedio de n_{shots} mediciones proyectivas independientes. Dado que los autovalores de Z_i son ± 1, cada disparo da ± 1 con probabilidad $P(+1) = (1 + \langle Z_i \rangle)/2$, de modo que la varianza de un disparo individual es $1 - \langle Z_i \rangle^2$. La varianza del estimador empírico $\hat{Z}_i = \frac{1}{n_{\text{shots}}} \sum_{s=1}^{n_{\text{shots}}} z_i^{(s)}$ está determinada exactamente por:

$$\text{Var}(\hat{Z}_i) = \frac{1 - \langle Z_i \rangle^2}{n_{\text{shots}}}. \tag{17}$$

La dispersión muestral es máxima cuando el estado es puramente ecuatorial ($\langle Z_i \rangle = 0$, varianza $1/n_{\text{shots}}$) y se anula si el qubit se halla en un autoestado de la base computacional ($\langle Z_i \rangle = \pm 1$).

El kernel de fidelidad cuántica, $K_Q(\mathbf{x}, \mathbf{x}') = |\langle \phi(\mathbf{x}) | \phi(\mathbf{x}') \rangle|^2$, se estima en hardware de otra forma: se implementa el circuito de *compute-uncompute* $U^\dagger(\mathbf{x}')U(\mathbf{x})$ sobre el estado $|0\rangle^{\otimes n}$ y se cuenta la frecuencia con la que se registra la cadena nula $|0 \ldots 0\rangle$. Por lo tanto, la estimación del kernel

en hardware es un proceso binomial con probabilidad de éxito $p = K_Q$, cuya varianza muestral es $K_Q(1-K_Q)/n_{\text{shots}}$.

En la metodología principal del presente trabajo, con objeto de evaluar las propiedades geométricas de las representaciones sin el ruido que introduce un número finito de disparos, los valores de expectativa y las matrices de fidelidad se evalúan analíticamente en simulación a partir del vector de estado exacto (*statevector*). El impacto empírico y analítico de la cota finita de disparos (n_{shots}) se analiza de forma explícita en el módulo de restricciones del simulador (M8).

3.2. Circuitos cuánticos variacionales y *quantum embeddings*

3.2.1. Circuitos cuánticos parametrizados (PQC)

Un *circuito cuántico parametrizado* (PQC, por sus siglas en inglés) es un circuito cuántico cuyas compuertas dependen de un conjunto de parámetros reales $\theta \in \mathbb{R}^m$ que pueden ajustarse mediante optimización clásica [31]. Un *circuito cuántico variacional* (VQC) es un tipo específico de PQC que combina un bloque de codificación de datos $U(\mathbf{x})$ con un bloque variacional entrenable $W(\theta)$, produciendo el estado cuántico:

$$|\psi(\mathbf{x},\theta)\rangle = W(\theta)\,U(\mathbf{x})\,|0\rangle^{\otimes n} \tag{18}$$

donde n es el número de qubits, $U(\mathbf{x})$ es el *feature map* cuántico que codifica el vector de características clásico $\mathbf{x} \in \mathbb{R}^k$ en el estado cuántico inicial, y $W(\theta)$ es el *ansatz* variacional que introduce correlaciones entre qubits mediante compuertas entrenables [27].

La arquitectura VQC es la más adecuada para el régimen NISQ actual porque mantiene profundidades de circuito moderadas y es diferenciable de extremo a extremo mediante el método de *parameter-shift*, descrito en la sección 3.2.7.

3.2.2. El *feature map* como mapeo no lineal al espacio de Hilbert

El bloque $U(\mathbf{x})$ define un mapeo no lineal:

$$\phi : \mathbb{R}^k \to \mathscr{H}, \qquad \mathbf{x} \mapsto |\phi(\mathbf{x})\rangle = U(\mathbf{x})\,|0\rangle^{\otimes n} \tag{19}$$

donde $\mathscr{H} = \mathbb{C}^{2^n}$ es el espacio de Hilbert del sistema de n qubits, de dimensión 2^n. Como se argumentó en la sección del planteamiento del problema, este espacio no es simplemente una versión ampliada del espacio clásico de entrada: su geometría está determinada por productos internos cuánticos $\langle \phi(\mathbf{x}) | \phi(\mathbf{x}') \rangle$, no por distancias euclidianas. El mapeo ϕ introduce correlaciones de orden superior entre las componentes de $\mathbf{x}$ que los métodos de codificación clásicos no capturan [27, 41].

Este mapeo define implícitamente un *kernel cuántico*:

$$k_Q(\mathbf{x}, \mathbf{x}') = \left| \langle \phi(\mathbf{x}) | \phi(\mathbf{x}') \rangle \right|^2 = \left| \langle 0 |^{\otimes n} U^\dagger(\mathbf{x}') U(\mathbf{x}) | 0 \rangle^{\otimes n} \right|^2 \tag{20}$$

La elección del *feature map* $U(\mathbf{x})$ determina completamente la geometría del espacio de representación y, con ello, la capacidad del sistema para separar las clases en ese espacio. En el presente trabajo se comparan dos diseños de *feature map*: *ZZFeatureMap* y *PauliFeatureMap*, descritos a continuación.

3.2.3. *ZZFeatureMap*: evolución de Pauli-Z de segundo orden

El *ZZFeatureMap* es un circuito de evolución de Pauli-Z de segundo orden introducido por Havlíček et al. [41] y disponible en Qiskit como `zz_feature_map`. Para n qubits y r repeticiones (`reps`), el circuito implementa el unitario:

$$U_{\mathrm{ZZ}}(\mathbf{x}) = \left[\mathscr{U}_\Phi(\mathbf{x}) H^{\otimes n} \right]^r \tag{21}$$

donde $H^{\otimes n}$ es la capa de compuertas de Hadamard que inicializa la superposición uniforme, y $\mathscr{U}_\Phi(\mathbf{x})$ es el bloque de codificación de datos definido por[2]:

$$\mathscr{U}_\Phi(\mathbf{x}) = \exp\left(-i \sum_{S \subseteq [n],\, |S| \leq 2} \phi_S(\mathbf{x}) \bigotimes_{j \in S} Z_j \right) \tag{22}$$

Los coeficientes $\phi_S(\mathbf{x})$ codifican los datos clásicos en el hamiltoniano de evolución:

$$\phi_{\{i\}}(\mathbf{x}) = x_i, \qquad \phi_{\{i,j\}}(\mathbf{x}) = (\pi - x_i)(\pi - x_j) \tag{23}$$

[2]Havlíček et al. y la documentación de Qiskit escriben $+i$; el circuito de Qiskit implementa $-i$, que produce el estado complejo conjugado. El kernel de fidelidad y los valores esperados de este trabajo no dependen de esa elección.

Como $e^{-i\phi Z} = \mathrm{diag}(e^{-i\phi}, e^{i\phi})$, cada término introduce una fase relativa $2\phi_S$ entre las componentes del estado. Por eso el circuito de Qiskit aplica compuertas de fase $P(2x_i)$ y $P\big(2(\pi - x_i)(\pi - x_j)\big)$: el factor 2 corresponde al parámetro `alpha` de la función, cuyo valor por defecto es 2. Con $x_i \in [0, \pi]$, la fase relativa propia recorre la circunferencia una vez.

El término de un qubit $\phi_{\{i\}}$ codifica cada característica x_i como una rotación alrededor del eje Z. El término de dos qubits $\phi_{\{i,j\}}$ introduce *entrelazamiento* entre pares de qubits que codifica las interacciones de segundo orden entre características, operando mediante la compuerta:

$$e^{i\,\phi_{\{i,j\}}(\mathbf{x})\,Z_i Z_j} = \mathrm{CNOT}_{i\to j}\; e^{i\,\phi_{\{i,j\}}(\mathbf{x})\,Z_j}\; \mathrm{CNOT}_{i\to j} \tag{24}$$

Esta capacidad de capturar interacciones de segundo orden entre pares de características es la razón por la que el ZZFeatureMap es uno de los métodos de codificación de datos más utilizados en tareas de clasificación cuántica, dada su capacidad para enriquecer la expresividad del espacio de características cuántico y la dificultad de simularlo clásicamente.

Es importante señalar que en Qiskit 2.x el uso de la clase `ZZFeatureMap` está marcado como obsoleto (*deprecated*) a favor de la función `zz_feature_map()`, que retorna un `QuantumCircuit` estándar [33]. En el presente trabajo se utiliza la función actualizada compatible con Qiskit 2.x.

3.2.4. *PauliFeatureMap*: generalización por elección de los operadores de Pauli

El circuito *PauliFeatureMap* constituye la generalización del esquema de Havlíček et al. que permite seleccionar subconjuntos arbitrarios de operadores de Pauli (X, Y, Z) en el bloque unitario de codificación. El operador adopta la forma general:

$$U_{\mathrm{Pauli}}(\mathbf{x}) = \left[\mathscr{U}_{\Phi}^{(P)}(\mathbf{x})\, H^{\otimes n}\right]^{r}, \tag{25}$$

donde el generador diagonal o no diagonal se define a partir de una familia de cadenas de Pauli $\{P_S\}$:

$$\mathscr{U}_{\Phi}^{(P)}(\mathbf{x}) = \prod_{P\in\mathscr{P}} \exp\left(-i \sum_{S} \phi_S(\mathbf{x}) \bigotimes_{j\in S} P_j\right), \tag{26}$$

donde $\mathscr{P}$ es la lista de cadenas de Pauli elegida, en el orden en que se aplican. Si los términos no conmutan, como Y y ZZ, el bloque es un producto de exponenciales y no una sola exponencial: en C5 se aplica primero $\exp\big(-i\sum_i x_i Y_i\big)$ y después $\exp\big(-i\sum_{i<j}(\pi - x_i)(\pi - x_j) Z_i Z_j\big)$. En el presente trabajo, la condición experimental C5 se define formalmente como `pauli_feature_map(paulis=['Y',`

`'ZZ'], reps=1)`, manteniendo el mismo número de qubits ($k = 12$) e idéntica conectividad de entrelazamiento de segundo orden (ZZ) que el mapa C4 (`zz_feature_map`). La comparación entre C4 y C5 aísla con precisión el efecto de sustituir el eje de rotación de la codificación de primer orden (eje Z frente a eje Y), preservando inalterada la estructura del entrelazamiento de dos cuerpos.

La elección de operadores de Pauli en la codificación de un solo qubit tiene consecuencias geométricas sobre la esfera de Bloch:

1. **El término en X no codifica nada:** Tras la capa inicial de Hadamard, el estado del registro se encuentra en $|+\rangle^{\otimes n} = \left(\frac{|0\rangle+|1\rangle}{\sqrt{2}}\right)^{\otimes n}$. Dado que el estado $|+\rangle$ es un autoestado del operador de Pauli X con autovalor $+1$ ($X|+\rangle = |+\rangle$), la aplicación del operador unitario de evolución bajo X satisface:

$$e^{-i\phi(x_i)X}|+\rangle = e^{-i\phi(x_i)}|+\rangle. \tag{27}$$

   La variable x_i induce únicamente una fase global no física sobre el qubit, sin alterar las amplitudes relativas ni modificar la densidad de probabilidad en ninguna base. Un mapa basado en $\{X, ZZ\}$ anula la codificación de primer orden y degenera en un circuito de puro entrelazamiento ZZ.

2. **Rotación a lo largo del ecuador (Pauli Z, C4):** El generador Z desplaza el estado $|+\rangle$ a lo largo del plano ecuatorial de la esfera de Bloch, alterando la fase relativa φ entre $|0\rangle$ y $|1\rangle$ sin cambiar las probabilidades marginales de ocupación de los polos.

3. **Rotación fuera del ecuador hacia los polos (Pauli Y, C5):** El generador Y actúa perpendicularmente al estado ecuatorial $|+\rangle$, rotándolo a lo largo de un meridiano hacia los polos $|0\rangle$ y $|1\rangle$. Esta transformación modifica de forma directa las probabilidades de medición en la base computacional antes de la aplicación del entrelazamiento.

Qiskit construye el término $\exp(-ix_iY)$ como $\sqrt{X}\,P(2x_i)\,\sqrt{X}^{\dagger}$, que equivale a $R_Y(2x_i)$ salvo una fase global. La condición C5 añade 12 compuertas $\sqrt{X}$ (`SX`) y 12 compuertas $\sqrt{X}^{\dagger}$ (`SXdg`) respecto a C4, con lo que la profundidad del circuito pasa de 65 a 67 capas, sin compuertas CNOT adicionales. Al restringirse ambos mapas a interacciones de grado $|S| \leq 2$, C5 no introduce interacciones de orden superior respecto a C4.

3.2.5. El *ansatz* variacional: RealAmplitudes

El bloque variacional $W(\theta)$ introduce capas de rotaciones parametrizadas y compuertas de entrelazamiento destinadas a manipular las amplitudes del estado codificado $|\phi(\mathbf{x})\rangle$. En este trabajo se emplea la función `real_amplitudes` de Qiskit 2.x, compuesta por una capa inicial de rotacio-

nes R_Y seguida de r bloques repetidos con una cadena de CNOT entre qubits vecinos y nuevas rotaciones R_Y:

$$W(\theta) = \left[\prod_{\ell=r}^{1}\Big(\bigotimes_{i=1}^{n} R_Y(\theta_{\ell,i})\Big)\, E\right] \bigotimes_{i=1}^{n} R_Y(\theta_{0,i}), \tag{28}$$

donde E es la cadena de CNOT, r es el número de repeticiones (`reps`) y el producto se escribe con ℓ creciente hacia la izquierda, que es el orden en que actúan las capas. Para $r = 1$, $W(\theta) = \big(\bigotimes_i R_Y(\theta_{1,i})\big)\, E\, \big(\bigotimes_i R_Y(\theta_{0,i})\big)$. El número total de parámetros es:

$$m = n\,(r+1). \tag{29}$$

Para la configuración experimental fijada en este trabajo ($n = 12$ qubits y $r = 1$ repetición), el *ansatz* contiene exactamente $m = 12 \times (1+1) = 24$ parámetros angulares $\theta \in \mathbb{R}^{24}$. R_Y y CNOT son matrices reales: aplicadas sobre $|0\rangle^{\otimes n}$ producirían solo amplitudes reales, de ahí el nombre. En este trabajo actúan sobre el estado complejo que deja el *feature map*.

El *ansatz* no puede suprimirse. En C4 (`zz_feature_map`), la codificación aplica Hadamard seguido de compuertas diagonales (Z y ZZ). Las compuertas diagonales modifican las fases relativas pero preservan inalteradas las magnitudes de las amplitudes complejas $|c_j| = 2^{-n/2}$. En consecuencia, medir el valor de expectativa en la base Z directamente tras el mapa de características produciría $\langle Z_i\rangle = 0$ para cualquier entrada $\mathbf{x}$. La información reside en las fases relativas del estado cuántico, a las que la medición en la base computacional es ciega. En C5 el giro en Y sí cambia las probabilidades, pero sin el *ansatz* se tendría $\langle Z_i\rangle = -\sin(2x_i)$: cada valor dependería de una sola característica y las fases del acoplamiento ZZ seguirían sin verse. El *ansatz* $W(\theta)$ mezcla los qubits y convierte parte de las diferencias de fase en diferencias de probabilidad medibles en $\langle Z_i\rangle$.

3.2.6. El *quantum embedding*: vector de salida del circuito

A partir del estado conjunto $|\psi(\mathbf{x},\theta)\rangle = W(\theta)\,U(\mathbf{x})\,|0\rangle^{\otimes n}$, el circuito extrae información mediante la medición del valor de expectativa del operador de Pauli Z sobre cada qubit i:

$$\langle Z_i\rangle = \langle\psi(\mathbf{x},\theta)|Z_i|\psi(\mathbf{x},\theta)\rangle \in [-1,1]. \tag{30}$$

El *quantum embedding* de la muestra $\mathbf{x}$ se formaliza como el vector de los n valores de expectativa:

$$\mathbf{e}(\mathbf{x},\theta) = \big(\langle Z_1\rangle, \langle Z_2\rangle, \ldots, \langle Z_n\rangle\big)^{\top} \in [-1,1]^n. \tag{31}$$

En el diseño adoptado, el vector de parámetros θ no se entrena mediante optimización iterativa supervisada: se fija de forma determinista una sola vez mediante un sorteo uniforme en $[0, 2\pi)$ con semilla declarada (42). Los valores de expectativa $\mathbf{e}(\mathbf{x}, \theta)$ se calculan analíticamente de forma exacta sobre el vector de estado (*statevector*) y se almacenan para alimentar directamente a los clasificadores clásicos.

Por otra parte, la matriz de kernel de fidelidad cuántica $K_Q(\mathbf{x}, \mathbf{x}')$, definida en la ecuación (20), se evalúa exclusivamente sobre el *feature map* $U(\mathbf{x})$, sin incluir el *ansatz* $W(\theta)$. Dado que $W(\theta)$ es un operador unitario ($W^\dagger W = I$), su inserción antes de la medición se cancelaría en el producto interno: $|\langle\phi(\mathbf{x})|W^\dagger W|\phi(\mathbf{x}')\rangle|^2 = |\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$.

3.2.7. El método *parameter-shift* para el cálculo del gradiente

Para la optimización de circuitos cuánticos variacionales en plataformas físicas, el cálculo del gradiente de un valor de expectativa respecto a los parámetros del circuito θ no puede llevarse a cabo mediante la retropropagación clásica de errores (*backpropagation*), dado que el estado interno colapsa durante la medición y las amplitudes intermedias son físicamente inaccesibles. En su lugar, se recurre a la regla analítica del *parameter-shift* [32, 31]. Para compuertas unitarias generadas por operadores hermíticos con dos autovalores distintos (tales como las rotaciones de Pauli $R_Y(\theta) = \exp(-i\frac{\theta}{2}Y)$), la derivada exacta del valor esperado viene dada por:

$$\frac{\partial\langle Z_i\rangle}{\partial\theta_j} = \frac{1}{2}\left[\langle Z_i\rangle_{\theta_j+\frac{\pi}{2}} - \langle Z_i\rangle_{\theta_j-\frac{\pi}{2}}\right], \tag{32}$$

donde $\langle Z_i\rangle_{\theta_j\pm\pi/2}$ denota el valor de expectativa del circuito evaluado sustituyendo el parámetro escalar θ_j por $\theta_j \pm \pi/2$, manteniendo los demás parámetros constantes.

Con $m = n(r+1) = 24$ parámetros, cada gradiente por muestra exige $2m = 48$ evaluaciones del circuito. Medido en el simulador con valores exactos, el gradiente por *parameter-shift* tardó 5.16 s por lesión, lo que para las 2 864 lesiones de entrenamiento y 50 épocas representa unas 205 h por *feature map*. La retropropagación a través del vector de estado produce el mismo gradiente (con una diferencia de $1{,}8 \times 10^{-15}$) en 3.4 min, unas 3 600 veces menos tiempo, pero exige conocer simultáneamente las 2^n amplitudes del estado, información que un computador cuántico no entrega porque medir colapsa el estado. En este trabajo θ no se entrena (sección 5.7); el costo se documenta como parte del OE-6.

3.3. Red neuronal clásica e integración Qiskit–PyTorch

3.3.1. Perceptrón multicapa (MLP)

La red neuronal clásica utilizada como clasificador *downstream* en el pipeline del presente trabajo es un perceptrón multicapa (MLP, *Multi-Layer Perceptron*), una arquitectura de aprendizaje supervisado compuesta por capas de neuronas totalmente conectadas [35].

Formalmente, dado un vector de entrada $\mathbf{z} \in \mathbb{R}^n$, que puede ser el *quantum embedding* $\mathbf{e}(\mathbf{x}, \theta)$ o cualquiera de los vectores de las condiciones clásicas, la transformación de la capa ℓ se define como:

$$\mathbf{h}^{(\ell)} = \sigma\left(W^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}\right), \qquad \ell = 1, \ldots, L \tag{33}$$

donde $W^{(\ell)} \in \mathbb{R}^{d_\ell \times d_{\ell-1}}$ es la matriz de pesos, $\mathbf{b}^{(\ell)} \in \mathbb{R}^{d_\ell}$ es el vector de sesgos, y $\sigma(\cdot)$ es la función de activación no lineal. La capa de salida produce una probabilidad de clasificación binaria mediante la función sigmoide:

$$\hat{y} = \sigma_{\text{sig}}\left(W^{(L)}\mathbf{h}^{(L-1)} + b^{(L)}\right) = \frac{1}{1 + e^{-(W^{(L)}\mathbf{h}^{(L-1)} + b^{(L)})}} \in [0, 1] \tag{34}$$

El modelo se entrena minimizando la función de pérdida de entropía cruzada binaria (*Binary Cross-Entropy*, BCE):

$$\mathscr{L}_{\text{BCE}}(\hat{y}, y) = -\left[y \log \hat{y} + (1 - y)\log(1 - \hat{y})\right] \tag{35}$$

donde $y \in \{0, 1\}$ es la etiqueta real (0 = benigno, 1 = maligno). Los parámetros $\{W^{(\ell)}, \mathbf{b}^{(\ell)}\}$ se optimizan mediante descenso de gradiente estocástico (*Adam* o equivalente) a través del algoritmo de *backpropagation* [35].

La arquitectura del MLP se mantiene idéntica para las cinco condiciones experimentales: mismo número de capas ocultas, mismas dimensiones, misma función de activación, mismos hiperparámetros y misma semilla aleatoria. Esta invarianza es el principio metodológico central que garantiza que las diferencias de rendimiento entre condiciones sean atribuibles únicamente a la transformación aplicada en M5, y no a diferencias en el clasificador.

3.3.2. Ponderación de clases para datos desbalanceados

Dado el desbalance de clases observado en el análisis exploratorio del dataset CBIS-DDSM (ratio 1.78:1 en calcificaciones), se aplica ponderación de clases durante el entrenamiento del MLP. La pérdida ponderada se define como:

$$\mathscr{L}_w = -\left[w_1\, y \log \hat{y} + w_0\,(1-y)\log(1-\hat{y})\right] \tag{36}$$

donde los pesos w_0 y w_1 se calculan inversamente proporcionales a la frecuencia de cada clase en el conjunto de entrenamiento:

$$w_c = \frac{N}{C \cdot N_c}, \qquad c \in \{0,1\} \tag{37}$$

siendo N el número total de muestras, $C = 2$ el número de clases y N_c el número de muestras de la clase c. Este ajuste se aplica de forma independiente para los subconjuntos de masas y calcificaciones.

3.3.3. Integración cuántico-clásica: *embeddings* precomputados

La integración entre los circuitos cuánticos y el clasificador clásico se formula mediante una arquitectura desacoplada basada en representaciones intermedias. En lugar de ensamblar el circuito cuántico como una capa diferenciable dentro de la red neuronal mediante adaptadores de software como `TorchConnector` [34], el pipeline separa la fase de transformación cuántica de la fase de clasificación supervisada.

El flujo de procesamiento opera de acuerdo con las siguientes etapas metodológicas:

1. **Generación determinista de representaciones:** A partir del vector de características seleccionado y escalado $\mathbf{x} \in [0,\pi]^{12}$ (M4), el circuito cuántico compuesto por el mapa de características (`zz_feature_map` en C4 o `pauli_feature_map` en C5) y el *ansatz* `real_amplitudes` con parámetros fijos θ calcula de forma analítica el vector de expectativas exactas $\mathbf{e}(\mathbf{x},\theta) \in [-1,1]^{12}$.

2. **Almacenamiento de representaciones:** Los vectores resultantes se precomputan una sola vez para la totalidad del conjunto de datos y se persisten en disco en formato estructurado,

eliminando la necesidad de reevaluar circuitos durante el ciclo de optimización del clasificador.

3. **Estandarización:** Los vectores de cada condición experimental se estandarizan empleando la media y desviación estándar ajustadas sobre el conjunto de entrenamiento de cada partición, compensando la disparidad en las escalas numéricas de las distintas condiciones (M7).

4. **Entrenamiento del clasificador clásico:** El perceptrón multicapa (MLP) en PyTorch se entrena sobre las representaciones estandarizadas, optimizando sus pesos sin modificar los parámetros del circuito cuántico.

Este diseño responde a tres razones:

- **Validez interna del experimento:** Las condiciones clásicas C2 (PCA) y C3 (Kernel PCA) operan como transformaciones no supervisadas que no acceden a las etiquetas de patología para construir el nuevo espacio. Si C4 y C5 ajustaran θ contra las etiquetas durante el entrenamiento, cualquier ganancia en clasificación podría atribuirse al ajuste paramétrico supervisado y no a las propiedades geométricas de la codificación cuántica ϕ.
- **Correspondencia con la pregunta de investigación:** El objetivo del trabajo consiste en determinar si el mapeo cuántico al espacio de Hilbert genera mayor separabilidad intrínseca en las características radiómicas, aislando la capacidad representacional del *feature map* frente a la optimización variacional.
- **Viabilidad computacional:** Evita el costo de cientos de horas de ejecución que demandaría el método *parameter-shift* en cada época de entrenamiento; en el simulador la retropropagación sobre el vector de estado abarataría el entrenamiento, pero ese atajo no existe en hardware (sección 3.2.7).

3.3.4. Implementación en Qiskit 2.x

En Qiskit 2.x, el flujo computacional del pipeline se estructura en los siguientes pasos:

1. Construcción del *feature map* con `zz_feature_map(12, reps=1)` o `pauli_feature_map(12, reps=1, paulis=['Y','ZZ'])`.

2. Instanciación del *ansatz* con `real_amplitudes(12, reps=1)` y vector de parámetros θ sorteado una sola vez con semilla determinista 42.

3. Composición del circuito y asignación fija de parámetros mediante los métodos `compose` y

`assign_parameters`.

4. Cálculo del vector de estado mediante la clase `Statevector` y obtención de los valores de expectativa $\langle Z_i \rangle = \sum_b p(b)\,(1-2b_i)$ a partir de las probabilidades exactas de la base computacional.

5. Evaluación del kernel de fidelidad cuántica mediante la clase `FidelityStatevectorKernel` de `qiskit-machine-learning`.

En este trabajo no se usan `EstimatorQNN` ni `TorchConnector`. `EstimatorQNN` solicita por defecto una precisión de 0,015625, y con ella la primitiva `StatevectorEstimator` suma a cada valor esperado un ruido gaussiano de esa desviación; el `EstimatorV2` de Qiskit Aer tampoco muestrea, sino que devuelve el valor exacto más un ruido gaussiano de la precisión pedida. Por eso, en este trabajo, "exacto" significa vector de estado directo o precisión cero explícita, y el estudio de *shots* se hace con un muestreo de las probabilidades exactas.

Es importante señalar que las clases `ZZFeatureMap`, `PauliFeatureMap` y `RealAmplitudes` están marcadas como obsoletas en Qiskit 2.x a favor de las funciones `zz_feature_map()`, `pauli_feature_map()` y `real_amplitudes()`, que retornan un `QuantumCircuit` estándar en lugar de un `BlueprintCircuit` [33]. El presente trabajo utiliza las funciones actualizadas para garantizar compatibilidad con Qiskit 2.x.

3.4. Métricas de separabilidad y evaluación

Este bloque formaliza las métricas utilizadas para evaluar las representaciones generadas por cada condición experimental. Se organizan en dos grupos: métricas de separabilidad, que miden la calidad del espacio de representación con independencia del clasificador; y métricas de clasificación, que miden el desempeño del MLP sobre cada representación.

3.4.1. *Kernel-Target Alignment* (KTA)

El *Kernel-Target Alignment* (KTA) cuantifica la similitud entre una matriz de kernel $K \in \mathbb{R}^{N\times N}$ evaluada sobre N muestras y la matriz de etiquetas ideales de clasificación $Y = \mathbf{y}\mathbf{y}^\top$, donde $\mathbf{y} \in \{-1,+1\}^N$ denota el vector de etiquetas binarias de patología.

La formulación original propuesta por Cristianini et al. [36] define la alineación no centrada como

el coseno de Frobenius entre ambas matrices:

$$\widehat{\mathrm{KTA}}_u(K,\mathbf{y}) = \frac{\langle K, \mathbf{y}\mathbf{y}^\top \rangle_F}{\|K\|_F \cdot \|\mathbf{y}\mathbf{y}^\top\|_F} = \frac{\mathbf{y}^\top K \mathbf{y}}{N\,\|K\|_F}, \tag{38}$$

donde $\langle A, B\rangle_F = \mathrm{Tr}(A^\top B) = \sum_{i,j} A_{ij}B_{ij}$ es el producto interno de Frobenius y $\|\cdot\|_F$ su norma inducida. Dado que $y_i \in \{-1,+1\}$, la norma de la matriz de etiquetas ideales satisface $\|\mathbf{y}\mathbf{y}^\top\|_F = N$.

No obstante, la métrica no centrada presenta un sesgo ante conjuntos de datos con desbalance de clases. Si la proporción de clases difiere del 50 %, el valor esperado de $y_i y_j$ es positivo, lo que provoca que una matriz de kernel no informativa (e.g., una matriz constante u homogénea) obtenga valores elevados de alineación simplemente por capturar la media de las etiquetas. Para suprimir este artefacto, Cortes, Mohri y Rostamizadeh [47] introdujeron la *alineación de kernel centrada* (*Centered Kernel Alignment*), adoptada en este trabajo como la métrica principal de KTA:

$$\widehat{\mathrm{KTA}}_c(K,\mathbf{y}) = \frac{\langle K_c, (\mathbf{y}\mathbf{y}^\top)_c \rangle_F}{\|K_c\|_F \cdot \|(\mathbf{y}\mathbf{y}^\top)_c\|_F} = \frac{\mathbf{y}^\top K_c \mathbf{y}}{\|K_c\|_F \sum_{i=1}^{N}(y_i - \bar{y})^2}, \tag{39}$$

donde $K_c = HKH$ representa la matriz de kernel centrada mediante la matriz de proyección $H = I - \frac{1}{N}\mathbf{1}\mathbf{1}^\top$, con componentes escalares:

$$(K_c)_{ij} = K_{ij} - \frac{1}{N}\sum_{k=1}^{N} K_{ik} - \frac{1}{N}\sum_{l=1}^{N} K_{lj} + \frac{1}{N^2}\sum_{k,l=1}^{N} K_{kl}. \tag{40}$$

El término de normalización $\|(\mathbf{y}\mathbf{y}^\top)_c\|_F$ coincide con la suma de desviaciones cuadráticas de las etiquetas centradas, $\sum_{i=1}^{N}(y_i - \bar{y})^2$.

A pesar del centrado, los kernels que presentan concentración exhiben una cota inferior analítica fija. Para la matriz identidad $K = I$ (el kernel de un espacio donde todas las muestras son mutuamente ortogonales), la KTA centrada adopta un valor constante e independiente de las etiquetas:

$$\widehat{\mathrm{KTA}}_c(I,\mathbf{y}) = \frac{1}{\sqrt{N-1}}, \tag{41}$$

que para la submuestra de evaluación de $N = 200$ lesiones equivale a $1/\sqrt{199} \approx 0{,}0709$. (Para la formulación no centrada, dicho valor equivale a $1/\sqrt{N} = 1/\sqrt{200} \approx 0{,}0707$). En consecuencia, las magnitudes absolutas de KTA no son directamente comparables entre kernels cuyos espectros de autovalores difieren mucho. Para establecer una comparación válida, la alineación de cada kernel se evalúa calculando el *exceso de alineación* respecto a la media de una prueba de permutación con

1 000 barajadas de las etiquetas que conservan el número de lesiones de cada clase:

$$\Delta\mathrm{KTA}_c = \widehat{\mathrm{KTA}}_c(K, \mathbf{y}) - \mathbb{E}_\pi \left[\widehat{\mathrm{KTA}}_c(K, \mathbf{y}_\pi) \right]. \tag{42}$$

Para C4 y C5 el kernel es el de fidelidad (ecuación (20)); la referencia clásica es el RBF con γ fijado por la heurística de la mediana; sobre los vectores de cada condición se calcula además la KTA del kernel lineal.

3.4.2. *Geometric difference*

La *geometric difference* fue formalizada por Huang et al. [42] para evaluar si un kernel cuántico K_Q induce sobre los datos una geometría que un kernel clásico K_C dado no puede reproducir. Dados $K_Q, K_C \in \mathbb{R}^{N\times N}$ normalizados a traza común $\mathrm{Tr}(K_Q) = \mathrm{Tr}(K_C) = N$, la *geometric difference* sin regularizar es:

$$g_{CQ} = g(K_C \parallel K_Q) = \sqrt{\left\| \sqrt{K_Q}\, K_C^{-1}\, \sqrt{K_Q} \right\|_\infty}, \tag{43}$$

donde $\|\cdot\|_\infty$ denota la norma espectral (el autovalor máximo de la matriz simétrica) y $\sqrt{K}$ es la raíz cuadrada matricial simétrica positiva obtenida por descomposición espectral:

$$K = V\Lambda V^\top \implies \sqrt{K} = V\Lambda^{1/2}V^\top, \tag{44}$$

con truncamiento a cero de posibles autovalores residuales negativos por precisión de punto flotante. En la ecuación (43), el kernel cuántico K_Q figura en los factores externos mientras que el kernel clásico K_C es la matriz invertida. Con kernels de diagonal unitaria y $\mathrm{Tr}\,K = N$, $g_{CQ} \geq 1$: basta evaluar el cociente de Rayleigh $v^\top K_Q v / v^\top K_C v$ en un vector canónico.

En conjuntos de datos reales, la evaluación directa de la ecuación (43) resulta numéricamente inestable debido a que las matrices de kernel clásicas suelen presentar valores propios muy pequeños, que disparan g_{CQ} y hacen que mida el condicionamiento de K_C y no la codificación. Para subsanar esto, Huang et al. [42] definieron la formulación regularizada mediante un parámetro de penalización $\lambda > 0$ (información suplementaria, sección 6 C, ecs. (S71) y (S72)):

$$g_{\mathrm{gen}}(K_C, K_Q; \lambda) = \sqrt{\left\| \sqrt{K_Q}\sqrt{K_C}\,(K_C + \lambda I)^{-2}\,\sqrt{K_C}\sqrt{K_Q} \right\|_\infty}, \tag{45}$$

junto con la cota del error de entrenamiento admisible para el predictor clásico:

$$g_{\mathrm{tra}}(K_C, K_Q; \lambda) = \lambda \sqrt{\left\| \sqrt{K_Q}\,(K_C + \lambda I)^{-2}\,\sqrt{K_Q} \right\|_\infty}. \tag{46}$$

Cuando $\lambda \to 0$, g_{gen} recupera la distancia de la ecuación (43).

Se sigue el protocolo de Huang et al. (información suplementaria, sección 12 C, ecs. (S113)–(S115)): se evalúa una malla de regularización $\lambda \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 0{,}025, 0{,}05, 0{,}1\}$ y una batería de kernels clásicos que comprende un kernel lineal sobre los datos centrados y kernels gaussianos (RBF) con parámetro $\gamma = m/(n \operatorname{Var}[\mathbf{x}])$, para multiplicadores $m \in \{0{,}25, 0{,}5, 1, 2, 4, 8, 16, 32, 64\}$, con $n = 12$ el número de características y $\operatorname{Var}[\mathbf{x}]$ la varianza de todas las coordenadas de la submuestra. Como análisis de sensibilidad se añaden gaussianos más estrechos, $m \in \{128, 256, 512\}$. Para cada kernel clásico, se identifica el mayor valor de λ admisible que satisface la restricción de error de entrenamiento:

$$g_{\text{tra}}(K_C, K_Q; \lambda) < 0{,}045, \tag{47}$$

y se reporta el valor mínimo alcanzable sobre toda la batería, $g = \min_{K_C} g_{\text{gen}}(K_C, K_Q; \lambda^*(K_C))$.

El criterio de decisión teórico establecido por Huang et al. contrasta este valor frente a la cota de dimensión de la muestra:

- Si $g \ll \sqrt{N}$ (donde $\sqrt{N} = \sqrt{200} \approx 14{,}14$), el modelo clásico predice con un error comparable o menor cualquier función que el modelo cuántico pueda aprender, sea cual sea el etiquetado.
- Si g es del orden de $\sqrt{N}$, existe un etiquetado para el que el modelo cuántico puede superar a los clásicos de la batería. Es una condición necesaria, no suficiente: la ventaja depende además de las etiquetas reales.

El cálculo se realiza sobre una submuestra fija de exactamente $N = 200$ lesiones estratificadas por clase del conjunto de entrenamiento por cada subproblema (semilla 42). La figura 3.4.1 ilustra el marco geométrico conceptual propuesto por Huang et al.

Concentración exponencial del kernel cuántico. Un obstáculo para escalar de clasificadores cuánticos basados en producto interno es el fenómeno de concentración, advertido por Huang et al. ("*all inputs are too far apart*") y formalizado por Thanasilp et al. [48]. A medida que el número de qubits n crece, las fidelidades cuánticas fuera de la diagonal $|\langle \phi(\mathbf{x}) | \phi(\mathbf{x}') \rangle|^2$ se concentran exponencialmente en n alrededor de un valor fijo, que para el kernel de fidelidad es cercano a cero. El kernel se acerca entonces a la matriz identidad, $K_Q \approx I$: todas las muestras parecen casi ortogonales entre sí y se pierde la noción de vecindad. Thanasilp et al. identifican cuatro fuentes de concentración: la expresividad del *embedding*, las mediciones globales (como el proyector $|0 \ldots 0\rangle\langle 0 \ldots 0|$ con que se estima el kernel de fidelidad), el entrelazamiento y el ruido. Los resultados empíricos sobre la concentración observada en este proyecto se presentan en la sección de resultados.

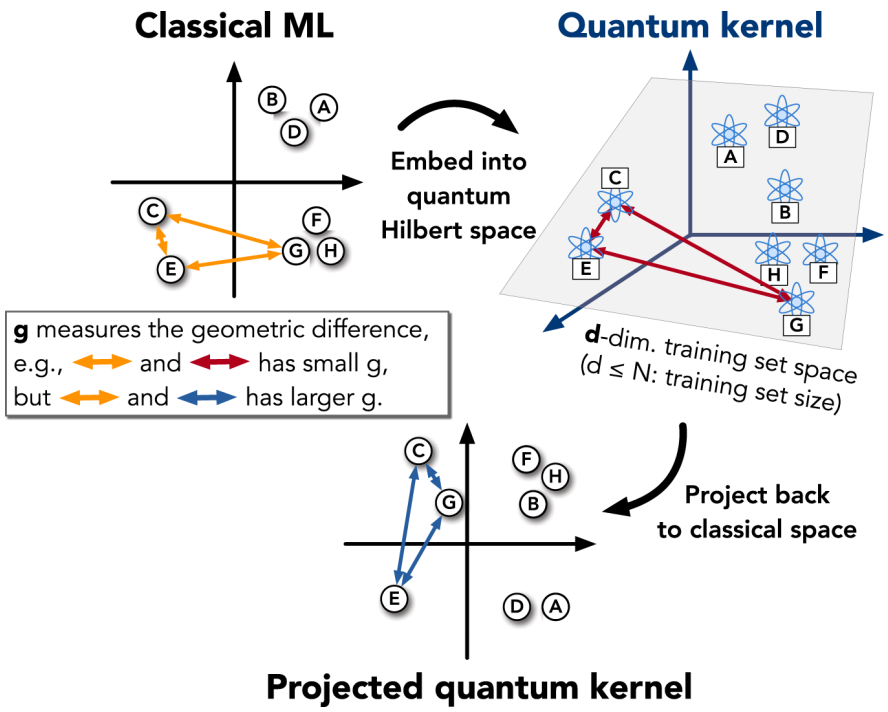


Figura 3.4.1: Geometría (función kernel) definida por modelos clásicos y cuánticos. Las letras representan datos y las flechas, la similitud entre ellos; la *geometric difference* g mide cuánto difieren esas similitudes entre modelos, y d es la dimensión efectiva del conjunto de entrenamiento en el espacio de Hilbert. Reproducida de Huang et al. (2021), *Nat. Commun.* 12, 2631, bajo licencia CC BY 4.0 (https://creativecommons.org/licenses/by/4.0/).

3.4.3. Dimensión efectiva

Para caracterizar la expresividad y la estructura espectral de la matriz de kernel sin depender de las etiquetas de clase, Huang et al. [42] propusieron el concepto de *dimensión efectiva* $d(K)$. Esta métrica cuantifica cuántas direcciones independientes u ortogonales explora el conjunto de datos en el espacio de Hilbert inducido por el kernel.

Sea $K \in \mathbb{R}^{N\times N}$ una matriz de kernel normalizada a traza N ($\mathrm{Tr}(K) = N$). Sean $t_1 \geq t_2 \geq \cdots \geq t_N \geq 0$ los autovalores ordenados de forma decreciente de K. La dimensión efectiva se define como:

$$d(K) = \sum_{k=1}^{N} \frac{1}{N-k+1} \sum_{l=k}^{N} t_l. \tag{48}$$

En la ecuación (48), el término interior $\sum_{l=k}^{N} t_l$ representa la suma de la cola espectral a partir del k-ésimo autovalor, y el denominador la promedia entre las $N-k+1$ direcciones restantes.

Nota sobre errata en la literatura: La ecuación (S64) de la información suplementaria de Huang et al. [42] (sección 6 B) imprime el factor normalizador como $\frac{1}{N-k}$, formulación que incurre en una indeterminación por división entre cero en el último sumando ($k = N$). La corrección consiste en emplear el denominador $N-k+1$. Con esta formulación, la métrica satisface las cotas que enuncian los autores:

$$1 \leq d(K) \leq N. \tag{49}$$

Los dos extremos se comprueban directamente:

- **Cota inferior ($d = 1$):** Si todas las muestras mapean al mismo estado cuántico, la matriz de kernel tiene rango 1 ($t_1 = N$ y $t_l = 0$ para $l \geq 2$). La suma total colapsa a $d = \frac{1}{N} t_1 = \frac{N}{N} = 1$.
- **Cota superior ($d = N$):** Si todas las muestras mapean a estados mutuamente ortogonales en el espacio de Hilbert ($K = I$, autovalores $t_l = 1$ para todo l), la cola espectral para cada índice k satisface $\sum_{l=k}^{N} 1 = N-k+1$. Al cancelarse con el denominador, cada sumando vale idénticamente 1, resultando en $d = \sum_{k=1}^{N} 1 = N$.

Valores de d cercanos a N indican que cada lesión ocupa casi su propia dirección, como ocurre con un kernel concentrado; valores pequeños, que el kernel agrupa las lesiones en pocas direcciones.

3.4.4. Índice Davies-Bouldin

El índice Davies-Bouldin (DB) [37] mide la calidad de la separación entre clusters en un espacio de representación, combinando la dispersión intra-clase con la separación inter-clase. Para el problema

de clasificación binaria (benigno / maligno), las dos clases diagnósticas se definen como clusters predeterminados ($C = 2$). El índice se define como:

$$\mathrm{DB} = \frac{1}{C} \sum_{i=1}^{C} \max_{j \neq i} \left\{ \frac{s_i + s_j}{d(c_i, c_j)} \right\} \tag{50}$$

donde $C = 2$ es el número de clases, s_i es la dispersión promedio de los puntos de la clase i respecto a su centroide c_i:

$$s_i = \frac{1}{|C_i|} \sum_{\mathbf{z} \in C_i} \|\mathbf{z} - c_i\|_2 \tag{51}$$

y $d(c_i, c_j) = \|c_i - c_j\|_2$ es la distancia euclidiana entre los centroides de las clases i y j. Valores bajos del índice DB indican clusters compactos y bien separados; el valor óptimo es 0. Esta métrica es independiente del clasificador y puede aplicarse directamente sobre el vector de embeddings $\mathbf{e}(\mathbf{x}, \theta)$ de las condiciones cuánticas o sobre los vectores transformados de las condiciones clásicas. Al depender de distancias euclidianas invariantes ante rotaciones ortogonales, el índice DB genera el mismo valor para C1 y C2.

3.4.5. Razón multivariante de Fisher

La razón de Fisher cuantifica la separabilidad lineal entre dos clases comparando la distancia entre sus centroides frente a la dispersión intraclase. En el análisis univariado clásico introducido por Fisher [38], el coeficiente mide la separación a lo largo de un único eje. Sin embargo, en un espacio de representación multivariado $\mathbb{R}^k$ (como el espacio de $k = 12$ dimensiones de los embeddings cuánticos o de las características radiómicas), la formulación unidimensional promediada coordenada por coordenada ignora las covarianzas entre variables y adolece de una limitación geométrica: no es invariante ante transformaciones de rotación.

Para garantizar consistencia metodológica, en este trabajo se adopta la *razón multivariante de Fisher* (distancia de Mahalanobis al cuadrado entre medias de clase con la matriz de covarianza combinada):

$$J = \Delta\mu^{\top} S_W^{-1} \Delta\mu, \tag{52}$$

donde $\Delta\mu = \mu_1 - \mu_0$ denota el vector de diferencia entre los centroides de las clases maligna y benigna en $\mathbb{R}^k$, y S_W es la matriz de dispersión intraclase combinada (*pooled within-class cova-*

riance):

$$S_W = \frac{1}{N-2}\left[\sum_{i\in\mathscr{C}_0}(\mathbf{e}_i-\mu_0)(\mathbf{e}_i-\mu_0)^\top + \sum_{j\in\mathscr{C}_1}(\mathbf{e}_j-\mu_1)(\mathbf{e}_j-\mu_1)^\top\right]. \tag{53}$$

La formulación matricial de la ecuación (52) posee una propiedad algebraica relevante: es invariante ante cualquier transformación afín invertible del espacio de características, $\mathbf{e} \mapsto A\mathbf{e}+\mathbf{b}$, con $A \in \mathbb{R}^{k\times k}$ y $\det(A) \neq 0$:

$$\begin{aligned} J(A\mathbf{e}+\mathbf{b}) &= (A\Delta\mu)^\top (AS_WA^\top)^{-1}(A\Delta\mu) \\ &= \Delta\mu^\top A^\top (A^\top)^{-1} S_W^{-1} A^{-1} A\Delta\mu \\ &= \Delta\mu^\top S_W^{-1}\Delta\mu = J(\mathbf{e}). \end{aligned} \tag{54}$$

Esta invariancia afín es necesaria para el diseño experimental del proyecto. La condición C2 aplica una transformación por Componentes Principales completa sin reducción de dimensión ($k \to k$). Dicha proyección es una traslación seguida de una rotación ($A \in \mathrm{O}(k)$), por lo que, bajo la formulación multivariante, se cumple necesariamente que $J(\mathrm{C1}) = J(\mathrm{C2})$ por construcción.

3.4.6. Visualización *t-SNE*

El algoritmo *t-Distributed Stochastic Neighbor Embedding* (t-SNE) [39] proyecta vectores de alta dimensionalidad a un espacio de dos dimensiones preservando la estructura de vecindad local. Se utiliza como herramienta de visualización cualitativa de la separabilidad de clases en el espacio de embeddings: si la proyección t-SNE muestra clusters compactos y bien separados por clase, el espacio de representación tiene estructura discriminativa.

Como complemento visual de las métricas de separabilidad del espacio de embeddings (DB, Fisher multivariante y KTA lineal), se emplea el algoritmo *t-Distributed Stochastic Neighbor Embedding* (t-SNE) [39] como herramienta de exploración cualitativa. Para garantizar reproducibilidad, la proyección bidimensional se genera fijando perplejidad 30, inicialización determinista basada en las dos primeras componentes principales (PCA) y semilla aleatoria 42 (`sklearn.manifold.TSNE`). Se utiliza con fines de soporte visual y no como criterio numérico de decisión.

3.4.7. Métricas de clasificación

El desempeño del clasificador MLP sobre cada condición experimental se evalúa a partir de las predicciones de probabilidad de malignidad $\hat{y} \in [0,1]$ generadas por la función sigmoide de salida. Para las métricas dependientes de umbral, se adopta el umbral de decisión operativo estándar de

0.5 ($\hat{y} \geq 0{,}5 \implies$ maligno):

Exactitud (*Accuracy*):

$$\text{Acc} = \frac{TP + TN}{TP + TN + FP + FN} \tag{55}$$

Precisión (*Precision*):

$$\text{Prec} = \frac{TP}{TP + FP} \tag{56}$$

Exhaustividad (*Recall*):

$$\text{Rec} = \frac{TP}{TP + FN} \tag{57}$$

F1-Score:

$$F_1 = \frac{2 \cdot \text{Prec} \cdot \text{Rec}}{\text{Prec} + \text{Rec}} \tag{58}$$

Área bajo la curva ROC (AUC-ROC):

$$\text{AUC} = \int_0^1 \text{TPR}(t)\, d\,\text{FPR}(t) \tag{59}$$

donde TP, TN, FP y FN son los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos respectivamente; $\text{TPR}(t) = TP/(TP + FN)$ es la tasa de verdaderos positivos y $\text{FPR}(t) = FP/(FP + TN)$ es la tasa de falsos positivos, ambas evaluadas al umbral de decisión t.

El **Área bajo la curva ROC (AUC-ROC)**, formalizada en la ecuación (59), constituye la métrica principal de comparación técnica entre condiciones. Al integrar la tasa de verdaderos positivos en función de la tasa de falsos positivos sobre la totalidad de los umbrales posibles $t \in [0, 1]$, el AUC-ROC cuantifica la capacidad discriminativa intrínseca del modelo con independencia del umbral operativo y de forma robusta frente al desbalance de clases del CBIS-DDSM.

El protocolo de validación evalúa todas las métricas mediante validación cruzada de 5 *folds* estratificada por clase y agrupada por paciente sobre el conjunto de entrenamiento, así como mediante una evaluación final sobre el conjunto de prueba oficial, que se usa una sola vez por modelo, reportando intervalos de confianza al 95 % derivados de 2 000 remuestreos *bootstrap* pareados por paciente.

3.4.8. Análisis de correlación separabilidad–clasificación

Para dar cumplimiento al objetivo específico OE-5, se evalúa si la jerarquía de separabilidad geométrica observada en el espacio de representación predice el desempeño predictivo alcanzado por el clasificador MLP. Para cuantificar la concordancia entre los ordenamientos de las cinco condiciones experimentales (C1 a C5), se calcula el coeficiente de correlación de rangos de Spearman ρ_s.

La fórmula $1 - 6\sum d_i^2/(n(n^2-1))$ solo vale sin empates. En el diseño metodológico del presente trabajo, las condiciones C1 y C2 arrojan idénticos valores de separabilidad por construcción matemática (invariancia rotacional de Davies-Bouldin, Fisher multivariante y KTA lineal). Al asignarse rangos promedio a las condiciones empatadas, las sumas de cuadrados de los rangos disminuyen respecto al caso de rangos discretos enteros, lo que invalida la fórmula de diferencias cuadráticas. La definición de ρ_s, adoptada en este trabajo, corresponde a la *correlación de Pearson evaluada sobre los rangos promedio*:

$$\rho_s = \frac{\sum_{i=1}^{n}(R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^{n}(R_i - \bar{R})^2 \sum_{i=1}^{n}(S_i - \bar{S})^2}}, \tag{60}$$

donde R_i representa el rango asignado a la condición i según la métrica de separabilidad, S_i denota el rango de la condición según el AUC-ROC de clasificación, y $\bar{R} = \bar{S} = \frac{n+1}{2} = 3$ es la media teórica de los rangos para $n = 5$ condiciones. A las condiciones C1 y C2 se les asigna el rango medio compartido correspondiente a las posiciones que ocupan conjuntamente.

Debido al tamaño reducido del conjunto de condiciones ($n = 5$), el espacio muestral de posibles permutaciones consta de exactamente $5! = 120$ órdenes posibles, todos equiprobables bajo la hipótesis nula de ordenamiento aleatorio. En este régimen de muestra pequeña, las aproximaciones asintóticas estándar (como la distribución t de Student) carecen de validez, y la distribución nula exacta es discreta:

- sin empates, solo $\rho_s = \pm 1$ llega a $p < 0{,}05$ bilateral, $p = 2/120 \approx 0{,}017$, y una sola inversión de vecinos da $\rho_s = 0{,}9$ con $p = 10/120 \approx 0{,}083$;
- con el empate C1 = C2, el máximo es $\rho_s = \sqrt{19/20} \approx 0{,}975$, alcanzado por 2 de los 120 órdenes, con p bilateral $= 4/120 \approx 0{,}033$.

Por esta razón, el coeficiente de Spearman entre separabilidad y clasificación se reporta con carácter descriptivo por subproblema (masas y calcificaciones), complementado con su distribución nula exacta tabulada, evaluando cualitativamente si las tres condiciones clásicas (C1, C2, C3) se

posicionan sistemáticamente por encima de las dos cuánticas (C4, C5) tanto en separabilidad como en desempeño clasificatorio.

3.5. Representaciones clásicas y modelos de kernel

Las secciones anteriores describen la parte cuántica del sistema. Esta reúne los métodos clásicos que la rodean: la extracción radiómica, que produce el vector de características de cada lesión; las dos transformaciones clásicas con las que se comparan las cuánticas, el análisis de componentes principales y su versión con kernel, y los modelos de kernel que se usan en los experimentos complementarios.

3.5.1. Características radiómicas

La radiómica es la extracción, a gran escala, de características cuantitativas de las imágenes médicas, que convierte las imágenes en datos analizables y permite usarlos como apoyo a la decisión [59]. En este trabajo, cada lesión se describe con 67 características calculadas con PyRadiomics [44] sobre la región de interés, agrupadas en cuatro familias: primer orden, forma, matriz de coocurrencia de niveles de gris (GLCM) y matriz de longitudes de secuencia (GLRLM). Su configuración se detalla en la sección 5.5.

Discretización de intensidades

Las familias de textura no trabajan con las intensidades originales, sino con niveles de gris discretos. Con el método de número fijo de niveles que define el manual de la *Image Biomarker Standardisation Initiative* (IBSI), la intensidad X_k de cada píxel de la región se lleva a uno de N_g niveles [64]:

$$X_{d,k} = \begin{cases} \left\lfloor N_g \dfrac{X_k - X_{\text{mín}}}{X_{\text{máx}} - X_{\text{mín}}} \right\rfloor + 1, & X_k < X_{\text{máx}}, \\ N_g, & X_k = X_{\text{máx}}, \end{cases} \tag{61}$$

donde $X_{\text{mín}}$ y $X_{\text{máx}}$ son la menor y la mayor intensidad dentro de la región. En este trabajo $N_g = 32$. Como el rango se toma de cada lesión, el método no depende de la escala absoluta de las intensidades, que en el CBIS-DDSM no está calibrada.

Primer orden y forma

Las características de primer orden son estadísticas de la distribución de intensidades dentro de la

región, sin información espacial: la media, los percentiles, la asimetría o la entropía,

$$H = -\sum_{i=1}^{N_g} p(i) \log_2 p(i), \tag{62}$$

donde $p(i)$ es la fracción de píxeles de la región con nivel de gris i. Las de forma describen la geometría del contorno de la máscara: área, perímetro, ejes mayor y menor, elongación. Como los DICOM del CBIS-DDSM no traen el espaciado de píxel, las medidas de forma quedan en píxeles.

Matriz de co-ocurrencia (GLCM)

La GLCM describe cómo se combinan los niveles de gris de píxeles vecinos a lo largo de una dirección de la imagen [64]. Para una distancia δ y una dirección θ, su elemento $P(i, j \mid \delta, \theta)$ cuenta cuántos pares de píxeles separados por δ en la dirección θ tienen los niveles i y j. Normalizada, $p(i, j) = P(i, j)/\sum_{i,j} P(i, j)$, es una distribución conjunta de la que se derivan las características; por ejemplo, el contraste,

$$\text{Contraste} = \sum_{i=1}^{N_g} \sum_{j=1}^{N_g} (i-j)^2 \, p(i, j), \tag{63}$$

que crece cuando los vecinos tienen niveles muy distintos. En este trabajo, $\delta = 1$ y las características se promedian sobre las cuatro direcciones del plano.

Matriz de longitudes de secuencia (GLRLM)

La GLRLM evalúa secuencias: una secuencia es un tramo de píxeles consecutivos con el mismo nivel de gris a lo largo de una dirección [64]. Su elemento $R(i, j \mid \theta)$ cuenta cuántas secuencias de nivel i y longitud j hay en la dirección θ. Con N_r el número total de secuencias, el énfasis en secuencias cortas,

$$\text{SRE} = \frac{1}{N_r} \sum_{i=1}^{N_g} \sum_{j} \frac{R(i, j)}{j^2}, \tag{64}$$

es alto en texturas finas, donde el nivel de gris cambia de un píxel al siguiente, y bajo en regiones homogéneas.

3.5.2. Análisis de componentes principales (PCA)

El análisis de componentes principales (PCA) busca las direcciones de máxima varianza de los datos [35]. Sea μ la media de los vectores de entrenamiento y $\tilde{X}$ la matriz de entrenamiento centrada,

con una lesión por fila. La matriz de covarianza se descompone como

$$\Sigma = \frac{1}{n-1}\tilde{X}^\top \tilde{X} = V \Lambda V^\top, \tag{65}$$

donde las columnas de V son los vectores propios ortonormales y Λ es la matriz diagonal de varianzas, en orden decreciente. La representación de una lesión $\mathbf{x}$ es su proyección sobre esas direcciones:

$$\mathbf{z} = V^\top (\mathbf{x} - \mu). \tag{66}$$

Cuando se conservan menos componentes que variables, PCA reduce la dimensión. En la condición C2 se conservan las $k = 12$, de modo que V es una matriz ortogonal de 12×12 y la transformación es una traslación seguida de una rotación. Una rotación conserva las distancias y los productos internos de los datos centrados:

$$\|\mathbf{z} - \mathbf{z}'\| = \|V^\top (\mathbf{x} - \mathbf{x}')\| = \|\mathbf{x} - \mathbf{x}'\|. \tag{67}$$

Por eso C2 es un control nulo: toda métrica de separabilidad que dependa solo de distancias o de productos internos centrados da el mismo valor en C1 y en C2. Si una métrica distinguiera ambas condiciones, la diferencia vendría de la implementación y no de la geometría. El clasificador, en cambio, no es invariante ante rotaciones, porque estandariza cada coordenada por separado, y puede dar resultados ligeramente distintos en C1 y C2.

3.5.3. Análisis de componentes principales con kernel (Kernel PCA)

El Kernel PCA aplica el análisis de componentes principales en el espacio de características de un kernel, sin calcular ese espacio de forma explícita [60]. Es la contraparte clásica no lineal de un *feature map*: como el kernel cuántico de fidelidad (ecuación (20)), un kernel $k(\mathbf{x}, \mathbf{x}')$ define implícitamente un mapa ϕ con $k(\mathbf{x}, \mathbf{x}') = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle$, y todo el cálculo se hace a través de k.

Con los n vectores de entrenamiento se forma la matriz $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ y se centra en el espacio de características:

$$\tilde{K} = K - \mathbf{1}_n K - K \mathbf{1}_n + \mathbf{1}_n K \mathbf{1}_n, \tag{68}$$

donde $\mathbf{1}_n$ es la matriz de $n \times n$ con todas sus entradas iguales a $1/n$. Si μ_ℓ y $\mathbf{a}^\ell$ son los valores y vectores propios unitarios de $\tilde{K}$, la componente ℓ de una lesión $\mathbf{x}$ es

$$z_\ell(\mathbf{x}) = \frac{1}{\sqrt{\mu_\ell}} \sum_{i=1}^{n} a_i^\ell \, \tilde{k}(\mathbf{x}_i, \mathbf{x}), \tag{69}$$

donde $\tilde{k}$ es el kernel centrado con las medias de entrenamiento. Sobre los puntos de entrenamiento, $z_\ell(\mathbf{x}_j) = \sqrt{\mu_\ell}\, a_j^\ell$.

En la condición C3 se usa el kernel gaussiano (RBF),

$$k(\mathbf{x},\mathbf{x}') = \exp\!\left(-\gamma\|\mathbf{x}-\mathbf{x}'\|^2\right), \qquad \gamma = \frac{1}{2\,\mathrm{med}_{i<j}\|\mathbf{x}_i-\mathbf{x}_j\|^2}, \tag{70}$$

con γ fijado por la heurística de la mediana sobre las distancias de entrenamiento, y se conservan 12 componentes, la misma dimensión que las demás condiciones. A diferencia de C2, C3 es no lineal: deforma la geometría de los datos, como lo hacen los mapas cuánticos, pero con un kernel clásico. Por eso es la comparación clásica más directa para C4 y C5. Los kernels gaussianos forman también parte de la batería de kernels clásicos de referencia con la que se calcula la *geometric difference* (sección 3.4).

3.5.4. Máquina de vectores de soporte (SVM)

La máquina de vectores de soporte (SVM) separa dos clases con el hiperplano de margen máximo, admitiendo errores con una penalización C [61]. En su forma dual, la función de decisión solo depende de los datos a través de un kernel:

$$f(\mathbf{x}) = \sum_{i=1}^{n} \alpha_i\, y_i\, k(\mathbf{x}_i,\mathbf{x}) + b, \qquad 0 \le \alpha_i \le C_{y_i}, \tag{71}$$

con $y_i \in \{-1,+1\}$. Los $\mathbf{x}_i$ con $\alpha_i > 0$ son los vectores de soporte. Como el modelo solo necesita la matriz de kernel, puede entrenarse con cualquier kernel semidefinido positivo, clásico o cuántico, sin cambiar el algoritmo. En los experimentos complementarios se usa con $C = 1$ y con C_y ponderado de forma inversa a la frecuencia de cada clase.

3.5.5. Máquina de vectores de soporte cuántica (QSVM)

Una QSVM es una SVM cuyo kernel se estima con un circuito cuántico [41]: en la ecuación (71) se usa el kernel de fidelidad $k(\mathbf{x},\mathbf{x}') = |\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$ de la ecuación (20). El computador cuántico solo calcula la matriz de kernel; el entrenamiento de la SVM es clásico. En un procesador real, cada entrada se estima midiendo el circuito $U^\dagger(\mathbf{x}')\,U(\mathbf{x})$ sobre $|0\rangle^{\otimes n}$ y contando la fracción de veces que el resultado es la cadena de ceros, por lo que su precisión depende del número de mediciones. En simulación de vector de estado se calcula de forma exacta.

En este trabajo, la QSVM se usa en un experimento complementario, con los mapas de C4 y C5 y

el mismo protocolo que una SVM con kernel RBF (sección 6.4). Su interés es metodológico: como el kernel de fidelidad usa solo el *feature map*, sin *ansatz* ni medición de $\langle Z_i \rangle$, permite separar lo que la codificación cuántica conserva de lo que se pierde al leer los valores esperados.

3.5.6. Kernel cuántico proyectado

El kernel de fidelidad compara estados en el espacio de Hilbert completo, de dimensión 2^n, donde, como se vio en la sección 2.1.6, las entradas tienden a quedar demasiado lejos entre sí. Huang et al. propusieron los kernels cuánticos proyectados, que primero proyectan cada estado a una representación clásica aproximada, por ejemplo mediante observables reducidos, y después comparan esas representaciones [42].

La forma más simple usa la matriz de densidad reducida de cada qubit [42]. Si $\rho(\mathbf{x}) = |\phi(\mathbf{x})\rangle\langle\phi(\mathbf{x})|$ es el estado codificado y $\rho_k(\mathbf{x}) = \mathrm{Tr}_{j\neq k}[\rho(\mathbf{x})]$ el del qubit k, que se obtiene trazando los demás, el kernel es

$$k^{\mathrm{PQ}}(\mathbf{x},\mathbf{x}') = \exp\left(-\gamma \sum_{k=1}^{n} \left\|\rho_k(\mathbf{x}) - \rho_k(\mathbf{x}')\right\|_F^2\right). \tag{72}$$

Esta expresión tiene una lectura directa en términos de mediciones. El estado de un qubit se escribe como $\rho_k = \frac{1}{2}\big(I + \sum_P \langle P_k\rangle P\big)$, con $P \in \{X,Y,Z\}$, y como $\mathrm{Tr}(PQ) = 2\,\delta_{PQ}$ para las matrices de Pauli,

$$\left\|\rho_k(\mathbf{x}) - \rho_k(\mathbf{x}')\right\|_F^2 = \frac{1}{2} \sum_{P\in\{X,Y,Z\}} \big(\langle P_k\rangle_{\mathbf{x}} - \langle P_k\rangle_{\mathbf{x}'}\big)^2. \tag{73}$$

El kernel proyectado es, por tanto, un kernel gaussiano con parámetro $\gamma/2$ sobre el vector de $3n$ valores esperados $\langle X_k\rangle$, $\langle Y_k\rangle$, $\langle Z_k\rangle$ de cada qubit. Se parece al *quantum embedding* de la sección 3.2.6, con dos diferencias: aquí se leen los tres ejes de cada qubit, y se leen directamente sobre el estado del *feature map*, sin *ansatz*. Su parámetro γ es un ancho de banda que se elige como en un kernel clásico.

En los experimentos numéricos de Huang et al., esta proyección aumentó, en lugar de reducir, la *geometric difference* con los modelos clásicos [42]. En este trabajo se evalúa en un experimento complementario, sobre los estados del ZZFeatureMap con el factor de escala del diseño (sección 6.4).

4. Análisis Exploratorio de Datos

El presente capítulo aborda la caracterización cuantitativa y técnica del conjunto de datos CBIS-DDSM (*Curated Breast Imaging Subset of DDSM*), procesando de manera unificada sus cuatro archivos de metadatos clínicos y enlazándolos con los 3 568 estudios mamográficos en formato DICOM disponibles en disco (recuperados íntegramente tras solventar la omisión de 84 series mediante la API REST de TCIA).

Lejos de constituir un ejercicio meramente descriptivo, este análisis exploratorio actúa como el puente empírico fundamental que justifica y condiciona de forma directa las decisiones de diseño del pipeline experimental desarrollado en el capítulo 5. En particular, la exploración busca dar respuesta a tres interrogantes estructurales:

1. **Estructura y balance de clases:** ¿Cuál es el grado de asimetría diagnóstica entre benignidad y malignidad en cada subconjunto, y qué esquemas de ponderación o métricas de evaluación exige dicha distribución?

2. **Relevancia de los metadatos clínicos frente a la imagen:** ¿Aportan las variables categóricas y ordinales registradas (densidad mamaria, sutileza, lateralidad o evaluación BI-RADS) señal predictiva utilizable, o debe extraerse la información discriminativa directamente del tejido tisular en la imagen?

3. **Factibilidad y restricciones de la representación cuántica:** ¿Qué características técnicas (resolución espacial, rango dinámico, profundidad de bits, alineación de máscaras de contorno y ausencia de espaciado físico de píxel) delimitan la viabilidad de codificar la información en estados cuánticos de pocos qubits?

El capítulo se estructura en cuatro bloques temáticos: saneamiento y validación del dataset, análisis de la variable patológica objetivo, evaluación de correlaciones en variables clínicas, e inspección técnica de las imágenes DICOM. Finalmente, se sintetizan las implicaciones directas que estos hallazgos imponen sobre cada módulo de la metodología. Todos los procedimientos y figuras analíticas descritos en este capítulo fueron ejecutados en el cuaderno `1_EDA.ipynb` del repositorio.

4.1. Validación y limpieza de los datos

La carga y unificación de los cuatro archivos CSV produjo un DataFrame consolidado de 3 568 registros, con las columnas `finding_type` (masa / calcificación) y `split` (train / test) agregadas

para facilitar el análisis por subconjunto. La Tabla 2 presenta el resumen de la composición del dataset.

Cuadro 2: Composición del dataset CBIS-DDSM unificado

Subconjunto	**Train**	**Test**
Masas (mass)	1 318	378
Calcificaciones (calc)	1 546	326
Total	**2 864**	**704**

La etiqueta objetivo `pathology` presentó tres valores distintos en los datos originales: `BENIGN` (1 548 casos), `MALIGNANT` (1 457 casos) y `BENIGN_WITHOUT_CALLBACK` (563 casos). Los casos `BENIGN_WITHOUT_CALLBACK` fueron normalizados a `BENIGN` por equivalencia clínica, resultando en la codificación binaria 0 = benigno (2 111 casos, 59.2 %) y 1 = maligno (1 457 casos, 40.8 %).

La validación de nulos confirmó que las columnas `mass_shape`, `mass_margins`, `calc_type` y `calc_distribution` presentan valores faltantes de naturaleza estructural: los registros de calcificaciones no tienen valores en las columnas de masas y viceversa, por diseño del dataset. No se identificaron errores de datos que requirieran corrección.

La verificación del enlace entre registros CSV y archivos DICOM en disco arrojó una cobertura del 100 % (3 568/3 568 registros con archivo DICOM encontrado), alcanzada tras recuperar las 84 series faltantes mediante la API REST de TCIA; la descarga inicial con el NBIA Data Retriever dejaba una cobertura del 97.6 %.

4.2. Análisis de la variable objetivo

4.2.1. Distribución de clases y balance

La distribución de la variable objetivo a nivel global, por tipo de hallazgo y por partición de entrenamiento y prueba (*train/test*) se ilustra en la Figura C.5.1 del Anexo C.5.

El dataset presenta un desbalance global moderado de 1.45:1 (benigno/maligno), que se distribuye de forma heterogénea entre los dos tipos de hallazgo. La Figura 4.2.1 ilustra esta asimetría mediante gráficas de pastel por subconjunto.

Las masas presentan un balance casi simétrico (ratio 1.16:1), con 912 casos benignos y 784 malignos. Las calcificaciones muestran un desbalance más pronunciado (ratio 1.78:1), con 1 199 ca-

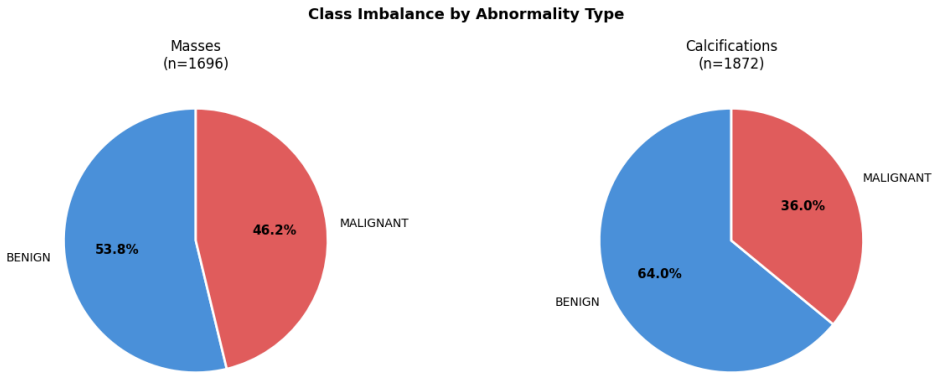


Figura 4.2.1: Desbalance de clases por tipo de hallazgo.

sos benignos frente a 673 malignos. Esta asimetría tiene una implicación metodológica directa: se requiere ponderación de clases (`class_weight=balanced`) durante el entrenamiento del MLP, aplicada de forma independiente para cada subconjunto, como se especifica en el requerimiento RF-19.

4.2.2. Distribución BI-RADS

La distribución detallada de la categoría BI-RADS por patología y tipo de hallazgo se presenta en la Figura C.5.2 del Anexo C.5.

Se observa una concentración de casos malignos en las categorías BI-RADS 4 y 5 (sospechoso y altamente sospechoso), mientras que los casos benignos se distribuyen predominantemente en las categorías 2 y 3. Esta distribución valida la coherencia clínica del dataset: la categoría BI-RADS refleja directamente el nivel de sospecha de malignidad asignado por el radiólogo.

4.2.3. Análisis de subtlety

La distribución de sutileza visual (*subtlety*) por patología y tipo de hallazgo se recoge en la Figura C.5.3 del Anexo C.5.

La media de *subtlety* en casos malignos (3.1 para masas, 2.8 para calcificaciones) es ligeramente inferior a la de casos benignos (3.4 y 3.2 respectivamente), aunque la diferencia es pequeña. Este hallazgo refuta la intuición de que las lesiones malignas son necesariamente más difíciles de detectar visualmente: la dificultad de detección es aproximadamente ortogonal a la patología, lo que explica parcialmente por qué los modelos de deep learning enfrentan dificultades de generalización al no poder apoyarse en la obviedad visual como señal discriminativa.

4.3. Análisis de variables clínicas

4.3.1. Densidad mamaria

La distribución de densidad mamaria clasificada por el radiólogo según patología y tipo de hallazgo se ilustra en la Figura C.5.4 del Anexo C.5.

La densidad mamaria más frecuente en el dataset es la categoría 2 (tejido disperso). El análisis de correlación confirmó que la densidad mamaria tiene una correlación casi nula con la etiqueta de patología ($r = -0{,}03$ para masas, $r = +0{,}09$ para calcificaciones), lo que indica que la densidad no predice la malignidad de la lesión. Sin embargo, se observó una correlación negativa moderada entre densidad y *subtlety* ($r = -0{,}31$ para masas), confirmando que las lesiones son más difíciles de detectar visualmente en tejidos más densos, donde el tejido glandular camufla las estructuras anómalas.

4.3.2. Lateralidad y vista mamográfica

La distribución de lateralidad anatómica y proyección mamográfica se presenta en la Figura C.5.5 del Anexo C.5.

La distribución de lateralidad es prácticamente simétrica (1 819 casos izquierdos vs. 1 749 derechos, ratio 1.04:1), lo que indica ausencia de sesgo de adquisición por lado. El ligero predominio de la vista MLO sobre la CC (1 896 vs. 1 672) es esperado clínicamente, dado que la vista MLO captura mayor volumen de tejido mamario incluyendo la región axilar.

4.3.3. Morfología de masas

La Figura 4.3.1 muestra la distribución de forma y margen de las masas por patología.

Los resultados revelan una separación morfológica marcada entre clases. Las masas malignas se asocian predominantemente con formas *IRREGULAR* y márgenes *SPICULATED*, patrón clínico clásico del carcinoma invasivo, donde el tumor crece desordenadamente con extensiones hacia el tejido circundante. Las masas benignas presentan formas *OVAL* con bordes *CIRCUMSCRIBED*, patrón típico de fibroadenomas o quistes encapsulados. Esta separación morfológica sugiere que las características extraídas de masas deberían ser intrínsecamente más separables en cualquier espacio de representación, incluyendo el espacio de Hilbert cuántico generado por los *feature maps*.

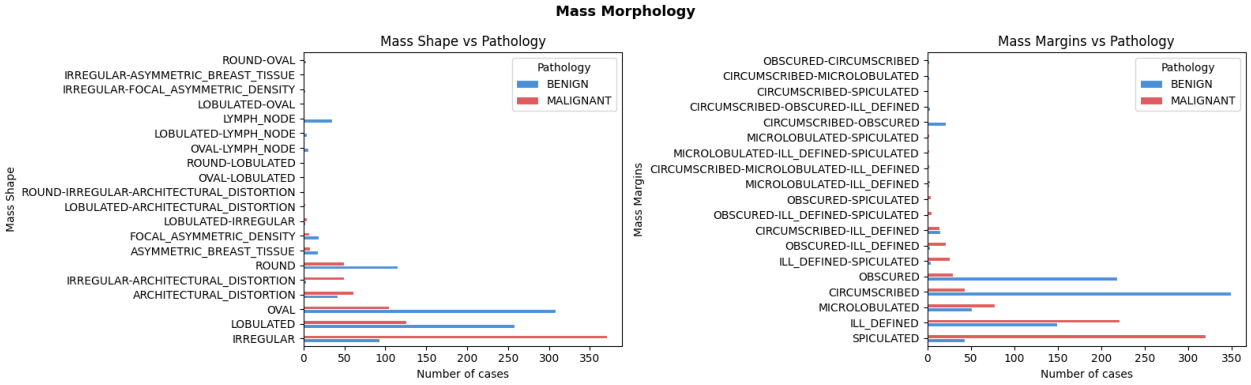


Figura 4.3.1: Distribución de forma y margen de masas por patología (benigno / maligno).

4.3.4. Morfología de calcificaciones

La Figura 4.3.2 presenta la distribución de tipo y distribución de las calcificaciones por patología.

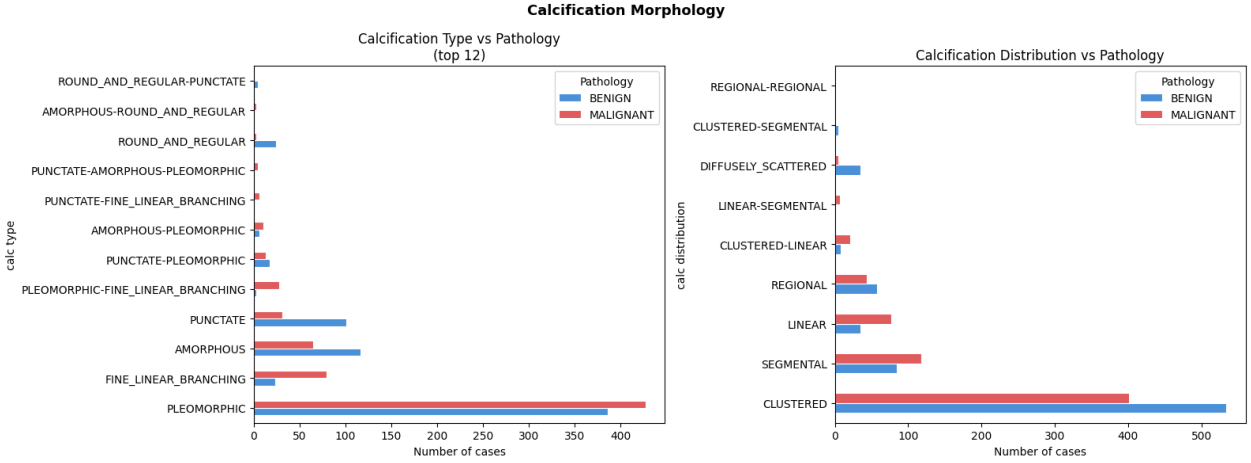


Figura 4.3.2: Distribución de tipo y distribución espacial de calcificaciones por patología.

A diferencia de las masas, las calcificaciones presentan el tipo morfológico más frecuente (*PLEOMORPHIC*) compartido entre ambas clases. Este solapamiento morfológico implica que las calcificaciones constituyen un problema de clasificación intrínsecamente más complejo, donde la separabilidad en el espacio de representación clásico es menor. Este escenario es particularmente relevante para el presente trabajo: es precisamente en estos casos de baja separabilidad clásica donde las transformaciones cuánticas variacionales tienen mayor potencial de aporte, al proyectar los datos en un espacio de Hilbert con geometría cualitativamente distinta que puede revelar estructura discriminativa no accesible para los métodos clásicos.

4.3.5. Correlaciones entre variables clínicas

La Figura 4.3.3 presenta la matriz de correlación de las variables clínicas numéricas del dataset.

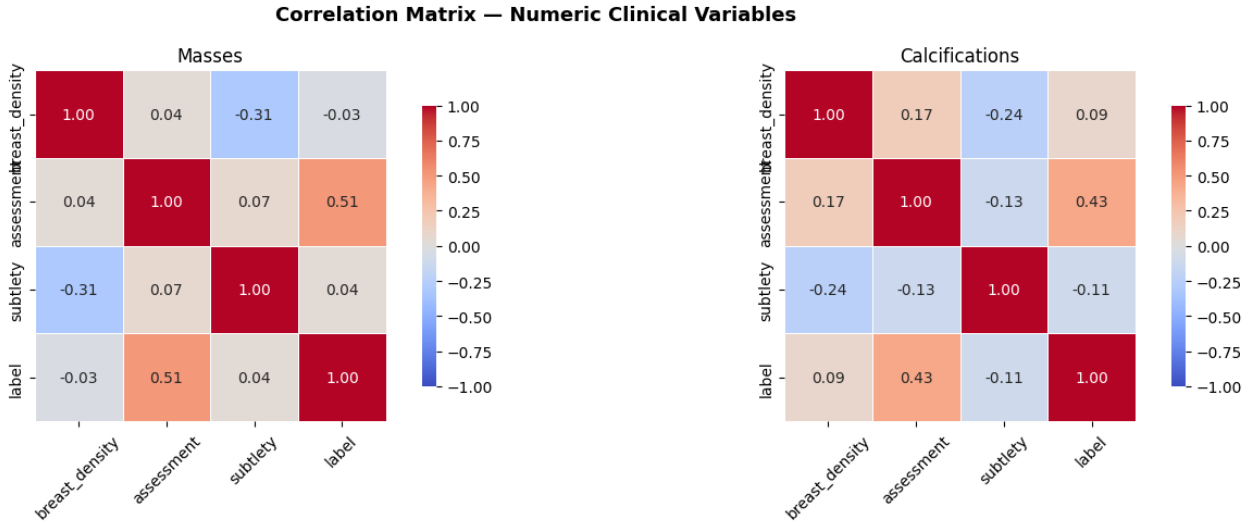


Figura 4.3.3: Matriz de correlación de variables clínicas numéricas por tipo de hallazgo.

La variable `assessment` (categoría BI-RADS) presenta la correlación más alta con la etiqueta de patología ($r = +0{,}51$ para masas, $r = +0{,}43$ para calcificaciones), lo cual es esperado dado que el BI-RADS fue diseñado precisamente como escala de sospecha de malignidad. Sin embargo, esta variable no puede utilizarse como *feature* de entrada al modelo porque constituye *data leakage*: es una etiqueta clínica derivada de la imagen, no una característica morfológica independiente.

Las variables `breast_density` y `subtlety` presentan correlaciones prácticamente nulas con la etiqueta de patología ($|r| < 0{,}12$ en todos los casos), confirmando que el poder predictivo reside en las características morfológicas de la imagen y no en los metadatos clínicos del CSV. Este resultado valida la decisión metodológica de extraer *features* directamente de las imágenes DICOM mediante PyRadiomics.

4.4. Análisis de imágenes DICOM

4.4.1. Dimensiones y características técnicas

La Figura 4.4.1 muestra la distribución de dimensiones de las mamografías completas en la muestra analizada.

Las mamografías completas presentan dimensiones medianas de $5\,037 \times 2\,960$ píxeles con profun-

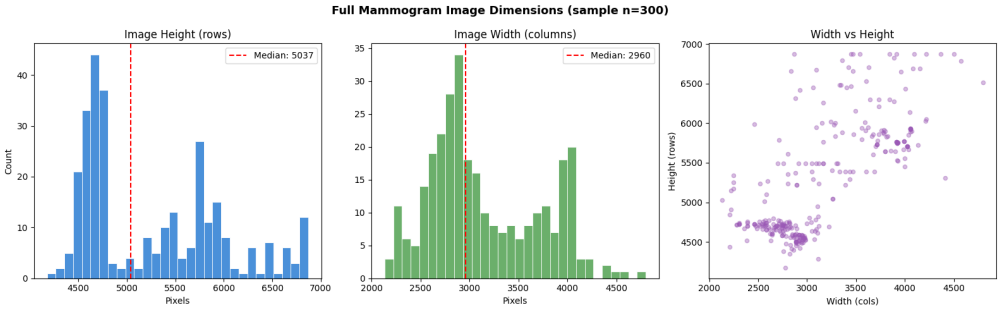


Figura 4.4.1: Distribución de dimensiones (altura y anchura en píxeles) de las mamografías completas (muestra n = 300).

didad de 16 bits, lo que confirma que su tamaño es incompatible con la entrada directa a un circuito cuántico. Este hallazgo valida la decisión de diseño de trabajar con recortes de la región de interés a resolución original, de los que se extraen características radiómicas (capítulo 5, sección 5.5) en lugar de las mamografías completas.

La inspección de los metadatos DICOM reveló que las imágenes del dataset son de tipo *Secondary Capture* (`SOPClassUID`: 1.2.840.10008.5.1.4.1.1.7), generadas mediante MATLAB (`SecondaryCapture DeviceManufacturer`: MathWorks) como parte del proceso de digitalización y curaduría del CBIS-DDSM. La convención fotométrica es `MONOCHROME2` de forma uniforme en todo el dataset, lo que elimina la necesidad de inversión de píxeles en el preprocesamiento.

4.4.2. Variabilidad inter-escáner

Ninguna de las 3 103 mamografías distintas incluye las etiquetas `Manufacturer`, `PixelSpacing` ni `ImagerPixelSpacing`; las tres faltan en los archivos DICOM (véase la Figura C.5.6 del Anexo C.5). Como consecuencia, no es posible un análisis de variabilidad entre escáneres a partir de metadatos, y las características de forma quedan en píxeles sin escala física; como el DDSM original se digitalizó con escáneres de distinta resolución, el mismo tamaño físico da distinto número de píxeles según el digitalizador, lo que se declara como limitación. Todas las imágenes corresponden a la modalidad MG, con profundidad de 16 bits y convención fotométrica `MONOCHROME2`.

4.4.3. Distribución de intensidades de píxeles

La comparación cuantitativa de las distribuciones estadísticas de intensidad de píxeles (media, desviación estándar y máximo) entre casos benignos y malignos en las imágenes de ROI se presenta en la Figura C.5.7 del Anexo C.5.

Las imágenes recortadas presentan valores de intensidad media en el rango de 45 000–50 000 sobre un máximo posible de 65 535 (16 bits), con máximos frecuentemente en el límite superior. Las distribuciones de casos benignos y malignos muestran solapamiento considerable en las tres estadísticas analizadas, confirmando que la información discriminativa no reside en estadísticas globales de intensidad sino en patrones texturales y morfológicos de orden superior, que son precisamente los que capturan las *features* radiómicas de PyRadiomics.

4.4.4. Galería de casos representativos

Una galería visual de casos representativos que ilustra la mamografía completa, la máscara binaria ROI y la imagen recortada de la lesión se exhibe en la Figura C.5.8 del Anexo C.5.

La galería ilustra visualmente las diferencias morfológicas descritas en el análisis de variables clínicas: las masas malignas muestran bordes irregulares y espiculados, mientras que las masas benignas presentan contornos lisos y bien definidos. En las calcificaciones, la distinción visual entre clases es menos evidente, consistente con el hallazgo de que PLEOMORPHIC es el tipo morfológico más frecuente en ambas clases.

La Figura 4.4.2 muestra la superposición de la máscara ROI sobre la mamografía completa para cuatro casos seleccionados.

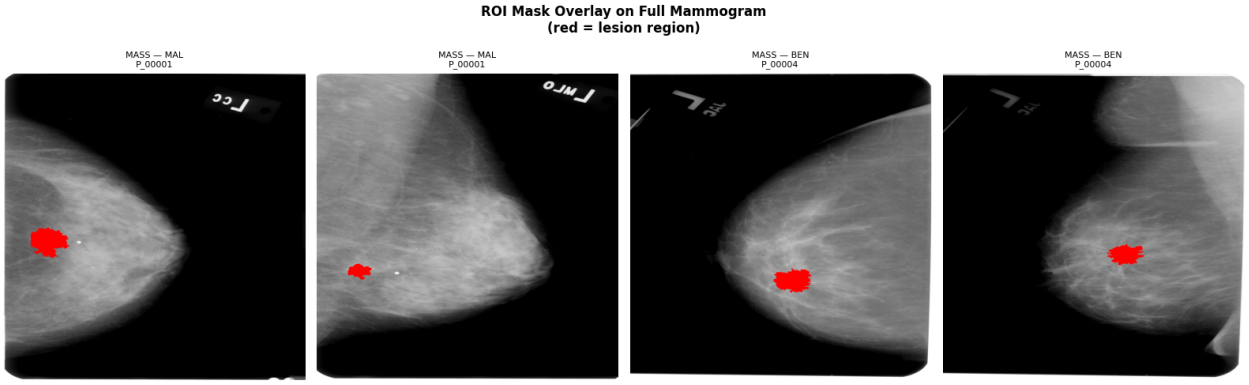


Figura 4.4.2: Superposición de la máscara ROI (región en rojo) sobre la mamografía completa para cuatro casos representativos.

La visualización confirma que las máscaras ROI delimitan con precisión la región de la lesión dentro de la mamografía completa, validando su uso como guía para el recorte en el preprocesamiento.

4.5. Implicaciones para el diseño

El análisis exploratorio de datos permite identificar un conjunto de hallazgos empíricos y restricciones técnicas que justifican de manera directa las decisiones de diseño metodológico del pipeline experimental. A continuación se detallan los hallazgos principales observados:

1. **Desbalance de clases diferenciado.** El ratio benigno/maligno presenta un desbalance moderado en masas y marcadamente superior en calcificaciones. La ponderación de clases durante el entrenamiento del MLP es necesaria para calcificaciones pero opcional para masas. Los modelos se evalúan con AUC-ROC como métrica principal por su robustez ante este desbalance.

2. **Asimetría de separabilidad esperada.** Las masas presentan patrones morfológicos claramente diferenciados entre clases (IRREGULAR/SPICULATED vs. OVAL/CIRCUMSCRIBED), prediciendo mayor separabilidad en el espacio de representación. Las calcificaciones comparten el tipo morfológico más frecuente (PLEOMORPHIC) entre ambas clases, prediciendo menor separabilidad y constituyendo el caso de prueba más exigente para los *quantum embeddings*.

3. **Variables clínicas no predictivas.** La densidad mamaria y el *subtlety* tienen correlación prácticamente nula con la patología. La información discriminativa reside en los patrones morfológicos de la imagen, validando el uso de PyRadiomics como extractor de características.

4. **Imágenes de alta dimensionalidad.** Las mamografías completas tienen dimensiones medianas de $5\,037 \times 2\,960$ píxeles, incompatibles con la entrada directa al circuito cuántico. El trabajo con recortes de la región de interés a resolución original, seguido de extracción de características radiómicas y selección de k características, es la estrategia viable para la simulación cuántica disponible.

5. **Convención fotométrica uniforme.** La totalidad del dataset utiliza `MONOCHROME2`, eliminando la necesidad de inversión de píxeles en el preprocesamiento.

En la Tabla 3 se sintetiza el puente entre cada hallazgo empírico del análisis exploratorio, la decisión de diseño adoptada y la subsección de la Metodología donde se materializa.

Cuadro 3: Correspondencia entre hallazgos del EDA y decisiones de diseño del pipeline

Hallazgo del EDA	**Decisión de diseño**	**Dónde se aplica**
Masas y calcificaciones con morfología y desbalance distintos	Tratamiento como subproblemas totalmente independientes a lo largo de todo el pipeline experimental.	Sec. 5.1 y M1–M8
Desbalance 1.16:1 en masas y 1.78:1 en calcificaciones	Ponderación de clases (`class_weight=balanced`) en la pérdida de entropía cruzada del MLP.	Sec. 5.9 (M7)
`breast_density` y `subtlety` sin correlación con patología	La señal reside en la imagen: extracción directa de features radiómicas (PyRadiomics), sin metadatos.	Sec. 5.5 (M3)
Mamografías completas de $\sim$5 037$\times$2 960 px	Recorte centrado en la ROI a resolución nativa y extracción radiómica; no se ingresa la imagen al circuito.	Sec. 5.4 y 5.5
`PixelSpacing` ausente en todos los DICOM	Cálculo de features de forma en píxeles sin escala física dimensional (declarado como limitación).	Sec. 5.5 (M3)
80 máscaras con dimensiones discrepantes	Alineación en M2 según tipo: remuestreo para 78 masas escaladas (factor 0.870) y anclaje para 2 casos.	Sec. 5.4 (M2)
Todas `MONOCHROME2`, 16 bits de profundidad	Sin inversión fotométrica; discretización de histograma mediante `binCount=32` en PyRadiomics.	Sec. 5.4 y 5.5
Estructura agrupada por paciente	Partición de validación cruzada con folds agrupados por paciente (`StratifiedGroupKFold`).	Sec. 5.6 (M4)

5. Metodología

La metodología adoptada en el presente trabajo es **CRISP-DM** (*Cross Industry Standard Process for Data Mining*), adaptada al contexto de cómputo cuántico. Esta metodología fue seleccionada por proporcionar un flujo estructurado que permite integrar de forma natural tanto las etapas clásicas de análisis de datos como las etapas cuánticas de codificación y transformación, manteniendo trazabilidad entre los objetivos de negocio y las decisiones técnicas de implementación.

La correspondencia entre las fases de CRISP-DM y los módulos del sistema se describe en la Tabla 6, y el diagrama completo del pipeline se presenta en la Figura 5.1.1.

5.1. Descripción general del proceso

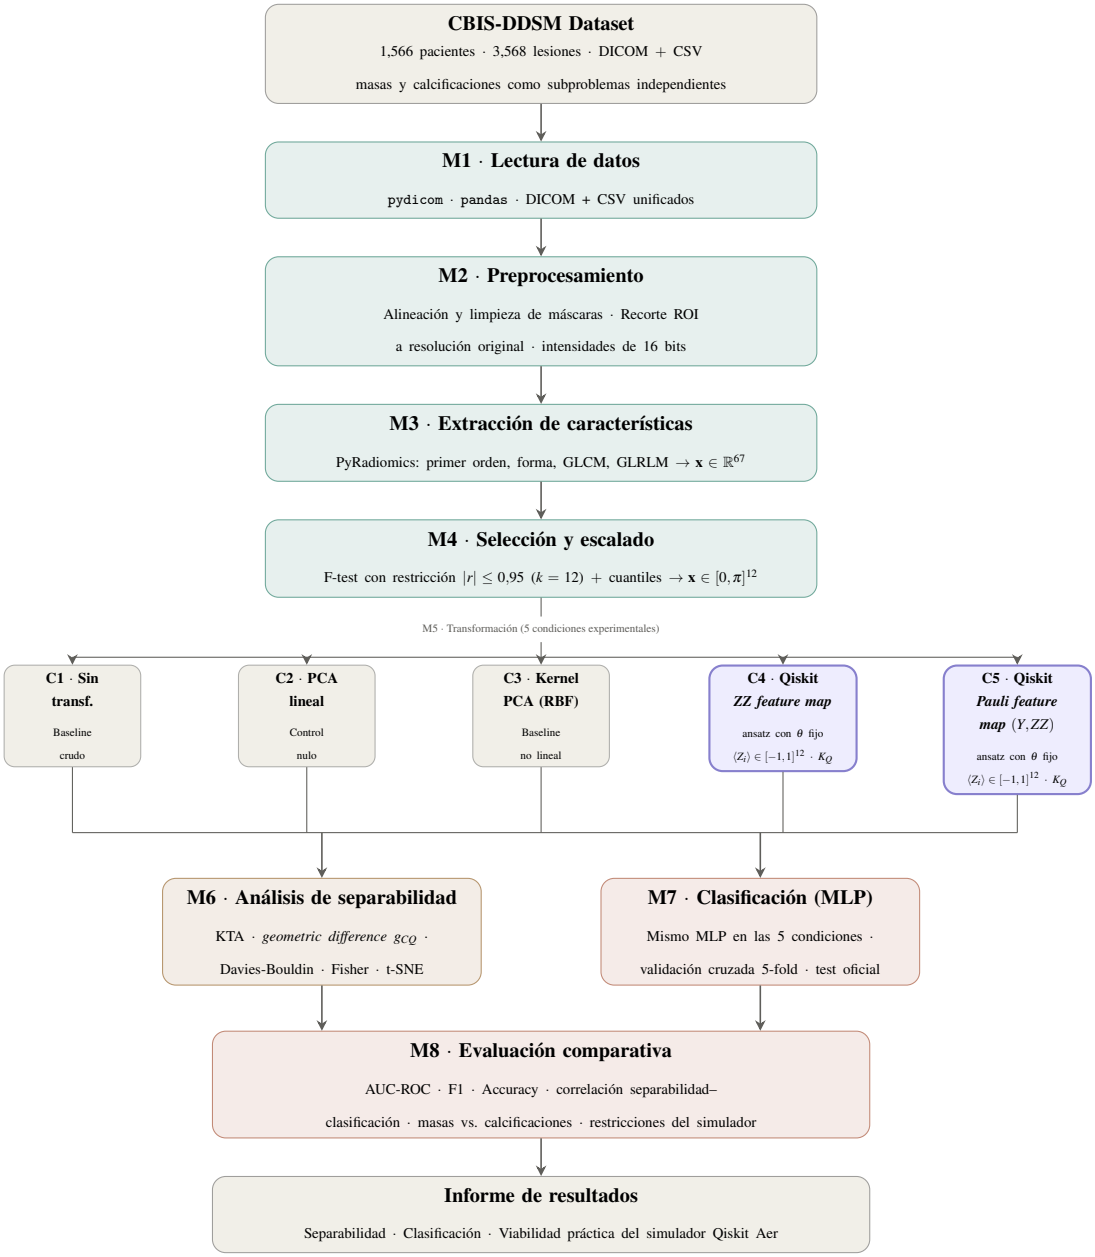


Figura 5.1.1: Pipeline del sistema híbrido cuántico-clásico para prediagnóstico de cáncer de mama. Masas y calcificaciones recorren el pipeline como subproblemas independientes. El módulo M4 selecciona 12 características por F-test con una restricción de redundancia y las transforma en ángulos en $[0,\pi]$ mediante una transformación por cuantiles, ajustada solo sobre el conjunto de entrenamiento; el mismo vector alimenta las cinco condiciones. En C4 y C5 los parámetros del *ansatz* se fijan con una semilla y no se entrenan, y el kernel de fidelidad K_Q se calcula con el *feature map* solo. C4 combina una codificación de primer orden en Z con el acoplamiento ZZ, y C5 una codificación de primer orden en Y con el mismo acoplamiento. La salida de M5 alimenta en paralelo el análisis de separabilidad (M6) y la clasificación (M7), que el módulo M8 compara.

El flujo es lineal hasta M4 y se ramifica a partir de M5. Las cinco condiciones de M5 reciben el mismo vector $\mathbf{x} \in [0, \pi]^{12}$, y sus salidas alimentan en paralelo dos módulos independientes: el análisis de separabilidad (M6), que mide la geometría de cada representación sin entrenar ningún clasificador, y la clasificación (M7), que entrena el mismo perceptrón multicapa sobre cada una. El módulo M8 compara ambos resultados. La separabilidad no alimenta a la clasificación: ambas consumen la salida de M5, y su relación es precisamente lo que M8 evalúa.

5.2. Requerimientos del sistema

El sistema desarrollado en el presente trabajo constituye un prototipo de investigación cuyo diseño responde a restricciones tanto técnicas como experimentales. Los requerimientos aquí presentados fueron definidos en concordancia con los objetivos específicos del proyecto y con las características del dataset CBIS-DDSM, y se organizan en requerimientos funcionales, que describen las capacidades que el sistema debe proveer, y requerimientos no funcionales, que establecen las condiciones de calidad, reproducibilidad y viabilidad bajo las cuales el sistema debe operar.

5.2.1. Requerimientos funcionales

Se presentan los requerimientos funcionales de mayor relevancia para justificar las decisiones de diseño del pipeline, organizados por las etapas que determinan la arquitectura del sistema. Cada requerimiento está identificado con un código RF-XX y vinculado al objetivo específico que lo origina.

Cuadro 4: Requerimientos funcionales del sistema

ID	Descripción	OE
Módulo 1 – Lectura de datos		
RF-01	Leer archivos DICOM del dataset CBIS-DDSM mediante `pydicom`, extrayendo el arreglo de píxeles en 16 bits y los metadatos clínicos.	OE-1
RF-02	Unificar los cuatro archivos CSV del dataset en un DataFrame consolidado con etiqueta binaria (BENIGN = 0 / MALIGNANT = 1).	OE-1

Continúa en la siguiente página

Tabla 4 – continuación

ID	Descripción	OE
RF-03	Tratar de forma independiente masas y calcificaciones como subproblemas de clasificación independientes.	OE-1, OE-3
Módulo 2 – Preprocesamiento		
RF-04	Alinear cada máscara ROI con su mamografía según el tipo de desajuste (remuestreo por vecino más cercano o anclaje sin escalar) y reducirla a su componente conexa mayor.	OE-1
RF-05	Generar una variante con CLAHE sobre la mamografía completa convertida a 8 bits, solo para cuantificar su efecto sobre las características; la ruta de extracción usa la imagen sin CLAHE.	OE-1
RF-06	Recortar la ROI con la caja de la máscara ampliada en 20 píxeles por lado, a resolución original y con las intensidades originales de 16 bits.	OE-1
Módulo 3 – Extracción de características		
RF-07	Extraer 67 características radiómicas con PyRadiomics (primer orden, forma 2D, GLCM y GLRLM) sobre la imagen original, con `binCount` = 32.	OE-1
Módulo 4 – Selección y escalado		
RF-08	Seleccionar $k = 12$ características por F-test ANOVA, aceptando una solo si su correlación absoluta con las ya elegidas es $\leq 0{,}95$, con el selector ajustado únicamente sobre el conjunto de entrenamiento.	OE-1, OE-2
RF-09	Transformar cada característica en un ángulo $\pi \hat{F}(r) \in [0, \pi]$, con $\hat{F}$ su distribución empírica, mediante una transformación por cuantiles ajustada sobre el conjunto de entrenamiento.	OE-1, OE-2
Módulo 5 – Transformación (5 condiciones)		
RF-10	*Baseline* crudo: vector seleccionado y escalado directo al MLP sin transformación adicional.	OE-2

Continúa en la siguiente página

Tabla 4 – continuación

ID	Descripción	OE
RF-11	*Baseline* lineal: PCA sobre el vector seleccionado y escalado, conservando k componentes. Actúa como control nulo: una PCA de k a k dimensiones es una rotación.	OE-2
RF-12	*Baseline* no lineal: Kernel PCA con kernel RBF sobre el vector seleccionado, con el ancho de banda γ fijado por la heurística de la mediana sobre el entrenamiento.	OE-2
RF-13	Condición C4: `zz_feature_map` de segundo orden seguido de `real_amplitudes` con parámetros θ fijos (semilla 42, sin entrenar), devolviendo los valores esperados exactos $\langle Z_i \rangle \in [-1,1]^k$.	OE-2
RF-14	Condición C5: `pauli_feature_map` con operadores (Y, ZZ), con el mismo *ansatz* y los mismos θ que C4.	OE-2
Módulo 6 – Análisis de separabilidad		
RF-15	Calcular el kernel cuántico de fidelidad, solo con el *feature map*, sobre 200 lesiones de entrenamiento por subconjunto (y, como robustez, sobre todo el entrenamiento), y su alineamiento centrado con las etiquetas, comparado contra una prueba de permutación.	OE-3
RF-16	Calcular la *geometric difference* regularizada entre el kernel cuántico y una batería de kernels clásicos, con el protocolo de Huang et al., junto con la dimensión efectiva: $g_{CQ} = \sqrt{\left\| \sqrt{K_Q}\sqrt{K_C}\,(K_C + \lambda I)^{-2}\sqrt{K_C}\sqrt{K_Q} \right\|_\infty}$.	OE-3
RF-17	Medir el índice de Davies-Bouldin, la razón de Fisher multivariante y el alineamiento del kernel lineal sobre la representación de cada condición, separado para masas y calcificaciones.	OE-3
Módulo 7 – Clasificación		
RF-18	Entrenar el mismo MLP ($k \to 32 \to 16 \to 1$) en las 5 condiciones, con idéntica arquitectura, hiperparámetros, protocolo y semilla.	OE-4

Continúa en la siguiente página

Tabla 4 – continuación

ID	Descripción	OE
RF-19	Entrenar con ponderación de clases, con pesos $w_c = N/(CN_c)$ (ecuación (37)) en la entropía cruzada binaria para compensar el desbalance observado.	OE-4
Módulo 8 – Evaluación comparativa		
RF-20	Reportar AUC-ROC, F1-Score, Accuracy, Precision y Recall por condición, separado para masas y calcificaciones.	OE-5
RF-21	Analizar la correlación entre ranking de separabilidad (OE-3) y ranking de clasificación (OE-5) de forma descriptiva, con la distribución exacta de ρ_s para $n = 5$.	OE-5
RF-22	Documentar restricciones del simulador: tiempo por muestra, qubits máximos, impacto de *shots* y costo del *parameter-shift*.	OE-6

5.2.2. Requerimientos no funcionales

Los requerimientos no funcionales establecen las condiciones bajo las cuales el sistema debe operar para garantizar la validez científica y reproducibilidad de los resultados.

Cuadro 5: Requerimientos no funcionales del sistema

ID	Categoría	Descripción
RNF-01	Reproducibilidad	Fijar semillas aleatorias en `numpy`, `PyTorch` y `Qiskit` al inicio de cada experimento (semilla 42). Las semillas de los *folds* (125 en masas y 168 en calcificaciones) se eligen por balance de clases.
RNF-02	Reproducibilidad	Declarar los parámetros de cada módulo en su *notebook* y guardar los parámetros ajustados junto a los datos procesados (`x_<tipo>.json` en M4, `emb_meta.json` en M5).

Continúa en la siguiente página

Tabla 5 – continuación

ID	Categoría	Descripción
RNF-03	Reproducibilidad	Usar la partición oficial train/test sin reordenarla, que los autores del CBIS-DDSM estratificaron por categoría BI-RADS [62], con la partición real de 2 864 / 704 lesiones (80.3 % / 19.7 %); el test se evalúa una sola vez por modelo y la validación cruzada usa 5 *folds* agrupados por paciente dentro del train.
RNF-04	Reproducibilidad	Ajustar el selector, el escalador por cuantiles y la estandarización del MLP solo con datos de entrenamiento para transformar el conjunto de prueba, previniendo *data leakage*.
RNF-05	Rendimiento	Calcular los valores esperados de forma exacta para el experimento, y cuantificar aparte el efecto de los *shots* muestreando n disparos de las probabilidades exactas (de 64 a 65 536, incluido 1 024).
RNF-06	Rendimiento	Calcular la matriz de kernel cuántico sobre una submuestra de 200 lesiones de entrenamiento por subconjunto, un tamaño que el protocolo *compute-uncompute* de un equipo cuántico admite ($N(N-1)/2$ circuitos por matriz), y repetir las métricas sobre todo el entrenamiento como análisis de robustez.
RNF-07	Escalabilidad	Circuito parametrizable en k, *feature map* y `reps`. Punto de operación $k = 12$ y `reps` = 1, con $k = 8$ y `reps` = 2 como análisis de sensibilidad.
RNF-08	Mantenibilidad	Código organizado en ocho módulos M1–M8, un *notebook* por módulo.
RNF-09	Propiedad intelectual	Registro del trabajo en INDAUTOR.

Cuadro 6: Correspondencia entre fases CRISP-DM y módulos del sistema

Fase CRISP-DM	**Módulo**	**Actividad principal**
1. Comprensión del negocio	—	Definición del problema de prediagnóstico, formulación de la pregunta de investigación y criterios de separabilidad.
2. Comprensión de los datos	M1	Lectura DICOM, análisis exploratorio del dataset CBIS-DDSM (EDA).
3. Preparación de los datos	M2, M3, M4	Preprocesamiento de imagen, extracción de features y selección/escalado.
4. Modelado	M5, M7	Implementación de las 5 condiciones de transformación y entrenamiento del MLP.
5. Evaluación	M6, M8	Análisis de separabilidad, métricas de clasificación, comparación clásico frente a cuántico y restricciones del simulador.
6. Despliegue	—	Documentación de hallazgos, reporte técnico y registro INDAUTOR.

5.3. Módulo 1: Lectura de datos

El primer módulo gestiona la adquisición y unificación de los datos del dataset CBIS-DDSM, disponible públicamente en The Cancer Imaging Archive (TCIA). El dataset comprende 1,566 pacientes con imágenes mamográficas digitalizadas en formato DICOM y cuatro archivos CSV con metadatos clínicos y anotaciones patológicas validadas.

La lectura de los archivos DICOM se realiza mediante la librería `pydicom`, extrayendo el arreglo de píxeles en formato de 16 bits y los metadatos clínicos relevantes: `PatientID`, `Modality`, `Rows`, `Columns`, `BitsStored` y `PhotometricInterpretation`. El análisis exploratorio confirmó que la totalidad de las imágenes del dataset utilizan la convención fotométrica `MONOCHROME2`, donde los valores altos corresponden al blanco (tejido denso) y los valores bajos al negro (fondo), lo que elimina la necesidad de inversión de píxeles en el preprocesamiento.

Ninguna de las 3 103 mamografías incluye las etiquetas `PixelSpacing`, `ImagerPixelSpacing` ni `Manufacturer`. Sin un espaciado físico, las características de forma se expresan en píxeles, y no

es posible distinguir el digitalizador de origen.

Los cuatro archivos CSV del dataset se unifican en un DataFrame mediante `pandas`:

- `mass_case_description_train_set`,
- `mass_case_description_test_set`,
- `calc_case_description_train_set`,
- `calc_case_description_test_set`.

Al unificarlos se agregan las columnas `finding_type` (masa / calcificación) y `split` (train / test). La etiqueta objetivo `pathology` se normaliza a una variable binaria con la codificación 0 = benigno y 1 = maligno; los casos `BENIGN_WITHOUT_CALLBACK` se tratan como `BENIGN`.

El enlace entre los registros CSV y los archivos DICOM en disco se resuelve mediante un índice construido recursivamente sobre la estructura de carpetas del NBIA Data Retriever, identificando para cada caso el archivo de mamografía completa, la máscara ROI binaria y la imagen recortada. La clasificación entre máscara y recorte se realiza leyendo el contenido de píxeles: las máscaras presentan exactamente dos valores únicos (0 y 255) mientras que las imágenes recortadas presentan cientos de valores distintos.

La descarga inicial resultó incompleta, lo que dejaba la cobertura en el 97.6 %. Las 84 series faltantes se recuperaron mediante la API REST de TCIA, solicitando cada serie por su identificador, después de que el NBIA Data Retriever rechazara un manifiesto reconstruido. Con ello la cobertura alcanza los 3 568 registros. Estos corresponden a 3 103 mamografías distintas, porque varias lesiones comparten la misma imagen.

La salida de este módulo es un DataFrame unificado con 3 568 registros, con rutas resueltas a los archivos DICOM correspondientes y etiquetas binarias validadas, que sirve como base para todos los módulos posteriores.

5.4. Módulo 2: Preprocesamiento de imagen

El módulo de preprocesamiento transforma las imágenes DICOM en pares (imagen, máscara) alineados y centrados en la región de interés, que son la entrada del módulo de extracción.

La primera etapa resuelve la correspondencia geométrica entre imagen y máscara. En 80 de los 3 568 registros las dimensiones de la máscara no coinciden con las de la mamografía, y el desajuste

es de dos tipos. En 78 masas la máscara reproduce la imagen a una escala de 0.870 en ambos ejes, y se remuestrea al tamaño de la imagen por vecino más cercano, que conserva su carácter binario. En 2 calcificaciones la diferencia es de pocas decenas de píxeles y no es proporcional, de modo que la máscara se ancla sin escalar. Ambas reglas se verificaron de forma independiente: cuando imagen y máscara están alineadas, los recortes que acompañan al CBIS-DDSM coinciden con la caja de la máscara ampliada en 20 píxeles por lado, relación que se cumple en el 99.8 % de los casos verificables; para las máscaras escaladas se empleó una prueba de contraste entre la lesión y su entorno. En 7 masas el recorte oficial y la máscara describen extensiones distintas de la lesión; se conservan y se declaran, porque excluirlas del conjunto de prueba cambia el AUC en menos de 0.004.

A continuación, cada máscara se reduce a su componente conexa mayor, con conectividad 8. El 86.3 % de las máscaras de masas contiene islas de pocos píxeles, residuos de la rasterización del contorno, que alterarían el perímetro y el diámetro máximo de la región. La componente mayor conserva en todos los casos al menos el 99.55 % del área.

La segunda etapa recorta la región de interés: se extrae la caja mínima de la máscara ampliada en 20 píxeles por lado, **conservando la resolución y las intensidades originales de 16 bits**. Los recortes del CBIS-DDSM no se emplean para la extracción, porque su intensidad está reescalada con una ganancia distinta en cada caso, de 1.00 a 5.31.

La decisión de no redimensionar el recorte es deliberada. Las cajas de las lesiones miden de 116×55 a $1\,329 \times 1\,365$ píxeles en masas y de 33×33 a $3\,777 \times 2\,753$ en calcificaciones, y las medidas de tamaño figuran entre las características más discriminativas: en masas, cinco de las doce con mayor tamaño de efecto en el conjunto de entrenamiento son de forma y tamaño ($|d|$ de Cohen entre 0.40 y 0.45). Redimensionar a una malla común igualaría la escala de las lesiones y eliminaría esa señal. La normalización a 224×224 correspondía a la estrategia basada en un codificador convolucional, descartada en favor de la extracción radiómica.

Por la misma razón, la ecualización adaptativa de histograma (CLAHE) [43] se excluye de la ruta de extracción: es una transformación local que depende del contenido de cada región y cambia las intensidades de las que se calculan las características de primer orden y de textura. IBSI advierte que las decisiones sobre las intensidades, como la discretización, tienen un impacto sustancial en los valores de las características y en su reproducibilidad, y solo contempla la ecualización global del histograma de la ROI como variante de la discretización [64]; la ecualización local adaptativa no figura entre los pasos que estandariza. Se genera además una variante con CLAHE, aplicada a la mamografía completa convertida a 8 bits, solo para cuantificar su efecto sobre las características extraídas.

Las imágenes de masas y calcificaciones se procesan por separado a lo largo de todo el pipeline, dado que sus características morfológicas relevantes son cualitativamente distintas: las masas requieren capturar geometría global y márgenes, mientras que las calcificaciones requieren capturar patrones texturales finos y distribución espacial de los depósitos de calcio.

5.5. Módulo 3: Extracción de características

El módulo de extracción transforma cada par (imagen, máscara) producido por M2 en un vector numérico $\mathbf{x} \in \mathbb{R}^{67}$ que describe la morfología de la lesión. Se emplea PyRadiomics [44] sobre la imagen original, sin filtros, con cuatro familias de características:

- *Primer orden* (18): estadísticas de la distribución de intensidades dentro de la lesión, como la media, los percentiles, la energía, la asimetría y la curtosis.
- *Forma 2D* (9): descriptores geométricos del contorno, como el perímetro, los ejes mayor y menor, el diámetro máximo, la elongación y la esfericidad.
- *GLCM* (24): textura a partir de la co-ocurrencia de pares de niveles de gris.
- *GLRLM* (16): textura a partir de la longitud de las secuencias de píxeles con el mismo nivel de gris.

Las intensidades se discretizan en un número fijo de 32 niveles (`binCount`), no en un ancho fijo. IBSI recomienda el número fijo cuando las unidades de intensidad son arbitrarias, como en la película digitalizada del CBIS-DDSM, y desaconseja el ancho fijo cuando no puede definirse un rango absoluto [64]. El manual no fija el número de niveles; 32 está entre los que menciona como ejemplo para la GLCM, y no se optimizó sobre los datos para no ajustar el preprocesamiento a las etiquetas. Con un ancho fijo, los datos de 16 bits generaban más de mil niveles. Las matrices de textura usan distancia 1 y promedian las cuatro direcciones del plano. Como las mamografías no traen espaciado de píxel, las características de forma se expresan en píxeles.

La extracción se aplica a las 3 568 lesiones y a la variante con CLAHE de M2, sin fallos ni valores faltantes. Masas y calcificaciones se extraen y se guardan por separado.

Como alternativa se contempló un codificador convolucional preentrenado (ResNet-18 o EfficientNet-B0). Se eligió PyRadiomics porque cada característica tiene un significado morfológico definido, lo que permite interpretar qué propiedades de la lesión conserva o pierde cada transformación.

5.6. Módulo 4: Selección y escalado

El módulo de selección y escalado prepara el vector de características para el circuito cuántico. Debe reducir la dimensión al número de qubits, $k = 12$, y convertir cada característica en un ángulo de rotación. Todos sus parámetros se ajustan solo con el conjunto de entrenamiento.

Número de qubits. El valor $k = 12$ se fijó antes de los experimentos, con un estudio de costos del simulador. Con la implementación de entonces, que evaluaba cada valor del kernel de fidelidad con un circuito propio, la etapa cuántica completa costaba 0.29 h con 8 qubits, 2.95 h con 12 y 41.25 h con 16: de 12 a 16 el costo se multiplicaba por 14, y el diseño requiere decenas de kernels, uno por mapa, subconjunto y factor de escala. Doce qubits eran el último escalón asumible. Hay además una razón de contenido: con menos qubits, la selección se concentra en una sola familia de características muy correlacionadas entre sí (con $k = 8$, la de masas pierde todas las de textura), mientras que con 12 caben familias distintas, cuyos productos codifica el acoplamiento ZZ. Más adelante, el cálculo del kernel a partir de los vectores de estado redujo ese costo en unas mil veces, y el límite físico de la máquina resultó mayor (sección 6). Aun así, el kernel por *compute-uncompute*, la única vía disponible en un procesador real, costaría unas 9 h para los 24 kernels del diseño con 16 qubits y más de cuatro días con 20. Aumentar k tampoco prometía una mejor separabilidad, porque la concentración de los *embeddings* crece con el número de qubits; la comparación con $k = 8$ se presenta en la sección 5.11.

Selección. Las características se ordenan por el estadístico F del ANOVA entre clases y se recorren en ese orden: una característica se acepta solo si su correlación absoluta de Pearson con todas las ya aceptadas es como máximo 0.95, hasta reunir doce. La restricción elimina duplicados exactos que PyRadiomics produce en 2D, como `Energy` y `TotalEnergy`, y variables casi idénticas, que harían que varios qubits codificaran el mismo valor. Sin ella, la selección en masas no incluía ninguna característica de textura. Con ella, las doce características de masas combinan intensidad, forma y textura (4, 5 y 3), y las de calcificaciones también (2, 3 y 7).

Escalado angular. Cada característica seleccionada, con valor radiómico r_i, se transforma mediante su función de distribución empírica en entrenamiento, $\hat{F}_i$:

$$x_i = \pi \hat{F}_i(r_i) \in [0, \pi]. \tag{74}$$

Es la transformación integral de probabilidad: cada ángulo se distribuye de manera uniforme en $[0, \pi]$, por sesgada que sea la característica. Conserva el orden de las lesiones y descarta las distancias dentro de cada característica. Con un escalado min-max, las características de cola pesada, como la energía o la superficie, quedaban casi constantes: en calcificaciones, la energía de la mitad

de las lesiones caía a menos de 0.05 rad de cero, y su qubit recibía casi la misma rotación para todas. El rango $[0, \pi]$ se debe a que el *feature map* aplica una fase $2x_i$: con $x_i \in [0, \pi]$, esa fase recorre la circunferencia una sola vez, sin que dos valores distintos de la característica produzcan la misma rotación.

Partición para la validación cruzada. El conjunto de entrenamiento se divide en cinco *folds* estratificados por clase y agrupados por paciente, de modo que todas las lesiones de un paciente quedan en el mismo *fold*. La semilla de la partición se elige entre 200 candidatas con un criterio que solo mira las etiquetas: la menor desviación de la proporción de malignas entre *folds*. Los *folds* se fijan aquí y los usan todos los módulos posteriores.

El vector $\mathbf{x} \in [0, \pi]^{12}$ resultante es el mismo para las cinco condiciones de M5, de forma que lo único que cambia entre ellas es la transformación.

5.7. Módulo 5: Transformación

El módulo de transformación implementa las cinco condiciones experimentales del estudio. Todas parten del mismo vector $\mathbf{x} \in [0, \pi]^{12}$ producido por M4 y su salida alimenta en paralelo dos módulos independientes: el análisis de separabilidad (M6) y la clasificación (M7). La Tabla 7 resume las cinco condiciones.

Cuadro 7: Cinco condiciones experimentales del Módulo 5

ID	Nombre	Transformación	Tipo
C1	Sin transformación	El vector $\mathbf{x}$ pasa directamente al clasificador.	Clásico
C2	PCA lineal	Proyección sobre las 12 componentes principales. Es una rotación, así que actúa como control nulo.	Clásico
C3	Kernel PCA (RBF)	Proyección no lineal a 12 dimensiones con kernel gaussiano; γ por la heurística de la mediana.	Clásico
C4	`zz_feature_map`	Primer orden en Z y acoplamiento ZZ, seguidos de `real_amplitudes` con θ fijo. Salida: $\langle Z_i \rangle \in [-1, 1]^{12}$.	Cuántico
C5	`pauli_feature_map`(Y, ZZ)	Primer orden en Y y el mismo acoplamiento ZZ, con el mismo *ansatz* y θ. Salida: $\langle Z_i \rangle \in [-1, 1]^{12}$.	Cuántico

Sobre la condición C2. Dado que M4 entrega un vector ya de dimensión $k = 12$, una proyección PCA a 12 componentes no constituye una reducción de dimensionalidad sino una rotación ortogonal, que preserva las distancias euclidianas. En consecuencia, los índices de Davies-Bouldin y Fisher y el *kernel-target alignment* son invariantes ante ella, y el perceptrón absorbe la rotación en su primera capa lineal. C2 se conserva deliberadamente como **control nulo**: si las métricas de separabilidad arrojaran valores distintos para C1 y C2, ello indicaría un defecto en su implementación. El comparador clásico sustantivo es C3.

Por qué mapas con entrelazamiento. Las dos condiciones cuánticas usan mapas de una misma familia, con acoplamiento ZZ entre todos los pares de qubits: 66 pares con $k = 12$. Se descartaron las codificaciones sin entrelazamiento porque su kernel es, por construcción, un kernel clásico. En la codificación angular, cada característica gira su propio qubit y el estado es un producto, $|\phi(\mathbf{x})\rangle = \bigotimes_{i=1}^{k} R_Y(x_i)|0\rangle$. Su fidelidad se factoriza en

$$K(\mathbf{x},\mathbf{x}') = \prod_{i=1}^{k} \cos^2\left(\frac{x_i - x_i'}{2}\right), \tag{75}$$

que se calcula con k operaciones clásicas y que, para diferencias pequeñas, se aproxima a un kernel gaussiano. En la codificación en amplitudes, el kernel es el cuadrado de la similitud coseno entre los vectores, un kernel polinomial clásico. Ambas equivalencias se comprobaron numéricamente en los experimentos complementarios (sección 5.11). Ninguna de las dos codificaciones podría, por tanto, mostrar una separabilidad que no ofrezcan ya los métodos clásicos.

El entrelazamiento cambia esto. El acoplamiento ZZ añade a cada par de qubits una fase que depende del producto $(\pi - x_i)(\pi - x_j)$, y el estado deja de ser un producto de estados de un qubit: la fidelidad ya no se descompone en contribuciones independientes por característica, y el kernel incorpora interacciones entre pares de características que la ecuación (75) no puede expresar. Esa es la condición mínima para que la pregunta de investigación no tenga respuesta de antemano, no una garantía de mejora: el entrelazamiento figura también entre las fuentes de concentración de los kernels cuánticos que identifican Thanasilp et al. [48], y la concentración observada en C4 y C5 se cuantifica en el capítulo 6. Otras familias con entrelazamiento quedaron fuera por el propio diseño. Los circuitos que repiten la codificación intercalada con capas entrenables, cuya expresividad estudian Schuld et al. [49], requieren entrenar parámetros, y aquí θ se mantiene fijo. Los kernels covariantes de Glick et al. [51] están pensados para datos con estructura de grupo, que las características radiómicas no tienen.

Sobre la elección de C5. La biblioteca Qiskit define `ZZFeatureMap` como un caso particular de `PauliFeatureMap` con operadores (Z, ZZ); ambas construcciones preparan el mismo estado, con

fidelidad $|\langle\phi_{ZZ}|\phi_{\text{Pauli}}\rangle|^2 = 1$. Especificadas así, C4 y C5 no constituirían condiciones independientes. Se consideró primero el conjunto (X, ZZ), pero con una repetición el término en X actúa sobre el estado $|+\rangle$ que deja la capa de Hadamard, que es autoestado de X, y solo añade una fase global: C5 equivaldría a un *feature map* con únicamente el acoplamiento ZZ. Se adopta por tanto el conjunto (Y, ZZ). Sobre la esfera de Bloch, el giro en Z de C4 desplaza cada qubit a lo largo del ecuador y solo cambia una fase relativa, mientras que el giro en Y de C5 lo saca del ecuador y cambia las probabilidades de medir 0 y 1. Ambas condiciones comparten el acoplamiento ZZ y el número de compuertas de entrelazamiento, de modo que la comparación entre C4 y C5 mide el efecto del eje de la codificación de primer orden.

Los parámetros θ del *ansatz* `real_amplitudes`, 24 en total con una repetición, se fijan una sola vez con una semilla declarada (42), muestreados de manera uniforme en $[0, 2\pi)$, y no se entrenan. Los valores esperados $\langle Z_i\rangle$ se calculan de forma exacta a partir del vector de estado, una sola vez para todo el conjunto, y se guardan en disco. El *ansatz* no puede suprimirse. En C4, el *feature map* aplica compuertas de Hadamard seguidas de compuertas diagonales, que cambian las fases de las amplitudes pero no sus magnitudes. Partiendo de $H^{\otimes k}|0\rangle$, toda amplitud conserva la magnitud $2^{-k/2}$, de modo que $P(q_i = 0) = 1/2$ y $\langle Z_i\rangle = 0$ para cualquier entrada. La información codificada reside en las fases, a las que una medición en la base Z es insensible, y el *ansatz* es lo que las convierte en probabilidades medibles. En C5 el giro en Y sí cambia las probabilidades, pero sin el *ansatz* $\langle Z_i\rangle = -\sin(2x_i)$ dependería de una sola característica y las fases del acoplamiento ZZ seguirían sin verse.

Además de los *embeddings*, para C4 y C5 se calcula, con el *feature map* solo, el kernel de fidelidad $K_Q(\mathbf{x}, \mathbf{x}') = |\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$. El *ansatz* no interviene, porque un mismo unitario aplicado a ambos estados no cambia su producto interno. Este kernel es la entrada del análisis de separabilidad (M6).

Ambos circuitos tienen 12 qubits y una repetición del *feature map*, y comparten las mismas compuertas de entrelazamiento. C5 solo añade las compuertas que realizan el giro en Y.

5.8. Módulo 6: Análisis de separabilidad

El análisis de separabilidad opera sobre dos objetos distintos, y conviene distinguirlos al interpretar los resultados. Todas las métricas se calculan sobre la misma submuestra: 200 lesiones del conjunto de entrenamiento por subconjunto, estratificadas por clase y elegidas con la semilla 42; el conjunto de prueba no interviene. El tamaño se fijó antes de ver los datos por el coste del protocolo físico: en un equipo cuántico, cada entrada del kernel es un circuito *compute-uncompute* distinto, de modo que una matriz de 200 lesiones requiere 19 900 circuitos, frente a cerca de 0.87 y 1.19 millones con

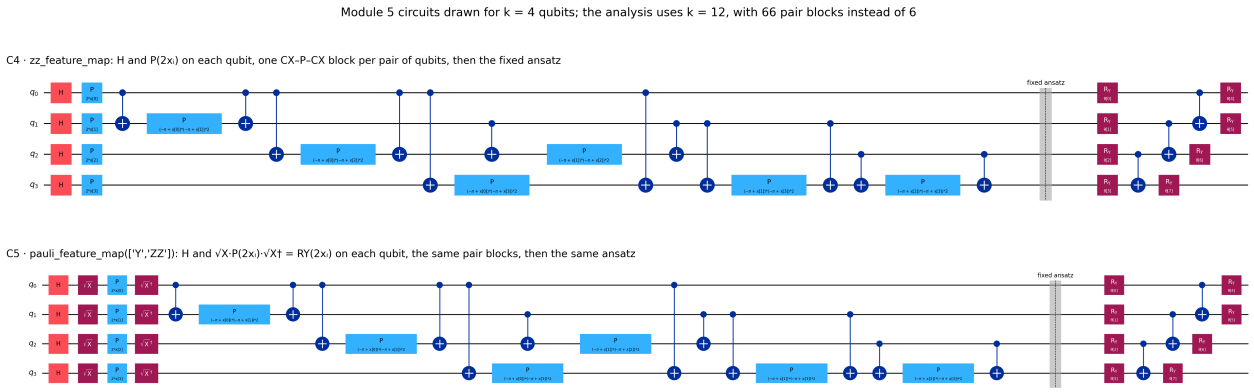


Figura 5.7.1: Circuitos de C4 y C5 dibujados para $k = 4$; el análisis usa $k = 12$, con 66 bloques de pares en lugar de 6; la barrera separa el *feature map* del *ansatz* fijo.

todas las masas y todas las calcificaciones de entrenamiento. En simulación, el cálculo a partir de los vectores de estado hace viable el conjunto completo; por ello, el experimento X9 (sección 5.11) repite las métricas sobre otras 19 submuestras y sobre todo el entrenamiento como análisis de robustez. Los kernels cuánticos se evalúan de forma exacta a partir de los vectores de estado, y la significancia de cada métrica que usa las etiquetas se estima con 1 000 permutaciones de las etiquetas que conservan el número de lesiones de cada clase.

Métricas sobre kernels. El kernel cuántico de fidelidad $K_Q(\mathbf{x},\mathbf{x}') = |\langle\phi(\mathbf{x})|\phi(\mathbf{x}')\rangle|^2$ se evalúa de forma exacta sobre el *feature map* exclusivamente, sin *ansatz*. Se calculan tres cantidades:

- El *kernel-target alignment* centrado [47], con la versión sin centrar [36] como complemento. Dado que para un kernel cercano a la identidad ambas valen aproximadamente $1/\sqrt{N}$ con independencia de las etiquetas, se compara el exceso sobre la media de una prueba de permutación.
- La dimensión efectiva d del espacio que generan las lesiones [42] (ecuación (48), sección 3.4), que cuantifica en cuántas direcciones independientes se reparten las lesiones dentro del espacio del kernel: va de 1, si todas se parecen, a N, si cada lesión es ortogonal a las demás, calculada a partir de los valores propios ordenados de la matriz del kernel normalizada.
- La *geometric difference* regularizada g_{gen} [42] (ecuaciones (45) y (46), sección 3.4), sujeta a que el error de entrenamiento g_{tra} sea menor que 0.045.

El kernel clásico de referencia K_C es el RBF con el ancho de banda γ fijado por la heurística de la mediana, el mismo de C3. Siguiendo el protocolo de Huang et al. [42], se reporta el mínimo sobre una batería de kernels clásicos (un kernel lineal sobre los datos centrados y nueve kernels gaussianos con $\gamma = m/(n\,\mathrm{Var}[\mathbf{x}])$, para $m \in \{0{,}25, 0{,}5, 1, 2, 4, 8, 16, 32, 64\}$) y valores de regularización $\lambda \in \{10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}, 0{,}025, 0{,}05, 0{,}1\}$, con $\mathrm{Tr}(K) = N$. Como sensibilidad se añaden tres

gaussianos más estrechos, $m \in \{128, 256, 512\}$; para cada kernel se toma el mayor λ admisible que satisface la cota sobre g_{tra}. Sin regularización, la cantidad mide sobre todo el condicionamiento de K_C y no la codificación.

Como análisis de sensibilidad, los kernels cuánticos se recalculan con los ángulos escalados, $\mathbf{x} \to c\,\mathbf{x}$, para $c \in \{1,0, 0{,}5, 0{,}2, 0{,}1, 0{,}05, 0{,}02\}$. Así se mide cómo cambia la geometría cuando las rotaciones son menores.

Métricas sobre los *embeddings*. El índice de Davies-Bouldin, la razón de Fisher multivariante (ecuación (52)) y el alineamiento del kernel lineal se calculan sobre los vectores de las cinco condiciones, que son los que recibe el clasificador; la visualización *t-SNE* (perplejidad 30, inicialización por PCA, semilla 42) se usa solo como apoyo visual. Las tres métricas son invariantes ante la rotación de C2, que actúa así como control nulo.

Ambas familias de métricas no son equivalentes: el kernel de fidelidad compara estados completos, incluida su información de fase, mientras que los valores esperados en la base Z solo ven la parte de esa información que el *ansatz* convierte en probabilidades. Por eso las dos familias pueden ordenar las condiciones de forma distinta.

5.9. Módulo 7: Clasificación

El módulo de clasificación entrena el mismo perceptrón multicapa en PyTorch sobre la representación de cada condición: una capa de entrada de dimensión 12, capas ocultas de 32 y 16 neuronas con activación ReLU, y una salida sigmoide que da la probabilidad de malignidad. La pérdida es la entropía cruzada binaria ponderada (ecuación (36)), con los pesos de la ecuación (37), optimizada con Adam (tasa 10^{-3}, decaimiento de pesos 10^{-4}, lotes de 128). Las entradas se estandarizan con la media y la desviación del entrenamiento de cada ajuste: las representaciones difieren en escala en más de un orden de magnitud (en masas, desviación típica media por dimensión de 0.90 en C1 frente a 0.056 en C4), y sin estandarizar el optimizador favorecería a las de escala grande por una razón ajena a su información. El entrenamiento se detiene cuando la pérdida, medida sobre el 15 % de los pacientes del entrenamiento, deja de mejorar durante 40 épocas, y se conservan los mejores pesos. Los hiperparámetros se fijaron antes de ver los resultados y son idénticos en las cinco condiciones, con la misma semilla.

Cada condición se evalúa con validación cruzada de cinco *folds*, los fijados en M4, y con un único ajuste sobre todo el entrenamiento que se evalúa una sola vez en el conjunto de prueba oficial. La incertidumbre del conjunto de prueba se estima con 2 000 remuestreos *bootstrap* por paciente, pareados entre condiciones. El selector y el escalador de M4 se ajustan una sola vez con todo el

entrenamiento, no dentro de cada *fold*, así que la validación cruzada es algo optimista; volver a seleccionar dentro de cada *fold* cambia el AUC en 0.006 o menos.

Los parámetros θ del circuito no se entrenan. La razón principal es de validez interna: C2 y C3 son transformaciones que no ven las etiquetas, y si C4 y C5 ajustaran θ contra ellas, cualquier ventaja podría deberse al ajuste supervisado y no a la codificación. Además, la pregunta de investigación se refiere a la codificación ϕ y no a un procedimiento de optimización. Una tercera razón es el costo: con el método de *parameter-shift*, el que puede usarse en un computador cuántico, entrenar θ, medido en el simulador, costaría unas 205 horas por *feature map*. En el simulador existe un atajo: retropropagar a través del vector de estado da el mismo gradiente unas 3 600 veces más rápido. Pero ese atajo no existe en el hardware, porque exige conocer todas las amplitudes del estado. La sensibilidad de la conclusión a la semilla, la red, el escalado, la parada temprana, `reps` y k se reporta en la sección de resultados.

5.10. Módulo 8: Evaluación comparativa

El módulo de evaluación compara las cinco condiciones a partir de los resultados de M6 y M7, sin volver a usar el conjunto de prueba.

Métricas de clasificación. Se reportan AUC-ROC, F1, *accuracy*, *precision* y *recall* en el conjunto de prueba, por condición y por tipo de hallazgo. El AUC-ROC es la métrica principal, porque no depende de un umbral de decisión y es robusta al desbalance de clases; las demás usan el umbral 0.5.

Correlación entre separabilidad y clasificación. Se calcula el coeficiente de Spearman ρ_s entre el ordenamiento de las cinco condiciones según cada métrica de separabilidad y su ordenamiento según el AUC-ROC. Con cinco condiciones solo hay $5! = 120$ órdenes posibles, y sin empates solo el acuerdo perfecto alcanza $p < 0{,}05$. Además, C1 y C2 empatan en toda métrica de separabilidad por construcción. Por eso ρ_s se reporta de forma descriptiva, por subconjunto y con su distribución exacta, y se calcula como la correlación de Pearson entre rangos promedio, que admite empates (ecuación (60)).

Masas frente a calcificaciones. Para interpretar la diferencia de dificultad entre subconjuntos, se ajusta una regresión logística sobre los descriptores que el CBIS-DDSM registra para cada lesión: forma y márgenes en masas, tipo y distribución en calcificaciones. Es una referencia, no un competidor: esos descriptores los escribió un radiólogo viendo la imagen.

Restricciones del simulador (OE-6). Se miden el tiempo por muestra y el número máximo de

qubits viable en el equipo de trabajo, y el costo del entrenamiento por *parameter-shift*. El efecto del número de *shots* se mide de dos formas. En el *embedding*, se simulan mediciones con n disparos a partir de las probabilidades exactas, con n de 64 a 65 536, y se reentrena el clasificador. En el kernel, se calcula de forma analítica el número de disparos que exigiría estimar cada valor en hardware.

5.11. Experimentos complementarios

Con el propósito de evaluar la solidez de las conclusiones obtenidas en el protocolo principal frente a hipótesis alternativas o variantes metodológicas que un lector o evaluador razonable plantearía, se diseñó una batería de nueve experimentos complementarios (denominados X1 a X9). Estos experimentos no alteran el diseño experimental básico ni los puntos de decisión congelados para el pipeline principal ($k = 12$, $reps = 1$, Arquitectura B con vector de parámetros θ fijo con semilla 42 y particiones independientes por paciente), sino que someten a prueba la sensibilidad de los hallazgos ante variaciones controladas en la selección de características, la dimensionalidad del registro cuántico, la arquitectura de clasificación, la optimización variacional y el protocolo de evaluación. La Tabla 8 resume las características de diseño de cada experimento, y los párrafos siguientes detallan su formulación metodológica. Los resultados cuantitativos derivados de estas pruebas se reportan en el Capítulo 6.

Experimento X1: Pérdida de información en la selección de características. Desarrollado en `Code/experiments/X1_Selection_Information_Loss.ipynb`, este análisis responde a la interrogante de cuánta información diagnóstica y varianza global se descarta al reducir el conjunto radiómico de 67 a 12 variables en M4. En su diseño se compara la capacidad predictiva y la varianza retenida evaluando distintos subconjuntos de características: las 67 originales, las 12 seleccionadas por el protocolo estándar, 12 variables reajustadas dentro de cada pliegue de validación cruzada, las 12 mejores según la prueba F univariante sin filtro de redundancia, y conjuntos de 12 variables elegidas al azar. Como control se emplean modelos clásicos de regresión logística y bosques aleatorios ajustados exclusivamente dentro de los pliegues de validación cruzada sobre el conjunto de entrenamiento, junto con una descomposición PCA de 12 componentes como cota lineal de retención de varianza. Este experimento no utiliza el conjunto de prueba oficial. Los resultados se analizan en la Sección 6.1.

Experimento X2: Estructura de clase en matrices de kernel. Implementado en `Code/experiments/X2_Kernel_Class_Structure.ipynb`, evalúa si dos lesiones de la misma clase diagnóstica (benigna–benigna o maligna–maligna) exhiben mayor similitud en el kernel que dos lesiones de clases opuestas, y en qué medida dicha diferenciación depende del factor de contracción angular c. El diseño analiza la distribución de similitudes por pares de lesiones sobre

Cuadro 8: Resumen de diseño de los experimentos complementarios X1 a X9.

Exp.	Nombre / Archivo	Pregunta metodológica	Variación vs. Fijo	Control	Uso de prueba
X1	`X1_Selection_Information_Loss`	¿Cuánta información se pierde al reducir de 67 a 12 variables?	Varía subconjunto de variables; fijos modelos clásicos.	67 variables y PCA con 12 componentes.	No (solo entrenamiento).
X2	`X2_Kernel_Class_Structure`	¿Conservan los kernels cuánticos similitud intra-clase?	Varía escala c; fijos kernels de C4 y C5.	Kernel RBF clásico y permutación.	No (submuestra de entrenamiento).
X3	`X3_Fewer_Qubits_k8`	¿Persiste la conclusión con un registro de $k = 8$ qubits?	Varía $k \in \{8, 12\}$; fijo protocolo de métricas.	Condiciones clásicas con 8 variables.	No en separabilidad; sensibilidad en M7.
X4	`X4_QSVM_and_67_Features`	¿Se pierde información en la codificación o en la lectura?	Varía clasificador (QSVM vs MLP) y variables ($k = 12$ vs 67).	SVM clásico RBF y MLP de M7.	Sí (una vez por configuración).
X5	`X5_Pipeline_Audit`	¿Existe algún fallo de implementación o fuga de datos?	Varía implementación de componentes; fijos datos.	Implementaciones alternativas y código Qiskit.	Sí (solo verificación de partición).
X6	`X6_Searching_for_Advantage`	¿Supera algún kernel cuántico al clásico en etiquetas reales?	Búsqueda anidada sobre familias cuánticas y clásicas.	Mejores modelos clásicos y etiquetado diseñado según Huang.	Sí con etiquetas reales (una vez por contendiente global); no con el etiquetado diseñado.
X7	`X7_Theta_Draws`	¿Introduce sesgo el sorteo único de θ?	Varía semilla de θ (10 sorteos); fijo MLP.	Variabilidad de MLP y condiciones clásicas.	No (solo validación cruzada).
X8	`X8_Trained_Theta`	¿Mejora la representación al entrenar θ?	Varía optimización de θ (entrenado vs fijo); fijo MLP.	Modelo con θ fijo de M7 y C1 crudo.	Sí (una vez por subconjunto y mapa).
X9	`X9_Sample_Size`	¿Depende la separabilidad de la submuestra de 200 lesiones?	Varía la muestra (20 submuestras y todo el entrenamiento); fijas las métricas del M6.	Submuestra del M6 y kernel RBF.	No (solo entrenamiento).

la submuestra estratificada de 200 casos de entrenamiento, calculando el área bajo la curva ROC de pares frente a un barrido del parámetro de escala angular. Como control de referencia se utiliza el kernel gaussiano RBF clásico con ancho de banda calibrado por la heurística de la mediana, contrastando la significancia estadística frente a una prueba de permutación de 1 000 iteraciones con etiquetas barajadas. El experimento prescinde del conjunto de prueba. Sus resultados se presentan en la Sección 6.2.

Experimento X3: Evaluación con registro reducido ($k = 8$ qubits). Desarrollado en `Code/experiments/X3_Fewer_Qubits_k8.ipynb`, examina si la ausencia de ventaja cuántica en separabilidad observada en M6 es atribuible a la concentración exponencial del espacio de Hilbert a $k = 12$ qubits. El diseño mantiene idénticos los protocolos de evaluación de KTA, dimensión efectiva, diferencia geométrica regularizada g y razón de Fisher, variando la dimensión del registro cuántico a $k = 8$ qubits (lo que reduce los acoplamientos ZZ de 66 a 28 bloques y los parámetros del circuito variacional de 24 a 16). Las 8 características se eligen con la misma regla de selección de M4; como la regla avanza en orden decreciente del estadístico F, coinciden con las 8 primeras de las 12. Como control, se evalúan las condiciones clásicas C1, C2 y C3 sobre las mismas 8 características de entrada. En la fase de separabilidad este experimento no accede al conjunto de prueba oficial, mientras que su traslación a clasificación se evalúa en el análisis de sensibilidad del Módulo 7. Los resultados se detallan en la Sección 6.2.

Experimento X4: Máquinas de soporte vectorial cuánticas y codificación de 67 variables. Ejecutado en `Code/experiments/X4_QSVM_and_67_Features.ipynb`, busca determinar si la pérdida de desempeño observada en M7 reside intrínsecamente en la codificación cuántica en el espacio de Hilbert o en la etapa de lectura mediante expectativas locales $\langle Z_i \rangle$ bajo la Arquitectura B. Para ello, se implementa una máquina de vectores de soporte con kernel cuántico (QSVM) evaluada directamente sobre las matrices completas de fidelidad de C4 y C5. Asimismo, se evalúa si codificar las 67 características radiómicas completas da lugar a kernels cuánticos con ventaja frente a los clásicos, analizando codificaciones en amplitud sobre 7 qubits y codificaciones angulares en producto tensorial sobre 67 qubits. Se contrasta directamente contra modelos SVM clásicos lineales y RBF, así como contra el clasificador MLP entrenado sobre las expectativas de M7. Los modelos se comparan en validación cruzada con $C = 1$ (un barrido de C mostró que apenas cambia el resultado) y se evalúan una única vez sobre el conjunto de prueba oficial. Los resultados se reportan en la Sección 6.4.

Experimento X5: Auditoría del pipeline experimental. Documentado en `Code/experiments/X5_Pipeline_Audit.ipynb`, responde a la necesidad metodológica de descartar que la ausencia de ventaja cuántica provenga de anomalías de software, fugas de datos (*data leakage*) entre entre-

namiento y prueba, asimetrías de preprocesamiento o discrepancias numéricas en el cómputo de fidelidades. La auditoría consta de 25 pruebas, programadas con implementaciones independientes de las de los módulos, que reconstruyen particiones y diagnósticos directamente desde las fuentes maestras de metadatos, contrastan el kernel calculado con circuitos *compute-uncompute* frente al obtenido con vectores de estado, y verifican la equivalencia de las implementaciones clasificatorias frente a bibliotecas estándar de la comunidad. El conjunto de prueba se utiliza exclusivamente para verificar la integridad y aislamiento de las particiones, sin entrenamiento ni ajuste de parámetros. Su análisis se discute en la Sección 6.4.

Experimento X6: Búsqueda de ventaja cuántica y control con un etiquetado diseñado. Desarrollado en `Code/experiments/X6_Searching_for_Advantage.ipynb`, plantea una búsqueda anidada y simétrica de configuraciones óptimas en ambos paradigmas. En el lado cuántico se exploran mapas *ZZ* con entrelazamiento lineal y completo, repeticiones $reps \in \{1,2\}$, factores de escala angular y kernels proyectados; en el lado clásico se evalúan familias gaussianas, lineales y polinomiales. Para discernir si la ausencia de ventaja obedece al protocolo experimental o a la relación geométrica intrínseca de las etiquetas patológicas reales, se incorpora un control con un etiquetado diseñado (*engineered*) según Huang et al. [42] (sección 7 de su información suplementaria): el etiquetado de las mismas lesiones que mejor se ajusta a la geometría del kernel cuántico y peor a la del clásico, evaluado solo mediante validación cruzada sobre el entrenamiento. Con las etiquetas reales, la selección de modelos se efectúa mediante validación cruzada anidada y la evaluación en el conjunto de prueba se restringe a una sola ejecución por contendiente global. Los resultados se exponen en la Sección 6.4.

Experimento X7: Sensibilidad al vector de parámetros variacionales θ. Implementado en `Code/experiments/X7_Theta_Draws.ipynb`, evalúa si la fijación de θ mediante un único sorteo aleatorio (semilla 42) en la Arquitectura B introdujo un sesgo desfavorable para las representaciones cuánticas C4 y C5. El diseño analiza diez sorteos pseudoaleatorios independientes del vector θ (semillas 42 a 51), manteniendo fijos la semilla del clasificador MLP, la arquitectura de red y los pliegues de validación cruzada de M7. Como control se compara la variación inducida por el parámetro θ frente a la variabilidad por semilla de inicialización del MLP clásico y frente a los desempeños obtenidos por C1 y C3. Este análisis opera de forma estricta sobre el conjunto de entrenamiento en validación cruzada sin tocar el conjunto de prueba. Sus resultados se reportan en la Sección 6.3.

Experimento X8: Optimización variacional conjunta de θ. Realizado en `Code/experiments/X8_Trained_Theta.ipynb`, examina si el entrenamiento supervisado de los parámetros θ en forma simultánea con los pesos del clasificador MLP permite cerrar la brecha de rendimiento observa-

da frente a las condiciones clásicas. En este esquema, el vector de expectativas se calcula con una capa diferenciable que actualiza θ mediante retropropagación sobre el vector de estado simulado en PyTorch con una tasa de aprendizaje dedicada. Se analiza la sensibilidad ante la inicialización de θ y se compara el modelo resultante frente a la condición fija de M7, frente a la condición clásica C1 y frente al clasificador QSVM de X4. El conjunto de prueba oficial se consulta exactamente una vez por modelo optimizado. Los resultados se analizan en las Secciones 6.3 y 6.6.

Experimento X9: Sensibilidad de la separabilidad a la muestra. Implementado en `Code/experiments/X9_Sample_Size.ipynb`, evalúa si las conclusiones del módulo de separabilidad dependen de las 200 lesiones elegidas o del tamaño de la muestra. Repite las métricas de ambas familias a $c = 1$ sobre 20 submuestras estratificadas de 200 lesiones de entrenamiento, la primera de las cuales coincide con la del análisis principal, y sobre la totalidad del conjunto de entrenamiento, cuyo kernel se obtiene en segundos a partir de los vectores de estado. Cuantifica además el número de circuitos y de disparos que exigiría cada tamaño con el protocolo *compute-uncompute*. No utiliza el conjunto de prueba. Sus resultados se reportan en la Sección 6.2.

Estudios de caracterización del simulador cuántico (B1–B3). De forma complementaria a los experimentos sobre datos radiómicos, se llevaron a cabo tres estudios sistemáticos en `Code/benchmark/` para cuantificar las restricciones operacionales de la simulación clásica de circuitos cuánticos en el contexto del proyecto. El estudio B1 (`B1_Quantum_Benchmark.ipynb`) midió la complejidad estructural de los circuitos (profundidad, número de compuertas CX y conteo total de compuertas en función de k y *reps*) y proyectó el coste computacional del entrenamiento conjunto bajo la Arquitectura A frente al esquema de precomputación de la Arquitectura B. No obstante, la sección de sensibilidad al número de disparos (*shots*) de B1 quedó formalmente invalidada debido a que la referencia analítica empleada incorporaba ruido gaussiano no nulo inyectado por omisión de precisión cero en el estimador de alto nivel. El estudio B2 (`B2_Design_Verifications.ipynb`) integró las comprobaciones empíricas que respaldaron las decisiones de diseño metodológico: número de qubits y profundidad, arquitectura del *embedding*, condiciones experimentales, cálculo de la *geometric difference* y validación cruzada. Finalmente, el estudio B3 (`B3_Sampling_and_Concentration.ipynb`) sustituyó y rectificó la caracterización de disparos de B1 mediante un esquema de muestreo real con el estimador por muestreo de cadenas de bits de Aer, verificando el escalamiento estadístico de error teórico $1/\sqrt{n}$ sin suelo de dispersión espuria hasta 2^{20} disparos, además de cuantificar la concentración asintótica del vector de expectativas en función de la dimensionalidad k y la profundidad del circuito. Sus hallazgos se integran en las Secciones 6.6 y 6.7.

6. Resultados

La presentación de los resultados experimentales sigue el orden establecido por los módulos del sistema. A lo largo de todo el análisis, los subconjuntos de masas y de calcificaciones se reportan de forma independiente debido a sus diferencias radiológicas y metodológicas. El conjunto de prueba oficial se reserva exclusivamente para la evaluación final del modelo de clasificación, garantizando que ninguna etapa previa acceda a dichos casos. Por su parte, las métricas de separabilidad geométrica se evalúan sobre una submuestra estratificada de 200 lesiones del conjunto de entrenamiento por subconjunto.

6.1. Datos, características y selección

En la auditoría del preprocesamiento sobre los 3 568 registros del conjunto de datos, se identificaron exactamente 80 máscaras cuyas dimensiones espaciales diferían de las de su mamografía correspondiente. Estas correspondieron a dos categorías: 78 casos de masas escalados de forma uniforme por un factor cercano a 0.870 (0.8700 a 0.8704 tanto en filas como en columnas), y 2 casos de calcificaciones con un ligero desplazamiento espacial. Al contrastar las anotaciones con los recortes oficiales proporcionados en el conjunto de datos, la regla geométrica de coincidencia se verificó al píxel en 3 206 de 3 213 casos evaluables (99.8 %). Se detectaron únicamente 7 casos discordantes en masas (4 en entrenamiento y 3 en prueba), en los cuales la máscara y el recorte describen extensiones disímiles de la lesión. La exclusión de los 3 casos de prueba modifica el área bajo la curva ROC (AUC) en el conjunto de prueba de masas entre $+0{,}001$ y $+0{,}004$ a través de las cinco condiciones evaluadas, y ninguno de estos casos forma parte de la submuestra de 200 casos de separabilidad.

Respecto a la topología de las máscaras binarias, 1 464 de las 1 696 lesiones de masas (86.3 %) presentaron islas desconectadas, frente a 0 de las 1 872 lesiones de calcificaciones. En todos los casos de masas, la componente conexa de mayor tamaño retuvo al menos el 99.55 % del área total. La supresión de componentes menores descartó una mediana de 5 píxeles por máscara (con un valor máximo de 110 píxeles, equivalente al 0.45 % del área de la lesión). La distancia del píxel descartado más lejano al borde de la componente mayor presentó una mediana de 3.6 píxeles, un percentil 99 de 9.2 píxeles y un máximo de 14 píxeles, lo que resulta consistente con la hipótesis de que las islas corresponden a artefactos periféricos inmediatos al contorno.

En la etapa de extracción de características radiómicas sobre el conjunto de entrenamiento (637 lesiones malignas y 681 benignas en masas; 544 malignas y 1 002 benignas en calcificaciones),

la evaluación univariante mediante la distancia estandarizada de Cohen ($|d|$) mostró que, en las características extraídas para este conjunto de entrenamiento, las calcificaciones alcanzan tamaños de efecto individual superiores a los de las masas. En masas, la característica con mayor tamaño de efecto fue `firstorder_Maximum` con $|d| = 0{,}50$ (con un rango de 0.40 a 0.50 en las doce primeras), seguida de descriptores morfológicos como `shape2D_MinorAxisLength` ($|d| = 0{,}45$), `shape2D_MaximumDiameter` ($|d| = 0{,}44$) y `shape2D_MajorAxisLength` ($|d| = 0{,}43$). Por su parte, en calcificaciones la característica más discriminativa fue `shape2D_MinorAxisLength` con $|d| = 0{,}82$ (con un rango de 0.64 a 0.82 en las doce primeras), seguida de `shape2D_Perimeter` ($|d| = 0{,}71$).

En el subconjunto de masas se observó que los primeros puestos del ordenamiento corresponden a características de primer orden calculadas sobre intensidades sin calibrar (`Maximum`, `90Percentile`, `Energy`, `Median` y `Mean`). Dado que la base de datos combina digitalizadores sin consignar el fabricante en los metadatos correspondientes, no es posible descartar que parte de dicha señal provenga de diferencias en la adquisición física de la imagen. Adicionalmente, el ordenamiento univariante directo en masas seleccionó 7 características de primer orden y 5 morfológicas sin incluir ninguna variable de textura (0 de matrices de coocurrencia GLCM y 0 de matrices de longitud de rachas GLRLM), exhibiendo una correlación media intercaracterística de $|r| = 0{,}61$ con 8 pares por encima de $|r| > 0{,}95$, además de duplicados exactos en dos dimensiones tales como `Energy` y `TotalEnergy`, o `MeshSurface` y `PixelSurface` ($r = 1{,}0000$). En calcificaciones, el conjunto preliminar incluyó 1 característica de primer orden, 2 morfológicas, 4 de GLCM y 5 de GLRLM, con una correlación media de $|r| = 0{,}58$ y 5 pares con $|r| > 0{,}95$.

La aplicación de ecualización adaptativa de histograma con limitación de contraste (CLAHE) reordenó las lesiones con una correlación de Spearman cercana a 0.84 respecto a las intensidades crudas, pero no aportó ganancia discriminativa neta. La variación mediana en $|d|$ fue de $-0{,}002$ en masas y de $-0{,}010$ en calcificaciones. Las características de intensidad de primer orden sufrieron una reducción mediana de $|d|$ de $-0{,}031$ en masas y de $-0{,}054$ en calcificaciones, compensada únicamente por incrementos menores en descriptores de textura (GLRLM $+0{,}011$ en masas, GLCM $+0{,}014$ en calcificaciones), sin mejorar el poder de separación de las características dominantes.

Para la selección final a doce características, la incorporación de la restricción de redundancia ($|r| \leq 0{,}95$) descartó 7 variables redundantes en masas y 8 en calcificaciones, eliminando los duplicados analíticos. En masas, la composición final se rebalanceó a 4 características de primer orden, 5 morfológicas, 1 de GLCM y 2 de GLRLM, reduciendo la correlación media a $|r| = 0{,}50$ y el valor máximo a $|r| = 0{,}94$. La entrada de descriptores de textura en masas se mantuvo estable ante variaciones del umbral de correlación entre 0.99 y 0.80. En calcificaciones, el conjunto final reunió 2 características de primer orden, 3 morfológicas, 4 de GLCM y 3 de GLRLM, con una correlación

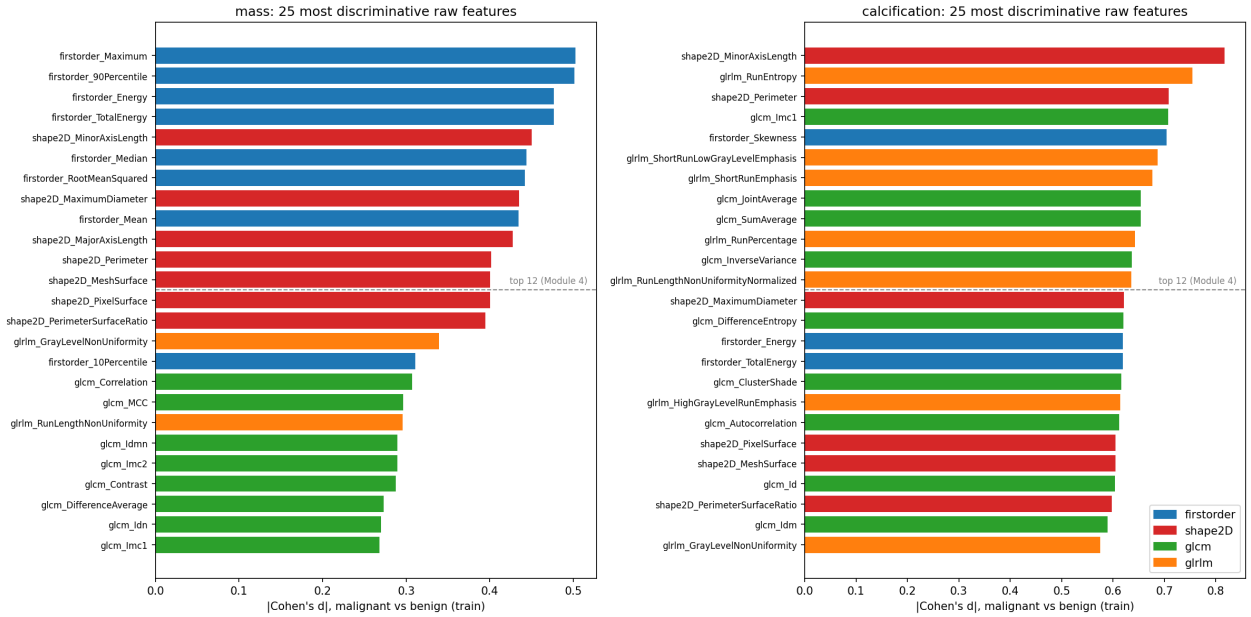


Figura 6.1.1: Tamaños de efecto de Cohen ($|d|$) para las características radiómicas evaluadas en el conjunto de entrenamiento de masas y calcificaciones.

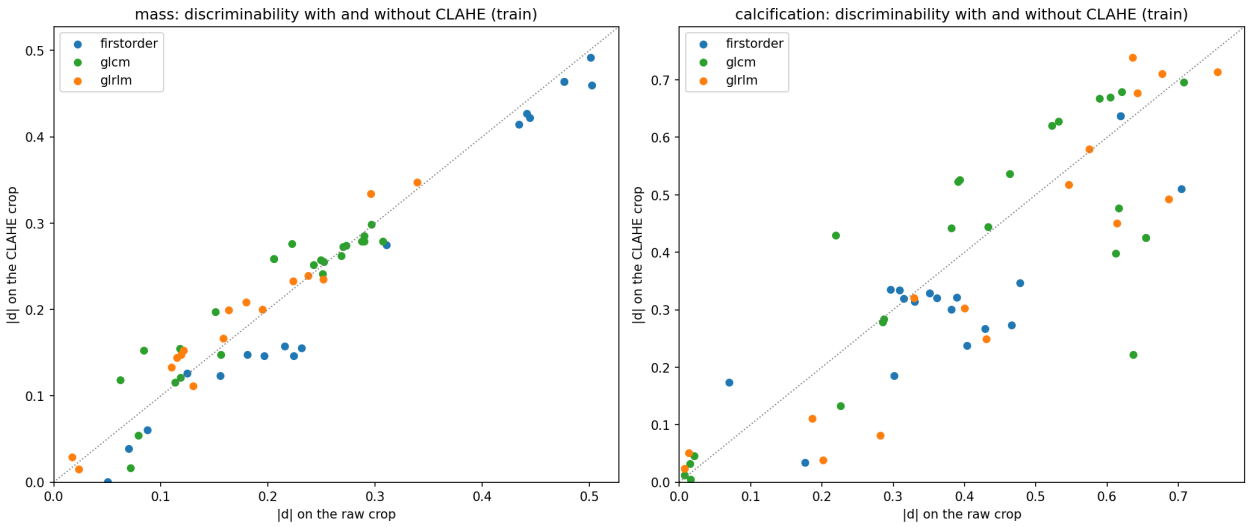


Figura 6.1.2: Efecto de la ecualización CLAHE sobre la capacidad discriminativa y el reordenamiento de características radiómicas por familia.

media de $|r| = 0{,}50$. Las doce variables resultantes se presentan en la Tabla 9.

Cuadro 9: Las 12 características seleccionadas en cada subconjunto (M4): F-test ANOVA sobre el entrenamiento con restricción de redundancia $|r| \leq 0.95$.

	Masas			Calcificaciones		
#	Característica	Familia	F	Característica	Familia	F
1	firstorder_Maximum	firstorder	83.1	shape2D_MinorAxisLength	shape2D	235.4
2	firstorder_90Percentile	firstorder	82.6	glrlm_RunEntropy	glrlm	200.9
3	firstorder_Energy	firstorder	74.7	shape2D_Perimeter	shape2D	177.0
4	shape2D_MinorAxisLength	shape2D	66.7	firstorder_Skewness	firstorder	174.6
5	shape2D_MaximumDiameter	shape2D	62.3	glrlm_ShortRunLowGrayLevelEmphasis	glrlm	166.2
6	shape2D_Perimeter	shape2D	53.1	glrlm_ShortRunEmphasis	glrlm	161.5
7	shape2D_MeshSurface	shape2D	52.8	glcm_JointAverage	glcm	150.9
8	shape2D_PerimeterSurfaceRatio	shape2D	51.3	glcm_InverseVariance	glcm	142.8
9	glrlm_GrayLevelNonUniformity	glrlm	37.8	glcm_DifferenceEntropy	glcm	135.6
10	firstorder_10Percentile	firstorder	31.7	firstorder_Energy	firstorder	135.1
11	glcm_Correlation	glcm	31.0	glcm_ClusterShade	glcm	133.9
12	glrlm_RunLengthNonUniformity	glrlm	28.8	shape2D_PixelSurface	shape2D	129.1

En la etapa de escalado angular, el uso de escalado por valores extremos (`MinMaxScaler`) hacia el intervalo $[0, \pi]$ comprimía excesivamente las distribuciones de aquellas características con colas pesadas. En calcificaciones, el rango intercuartílico (IQR) de `firstorder_Energy` resultaba en 0,046 rad (con mediana de 0,015 rad) y el de `shape2D_PixelSurface` en 0,057 rad (mediana de 0,020 rad), en contraste con una mediana global de IQR de 0,34 rad en masas y 0,40 rad en calcificaciones. La adopción de una transformación por cuantiles hacia una distribución uniforme en $[0, \pi]$ permitió que las doce características en ambos subconjuntos alcanzaran de forma homogénea un IQR de $\pi/2$ (1,569 a 1,572 rad).

Para la partición en cinco pliegues de validación cruzada, la agrupación por paciente evitó la fragmentación de estudios pertenecientes a un mismo individuo, la cual afectaba al 59 % de los pacientes en masas y al 74 % en calcificaciones bajo particiones estratificadas simples. Al evaluar la partición inicial con semilla 42, el segundo pliegue de calcificaciones exhibió un 52 % de casos malignos frente al 35 % poblacional (desviación de 0.168). La selección mediante búsqueda sistemática entre 200 semillas identificó la semilla 125 en masas y la semilla 168 en calcificaciones, acotando la desviación máxima de malignidad a 0.011 en masas y a 0.019 en calcificaciones (proporciones entre 0.33 y 0.37 por pliegue).

En cuanto a la división entre los conjuntos de entrenamiento y prueba, la auditoría de partición confirmó la ausencia de fuga de pacientes (*data leakage*) dentro de cada subproblema analizado.

En masas se contabilizaron 691 pacientes en entrenamiento y 201 en prueba sin solapamiento alguno (0 pacientes compartidos); análogamente, en calcificaciones se identificaron 602 pacientes en entrenamiento y 151 en prueba, igualmente con 0 solapes. A nivel global, considerando ambos hallazgos de forma conjunta, se registraron 1 248 pacientes en entrenamiento y 349 en prueba con 31 pacientes solapados, discrepancia que se origina porque la partición oficial del CBIS-DDSM se formuló de forma independiente para cada tipo de lesión, de modo que un mismo individuo puede presentar masas en entrenamiento y calcificaciones en prueba. Este comportamiento proporciona respaldo metodológico para procesar masas y calcificaciones como subproblemas independientes, eliminando por construcción la posibilidad de contaminación entre conjuntos.

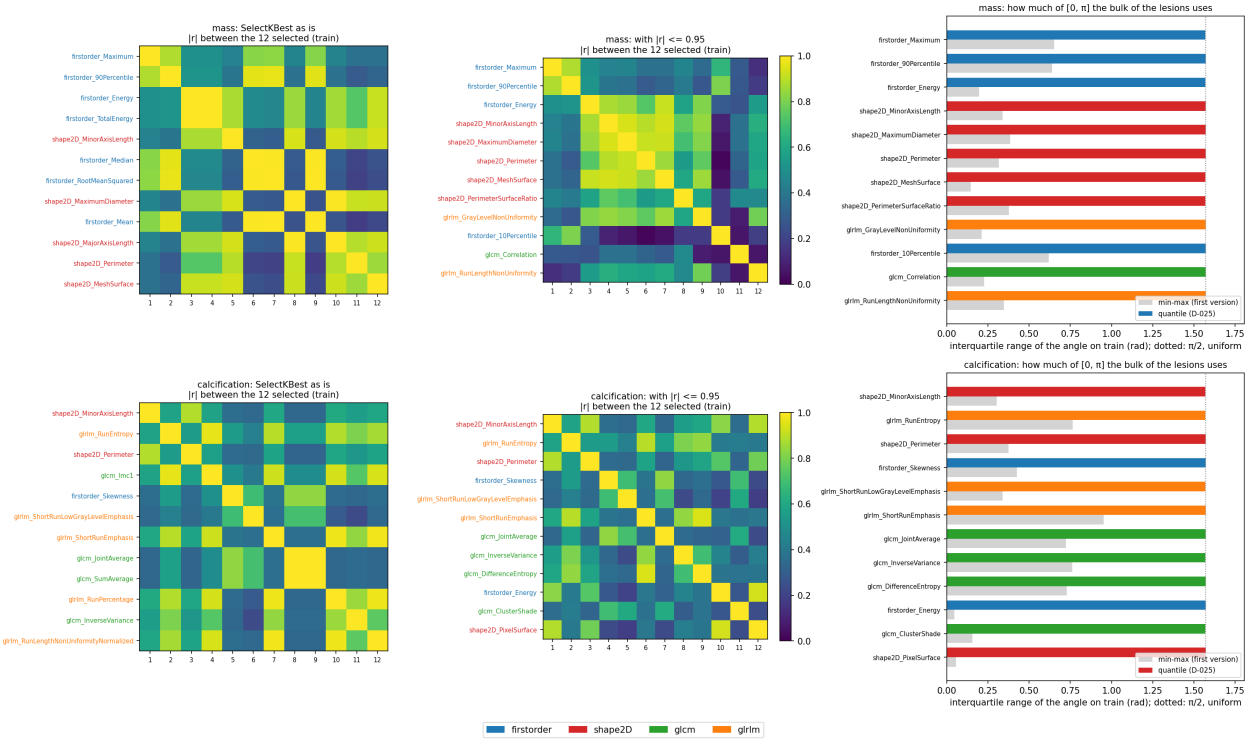


Figura 6.1.3: Distribución angular tras la selección de características y comparación entre escalado por valores extremos y transformación por cuantiles.

El análisis sobre la pérdida de información al reducir de 67 a 12 características reveló que las variables seleccionadas retienen el 86.8 % de la varianza total en masas y el 90.2 % en calcificaciones, frente al 98.0 % y 97.8 % alcanzable mediante las doce primeras componentes de un análisis de componentes principales. En términos de capacidad predictiva sobre el conjunto de entrenamiento, la reducción a doce dimensiones implicó una disminución de 2 a 4 puntos de AUC en modelos clásicos: en regresión logística, el AUC descendió de $0{,}693 \pm 0{,}039$ a $0{,}650 \pm 0{,}056$ en masas y de $0{,}800 \pm 0{,}028$ a $0{,}758 \pm 0{,}025$ en calcificaciones; en bosques aleatorios, la variación fue de $0{,}695 \pm 0{,}043$ a $0{,}680 \pm 0{,}046$ en masas y de $0{,}796 \pm 0{,}018$ a $0{,}773 \pm 0{,}024$ en calcificaciones. Asimismo, doce características seleccionadas al azar obtuvieron desempeños comparables

(0,656 ± 0,019 y 0,659 ± 0,023 en masas; 0,765 ± 0,015 y 0,775 ± 0,016 en calcificaciones), ilustrando que las variables con mayor puntuación univariante individual no necesariamente configuran el conjunto óptimo debido a redundancias en la información compartida [54].

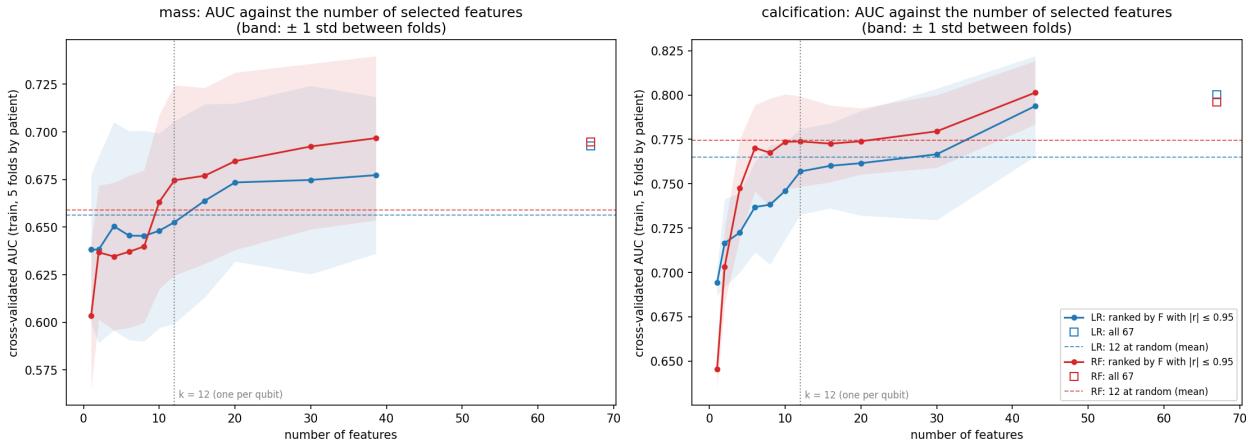


Figura 6.1.4: Evolución del área bajo la curva ROC en función del número de características k para modelos clásicos en entrenamiento.

Esta limitación intrínseca de la selección univariante introduce una consideración metodológica central que matiza la comparación: el criterio de `SelectKBest` evalúa cada variable de forma aislada mediante la prueba F de ANOVA, mientras que el filtro de redundancia examina correlaciones lineales dos a dos. Como consecuencia, aquellas características cuyo poder discriminativo dependa exclusivamente de interacciones de orden superior con otras variables (como en configuraciones de tipo o-exclusivo) resultan descartadas antes de alimentar el circuito cuántico. Esta dinámica genera una tensión conceptual con el diseño experimental, puesto que el bloque de acoplamiento ZZ del mapa de características codifica precisamente productos de pares $(\pi - x_i)(\pi - x_j)$, que constituyen el mecanismo primario mediante el cual la transformación cuántica podría aportar ventajas frente a representaciones clásicas. Aunque la comparación entre las cinco condiciones se mantiene metodológicamente rigurosa al suministrar exactamente el mismo vector de 12 características a todos los modelos, la ausencia de una selección multivariante capaz de capturar interacciones complejas representa una restricción de diseño que contextualiza los resultados y explica por qué la selección guiada por F no supera de forma concluyente a selecciones aleatorias en el experimento X1.

6.2. Separabilidad de las representaciones

En la evaluación del kernel cuántico de fidelidad a escala nominal ($c = 1$) sobre la submuestra estratificada de 200 lesiones de entrenamiento por subconjunto, las matrices de similitud resultaron cercanas a la identidad. En masas, la mediana fuera de la diagonal fue de 0.0022 en C4 (con per-

centil 95 de 0.011 y 23 % de pares con fidelidad inferior a 10^{-3}) y de 0.000032 en C5 (con 80 % de pares por debajo de 10^{-3} y 26 % por debajo de 10^{-6}). En calcificaciones, la mediana fue de 0.0029 en C4 (percentil 95 de 0.014 y 16 % bajo 10^{-3}) y de 0.000031 en C5 (76 % bajo 10^{-3} y 28 % bajo 10^{-6}). En contraste, el kernel clásico gaussiano RBF con parámetro γ determinado por la heurística de la mediana registró una mediana fuera de la diagonal de 0.607 en ambos subconjuntos.

Sobre todas las lesiones del conjunto de entrenamiento (1 318 masas y 1 546 calcificaciones), la desviación estándar media por dimensión de los valores esperados $\langle Z_i \rangle$ fue de 0.056 en masas y 0.048 en calcificaciones para C4, mientras que en C5 ascendió a 0.180 en masas y 0.178 en calcificaciones. En C4 las compuertas aplicadas tras la capa inicial de Hadamard son diagonales, por lo que el término propio en Z añade una variación angular moderada frente a las fases de acoplamiento ZZ. En C5, la rotación no diagonal en el eje Y modifica directamente las amplitudes antes de la acción de los términos ZZ, dispersando los valores esperados locales pero acentuando la ortogonalidad mutua en el espacio de estados cuánticos y concentrando la fidelidad unas setenta veces más que en C4 [48].

Esta concentración del *embedding* reproduce el comportamiento caracterizado en el estudio B3 sobre la dispersión de los valores esperados $\langle Z_i \rangle$ (evaluada sobre 100 entradas y 10 sorteos de θ con cálculo analítico exacto tras corregir la inyección de ruido en la referencia). Dicho análisis evidenció tres patrones fundamentales: en primer lugar, la concentración con el número de qubits es sistemática, reduciéndose la dispersión media a `reps` = 1 de $0{,}0837 \pm 0{,}0131$ con $k = 8$ a $0{,}0417 \pm 0{,}0068$ con $k = 12$ y a $0{,}0363 \pm 0{,}0090$ con $k = 16$, comportamiento característico del crecimiento exponencial del espacio de Hilbert y precursor de las mesetas áridas (*barren plateaus*). En segundo lugar, la concentración con la profundidad del circuito no es monótona en el rango analizado: para $k = 12$, la dispersión se incrementa en un 30 % al pasar de `reps` = 1 a `reps` = 2 ($0{,}0417 \pm 0{,}0068$ frente a $0{,}0544 \pm 0{,}0036$), descendiendo a $0{,}0305 \pm 0{,}0044$ con `reps` = 3. En tercer lugar, la variabilidad entre distintos sorteos del vector θ colapsa con la profundidad: a $k = 16$, la desviación entre sorteos se reduce de 0.0090 a 0.0043 y finalmente a 0.0023, reflejando una pérdida progresiva de sensibilidad respecto a los parámetros del circuito que es indicativa del régimen de meseta árida.

Los resultados de separabilidad formal en la familia de kernels se resumen en la Tabla 10, calculados sobre la submuestra de entrenamiento con $c = 1$.

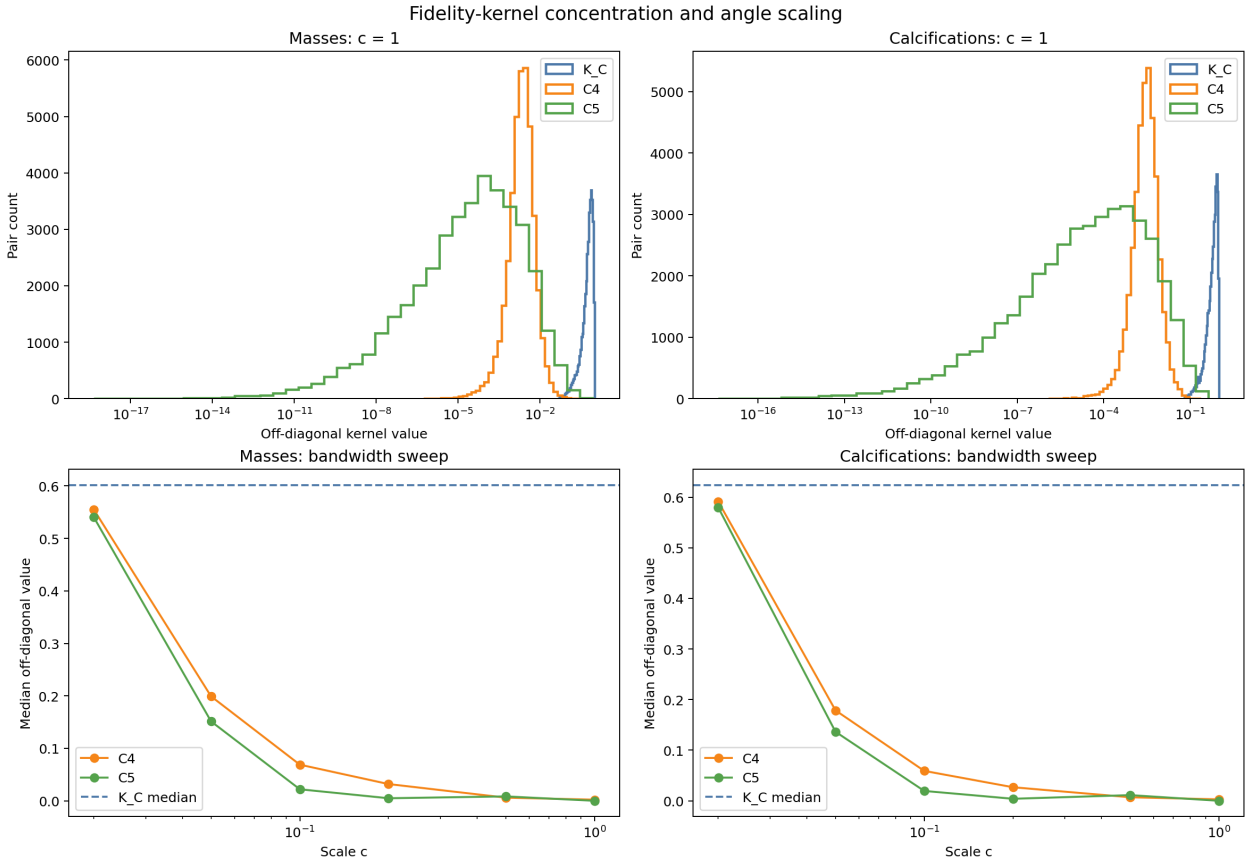


Figura 6.2.1: Distribución de los valores fuera de la diagonal en las matrices de kernel cuántico para C4 y C5 frente al kernel clásico RBF.

Cuadro 10: Separabilidad en la familia de kernels (M6), $c = 1$, 200 lesiones de entrenamiento por subconjunto.

Kernel	KTA centrada	Exceso sobre permutación	p	d_{eff} (de 200)	g regularizada
Masas					
RBF (clásico)	0.059	0.049	<0.001	2.8	—
C4, ZZ	0.073	0.003	0.002	184.0	1.433
C5, Y–ZZ	0.075	0.005	0.003	171.3	1.511
Calcificaciones					
RBF (clásico)	0.161	0.151	<0.001	2.6	—
C4, ZZ	0.077	0.006	<0.001	187.7	1.400
C5, Y–ZZ	0.075	0.007	0.003	167.6	1.701

El exceso es la KTA centrada menos la media de 1,000 permutaciones de etiquetas; p es unilateral. g es el mínimo de la *geometric difference* regularizada sobre la batería de kernels clásicos del Apéndice L.3 de Huang et al. $\sqrt{N} \approx 14$.

El exceso de alineamiento centrado (*kernel-target alignment*, KTA) sobre la media de 1 000 permutaciones de etiquetas fue en masas de 0.049 ($p < 0{,}001$) para el kernel clásico RBF, frente a 0.003 ($p = 0{,}002$) en C4 y 0.005 ($p = 0{,}003$) en C5. En calcificaciones, el exceso del kernel RBF fue de 0.151 ($p < 0{,}001$), frente a 0.006 ($p < 0{,}001$) en C4 y 0.007 ($p = 0{,}003$) en C5. Aunque el exceso en los kernels cuánticos resultó estadísticamente significativo, representó únicamente entre el 4 % y el 10 % del exceso clásico. Los valores absolutos de KTA centrada en C4 y C5 (0,073 a 0,077) se encuentran acotados por el valor base de $1/\sqrt{N-1} \approx 0{,}071$ inherente a matrices cercanas a la identidad para muestras de $N = 200$ [47].

La dimensión efectiva normalizada (d_{eff} de 200) arrojó 2.8 en masas y 2.6 en calcificaciones para el kernel clásico RBF. Para los kernels cuánticos, los valores fueron de 184.0 en C4 y 171.3 en C5 para masas, y de 187.7 en C4 y 167.6 en C5 para calcificaciones. Las representaciones cuánticas ocupan casi la totalidad de las dimensiones del espacio disponible ($d_{\text{eff}} \approx N$), régimen en el cual las cotas teóricas de error de generalización derivadas por Huang et al. [42] se aproximan a su valor máximo al escalar con $\sqrt{\text{mín}(d_{\text{eff}}, \text{Tr}(O^2))/N}$.

En la métrica de diferencia geométrica regularizada frente a la batería de kernels clásicos, los valores mínimos obtenidos fueron $g = 1{,}433$ en C4 y 1,511 en C5 para masas, y $g = 1{,}400$ en C4 y 1,701 en C5 para calcificaciones. En comparación con la cota de referencia $\sqrt{N} \approx 14{,}1$, se cumple de forma consistente la condición $g \ll \sqrt{N}$, bajo la cual el marco teórico de Huang et al. [42] indica que los modelos clásicos pueden igualar o mejorar el desempeño del modelo cuántico con cualquier vector de etiquetas. En la batería clásica extendida con gaussianos estrechos, el valor mínimo se

reduce a 1.31 en C4 y 1.48 en C5 para masas, y a 1.38 en C4 y 1.70 en C5 para calcificaciones. Por el contrario, el cálculo de g sin regularizar genera valores entre 306 y 388 (próximos a la cota teórica de $K_Q = I$, $1/\sqrt{\lambda_{\text{mín}}(K_C)} \approx 410$), producto del condicionamiento numérico de la matriz clásica invertida.

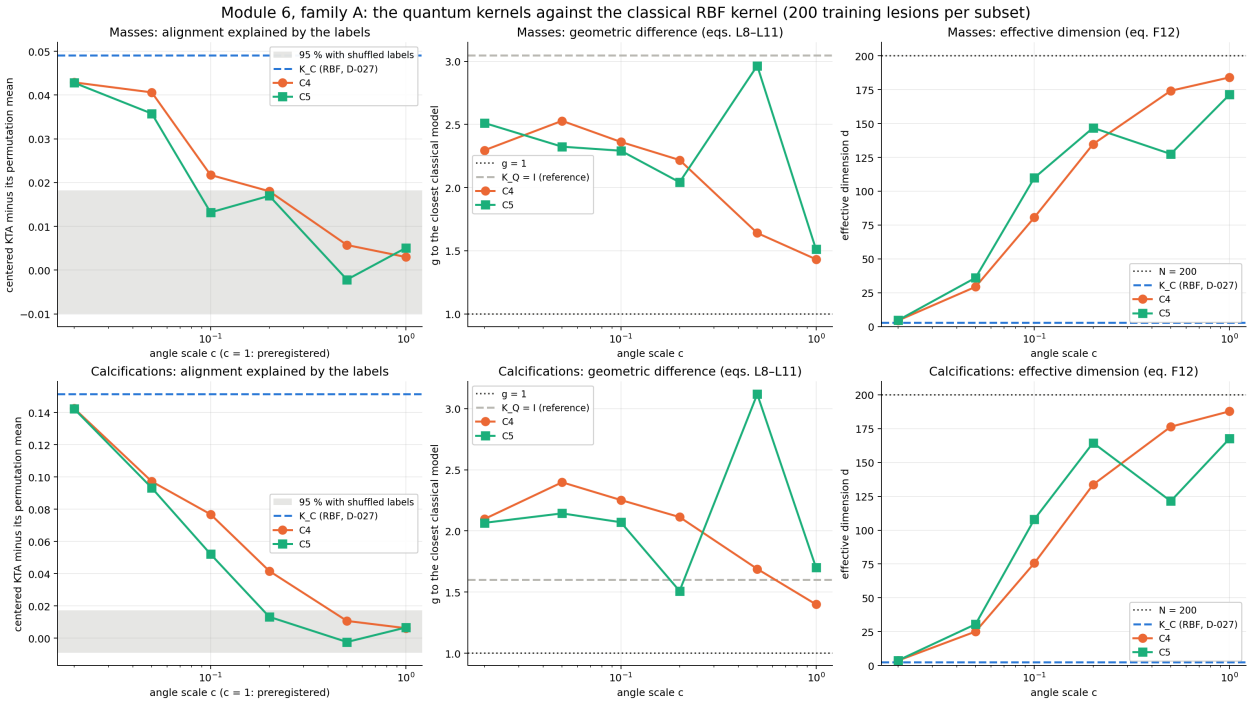


Figura 6.2.2: Métricas de separabilidad en la familia de kernels: alineamiento KTA y dimensión efectiva normalizada.

La separabilidad sobre las representaciones vectoriales generadas por los cinco esquemas metodológicos se presenta en la Tabla 11.

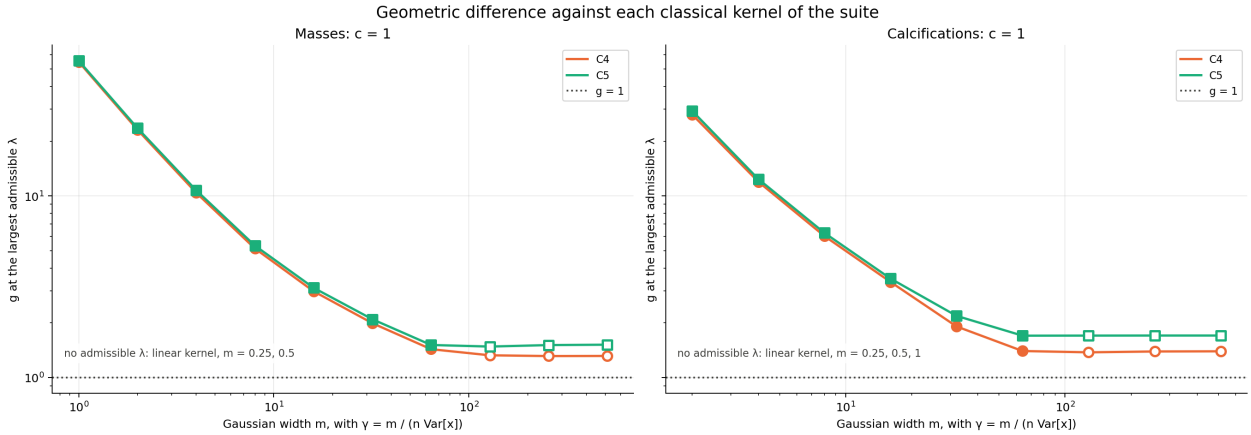


Figura 6.2.3: Diferencia geométrica regularizada g respecto a la batería de modelos clásicos frente al límite $\sqrt{N}$.

Cuadro 11: Separabilidad en la familia de embeddings (M6): 200 lesiones de entrenamiento por subconjunto.

Condición	Davies–Bouldin ↓	Fisher J ↑	KTA lineal ↑
Masas			
C1	4.301	0.669	0.070
C2	4.301	0.669	0.070
C3	5.564	0.781	0.059
C4	5.898	0.449	0.041
C5	13.346	0.668	0.012
Calcificaciones			
C1	2.387	1.284	0.181
C2	2.387	1.284	0.181
C3	2.995	1.390	0.161
C4	6.890	0.399	0.031
C5	6.247	0.753	0.041

Fisher $J = \Delta\mu^\top S_W^{-1}\Delta\mu$, con la covarianza intraclase combinada. C1 y C2 coinciden por construcción.

En la submuestra de 200 lesiones, las tres representaciones clásicas (C1, C2 y C3) superaron a las cuánticas (C4 y C5) en todas las métricas evaluadas. En masas, el índice de Davies–Bouldin fue de 4.301 en C1 y C2 frente a 5.898 en C4 y 13.346 en C5 ($p = 0{,}41$); la razón de Fisher J fue de 0.669 en C1 y C2 (y 0.781 en C3) frente a 0.449 en C4 ($p = 0{,}05$) y 0.668 en C5; y el alineamiento lineal fue de 0.070 en C1 y C2 frente a 0.041 en C4 y 0.012 en C5 ($p = 0{,}41$). En calcificaciones, Davies–Bouldin fue de 2.387 en C1 y C2 frente a 6.890 en C4 y 6.247 en C5; Fisher J fue de 1.284 en C1 y C2 (y 1.390 en C3) frente a 0.399 en C4 ($p = 0{,}15$) y 0.753 en C5; y el alineamiento lineal

fue de 0.181 en C1 y C2 frente a 0.031 en C4 y 0.041 en C5. Las métricas de C1 y C2 coincidieron con discrepancias numéricas del orden del límite de precisión ($< 10^{-14}$), lo cual concuerda con la invarianza teórica de las distancias y dispersiones ante rotaciones ortogonales bajo la condición de control nulo. Al evaluar la razón de Fisher sobre la totalidad del conjunto de entrenamiento, la ventaja clásica se mantuvo: C1 obtuvo 0.45 en masas y 1.06 en calcificaciones, frente a 0.13 y 0.42 en C4, y 0.21 y 0.31 en C5.

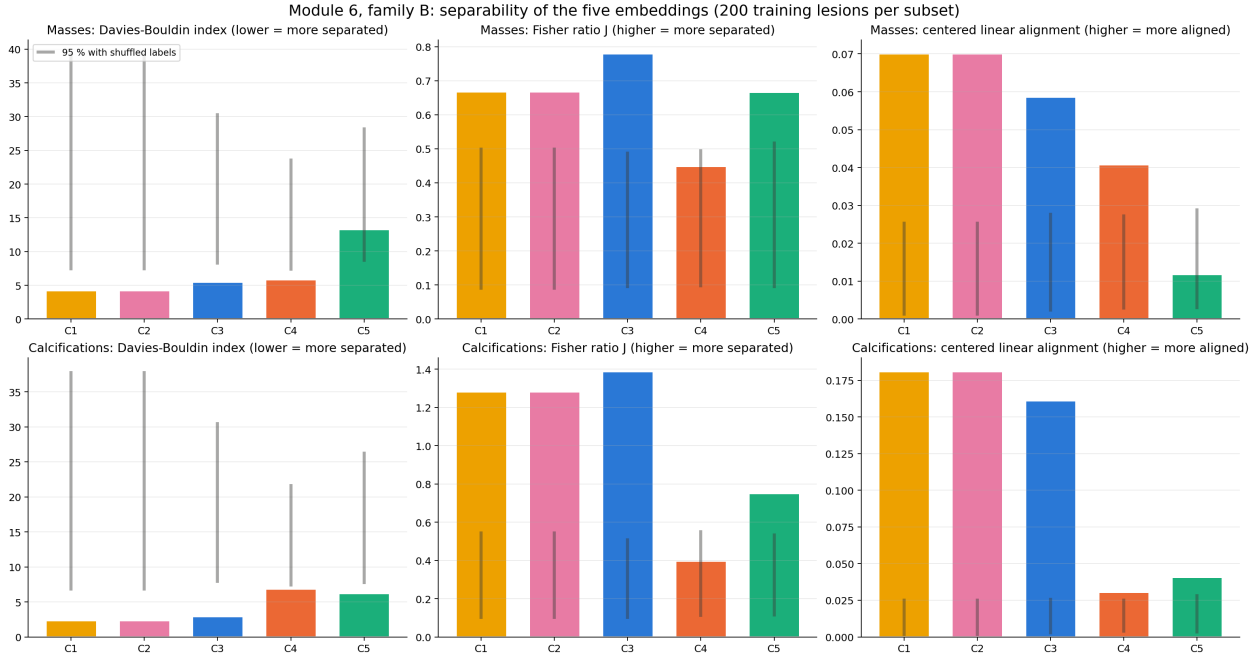


Figura 6.2.4: Métricas de separabilidad sobre las representaciones vectoriales: índice de Davies–Bouldin, razón de Fisher y alineamiento lineal.

Para descartar que estas conclusiones dependan de la submuestra, las métricas a $c = 1$ se repitieron sobre otras 19 submuestras estratificadas de 200 lesiones de entrenamiento y sobre la totalidad del conjunto de entrenamiento, sin usar el conjunto de prueba (Figura 6.2.6). En las 20 submuestras de ambos subconjuntos, el kernel RBF conservó un exceso de KTA mayor que el de los dos kernels cuánticos, sin traslape de rangos: el menor exceso clásico, 0.019 en masas y 0.055 en calcificaciones, superó al mayor exceso cuántico, 0.011 y 0.014. La diferencia geométrica mínima se mantuvo entre 1.31 y 2.87, a lo sumo 0.20 veces $\sqrt{N}$, y la dimensión efectiva de C4 y C5, entre 0.82 y 0.95 veces N. En las representaciones vectoriales, la mejor condición clásica (C1 o C3) superó a las dos cuánticas en las 20 submuestras y en las tres métricas. Sobre todo el entrenamiento (1 318 masas y 1 546 calcificaciones), el exceso de KTA fue de 0.055 para el RBF frente a 0.006 (C4) y 0.009 (C5) en masas, y de 0.148 frente a 0.018 y 0.020 en calcificaciones, con $p = 0{,}001$ en todos los casos; g se ubicó entre 2.95 y 3.25, frente a $\sqrt{N}$ de 36.3 y 39.3. El exceso cuántico crece con N porque en un kernel concentrado la señal de clase reside en los $N(N-1)$ pares fuera de la diagonal, cada uno con un traslape mínimo; por ello los valores de alineamiento, g y dimensión efectiva solo se comparan

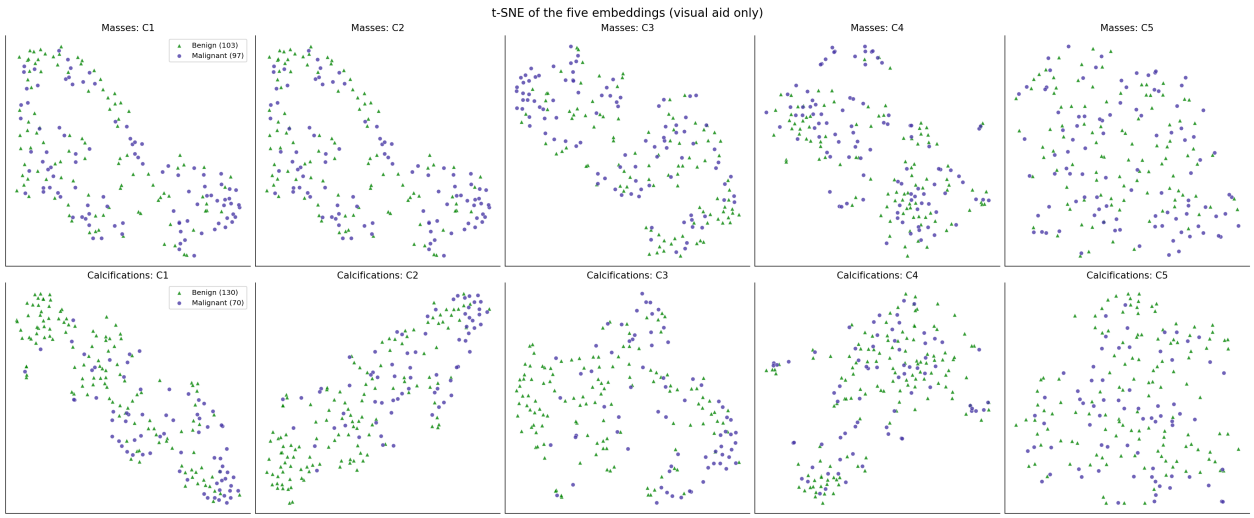


Figura 6.2.5: Proyecciones bidimensionales mediante t-SNE para las representaciones generadas en las cinco condiciones.

entre condiciones con el mismo N. Dos aspectos sí dependen de la muestra: la significancia de los efectos más pequeños, pues C5 en masas llegó a $p = 0{,}24$ en alguna submuestra, y el orden entre C4 y C5, que cambia con la métrica y con la submuestra.

En el análisis por pares sobre la submuestra de entrenamiento, el kernel clásico RBF obtuvo un AUC de pares de 0.523 ($p = 0{,}002$) en masas y de 0.575 ($p = 0{,}001$) en calcificaciones. A escala $c = 1$, C4 registró 0.510 ($p = 0{,}012$) en masas y 0.520 ($p = 0{,}021$) en calcificaciones, mientras que C5 obtuvo 0.508 ($p = 0{,}047$) en masas y 0.547 ($p = 0{,}001$) en calcificaciones. En calcificaciones, C5 superó a C4 en 0.027, aunque ambos kernels permanecieron por debajo del RBF. Al excluir los pares con fidelidad inferior a 10^{-6}, el AUC de pares de C5 se mantuvo en 0.510 en masas y 0.570 en calcificaciones, descartando que la discriminación dependa de valores numéricamente irresolubles en hardware. La evolución del AUC de pares se ilustra en la Figura 6.2.7.

Al contraer los ángulos de rotación mediante el factor de escala $\mathbf{x} \to c\mathbf{x}$ con $c \in \{1,\ 0{,}5,\ 0{,}2,\ 0{,}1,\ 0{,}05,\ 0{,}02\}$, la concentración se reduce progresivamente: para $c = 0{,}02$, la mediana fuera de la diagonal sube a 0.55 (C4) y 0.54 (C5) en masas, y a 0.59 y 0.58 en calcificaciones, el exceso de KTA alcanza 0.043 en masas y 0.143 en calcificaciones (próximo a 0.049 y 0.151 del RBF), la dimensión efectiva decae a aproximadamente 4 y g se ubica entre 2.1 y 2.5 (con un valor máximo de 3.1 en todo el barrido para C5 con $c = 0{,}5$). Este incremento en alineamiento no representa información cuántica novedosa: la fase acumulada en el bloque ZZ corresponde a $2\pi^2 - 2\pi c(x_i + x_j) + 2c^2 x_i x_j$, donde la fase constante es invariante y el producto cruzado $x_i x_j$ decae con c^2. A escala $c = 0{,}02$, la correlación entre el kernel cuántico completo y una versión idéntica que prescinde del producto entre características es de 0.99997 en masas y 0.99999 en calcificaciones. La concentración del kernel solo se disipa cuando el término de interacción de segundo orden deja de tener efecto, recuperando

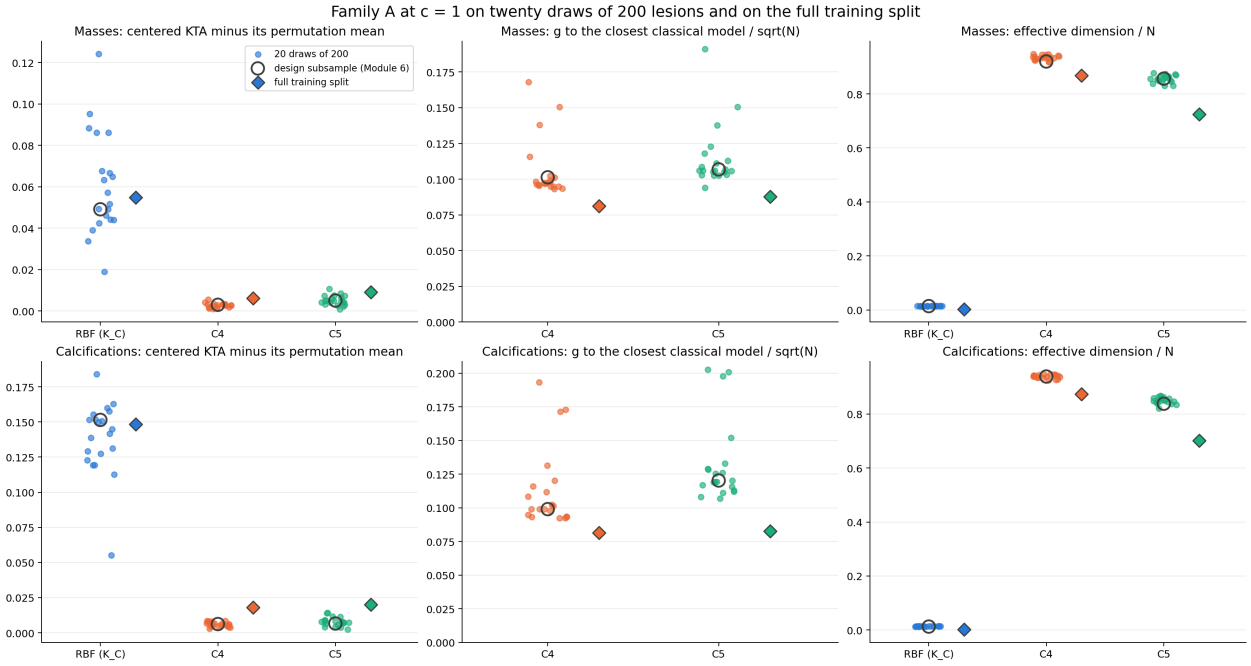


Figura 6.2.6: Métricas de la familia de kernels a $c = 1$ en 20 submuestras de 200 lesiones (puntos), la submuestra del análisis principal (círculo) y todo el conjunto de entrenamiento (rombo).

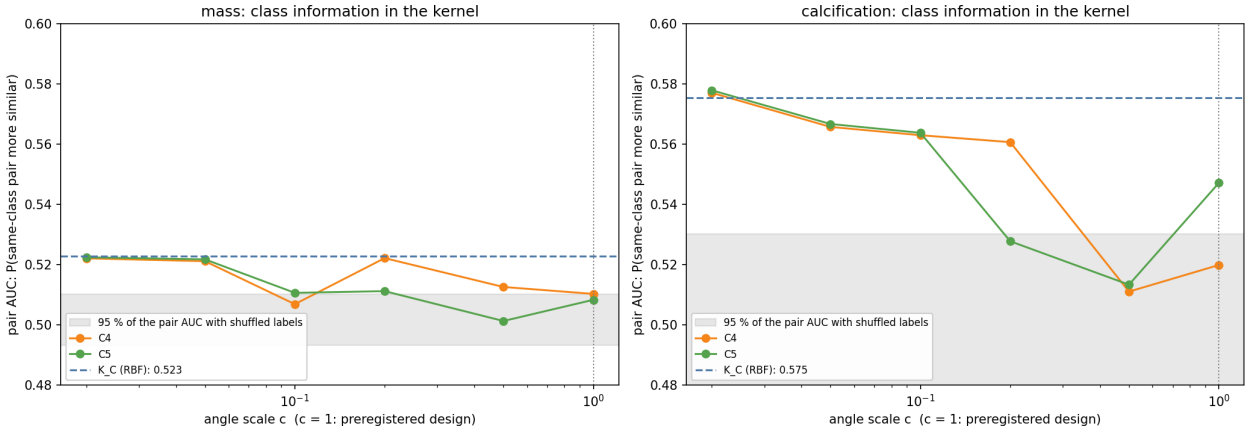


Figura 6.2.7: Evolución del AUC de pares en función del factor de escala angular c para kernels cuánticos y clásico.

la estructura de similitud suave que un kernel clásico modela de forma directa.

El experimento con un registro reducido a 8 qubits ($k = 8$) evaluó las ocho primeras características de la selección con 28 bloques *ZZ* y un circuito con 16 parámetros libres. Al reducir la dimensión, la concentración disminuye: a $c = 1$, la mediana fuera de la diagonal asciende a 0.010 en C4 y 0.0015 en C5 para masas, y a 0.008 en C4 y 0.0008 en C5 para calcificaciones; la dimensión efectiva se reduce a 140 en C4 y 103 en C5 para masas, y a 170 en C4 y 131 en C5 para calcificaciones; y el exceso de KTA se incrementa entre 1.7 y 4.6 veces (0.012 en C4 y 0.023 en C5 para masas; 0.011 en C4 y 0.024 en C5 para calcificaciones), manteniéndose por debajo del RBF (0.049 y 0.150). La diferencia geométrica mínima g se ubicó en 2.40 en C4 y 3.23 en C5 para masas, y en 1.71 en C4 y 2.16 en C5 para calcificaciones, muy por debajo de $\sqrt{N} = 14{,}1$. En las representaciones vectoriales sobre el entrenamiento completo, la condición clásica C1 mantuvo la ventaja en la razón de Fisher: 0.37 frente a 0.09 (C4) y 0.17 (C5) en masas; y 0.98 frente a 0.29 (C4) y 0.37 (C5) en calcificaciones. La síntesis comparativa se presenta en la Tabla 12 y la Figura 6.2.8.

Cuadro 12: Comparación de métricas de separabilidad entre las configuraciones con $k = 12$ y $k = 8$ qubits ($c = 1$, submuestra de 200 lesiones por subconjunto).

Métrica	Masas, $k = 12$	Masas, $k = 8$	Calcif., $k = 12$	Calcif., $k = 8$
Mediana del kernel (C4 / C5)	0.002 / 0.00003	0.010 / 0.0015	0.003 / 0.00003	0.008 / 0.0008
Dimensión efectiva (C4 / C5 de 200)	184.0 / 171.3	139.6 / 103.3	187.7 / 167.6	169.7 / 131.0
Exceso de KTA (C4 / C5)	0.003 / 0.005	0.012 / 0.023	0.006 / 0.007	0.011 / 0.024
Exceso de KTA del RBF	0.049	0.049	0.151	0.150
g mínima (C4 / C5; $\sqrt{N} \approx 14{,}1$)	1.43 / 1.51	2.40 / 3.23	1.40 / 1.70	1.71 / 2.16
Dispersión $\langle Z_i \rangle$ en todo el train (C4 / C5)	0.058 / 0.180	0.099 / 0.276	0.048 / 0.178	0.076 / 0.267
Fisher J en todo el train (C1 / C4 / C5)	0.45 / 0.13 / 0.21	0.37 / 0.09 / 0.17	1.06 / 0.42 / 0.31	0.98 / 0.29 / 0.37

En conjunto, estos hallazgos proporcionan respuesta al objetivo específico OE-3: bajo la configuración metodológica predefinida ($k = 12$, $c = 1$), las transformaciones cuánticas evaluadas no muestran una separabilidad geométrica superior a la obtenida mediante representaciones y kernels clásicos, ni en la formulación basada en fidelidades ni en la basada en valores esperados. Esta evidencia empírica describe la viabilidad y las propiedades de separabilidad del espacio de estados cuánticos generado en el contexto del problema radiómico abordado.

6.3. Clasificación

El protocolo de clasificación evalúa las cinco representaciones bajo una misma arquitectura de perceptrón multicapa ($k \to 32 \to 16 \to 1$) optimizada con entropía cruzada binaria ponderada. Los resultados sobre el conjunto de prueba oficial se detallan en el cuadro 13 y las diferencias pareadas correspondientes en el cuadro 14. En el subconjunto de masas, la condición de referencia

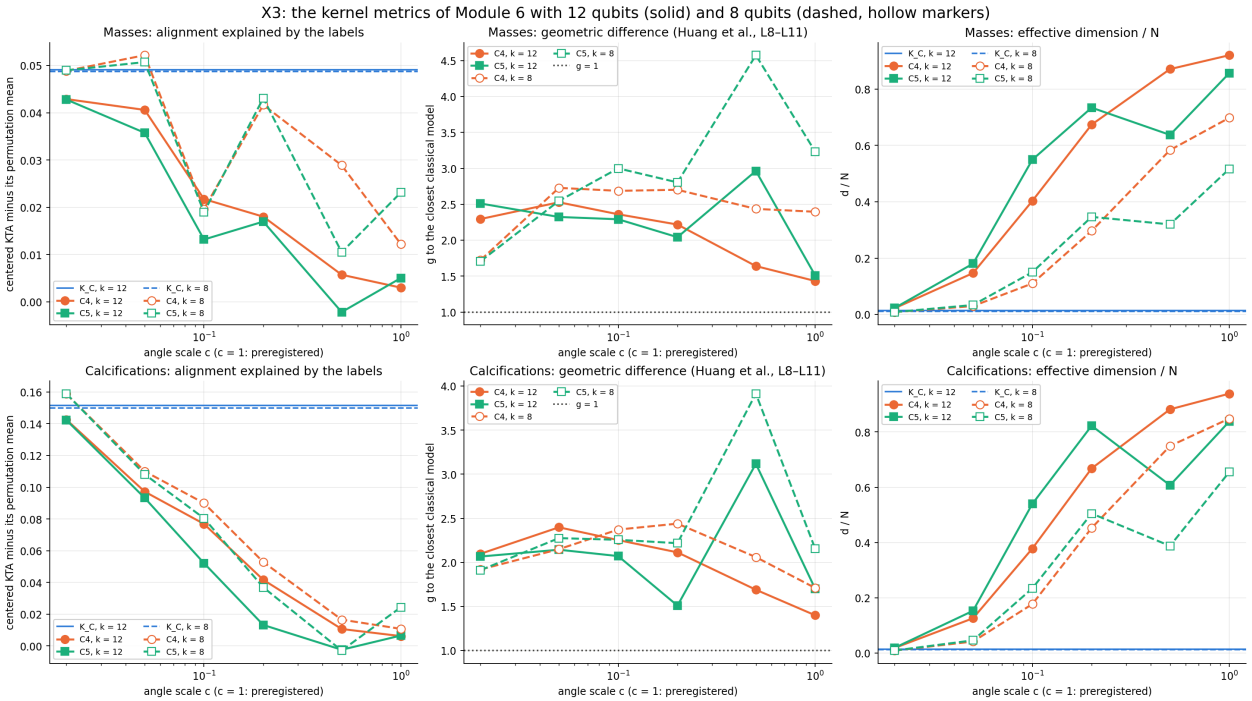


Figura 6.2.8: Comparación de métricas de separabilidad en kernels cuánticos entre configuraciones con 12 y 8 qubits.

C1 alcanza un AUC-ROC en el conjunto de prueba de 0.651 [IC 95 %: 0.578, 0.724] (0.652 $\pm$ 0.068 en validación cruzada), mientras que C2 obtiene 0.641 [0.572, 0.710] y C3 registra 0.646 [0.572, 0.721]. Las representaciones cuánticas obtienen un desempeño inferior: C4 alcanza un AUC de 0.530 [0.473, 0.587] (0.565 $\pm$ 0.079 en validación cruzada) y C5 logra 0.581 [0.521, 0.644] (0.563 $\pm$ 0.024 en validación cruzada). En masas, el clasificador sobre C4 no se distingue del azar en el conjunto de prueba.

En el subconjunto de calcificaciones, el desempeño general es más elevado en todas las condiciones. La condición C1 alcanza un AUC en el conjunto de prueba de 0.769 [0.694, 0.836] (0.742 $\pm$ 0.038 en validación cruzada), C2 obtiene 0.788 [0.719, 0.851] (0.758 $\pm$ 0.046 en validación cruzada) y C3 registra 0.758 [0.685, 0.826] (0.739 $\pm$ 0.036 en validación cruzada). Por su parte, las representaciones cuánticas descienden a 0.633 [0.558, 0.700] en C4 (0.640 $\pm$ 0.041 en validación cruzada) y a 0.652 [0.571, 0.725] en C5 (0.667 $\pm$ 0.035 en validación cruzada).

El comportamiento del control nulo resulta consistente con lo esperado: las diferencias pareadas entre C2 y C1 en el conjunto de prueba, de $-0{,}011$ [$-0{,}061$, $0{,}038$] ($p = 0{,}659$) en masas y de $0{,}020$ [$-0{,}026$, $0{,}067$] ($p = 0{,}377$) en calcificaciones, no resultan estadísticamente distinguibles de cero, como cabe esperar de una rotación, que no cambia la información disponible para el clasificador. En contraste, las representaciones cuánticas presentan pérdidas significativas respecto a C1: en masas, C4 $-$ C1 es de $-0{,}122$ [$-0{,}202$, $-0{,}044$] ($p = 0{,}003$) y C5 $-$ C1 es de $-0{,}070$ [$-0{,}140$, $-0{,}004$]

($p = 0{,}044$); en calcificaciones, C4 − C1 es de $-0{,}135$ [$-0{,}208$, $-0{,}061$] ($p = 0{,}001$) y C5 − C1 es de $-0{,}118$ [$-0{,}182$, $-0{,}046$] ($p < 0{,}001$). Frente a C3 las diferencias son comparables: en masas, $-0{,}116$ para C4 ($p = 0{,}006$) y $-0{,}065$ para C5 ($p = 0{,}058$); en calcificaciones, $-0{,}124$ para C4 ($p = 0{,}001$) y $-0{,}108$ para C5 ($p = 0{,}004$). La diferencia entre ambas condiciones cuánticas (C5 − C4) no resulta estadísticamente significativa en ninguno de los subconjuntos: 0,051 [$-0{,}027$, 0,128] en masas y 0,017 [$-0{,}061$, 0,098] ($p = 0{,}679$) en calcificaciones.

Al considerar el problema de comparaciones múltiples sobre la familia de las cuatro diferencias cuánticas frente a C1 (C4 masas con $p \approx 0{,}003$, C4 calcificaciones con $p \approx 0{,}001$, C5 calcificaciones con $p < 0{,}001$ y C5 masas con $p \approx 0{,}044$), el procedimiento escalonado de Holm mantiene la significancia estadística de las cuatro diferencias a un nivel global $\alpha = 0{,}05$. Bajo la corrección más estricta de Bonferroni ($0{,}044 \times 4 \approx 0{,}18$), la diferencia de C5 en masas se sitúa en el límite y deja de ser estadísticamente significativa.

Cuadro 13: Clasificación con el mismo MLP sobre las cinco representaciones (M7, $k = 12$).

Condición	AUC en VC	AUC en prueba [IC 95 %]	F1	Exactitud	Precisión	Sensibilidad
Masas						
C1	0.652 ± 0.068	0.651 [0.578, 0.724]	0.519	0.638	0.536	0.503
C2	0.641 ± 0.059	0.641 [0.572, 0.710]	0.512	0.616	0.507	0.517
C3	0.648 ± 0.055	0.646 [0.572, 0.721]	0.502	0.606	0.493	0.510
C4	0.565 ± 0.079	0.530 [0.473, 0.587]	0.386	0.529	0.392	0.381
C5	0.563 ± 0.024	0.581 [0.521, 0.644]	0.456	0.571	0.450	0.463
Calcificaciones						
C1	0.742 ± 0.038	0.769 [0.694, 0.836]	0.665	0.666	0.551	0.837
C2	0.758 ± 0.046	0.788 [0.719, 0.851]	0.669	0.693	0.584	0.783
C3	0.739 ± 0.036	0.758 [0.685, 0.826]	0.652	0.653	0.541	0.822
C4	0.640 ± 0.041	0.633 [0.558, 0.700]	0.504	0.607	0.504	0.504
C5	0.667 ± 0.035	0.652 [0.571, 0.725]	0.565	0.571	0.472	0.705

VC: media $\pm$ desviación estándar sobre los 5 folds de M4. Prueba: el conjunto oficial, usado una sola vez por modelo; el intervalo es un *bootstrap* por paciente con 2,000 réplicas. Umbral de 0.5 para F1, exactitud, precisión y sensibilidad.

Cuadro 14: Diferencias pareadas de AUC en el conjunto de prueba (M7).

Comparación	Diferencia	IC 95 %	p bilateral
Masas			
C4 − C1	−0.122	[−0.202, −0.044]	0.003
C4 − C3	−0.116	[−0.193, −0.041]	0.006
C5 − C1	−0.070	[−0.140, −0.004]	0.044
C5 − C3	−0.065	[−0.139, 0.002]	0.058
C2 − C1	−0.011	[−0.061, 0.038]	0.659
C3 − C1	−0.005	[−0.044, 0.032]	0.796
C5 − C4	0.051	[−0.027, 0.128]	0.180
Calcificaciones			
C4 − C1	−0.135	[−0.208, −0.061]	0.001
C4 − C3	−0.124	[−0.195, −0.051]	0.001
C5 − C1	−0.118	[−0.182, −0.046]	<0.001
C5 − C3	−0.108	[−0.177, −0.035]	0.004
C2 − C1	0.020	[−0.026, 0.067]	0.377
C3 − C1	−0.010	[−0.034, 0.014]	0.377
C5 − C4	0.017	[−0.061, 0.098]	0.679

Las diferencias usan las mismas réplicas del *bootstrap* por paciente para ambas condiciones. $p \approx 2\,\mathrm{mín}(q, 1-q)$, con q la fracción de réplicas con diferencia positiva; no está corregido por comparaciones múltiples.

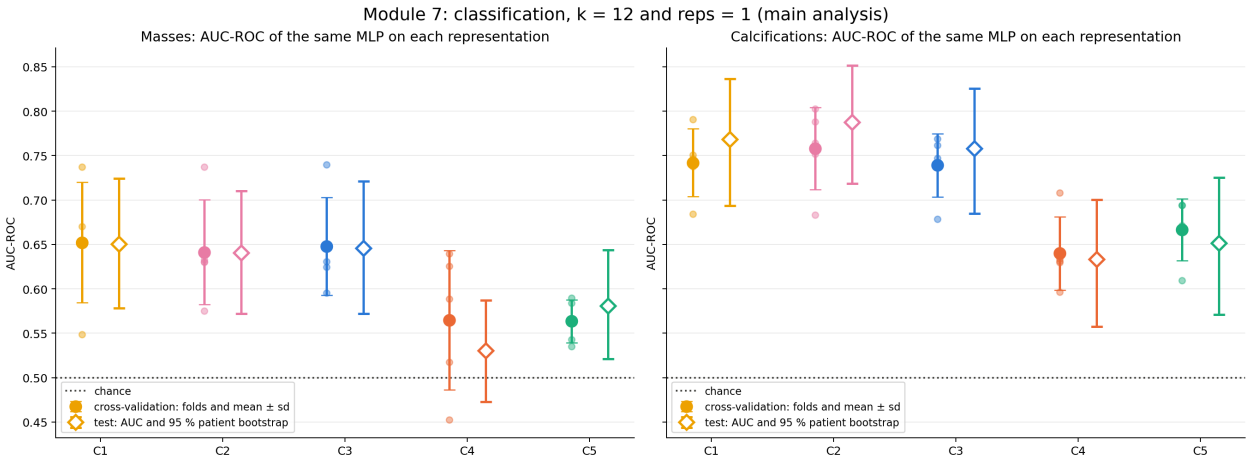


Figura 6.3.1: Comparación de AUC-ROC entre las cinco condiciones evaluadas en validación cruzada y en el conjunto de prueba para masas y calcificaciones.

El análisis de sensibilidad indica que la brecha observada entre condiciones clásicas y cuánticas se mantiene estable ante las variaciones evaluadas en la inicialización estocástica, la arquitectura de capas, la estandarización de las entradas y el régimen de épocas de entrenamiento. La dispersión

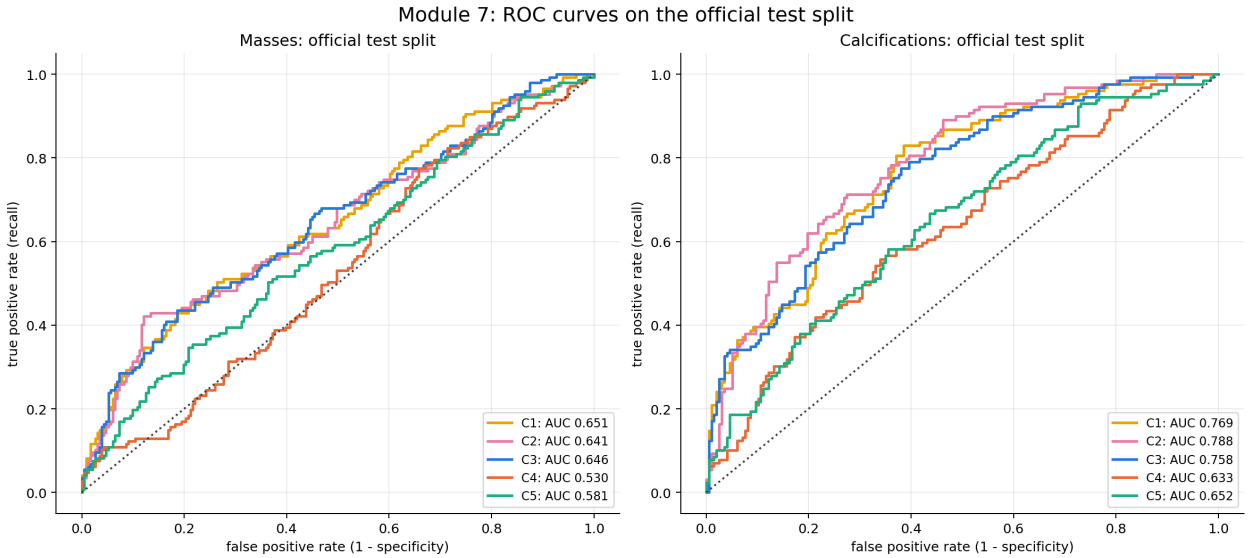


Figura 6.3.2: Curvas ROC sobre el conjunto de prueba oficial para masas y calcificaciones bajo las cinco condiciones de representación.

del AUC medio en validación cruzada atribuible a la semilla del clasificador (semillas 42 a 46) no excede 0.039 en ninguna condición, lo que representa menos de la mitad de la brecha observada entre las condiciones clásicas y cuánticas (0.08 a 0.10). El empleo de arquitecturas alternativas de perceptrón multicapa (16-8 y 64-32) y el entrenamiento sin estandarización previa de entradas preservan exactamente el orden relativo de las condiciones. Por otra parte, forzar el entrenamiento a 200 épocas sin parada temprana no favorece a los modelos cuánticos: C4 y C5 deterioran su AUC medio a 0.533 y 0.557 en masas, y a 0.596 y 0.631 en calcificaciones, mientras que C1 se mantiene o mejora (0.680 en masas). Los modelos sobre representaciones cuánticas detienen su entrenamiento temprano debido a que la pérdida en el conjunto de validación cesa de mejorar, y no por subentrenamiento.

Al profundizar el *ansatz* a dos repeticiones (`reps` = 2), la dispersión en datos reales con el vector de parámetros θ fijado disminuye en C4 (de 0.058 a 0.047 en masas) y se incrementa en C5 (de 0.180 a 0.196). En clasificación, C5 mejora en el conjunto de prueba (de 0.581 a 0.603 en masas y de 0.652 a 0.682 en calcificaciones), si bien sus intervalos de diferencia frente a C1 se mantienen negativos: $-0{,}048$ $[-0{,}093, -0{,}005]$ en masas y $-0{,}086$ $[-0{,}141, -0{,}034]$ en calcificaciones. La condición C4 no presenta cambios apreciables. Finalmente, al reducir la dimensionalidad a $k = 8$ qubits, las condiciones clásicas prácticamente no varían, mientras que C4 tiende a empeorar en calcificaciones, alcanzando 0.561 en el conjunto de prueba con una diferencia de $-0{,}070$ $[-0{,}141, +0{,}0005]$ respecto a $k = 12$, cuyo intervalo llega al cero. En este régimen de $k = 8$, las condiciones cuánticas se ubican entre 0.07 y 0.19 por debajo de C1 en el conjunto de prueba, lo cual es consistente con la observación de que una mayor dispersión geométrica en el espacio de expectativas no

garantiza una mejora en la capacidad de discriminación del clasificador supervisado.

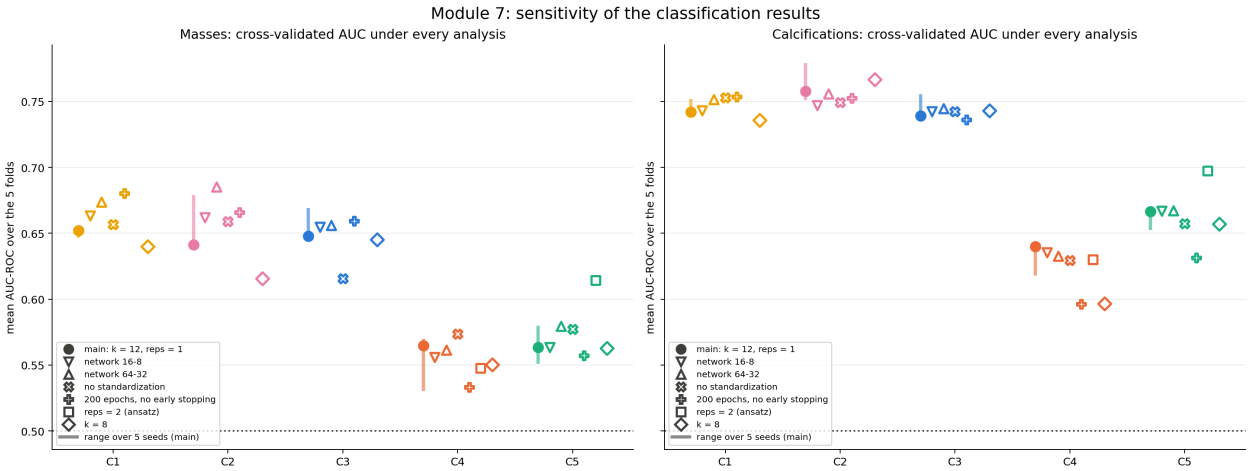


Figura 6.3.3: Análisis de sensibilidad del rendimiento de clasificación frente a cambios de semilla, arquitectura de red, escalado, épocas fijas, profundidad de circuito (`reps = 2`) y dimensión de entrada ($k = 8$).

Cuadro 15: Dependencia del AUC de C4 y C5 respecto al sorteo de θ: 10 sorteos, mismo MLP y mismos folds que el M7.

Subconjunto	Mapa	Semilla 42 (lugar)	Mín.–máx.	Rango (θ)	Rango (MLP)	C1 − mejor
Masas	C4	0.565 (6.º)	0.546–0.589	0.042	0.039	0.064
Masas	C5	0.563 (9.º)	0.557–0.624	0.068	0.029	0.028
Calcificaciones	C4	0.640 (6.º)	0.566–0.676	0.110	0.022	0.066
Calcificaciones	C5	0.667 (1.º)	0.627–0.667	0.040	0.018	0.075

AUC medio en validación cruzada; el conjunto de prueba no se usó. Rango (MLP): variación entre las 5 semillas del MLP con el θ del diseño.

La evaluación de diez sorteos aleatorios independientes del vector de parámetros θ (semillas 42 a 51) sobre los mismos pliegues de validación cruzada revela que θ constituye una fuente de variación relevante, como se expone en el cuadro 15. El rango de variación del AUC debido a la elección de θ oscila entre 0.040 y 0.110 (0.042 en C4 masas, 0.068 en C5 masas, 0.110 en C4 calcificaciones y 0.040 en C5 calcificaciones), igualando o superando la variación inducida por la semilla del clasificador (0.018 a 0.039). La semilla 42 establecida en el diseño inicial no constituye un caso sesgado: ocupa la sexta posición en C4 para ambos subconjuntos, la novena en C5 masas y la primera en C5 calcificaciones. Fundamentalmente, ninguno de los 40 sorteos evaluados alcanza el AUC de C1 (0.652 en masas y 0.742 en calcificaciones) ni de C3: el mejor sorteo queda entre 0.028 y 0.075 por debajo de C1, y el déficit frente a C1 se sitúa entre 0.03 y 0.18 según el sorteo. Asimismo, la correlación de Spearman entre la dispersión de $\langle Z_i \rangle$ y el AUC entre sorteos resulta no

significativa en todos los casos ($p > 0{,}29$: 0.09 y $-0{,}02$ en masas; 0.03 y $-0{,}37$ en calcificaciones). Cabe destacar que los productos internos y las matrices de kernel no dependen de θ, dado que el operador unitario $V(\theta)$ se cancela en el cálculo de fidelidades ($V(\theta)^{\dagger}V(\theta) = I$).

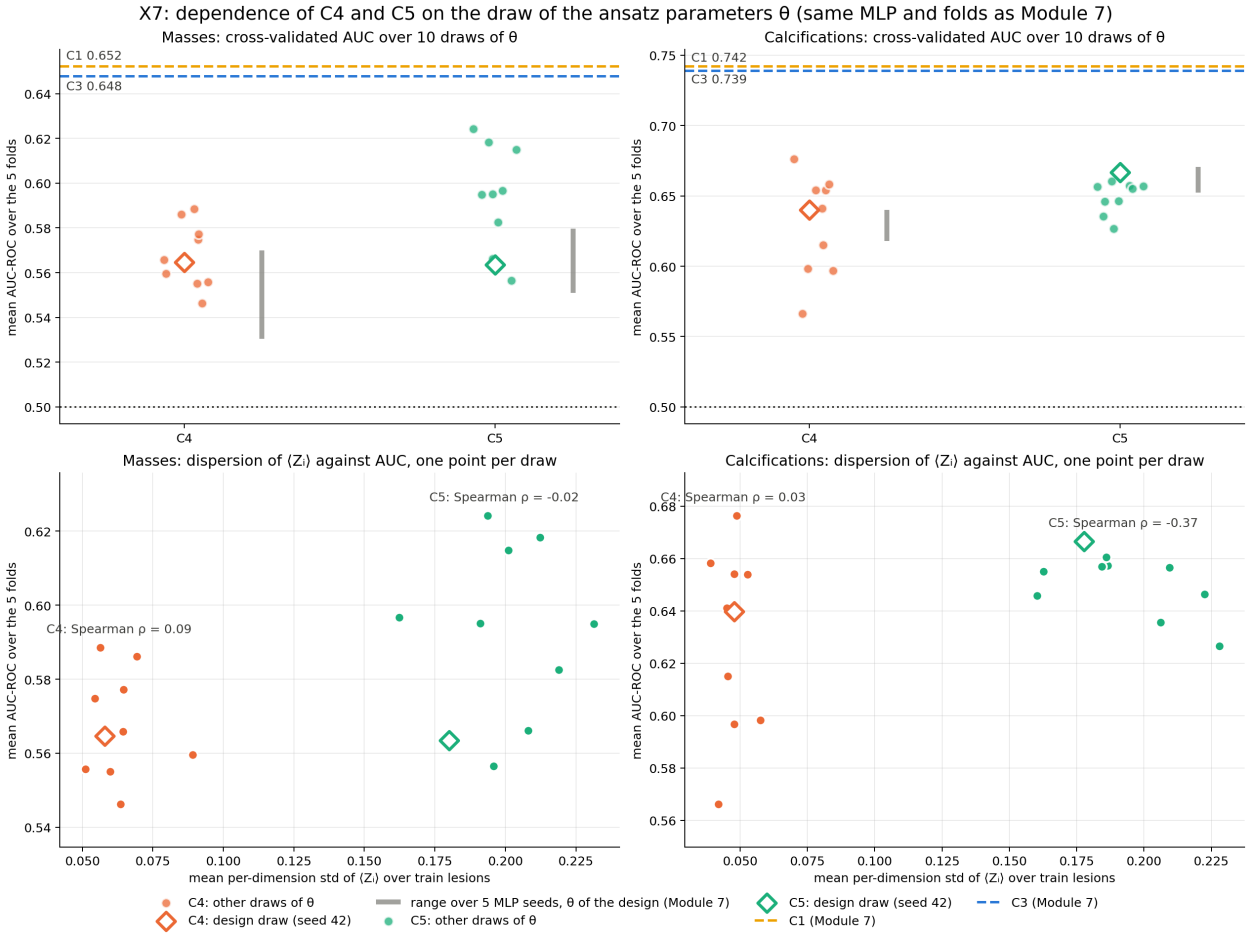


Figura 6.3.4: Distribución del AUC en validación cruzada a lo largo de diez sorteos aleatorios independientes de θ para C4 y C5 en masas y calcificaciones.

Cuadro 16: Efecto de entrenar θ junto con el MLP: de θ fijo (M7) a θ entrenado.

Mapa	AUC en VC	AUC en prueba	IC 95 % (entrenado)	Entrenado − C1 en prueba
Masas				
C4	$0.565 \rightarrow 0.568$	$0.530 \rightarrow 0.533$	[0.468, 0.598]	-0.118 [-0.194, -0.043]
C5	$0.563 \rightarrow 0.612$	$0.581 \rightarrow 0.585$	[0.518, 0.656]	-0.066 [-0.116, -0.019]
Calcificaciones				
C4	$0.640 \rightarrow 0.694$	$0.633 \rightarrow 0.674$	[0.593, 0.750]	-0.094 [-0.154, -0.033]
C5	$0.667 \rightarrow 0.687$	$0.652 \rightarrow 0.671$	[0.588, 0.745]	-0.098 [-0.147, -0.048]

Mismo protocolo que el M7; solo cambia que θ se entrena desde el sorteo del diseño, con gradientes exactos del simulador.

El entrenamiento conjunto de los parámetros θ junto con los pesos del clasificador, partiendo del sorteo inicial de diseño, produce únicamente ganancias marginales que no resultan estadísticamente significativas, según se muestra en el cuadro 16. En el conjunto de prueba, la ganancia en AUC respecto a θ fijo es de $+0{,}003$ $[-0{,}06, 0{,}07]$ en C4 masas (0.530 a 0.533), $+0{,}004$ $[-0{,}05, 0{,}06]$ en C5 masas (0.581 a 0.585), $+0{,}041$ $[-0{,}03, 0{,}10]$ en C4 calcificaciones (0.633 a 0.674) y $+0{,}020$ $[-0{,}04, 0{,}08]$ en C5 calcificaciones (0.652 a 0.671), abarcando en todos los casos el cero. Las cuatro combinaciones continúan ubicándose por debajo de C1 en el conjunto de prueba, con intervalos que excluyen el cero (diferencias de $-0{,}118$, $-0{,}066$, $-0{,}094$ y $-0{,}098$). Los parámetros θ experimentan desplazamientos medios reducidos (0.13 a 0.39 radianes) y la época óptima de validación se alcanza entre la 4 y la 27, indicando que los 24 parámetros adicionales aportan sobreajuste antes que capacidad discriminativa generalizable.

En términos de viabilidad computacional, la obtención del gradiente exacto mediante la regla de *parameter-shift* (el procedimiento exigido en procesadores cuánticos físicos, con evaluaciones en $\pm\pi/2$) demanda 48 ejecuciones de circuito por lesión (5.2 s por muestra a $k = 12$). Esto proyecta un coste de aproximadamente 205 horas de simulación por mapa de características para 50 épocas sobre el conjunto de entrenamiento. En contraste, la diferenciación automática por retropropagación analítica sobre el vector de estado en el simulador ejecuta cada muestra en 1.4 ms (3 600 veces más rápido, completando 50 épocas en 3.4 minutos) y reproduce el Jacobiano con una discrepancia numérica de apenas $1{,}8 \times 10^{-15}$. No obstante, este atajo analítico solo es posible en simulación clásica mediante el acceso a las 4 096 amplitudes complejas del estado, y no existe en un computador cuántico real debido al colapso del estado inducido por la medición.

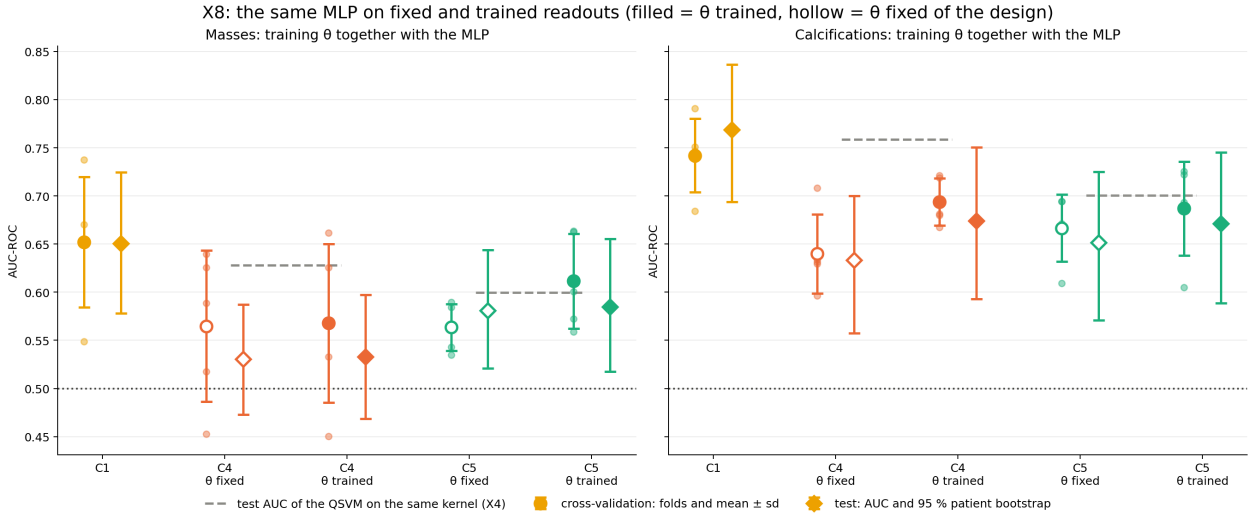


Figura 6.3.5: Desempeño de clasificación al entrenar los parámetros variacionales θ junto con la red neuronal en comparación con θ fijo, la referencia clásica C1 y el clasificador de kernel cuántico.

6.4. Clasificadores de kernel y búsqueda de ventaja

Para dilucidar si el rendimiento inferior observado en el perceptrón multicapa obedece a la codificación cuántica de los datos o al método de lectura, se evaluó un clasificador de vectores de soporte con kernel cuántico (QSVM) con regularización $C = 1$ y escala fija $c = 1$. En el conjunto de prueba oficial, el SVM clásico con kernel de base radial (RBF) alcanza un AUC-ROC de 0.649 [IC 95 %: 0.57, 0.73] en masas y de 0.769 [0.70, 0.83] en calcificaciones. El QSVM evaluado sobre el kernel cuántico de la condición C4 obtiene 0.628 [0.55, 0.70] en masas y 0.759 [0.69, 0.83] en calcificaciones, mientras que con el kernel de C5 logra 0.599 [0.52, 0.68] y 0.701 [0.62, 0.78]. La diferencia pareada entre el QSVM sobre C4 y el SVM RBF clásico resulta estadísticamente indistinguible de cero: $-0{,}02$ [$-0{,}05$, 0,01] en masas y $-0{,}01$ [$-0{,}04$, 0,02] en calcificaciones.

En contraste, al comparar el QSVM sobre el kernel de C4 frente al clasificador entrenado sobre las expectativas locales $\langle Z_i \rangle$ de C4 (AUC de 0.530 [0.47, 0.59] en masas y 0.633 [0.56, 0.70] en calcificaciones), el QSVM supera al modelo sobre expectativas en $+0{,}10$ [0,03, 0,17] en masas y en $+0{,}13$ [0,05, 0,20] en calcificaciones. Esta comparación sugiere que el kernel cuántico retiene una información diagnóstica comparable a la del kernel clásico en la muestra evaluada, y que la pérdida del perceptrón se produce al reducir el estado de 4 096 amplitudes a las 12 expectativas locales $\langle Z_i \rangle$ con θ fijo. La comparación cambia a la vez la representación y el clasificador; sin embargo, sobre las características clásicas, el perceptrón y el SVM con kernel RBF obtienen el mismo AUC (0.651 frente a 0.649 en masas y 0.769 en ambos casos en calcificaciones), por lo que el cambio de clasificador no parece explicar la diferencia. Al optimizar la escala angular c por validación cruzada, el QSVM con C4 iguala al mejor kernel clásico en el conjunto de prueba (diferencias de $-0{,}002$ en masas con $c = 0{,}05$ y $-0{,}005$ en calcificaciones con $c = 0{,}2$), en concordancia con el valor moderado de la diferencia geométrica ($g \approx 1{,}4 \ll \sqrt{N}$) formulada por Huang et al. [42].

La evaluación exploratoria incorporando la totalidad de las 67 características radiómicas extraídas tampoco evidencia ventaja computacional cuántica. El clasificador SVM RBF clásico sobre las 67 características obtiene un AUC de 0.649 en masas (diferencia de $-0{,}001$ frente a las 12 variables seleccionadas) y de 0.787 [0.73, 0.85] en calcificaciones ($+0{,}02$ [$-0{,}02$, 0,06]). La codificación en amplitudes cuánticas sobre 7 qubits genera una matriz de kernel idéntica al cuadrado de la similitud coseno (un kernel polinomial clásico de segundo grado, con discrepancia numérica de 2×10^{-16}); este mapa alcanza un AUC de 0.795 [0.73, 0.85] en calcificaciones (sin superar significativamente al RBF clásico, con diferencia de $+0{,}008$) y de 0.599 en masas (diferencia de $-0{,}05$ [$-0{,}10$, 0,00]). Por su parte, la codificación angular en producto tensorial sobre 67 qubits se concentra enteramente a escala $c = 1$ (mediana fuera de la diagonal de 0.0000), mientras que a escalas reducidas c aproxima analíticamente a un kernel gaussiano clásico ($\prod \cos^2(c\Delta_i) \approx \exp(-c^2\|\Delta\|^2)$) rindiendo

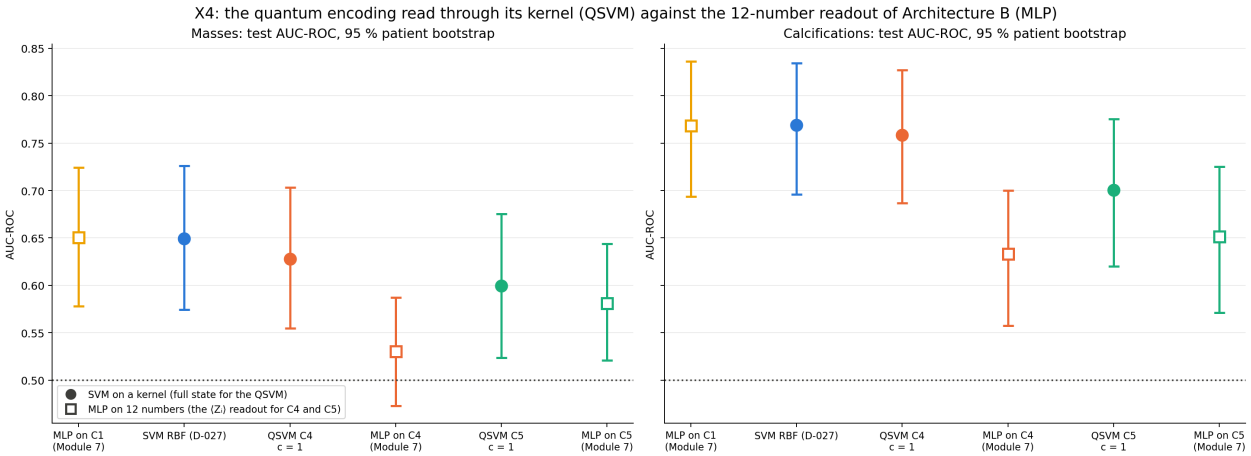


Figura 6.4.1: Comparación entre el clasificador de kernel cuántico (QSVM), el clasificador de vectores de soporte clásico (SVM RBF) y la lectura mediante expectativas locales $\langle Z_i \rangle$ con red neuronal.

a la par del SVM clásico. Un mapa con entrelazamiento completo sobre 67 variables requeriría simular $2^{67} \approx 1{,}5 \times 10^{20}$ amplitudes, resultando intratable clásicamente e inaccesible físicamente debido a la concentración exponencial [48].

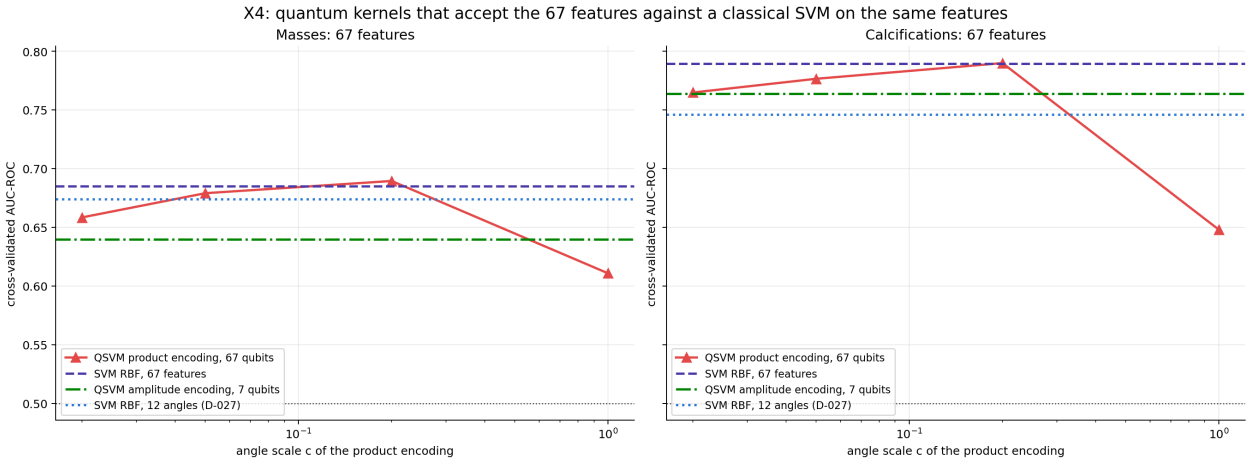


Figura 6.4.2: Rendimiento de clasificación en el conjunto de prueba al emplear las 67 características radiómicas bajo kernels clásicos, codificación en amplitudes y mapas angulares.

Con el fin de verificar que la ausencia de ventaja cuántica no se deba a anomalías de implementación, se llevó a cabo una auditoría del pipeline experimental, que superó las 25 verificaciones programadas. Estas pruebas confirmaron la integridad de las particiones y etiquetas de los 3 568 casos reconstruidos directamente desde los metadatos originales sin filtración entre conjuntos, la reproducibilidad analítica del kernel cuántico por circuitos frente al cálculo por vectores de estado (6×10^{-11}), la concordancia idéntica entre la implementación propia de SVM y la librería Qiskit Machine Learning, y la invarianza del kernel ante permutaciones de variables. Aunque dicha au-

ditoría interna fue formulada por el propio equipo de trabajo, la reproducibilidad externa queda respaldada por la re-ejecución automatizada e integral del pipeline en un entorno limpio independiente, en la cual cero cuadernos presentaron fallos y los 81 archivos de resultados junto con los 10 704 archivos de imágenes preprocesadas resultaron idénticos bit a bit.

Bajo un protocolo simétrico de validación cruzada anidada (tres pliegues internos por paciente) diseñado para buscar activamente ventaja cuántica, se contrastaron familias extendidas de kernels cuánticos y clásicos. En este procedimiento se evaluó un conjunto asimétrico compuesto por 28 candidatos cuánticos frente a 12 clásicos (140 frente a 60 ajustes considerando los pliegues de validación), una asimetría deliberada que favorece la exploración del espacio de hipótesis cuántico frente al clásico y otorga un carácter conservador a los hallazgos. En validación cruzada anidada, los contendientes clásico y cuántico alcanzan un AUC de 0.677 frente a 0.651 en masas (diferencia de $-0{,}027$ [$-0{,}043$, $-0{,}009$]) y de 0.745 frente a 0.753 en calcificaciones ($+0{,}007$ [$-0{,}007$, $0{,}023$]). En la evaluación final sobre el conjunto de prueba, el mejor modelo clásico y el mejor modelo cuántico arrojan 0.652 frente a 0.656 en masas ($+0{,}004$ [$-0{,}023$, $0{,}033$]) y 0.760 frente a 0.755 en calcificaciones ($-0{,}005$ [$-0{,}032$, $0{,}022$]).

La configuración cuántica óptima seleccionada por el procedimiento anidado converge a la equivalencia funcional con el kernel clásico: selecciona el mapa ZZ completo con escala reducida ($c = 0{,}05$ y $c = 0{,}2$), régimen en el que los términos de entrelazamiento de segundo orden se vuelven despreciables y el comportamiento emula un kernel RBF clásico. Por su parte, la hipótesis de que un entrelazamiento lineal reduciría la concentración de fidelidades resultó refutada: la mediana del kernel se reduce a 0.0001 (frente a 0.002 en el mapa completo), aproximando estados producto cuya fidelidad decae exponencialmente. Asimismo, los kernels proyectados propuestos por Huang et al. [42], si bien elevan la diferencia geométrica g a un rango de 6 a 9 y la dimensión efectiva a aproximadamente 10, obtienen el desempeño clasificatorio más deficiente sobre las etiquetas clínicas reales (AUC inferior en $-0{,}11$ en masas y $-0{,}06$ en calcificaciones respecto a los clásicos), lo cual concuerda con el marco teórico de Huang et al. [42], que establece que una diferencia geométrica elevada constituye una condición necesaria pero no suficiente para alcanzar ventaja en generalización.

Para esclarecer si la ausencia de ventaja obedece al protocolo clasificatorio o a la estructura intrínseca del problema, se aplicó a las mismas lesiones y características un etiquetado diseñado (*engineered*) según el procedimiento de Huang et al. [42], descrito en la sección 7 de su información suplementaria. Ese procedimiento busca, entre todas las formas de etiquetar las lesiones, la que mejor se ajusta al parecido que mide el kernel cuántico y peor al que mide el kernel clásico más cercano: las lesiones que el kernel cuántico considera próximas reciben valores próximos. Se obtiene

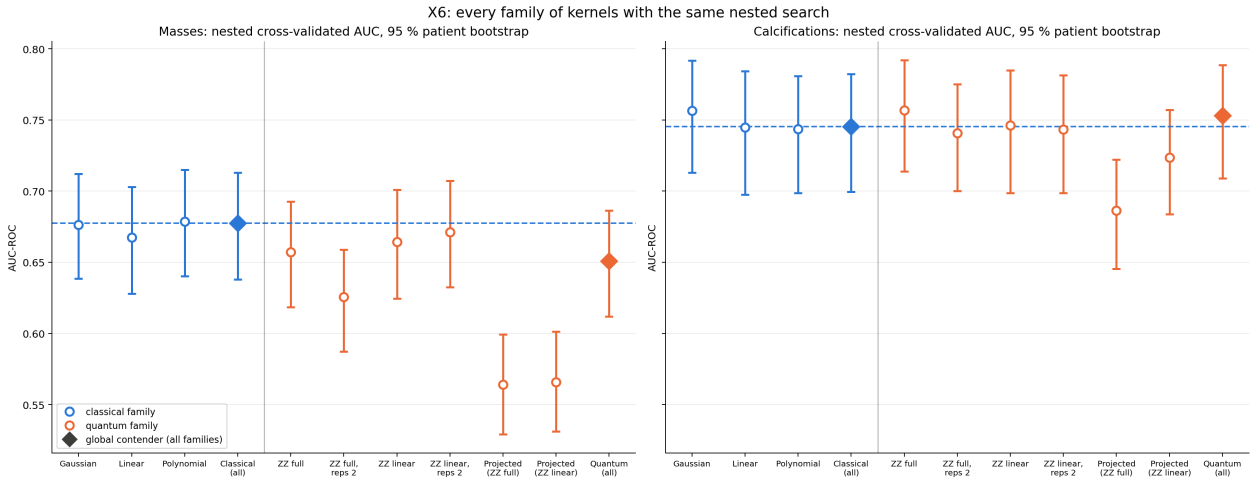


Figura 6.4.3: Búsqueda anidada sistemática de ventaja computacional cuántica: curvas de rendimiento en validación cruzada interna y evaluación pareada en el conjunto de prueba oficial.

como la solución de un problema de valores propios, $y = \sqrt{K_Q}\,\mathbf{v}$, con $\mathbf{v}$ el vector propio principal de la matriz que define la diferencia geométrica regularizada; como indica el mismo procedimiento, los valores continuos resultantes se dividen en dos clases por la mediana. Es, por construcción, el escenario más favorable para el modelo cuántico, y funciona como un control positivo del protocolo. Se evaluó solo mediante validación cruzada sobre el conjunto de entrenamiento, sin usar el conjunto de prueba. Con el etiquetado diseñado, el clasificador de kernel proyectado cuántico alcanza un AUC de 0.998 en masas y de 0.994 en calcificaciones, superando holgadamente al mejor clasificador clásico optimizado (0.800 en masas y 0.824 en calcificaciones), en agudo contraste con el rendimiento observado sobre las etiquetas diagnósticas reales (0.566 frente a 0.682 en masas; 0.667 frente a 0.759 en calcificaciones). Con el mapa ZZ completo, la ganancia con el etiquetado diseñado es menor (0.730 frente a 0.712 en masas; 0.829 frente a 0.807 en calcificaciones), acorde con su bajo valor de diferencia geométrica, que acota la ventaja máxima alcanzable con cualquier etiquetado.

Este control proporciona evidencia de que la ausencia de ventaja cuántica observada se vincula a la falta de alineación entre las etiquetas diagnósticas clínicas reales, las 12 características radiómicas seleccionadas y las familias de kernels cuánticos evaluadas (mapas ZZ con entrelazamiento completo o lineal, una o dos repeticiones, y kernels proyectados; el mapa Pauli Y-ZZ de C5 no formó parte de este barrido), y no a una incapacidad del protocolo: cuando el etiquetado se alinea con la geometría del espacio de Hilbert inducido por el circuito, el mismo protocolo sí detecta la ventaja.

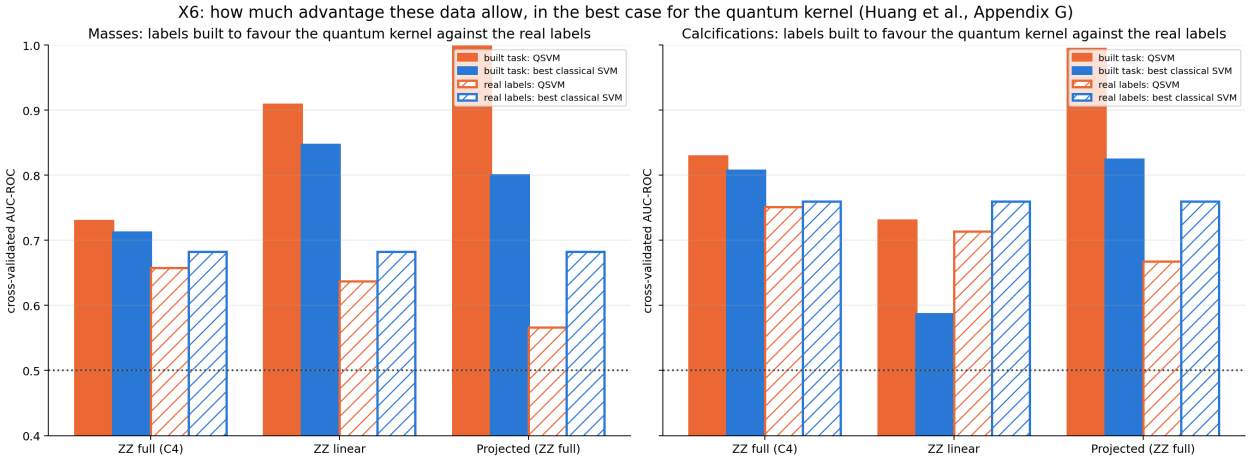


Figura 6.4.4: Desempeño clasificatorio con el etiquetado diseñado según Huang et al. a partir del kernel cuántico, en comparación con las etiquetas diagnósticas reales del CBIS-DDSM (validación cruzada sobre el entrenamiento).

6.5. Evaluación comparativa

Cuadro 17: Correlación de Spearman entre el orden de separabilidad y el de clasificación de las cinco condiciones (M8).

Subconjunto	Métrica de separabilidad	ρ_s	p exacto bilateral
Masas	Davies–Bouldin	0.718	0.167
Masas	Fisher J	0.821	0.133
Masas	KTA lineal	0.718	0.167
Calcificaciones	Davies–Bouldin	0.975	0.033
Calcificaciones	Fisher J	0.667	0.267
Calcificaciones	KTA lineal	0.975	0.033

Submuestra de 200 lesiones frente al AUC de prueba, $k = 12$. Con $n = 5$ hay 120 órdenes; ρ_s es la correlación de Pearson de los rangos promedio, porque C1 y C2 empatan. Es descriptivo: con el empate, el mejor orden alcanzable da $p = 4/120$.

La correlación de rangos de Spearman (ρ_s) entre los ordenamientos de separabilidad espacial calculados en el espacio de *embedding* y el orden de desempeño clasificatorio en el conjunto de prueba se presenta en el cuadro 17. Conforme al diseño metodológico, dicho coeficiente se evalúa de manera descriptiva: para $n = 5$ condiciones existen únicamente $5! = 120$ permutaciones posibles, y dado que las condiciones clásicas C1 y C2 empatan de forma exacta en toda métrica geométrica afín por construcción, el valor máximo teóricamente alcanzable es $\rho_s = 0{,}975$, cuya probabilidad nula exacta bilateral es $p = 4/120 \approx 0{,}033$. En la muestra primaria de 200 lesiones a $k = 12$, los

coeficientes observados son positivos en su totalidad: en masas, el índice de Davies–Bouldin arroja $\rho_s = 0{,}718$ ($p = 0{,}167$), la razón de Fisher J obtiene $\rho_s = 0{,}821$ ($p = 0{,}133$) y la alineación KTA lineal registra $\rho_s = 0{,}718$ ($p = 0{,}167$); en calcificaciones, Davies–Bouldin y KTA lineal alcanzan el acuerdo máximo posible con $\rho_s = 0{,}975$ ($p = 0{,}033$), mientras que Fisher J registra $\rho_s = 0{,}667$ ($p = 0{,}267$).

En el análisis de sensibilidad sobre los 48 coeficientes de correlación de Spearman calculados (combinando tres métricas de separabilidad, dos tamaños de muestra, dos evaluaciones de clasificación y los valores $k \in \{8, 12\}$), los valores observados resultaron sistemáticamente positivos (en el rango de 0.67 a 0.97), situando en todas las combinaciones analizadas a las tres condiciones clásicas (C1, C2 y C3) por delante de las representaciones cuánticas (C4 y C5), si bien debe tenerse en cuenta que, con solo cinco condiciones, varios de estos coeficientes individuales presentan valores de p que superan el umbral de 0.05. Las fluctuaciones menores observadas al interior de cada bloque reflejan ruido numérico propio del entrenamiento. Asimismo, en el espacio de kernels ($n = 3$), el kernel RBF clásico lidera tanto en alineamiento de matrices como en clasificación con SVM respecto a las variantes cuánticas C4 y C5. Estos resultados muestran una coherencia descriptiva entre el ordenamiento espacial de separabilidad y el rendimiento del clasificador supervisado, siendo consistentes con la ausencia de mejoras diagnósticas derivadas de las transformaciones cuánticas analizadas.

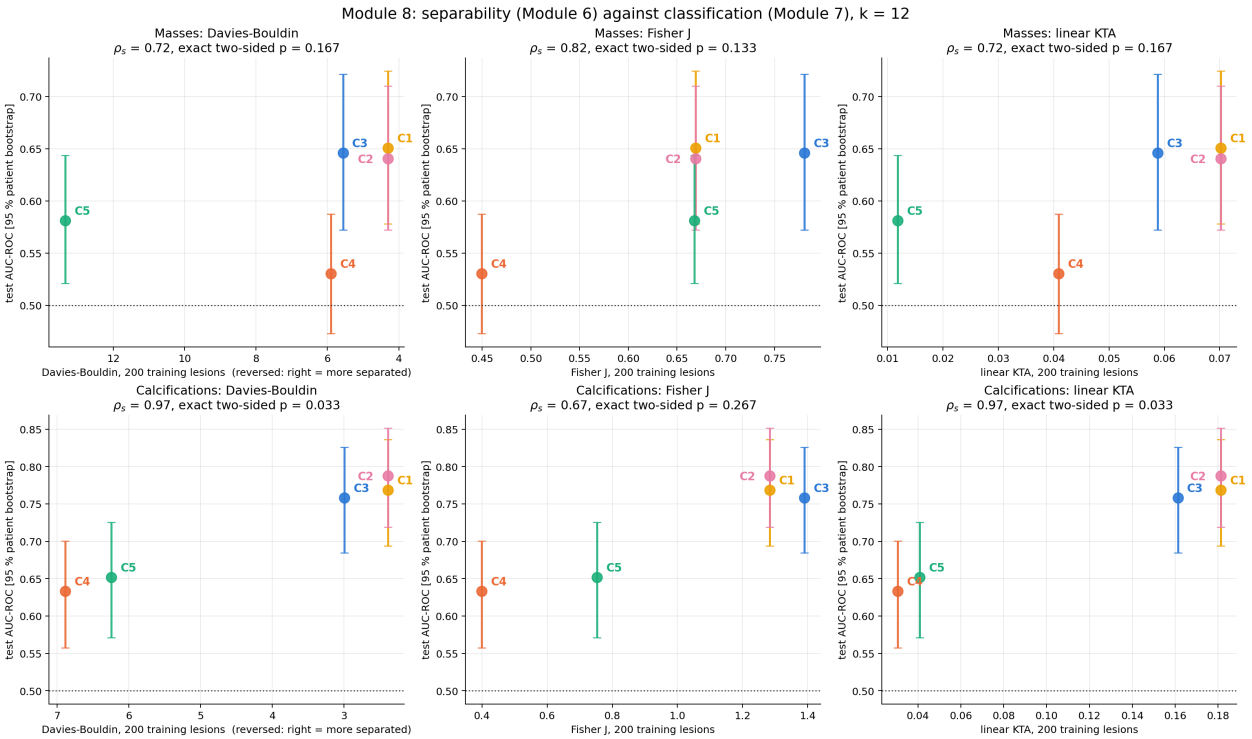


Figura 6.5.1: Correlación de Spearman entre los ordenamientos de separabilidad del espacio de estados y el desempeño de clasificación en el conjunto de prueba oficial.

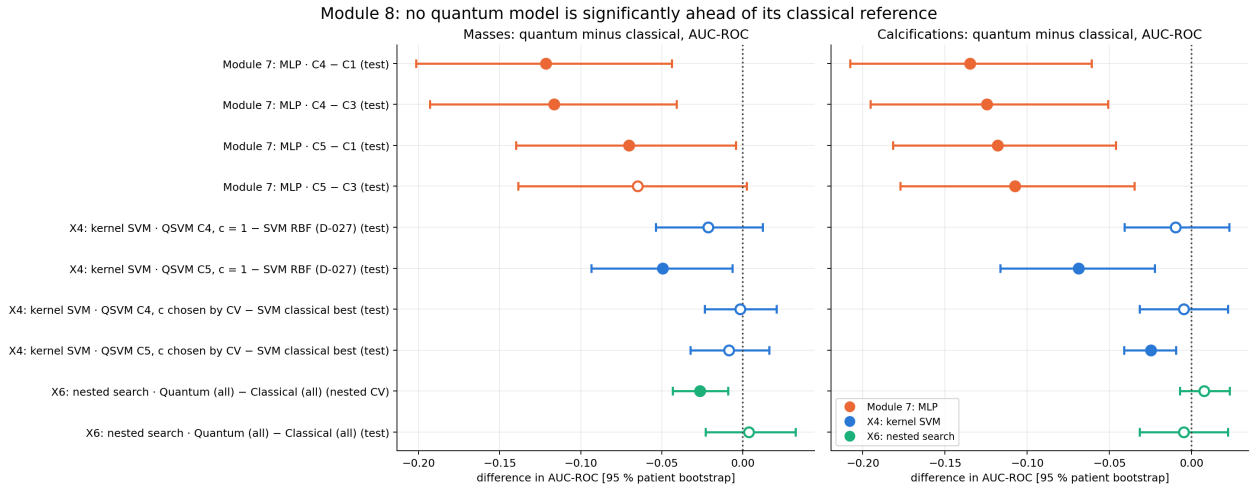


Figura 6.5.2: Dispersión bivariada y contraste pareado de métricas de separabilidad frente al AUC de clasificación entre condiciones clásicas y cuánticas.

La aparente discordancia observada entre el análisis exploratorio inicial (donde las masas exhibían patrones morfológicos distintivos que sugerían una mayor separabilidad que las calcificaciones) y el rendimiento del clasificador final se explica por la naturaleza de los descriptores radiómicos extraídos. Al evaluar una regresión logística sobre los descriptores categóricos anotados por el médico radiólogo en CBIS-DDSM (forma y margen en masas; tipo morfológico y distribución en calcificaciones), las masas constituyen el subconjunto más separable, alcanzando un AUC en validación cruzada de 0.872 frente a 0.825 en calcificaciones. Estos descriptores radiológicos operan como una referencia clínica interpretativa y no como un sistema automatizado competidor, dado que fueron asignados mediante inspección médica experta.

Al sustituir el juicio experto por las características radiómicas cuantitativas calculadas en el pipeline, el orden de dificultad se invierte: las 67 características radiómicas recuperan un AUC de 0.800 en calcificaciones (muy próximo a los 0.825 del radiólogo), pero descienden a 0.693 en masas (lejos de los 0.872 del radiólogo). Con las 12 características seleccionadas en M4, el AUC se sitúa en 0.745 en calcificaciones y en 0.668 en masas. Esta discrepancia revela que la mayor dificultad clasificatoria en masas es una propiedad de las variables radiómicas cuantitativas estándar empleadas, las cuales resumen la textura y contorno global sin capturar con la misma fidelidad los detalles finos de espiculación perilesional que distingue el ojo experto. Por otra parte, el impacto de la representación cuántica resulta equivalente en ambos subconjuntos: la brecha C4 − C1 es de $-0{,}12$ en masas y de $-0{,}14$ en calcificaciones, con medianas del kernel análogas (0.002 a 0.003 en C4; 0.00003 en C5) y diferencias geométricas similares (g entre 1.4 y 1.7), lo que indica que la asimetría de dificultad diagnóstica observada entre masas y calcificaciones se vincula primordialmente a la estructura de las variables radiómicas extraídas y no a una disparidad en la respuesta del circuito cuántico.

6.6. Restricciones del simulador (OE-6)

Para evaluar los límites de viabilidad computacional (OE-6), se cronometró la simulación de estados del circuito cuántico de C4 mediante `AerSimulator` en modo vector de estado sobre un procesador Apple M3 con 16 GiB de memoria RAM unificada para valores pares de k entre 8 y 28. A partir de estas mediciones se proyectaron los techos operacionales bajo el criterio de viabilidad de ejecución en menos de 24 horas y un consumo máximo correspondiente a la mitad de la memoria RAM disponible (8 GiB). El almacenamiento de un único vector de estado en memoria (16×2^k bytes) resulta viable hasta $k = 29$ qubits. La extracción completa de representaciones de todas las lesiones del conjunto en 24 horas admite entre 25 y 26 qubits según la carga de la máquina. El cómputo de la matriz de kernel de 200×200 mediante el protocolo físico de *compute-uncompute* soporta entre 22 y 23 qubits según la carga de la máquina, mientras que el cálculo con almacenamiento simultáneo de todos los vectores de estado en memoria alcanza hasta $k = 21$ qubits. Finalmente, el entrenamiento variacional de θ por *parameter-shift* (50 épocas, un mapa cuántico) únicamente resulta factible hasta 14–15 qubits según la carga de la máquina. A $k = 12$, el tiempo de cálculo por muestra fue de 3 ms con `AerSimulator`, 8 ms mediante el cálculo analítico de vector de estado y 93 ms mediante la primitiva de alto nivel `EstimatorQNN`.

El coste computacional escala como 2^k: a partir de 20 qubits, el tiempo se multiplica por aproximadamente 1.9 por cada qubit adicional, con unos 75 s por estado a $k = 28$; otras ejecuciones del mismo barrido dieron entre 46 y 152 s, según la carga de la máquina. Entre los factores computacionales evaluados, el cuello de botella más restrictivo para el diseño experimental no provino del número de qubits requeridos para almacenar el vector de estado ($k = 12$ se ubica por debajo del límite práctico de 25–26 qubits), sino del coste temporal del cálculo de gradientes. La estimación exacta de gradientes mediante la regla de *parameter-shift* requiere 48 evaluaciones de circuito por lesión a $k = 12$; medido en el simulador con valores exactos, son 5.16 s por lesión y unas 205 h por *feature map* para 50 épocas sobre las 2 864 lesiones de entrenamiento. Por su parte, el atajo computacional implementado mediante `FidelityStatevectorKernel` (que evalúa la matriz de 200×200 en 1.5 s mediante productos internos vectoriales frente a los 41 minutos proyectados para circuitos independientes) solo existe en simulación clásica gracias al conocimiento simultáneo de todas las amplitudes y es físicamente irrealizable en hardware cuántico, donde cada fidelidad debe estimarse mediante medición repetida de circuitos *compute-uncompute*.

El impacto del número finito de disparos (*shots*) sobre las representaciones locales $\langle Z_i \rangle$ y las matrices de kernel se modeló mediante muestreo multinomial ideal sobre las probabilidades teóricas exactas. En el espacio de *embedding*, la medición con 1 024 disparos induce un ruido estocástico que representa el 55 % y el 65 % de la dispersión entre lesiones en C4 (masas y calcificaciones,

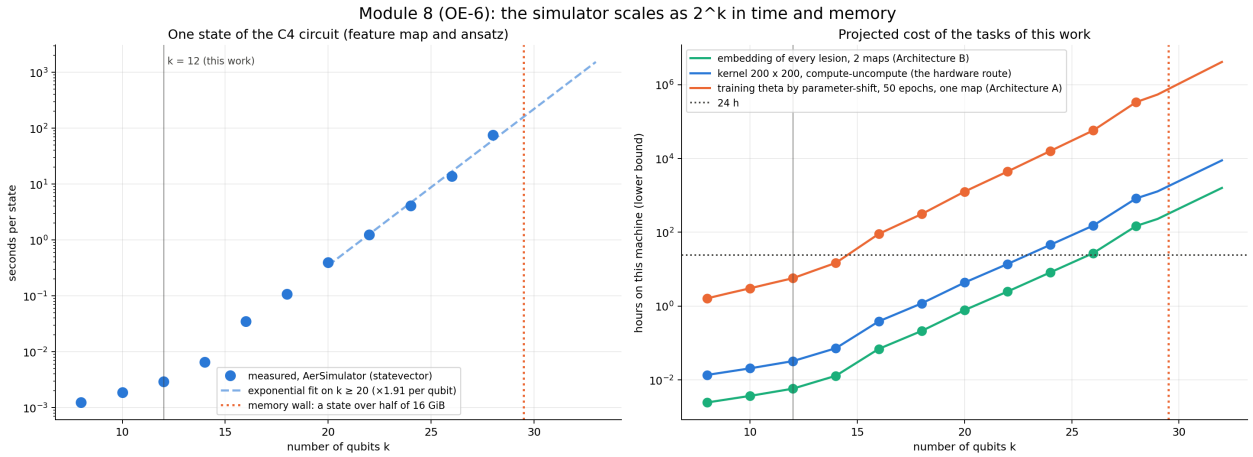


Figura 6.6.1: Escalabilidad computacional del simulador de vectores de estado en función del número de qubits (k) y proyección de límites temporales y de memoria para tareas del pipeline.

respectivamente), y el 17 % en C5. Se requerirían entre 31 000 y 44 000 disparos en C4, y entre 2 900 y 3 000 en C5, para reducir el ruido al 10 % de la dispersión entre lesiones. No obstante, el clasificador de red neuronal tolera el ruido de medición: con 1 024 disparos el AUC en validación cruzada retiene prácticamente todo el valor exacto (0.548 frente a 0.565 exacto en C4 masas; 0.630 frente a 0.640 en C4 calcificaciones; 0.565 frente a 0.563 en C5 masas; 0.654 frente a 0.667 en C5 calcificaciones), requiriendo descender a 64 disparos para observar deterioros de hasta 0.08 en AUC.

En contraste, la medición del kernel cuántico en hardware físico resulta experimentalmente inviable a escala $c = 1$. Dado que cada elemento del kernel corresponde a la probabilidad binomial de medir el estado cero ($|0 \ldots 0\rangle$), la concentración exponencial de la fidelidad hace que a 1 024 disparos por par, el 21.5 % de los pares en masas y el 15.7 % en calcificaciones lean exactamente cero en C4. Para C5, cuya fidelidad se concentra en órdenes de magnitud menores, el 74.5 % de las entradas en masas y el 71.6 % en calcificaciones arrojarían una lectura idénticamente nula. Incluso con 8 192 disparos por par, el 2.5 % de los pares en C4 masas y el 1.5 % en C4 calcificaciones registrarían cero, mientras que en C5 la fracción de lecturas nulas alcanzaría el 57.0 % en masas y el 55.9 % en calcificaciones. La mediana de disparos requerida por par para acotar el error relativo al 10 % asciende a 46 000 en C4 masas, 35 000 en C4 calcificaciones, 3.1 millones en C5 masas y 3.2 millones en C5 calcificaciones. La concentración de los valores del kernel, que a $c = 1$ reduce la información de clase del kernel cuántico sin eliminarla, es la misma propiedad que dificulta de forma crítica su estimación mediante un número realista de disparos, incluso sin el ruido propio de un dispositivo físico.

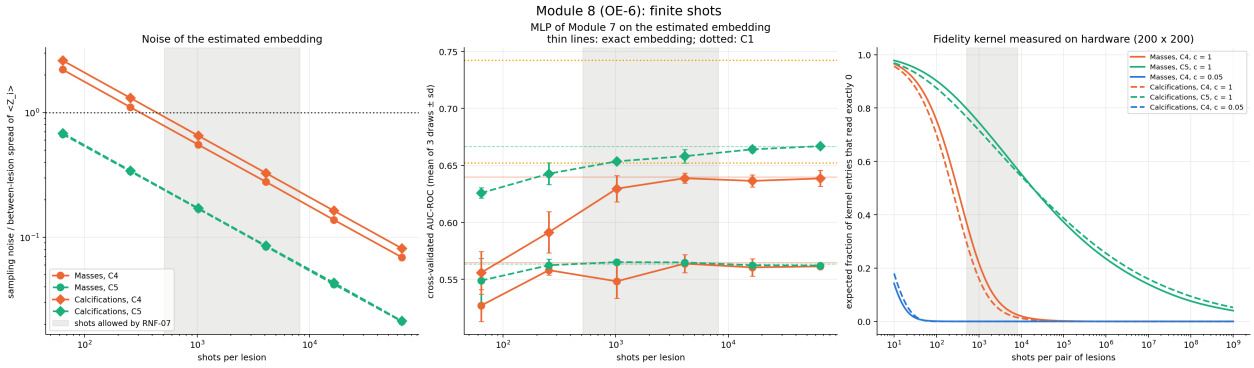


Figura 6.6.2: Efecto del número de disparos (*shots*) sobre la reconstrucción de expectativas en el espacio de estados y sobre la resolución empírica de matrices de kernel cuántico.

6.7. Hallazgos de implementación

La materialización práctica del pipeline experimental de aprendizaje automático cuántico en simulación clásica condujo al descubrimiento de un conjunto de limitaciones, ambigüedades de especificación y particularidades numéricas tanto del formalismo cuántico como de la biblioteca de desarrollo. Estos hallazgos constituyen una contribución técnica directa a la respuesta del objetivo específico OE-6, al documentar los factores que determinan la reproducibilidad y la viabilidad operacional del cómputo cuántico simulado. Para cada caso se distingue explícitamente entre propiedades fundamentales del formalismo cuántico y particularidades de implementación de la biblioteca Qiskit.

Identidad estructural entre circuitos en mapas de Pauli. Al comparar la fidelidad cuántica entre los estados generados por el mapa `zz_feature_map` (condición C4) y el mapa general `pauli_feature_map` configurado con paulis $=$ ['Z', 'ZZ'] (especificación inicial de C5), se obtuvo un valor de fidelidad idéntico a 1,000000000000 tanto para $k = 4$ como para $k = 8$. De manera concurrente, las 18 filas del análisis de complejidad de circuitos en B1 resultaron exactamente idénticas en profundidad cruda (50 a 112), profundidad transpilada (58 a 126), compuertas CX (63 a 285) y conteo total de compuertas (187 a 725). Este comportamiento obedece a un **detalle de implementación de Qiskit**: en la biblioteca, la función `zz_feature_map` está definida de forma literal como una invocación a `pauli_feature_map` con el conjunto ['Z', 'ZZ']. Por tanto, ambas opciones representaban el mismo circuito y no constituían condiciones experimentales independientes. Ante esta evidencia, se descartó esa especificación y se evaluaron configuraciones alternativas con idéntico coste de compuertas entrelazadoras ($n_{cx} = 12$) promediando sobre 200 entradas aleatorias en $[0, \pi]^4$.

Inoperancia del operador Pauli X tras la capa de Hadamard. Al formular la condición C5 me-

diante paulis = ['X', 'ZZ'] con el propósito de alternar el eje de rotación de primer orden, la fidelidad respecto a un circuito que omite por completo los términos lineales en X (un mapa puramente ZZ) arrojó un valor mínimo de 0,99999999999999 para 20 entradas al azar con $reps = 1$, y sobre las lesiones reales de masas la discrepancia máxima en las matrices de kernel fue de $5{,}9 \times 10^{-15}$. Este fenómeno corresponde a una **propiedad del formalismo cuántico**: la capa inicial de compuertas Hadamard prepara a cada qubit en el estado $|+\rangle$, el cual es autoestado de la compuerta de Pauli X con autovalor $+1$. La rotación $R_X(2x_i) = HP(2x_i)H$ actúa sobre su propio autoestado multiplicando al qubit únicamente por una fase compleja escalar. Sobre el estado producto global, estas fases individuales se agregan en una fase global indetectable que no afecta ninguna medición ni producto interno. Como consecuencia, se redefinió la condición C5 utilizando paulis = ['Y', 'ZZ'], donde la rotación en Y no preserva el autoestado ecuatorial y modifica sustantivamente la codificación previa al entrelazamiento ZZ.

Nulidad idéntica del vector de expectativas sin capa variacional. Al evaluar el vector de valores esperados $\langle Z_i \rangle$ directamente a la salida del mapa de características ZZ prescindiendo del *ansatz* variacional, el resultado fue $\langle Z_i \rangle = 0$ de forma exacta para todo qubit y cualquier vector de entrada x. Este resultado responde a una **propiedad del formalismo cuántico**: partiendo del estado de superposición uniforme $H^{\otimes k}|0\rangle$ (en el cual todas las amplitudes poseen módulo $2^{-k/2}$), todas las compuertas que componen el mapa ZZ (rotaciones de fase R_Z y bloques $CX - R_Z - CX$) son operadores diagonales en la base computacional. Las matrices diagonales multiplican cada amplitud por factores de fase compleja pero preservan de forma estricta sus magnitudes originales. Por lo tanto, la probabilidad marginal de medir cero satisface $P(\text{qubit}_i = 0) = 1/2$, lo que impone $\langle Z_i \rangle = 0$. Toda la información inyectada por el mapa reside en las fases relativas, respecto a las cuales la medición en Z es ciega. En respuesta, se concluyó que bajo la Arquitectura B el *ansatz* variacional es metodológicamente indispensable: sus parámetros θ deben fijarse con una semilla declarada (semilla 42) para que las rotaciones $R_Y(\theta)$ proyecten las diferencias de fase a poblaciones medibles. Asimismo, se clarificó que el kernel de fidelidad no sufre esta limitación al operar sobre los vectores de estado completos en el espacio de Hilbert.

Valores por defecto en estimadores y modelado de disparos en Aer. En las evaluaciones iniciales de sensibilidad al número de disparos (*shots*), el error frente a la supuesta referencia analítica se estancaba en un suelo constante de $\approx 0{,}013$ hasta un millón de disparos, y el error parecía insensible entre 512 y 8 192 disparos. Este comportamiento combinó una **propiedad del formalismo cuántico** con dos **detalles de implementación de Qiskit**. En el formalismo, la dispersión por disparos decae como $1/\sqrt{n}$ con varianza $(1 - \langle Z_i \rangle^2)/n$. En la biblioteca, la clase `EstimatorQNN` se construye con una precisión por defecto de 0,015625 ($= 1/\sqrt{4096}$) y sobrescribe cualquier precisión fijada en el estimador subyacente; al transferir dicho valor a `StatevectorEstimator`, este último

suma ruido gaussiano $\mathcal{N}(0, \text{precisión})$ incluso en simulación de vector de estado, generando un error medio analítico de $0{,}015625\sqrt{2/\pi} = 0{,}01247$ en la referencia teórica. Además, el estimador `EstimatorV2` de Aer no simula disparos discretos, sino que calcula la expectativa analítica y le adiciona ruido gaussiano continuo, generando una dependencia circular con pendiente log-log de $-0{,}5065$. En consecuencia, se invalidó aquel hallazgo preliminar y la sección de disparos de B1; para el Módulo 5 se fijó que toda expectativa exacta debe evaluarse con `Statevector` directo o primitivas con precisión cero explícita (`default_precision = 0.0`); y para modelar disparos reales en B3 y OE-6 se adoptó exclusivamente el muestreador `SamplerV2` de Aer a partir de cadenas de bits, verificando pendientes de $-0{,}4986$ en dispersión y $-0{,}4983$ en MAE sin suelo espurio hasta 2^{20} disparos.

Aceleración analítica mediante productos internos matriciales. La estimación inicial de tiempo de cálculo en B1 proyectaba aproximadamente 41 minutos por matriz de kernel cuántico de 200×200 mediante `FidelityQuantumKernel` (superando las 2.75 h para las cuatro matrices del protocolo), mientras que la implementación con `FidelityStatevectorKernel` evaluó la misma matriz exacta en 1.5 s. Este hallazgo constituye un **detalle de implementación del simulador clásico**: `FidelityQuantumKernel` construye y ejecuta circuitos cuánticos independientes de tipo *compute-uncompute* por cada par de muestras ($O(N^2)$ ejecuciones de circuito), mientras que `FidelityStatevectorKernel` aprovecha la disponibilidad simultánea de los N vectores de estado en memoria clásica ($O(N)$ simulaciones) y calcula la matriz completa mediante productos internos vectoriales directos. Se adoptó `FidelityStatevectorKernel` para agilizar los módulos M6 y derivados en más de tres órdenes de magnitud ($\sim 1\,000\times$), explicitando en el reporte que dicho atajo computacional es una ventaja exclusiva de la simulación clásica que no existe en procesadores cuánticos físicos.

Obsolescencia de `PauliFeatureMap` en Qiskit 2.x. A partir de Qiskit 2.1, la clase `PauliFeatureMap` está marcada como obsoleta en favor de la función `pauli_feature_map()`, que devuelve un `QuantumCircuit` estándar. Se trata de un **detalle de implementación de la API de Qiskit**, sin consecuencia sobre el circuito que se construye. El código del proyecto emplea las funciones `pauli_feature_map()` y `zz_feature_map()`.

6.8. Síntesis por objetivo específico

A fin de articular los hallazgos empíricos obtenidos a lo largo del protocolo experimental con los compromisos planteados al inicio de la investigación, la Tabla 18 presenta una síntesis estructurada por cada uno de los seis objetivos específicos (OE-1 a OE-6) formulados en el planteamiento del trabajo. Para cada objetivo se resume el alcance establecido, la evidencia cuantitativa central

generada, la sección del reporte donde se desarrolla el análisis detallado y la respuesta concreta alcanzada en función de los datos.

A partir de esta correspondencia empírica, la respuesta integral a la pregunta de investigación se estructura en torno a las tres dimensiones de análisis que fundamentaron el planteamiento del problema:

Dimensión de representación (OE-3). Respecto a la capacidad de las transformaciones cuánticas variacionales para generar espacios de características con mayor separabilidad de clases, la evidencia empírica indica de forma consistente que los mapas cuánticos evaluados a escala nominal ($c = 1$) no superan a las representaciones clásicas de referencia en ninguna de las familias métricas analizadas. En el espacio de kernels, el exceso de alineamiento centrado (*kernel-target alignment*, KTA) de C4 y C5 se sitúa entre 0.003 y 0.007, abarcando menos del 10 % del exceso registrado por el kernel gaussiano RBF clásico (0.049 en masas y 0.151 en calcificaciones); las matrices cuánticas resultan cercanas a la identidad con una dimensión efectiva que satura el espacio disponible ($d_{\text{eff}} \approx 168$–$188$ sobre 200), y la diferencia geométrica regularizada ($g \approx 1{,}40$–$1{,}70$) permanece muy alejada de la cota teórica de ventaja cuántica potencial ($\sqrt{N} \approx 14{,}1$). Asimismo, en las representaciones locales $\langle Z_i \rangle$, los índices de Fisher y Davies–Bouldin sitúan a las condiciones clásicas C1 y C3 sistemáticamente por delante de las condiciones cuánticas. Aunque la contracción angular ($c \to 0{,}02$) o la reducción a 8 qubits (X3) atenúan la concentración, dicha recuperación no introduce estructura cuántica genuina: el alineamiento solo se aproxima al clásico en el régimen en que el producto cruzado entre características deja de influir, emulando la geometría de un kernel clásico.

Dimensión de clasificación (OE-5). En lo concerniente a si la transformación cuántica se traduce en una mejora en la clasificación binaria de lesiones mamográficas, los resultados sobre el clasificador perceptrón multicapa muestran que el mismo modelo clasifica de manera desfavorable sobre las representaciones cuánticas C4 y C5 en comparación con las condiciones clásicas. En el conjunto de prueba independiente, las condiciones cuánticas exhiben un déficit de 0.07 a 0.14 de AUC-ROC frente al vector de características crudas C1 (alcanzando 0.530 en C4 masas y 0.633 en C4 calcificaciones, frente a 0.651 y 0.769 en C1), brecha estadísticamente significativa respaldada por intervalos de confianza por remuestreo que excluyen el cero. Este menoscabo no responde a artefactos de optimización, pues los análisis de sensibilidad sugieren que ni la variación de semillas, ni arquitecturas alternativas, ni el entrenamiento prolongado a 200 épocas sin parada temprana logran revertir la diferencia. El análisis de correlación de rangos de Spearman ($\rho_s \in [0{,}67, 0{,}97]$) muestra una coincidencia descriptiva en el ordenamiento relativo de ambas etapas (con el bloque clásico C1–C3 situado por delante de C4 y C5); no obstante, debido a que las condiciones cuánticas no alcanzaron mayor separabilidad en OE-3, no existió una ganancia representacional que pudiera

Cuadro 18: Síntesis de resultados y evidencia empírica por objetivo específico.

Objetivo	Objetivo resumido	Evidencia principal	Sección	Resultado
OE-1	Construir pipeline sobre CBIS-DDSM (DICOM, ROI, 67 variables radiómicas, selección a $k = 12$ y escalado angular $[0, \pi]$ en subproblemas independientes).	3 568 registros con cobertura DICOM 100 %; 67 variables extraídas; 12 seleccionadas retienen 86.8 % (masas) y 90.2 % (calcificaciones) de varianza; 0 solapes entre train y test.	Sección 6.1	Pipeline validado sin fuga de pacientes; selección por prueba F con filtro de redundancia ($\lvert r\rvert \leq 0{,}95$) y escalado por cuantiles con IQR de $\pi/2$.
OE-2	Implementar cinco condiciones experimentales de dimensión $k = 12$ (C1 crudo, C2 PCA lineal, C3 Kernel PCA RBF, C4 ZZFeatureMap, C5 PauliFeatureMap).	5 condiciones simétricas sobre el mismo vector; θ fijo (semilla 42) en Arquitectura B; C5 diferenciado con compuertas Y y ZZ; extracción analítica en 0.20 h frente a 381.7 h de Arquitectura A.	Secciones 5.7, 6.7	Condiciones implementadas; control nulo C2 preservado; Arquitectura B desacopla codificación de clasificación favoreciendo la reproducibilidad.
OE-3	Analizar y comparar separabilidad de clases en las cinco condiciones mediante KTA, diferencia geométrica g, Davies–Bouldin y distancia de Fisher.	A $c = 1$, exceso de KTA de 0.003 a 0.007 en C4/C5 frente a 0.049 y 0.151 en RBF; d_{eff} cuántica de 167.6 a 187.7; g mínima de 1.40 a 1.70 ($\sqrt{N} \approx 14{,}1$); condiciones clásicas superan a cuánticas en Fisher.	Sección 6.2	Las transformaciones cuánticas a $c = 1$ no muestran mayor separabilidad que las clásicas en ninguna familia métrica; matrices de kernel concentradas próximas a la identidad.
OE-4	Entrenar un mismo clasificador MLP sobre las cinco representaciones bajo idéntica arquitectura, hiperparámetros y validación cruzada 5-fold por paciente.	Red $12 \to 32 \to 16 \to 1$, optimizador Adam, parada temprana; variación máxima por semilla de 0.039 en CV; 200 épocas sin parada temprana no mejora C4/C5 (AUC 0.533 y 0.557 en masas; 0.596 y 0.631 en calcificaciones).	Sección 6.3	Protocolo simétrico validado; convergencia uniforme; el déficit cuántico no es atribuible a subentrenamiento ni a sensibilidad de hiperparámetros.
OE-5	Evaluar si la separabilidad se traslada a clasificación binaria (AUC-ROC, F1, Accuracy, Precision, Recall) y correlación de Spearman entre rankings.	En test, AUC masas: C1 0.651, C3 0.646, C4 0.530, C5 0.581; calcificaciones: C1 0.769, C3 0.758, C4 0.633, C5 0.652. Diferencias frente a C1 entre $-0{,}07$ y $-0{,}14$. Coeficiente ρ_s descriptivo en el rango de 0.67 a 0.97.	Secciones 6.3, 6.5	El MLP clasifica peor sobre C4/C5; separabilidad y clasificación coinciden en su ordenamiento (C1–C3 delante de C4–C5), pero sin ganancia previa en separabilidad que trasladar.
OE-6	Evaluar restricciones prácticas y del simulador cuántico (recursos, escalabilidad en qubits, gradientes y shots) para determinar viabilidad en salud.	Simulación exacta viable hasta $k \approx 25$ en 24 h; gradiente por *parameter-shift* requiere 5.16 s/muestra ($\sim$ 205 h a $k = 12$); a 1 024 disparos, entre 15.7 % y 74.5 % de pares del kernel leen cero; MLP tolera disparos perdiendo $< 0{,}02$ de AUC.	Secciones 6.6, 6.7	Techo práctico impuesto por gradientes físicos y concentración del kernel; fidelidad experimentalmente inmedible con disparos realistas en NISQ; atajos de simulación no trasladables a hardware.

trasladarse al desempeño diagnóstico.

Dimensión de viabilidad práctica (OE-6). En relación con la factibilidad computacional y operacional de trasladar estos esquemas a un contexto clínico real, las mediciones revelan restricciones fundamentales impuestas por el formalismo físico de la medición cuántica. Si bien el clasificador de red neuronal tolera el ruido estocástico inducido por un régimen realista de 1 024 disparos por muestra sobre las expectativas locales $\langle Z_i \rangle$ (reteniendo el AUC exacto a menos de 0.02), la estimación de matrices de kernel de fidelidad en procesadores cuánticos físicos resulta experimentalmente inviable a escala nominal ($c = 1$): debido a la concentración exponencial de la fidelidad cuántica, entre el 15.7 % y el 74.5 % de los pares de lesiones registrarían lecturas idénticamente nulas a 1 024 disparos, y acotar el error relativo al 10 % exigiría una mediana de decenas de miles de mediciones por par en C4 y de millones en C5. Asimismo, el coste computacional del gradiente exacto por *parameter-shift* (5.16 s por muestra a $k = 12$, equivalente a unas 205 h de cálculo para 50 épocas) restringe de forma severa el entrenamiento variacional en ausencia de los atajos de vector de estado analítico, los cuales solo existen en simulación clásica y son inaplicables en dispositivos cuánticos físicos.

7. Conclusiones

Este capítulo responde a la pregunta de investigación planteada en la sección 1.2 a partir de los resultados del capítulo 6. Primero se da la respuesta y se resume cómo se cumplió cada objetivo específico; después se explica por qué las transformaciones cuánticas no aumentaron la separabilidad, qué aporta el trabajo y cuáles son los límites de lo que puede afirmar. En todo el capítulo, masas y calcificaciones se tratan como subproblemas independientes, y "cuántico" se refiere a simulación clásica exacta con Qiskit Aer.

7.1. Respuesta a la pregunta de investigación

La pregunta de investigación era en qué medida las transformaciones cuánticas variacionales implementadas con *ZZFeatureMap* y *PauliFeatureMap* modifican la separabilidad de clases benigno/-maligno de características radiómicas del CBIS-DDSM, y hasta qué punto esa diferencia se refleja en la clasificación. Con el diseño fijado de antemano ($k = 12$ qubits, una repetición y escala angular $c = 1$), la respuesta es que **las transformaciones cuánticas no aumentaron la separabilidad; la redujeron**. En el espacio del kernel, el alineamiento explicado por las etiquetas de C4 y C5 fue de 0.003 a 0.007, frente a 0.049 (masas) y 0.151 (calcificaciones) del kernel RBF clásico, y la diferencia geométrica respecto al modelo clásico más cercano quedó entre 1.40 y 1.70, muy por debajo de $\sqrt{N} \approx 14{,}1$. En las representaciones que recibe el clasificador, las condiciones clásicas C1 a C3 superaron a C4 y C5 en el índice de Davies-Bouldin, en la razón de Fisher y en el alineamiento lineal, en ambos subconjuntos. La conclusión se mantuvo en 20 submuestras distintas de 200 lesiones y sobre todo el conjunto de entrenamiento.

La diferencia sí se reflejó en la clasificación, en la misma dirección. El mismo perceptrón multicapa, con idéntica arquitectura, hiperparámetros y protocolo, obtuvo en el conjunto de prueba un AUC-ROC de 0.530 (C4) y 0.581 (C5) en masas frente a 0.651 sin transformación, y de 0.633 y 0.652 en calcificaciones frente a 0.769: entre 0.07 y 0.14 menos. El ordenamiento de las condiciones por separabilidad y por clasificación coincidió en lo esencial (ρ_s entre 0.67 y 0.97, de carácter descriptivo con cinco condiciones): las representaciones clásicas van delante en ambas etapas. Lo que se trasladó a la clasificación no fue una ganancia de separabilidad, que no existió, sino su pérdida.

Bajo el marco del proyecto, este resultado es una respuesta válida a una pregunta de viabilidad, no un fracaso del sistema. El trabajo no buscaba superar a un clasificador clásico, sino medir con el mismo rigor si la codificación cuántica reorganiza las lesiones de forma más separable, y documen-

tar las restricciones que lo explican. Las secciones siguientes muestran que la respuesta negativa tiene una causa identificable y que no depende de las elecciones de diseño que podrían haberla producido.

7.2. Cumplimiento de los objetivos

La Tabla 18 resume la evidencia de cada objetivo específico. En síntesis, los seis se cumplieron:

1. **OE-1.** El *pipeline* procesa las 3 568 lesiones con cobertura DICOM completa, recorta la región de interés a resolución original, corrige las máscaras desalineadas según su tipo, extrae 67 características radiómicas y selecciona 12 por prueba F con restricción de redundancia, escaladas a $[0, \pi]$ por cuantiles y ajustadas solo con el entrenamiento, por separado para masas y calcificaciones.

2. **OE-2.** Las cinco condiciones parten del mismo vector y producen representaciones de dimensión 12. C2 funciona como control nulo: coincide con C1 en toda métrica de separabilidad hasta el límite de precisión numérica, lo que muestra que los instrumentos no reaccionan a una rotación.

3. **OE-3.** La separabilidad se midió con dos familias de métricas, sobre el kernel y sobre las representaciones, con pruebas de permutación y con la diferencia geométrica regularizada según el protocolo de Huang et al. [42]. Ninguna transformación cuántica superó a las clásicas.

4. **OE-4.** Un mismo perceptrón multicapa se entrenó sobre las cinco representaciones con validación cruzada por paciente; la conclusión resiste cambios de semilla, de arquitectura, de escalado y de duración del entrenamiento.

5. **OE-5.** Las diferencias de separabilidad se reflejaron en la clasificación en el mismo sentido, con las cinco métricas de clasificación reportadas por subconjunto.

6. **OE-6.** Se midieron las restricciones del simulador y se proyectó el número de mediciones que exigiría un procesador real. Su conclusión se desarrolla en la sección 7.4.

7.3. Por qué la codificación cuántica no aumentó la separabilidad

Los resultados apuntan a tres causas, que actúan en etapas distintas del *pipeline*.

La codificación coloca a las lesiones casi ortogonales entre sí. Con 12 qubits y ángulos en $[0, \pi]$, la fidelidad mediana entre dos lesiones distintas fue de 0.002 a 0.003 en C4 y del orden de 3×10^{-5} en C5, frente a 0.61 del kernel RBF, y la dimensión efectiva de los kernels cuánticos ocupó entre 168 y 188 de las 200 posibles. Cada lesión se parece a sí misma y a casi ninguna otra: es el régimen que Huang et al. [42] identifican como causa de una diferencia geométrica pequeña, en el que todas las entradas quedan demasiado lejos entre sí dentro de un espacio de Hilbert exponencialmente grande. Reducir la escala angular disipa la concentración, pero solo cuando el término de interacción $x_i x_j$ deja de influir: a $c = 0{,}02$ el kernel cuántico es prácticamente idéntico al de un mapa sin ese término, y el alineamiento que recupera es el que un kernel clásico ya veía. Con 8 qubits la concentración disminuye y la conclusión se mantiene.

La lectura de 12 valores esperados pierde información que el kernel conserva. Un clasificador de vectores de soporte sobre el kernel de C4 alcanzó en el conjunto de prueba 0.628 en masas y 0.759 en calcificaciones, estadísticamente indistinguible del SVM con kernel RBF (0.649 y 0.769) y entre 0.10 y 0.13 por encima del perceptrón sobre los valores esperados $\langle Z_i \rangle$ de la misma condición. El estado codificado retiene, por tanto, una información diagnóstica comparable a la clásica, y la pérdida del Módulo 7 ocurre al reducir 4 096 amplitudes a 12 observables locales. Esa pérdida no se explica por el sorteo de los parámetros de la capa variacional, que en diez sorteos dejó a C4 y C5 entre 0.03 y 0.18 por debajo de C1, ni por no entrenarlos: entrenarlos junto con el perceptrón ganó a lo sumo 0.05 de AUC, sin significancia.

Las etiquetas clínicas no se alinean con la geometría de los kernels cuánticos evaluados. Una búsqueda anidada con el mismo protocolo para ambos lados, sesgada a favor de lo cuántico en el número de candidatos, no encontró ningún kernel cuántico que superara a los clásicos con las etiquetas reales. Con un etiquetado diseñado según el procedimiento de Huang et al. [42], que asigna a las mismas lesiones las clases que mejor se ajustan a la geometría del kernel cuántico y peor a la del clásico, el kernel proyectado alcanzó en validación cruzada un AUC de 0.998 en masas y 0.994 en calcificaciones frente a 0.800 y 0.824 del mejor clásico. El protocolo, por tanto, sí detecta una ventaja cuando el etiquetado la permite; su ausencia es una propiedad de estas etiquetas y de las familias de kernels probadas, no del método de evaluación.

Ninguna de las elecciones de diseño que podían haber producido el resultado lo explica por sí sola: la conclusión se mantuvo con 8 qubits, con dos repeticiones de la capa variacional, con diez sorteos de sus parámetros, con esos parámetros entrenados, con otras submuestras y con todo el conjunto de entrenamiento.

7.4. Viabilidad práctica

En simulación, el número de qubits no fue la restricción que condicionó el diseño. En la máquina empleada, con 16 GiB de memoria, el *embedding* de todas las lesiones cabe en 24 h hasta unos 25 qubits y el kernel de 200×200 por *compute-uncompute* hasta unos 22. El límite lo impuso el gradiente: entrenar los parámetros variacionales por *parameter-shift*, la regla que funciona en *hardware*, cuesta 5.16 s por lesión a $k = 12$, unas 205 h para 50 épocas, y deja de caber en un día a partir de unos 15 qubits.

Varios de los atajos que hicieron viable el estudio solo existen en simulación. El kernel de 200×200 se calculó en 1.5 s a partir de los vectores de estado, y el gradiente por retropropagación costó unas 3 600 veces menos que por *parameter-shift*; ninguno de los dos es realizable en un procesador cuántico, porque medir colapsa el estado. En *hardware*, cada entrada del kernel es un circuito distinto que se repite con múltiples disparos: 19 900 circuitos por matriz con 200 lesiones y más de un millón con todas las calcificaciones de entrenamiento. Con 1 024 disparos, el perceptrón sobre los $\langle Z_i \rangle$ queda a menos de 0.02 del AUC exacto, pero el kernel no es medible: a $c = 1$, entre el 16 y el 74 % de sus valores leería exactamente cero. Es la situación que describen Thanasilp et al. [48], en la que con un número polinomial de mediciones las predicciones dejan de depender de los datos. La viabilidad de estas codificaciones en un contexto de salud queda condicionada, antes que al número de qubits, a evitar la concentración del kernel y a disponer de gradientes que un procesador real pueda estimar.

7.5. Aportaciones

Respuesta a las líneas abiertas por Azevedo et al. El trabajo retoma cuatro de las líneas que Azevedo et al. [15] dejaron como trabajo futuro: separar masas y calcificaciones antes de clasificar, probar otro conjunto de datos, considerar otras codificaciones y observar cómo se distribuyen los datos en el espacio de Hilbert, donde idealmente cada clase formaría un conglomerado compacto. Sobre el CBIS-DDSM, con codificaciones de mapa ZZ y de Pauli, la respuesta a la última es que las lesiones no forman conglomerados: quedan casi ortogonales entre sí, con independencia de su clase. La línea que no se abordó es la ejecución en dispositivos cuánticos con menor error.

Masas frente a calcificaciones. En validación cruzada, con los descriptores del radiólogo las masas son el subconjunto más separable (AUC de 0.872 frente a 0.825); con las 67 características radiómicas, el menos (0.693 frente a 0.800). El análisis exploratorio acertó sobre las clases, y la inversión está en las características: en calcificaciones recuperan casi toda la información de los

descriptores, y en masas mucho menos. Una hipótesis, no comprobada en este trabajo, es que los márgenes espiculados o mal definidos son detalles del borde que las características de la región completa no resumen bien. La penalización cuántica, en cambio, es similar en ambos subconjuntos: lo que cambia entre ellos es la señal clásica, no la codificación.

Un protocolo de comparación verificable. El diseño incluye un control nulo (C2) que permite comprobar que las métricas no reaccionan a transformaciones que no cambian la geometría, y aplica la diferencia geométrica con la regularización y la batería de kernels clásicos del protocolo original. Su versión sin regularizar, entre 306 y 388, es un artefacto del condicionamiento numérico del kernel clásico. Además, el alineamiento de un kernel cercano a la identidad vale aproximadamente $1/\sqrt{N}$ con cualquier etiquetado, por lo que solo es comparable su exceso sobre una prueba de permutación. Ambas precauciones son trasladables a otros estudios de kernels cuánticos.

Propiedades del formalismo y detalles de implementación. Varios hallazgos de implementación separan lo que es una propiedad de la mecánica cuántica de lo que es una convención de Qiskit. Son propiedades del formalismo que, tras la capa de Hadamard, un término en X no codifica nada porque actúa sobre un autoestado de X, y que sin capa variacional los valores esperados en Z son nulos porque las compuertas diagonales solo introducen fases. Son detalles de implementación que `PauliFeatureMap` con los términos Z y ZZ genera el mismo circuito que `zz_feature_map`, y que `EstimatorQNN` fija por omisión una precisión de 0.015625, con la que el estimador de vector de estado suma ruido gaussiano a valores que se suponían exactos. Detectarlos a tiempo evitó dos condiciones experimentales que no medían lo que pretendían. El *pipeline* completo se reproduce bit a bit en un entorno limpio.

7.6. Limitaciones

Las conclusiones anteriores están acotadas por las siguientes condiciones:

- **Un solo conjunto de datos, sin calibración física.** Todos los resultados provienen del CBIS-DDSM, sin validación externa. Sus mamografías son películas digitalizadas sin espaciado de píxel ni escala de intensidad; las características de primer orden, que lideran en masas, podrían reflejar en parte el digitalizador de origen.
- **Doce características.** Pasar de 67 a 12 características cuesta entre 2 y 4 puntos de AUC con clasificadores clásicos. La comparación es justa porque todas las condiciones parten del mismo vector, pero ese vector ya contiene menos información que el conjunto completo.
- **Dos codificaciones con una repetición.** Las conclusiones se refieren a los mapas ZZ y de

Pauli con los términos Y y ZZ, con entrelazamiento completo y una repetición, y a una capa variacional de parámetros fijos. Otras codificaciones, en particular las diseñadas a partir de la estructura del problema, podrían comportarse de otro modo.

- **Simulación ideal.** No se modeló el ruido de los dispositivos. Todo lo que se afirma sobre la ejecución en un procesador real son proyecciones a partir de un muestreo ideal de las probabilidades exactas.
- **Alcance estadístico.** Las métricas de separabilidad del análisis principal se calcularon sobre 200 lesiones de entrenamiento por subconjunto; la robustez con otras submuestras y con todo el entrenamiento confirma la conclusión, pero la significancia de los efectos más pequeños y el orden entre C4 y C5 dependen de la muestra. Los valores p son indicativos, porque se prueban muchas estadísticas; los pliegues de validación cruzada se fijaron una sola vez sobre el entrenamiento, y la correlación de Spearman, con cinco condiciones, es descriptiva.

8. Trabajo a Futuro

Las líneas siguientes parten de los resultados de este trabajo: cada una responde a una de las causas identificadas en la sección 7.3 o a una de las limitaciones de la sección 7.6. Se ordenan de la más próxima al trabajo realizado a la que exige más recursos.

8.1. Codificaciones que eviten la concentración

El factor de escala angular c funcionó en este trabajo como un análisis de sensibilidad fijado de antemano. En la literatura, ese mismo factor se estudia como el ancho de banda del kernel cuántico: Shaydulin y Wild [69] muestran que optimizarlo ayuda a mitigar el decaimiento exponencial de los valores del kernel con el número de qubits, y Canatar et al. [70], que cambiarlo puede llevar a un modelo de no poder generalizar ninguna función objetivo a generalizar bien las que están alineadas con el kernel. En este trabajo, el QSVM con c elegido por validación cruzada igualó al mejor kernel clásico, pero en un régimen en que el término de interacción entre características apenas influye. Queda por estudiar si existe un intervalo intermedio de c, o un ancho de banda distinto por característica, en el que el kernel deje de estar concentrado sin perder el término de interacción, y cómo cambia ese intervalo al aumentar el número de qubits.

El control con el etiquetado diseñado mostró que el protocolo detecta una ventaja cuando las etiquetas se alinean con la geometría del circuito. Los mapas ZZ y de Pauli, en cambio, no se diseñaron a partir de ningún conocimiento de la mamografía. Kübler et al. [71] conjeturan que los modelos cuánticos solo pueden ofrecer ventajas si se codifica en el circuito un conocimiento del problema que sería difícil codificar en un modelo clásico, y Glick et al. [51] construyen kernels a partir de la estructura de grupo de los datos. Una línea natural es diseñar codificaciones que incorporen propiedades conocidas de las lesiones, como la invariancia de la textura ante rotaciones, en lugar de mapas genéricos.

Otra opción es entrenar los parámetros de la propia codificación maximizando el alineamiento con las etiquetas, como proponen Hubregtsen et al. [53]. Thanasilp et al. [48] advierten que este entrenamiento también es susceptible a la concentración exponencial cuando los datos son clásicos, de modo que habría que vigilar la concentración durante el entrenamiento y no solo al final.

8.2. Lecturas más ricas del estado codificado

La pérdida de la clasificación ocurrió en la lectura: el kernel de C4 conserva una información comparable a la clásica, pero los 12 valores esperados locales no, ni siquiera con la capa variacional entrenada. Un paso intermedio entre ambos extremos sería leer más observables, como las correlaciones entre pares de qubits $\langle Z_i Z_j \rangle$, que añaden 66 valores con 12 qubits, y medir cuánta de la información del kernel recuperan y cuántos disparos exigen. Esta línea conserva la ventaja práctica de la Arquitectura B, que calcula la representación una sola vez, y en *hardware* evita estimar un kernel cuyas entradas se concentran cerca de cero.

8.3. Ejecución en procesadores cuánticos

La línea de Azevedo et al. [15] que este trabajo no abordó es la ejecución en dispositivos reales. Los resultados permiten planearla con cifras: con 200 lesiones, una matriz de kernel exige 19 900 circuitos, del orden de 20 millones de ejecuciones con 1 024 disparos, y a $c = 1$ una parte de sus entradas leería cero con cualquier presupuesto razonable. Un primer paso sería simular el mismo protocolo con modelos de ruido de dispositivos concretos, para separar el efecto del ruido del de la concentración; después, ejecutar sobre un procesador real los valores esperados de una muestra reducida, que toleran el muestreo, y el kernel solo en el intervalo de c en el que sea medible. El entrenamiento de parámetros variacionales en *hardware* exigiría gradientes que un procesador pueda estimar, cuyo coste por *parameter-shift* se midió en este trabajo.

8.4. Datos y características

Todas las conclusiones dependen de un solo conjunto de datos de películas digitalizadas. Repetir el estudio sobre mamografía digital con espaciado de píxel y escala de intensidad conocidos permitiría expresar las características de forma en unidades físicas, descartar la influencia del digitalizador en las de primer orden y validar los resultados de forma externa. En el lado de las características, dos resultados señalan dónde buscar: la selección de 12 de las 67 cuesta entre 2 y 4 puntos de AUC, y en masas las características radiómicas recuperan mucho menos que los descriptores del radiólogo. Las características específicas del margen de la lesión, o las extraídas por una red convolucional preentrenada, que el diseño dejó como alternativa documentada, son candidatas para cerrar esa brecha antes de cualquier codificación cuántica.

8.5. Refinamientos metodológicos

Tres refinamientos harían más precisas las estimaciones de este trabajo sin cambiar su diseño. Primero, ajustar los pliegues y toda selección dentro de una validación cruzada anidada, en lugar de fijarlos una sola vez sobre el entrenamiento. Segundo, incorporar al análisis principal la variabilidad de los parámetros variacionales y de la submuestra, que en este trabajo se midieron como análisis de robustez, y corregir los valores p por comparaciones múltiples. Tercero, extender la búsqueda anidada de ventaja al mapa de Pauli con los términos Y y ZZ, que no formó parte de ese barrido.

Referencias

[1] World Health Organization. (2025, August 14). *World Health Organization*. Retrieved from WHO Web site: https://www.who.int/news-room/fact-sheets/detail/breast-cancer

[2] Freihat, O., Sipos, D., & Kovacs, A. (2025). Global burden and projections of breast cancer incidence and mortality to 2050: a comprehensive analysis of GLOBOCAN data. *Frontiers in Public Health*, 13, 1622954. https://doi.org/10.3389/fpubh.2025.1622954

[3] Breast Cancer Research Foundation. (2025). Breast cancer statistics and resources. Retrieved from https://www.bcrf.org/breast-cancer-statistics-and-resources/

[4] Stop Breast Cancer. (2025). Facts & figures. Retrieved from https://www.stopbreastcancer.org/information-center/facts-figures/

[5] American Cancer Society. (2024). Global cancer statistics. Retrieved from https://pressroom.cancer.org/GlobalCancerStatistics2024

[6] Consultores Salud. (2025). Cáncer de mama en México. Retrieved from https://consultorsalud.com.mx/cancer-de-mama-en-mexico/

[7] Instituto Nacional de Estadística y Geografía. (2025). Estadísticas de cáncer de mama. Retrieved from https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2025/EAP_CancerMama_25.pdf

[8] National Breast Cancer Foundation. (2026). Early detection of breast cancer. Retrieved from https://www.nationalbreastcancer.org/early-detection-of-breast-cancer/

[9] National Breast Cancer Foundation. (2026). Breast cancer facts & statistics. Retrieved from https://www.nationalbreastcancer.org/breast-cancer-facts/

[10] Windsong Radiology. (2026). How early detection affects breast cancer survival rates. Retrieved from https://windsongwny.com/breast-health/how-early-detection-affects-breast-cancer-survival-rates/

[11] Instituto Nacional de Estadística y Geografía. (2023). Estadísticas de cáncer de mama. Retrieved from https://www.inegi.org.mx/contenidos/saladeprensa/aproposito/2023/EAP_CMAMA23.pdf

[12] Wang, X., Liang, G., Zhang, Y., Blanton, H., Bessinger, Z., & Jacobs, N. (2020). Inconsistent

performance of deep learning models on mammogram classification. *Journal of the American College of Radiology*, 17(6), 796-803. https://doi.org/10.1016/j.jacr.2020.01.006

[13] Kim, J., Harper, A., McCormack, V., Sung, H., Houssami, N., Morgan, E., Mutebi, M., et al. (2025). Global patterns and trends in breast cancer incidence and mortality across 185 countries. *Nature Medicine*, 31(4), 1154-1162. https://doi.org/10.1038/s41591-025-03502-3

[14] Xiang, Q., Li, D., Hu, Z., Yuan, Y., Sun, Y., Zhu, Y., Fu, Y., Jiang, Y., et al. (2024). Quantum classical hybrid convolutional neural networks for breast cancer diagnosis. *Scientific Reports*, 14(1), 24699. https://doi.org/10.1038/s41598-024-74778-7

[15] Azevedo, V., Silva, C., & Dutra, I. (2022). Quantum transfer learning for breast cancer detection. *Quantum Machine Intelligence*, 4(1), 5. https://doi.org/10.1007/s42484-022-00062-4

[16] Sáez Ortuño, L., Forgas Coll, S., & Ferrara, M. (2026). Quantum kernel methods for marketing analytics with convergence theory and separation bounds. *Scientific Reports*, 16(1), 6645. https://doi.org/10.1038/s41598-026-35793-y

[17] Alvarez-Estevez, D. (2024). Benchmarking quantum machine learning kernel training for classification tasks. arXiv preprint arXiv:2408.10274. https://doi.org/10.48550/arXiv.2408.10274

[18] Author(s). (2021). [Article title]. *AI Magazine*, 42(4), [pages]. https://doi.org/10.1080/08839514.2021.2001177

[19] Gao, Y., Lin, J., Zhou, Y., & Lin, R. (2023). The application of traditional machine learning and deep learning techniques in mammography: a review. *Frontiers in Oncology*, 13, 1213045. https://doi.org/10.3389/fonc.2023.1213045

[20] Mashekova, A., Zhao, M. Y., Zarikas, V., Mukhmetov, O., Aidossov, N., Ng, E. Y. K., & Wang, D. (2025). Review of artificial intelligence techniques for breast cancer detection with different modalities: Mammography, ultrasound, and thermography images. *Bioengineering*, 12(10), 1110. https://doi.org/10.3390/bioengineering12101110

[21] Avcı, H., & Karakaya, J. (2023). A novel medical image enhancement algorithm for breast cancer detection on mammography images using machine learning. *Diagnostics*, 13(3), 348. https://doi.org/10.3390/diagnostics13030348

[22] Añez, D., Conti, G., Uriarte, J. J., Serrano-Olmedo, J.-J., Martínez-Murillo, R., & Casanova-

Carvajal, O. (2025). Artificial intelligence pipeline for mammography-based breast cancer detection: An integrated systematic review and large-scale experimental validation. *Medicina*, 61(12), 2237. https://doi.org/10.3390/medicina61122237

[23] Abdelhafiz, D., Yang, C., Ammar, R., et al. (2019). Deep convolutional neural networks for mammography: advances, challenges and applications. *BMC Bioinformatics*, 20(Suppl 11), 281. https://doi.org/10.1186/s12859-019-2823-4

[24] Shen, L., Margolies, L. R., Rothstein, J. H., et al. (2019). Deep learning to improve breast cancer detection on screening mammography. *Scientific Reports*, 9, 12495. https://doi.org/10.1038/s41598-019-48995-4

[25] Baccouche, A., Garcia-Zapirain, B., & Elmaghraby, A. S. (2022). An integrated framework for breast mass classification and diagnosis using stacked ensemble of residual neural networks. *Scientific Reports*, 12, 12259. https://doi.org/10.1038/s41598-022-15632-6

[26] Shia, W. C. (2025). Deep learning-based classification of benign and malignant breast microcalcifications in mammography. *Scientific Reports*, 15, 42768. https://doi.org/10.1038/s41598-025-27149-9

[27] Schuld, M., & Killoran, N. (2019). Quantum machine learning in feature Hilbert spaces. *Physical Review Letters*, 122(4), 040504. https://doi.org/10.1103/PhysRevLett.122.040504

[28] Long, C., Huang, M., Ye, X., et al. (2025). Hybrid quantum-classical-quantum convolutional neural networks. *Scientific Reports*, 15, 31780. https://doi.org/10.1038/s41598-025-13417-1

[29] Radhi, E. A., Kamil, M. Y., & Mohammed, M. A. (2025). Quantum machine and deep learning for medical image classification: A systematic review of trends, methodologies, and future directions. *Iraqi Journal for Computer Science and Mathematics*, 6(2), Article 9. https://doi.org/10.52866/2788-7421.1252

[30] Nielsen, M. A., & Chuang, I. L. (2010). *Quantum computation and quantum information: 10th anniversary edition*. Cambridge University Press. https://doi.org/10.1017/CBO9780511976667

[31] Cerezo, M., Arrasmith, A., Babbush, R., Benjamin, S. C., Endo, S., Fujii, K., McClean, J. R., Mitarai, K., Yuan, X., Cincio, L., & Coles, P. J. (2021). Variational quantum algorithms. *Nature Reviews Physics*, 3, 625–644. https://doi.org/10.1038/s42254-021-00348-9

[32] Mitarai, K., Negoro, M., Kitagawa, M., & Fujii, K. (2018). Quantum circuit learning. *Physical Review A*, 98(3), 032309. https://doi.org/10.1103/PhysRevA.98.032309

[33] IBM Quantum. (2024). Qiskit Circuit Library: `zz_feature_map` and `PauliFeatureMap`. IBM Quantum Documentation. https://docs.quantum.ibm.com/api/qiskit/qiskit.circuit.library.zz_feature_map

[34] IBM Quantum. (2024). Qiskit Machine Learning: `EstimatorQNN` and `TorchConnector`. Qiskit Machine Learning Documentation. https://qiskit-community.github.io/qiskit-machine-learning/

[35] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. https://www.deeplearningbook.org

[36] Cristianini, N., Shawe-Taylor, J., Elisseeff, A., & Kandola, J. (2002). On kernel-target alignment. In *Advances in Neural Information Processing Systems (NeurIPS)*, 14. https://proceedings.neurips.cc/paper/2001/hash/1f71e393b3809197ed66df836fe833e5-Abstract.html

[37] Davies, D. L., & Bouldin, D. W. (1979). A cluster separation measure. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1(2), 224–227. https://doi.org/10.1109/TPAMI.1979.4766909

[38] Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, 7(2), 179–188. https://doi.org/10.1111/j.1469-1809.1936.tb02137.x

[39] van der Maaten, L., & Hinton, G. (2008). Visualizing data using *t-SNE*. *Journal of Machine Learning Research*, 9, 2579–2605. https://jmlr.org/papers/v9/vandermaaten08a.html

[40] Powers, D. M. W. (2011). Evaluation: from precision, recall and *F-measure* to *ROC*, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63. https://arxiv.org/abs/2010.16061

[41] Havlíček, V., Córcoles, A. D., Temme, K., Harrow, A. W., Kandala, A., Chow, J. M., & Gambetta, J. M. (2019). Supervised learning with quantum-enhanced feature spaces. *Nature*, 567, 209–212. https://doi.org/10.1038/s41586-019-0980-2

[42] Huang, H.-Y., Broughton, M., Mohseni, M., Babbush, R., Boixo, S., Neven, H., & McClean, J. R. (2021). Power of data in quantum machine learning. *Nature Communications*, 12, 2631. https://doi.org/10.1038/s41467-021-22539-9

[43] Reza, A. M. (2004). Realization of the contrast limited adaptive histogram equalization (CLAHE) for real-time image enhancement. *Journal of VLSI Signal Processing*, 38, 35–44. https://doi.org/10.1023/B:VLSI.0000028532.53893.82

[44] van Griethuysen, J. J. M., et al. (2017). Computational radiomics system to decode the radiographic phenotype. *Cancer Research*, 77(21), e104–e107. https://doi.org/10.1158/0008-5472.CAN-17-0339

[45] IBM Quantum. (2024). Basics of quantum information. IBM Quantum Learning. https://learning.quantum.ibm.com/course/basics-of-quantum-information

[46] Bray, F., Laversanne, M., Sung, H., Ferlay, J., Siegel, R. L., Soerjomataram, I., & Jemal, A. (2024). Global cancer statistics 2022: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 74(3), 229–263. https://doi.org/10.3322/caac.21834

[47] Cortes, C., Mohri, M., & Rostamizadeh, A. (2012). Algorithms for learning kernels based on centered alignment. *Journal of Machine Learning Research*, 13(28), 795–828. https://jmlr.org/papers/v13/cortes12a.html

[48] Thanasilp, S., Wang, S., Cerezo, M., & Holmes, Z. (2024). Exponential concentration in quantum kernel methods. *Nature Communications*, 15(1), 5200. https://doi.org/10.1038/s41467-024-49287-w

[49] Schuld, M., Sweke, R., & Meyer, J. J. (2021). Effect of data encoding on the expressive power of variational quantum-machine-learning models. *Physical Review A*, 103(3), 032430. https://doi.org/10.1103/PhysRevA.103.032430

[50] Liu, Y., Arunachalam, S., & Temme, K. (2021). A rigorous and robust quantum speed-up in supervised machine learning. *Nature Physics*, 17(9), 1013–1017. https://doi.org/10.1038/s41567-021-01287-z

[51] Glick, J. R., Gujarati, T. P., Córcoles, A. D., Kim, Y., Kandala, A., Gambetta, J. M., & Temme, K. (2024). Covariant quantum kernels for data with group structure. *Nature Physics*, 20(3), 479–483. https://doi.org/10.1038/s41567-023-02340-9

[52] Huang, H.-Y., Broughton, M., Cotler, J., Chen, S., Li, J., Mohseni, M., Neven, H., Babbush, R., Kueng, R., Preskill, J., & McClean, J. R. (2022). Quantum advantage in learning from experiments. *Science*, 376(6598), 1182–1186. https://doi.org/10.1126/science.abn7293

[53] Hubregtsen, T., Wierichs, D., Gil-Fuster, E., Derks, P.-J. H. S., Faehrmann, P. K., & Meyer, J. J. (2022). Training quantum embedding kernels on near-term quantum computers. *Physical Review A*, 106(4), 042431. https://doi.org/10.1103/PhysRevA.106.042431

[54] Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3, 1157–1182. https://jmlr.org/papers/v3/guyon03a.html

[55] El Hafidi, M. Y., Toufah, A., & Kadim, M. A. (2025). Investigating quantum feature maps in quantum support vector machines for lung cancer classification. *arXiv preprint* arXiv:2506.03272. https://doi.org/10.48550/arXiv.2506.03272

[56] Arrasmith, A., Cerezo, M., Czarnik, P., Cincio, L., & Coles, P. J. (2021). Effect of barren plateaus on gradient-free optimization. *Quantum*, 5, 558. https://doi.org/10.22331/q-2021-10-05-558

[57] Rifat, R. C., Tonmoy, M. T. U. I., Aziz, R. T., & Abdul Qayum, M. (2024). Enhanced hybrid quantum neural network for breast cancer detection. En *2024 27th International Conference on Computer and Information Technology (ICCIT)* (pp. 1464–1469). IEEE. https://doi.org/10.1109/iccit64611.2024.11021989

[58] Yang, J., Shi, R., Wei, D., Liu, Z., Zhao, L., Ke, B., Pfister, H., & Ni, B. (2023). MedMNIST v2 – A large-scale lightweight benchmark for 2D and 3D biomedical image classification. *Scientific Data*, 10(1), 41. https://doi.org/10.1038/s41597-022-01721-8

[59] Gillies, R. J., Kinahan, P. E., & Hricak, H. (2016). Radiomics: Images are more than pictures, they are data. *Radiology*, 278(2), 563–577. https://doi.org/10.1148/radiol.2015151169

[60] Schölkopf, B., Smola, A., & Müller, K.-R. (1998). Nonlinear component analysis as a kernel eigenvalue problem. *Neural Computation*, 10(5), 1299–1319. https://doi.org/10.1162/089976698300017467

[61] Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. https://doi.org/10.1007/BF00994018

[62] Lee, R. S., Gimenez, F., Hoogi, A., Miyake, K. K., Gorovoy, M., & Rubin, D. L. (2017). A curated mammography data set for use in computer-aided detection and diagnosis research. *Scientific Data*, 4(1), 170177. https://doi.org/10.1038/sdata.2017.177

[63] Clark, K., Vendt, B., Smith, K., Freymann, J., Kirby, J., Koppel, P., Moore, S., Phillips, S.,

Maffitt, D., Pringle, M., Tarbox, L., & Prior, F. (2013). The Cancer Imaging Archive (TCIA): Maintaining and operating a public information repository. *Journal of Digital Imaging*, 26(6), 1045–1057. https://doi.org/10.1007/s10278-013-9622-7

[64] Zwanenburg, A., Vallières, M., Abdalah, M. A., Aerts, H. J. W. L., Andrearczyk, V., Apte, A., Ashrafinia, S., Bakas, S., Beukinga, R. J., Boellaard, R., Bogowicz, M., Boldrini, L., Buvat, I., Cook, G. J. R., Davatzikos, C., Depeursinge, A., Desseroit, M.-C., Dinapoli, N., Dinh, C. V., ... Löck, S. (2020). The Image Biomarker Standardization Initiative: Standardized quantitative radiomics for high-throughput image-based phenotyping. *Radiology*, 295(2), 328–338. https://doi.org/10.1148/radiol.2020191145

[65] Preskill, J. (2018). Quantum computing in the NISQ era and beyond. *Quantum*, 2, 79. https://doi.org/10.22331/q-2018-08-06-79

[66] McClean, J. R., Boixo, S., Smelyanskiy, V. N., Babbush, R., & Neven, H. (2018). Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9(1), 4812. https://doi.org/10.1038/s41467-018-07090-4

[67] Mari, A., Bromley, T. R., Izaac, J., Schuld, M., & Killoran, N. (2020). Transfer learning in hybrid classical-quantum neural networks. *Quantum*, 4, 340. https://doi.org/10.22331/q-2020-10-09-340

[68] Schuld, M., & Killoran, N. (2022). Is quantum advantage the right goal for quantum machine learning? *PRX Quantum*, 3(3), 030101. https://doi.org/10.1103/PRXQuantum.3.030101

[69] Shaydulin, R., & Wild, S. M. (2022). Importance of kernel bandwidth in quantum machine learning. *Physical Review A*, 106(4), 042407. https://doi.org/10.1103/PhysRevA.106.042407

[70] Canatar, A., Peters, E., Pehlevan, C., Wild, S. M., & Shaydulin, R. (2022). Bandwidth enables generalization in quantum kernel models. *arXiv preprint* arXiv:2206.06686. https://doi.org/10.48550/arXiv.2206.06686

[71] Kübler, J. M., Buchholz, S., & Schölkopf, B. (2021). The inductive bias of quantum kernels. En *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)*. https://doi.org/10.48550/arXiv.2106.03747

[72] Bowles, J., Ahmed, S., & Schuld, M. (2024). Better than classical? The subtle art of benchmar-

king quantum machine learning models. *arXiv preprint* arXiv:2403.07059. https://doi.org/10.48550/arXiv.2403.07059

[73] Le, P. Q., Dong, F., & Hirota, K. (2011). A flexible representation of quantum images for polynomial preparation, image compression, and processing operations. *Quantum Information Processing*, 10(1), 63–84. https://doi.org/10.1007/s11128-010-0177-y

[74] Zhang, Y., Lu, K., Gao, Y., & Wang, M. (2013). NEQR: A novel enhanced quantum representation of digital images. *Quantum Information Processing*, 12(8), 2833–2860. https://doi.org/10.1007/s11128-013-0567-z

[75] Parigi, M., Khosrojerdi, M., Caruso, F., & Banchi, L. (2026). Analysis of quantum image representations for supervised classification. *AVS Quantum Science*, 8(1), 013801. https://doi.org/10.1116/5.0296376

[76] Elmore, J. G., Wells, C. K., Lee, C. H., Howard, D. H., & Feinstein, A. R. (1994). Variability in radiologists' interpretations of mammograms. *New England Journal of Medicine*, 331(22), 1493–1499. https://doi.org/10.1056/NEJM199412013312206

[77] Monticciolo, D. L., Malak, S. F., Friedewald, S. M., Eby, P. R., Newell, M. S., Moy, L., Destounis, S., Leung, J. W. T., Hendrick, R. E., & Smetherman, D. (2021). Breast cancer screening recommendations inclusive of all women at average risk: Update from the ACR and Society of Breast Imaging. *Journal of the American College of Radiology*, 18(9), 1280–1288. https://doi.org/10.1016/j.jacr.2021.04.021

Glosario

Pendiente. El glosario se completa a partir de los términos definidos en los capítulos 3 y 5.

A. Código de los módulos

En este anexo se presentan los fragmentos de código más representativos del pipeline experimental desarrollado en el proyecto. Todos los listados incluidos han sido extraídos de manera literal directamente desde las celdas ejecutadas de los cuadernos de trabajo (*Jupyter notebooks*) mediante la herramienta automatizada del repositorio. Las rutinas auxiliares de utilidad general localizadas en el módulo `Code/tools/` son omitidas en los listados para centrar la atención en la lógica nuclear de cada etapa.

A.1. Módulo 2: Preprocesamiento y alineación de máscaras

La función `align_mask` implementa la regla de corrección espacial para las 80 máscaras del CBIS-DDSM cuyas dimensiones difieren de la mamografía completa. Cuando el desajuste se debe a un factor de submuestreo de 0.870 se aplica interpolación al vecino más cercano, mientras que en discrepancias de resolución nativa se preserva el anclaje en la esquina superior izquierda sin remuestreo continuo.

Listado 1: Función de alineación espacial de máscaras (`Code/2_Preprocessing.ipynb`, celda de código 5).

```
def align_mask(mask, shape, kind):
    H, W = shape
    if kind == "none":
        return mask
    if kind == "scaled":
        return cv2.resize(mask, (W, H), interpolation=cv2.INTER_NEAREST_EXACT)
    out = np.zeros((H, W), mask.dtype)          # "offset": same scale, top-left anchor
    h, w = min(H, mask.shape[0]), min(W, mask.shape[1])
    out[:h, :w] = mask[:h, :w]
    return out
```

La rutina `prepare_mask` realiza el análisis morfológico de componentes conexas mediante la función `connectedComponentsWithStats` de OpenCV. Identifica la componente de mayor área como la lesión patológica principal y descarta motas satélite aisladas, registrando la distancia euclidiana máxima y el número de píxeles eliminados para control de calidad.

Listado 2: Depuración y selección de componente conexa mayor (`Code/2_Preprocessing.ipynb`, celda de código 11).

```
def prepare_mask(i):
    # Aligned, cleaned mask (uint8, 0/1) in the image space, plus cleaning diagnostics
    row = df.loc[i]
    raw = (pydicom.dcmread(row.path_roi_mask).pixel_array > 0).astype(np.uint8)
```

```
    m = align_mask(raw, (row.img_rows, row.img_cols), row.mismatch)
    n, lab, st, _ = cv2.connectedComponentsWithStats(m, connectivity=8)
    if n <= 2:
        return m, 0, 0.0
    k = 1 + int(np.argmax(st[1:, cv2.CC_STAT_AREA]))
    main = (lab == k).astype(np.uint8)
    rest = (lab > 0) & (lab != k)
    reach = cv2.distanceTransform(1 - main, cv2.DIST_L2, 5)[rest].max()
    return main, int(rest.sum()), float(reach)
```

La función `export_mammogram` formaliza el contrato de salida del Módulo 2. Calcula la caja delimitadora ajustada a la lesión depurada y le agrega un margen de seguridad de 20 píxeles por lado, extrayendo los parches sobre las intensidades crudas de 16 bits y almacenándolos en formato comprimido NRRD con espaciado espacial unitario.

Listado 3: Recorte de región de interés con margen y exportación (`Code/2_Preprocessing.ipynb`, celda de código 13).

```
def export_mammogram(item):
    path_full, idxs = item
    img = pydicom.dcmread(path_full).pixel_array
    eq = cv2.createCLAHE(clipLimit=CLAHE_CLIP, tileGridSize=CLAHE_TILES).apply(to_uint8(img))
    recs = []
    for i in idxs:
        row = df.loc[i]
        mask, _, _ = prepare_mask(i)
        y0, y1, x0, x1 = bbox(mask)
        Y0, Y1 = max(0, y0 - MARGIN), min(img.shape[0], y1 + MARGIN)
        X0, X1 = max(0, x0 - MARGIN), min(img.shape[1], x1 + MARGIN)
        base = OUT_DIR / row.finding_type / row.case_id
        paths = {k: base.with_name(f"{row.case_id}_{k}.nrrd") for k in ("image", "mask", "clahe")}
        write_nrrd(img[Y0:Y1, X0:X1], paths["image"])
        write_nrrd(mask[Y0:Y1, X0:X1], paths["mask"])
        write_nrrd(eq[Y0:Y1, X0:X1], paths["clahe"])
        recs.append(dict(i=i, crop_y0=Y0, crop_x0=X0, crop_h=Y1 - Y0, crop_w=X1 - X0,
                         margin_clipped=(Y0 > y0 - MARGIN) or (Y1 < y1 + MARGIN) or (X0 > x0 - MARGIN) or (
    X1 < x1 + MARGIN),
                         **{f"path_{k}": str(p.relative_to(DATA_DIR)) for k, p in paths.items()}))
    return recs
```

A.2. Módulo 3: Extracción de características radiómicas

La inicialización del extractor radiómico fija el parámetro `binCount=32` sobre las intensidades originales, asegurando invarianza a traslaciones lineales sin forzar un ancho fijo de contenedor. Se inhabilitan los filtros derivados complejos y se activan únicamente las cuatro familias morfológicas y texturales bidimensionales primarias (*firstorder*, *shape2D*, *glcm* y *glrlm*), totalizando 67 características.

Listado 4: Configuración del extractor PyRadiomics y activación de familias (`Code/3_Feature_Extraction.ipynb`, celda de código 3).

```
extractor = featureextractor.RadiomicsFeatureExtractor(binCount=32, force2D=True, label=1)
extractor.disableAllFeatures()
for fam in FAMILIES:
    extractor.enableFeatureClassByName(fam)

print("Settings:")
for k in ("binCount", "force2D", "distances", "normalize", "resampledPixelSpacing", "label"):
    print(f"  {k:22s}: {extractor.settings.get(k)}")
print(f"Image types: {list(extractor.enabledImagetypes)}")

probe = index.iloc[0]
probe_feats = extractor.execute(str(DATA_DIR / probe.path_image), str(DATA_DIR / probe.path_mask))
FEATURES = [k for k in probe_feats if k.startswith("original_")]
```

A.3. Módulo 4: Selección y escalado angular

La función `select` aplica un procedimiento voraz guiado por el estadístico F del análisis de varianza univariado, calculado estrictamente sobre los datos de entrenamiento. Cada variable candidata se incorpora solo si el valor absoluto de su correlación de Pearson frente a las variables ya seleccionadas no excede el límite de redundancia $|r| \leq 0{,}95$.

Listado 5: Selección voraz por F-test con restricción de redundancia lineal (`Code/4_Selection_and_Scaling.ipynb`, celda de código 5).

```
def select(ft, r_max, k=K):
    tr = data[ft][data[ft].split == "train"]
    C = tr[FEATURES].corr().abs()
    chosen, skipped = [], []
    for f in scores[ft].feature:
        clash = [(s, C.loc[f, s]) for s in chosen if C.loc[f, s] > r_max]
        if clash:
            s, r = max(clash, key=lambda c: c[1])
            skipped.append(dict(feature=f, redundant_with=s, abs_r=r))
        else:
            chosen.append(f)
        if len(chosen) == k:
            break
    return chosen, pd.DataFrame(skipped), C
```

El escalado angular utiliza `QuantileTransformer` configurado para proyectar a una distribución uniforme y multiplicado por π. Esto asegura que cada característica ocupe de forma homogénea el intervalo angular $[0, \pi]$, mitigando la influencia de asimetrías y valores atípicos sin alterar el orden relativo de las observaciones de entrenamiento.

Listado 6: Transformación angular por cuantiles acotada a $[0, \pi]$ (`Code/4_Selection_and_Scaling.ipynb`, celda de código 8).

```
    d = data[ft]
    cols = selection[ft]
    is_tr = (d.split == "train").values
    tr = d[is_tr]
    qt = QuantileTransformer(n_quantiles=min(1000, len(tr)), output_distribution="uniform",
                             subsample=10**9, random_state=SEED).fit(tr[cols].values)
    mm = MinMaxScaler(feature_range=(0, np.pi), clip=True).fit(tr[cols].values)   # comparison only
    X, Xmm = np.pi * qt.transform(d[cols].values), mm.transform(d[cols].values)
    transformers[ft], scaled[ft] = qt, X
    te_raw = d.loc[~is_tr, cols].values
```

La conformación de los pliegues de validación cruzada utiliza `StratifiedGroupKFold` para agrupar las lesiones por paciente. La rutina evalúa múltiples semillas deterministas y selecciona aquella que minimiza la desviación máxima en la proporción de malignidad entre los cinco pliegues, garantizando particiones homogéneas e independientes a nivel de sujeto.

Listado 7: Generación y balanceo de folds agrupados por paciente (`Code/4_Selection_and_Scaling.ipynb`, celda de código 9).

```
def group_folds(tr, seed):
    y, g = tr.label.values, tr.patient_id.values
    fold = np.empty(len(tr), int)
    for k, (_, va) in enumerate(StratifiedGroupKFold(N_FOLDS, shuffle=True, random_state=seed).split(tr, y,
     g)):
        fold[va] = k
    return fold


def max_dev(tr, fold):
    y = tr.label.values
    return float(np.abs(pd.Series(y).groupby(fold).mean() - y.mean()).max())
```

A.4. Módulo 5: Transformaciones cuánticas y kernels

El cálculo del embedding cuántico combina los circuitos de codificación C4 y C5 con un *ansatz* variacional `RealAmplitudes` parametrizado mediante un vector θ fijo generado con semilla 42. El valor esperado local $\langle Z_i \rangle$ se obtiene de forma exacta multiplicando la distribución de probabilidades del vector de estado por la matriz de signos.

Listado 8: Construcción de mapas cuánticos, ansatz con θ fijo y cálculo de $\langle Z_i \rangle$ (`Code/5a_Embeddings.ipynb`, celda de código 2).

```
ansatz = real_amplitudes(N_QUBITS, reps=1)
theta = np.random.default_rng(SEED).uniform(0, 2*np.pi, ansatz.num_parameters)
```

```
feature_maps = {'C4': zz_feature_map(N_QUBITS, reps=1), 'C5': pauli_feature_map(N_QUBITS, reps=1, paulis=['Y', 'ZZ'])}
basis = np.arange(2**N_QUBITS)[:, None]
signs = 1.0 - 2.0 * ((basis >> np.arange(N_QUBITS)) & 1)

def exact_embedding(feature_map, x):
    values = {p: float(v) for p, v in zip(feature_map.parameters, x)}
    values.update({p: float(v) for p, v in zip(ansatz.parameters, theta)})
    circuit = feature_map.compose(ansatz).assign_parameters(values, inplace=False)
    return Statevector.from_instruction(circuit).probabilities() @ signs
```

La computación de matrices de kernel emplea `FidelityStatevectorKernel` sobre los vectores cuánticos precomputados, optimizando el cálculo de productos internos exactos en la submuestra representativa. En paralelo, se construye el kernel clásico RBF empleando el ancho de banda óptimo determinado por la heurística de la mediana.

Listado 9: Evaluación de matrices de kernel clásico y cuántico (`Code/5b_Quantum_Kernels.ipynb`, celda de código 4).

```
feature_maps = {
    'C4': zz_feature_map(12, reps=1),
    'C5': pauli_feature_map(12, reps=1, paulis=['Y', 'ZZ']),
}
kernels, gammas, timing_rows = {}, {}, []
for finding in FINDINGS:
    feature_cols = [c for c in data[finding].columns if c.startswith('x_')]
    X_train = data[finding].loc[data[finding].split.eq('train'), feature_cols].to_numpy(dtype=float)
    train_d2 = pairwise_sqdist(X_train)
    gamma = 1.0 / (2.0 * np.median(train_d2[np.triu_indices_from(train_d2, k=1)]))
    gammas[finding] = gamma
    X = Xs[finding]
    results = {'K_C': rbf_kernel(X, gamma)}
    for name, feature_map in feature_maps.items():
        t0 = time.perf_counter()
        results[f'K_Q_{name}'] = FidelityStatevectorKernel(feature_map=feature_map).evaluate(X)
```

A.5. Módulo 6: Separabilidad geométrica

El alineamiento de matrices de kernel evalúa la correspondencia con la estructura de clases. La rutina `alignment_with_null` centra la matriz de kernel y calcula tanto la métrica empírica observada como su exceso respecto a la media de una distribución nula obtenida mediante permutaciones exhaustivas de las etiquetas binarias.

Listado 10: Centrado matricial y alineamiento kernel-objetivo con prueba de permutación (`Code/6_Separability.ipynb`, celda de código 3).

```
def center(k):
```

```
    # H K H with H = I - 11^T / n
    return k - k.mean(0) - k.mean(1)[:, None] + k.mean()


def alignment_with_null(k, y, perms):
    # uncentered and centered alignment for the observed labels y and for each permuted row of perms (labels +-1)
    n, kc = len(y), center(k)
    yc2 = np.sum((y - y.mean()) ** 2)        # ||H yy^T H||_F; the same for every permutation
    obs_u = y @ k @ y / (np.linalg.norm(k) * n)
    obs_c = y @ kc @ y / (np.linalg.norm(kc) * yc2)
    null_u = np.einsum('pi,ij,pj->p', perms, k, perms) / (np.linalg.norm(k) * n)
    null_c = np.einsum('pi,ij,pj->p', perms, kc, perms) / (np.linalg.norm(kc) * yc2)
```

La evaluación de ventaja cuántica potencial implementa la diferencia geométrica regularizada $g(K_C \,\|\, K_Q)$ descrita por Huang et al. El algoritmo computa la raíz simétrica de la matriz cuántica y diagonaliza el kernel clásico, evaluando las cotas teóricas de generalización y entrenamiento sobre una grilla de parámetros de regularización λ.

Listado 11: Cálculo de la diferencia geométrica regularizada de Huang et al. (`Code/6_Separability.ipynb`, celda de código 3).

```
def geometric_difference(kq, kc, lambdas):
    # g(K_C || K_Q): eq. (F19) for g_gen and eq. (F20) for g_tra; lambda = 0 gives the unregularized eq. (5)
    sq = psd_sqrt(kq)
    t, v = eigh(sym(kc))
    t = np.clip(t, 0, None)
    out = {}
    for lam in lambdas:
        if lam == 0:
            out[lam] = (np.sqrt(top_eigenvalue(sq @ ((v / t) @ v.T) @ sq)), 0.0) if t.min() > 0 else (np.inf, 0.0)
        else:
            gen = (v * (t / (t + lam) ** 2)) @ v.T          # sqrt(K_C) (K_C + lam I)^-2 sqrt(K_C)
            tra = (v * (1 / (t + lam) ** 2)) @ v.T          # (K_C + lam I)^-2
            out[lam] = (np.sqrt(top_eigenvalue(sq @ gen @ sq)), lam * np.sqrt(top_eigenvalue(sq @ tra @ sq)))
    return out
```

A.6. Módulo 7: Clasificación supervisada

El clasificador neuronal común consiste en un perceptrón multicapa implementado en PyTorch con estructura $k \to 32 \to 16 \to 1$, capas lineales continuas con activaciones ReLU y salida en escala logit, lo que permite integrar numéricamente la función sigmoide dentro de la función de costo de entropía cruzada binaria ponderada.

Listado 12: Definición del perceptrón multicapa para clasificación supervisada (`Code/7_Classification.ipynb`, celda de código 3).

```
class MLP(torch.nn.Module):
    def __init__(self, n_in, hidden):
        super().__init__()
        layers, d = [], n_in
        for h in hidden:
            layers += [torch.nn.Linear(d, h), torch.nn.ReLU()]
            d = h
        layers.append(torch.nn.Linear(d, 1))
        self.net = torch.nn.Sequential(*layers)

    def forward(self, x):
        return self.net(x).squeeze(-1)          # logit; the sigmoid lives in the loss and in predict
```

El ciclo de optimización `fit_predict` utiliza el optimizador Adam y aplica parada temprana monitoreando la pérdida ponderada sobre una partición interna independiente de pacientes. Si tras 40 épocas no se detecta mejoría, se detiene el entrenamiento y se restauran los mejores pesos obtenidos para evaluar el conjunto de prueba.

Listado 13: Bucle de entrenamiento con parada temprana y restauración de pesos (`Code/7_Classification.ipynb`, celda de código 3).

```
    best, best_state, best_epoch, wait = np.inf, None, 0, 0
    for epoch in range(1, (fixed or MAX_EPOCHS) + 1):
        model.train()
        order = torch.randperm(len(xt), generator=gen)
        for i in range(0, len(xt), BATCH):
            b = order[i:i + BATCH]
            opt.zero_grad()
            (loss_fn(model(xt[b]), yt[b]) * wt[b]).mean().backward()
            opt.step()
        if fixed:
            continue
        model.eval()
        with torch.no_grad():
            val = float((loss_fn(model(xv), yv) * wv).mean())
        if val < best - 1e-6:
            best, best_state, best_epoch, wait = val, copy.deepcopy(model.state_dict()), epoch, 0
        else:
            wait += 1
            if wait >= PATIENCE:
                break
    if not fixed:
        model.load_state_dict(best_state)
    model.eval()
    with torch.no_grad():
        return torch.sigmoid(model(prep(x_eval))).numpy(), (fixed or best_epoch)
```

A.7. Módulo 8: Evaluación comparativa y muestreo

El análisis comparativo evalúa la correlación de rangos de Spearman entre las métricas de separabilidad geométrica y el desempeño clasificador. La rutina asigna rangos promedio a condiciones empatadas y deriva la distribución nula exacta mediante las 120 permutaciones posibles para determinar la significación estadística bilateral.

Listado 14: Cálculo del coeficiente de Spearman con empates y distribución nula exacta (`Code/8_Comparison.ipynb`, celda de código 6).

```
PERMS = np.array(list(itertools.permutations(range(5))))


def ranks(values, higher_is_better):
    # rank 1 = most separated or best classified; tied values share their average rank. Values are rounded to
    # 9 decimals first: the metrics of C1 and C2 differ only by floating-point noise (1e-14), and that is a tie (D-016)
    v = np.round(np.asarray(values, float), 9)
    return rankdata(-v if higher_is_better else v, method='average')


def rho(a, b):
    return float(np.corrcoef(a, b)[0, 1])


def exact_null(sep_ranks, cls_ranks):
    return np.array([rho(sep_ranks, cls_ranks[p]) for p in PERMS])


def spearman_exact(sep_ranks, cls_ranks):
    r = rho(sep_ranks, cls_ranks)
    return r, float(np.mean(np.abs(exact_null(sep_ranks, cls_ranks)) >= abs(r) - 1e-9))
```

La cuantificación del coste por mediciones finitas simula el comportamiento de un dispositivo físico mediante muestreo multinomial de las probabilidades exactas. Este procedimiento emula un ejecutor ideal de disparos finitos (*shots*) y permite contrastar el error empírico frente a la cota teórica de desviación estándar de la medición cuántica.

Listado 15: Muestreo multinomial de mediciones finitas y ley de dispersión (`Code/8_Comparison.ipynb`, celda de código 17).

```
rng = np.random.default_rng(SEED)
shot_rows, law = [], []
t0 = time.perf_counter()
for ft in FINDINGS:
    frame = frames[ft]
    for q in QUANTUM:
        p, z = probs[(ft, q)], frame[cols(q)].to_numpy()
        spread = float(z.std(axis=0).mean())                    # between-lesion spread, as in 5a
```

```
        mean_var = float((1 - z ** 2).mean())                    # mean of 1 - <Z_i>^2 over lesions and
    qubits
        exact = main_cv[(main_cv.finding_type == ft) & (main_cv.condition == q)].auc.mean()
        shot_rows.append({'finding_type': ft, 'map': q, 'shots': np.inf, 'repeat': 0, 'noise_sd': 0.0, '
    theory_sd': 0.0,
                          'spread': spread, 'noise_over_spread': 0.0, 'cv_auc': exact})
        for n in SHOTS:
            for rep in range(SHOT_REPEATS):
                z_hat = rng.multinomial(n, p) @ signs / n
                e = z_hat - z
                theory = np.sqrt(mean_var / n)
                law.append({'finding_type': ft, 'map': q, 'shots': n, 'ratio_sd': e.std() / theory,
                            'mean_error_in_se': abs(e.mean()) / (theory / np.sqrt(e.size))})
                shot_rows.append({'finding_type': ft, 'map': q, 'shots': n, 'repeat': rep, 'noise_sd': float
    (e.std()), 'theory_sd': theory,
                                  'spread': spread, 'noise_over_spread': float(e.std()) / spread, 'cv_auc':
    cv_auc(z_hat, frame).mean()})
```

B. Salidas y resultados complementarios

En este anexo se presentan las tablas cuantitativas complementarias que respaldan las etapas de preprocesamiento, selección de variables, validación cruzada, coste computacional y verificación de consistencia interna del sistema. Todas las tablas han sido generadas directamente a partir de los registros estructurados en archivos CSV del repositorio mediante el script `tablas_anexos.py` de `Code/tools/`, garantizando trazabilidad completa.

B.1. Preprocesamiento y auditoría de máscaras (Módulo 2)

La Tabla 19 sintetiza el control de calidad aplicado sobre las 3 568 mamografías, documentando los casos con desajuste dimensional corregidos y la concordancia con los recortes oficiales.

Cuadro 19: Resumen del preprocesamiento, alineación de máscaras y control de calidad (Módulo 2).

Subconjunto	Lesiones analizadas	Desalineadas (escal./offset)	Máscaras depuradas	Recortes coincidentes	Recortes oficiales con discrepancia/sin	Dimensión mediana de lesión (px)	Recortes en borde
Calcificaciones	1872	2	0	1663	209	273×289	120
Masas	1696	78	1464	1543	75	302×304	67

Auditoría y control de calidad de M2. Desalineadas: 78 por escala (0,870) en masas y 2 por traslación en calcificaciones. Depuradas: reducción a la componente conexa mayor eliminando artefactos menores aislados. Recortes coincidentes: concordancia exacta al píxel con los recortes oficiales del CBIS-DDSM.

B.2. Selección y redundancia de características (Módulo 4)

La Tabla 20 reporta las 12 características radiómicas seleccionadas en cada subconjunto clínico, acompañadas de sus estadísticos univariados de significación y tamaño del efecto.

Cuadro 20: Conjunto completo de características radiómicas seleccionadas por subconjunto (Módulo 4).

	Masas					Calcificaciones				
#	Característica	Familia	F	p	$\lvert d\rvert$	Característica	Familia	F	p	$\lvert d\rvert$
1	firstorder_Maximum	firstorder	83.1	<0.001	0.502	shape2D_MinorAxisLength	shape2D	235.4	<0.001	0.817
2	firstorder_90Percentile	firstorder	82.6	<0.001	0.501	glrlm_RunEntropy	glrlm	200.9	<0.001	0.755
3	firstorder_Energy	firstorder	74.7	<0.001	0.476	shape2D_Perimeter	shape2D	177.0	<0.001	0.709
4	shape2D_MinorAxisLength	shape2D	66.7	<0.001	0.450	firstorder_Skewness	firstorder	174.6	<0.001	0.704
5	shape2D_MaximumDiameter	shape2D	62.3	<0.001	0.435	glrlm_ShortRunLowGrayLevelEmphasis	glrlm	166.2	<0.001	0.687
6	shape2D_Perimeter	shape2D	53.1	<0.001	0.402	glrlm_ShortRunEmphasis	glrlm	161.5	<0.001	0.677
7	shape2D_MeshSurface	shape2D	52.8	<0.001	0.400	glcm_JointAverage	glcm	150.9	<0.001	0.654
8	shape2D_PerimeterSurfaceRatio	shape2D	51.3	<0.001	0.395	glcm_InverseVariance	glcm	142.8	<0.001	0.636
9	glrlm_GrayLevelNonUniformity	glrlm	37.8	<0.001	0.339	glcm_DifferenceEntropy	glcm	135.6	<0.001	0.620
10	firstorder_10Percentile	firstorder	31.7	<0.001	0.311	firstorder_Energy	firstorder	135.1	<0.001	0.619
11	glcm_Correlation	glcm	31.0	<0.001	0.307	glcm_ClusterShade	glcm	133.9	<0.001	0.616
12	glrlm_RunLengthNonUniformity	glrlm	28.8	<0.001	0.296	shape2D_PixelSurface	shape2D	129.1	<0.001	0.605

Selección de las 12 características en cada subconjunto mediante ANOVA univariado (F-test) sobre el conjunto de entrenamiento con restricción de redundancia lineal $|r| \leq 0{,}95$. p reporta el nivel de significación estadística; $|d|$ es el tamaño del efecto (d de Cohen sobre intensidades crudas).

La Tabla 21 documenta las características candidatas que, a pesar de su relevancia individual, fueron descartadas del conjunto final por exceder el límite de redundancia lineal.

Cuadro 21: Características radiómicas descartadas por restricción de redundancia (Módulo 4).

Característica candidata	Redundante con	$\lvert r \rvert$	Estado
Masas			
firstorder_TotalEnergy	firstorder_Energy	1.000	Descartada ($\lvert r \rvert > 0{,}95$)
firstorder_Median	firstorder_90Percentile	0.959	Descartada ($\lvert r \rvert > 0{,}95$)
firstorder_RootMeanSquared	firstorder_90Percentile	0.966	Descartada ($\lvert r \rvert > 0{,}95$)
firstorder_Mean	firstorder_90Percentile	0.955	Descartada ($\lvert r \rvert > 0{,}95$)
shape2D_MajorAxisLength	shape2D_MaximumDiameter	0.993	Descartada ($\lvert r \rvert > 0{,}95$)
shape2D_PixelSurface	shape2D_MeshSurface	1.000	Descartada ($\lvert r \rvert > 0{,}95$)
glcm_MCC	glcm_Correlation	0.986	Descartada ($\lvert r \rvert > 0{,}95$)
Calcificaciones			
glcm_Imc1	glrlm_RunEntropy	0.961	Descartada ($\lvert r \rvert > 0{,}95$)
glcm_SumAverage	glcm_JointAverage	1.000	Descartada ($\lvert r \rvert > 0{,}95$)
glrlm_RunPercentage	glrlm_ShortRunEmphasis	0.975	Descartada ($\lvert r \rvert > 0{,}95$)
glrlm_RunLengthNonUniformityNormalized	glrlm_ShortRunEmphasis	0.980	Descartada ($\lvert r \rvert > 0{,}95$)
shape2D_MaximumDiameter	shape2D_Perimeter	0.980	Descartada ($\lvert r \rvert > 0{,}95$)
firstorder_TotalEnergy	firstorder_Energy	1.000	Descartada ($\lvert r \rvert > 0{,}95$)
glrlm_HighGrayLevelRunEmphasis	glcm_JointAverage	0.972	Descartada ($\lvert r \rvert > 0{,}95$)
glcm_Autocorrelation	glcm_JointAverage	0.981	Descartada ($\lvert r \rvert > 0{,}95$)

Características candidatas con alto valor de F que fueron omitidas de la selección final para evitar colinealidad extrema ($\lvert r \rvert > 0{,}95$). En masas se descartaron 7 variables y en calcificaciones 8.

B.3. Estratificación de pliegues en validación cruzada (Módulo 4)

La Tabla 22 detalla el reparto de lesiones, el número de pacientes únicos y la proporción de malignidad en cada uno de los cinco pliegues de validación cruzada generados.

Cuadro 22: Balance de lesiones, pacientes y proporción de malignidad por fold (Módulo 4).

	Masas (semilla elegida: 125)			Calcificaciones (semilla elegida: 168)		
Fold	Lesiones	Pacientes	Malignas (%)	Lesiones	Pacientes	Malignas (%)
0	255	139	48.6 %	315	120	33.3 %
1	258	134	47.3 %	271	119	35.4 %
2	268	138	48.9 %	322	121	36.6 %
3	257	140	49.4 %	314	121	35.7 %
4	280	140	47.5 %	324	121	34.9 %
Total / media	1318	691	48.3 %	1546	602	35.2 %

Partición de validación cruzada 5-fold estratificada por paciente (`StratifiedGroupKFold`). Garantiza cero fuga de pacientes entre folds y balance de clases óptimo entre candidatos de semillas.

B.4. Costes computacionales de simulación cuántica (Módulos 5, 8 y X8)

La Tabla 23 presenta la comparativa de tiempos de ejecución empíricos entre el cálculo matricial por vector de estado y la simulación individual por circuito.

Cuadro 23: Costes computacionales de evaluación de kernels cuánticos (Módulo 5).

Subconjunto	Kernel cuántico evaluado	Dimensión	Tiempo total (s)
Masas	`FidelityStatevectorKernel_C4`	200x200	1.468
Masas	`FidelityStatevectorKernel_C5`	200x200	1.590
Calcificaciones	`FidelityStatevectorKernel_C4`	200x200	1.569
Calcificaciones	`FidelityStatevectorKernel_C5`	200x200	1.574
Masas	`FidelityQuantumKernel_C4`	10x10	4.970
Masas	`FidelityQuantumKernel_C5`	10x10	4.985
Calcificaciones	`FidelityQuantumKernel_C4`	10x10	4.948
Calcificaciones	`FidelityQuantumKernel_C5`	10x10	5.041

Tiempos medidos en simulación exacta. `FidelityStatevectorKernel` calcula la matriz 200×200 en $\sim$1.5 s aprovechando vectores de estado precomputados. `FidelityQuantumKernel` evalúa el circuito cuántico directo requiriendo $\sim$5.0 s para una matriz reducida de solo 10×10.

La Tabla 24 reporta el escalamiento de los requerimientos de memoria y tiempo de simulación en función del número de qubits del sistema, contrastando mediciones directas y extrapolaciones.

Cuadro 24: Escalamiento computacional con el número de qubits en simulación por vector de estado (OE-6).

k (qubits)	Tipo de dato	Memoria estado	Tiempo/estado (s)	Tiempo embedding (h)	Entrenamiento (h/mapa)
8	Medido	0.00 MiB	0.0012	0.002	1.6
10	Medido	0.02 MiB	0.0019	0.004	3.0
12	Medido	0.06 MiB	0.0029	0.006	5.7
14	Medido	0.25 MiB	0.0065	0.013	14.8
16	Medido	1.00 MiB	0.0349	0.069	90.3
18	Medido	4.00 MiB	0.1071	0.212	311
20	Medido	16.00 MiB	0.3924	0.778	1264
22	Medido	64.00 MiB	1.2	2.472	4415
24	Medido	256.00 MiB	4.1	8.194	15950
26	Medido	1.00 GiB	13.7	27.3	57421
28	Medido	4.00 GiB	74.8	148.2	336114
30	Extrapolado	16.00 GiB	221.0	438.0	1063514
32	Extrapolado	64.00 GiB	802.7	1591.1	4118952

Escalamiento del coste en simulación cuántica por vector de estado en función del número de qubits (k). Para $k \leq 28$ las cifras corresponden a ejecuciones empíricas en el hardware de referencia (Apple M3); para $k \geq 30$ corresponden a la extrapolación exponencial teórica.

La Tabla 25 expone la evaluación comparativa del coste por muestra para el cálculo de gradientes cuánticos mediante la regla analítica de desplazamiento de parámetros frente a diferenciación automática.

Cuadro 25: Coste computacional del cálculo de gradientes variacionales (Experimento X8).

Método de cálculo	Naturaleza del gradiente	Tiempo/lesión (s)	Coste estimado (50 épocas, h)
parameter shift (EstimatorQNN, exact)	Jacobian 12×24 (also needed for a scalar loss)	5.1589	205.21
automatic differentiation (state vector)	Jacobian 12×24	0.2369	9.42
automatic differentiation (state vector)	scalar loss, one backward pass	0.0014	0.06

Comparación de costes entre diferenciación exacta por *parameter-shift rule* y diferenciación automática directa sobre vector de estado en simulación (Experimento X8).

B.5. Verificaciones automáticas y control metodológico (Módulos 5 a 8 y X5)

La Tabla 26 resume el catálogo de verificaciones automáticas integradas en los módulos de transformación, separabilidad y clasificación supervisada.

Cuadro 26: Resumen de la suite de verificaciones automáticas de consistencia y correctitud.

Módulo	Archivo de resultados	Pruebas	Superadas	Ámbito de verificación
Módulo 5a	`5a_verificaciones.csv`	18	18 (100 %)	Recomputación exacta, dispersión positiva y validación con SparsePauliOp
Módulo 5b	`5b_verificaciones.csv`	38	38 (100 %)	Simetría de matrices, diagonal unitaria y semidefinición positiva ($\lambda_{\text{mín}} \geq 0$)
Módulo 6	`6_verificaciones.csv`	20	20 (100 %)	Normalización de traza, identidades teóricas de g, KTA y control nulo C1=C2
Módulo 7	`7_verificaciones.csv`	16	16 (100 %)	Cero fuga de pacientes, convergencia por parada temprana y estabilidad de probabilidades
Módulo 8	`8_verificaciones.csv`	22	22 (100 %)	Reproducción de AUC en test y CV, nula exacta de Spearman y muestreo de $\langle Z_i \rangle$
Total suite	5 archivos CSV	114	114 (100 %)	Suite completa de aserciones automáticas

Todas las pruebas automáticas del pipeline ejecutan aserciones matemáticas estrictas sobre las estructuras de datos generadas. El 100 % de las verificaciones resultó exitoso, sin discrepancias numéricas tolerables más allá del error de redondeo de punto flotante.

La Tabla 27 reúne los resultados de la auditoría independiente de consistencia metodológica, verificando la ausencia de fugas de datos y la integridad de las etiquetas clínicas.

Cuadro 27: Auditoría metodológica independiente de consistencia, datos y modelos (Experimento X5).

Propiedad auditada	Discrepancia máxima	Veredicto
Integridad de etiquetas y particiones		
mass: every lesion of Module 4 exists in the original CSV files	0.0	Superada
mass: labels equal MALIGNANT = 1 from the CSV files	0.0	Superada
mass: train/test split equals the file of origin	0.0	Superada
calcification: every lesion of Module 4 exists in the original CSV files	0.0	Superada
calcification: labels equal MALIGNANT = 1 from the CSV files	0.0	Superada
calcification: train/test split equals the file of origin	0.0	Superada
mass: class counts equal the EDA (912 benign, 784 malignant)	0.0	Superada
calcification: class counts equal the EDA (1199 benign, 673 malignant)	0.0	Superada
Ausencia de fuga de datos (escalado y folds)		
mass: angles refitted on train only equal Module 4, test included	0.0	Superada
mass: every angle lies in [0, π], test included	0.0	Superada
mass: no patient split across folds nor across train and test	0.0	Superada
calcification: angles refitted on train only equal Module 4, test included	0.0	Superada
calcification: every angle lies in [0, π], test included	0.0	Superada
calcification: no patient split across folds nor across train and test	0.0	Superada
Equivalencia física de kernels cuánticos		
mass: C4 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
mass: C5 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
calcification: C4 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
calcification: C5 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
Equivalencia de formulación QSVM (Qiskit vs dual)		
mass: QSVC of qiskit-machine-learning equals the precomputed-kernel SVM of X4	0.0	Superada
calcification: QSVC of qiskit-machine-learning equals the precomputed-kernel SVM of X4	0.0	Superada
Invarianza de rotación y transformaciones		
changing x_i changes only <Z_i>of C5, to -sin(2 x_i)	0.0	Superada
C4: the kernel is invariant under a reordering of the features	0.0	Superada
C5: the kernel is invariant under a reordering of the features	0.0	Superada
Consistencia de modelos de referencia clásicos		
mass: three classical models agree within one fold standard deviation	2.39e-02	Superada
calcification: three classical models agree within one fold standard deviation	1.63e-02	Superada

Auditoría metodológica independiente de extremo a extremo (Experimento X5). Comprueba rigurosamente la ausencia de fugas de datos entre particiones de pacientes, la correspondencia exacta de etiquetas patológicas con los metadatos clínicos de CBIS-DDSM y la consistencia matemática de los componentes cuánticos.

C. Figuras complementarias

En esta sección se compilan aquellas figuras generadas durante las fases de caracterización, evaluación de complejidad y análisis exploratorio del pipeline que, por razones de espacio y fluidez narrativa, no fueron incluidas en los capítulos metodológicos ni de resultados principales. Las figuras relativas a la distribución exploratoria de variables clínicas e imágenes DICOM del conjunto de datos se presentan en el anexo correspondiente.

C.1. Preprocesamiento e imágenes de entrada

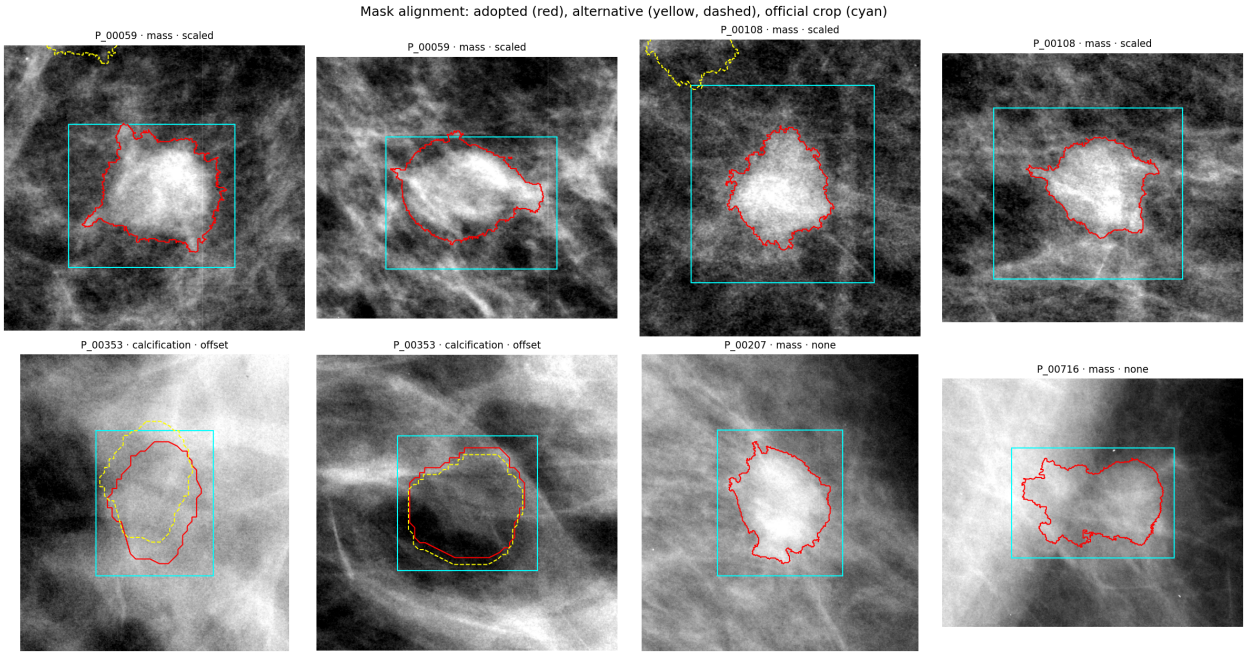


Figura C.1.1: Diagnóstico de desajuste dimensional y verificación de alineación espacial de máscaras en el Módulo 2. Se ilustran los dos casos identificados: discordancia por factor de escala (0,870) y desajuste por traslación de origen, contrastados con el recorte oficial.

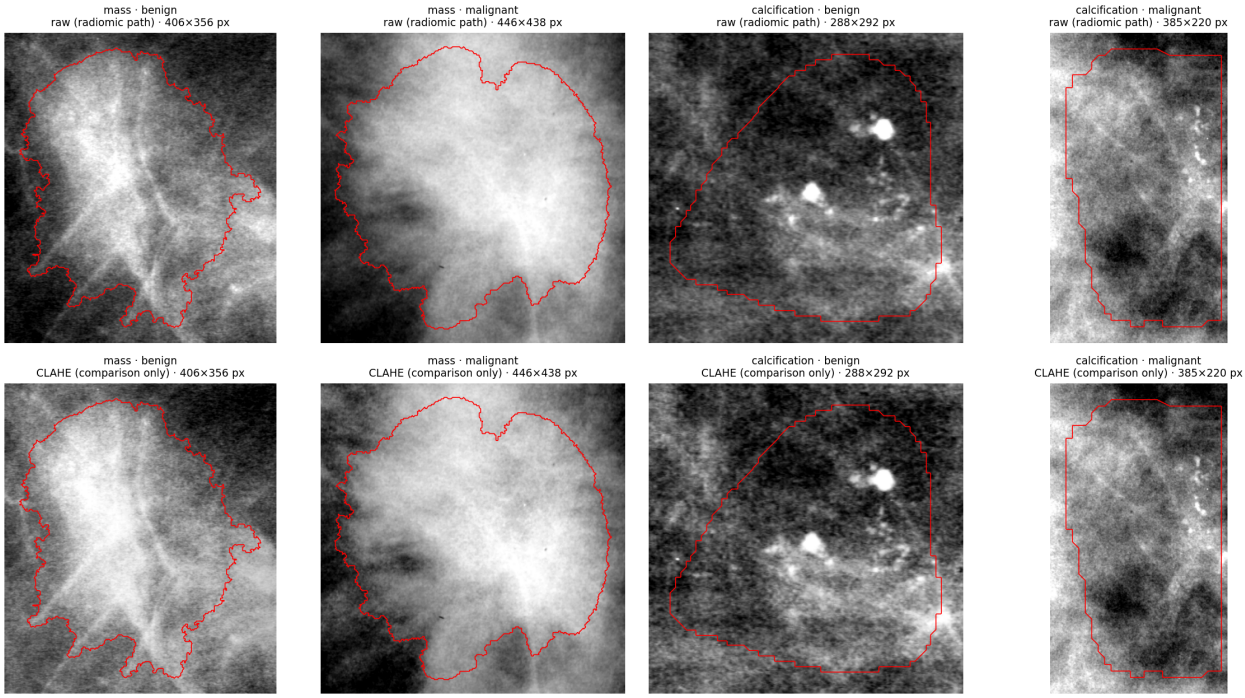


Figura C.1.2: Ejemplos ilustrativos de las etapas de preprocesamiento sobre mamografías del CBIS-DDSM (Módulo 2). Se muestra la mamografía completa, la máscara binarizada depurada, la región de interés recortada con margen de seguridad y su correspondiente versión procesada mediante ecualización CLAHE.

C.2. Circuitos cuánticos y mapas de características

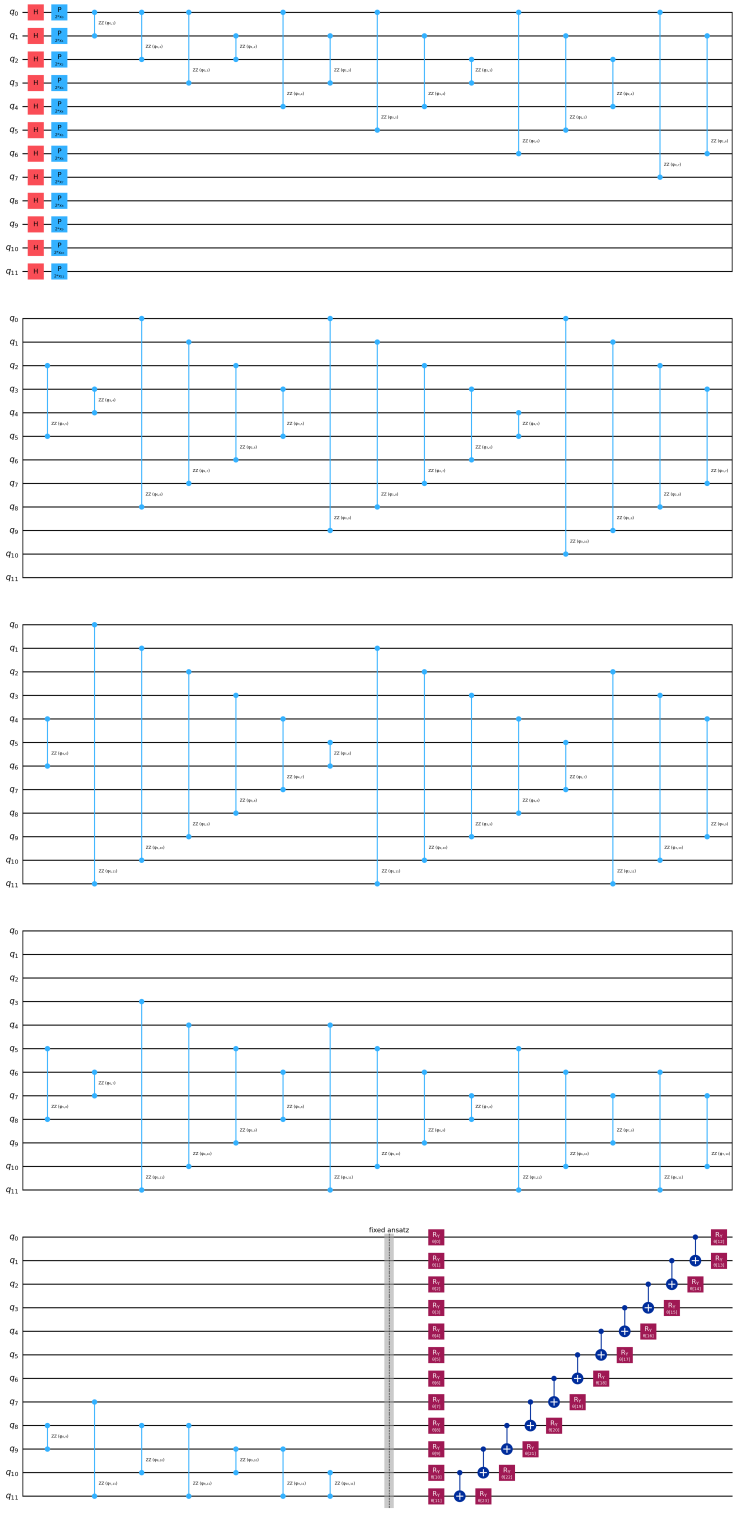


Figura C.2.1: Diagrama esquemático completo del circuito cuántico variacional implementado para $k = 12$ qubits (Módulo 5). Incluye la codificación angular de características, el entrelazamiento completo de dos qubits y la capa variacional con *ansatz* `RealAmplitudes` de una repetición parametrizada con vector θ fijo.

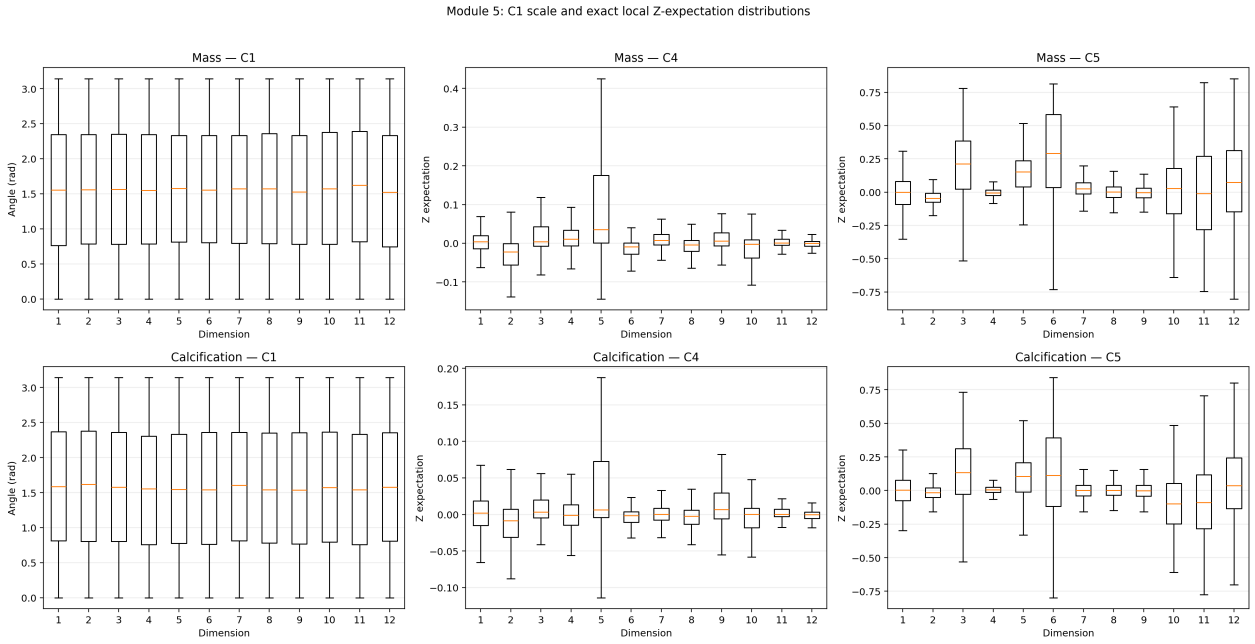


Figura C.2.2: Distribución empírica de los valores esperados de Pauli locales $\langle Z_i \rangle$ generados por los mapas cuánticos C4 y C5 para cada dimensión del embedding en masas y calcificaciones (Módulo 5).

C.3. Complejidad, costes y muestreo de estados cuánticos

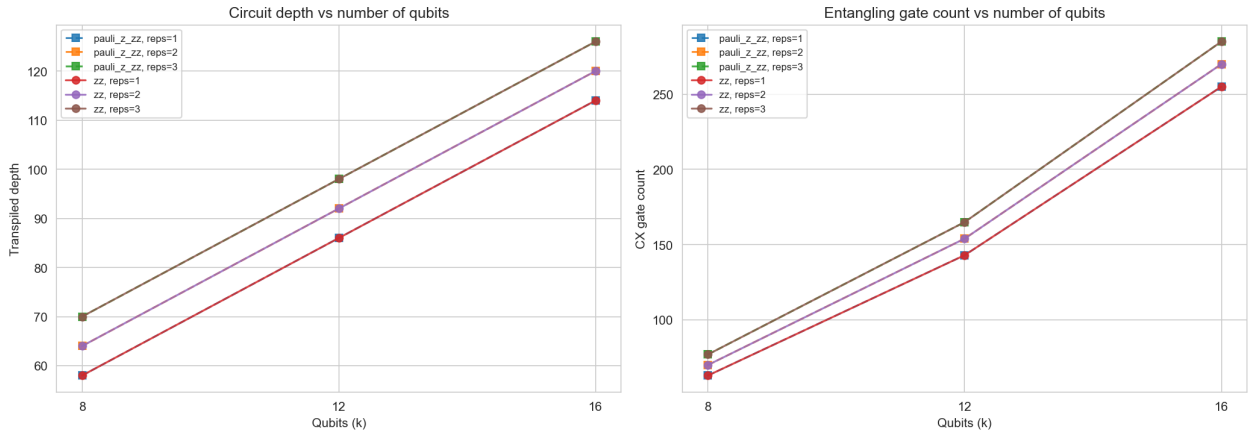


Figura C.3.1: Complejidad estructural de los circuitos cuánticos evaluados en función del número de qubits k. Se reporta la profundidad total del circuito y el número de compuertas de dos cúbits requeridas para distintas configuraciones.

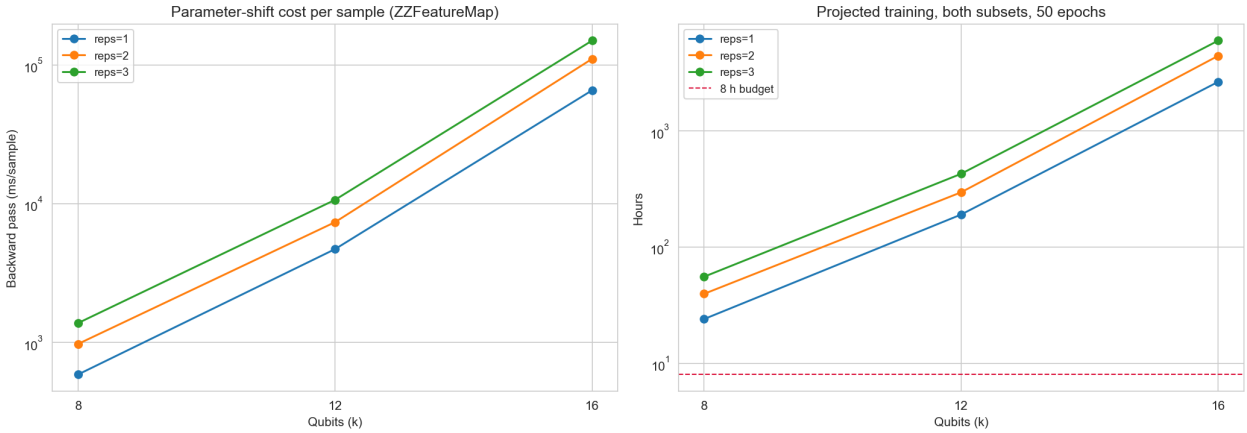


Figura C.3.2: Coste computacional del entrenamiento variacional medido en segundos por época y muestra en simuladores cuánticos para diversas topologías de circuito y números de qubits.

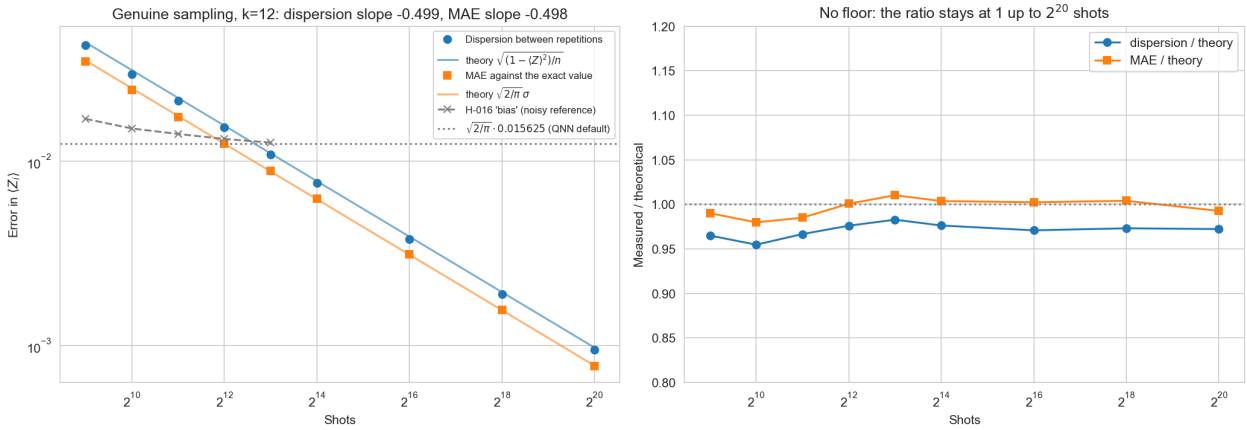


Figura C.3.3: Sensibilidad del error de estimación al número de disparos finitos (*shots*). El aparente estancamiento en precisión observado en la versión preliminar de este análisis respondió a ruido numérico en la referencia de evaluación, según se documentó y subsanó posteriormente en el cuaderno B3 con cálculos exactos.

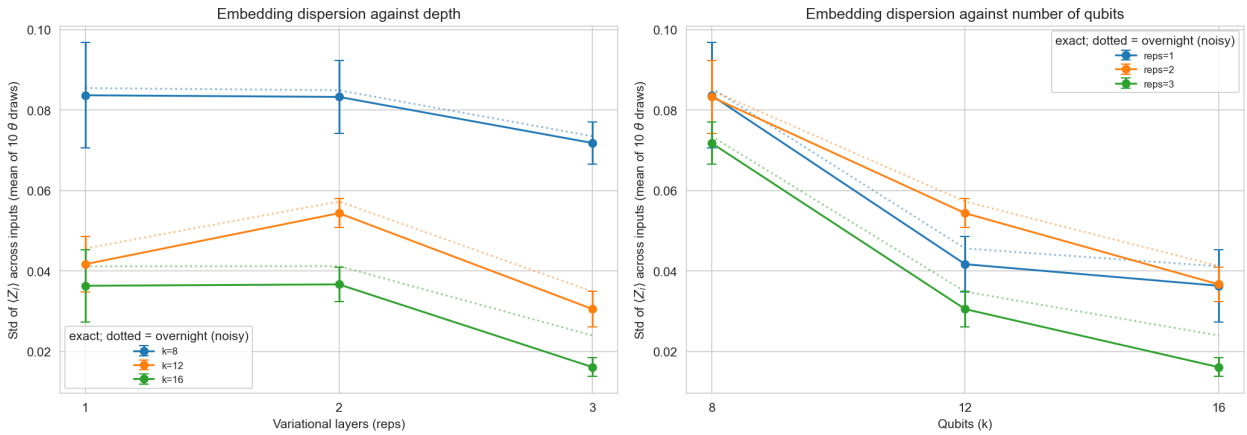


Figura C.3.4: Efecto de concentración de medida en el espacio de Hilbert al incrementar el número de qubits k. La dispersión entre estados para diferentes lesiones decae exponencialmente conforme aumenta la dimensionalidad cuántica.

C.4. Experimentos complementarios de kernels, dimensionalidad y QSVM

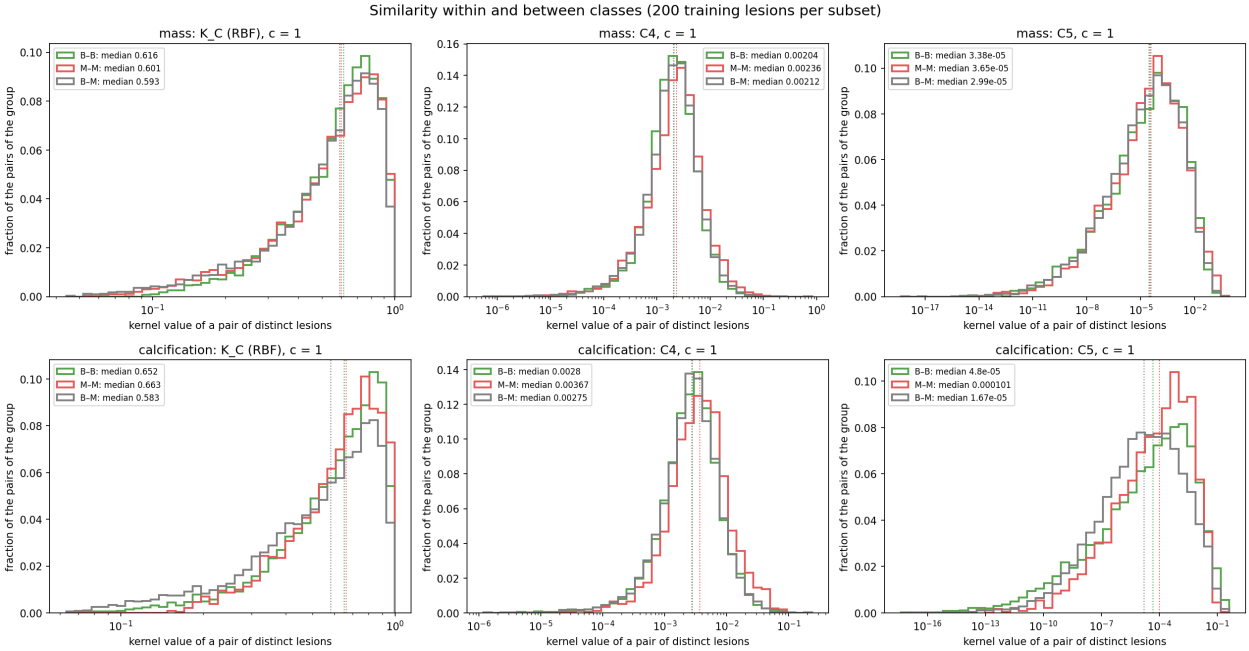


Figura C.4.1: Distribución de valores de similitud en matrices de kernel intraclase e interclase (Experimento X2). Se compara la discriminación obtenida por el kernel clásico RBF frente a los mapas cuánticos C4 y C5 bajo distintos factores de escala angular c.

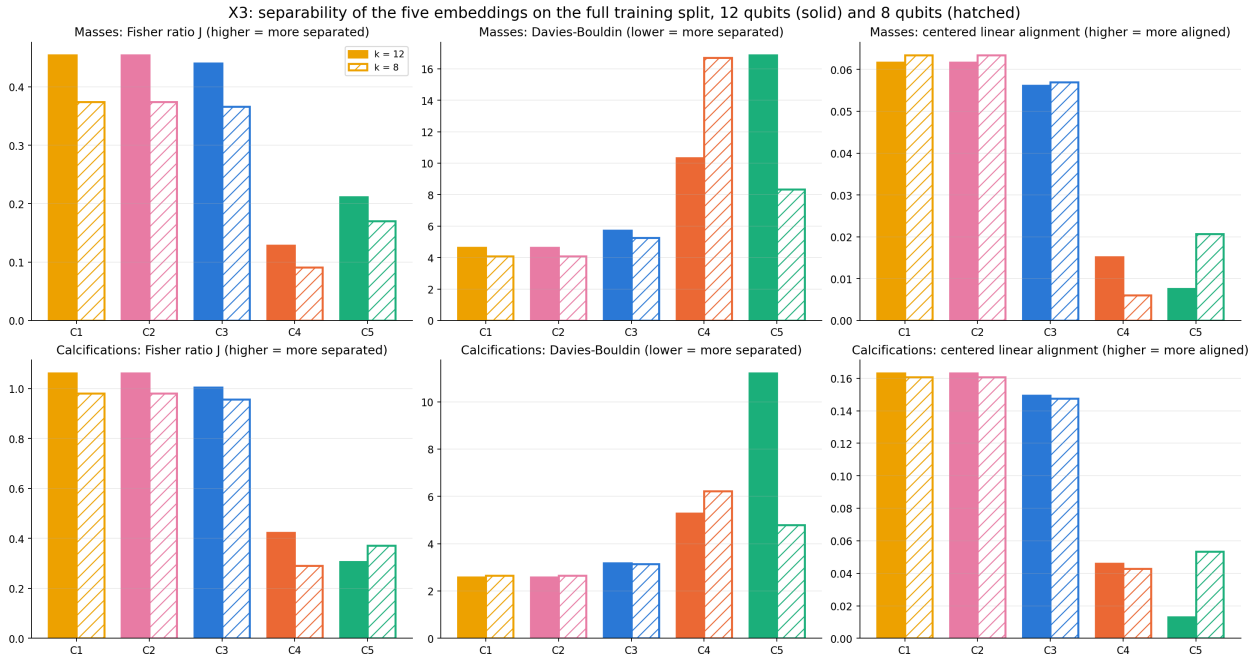


Figura C.4.2: Comparativa de métricas de separabilidad geométrica (Davies–Bouldin, Fisher J y alineamiento KTA) entre la configuración reducida de $k = 8$ qubits y el diseño principal de $k = 12$ qubits (Experimento X3).

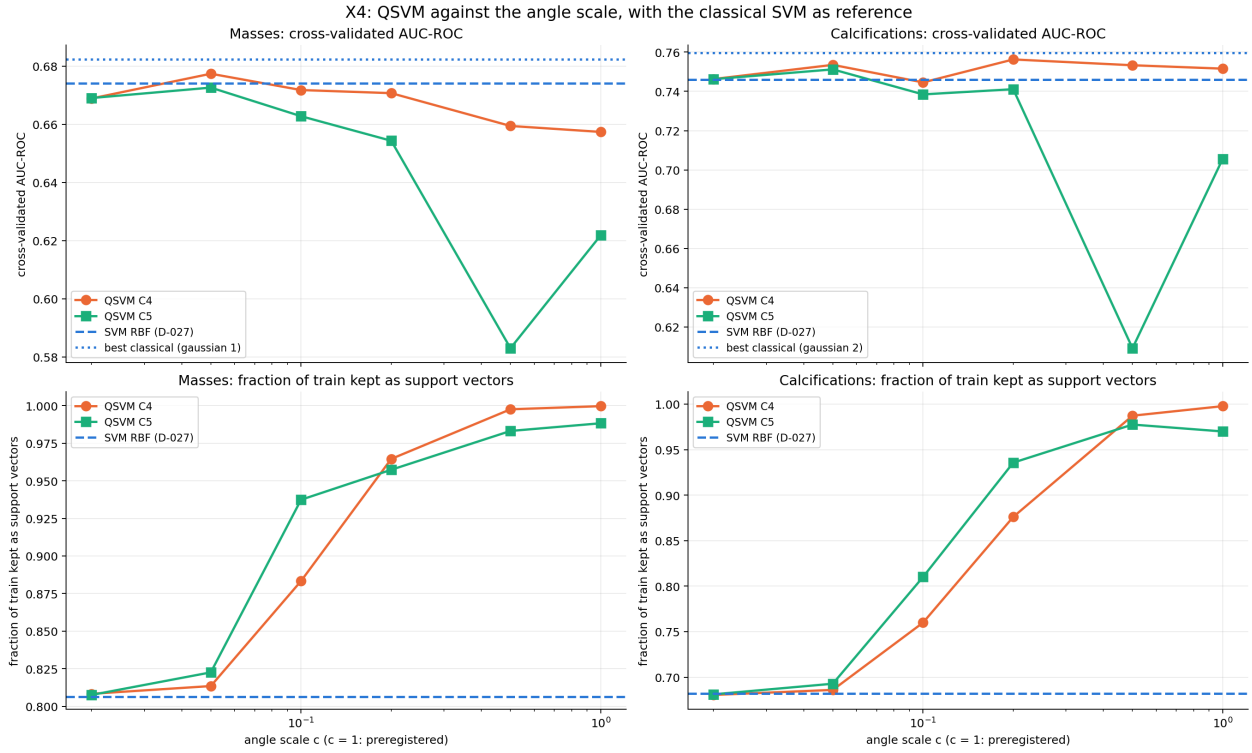


Figura C.4.3: Desempeño en clasificación del algoritmo QSVM frente a variaciones en el factor de escala angular c (Experimento X4), contrastado con la referencia clásica de SVM con kernel gaussiano RBF.

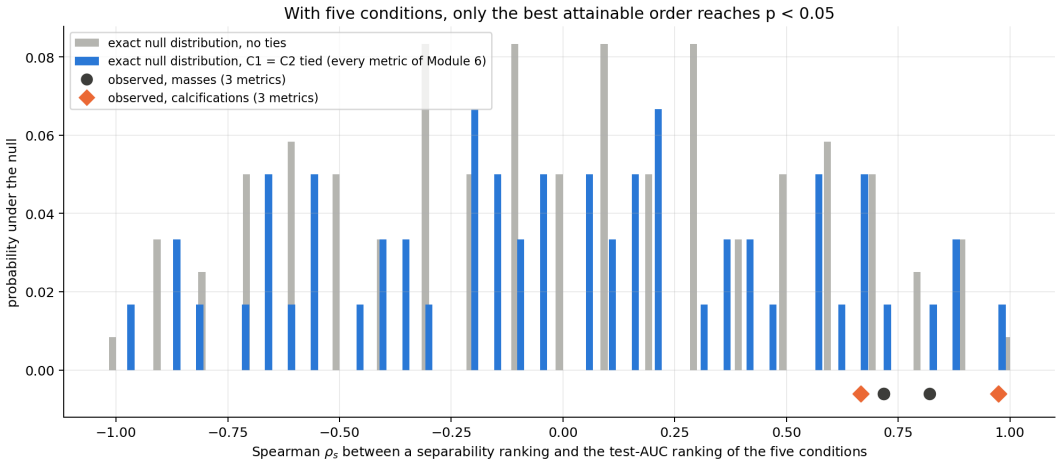


Figura C.4.4: Distribución nula exacta del estadístico de correlación de Spearman ρ_s generada a partir de las 120 permutaciones exhaustivas de las cinco condiciones experimentales con rangos promedio por empates (Módulo 8).

C.5. Figuras del análisis exploratorio

Las siguientes figuras complementan la caracterización realizada en el capítulo 4, reuniendo aquellas distribuciones de clases, metadatos clínicos, características de escáner e intensidades de píxeles trasladadas del cuerpo principal para optimizar la concisión del reporte técnico.

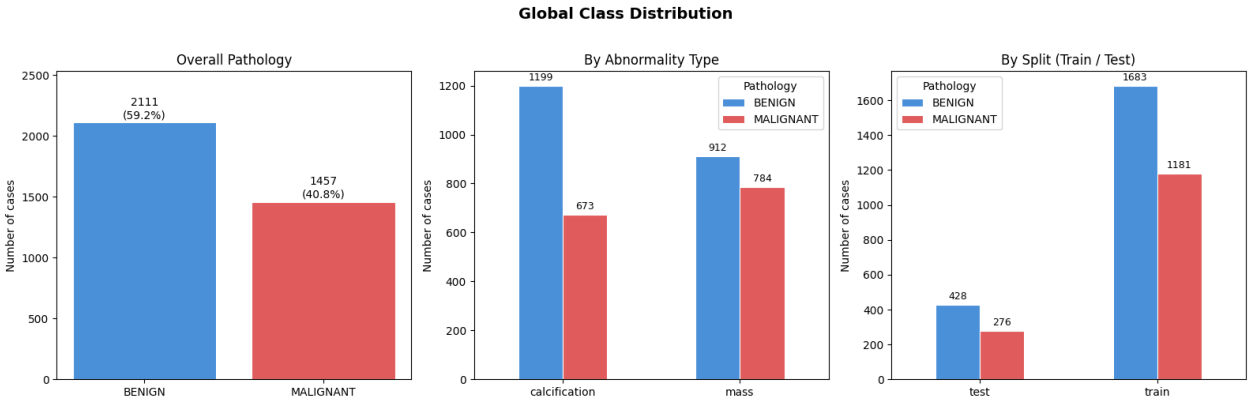


Figura C.5.1: Distribución de clases global, por tipo de hallazgo y por split train/test.

D. Entorno de ejecución y reproducibilidad

La reproducibilidad computacional del pipeline depende del control estricto de las versiones de software, la compilación determinista de extensiones nativas en C y la fijación de semillas pseudoaleatorias en todas las etapas del procesamiento.

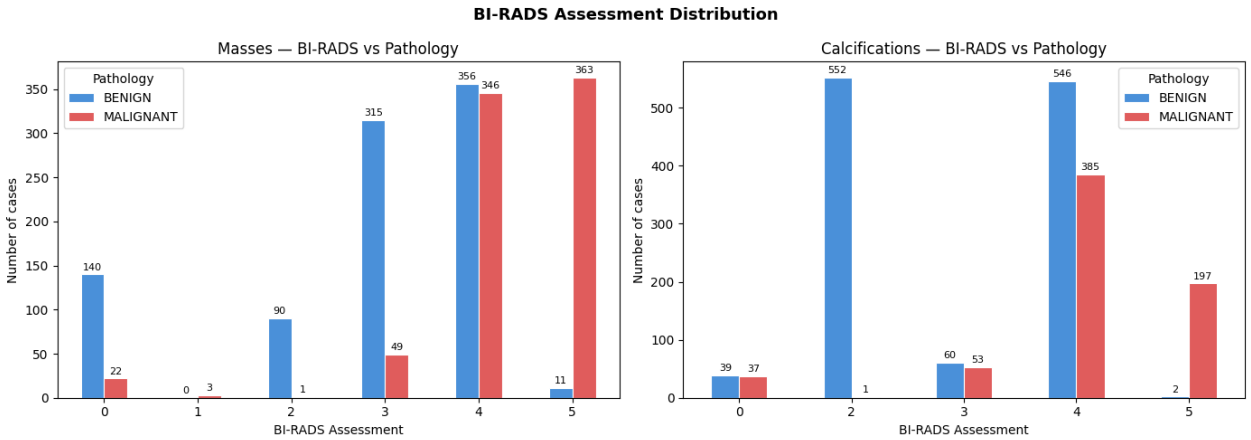


Figura C.5.2: Distribución de categorías BI-RADS por patología y tipo de hallazgo.

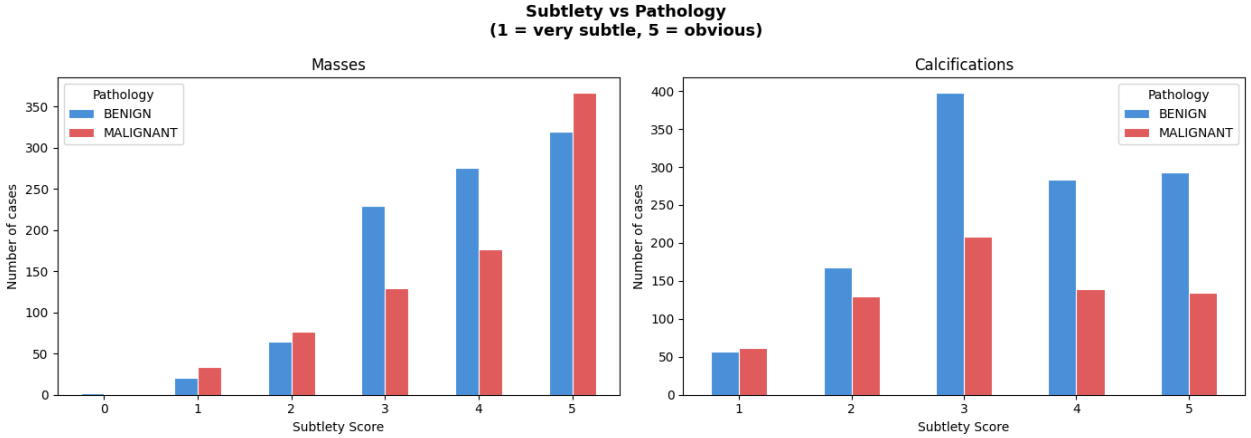


Figura C.5.3: Distribución de *subtlety* por patología y tipo de hallazgo (1 = muy sutil, 5 = obvio).

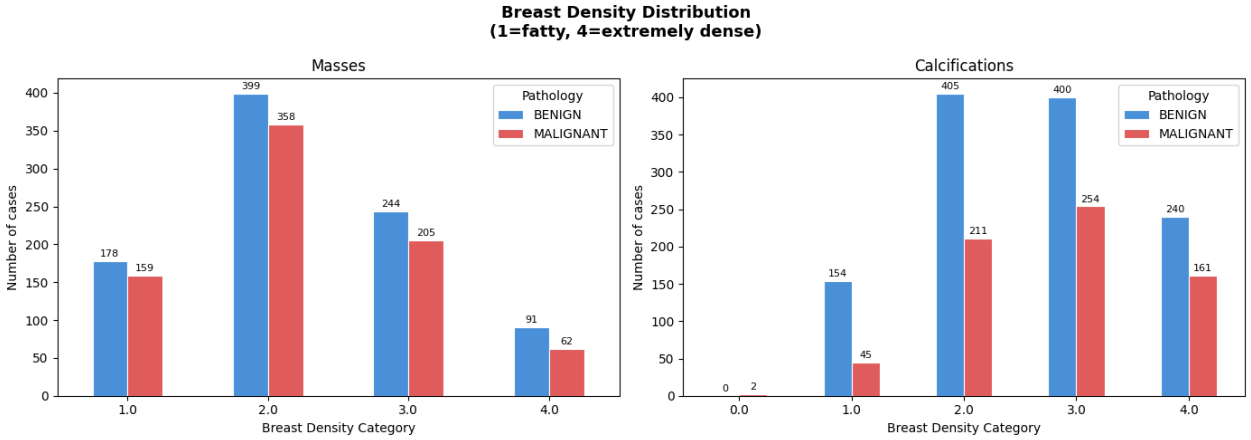


Figura C.5.4: Distribución de densidad mamaria (1 = grasa, 4 = extremadamente densa) por patología y tipo de hallazgo.

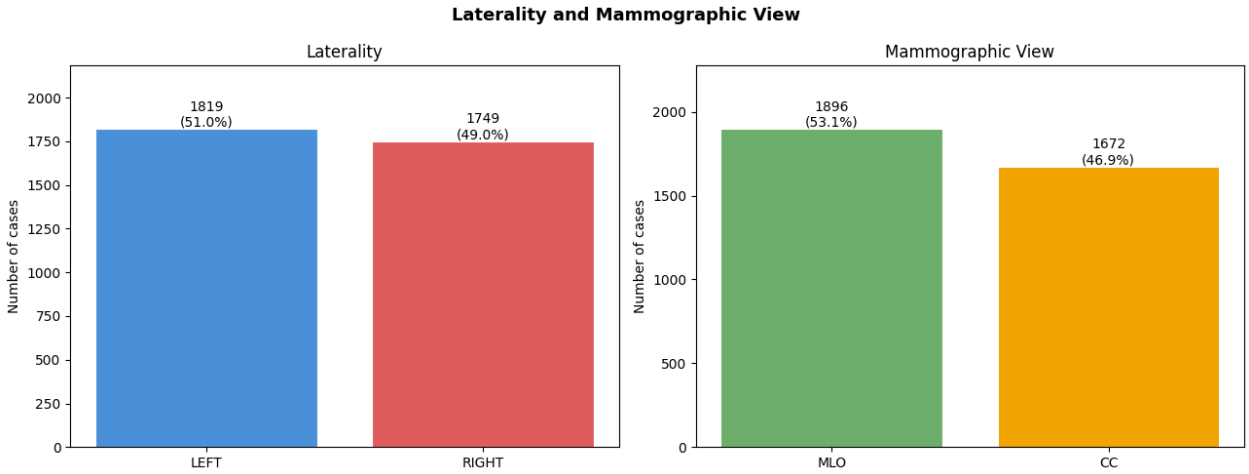


Figura C.5.5: Distribución de lateralidad y vista mamográfica en el dataset.

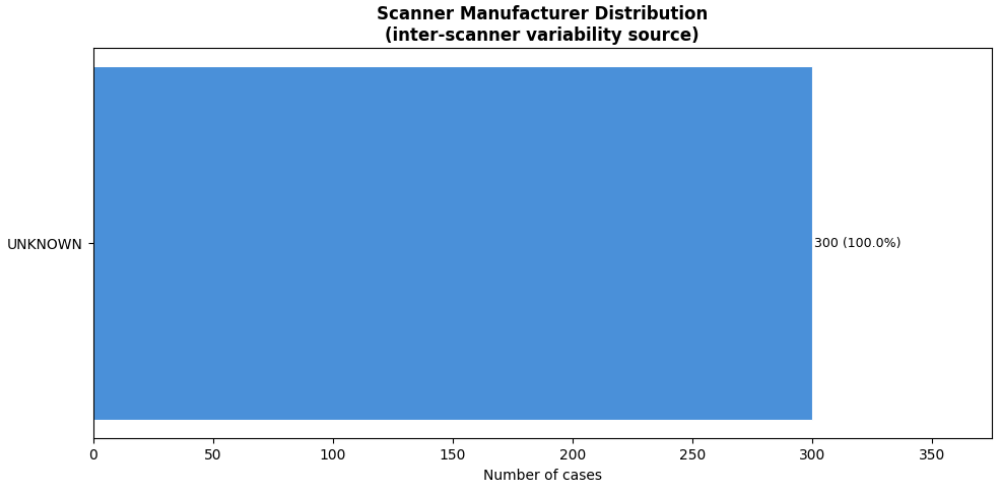


Figura C.5.6: Distribución de fabricantes de escáner en la muestra analizada.

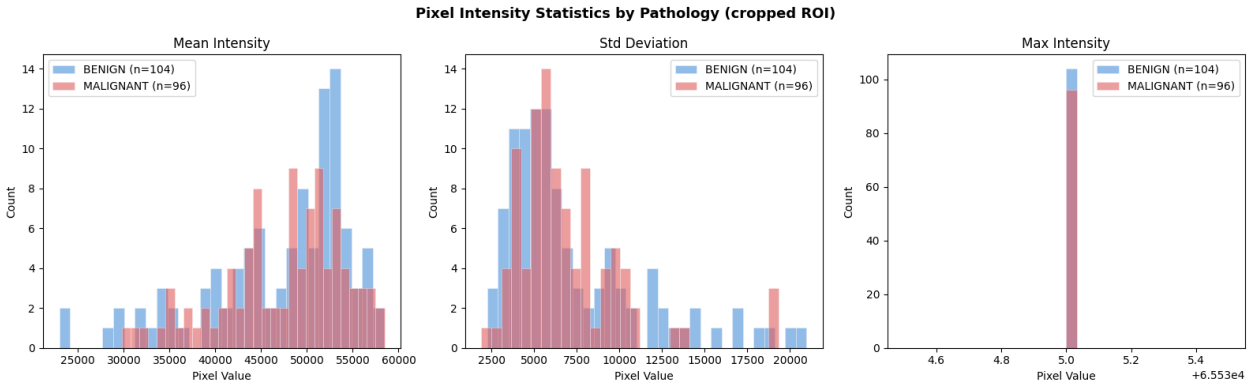


Figura C.5.7: Distribución de estadísticas de intensidad de píxeles (media, desviación estándar y máximo) en imágenes recortadas de ROI, por patología.

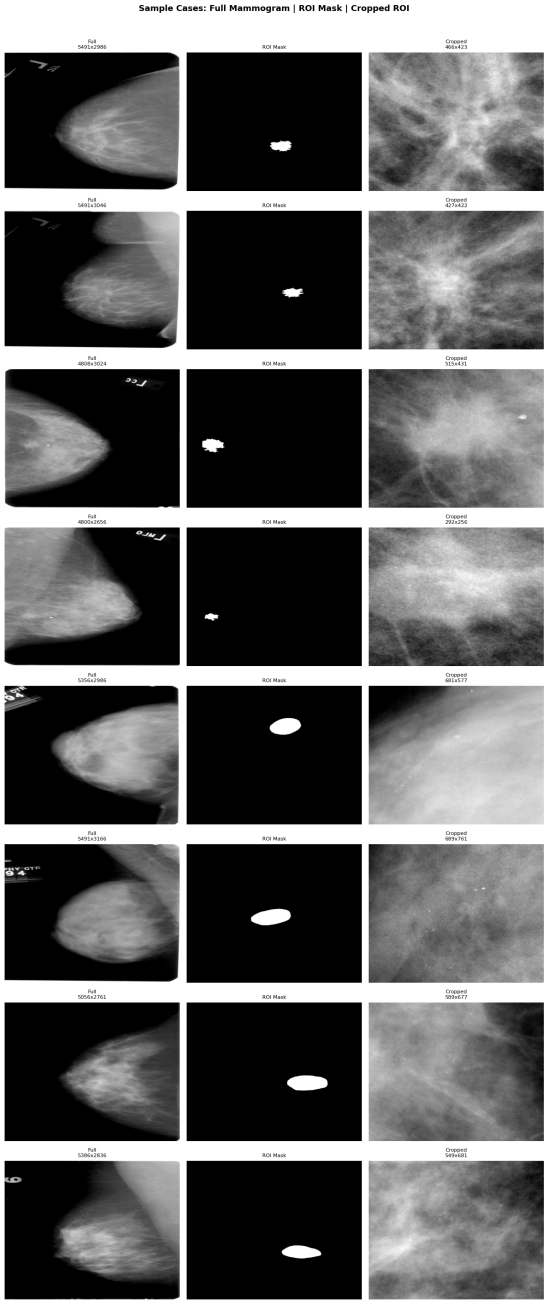


Figura C.5.8: Galería de casos representativos: mamografía completa, máscara ROI e imagen recortada, para masas y calcificaciones benignas y malignas.

D.1. Paquetes y dependencias del sistema

El desarrollo se articuló en dos entornos independientes de Conda: el entorno `radiomics`, destinado al preprocesamiento espacial y la extracción de características morfo-texturales (Módulos 2 y 3), y el entorno `qml_cancer`, orientado a la selección estadística, transformaciones cuánticas variacionales, separabilidad y modelado supervisado (Módulos 4 a 8). La Tabla 28 especifica las versiones instaladas de los paquetes fundamentales.

Cuadro 28: Versiones de los paquetes de software fundamentales en los entornos de ejecución.

Paquete de software	Función en el pipeline	Entorno `radiomics`	Entorno `qml_cancer`
`python`	Lenguaje base del entorno	`3.10.20`	`3.10.19`
`numpy`	Cómputo matricial y vectores	`2.2.6`	`2.2.6`
`scipy`	Rutinas científicas y optimización	–	`1.15.3`
`pandas`	Estructuras de datos tabulares	`2.3.3`	`2.3.3`
`scikit-learn`	Modelos clásicos y métricas ML	–	`1.7.2`
`pyradiomics`	Extracción de características radiómicas	`0.1.dev1+g8ed579383`	`3.1.1.dev111+g8ed579383`
`pydicom`	Lectura de mamografías DICOM crudas	`3.0.2`	`3.0.1`
`SimpleITK`	Conversión y exportación espacial NRRD	`2.5.6`	`2.5.3`
`opencv-python`	Alineación de máscaras y CLAHE	`4.11.0.86`	`4.13.0.92`
`matplotlib`	Generación de gráficos y figuras	`3.10.9`	`3.10.8`
`torch`	Redes neuronales y optimización MLP	–	`2.10.0`
`qiskit`	Definición de circuitos cuánticos	–	`2.3.0`
`qiskit-aer`	Simulación cuántica de alto rendimiento	–	`0.17.2`
`qiskit-machine-learning`	Kernels y algoritmos cuánticos de aprendizaje	–	`0.9.0`

Versiones exactas de librerías en los dos entornos de ejecución reproducible gestionados con Conda. `pyradiomics` se encuentra anclado en ambos entornos al commit `8ed579383b44806651c463d5e691f3b2b57522ab`.

D.2. Procedimiento de compilación de PyRadiomics

La librería PyRadiomics no admite instalación directa desde los repositorios de PyPI debido a que la distribución fuente de la versión 3.1.0 declara inconsistencias de versión en sus metadatos y omite en su manifiesto los archivos de cabecera `cmatrices.h` y `cshape.h`, impidiendo la compilación. Tampoco existe un paquete de PyRadiomics en conda-forge.

Por ello, la biblioteca se compiló directamente a partir del código fuente del repositorio oficial de AIM-Harvard fijado en el commit `8ed579383b44806651c463d5e691f3b2b57522ab`. La compilación se efectuó empleando `scikit-build-core` y `setuptools_scm`, enlazando las extensiones nativas en C directamente contra el entorno local sin aislamiento de construcción (`--no-build-`

`isolation`) para prevenir actualizaciones accidentales de NumPy que pudiesen comprometer la interoperabilidad con Qiskit.

D.3. Especificaciones de hardware y plataforma

Todas las mediciones temporales, consumos de memoria y ejecuciones de simulación exacta reportados fueron llevados a cabo en una estación de trabajo homogénea con las siguientes especificaciones:

- **Procesador:** Apple M3 con microarquitectura ARM64 de 8 núcleos (4 núcleos de rendimiento y 4 de eficiencia energética).
- **Memoria principal:** 16 GB de memoria unificada LPDDR5 (`hw.memsize`: 17 179 869 184 bytes).
- **Sistema operativo:** macOS Sonoma versión 26.6.2 (Darwin Kernel versión 25G83).

D.4. Semillas aleatorias y verificación de reproducción determinista

Para asegurar la reproducibilidad bit a bit de todos los experimentos se definieron semillas deterministas:

- **Semilla global 42:** empleada para la inicialización pseudoaleatoria del vector de parámetros variacionales θ del *ansatz* (D-014), el sorteo de submuestras estratificadas de 200 lesiones para análisis geométrico y el generador de números aleatorios en pruebas de permutación.
- **Semillas de pliegues:** semilla 125 para el subconjunto de masas y semilla 168 para el de calcificaciones (D-026), seleccionadas tras una búsqueda exhaustiva entre candidatos para minimizar la discrepancia máxima en la prevalencia de malignidad entre pliegues.

La totalidad del pipeline experimental (Módulos 2 al 8 y experimentos complementarios X1 al X6) fue objeto de un protocolo de re-ejecución completa y verificación independiente entre el 8 y el 10 de octubre de 2026 sobre un clon limpio del repositorio, constatándose la reproducción exacta e invariable de todas las predicciones, métricas y tablas numéricas obtenidas.

E. Índice de decisiones metodológicas

La bitácora metodológica completa acompaña al presente reporte técnico como material complementario, documentando el contexto, los antecedentes, las alternativas analizadas y las justificaciones numéricas de cada determinación adoptada durante el desarrollo del proyecto. La Tabla 29 recopila el índice cronológico de las 40 decisiones metodológicas registradas (D-001 a D-040), identificando su estado de vigencia y las secciones correspondientes del cuerpo del reporte que fundamentan.

Cuadro 29: Índice cronológico de decisiones metodológicas documentadas en la bitácora.

Identificador	Estado	Título de la decisión	Sección en reporte
D-001	Firme	SelectKBest + MinMaxScaler en lugar de PCA antes del circuito	§ 4.6, § 7.2
D-002	**Revertida**	ZZFeatureMap y PauliFeatureMap como condiciones separadas	§ 4.7, § 7.2
D-003	Firme	Geometric difference como métrica de ventaja cuántica potencial	§ 3.4.2, § 7.2
D-004	Firme	Escalado angular a $[0,\pi]$ y no a $[0,2\pi]$	§ 4.6
D-005	Firme	Masas y calcificaciones como subproblemas independientes	§ 4.4
D-006	Firme	PyRadiomics (Estrategia A) en lugar de encoder CNN	§ 4.5
D-007	Firme	Entorno `radiomics` separado, compilado desde GitHub	§ 8.x
D-008	Firme	`binCount=32` en lugar de `binWidth`	§ 8.x
D-009	Firme	Sin resize a 224×224 en la ruta radiómica	§ 4.4, § 8.x
D-010	Firme	CLAHE fuera de la ruta radiómica	§ 4.4
D-011	Firme	Unidad de análisis = lesión/ROI, no paciente	§ 4.6
D-012	Firme	Descargar por la API REST de TCIA, no con NBIA Data Retriever	§ 8.x
D-013	Firme	Punto de operación: k=12 qubits, reps=1	§ 4.6, § 4.7
D-014	Firme	Arquitectura B: embedding precomputado con θ fijo (semilla 42)	§ 4.7, § 4.8
D-015	**Revertida**	C5 usa `pauli_feature_map(paulis=['X','ZZ'])`	§ 4.7

Continúa en la siguiente página...

Cuadro 29 – *continuación de la página anterior*

Identificador	Estado	Título de la decisión	Sección en reporte
D-016	Firme	C2 se declara control nulo; se mantienen cinco condiciones	§ 4.7, § 6.x
D-017	Firme	La *geometric difference* se calcula con `FidelityQuantumKernel`	§ 3.4.2, § 4.9
D-018	Firme	Validación cruzada 5-fold estratificada sobre el conjunto de entrenamiento	§ 4.8, § 4.9
D-019	Firme	Las líneas de trabajo futuro se atribuyen a Azevedo et al. (2022)	§ 1.3, § 2.1.5
D-020	Firme	Alinear cada máscara según su tipo de desajuste, no remuestrear las 80	§ 4.4, § 8.x
D-021	Firme	Reducir cada máscara a su componente conexa mayor	§ 4.4, § 8.x
D-022	Firme	Contrato de salida de M2: caja + 20 px, intensidades crudas, NRRD	§ 4.4, § 8.x
D-023	Firme	M3 extrae 67 features: cuatro familias sobre la imagen original, sin filtros	§ 4.5
D-024	Firme	Selección por F-test con restricción de redundancia $\|r\| \leq 0.95$	§ 4.6
D-025	Firme	Escalado angular por cuantiles (uniforme $\times$ π) en lugar de min-max	§ 4.6
D-026	Firme	Semilla de los folds elegida por balance de clases	§ 4.9
D-027	Firme	γ del RBF por heurística de la mediana (C3 y kernel clásico de la *geometric difference*)	§ 4.7, § 4.9
D-028	Firme	Separabilidad sobre 200 lesiones de train por subconjunto, estratificadas	§ 4.9
D-029	Firme	Kernel concentrado: se mantiene el diseño fijado de antemano y se añade un barrido del factor de escala	§ 4.9, § 6.x, OE-6
D-030	Firme	La separabilidad pasa a ser el Módulo 6; la clasificación, el M7, y la evaluación comparativa, el M8	§ 4.1–§ 4.9, RF, CRISP-DM
D-031	Firme	C5 pasa a `pauli_feature_map(paulis=['Y','ZZ'])`	§ 4.7, § 6.x

Continúa en la siguiente página...

Cuadro 29 – *continuación de la página anterior*

Identificador	Estado	Título de la decisión	Sección en reporte
D-032	Firme	La *geometric difference* sigue el protocolo de Huang et al. (Apéndice L.3)	§ 3.4.2, § 4.9, RF-16
D-033	Firme	Definiciones de las demás métricas del M6	§ 4.9
D-034	Firme	Se reproduce la Fig. 2 de Huang et al. (2021) en el reporte	§ 3.4.2
D-035	Firme	Se compara contra k = 8 antes de concluir el OE-3, como experimento X3	§ 6.x, § 7, OE-6
D-036	Firme	Protocolo de clasificación del M7: MLP 32-16, estandarización y parada temprana por paciente	§ 4.8, § 6.x
D-037	Firme	Análisis de sensibilidad del M7: reps = 2 en el ansatz, k = 8, semillas y configuraciones	§ 6.x, § 7
D-038	Firme	Análisis exploratorios X4 a X6: QSVM, auditoría y búsqueda de ventaja, con protocolo simétrico	§ 6.x, § 7
D-039	Firme	El Spearman del M8 se reporta como descriptivo: por subconjunto, con su distribución exacta para n = 5	§ 3.4, § 4.10, § 6.x
D-040	Firme	Contenido del M8: OE-6 medido (qubits, shots en el embedding y en el kernel) y referencia con los descriptores del radiólogo	§ 4.10, § 6.x, § 7, OE-6