INSTITUTO POLITÉCNICO NACIONAL · ESCUELA SUPERIOR DE CÓMPUTO

Modelo de transformación cuántica variacional de características de cáncer de mama para un sistema híbrido de prediagnóstico

Trabajo Terminal 2026-B039

PRESENTA

Miguel Alexander Sánchez García

DIRECTORES

Dr. Jesús Yaljá Montiel Pérez · Dra. Ana María Winfield Reyes

24 de noviembre de 2026

Detectar a tiempo cambia la supervivencia de 33 % a más de 99 %

2.3 M

nuevos casos en el mundo, 2022

OMS

8,451

defunciones en México, 2024

INEGI

>99 % vs 33 %

supervivencia a 5 años: etapa temprana frente a metástasis

ACS · SEER

El aprendizaje automático clásico ya clasifica lesiones; la pregunta abierta es si una codificación cuántica las representa de forma más separable.

Ningún trabajo previo había combinado codificación cuántica, CBIS-DDSM y análisis de separabilidad

	Trabajo	Datos	Circuito cuántico	CBIS-DDSM	Analiza separabilidad	Masas y calcs. por separado	Desempeño
Aprendizaje profundo en mamografía	Shen et al. (2019)	CBIS-DDSM	✗	✓	✗	✗	AUC 0.91
	Wang et al. (2020)	DDSM, INbreast, MIAS, UKy	✗	Parcial	✗	✗	AUC 0.88–0.95; externos 0.44–0.65
	Baccouche et al. (2022)	CBIS-DDSM, INbreast	✗	✓	✗	✗	Exactitud 0.95
Aprendizaje cuántico fuera de la mamografía	Xiang et al. (2024)	tabulares (GBSG, SEER, WDBC)	✓ sim.	✗	✗	—	Exactitud 0.70–0.96
	Toufah et al. (2025)	cáncer de pulmón (tabular)	✓ sim.	✗	✗	—	Exactitud 0.91–0.96 (RBF 0.95)
	Parigi et al. (2026)	MNIST, F-MNIST	✓ sim.	✗	✓	—	Exactitud 0.94–0.99
Aprendizaje cuántico en mamografía	Azevedo et al. (2022)	BCDR	✓ sim. y hardware	✗	✗	✗	AUC 0.77 (clásico 0.58)
	Este trabajo	CBIS-DDSM	✓ sim.	✓	✓	✓	AUC masas 0.53/0.58 (C1 0.65); calcs. 0.63/0.65 (C1 0.77)

la combinación que faltaba

Azevedo et al. (2022) dejaron como trabajo futuro...

- separar masas y calcificaciones
- probar otros conjuntos de datos
- ver cómo quedan las clases en el espacio de Hilbert
- probar otras codificaciones

→ este trabajo lo hace

Azevedo et al. (2022), pp. 12–13

La pregunta de investigación

¿En qué medida las transformaciones cuánticas variacionales implementadas mediante **ZZFeatureMap y PauliFeatureMap** en Qiskit **modifican la separabilidad** [1] de clases benigno/maligno de características radiómicas extraídas de mamografías del CBIS-DDSM, y **hasta qué punto esa diferencia se refleja en la capacidad de clasificación** de una misma red neuronal clásica, en comparación con [2] representaciones clásicas construidas a partir del **mismo vector de características**?

Objetivo: viabilidad, no superar a una CNN · Simulación ideal (Qiskit Aer)

Del mamograma a la comparación: el proceso del trabajo

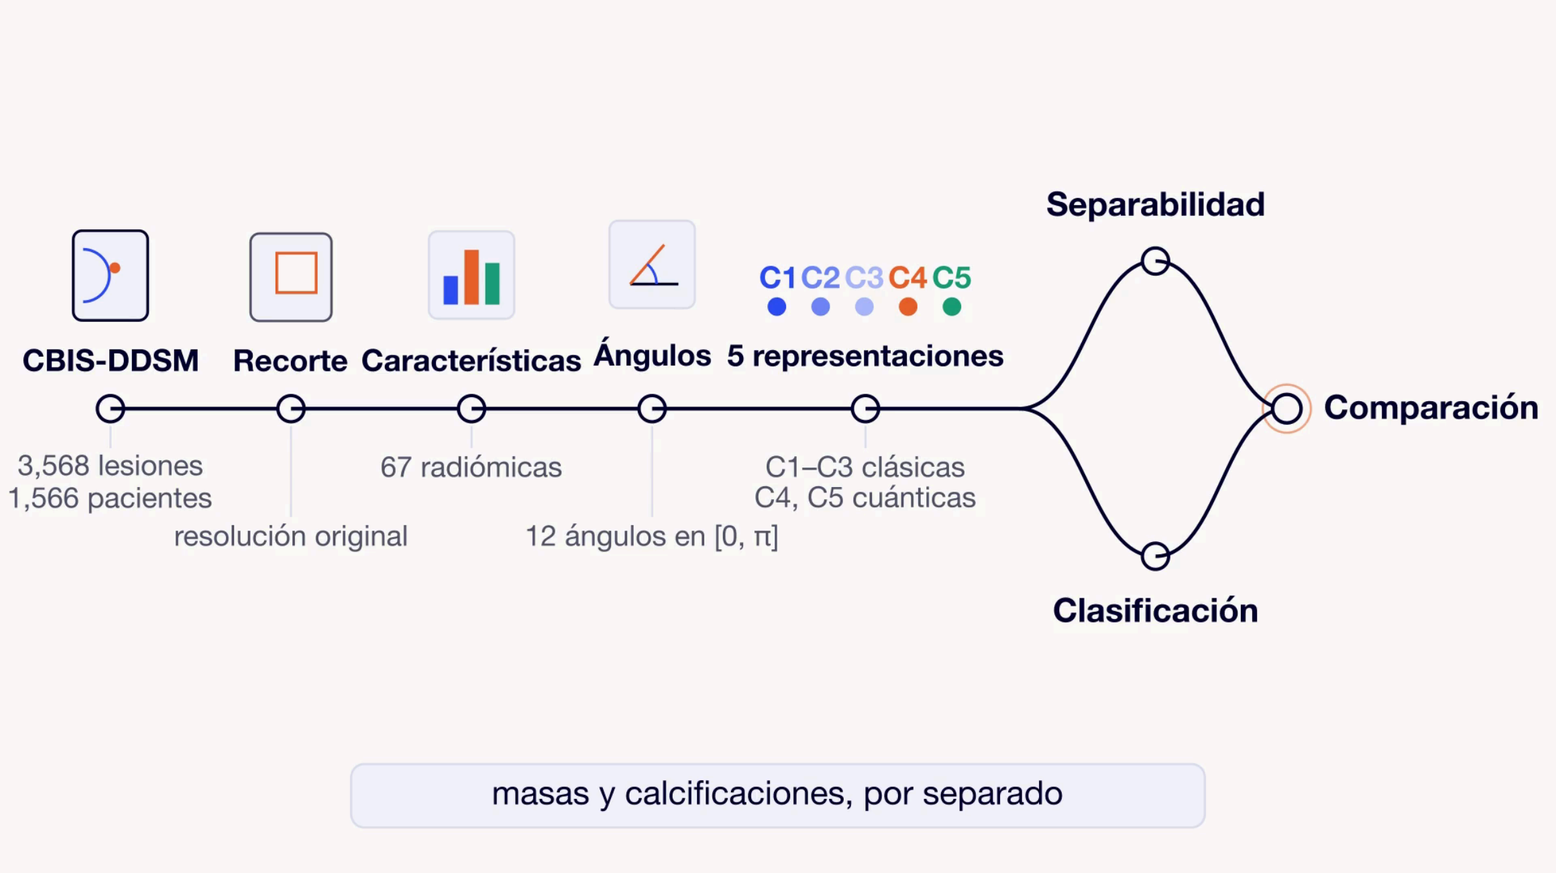

Un qubit es una flecha en una esfera; 12 qubits combinan 4,096 posibilidades

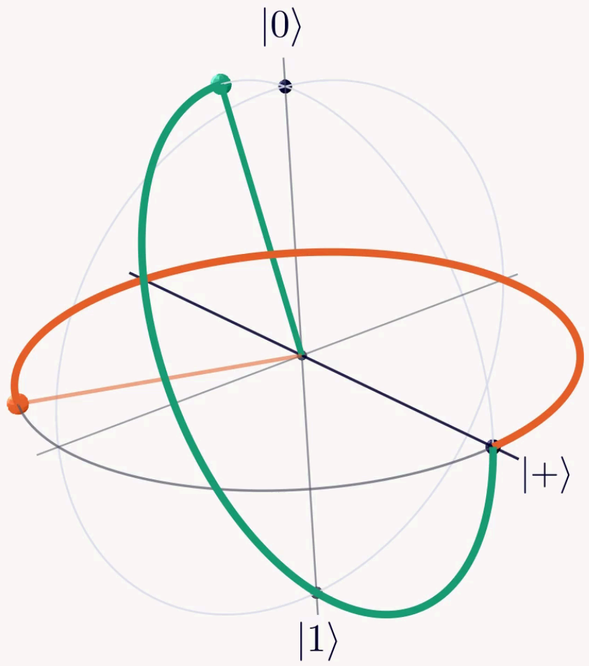

Hadamard

C4: giro en Z, se queda en el ecuador

C5: giro en Y, sale del ecuador

12 qubits = 2^{12} = 4,096 combinaciones

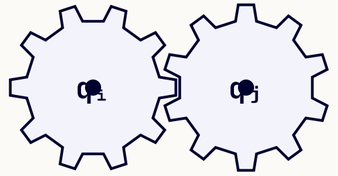

ZZ: cada par gira según sus dos características

esquema ilustrativo

Un circuito convierte 12 números en un estado de 12 qubits, y hay dos formas de leerlo

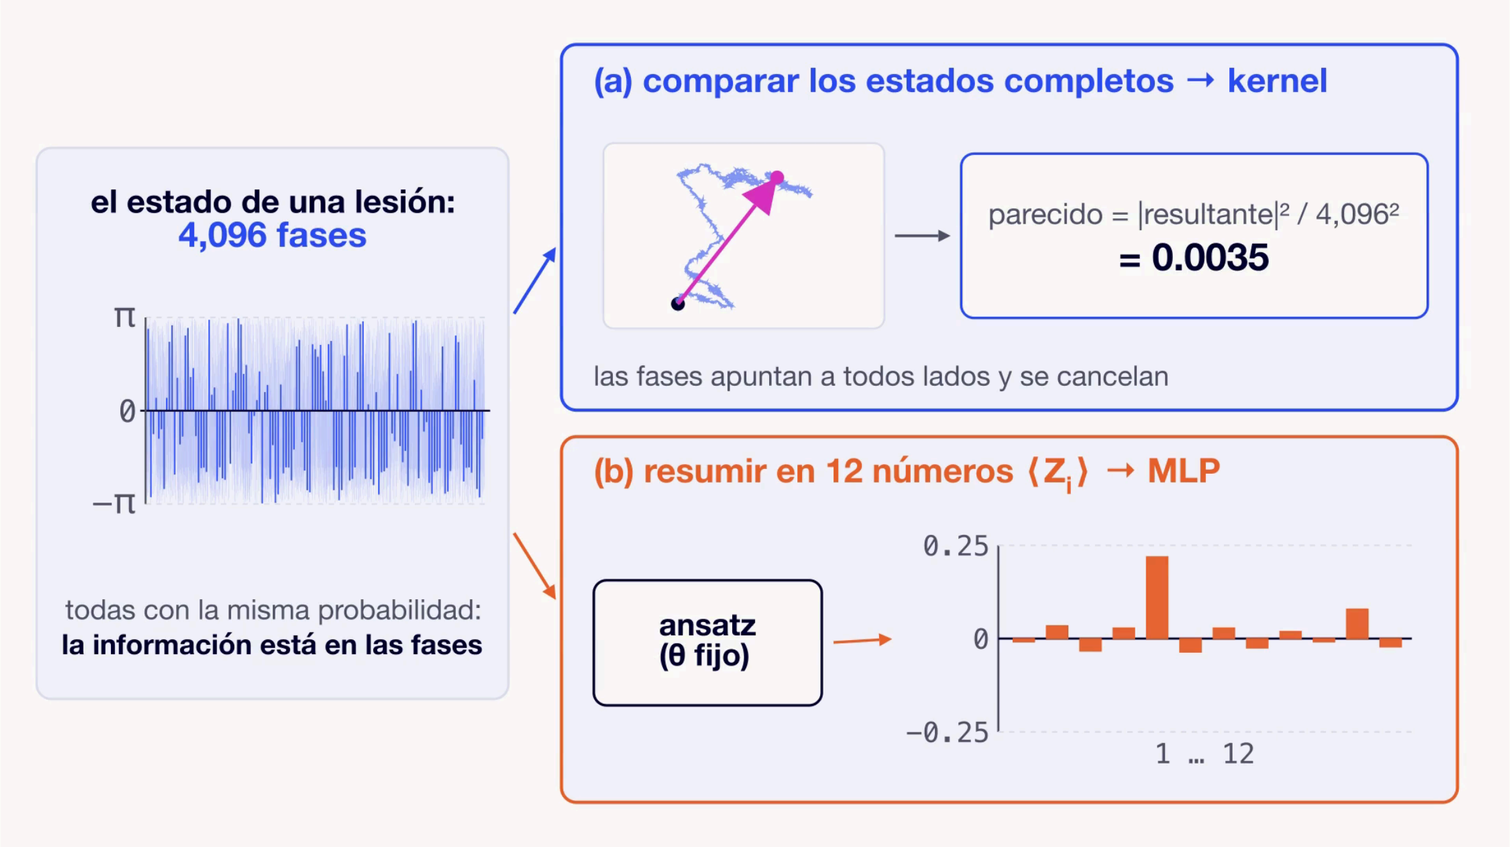

Arquitectura B: θ fijo; los 12 valores se calculan una vez

02 · DISEÑO

Cinco representaciones del mismo vector, un mismo clasificador

C1	**Sin transformación** · referencia		clásico
C2	**PCA lineal** · control nulo: rota, no añade información	girar no cambia la información	clásico
C3	**Kernel PCA con RBF** · no lineal clásico		clásico
C4	**ZZFeatureMap** + ansatz fijo		cuántico
C5	**PauliFeatureMap (Y, ZZ)** + ansatz fijo		cuántico

Misma entrada x, mismo MLP 12→32→16→1, mismos hiperparámetros y semilla. **La única variable es la transformación.**

esquema ilustrativo

03 · RESULTADOS

El kernel cuántico ve casi todos los pares de lesiones como ortogonales

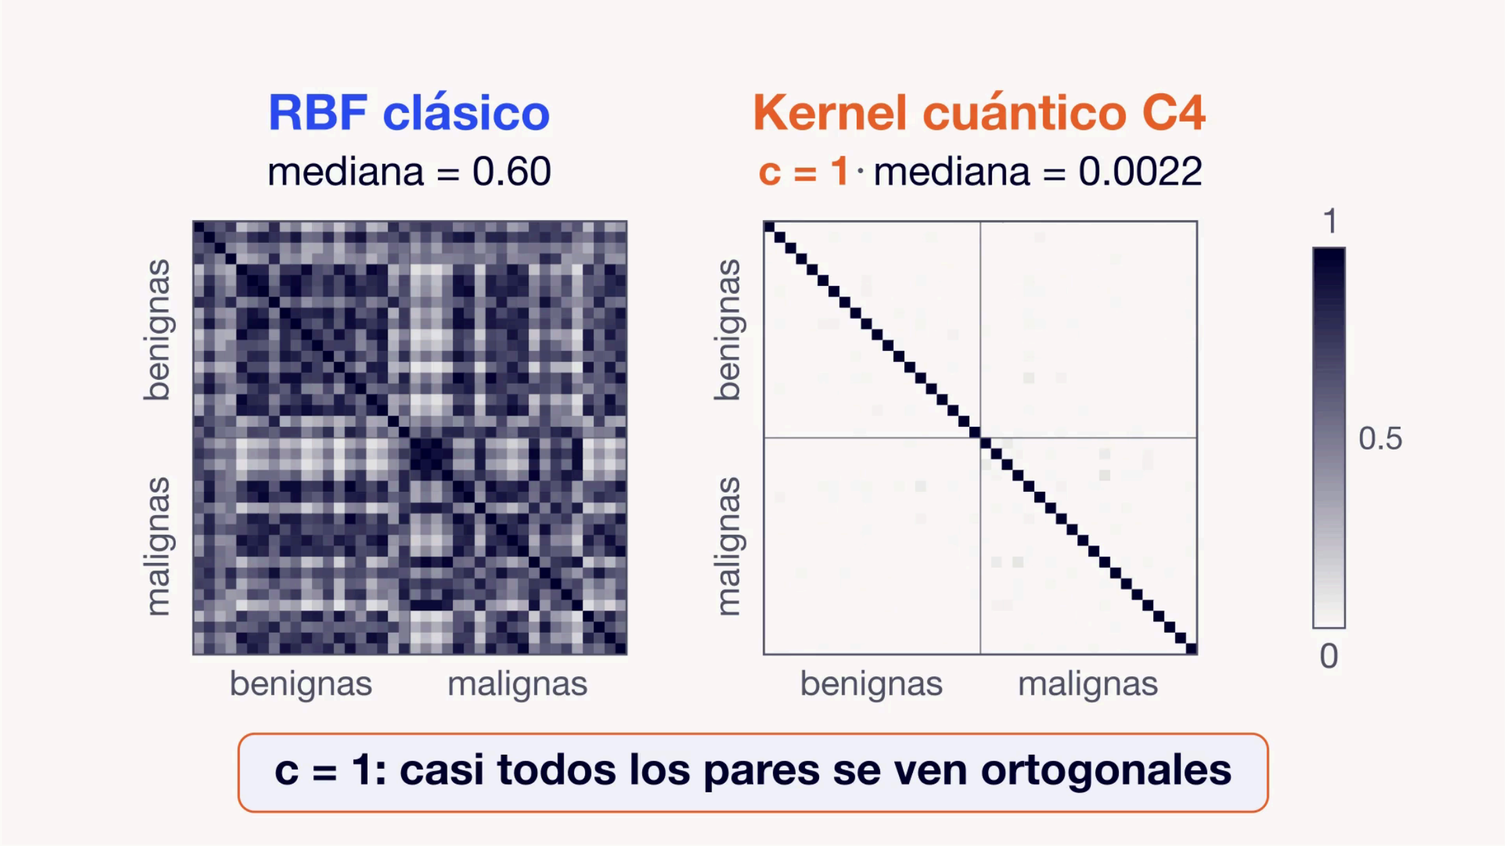

40 lesiones de masas de la submuestra de 200 · cada celda = parecido entre dos lesiones

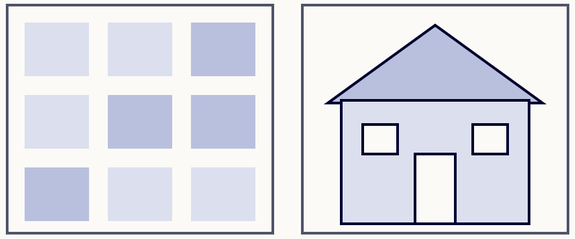

demasiado zoom: todo queda igual de lejos

esquema ilustrativo

Si todas las lesiones están igual de lejos, el parecido no distingue clases: concentración.

Los kernels cuánticos no separan mejor las clases

Alineamiento kernel-objetivo explicado por las etiquetas

¿el parecido entre lesiones coincide con el diagnóstico?

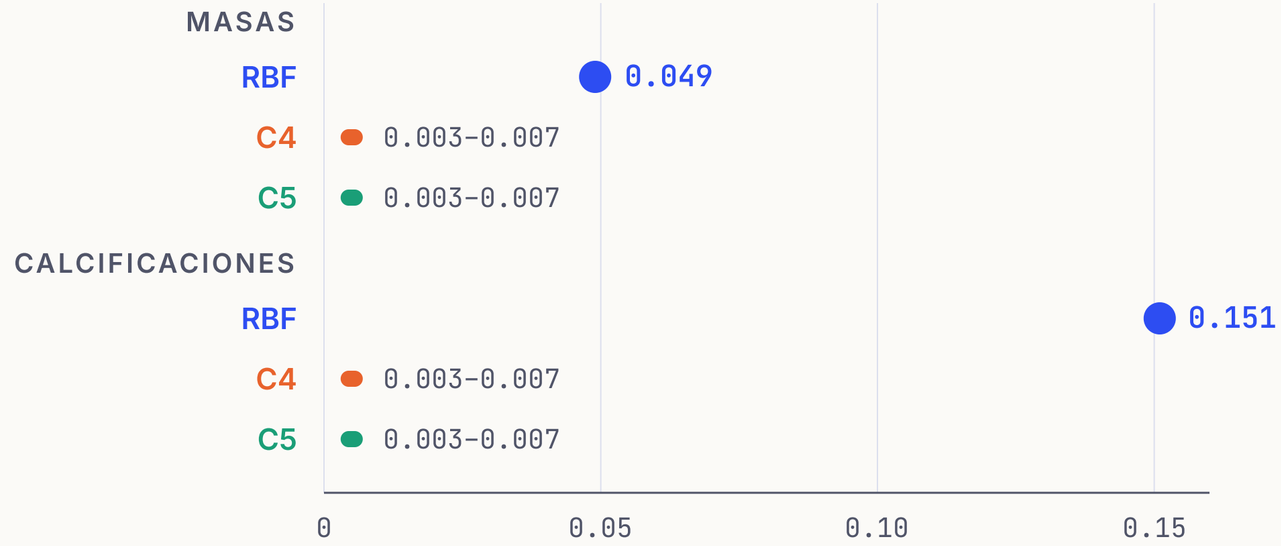

Diferencia geométrica

$$g = 1.40 - 1.70$$

umbral de ventaja potencial: $\sqrt{N} \approx 14.1$

¿el mapa cuántico tiene caminos que el clásico no puede trazar?

03 · RESULTADOS

Las representaciones que recibe el clasificador tampoco separan mejor

Fig. 6.2.4 y 6.2.5 del reporte · 200 lesiones de entrenamiento por subconjunto

03 · RESULTADOS

El mismo MLP clasifica peor sobre los embeddings cuánticos

-0.07 a -0.14 de AUC frente a C1

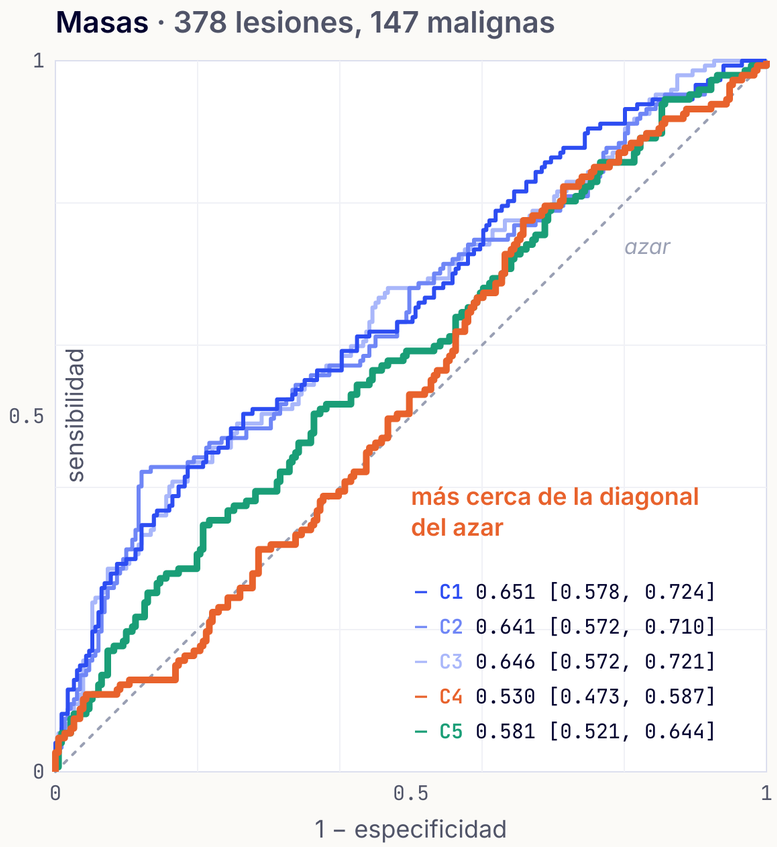

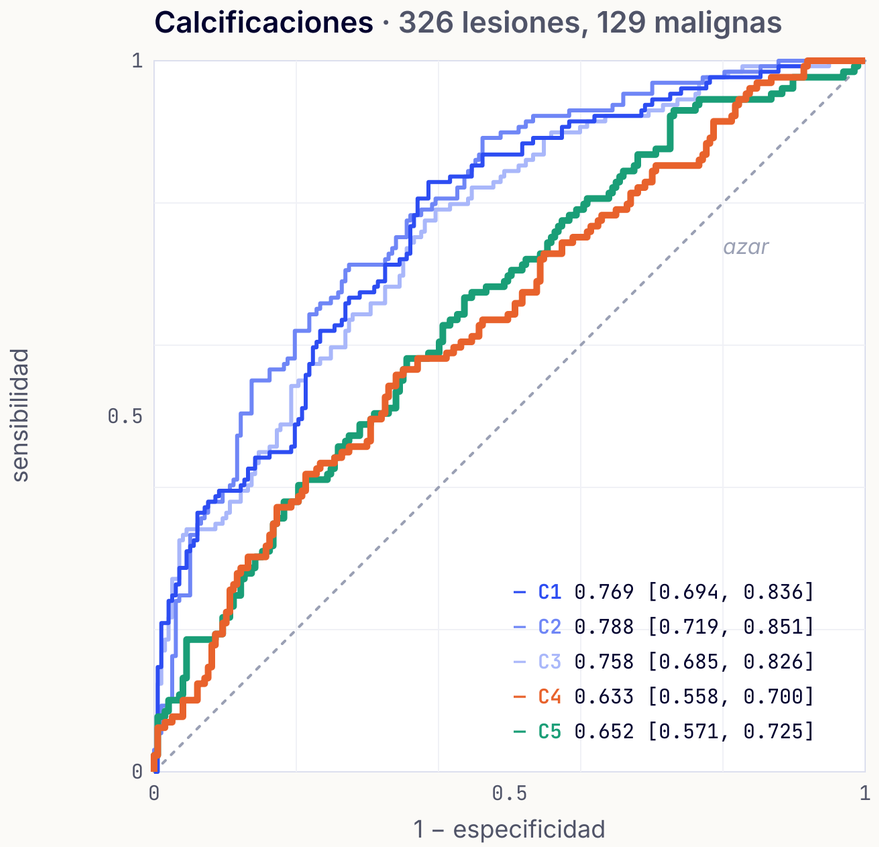

Fig. 6.3.2 del reporte · conjunto de prueba oficial, usado una vez

Con árboles, bosques y *boosting*, ninguna representación cuántica supera a C1

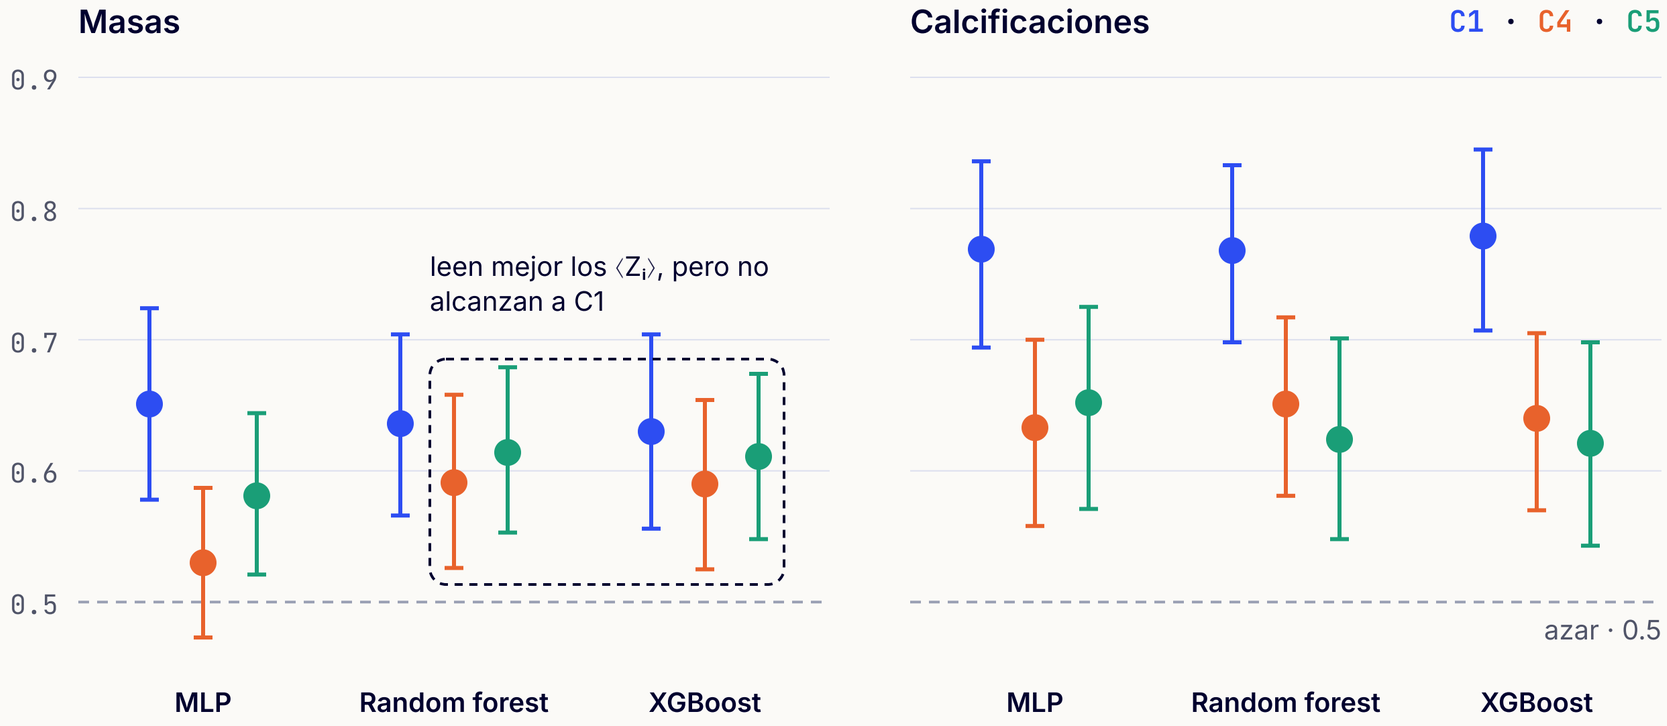

AUC-ROC en prueba · IC 95 %

0 de 24

comparaciones a favor de C4/C5

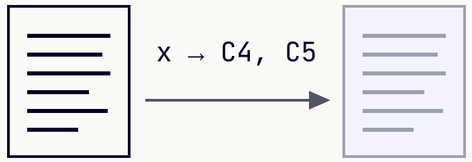

C4 y C5 se calculan a partir de x: no contienen más información que x

esquema ilustrativo

La pérdida está en la lectura de 12 números, no en la codificación

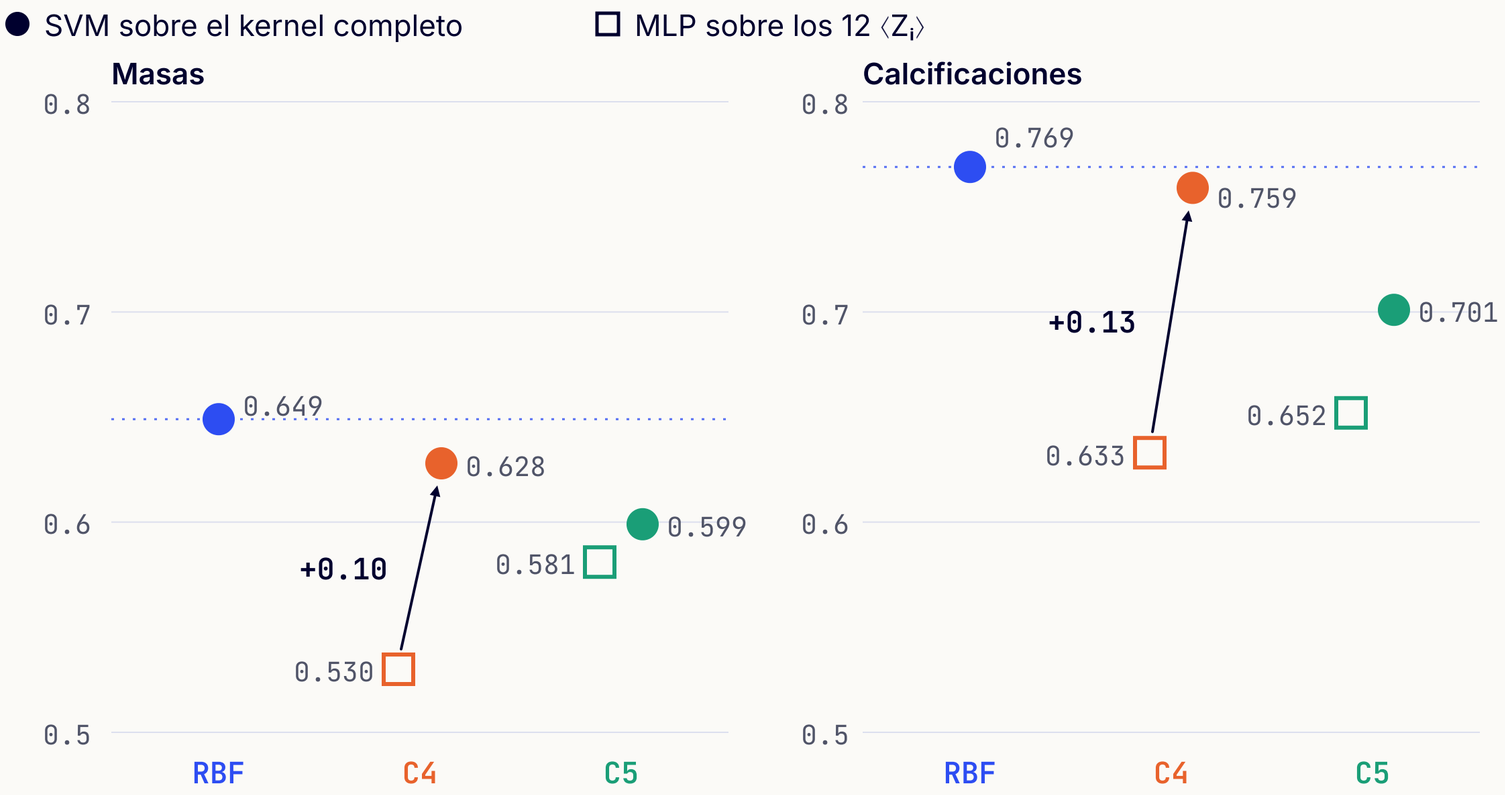

AUC-ROC en prueba · línea punteada azul = nivel de la SVM con RBF

Leído a través de su kernel, el estado cuántico iguala al clasificador clásico; resumido en 12 valores esperados, pierde información.

película completa = el estado

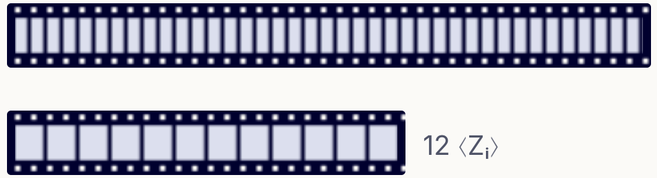

12 ⟨Zᵢ⟩

esquema ilustrativo

Análisis exploratorio

03 · RESULTADOS

Resumen: lo clásico va delante en separabilidad y en clasificación; el QSVM solo empata

	Exceso de KTA ↑	*g*	Davies-Bouldin ↓	Fisher J ↑	AUC en prueba
C1 · sin transformar	—	—	**4.301 / 2.387**	0.669 / 1.284	**0.651** / 0.769
C2 · PCA (control nulo)	—	—	**4.301 / 2.387**	0.669 / 1.284	0.641 / **0.788**
C3 · Kernel PCA RBF	**0.049 / 0.151**	—	5.564 / 2.995	**0.781 / 1.390**	0.646 / 0.758
C4 · ZZ	0.003 / 0.006	1.433 / 1.400	5.898 / 6.890	0.449 / 0.399	0.530 / 0.633
C5 · Y + ZZ	0.005 / 0.007	1.511 / 1.701	13.346 / 6.247	0.668 / 0.753	0.581 / 0.652
SVM sobre el kernel RBF					0.649 / 0.769
QSVM sobre el kernel de C4					0.628 / 0.759

el QSVM empata con el SVM clásico: la información está en el estado, se pierde al leer 12 números

Exceso de KTA de C3 = kernel RBF. *g* muy por debajo de √N ≈ 14.1. AUC de C1–C5 con el mismo MLP; SVM y QSVM del experimento X4.

Tabla 23 del reporte (versión completa en anexos) · cada celda: masas / calcificaciones

La ventaja cuántica sí existe: Huang et al. la construyeron y aquí se reproduce

Huang et al. (2021): con etiquetas diseñadas, el kernel cuántico supera a todos los clásicos

Nature Communications 12, 2631

¿Por qué no se usa siempre?

las etiquetas no se eligen

diseñadas = ventaja asegurada

0.566 vs 0.677

con etiquetas reales, pierde

Mismas lesiones y mismas 12 características, etiquetas diseñadas

AUC-ROC (validación cruzada)

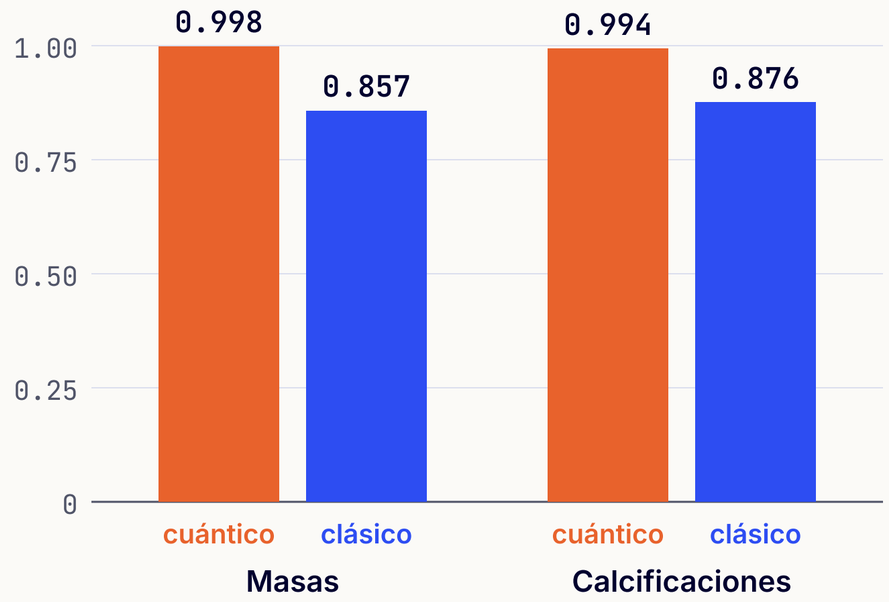

La pregunta deja de ser si la ventaja existe y pasa a ser si el diagnóstico es una de esas tareas.

La ventaja cuántica aparece cuando la tarea sigue la geometría del circuito; el diagnóstico no la sigue

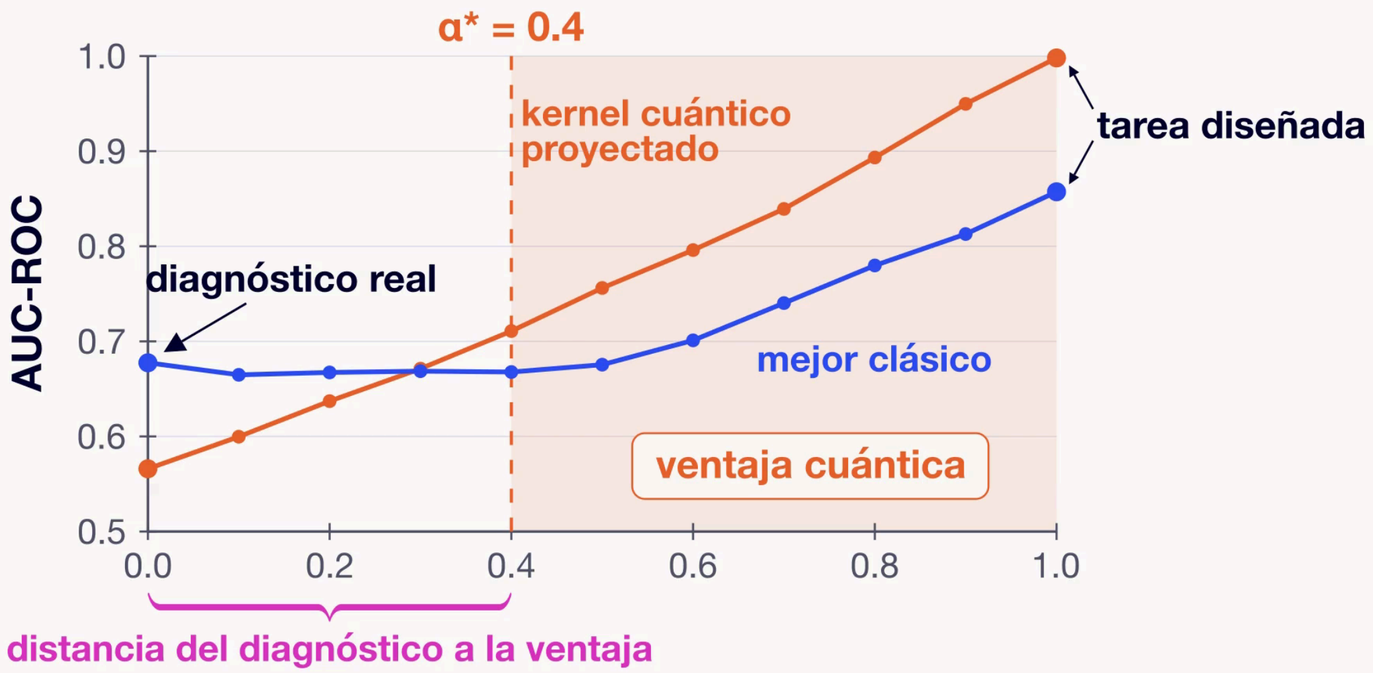

α = cuántas preguntas salen del libro del circuito

esquema ilustrativo

Etiquetas intermedias artificiales: instrumento de medida, no tarea clínica

Simular cabe; medir en hardware sería el problema

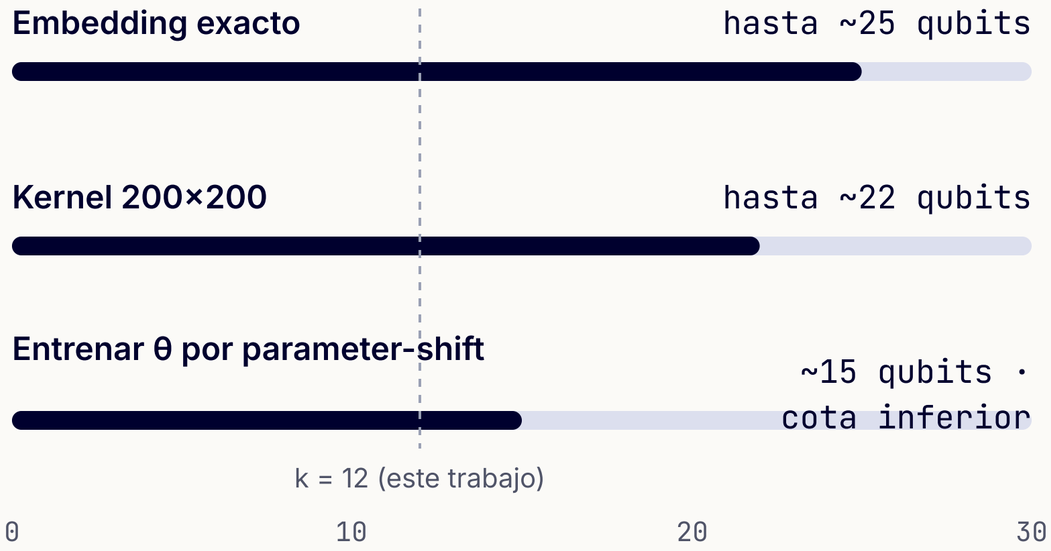

Qubits que caben en 24 h · Apple M3, 16 GiB

Los $\langle Z_i \rangle$ sí toleran 1,024 disparos: el MLP queda a menos de 0.02 del AUC exacto

05 · CONCLUSIONES

Los seis objetivos se cumplieron

> **La codificación cuántica no aumentó la separabilidad; la redujo, y la diferencia se nota al clasificar.**

Objetivo	Estado	Evidencia
General: efecto de la codificación cuántica en la separabilidad y la clasificación	✓ Cumplido	Sin mayor separabilidad; −0.07 a −0.14 de AUC con el mismo MLP
OE-1 · Pipeline de datos sobre CBIS-DDSM	✓ Cumplido	3,568 lesiones, 100 % DICOM; 67 → 12 características; sin fuga entre pacientes
OE-2 · Cinco representaciones del mismo vector	✓ Cumplido	C1–C5 con k = 12; θ fijo con semilla 42
OE-3 · Separabilidad con cuatro métricas	✓ Cumplido	Exceso de KTA 0.003–0.007 frente a 0.049/0.151 del RBF; g = 1.40–1.70 ≪ √N ≈ 14.1
OE-4 · El mismo MLP en las cinco condiciones	✓ Cumplido	12 → 32 → 16 → 1; validación cruzada de 5 folds por paciente
OE-5 · ¿La separabilidad se refleja al clasificar?	✓ Cumplido	Mismo orden en ambos (ρ = 0.67–0.97): C1–C3 delante de C4–C5
OE-6 · Viabilidad práctica	✓ Cumplido	Simulación viable hasta ~25 qubits; en hardware, del 16 al 74 % de los valores del kernel se leerían 0

> *Un resultado negativo, medido con rigor, es evidencia de viabilidad*

06 · CIERRE

Lo que sigue: de cada limitación, una línea de trabajo

	Lo que se observó	Línea de trabajo futuro
</> **Codificación**	El kernel se concentra a c = 1	→ **Codificaciones sin concentración**: ancho de banda por característica y conocimiento del problema
Lectura	12 valores esperados pierden información	→ **Lecturas intermedias**: correlaciones $\langle Z_i Z_j \rangle$ (66 valores) y lectores más profundos
Hardware	Todo fue simulación sin ruido	→ **Procesadores reales**: primero simular con el ruido de un dispositivo, luego medir en uno
Datos	Un solo conjunto, sin escala física	→ **Mamografía digital con escala conocida** y validación externa

Gracias · ¿Preguntas?

Miguel Alexander Sánchez García

Anexos

1 Estado del arte
2 Qubit
3 Entrelazamiento
4 Feature map
5 Kernel y SVM
6 Medición
7 Simulación
8 AUC-ROC
9 Radiómica
10 Pregunta completa
11 θ fijo
12 θ entrenado
13 Arquitecturas
14 Modelos
15 k = 12
16 Repeticiones
17 Cuantiles
18 ZZ y Pauli
19 Por qué C2
20 200 lesiones
21 5 folds
22 Preprocesamiento
23 Sin fuga de información
24 La respuesta en cinco puntos
25 Todas las métricas
26 AUC en prueba con intervalos de confianza
27 Resumen completo de resultados (Tabla 23)
28 Métricas de separabilidad con su significancia
29 t-SNE
30 QSVM
31 Búsqueda simétrica
32 Robustez
33 Separabilidad y clasificación
34 Barrido de c
35 Masas y calcificaciones
36 Métricas de separabilidad
37 Umbral α*
38 Fórmulas de la codificación
39 Fórmulas de las dos lecturas
40 Fórmulas de separabilidad
41 Diferencia geométrica g
42 Medición y gradiente
43 Fórmulas de clasificación
44 Kernels clásicos
45 ¿Vale un resultado negativo?
46 ¿Por qué no una CNN?
47 Intensidades
48 De 67 a 12 características
49 Generalización
50 ¿Cuándo hardware?
51–86 **Figuras del reporte técnico (3.4.1 a C.4.1)**

ANEXO 1

Estado del arte: la tabla completa

Trabajo	Datos	Cuántico	CBIS-DDSM	Separab.	Masas/calcs.	Desempeño	P1	P2	P3	P4
Profundo · mamografía										
Shen et al. (2019)	CBIS-DDSM	×	✓	×	×	AUC 0.91	—	—	—	—
Wang et al. (2020)	DDSM, INbreast, MIAS, UKy	×	Parcial	×	×	AUC 0.88–0.95; externos 0.44–0.65	—	—	—	—
Baccouche et al. (2022)	CBIS-DDSM, INbreast	×	✓	×	×	Exactitud 0.95	—	—	—	—
Cuántico · otros datos										
Xiang et al. (2024)	tabulares (GBSG, SEER, WDBC)	✓ sim.	×	×	—	Exactitud 0.70–0.96	Parcial	No	No	No
Toufah et al. (2025)	cáncer de pulmón (tabular)	✓ sim.	×	×	—	Exactitud 0.91–0.96 (RBF 0.95)	Sí	No	ND	No
Parigi et al. (2026)	MNIST, F-MNIST	✓ sim.	×	✓	—	Exactitud 0.94–0.99	Sí	Sí	Sí	No
Cuántico · mamografía										
Azevedo et al. (2022)	BCDR	✓ sim. y hardware	×	×	×	AUC 0.77 (clásico 0.58)	Parcial	No	No	No
Este trabajo	CBIS-DDSM	✓ sim.	✓	✓	✓	AUC masas 0.53/0.58 (C1 0.65); calcs. 0.63/0.65 (C1 0.77)	Sí	Sí	Sí	No

P1 paridad: el clásico recibe los mismos datos y ajuste · P2 incertidumbre reportada · P3 conjunto de prueba usado una vez · P4 circuito difícil de simular · ND: el trabajo no lo dice

Un qubit puede estar en una mezcla de 0 y 1

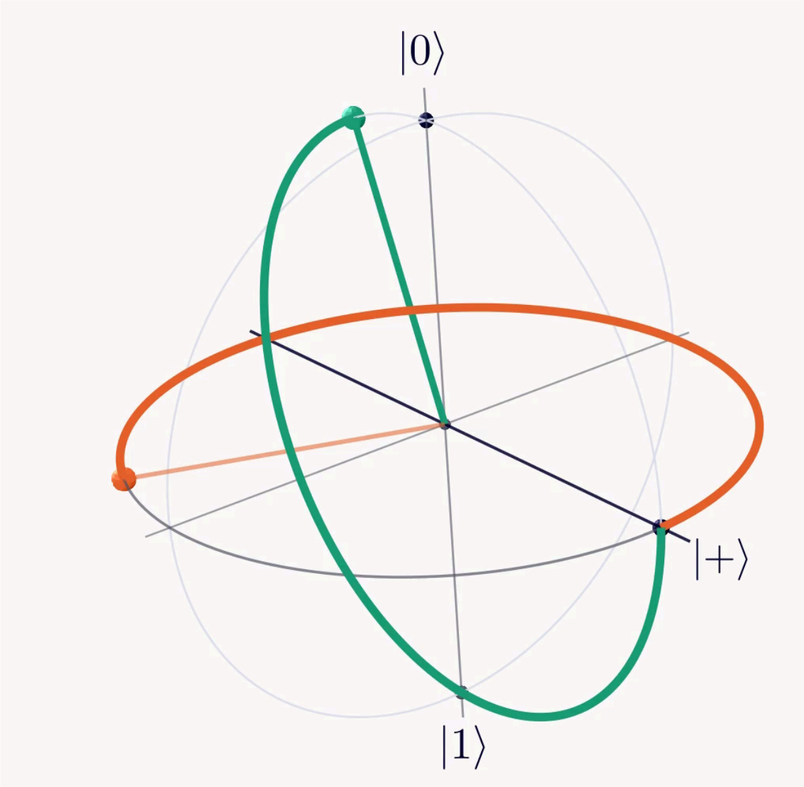

$$|\psi\rangle = \cos\frac{\theta}{2}|0\rangle + e^{i\varphi}\sin\frac{\theta}{2}|1\rangle$$

ANEXO 3

Entrelazar es acoplar los qubits: el todo no se describe por partes

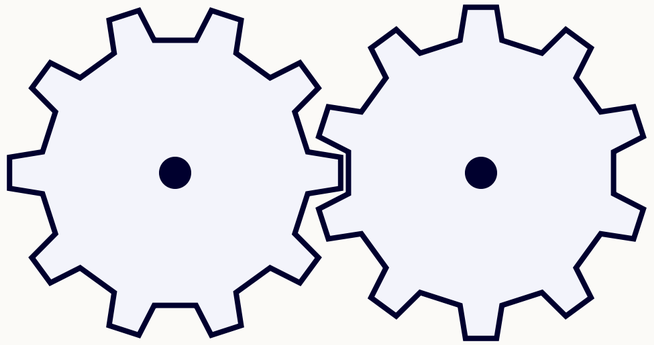

12 qubits → 2^{12} = 4,096 dimensiones

esquema ilustrativo

ANEXO 4

Un *feature map* convierte un vector de números en un estado cuántico

ANEXO 5

Un kernel mide el parecido entre dos lesiones; una SVM separa con ese parecido

k = parecido

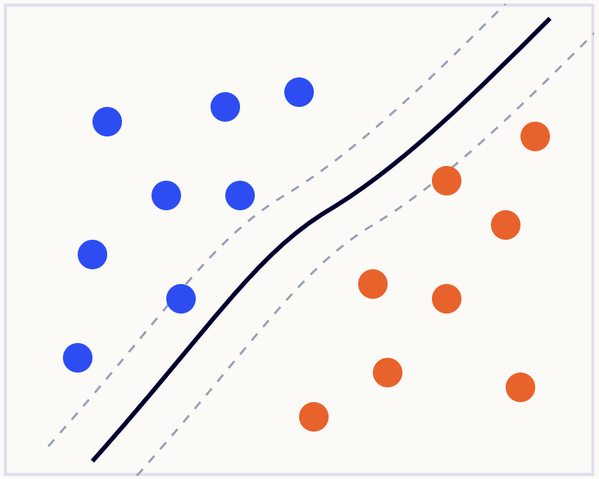

SVM: frontera

esquema ilustrativo

Medir un qubit es como hacer una encuesta

$$\mathrm{Var}(\hat{Z}_i) = \frac{1 - \langle Z_i \rangle^2}{n_{\mathrm{shots}}}$$

ANEXO 7

Todo se hizo en simulación exacta, a propósito

Simulador

exacto, sin ruido

Hardware

ruido y disparos

AUC-ROC: 0.5 es azar, 1 es perfecto

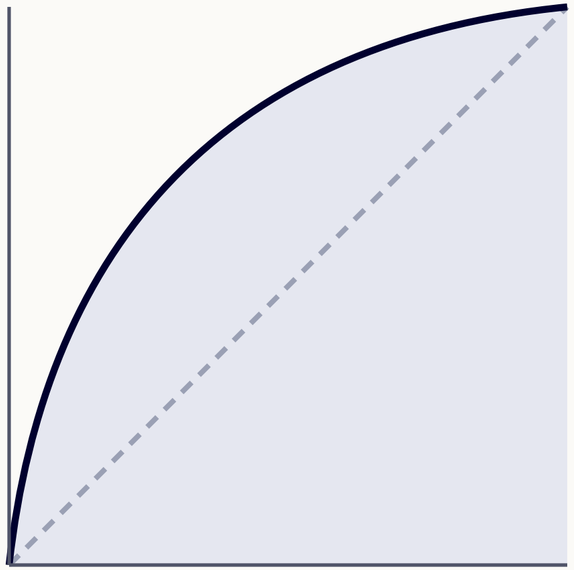

horizontal: FPR · vertical: TPR · punteada: azar

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}\, d\,\mathrm{FPR}$$

esquema ilustrativo

ANEXO 9

67 características radiómicas de forma, intensidad y textura

forma 2D	primer orden (intensidad)	GLCM (textura)	GLRLM (textura)

Las 12 elegidas en masas

- `Maximum`
- `MinorAxisLength`
- `MeshSurface`
- `10Percentile`
- `90Percentile`
- `MaximumDiameter`
- `PerimeterSurfaceRatio`
- `Correlation (GLCM)`
- `Energy`
- `Perimeter`
- `GrayLevelNonUniformity (GLRLM)`
- `RunLengthNonUniformity (GLRLM)`

ANEXO 10

La pregunta de investigación completa

> ¿En qué medida las transformaciones cuánticas variacionales implementadas mediante ZZFeatureMap y PauliFeatureMap en Qiskit modifican la separabilidad de clases benigno/maligno de características radiómicas extraídas de mamografías del CBIS-DDSM, y hasta qué punto esa diferencia se refleja en la capacidad de clasificación de una misma red neuronal clásica, en comparación con representaciones clásicas construidas a partir del mismo vector de características?

ANEXO 11

θ se fijó por tres razones: justicia, pregunta y costo

Justicia

C2 y C3 no ven las etiquetas; un θ entrenado sí. La comparación dejaría de ser pareja.

Pregunta

Se mide el efecto de la codificación, no de un modelo entrenado.

Costo

Entrenar θ por *parameter-shift* costaba 22.4 h a k = 8 y 2,689 h a k = 16, por condición.

ANEXO 12

¿Y si se entrenaba θ? Como mucho igualaría a lo clásico; en la práctica, ni eso

AUC en prueba

	θ fijo	θ entrenado	Entrenado - C1
Masas, C4	0.530	0.533	-0.118
Masas, C5	0.581	0.585	-0.066
Calcif., C4	0.633	0.674	-0.094
Calcif., C5	0.652	0.671	-0.098

C4 y C5 se calculan a partir de x: no pueden saber más que x

ANEXO 13

Las tres arquitecturas del trabajo

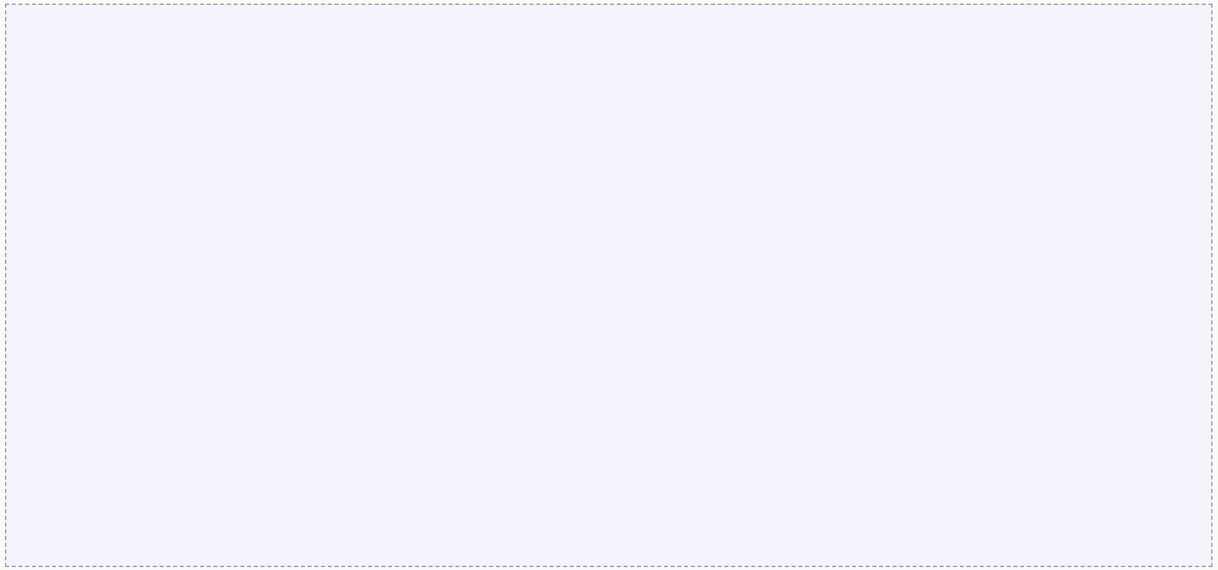

H · P(2x_i) · ZZ · real_amplitudes (reps = 1, 24 parámetros)

MLP

12 → 32 → 16 → 1

QSVM

kernel cuántico → SVM

ANEXO 14

Qué modelos se compararon y dónde

Modelo	Sobre	Dónde
MLP 12-32-16-1	C1–C5	M7 (principal), X7, X8, X10
SVM clásica (lineal, polinomial, RBF)	x	X4, X6, X11
QSVM (kernel de C4/C5, ZZ lineal, proyectado)	kernel cuántico	X4, X6, X11
Árbol de decisión, random forest, XGBoost	C1–C5	X10
Regresión logística	67 o 12 características, descriptores del radiólogo	X1, M8

ANEXO 15

12 qubits por costo y por diversidad de características; con 8, la conclusión es la misma

$$k = 12$$

k = 8: misma conclusión

Una repetición del circuito; con dos, C4 y C5 siguen por debajo

reps = 1

reps = 2: C4 y C5 siguen por debajo

ANEXO 17

Ángulos en [0, π] por cuantiles

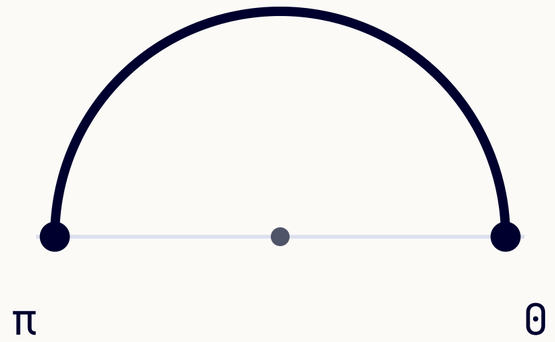

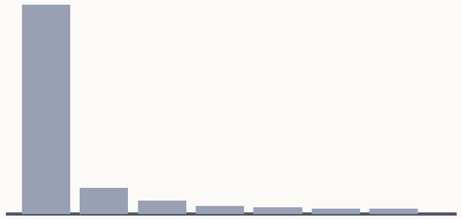

min-max: casi constante

cuantiles: uniforme

esquema ilustrativo

C4 y C5 comparten el entrelazamiento ZZ; difieren en el eje del giro de cada qubit

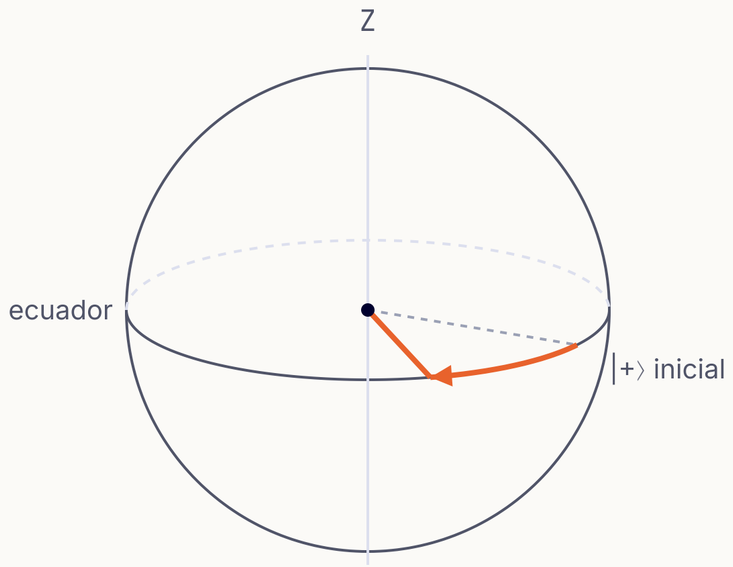

C4 · giro $P(2x_i)$ en Z

permanece en el ecuador

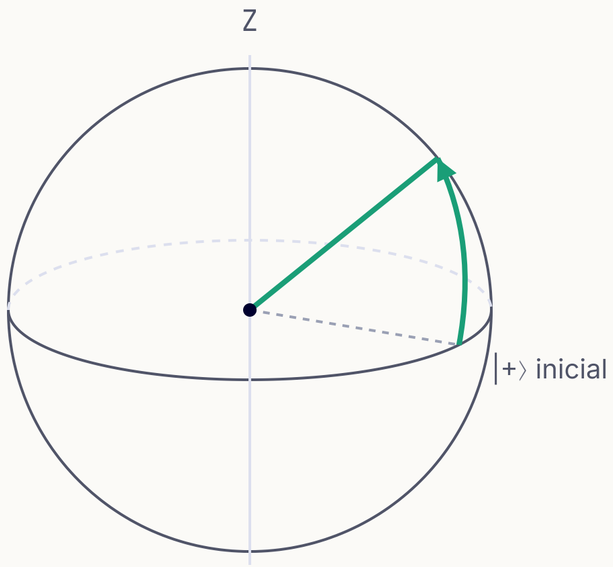

C5 · giro $RY(2x_i)$ en Y

sale del ecuador

Mismo bloque ZZ entre pares y mismo ansatz. Solo cambia el eje del giro por característica.

esquema ilustrativo

(Z, ZZ) es el mismo circuito que ZZ · (X, ZZ) no codifica nada con una repetición

C2 es un control nulo: rotar no cambia la información

girar no cambia la información

esquema ilustrativo

ANEXO 20

Separabilidad sobre 200 lesiones: el tamaño repetible en hardware

200 lesiones	→ 19,900 circuitos por matriz
todo el entrenamiento	→ 0.87–1.19 millones

ANEXO 21

¿Por qué 5 folds? Es el mayor número que mantiene equilibradas las clases

Folds	Entrena con	Desviación máx. de la proporción de malignas (masas / calc.)	Malignas en el fold más pobre (masas / calc.)	Peso del paciente más grande (calc.)
3	67 %	0.003 / 0.003	200 / 167	5 %
5	80 %	0.011 / 0.019	122 / 96	9 %
10	90 %	0.044 / 0.045	57 / 49	17 %

C4 − C1 y C5 − C1 en validación cruzada, con 5 y con 3 folds

	C4−C1 (5)	C4−C1 (3)	C5−C1 (5)	C5−C1 (3)
Masas	−0.087	−0.123	−0.089	−0.098
Calcificaciones	−0.102	−0.119	−0.075	−0.092

Con 3 folds la conclusión no cambia

ANEXO 22

Se corrigieron 80 máscaras y se conservó la escala original de cada lesión

80

máscaras desalineadas

78 masas escaladas ×0.870 y 2 calcificaciones desplazadas

1

componente conexa

se conserva la mayor de cada máscara

1:1

resolución original

sin CLAHE ni 224×224: destruyen las medidas de tamaño

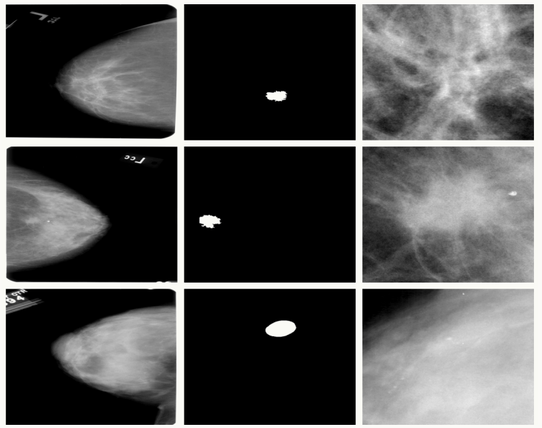

Completa · máscara · ROI recortada

ANEXO 23

Ningún paciente aparece a la vez en entrenamiento y en prueba

01

Particiones por paciente

StratifiedGroupKFold, 5 particiones, estratificadas por clase

02

Pérdida ponderada

entropía cruzada binaria ponderada por el desbalance de clases

03

Parada temprana

sobre el 15 % de los pacientes de entrenamiento

04

Prueba una sola vez

704 lesiones, evaluadas al final del estudio

ANEXO 24

Respuesta: la codificación cuántica no aumentó la separabilidad; la redujo

1. C4 y C5 separan peor que C1–C3 en todas las métricas
2. Se nota al clasificar: −0.07 a −0.14 de AUC; 0 de 24 a favor
3. Causa: concentración y lectura de 12 números
4. La ventaja existe con etiquetas diseñadas; el diagnóstico está en $\alpha = 0$
5. Viable en simulación; en hardware, el kernel sería inmedible

> *Un resultado negativo, medido con rigor, es evidencia de viabilidad.*

ANEXO 25

Todas las métricas de clasificación, en prueba

	AUC	F1	Exactitud	Precisión	Sensibilidad
Masas C1	0.651	0.519	0.638	0.536	0.503
Masas C2	0.641	0.512	0.616	0.507	0.517
Masas C3	0.646	0.502	0.606	0.493	0.510
Masas C4	0.530	0.386	0.529	0.392	0.381
Masas C5	0.581	0.456	0.571	0.450	0.463
Calcif. C1	0.769	0.665	0.666	0.551	0.837
Calcif. C2	0.788	0.669	0.693	0.584	0.783
Calcif. C3	0.758	0.652	0.653	0.541	0.822
Calcif. C4	0.633	0.504	0.607	0.504	0.504
Calcif. C5	0.652	0.565	0.571	0.472	0.705

MLP del M7, umbral 0.5 · fuente: 8_tabla_clasificacion.csv

AUC en prueba con intervalos de confianza

-0.07 a -0.14 de AUC frente a C1

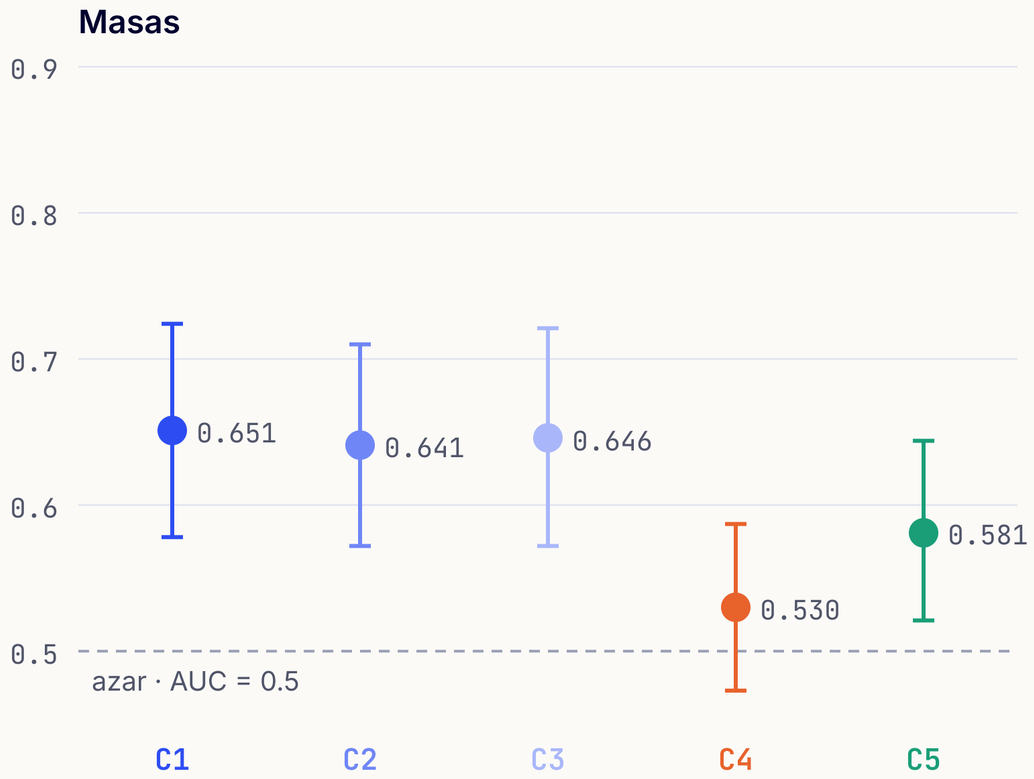

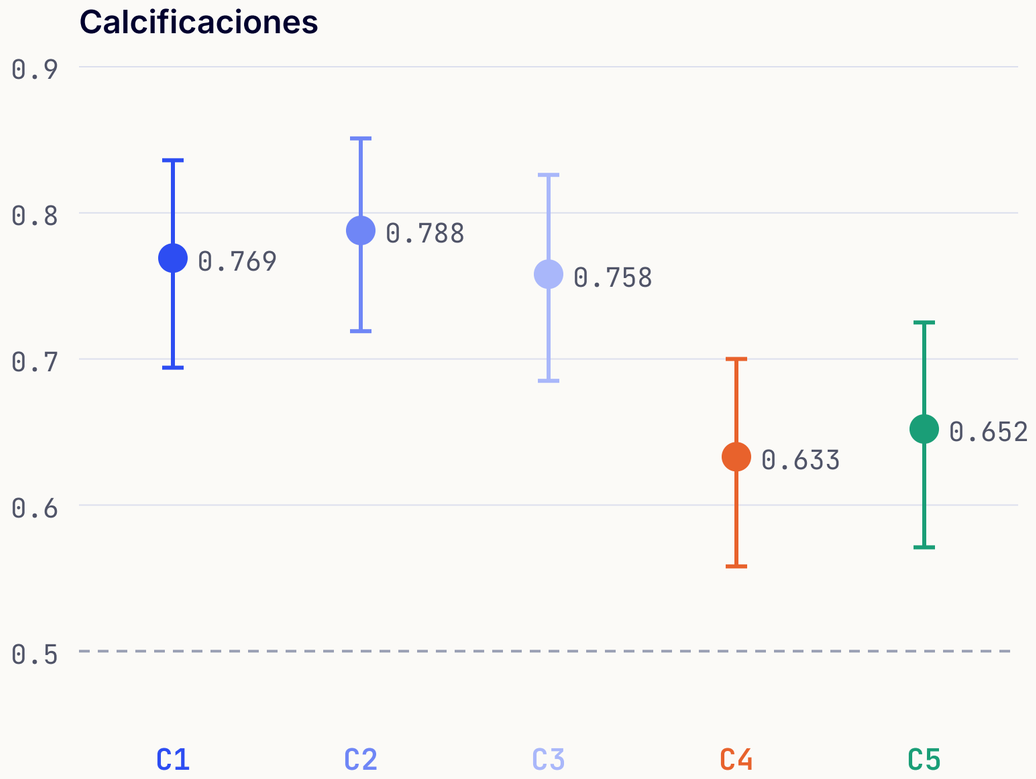

AUC-ROC en prueba · punto = estimación · barra = IC 95 % (bootstrap por paciente)

ANEXO 27

Resumen completo de resultados (Tabla 23 del reporte)

	Exceso de KTA ↑	d_eff (de 200)	g	Davies-Bouldin ↓	Fisher J ↑	AUC en VC	AUC en prueba
C1 · sin transformar	—	—	—	4.301 / 2.387	0.669 / 1.284	0.652 / 0.742	0.651 / 0.769
C2 · PCA (control nulo)	—	—	—	4.301 / 2.387	0.669 / 1.284	0.641 / 0.758	0.641 / 0.788
C3 · Kernel PCA RBF	0.049 / 0.151	2.8 / 2.6	—	5.564 / 2.995	0.781 / 1.390	0.648 / 0.739	0.646 / 0.758
C4 · ZZ	0.003 / 0.006	184.0 / 187.7	1.433 / 1.400	5.898 / 6.890	0.449 / 0.399	0.565 / 0.640	0.530 / 0.633
C5 · Y + ZZ	0.005 / 0.007	171.3 / 167.6	1.511 / 1.701	13.346 / 6.247	0.668 / 0.753	0.563 / 0.667	0.581 / 0.652
SVM sobre el kernel RBF							0.649 / 0.769
QSVM sobre el kernel de C4							0.628 / 0.759
QSVM sobre el kernel de C5							0.599 / 0.701

Cada celda: masas / calcificaciones. Exceso de KTA de C3 = kernel RBF. g muy por debajo de $\sqrt{N} \approx 14.1$. d_eff: dimensión efectiva del kernel, de 200. AUC de C1–C5 con el mismo MLP; SVM y QSVM del experimento X4, en el conjunto de prueba.

ANEXO 28

Métricas de separabilidad con su significancia

	C1	C2	C3	C4	C5
Masas · Davies-Bouldin ↓	4.301 (p = 0.001)	4.301 (p = 0.001)	5.564 (p = 0.001)	5.898 (p = 0.002)	13.346 (p = 0.409)
Masas · Fisher J ↑	0.669 (p = 0.004)	0.669 (p = 0.004)	0.781 (p = 0.002)	0.449 (p = 0.050)	0.668 (p = 0.003)
Masas · Alineamiento lineal ↑	0.070 (p = 0.001)	0.070 (p = 0.001)	0.059 (p = 0.001)	0.041 (p = 0.001)	0.012 (p = 0.406)
Calcificaciones · Davies-Bouldin ↓	2.387 (p = 0.001)	2.387 (p = 0.001)	2.995 (p = 0.001)	6.890 (p = 0.018)	6.247 (p = 0.005)
Calcificaciones · Fisher J ↑	1.284 (p = 0.001)	1.284 (p = 0.001)	1.390 (p = 0.001)	0.399 (p = 0.152)	0.753 (p = 0.003)
Calcificaciones · Alineamiento lineal ↑	0.181 (p = 0.001)	0.181 (p = 0.001)	0.161 (p = 0.001)	0.031 (p = 0.010)	0.041 (p = 0.005)

Valor p frente a 1,000 permutaciones de las etiquetas · en magenta, p > 0.05 (no se distingue del azar) · 200 lesiones de entrenamiento por subconjunto · Fig. 6.2.4 del reporte

ANEXO 29

t-SNE: ninguna representación separa visualmente las clases

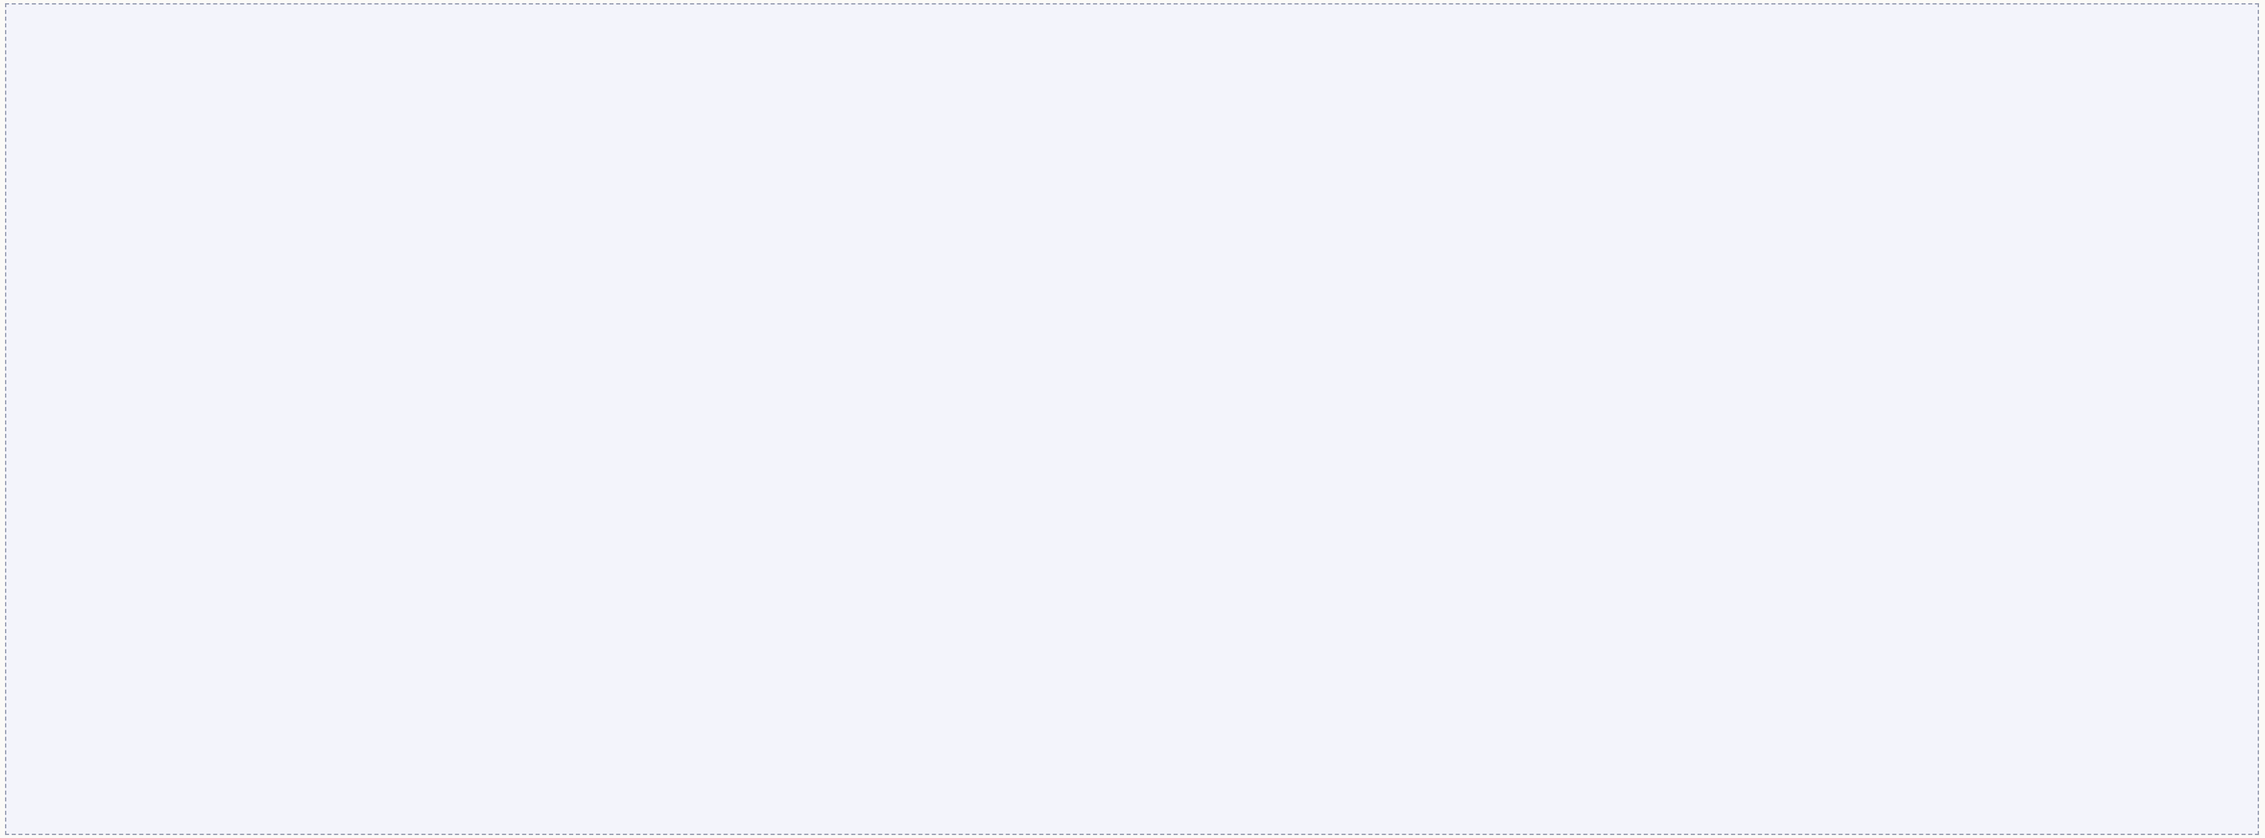

ANEXO 30

Un QSVM sobre el kernel de C4 iguala al SVM clásico

AUC en prueba

	Masas	Calcificaciones
SVM RBF	0.649	0.769
QSVM C4	0.628	0.759
QSVM C5	0.599	0.701
MLP sobre $\langle Z_i \rangle$ de C4	0.530	0.633

ANEXO 31

Buscando ventaja con la misma búsqueda en los dos lados: ninguna

Kernels clásicos

búsqueda anidada

=

Kernels cuánticos

la misma búsqueda

Con etiquetas reales, ningún kernel cuántico supera a los clásicos

ANEXO 32

La conclusión resiste cambios en θ, en k y en la muestra

10 sorteos de θ	déficit frente a C1 de 0.03 a 0.18 de AUC
θ entrenado	+0.05 como máximo, no significativo
k = 8 características	misma conclusión
20 submuestras	RBF delante en el 100 %
6 clasificadores (árboles, *random forest*, XGBoost, MLP)	0 de 24 comparaciones a favor de C4/C5

ANEXO 33

Separabilidad y clasificación ordenan las condiciones de forma parecida

$\rho = 0.67 - 0.97$

Spearman entre métricas de separabilidad y AUC · descriptivo, n = 5 condiciones

Delante — C1–C3

Detrás — C4–C5

en todos los rankings

ANEXO 34

Reducir la escala de los ángulos quita la concentración, pero también la interacción

Mediana del kernel C4, masas · escala logarítmica

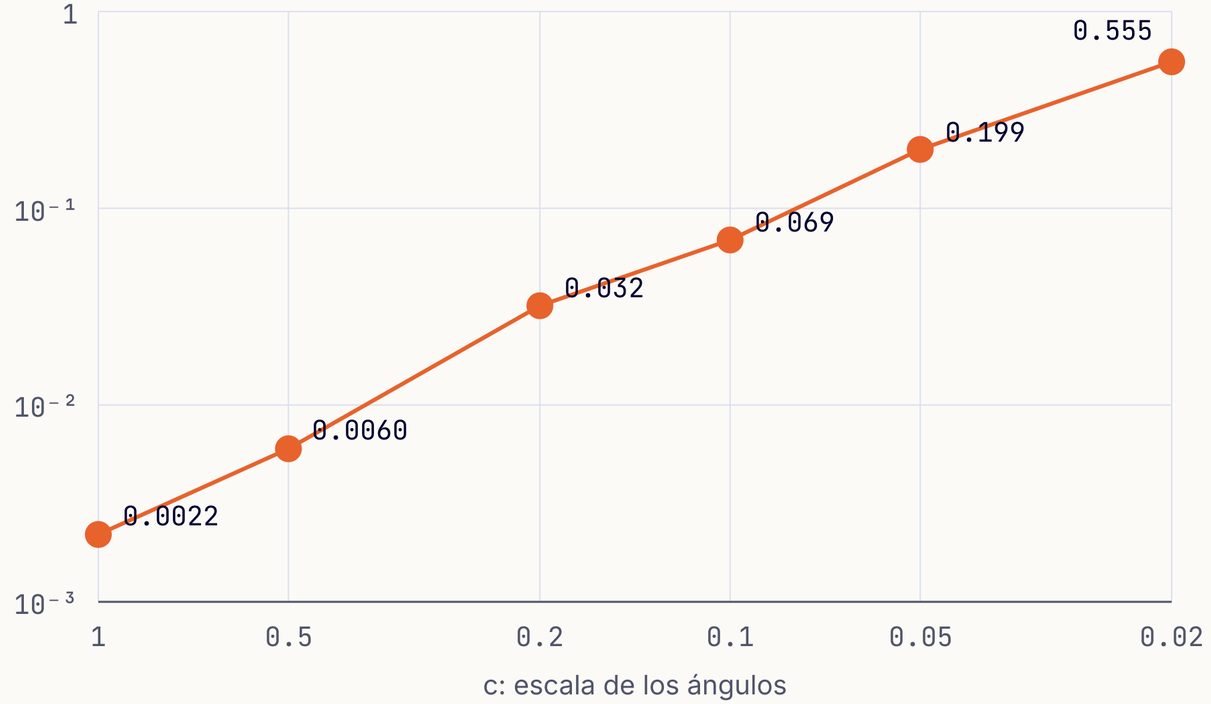

idéntico al kernel sin el término $x_i x_j$ (correlación 1.0000)

demasiado lejos: se pierden las calles (las interacciones)

esquema ilustrativo

ANEXO 35

Con descriptores del radiólogo las masas son más separables; con radiómica, menos

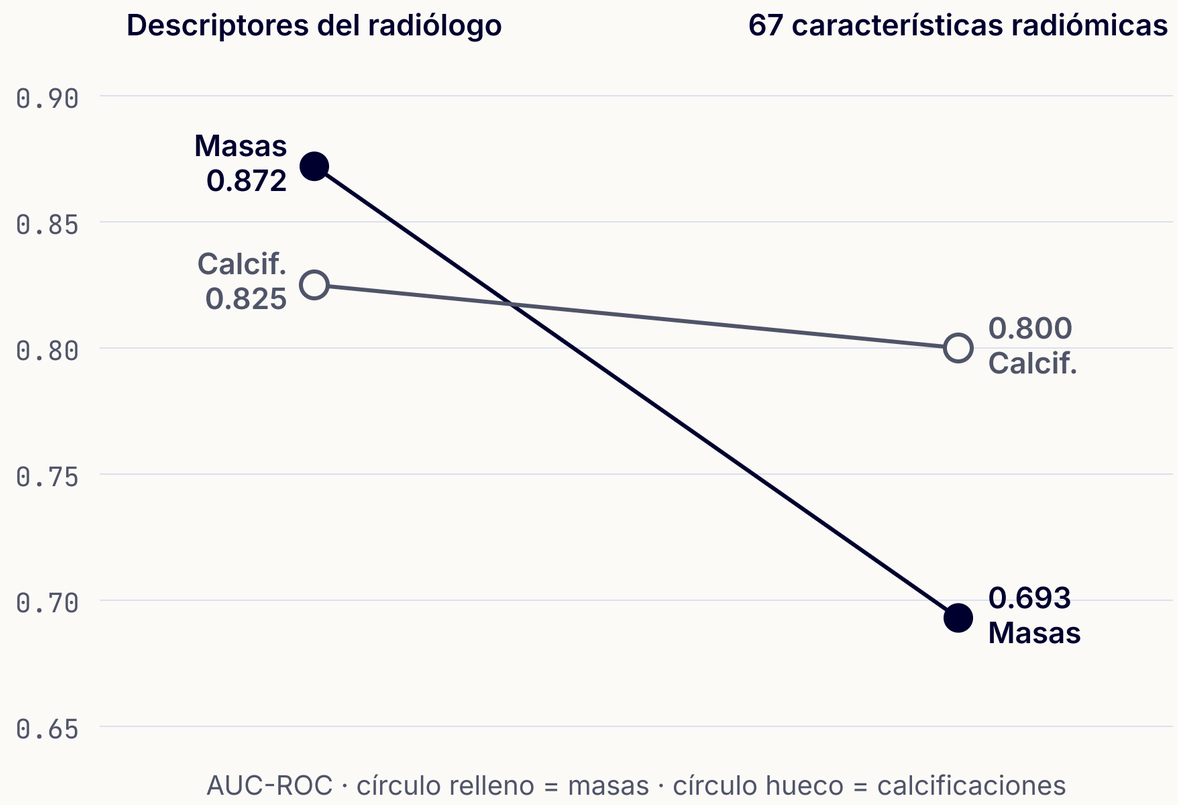

AUC-ROC · círculo relleno = masas · círculo hueco = calcificaciones

La dificultad relativa de masas y calcificaciones se invierte según la representación.

ANEXO 36

Separabilidad medida antes de clasificar

En el kernel

Alineamiento kernel-objetivo

exceso sobre etiquetas permutadas

Diferencia geométrica g

Huang et al., 2021 · ventaja potencial solo si g ≈ √N

En los vectores

Davies-Bouldin

↓ menor es mejor

Razón de Fisher

↑ mayor es mejor

t-SNE

cualitativo

Clasificación: AUC-ROC (principal), F1, exactitud, precisión, sensibilidad. Validación cruzada de 5 particiones por paciente.

ANEXO 37

Umbral α* de cada kernel

Kernel cuántico	Masas	Calcificaciones
ZZ completo (C4)	0.6	0.7
ZZ lineal	0.5	0.6
Proyectado	0.4	0.5

el diagnóstico real está en α = 0

ANEXO 38

La codificación

estado $$|\phi(\mathbf{x})\rangle = U(\mathbf{x})\,|0\rangle^{\otimes n}$$

mapa ZZ $$U_{\mathrm{ZZ}}(\mathbf{x}) = \left[\mathcal{U}_{\Phi}(\mathbf{x})\,H^{\otimes n}\right]^{r}$$

con $$\mathcal{U}_{\Phi}(\mathbf{x}) = \exp\left(-i \sum_{|S|\leq 2} \phi_S(\mathbf{x}) \bigotimes_{j\in S} Z_j\right)$$

fases $$\phi_{\{i\}}(\mathbf{x}) = x_i, \qquad \phi_{\{i,j\}}(\mathbf{x}) = (\pi - x_i)(\pi - x_j)$$

n: qubits · r: repeticiones · H: Hadamard · Z_j: Pauli Z en el qubit j · φ_S: fase del conjunto S de qubits

ANEXO 39

Las dos lecturas

kernel	$K_Q(\mathbf{x}, \mathbf{x}') = \left\lvert \langle \phi(\mathbf{x}) \rvert \phi(\mathbf{x}') \rangle \right\rvert^2$
valores esperados	$\langle Z_i \rangle = \langle \psi(\mathbf{x}, \boldsymbol{\theta}) \rvert Z_i \rvert \psi(\mathbf{x}, \boldsymbol{\theta}) \rangle \in [-1, 1]$
con	$\lvert \psi(\mathbf{x}, \boldsymbol{\theta}) \rangle = W(\boldsymbol{\theta})\, U(\mathbf{x})\, \lvert 0 \rangle^{\otimes n}$
parámetros del *ansatz*	$m = n\,(r+1) = 24$

W(θ): *ansatz* · θ: sus parámetros · Z_i: Pauli Z en el qubit i · n: qubits · r: repeticiones

ANEXO 40

Separabilidad

alineamiento

$$\widehat{\mathrm{KTA}}_c(K, \mathbf{y}) = \frac{\langle K_c, (\mathbf{y}\mathbf{y}^\top)_c \rangle_F}{\|K_c\|_F \, \|(\mathbf{y}\mathbf{y}^\top)_c\|_F}$$

piso

$$\widehat{\mathrm{KTA}}_c(I, \mathbf{y}) = \frac{1}{\sqrt{N-1}}$$

exceso

$$\Delta\mathrm{KTA}_c = \widehat{\mathrm{KTA}}_c(K, \mathbf{y}) - \mathbb{E}_\pi[\widehat{\mathrm{KTA}}_c(K, \mathbf{y}_\pi)]$$

Fisher

$$J = \Delta\boldsymbol{\mu}^\top S_W^{-1} \Delta\boldsymbol{\mu}$$

Davies-Bouldin

$$\mathrm{DB} = \frac{1}{C} \sum_i \max_{j \neq i} \frac{s_i + s_j}{d(c_i, c_j)}$$

K_c: kernel centrado · y: etiquetas · π: permutación · S_W: dispersión intraclase · s_i: dispersión del grupo i · c_i: su centro

ANEXO 41

La diferencia geométrica acota la ventaja posible del kernel cuántico

sin regularizar

$$g_{CQ} = \sqrt{\left\| \sqrt{K_Q}\, K_C^{-1}\, \sqrt{K_Q} \right\|_\infty}$$

regularizada

$$g = \sqrt{\left\| \sqrt{K_Q}\, \sqrt{K_C}\, (K_C + \lambda I)^{-2}\, \sqrt{K_C}\, \sqrt{K_Q} \right\|_\infty}$$

condición

$$g_{\mathrm{tra}}(K_C, K_Q; \lambda) = \lambda \sqrt{\| \sqrt{K_Q} (K_C + \lambda I)^{-2} \sqrt{K_Q} \|_\infty} < 0.045$$

cota

$$s_C \leq g^2\, s_Q$$

(Huang et al., 2021, p. 5)

dimensión efectiva

$$d(K) = \sum_{k=1}^{N} \frac{1}{N-k+1} \sum_{l=k}^{N} t_l, \qquad 1 \leq d \leq N$$

K_Q: kernel cuántico de fidelidad · K_C: kernel clásico: lineal y 9 gaussianos; se toma el mínimo · λ: regularización · ‖·‖∞: norma espectral · s: complejidad del modelo

Protocolo de Huang et al. (2021), suplemento, sección 12 C. Ventaja potencial solo si g ≈ √N; aquí g = 1.40–1.70 frente a √N ≈ 14.1.

ANEXO 42

Medición y gradiente

ruido de un valor esperado	$\mathrm{Var}(\hat{Z}_i) = \dfrac{1 - \langle Z_i \rangle^2}{n_{\mathrm{shots}}}$
ruido de un valor del kernel	$\dfrac{K_Q(1 - K_Q)}{n_{\mathrm{shots}}}$
probabilidad de leer exactamente 0	$(1 - K_Q)^{n_{\mathrm{shots}}}$
parameter-shift	$\dfrac{\partial \langle Z_i \rangle}{\partial \theta_j} = \dfrac{1}{2}\left[\langle Z_i \rangle_{\theta_j + \frac{\pi}{2}} - \langle Z_i \rangle_{\theta_j - \frac{\pi}{2}}\right]$

n_shots: disparos · K_Q: valor del kernel · θ_j: parámetro j del *ansatz*

ANEXO 43

Clasificación

pérdida ponderada

$$\mathcal{L}_w = -\left[w_1\, y \log \hat{y} + w_0\, (1-y) \log(1-\hat{y})\right]$$

con

$$w_c = \frac{N}{C \cdot N_c}$$

AUC

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}(t)\, d\,\mathrm{FPR}(t)$$

Spearman con empates

$$\rho_s = \frac{\sum (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum (R_i - \bar{R})^2 \sum (S_i - \bar{S})^2}}$$

w_c: peso de la clase c · N_c: lesiones de la clase c · C: número de clases · R, S: rangos promedio

ANEXO 44

Los kernels clásicos de referencia

RBF

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$$

con

$$\gamma = \frac{1}{2 \, \mathrm{med}_{i<j} \, \|\mathbf{x}_i - \mathbf{x}_j\|^2}$$

PCA conserva distancias

$$\|\mathbf{z} - \mathbf{z}'\| = \|\mathbf{x} - \mathbf{x}'\|$$

kernel proyectado

$$k^{\mathrm{PQ}}(\mathbf{x}, \mathbf{x}') = \exp\left(-\gamma \sum_k \|\rho_k(\mathbf{x}) - \rho_k(\mathbf{x}')\|_F^2 \right)$$

γ: ancho de banda · z: vector tras PCA · ρ_k(x): estado del qubit k

ANEXO 45

¿Un resultado negativo vale? Sí: el método detecta la ventaja cuando existe

Objetivo: viabilidad →

control positivo

0.998 vs 0.857

diapositiva 16

¿Por qué no una CNN?

~~mamografía ~5,037 × 2,960 px → circuito de 12 qubits~~

mamografía → 67 características → 12 ángulos

¿Las intensidades no calibradas meten el efecto del digitalizador?

Un sesgo, si existe, afecta a las cinco por igual

ANEXO 48

¿Cuánto se pierde al quedarse con 12 de 67?

67 → 12

de 2 a 4 puntos de AUC

ANEXO 49

¿El resultado se generaliza?

un solo conjunto

CBIS-DDSM

sin escala física

PixelSpacing ausente

familias probadas

mapas ZZ y proyectados

ANEXO 50

¿Cuándo valdría la pena el hardware?

- ✓ etiquetas que siguen la geometría del circuito
- ✓ un kernel que no se concentre
- ✓ una codificación difícil de simular

ANEXOS · FIGURAS DEL REPORTE

Índice de figuras del reporte

Figura 3.4.1	→ Anexo 51	Figura 6.2.4	→ Anexo 63	Figura 6.4.1	→ Anexo 75
Figura 4.3.1	→ Anexo 52	Figura 6.2.5	→ Anexo 64	Figura 6.4.2	→ Anexo 76
Figura 4.3.2	→ Anexo 53	Figura 6.2.6	→ Anexo 65	Figura 6.4.3	→ Anexo 77
Figura 5.6.1	→ Anexo 54	Figura 6.2.7	→ Anexo 66	Figura 6.4.4	→ Anexo 78
Figura 5.7.1	→ Anexo 55	Figura 6.2.8	→ Anexo 67	Figura 6.4.5	→ Anexo 79
Figura 6.1.1	→ Anexo 56	Figura 6.3.1	→ Anexo 68	Figura 6.5.1	→ Anexo 80
Figura 6.1.2	→ Anexo 57	Figura 6.3.2	→ Anexo 69	Figura 6.5.2	→ Anexo 81
Figura 6.1.3	→ Anexo 58	Figura 6.3.3	→ Anexo 70	Figura 6.6.1	→ Anexo 82
Figura 6.1.4	→ Anexo 59	Figura 6.3.4	→ Anexo 71	Figura 6.6.2	→ Anexo 83
Figura 6.2.1	→ Anexo 60	Figura 6.3.5	→ Anexo 72	Figura C.1.1	→ Anexo 84
Figura 6.2.2	→ Anexo 61	Figura 6.3.6	→ Anexo 73	Figura C.1.2	→ Anexo 85
Figura 6.2.3	→ Anexo 62	Figura 6.3.7	→ Anexo 74	Figura C.4.1	→ Anexo 86

Figura 3.4.1 · Geometría de los kernels clásico y cuántico (Huang et al., 2021)

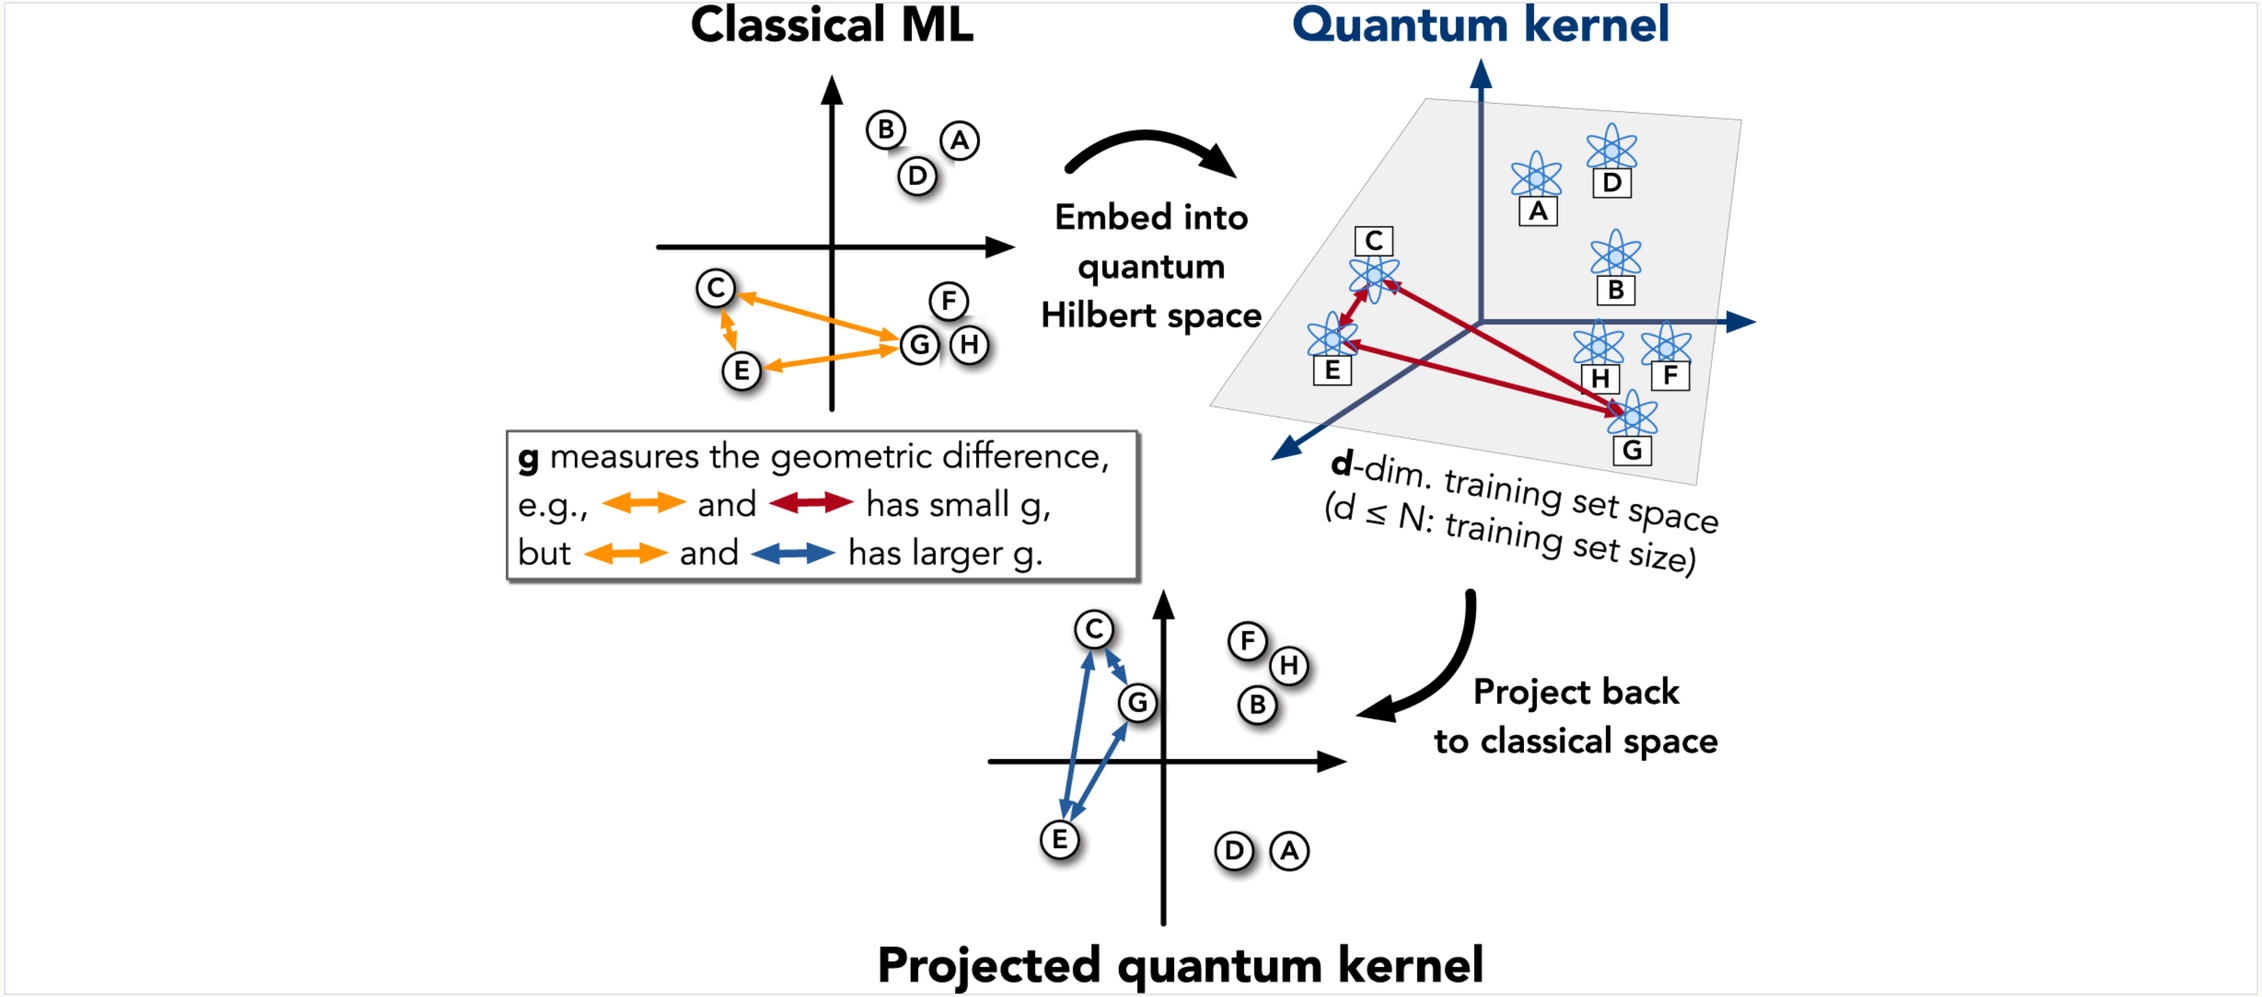

ANEXO 52

Figura 4.3.1 · Forma y margen de las masas por patología

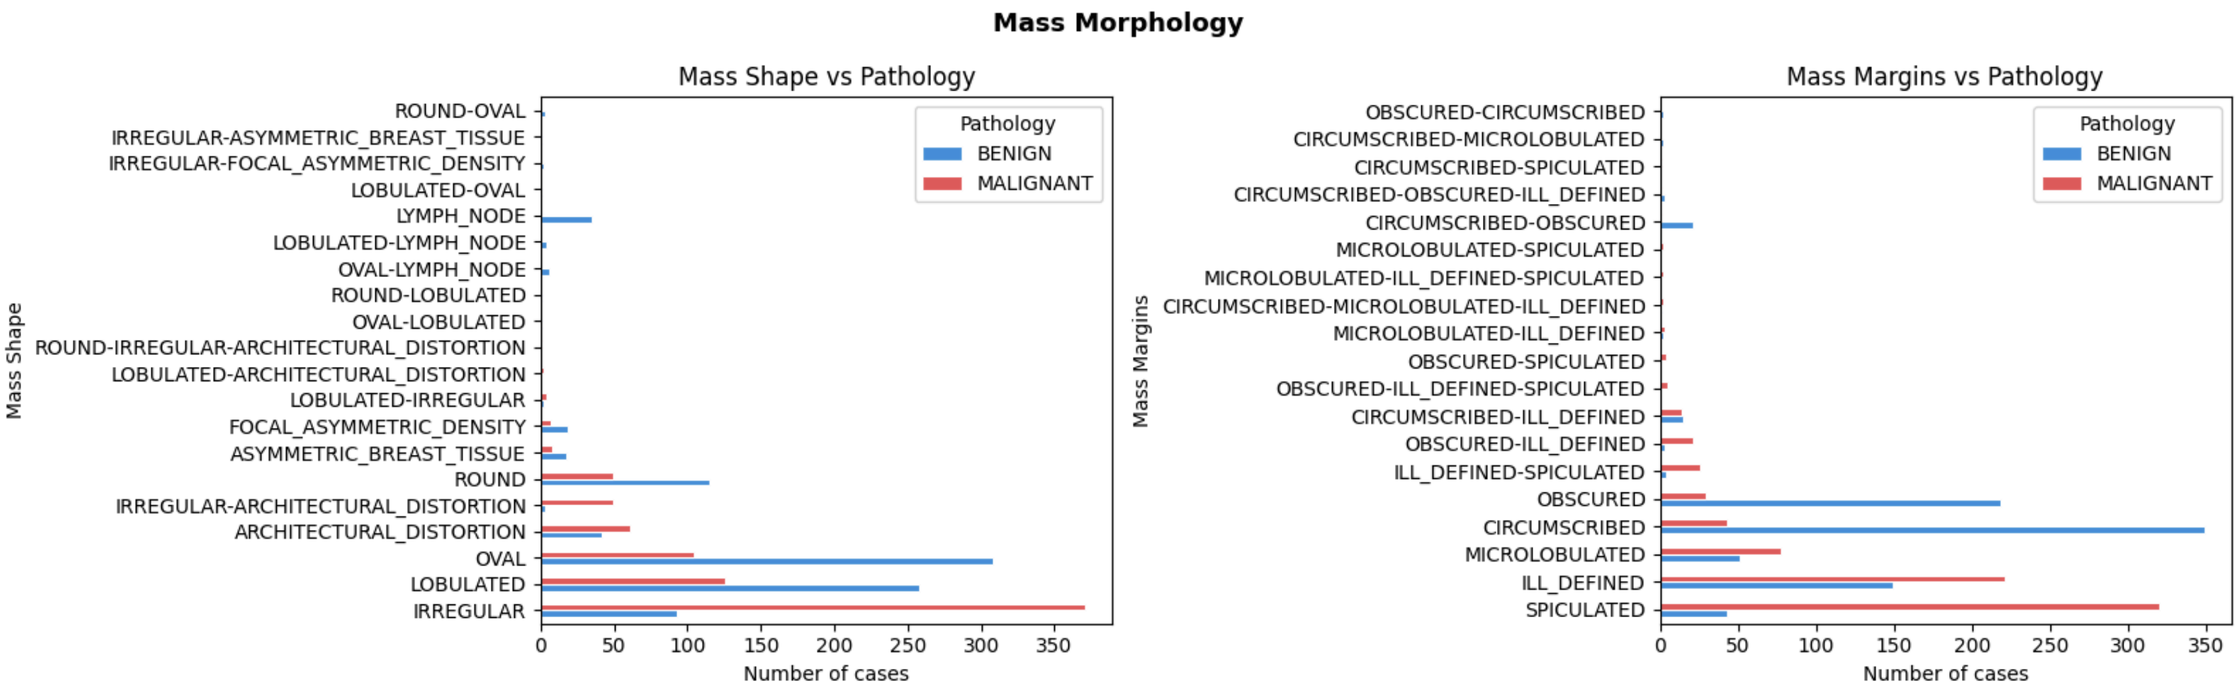

ANEXO 53

Figura 4.3.2 · Tipo y distribución de las calcificaciones por patología

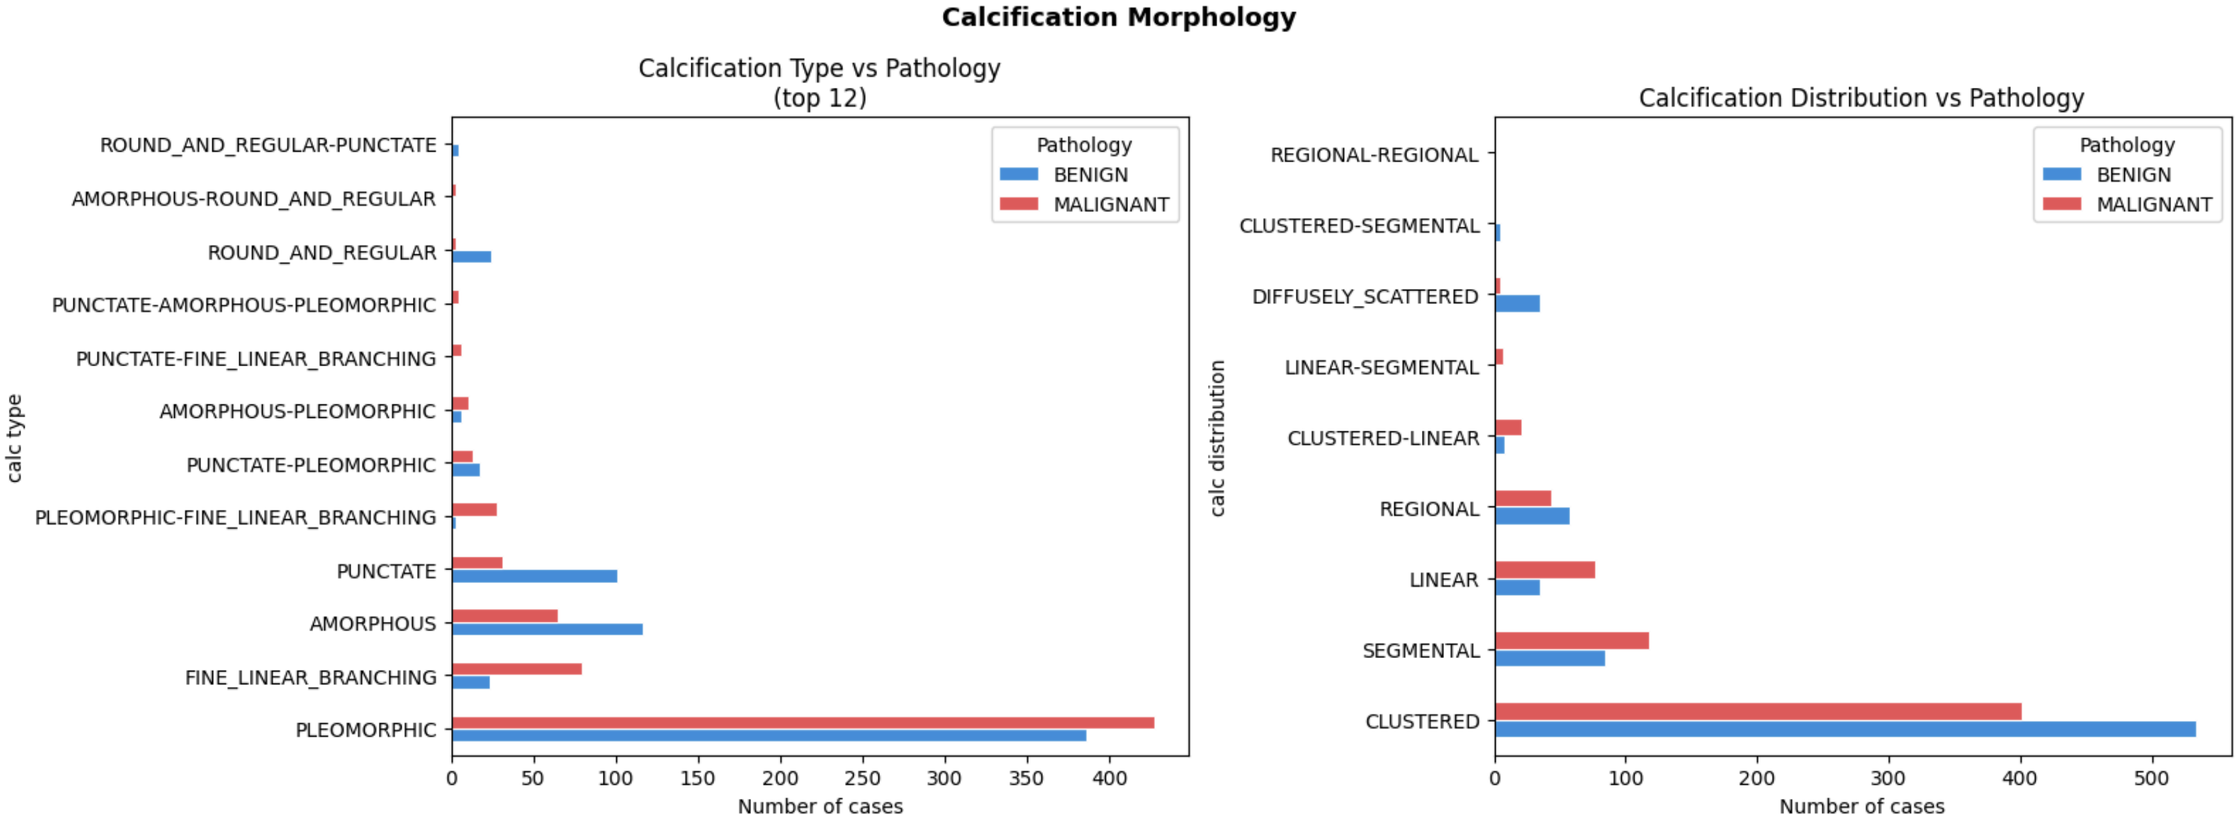

ANEXO 54

Figura 5.6.1 · Costo del número de *folds*

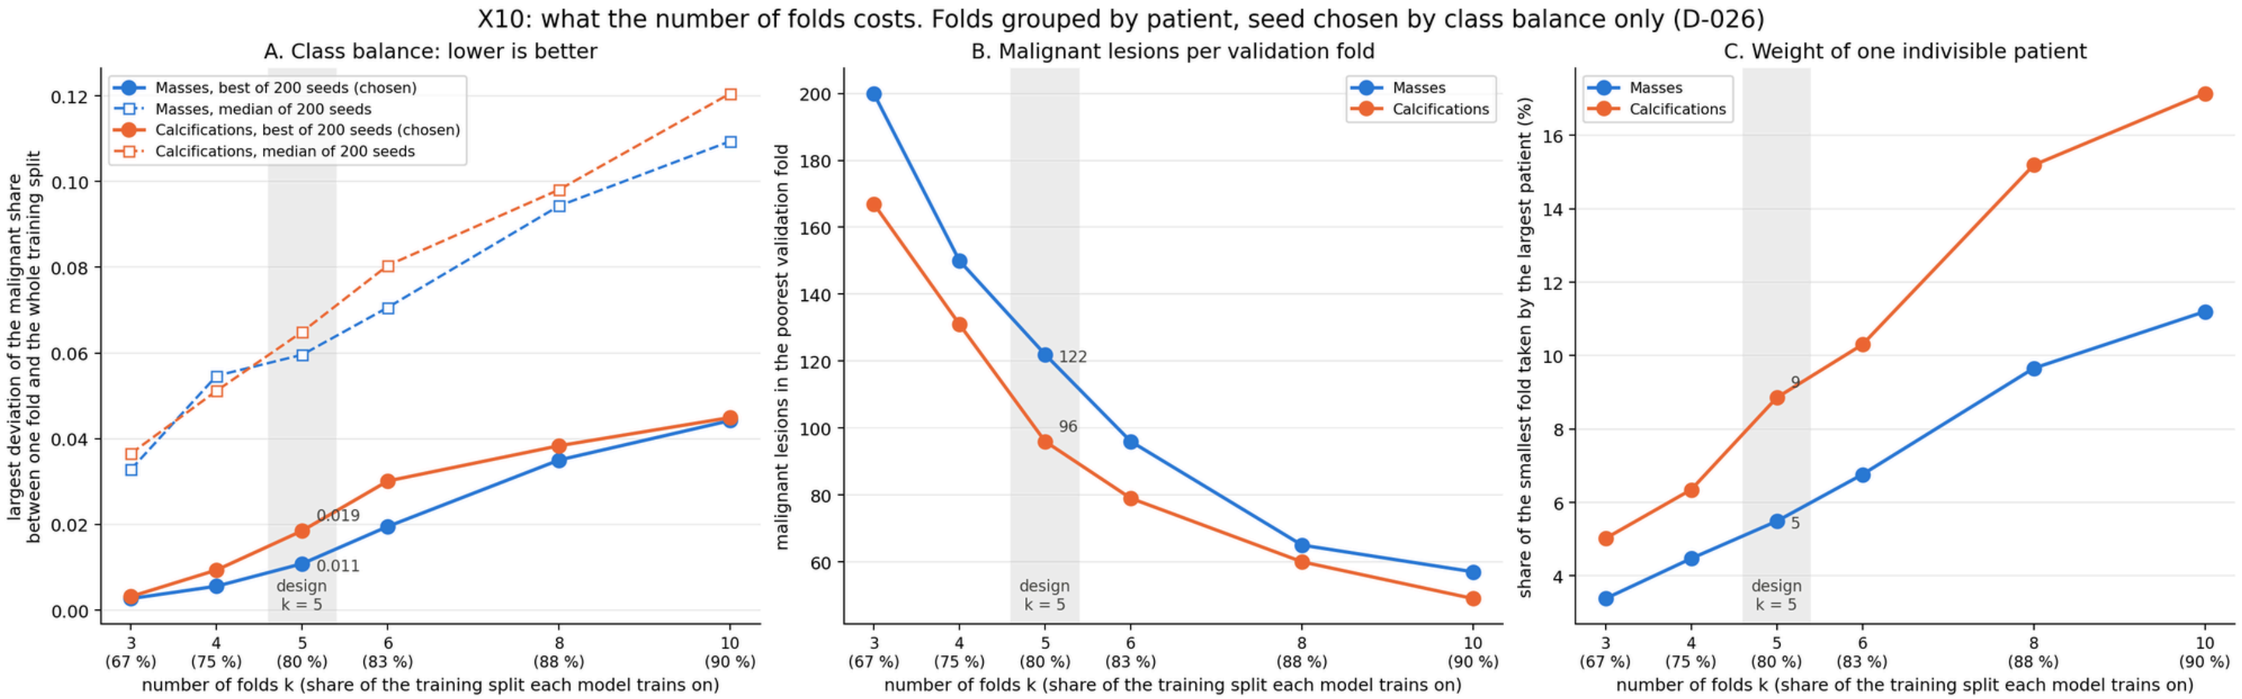

Figura 5.7.1 · Circuitos de C4 y C5 dibujados para k = 4

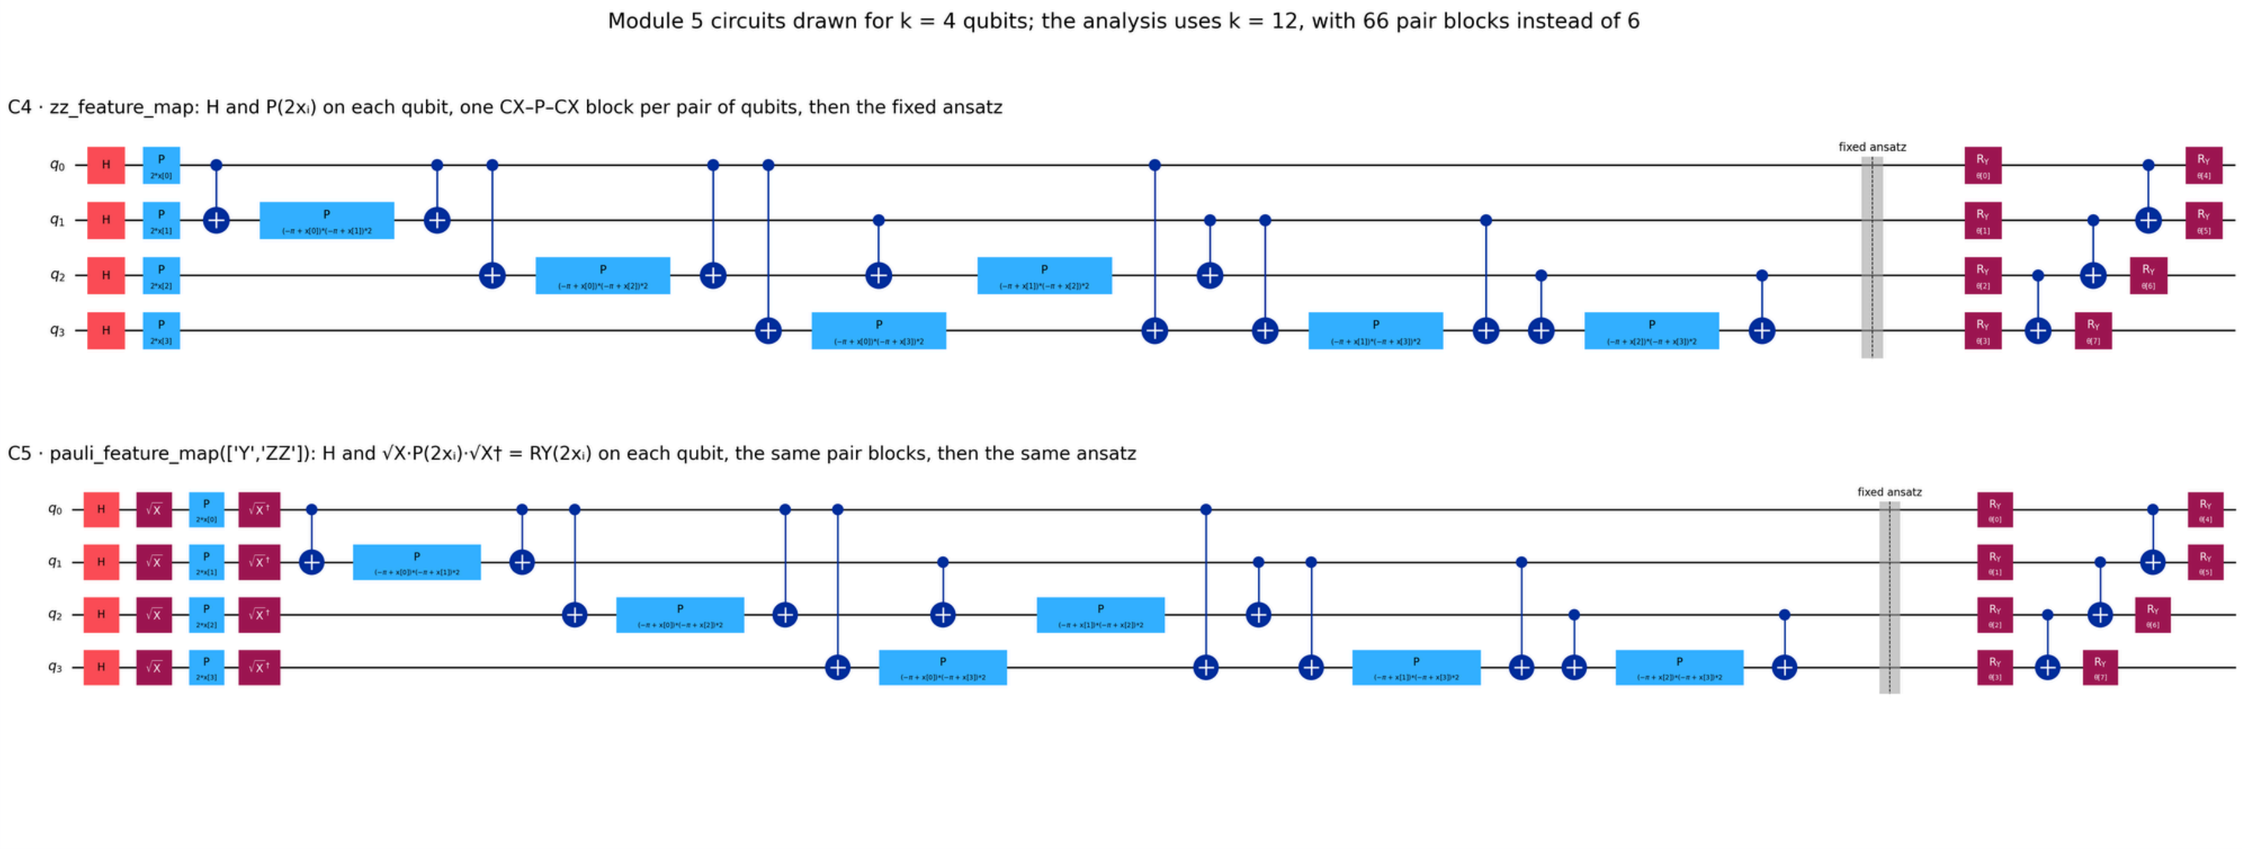

Figura 6.1.1 · Tamaños de efecto de las 67 características

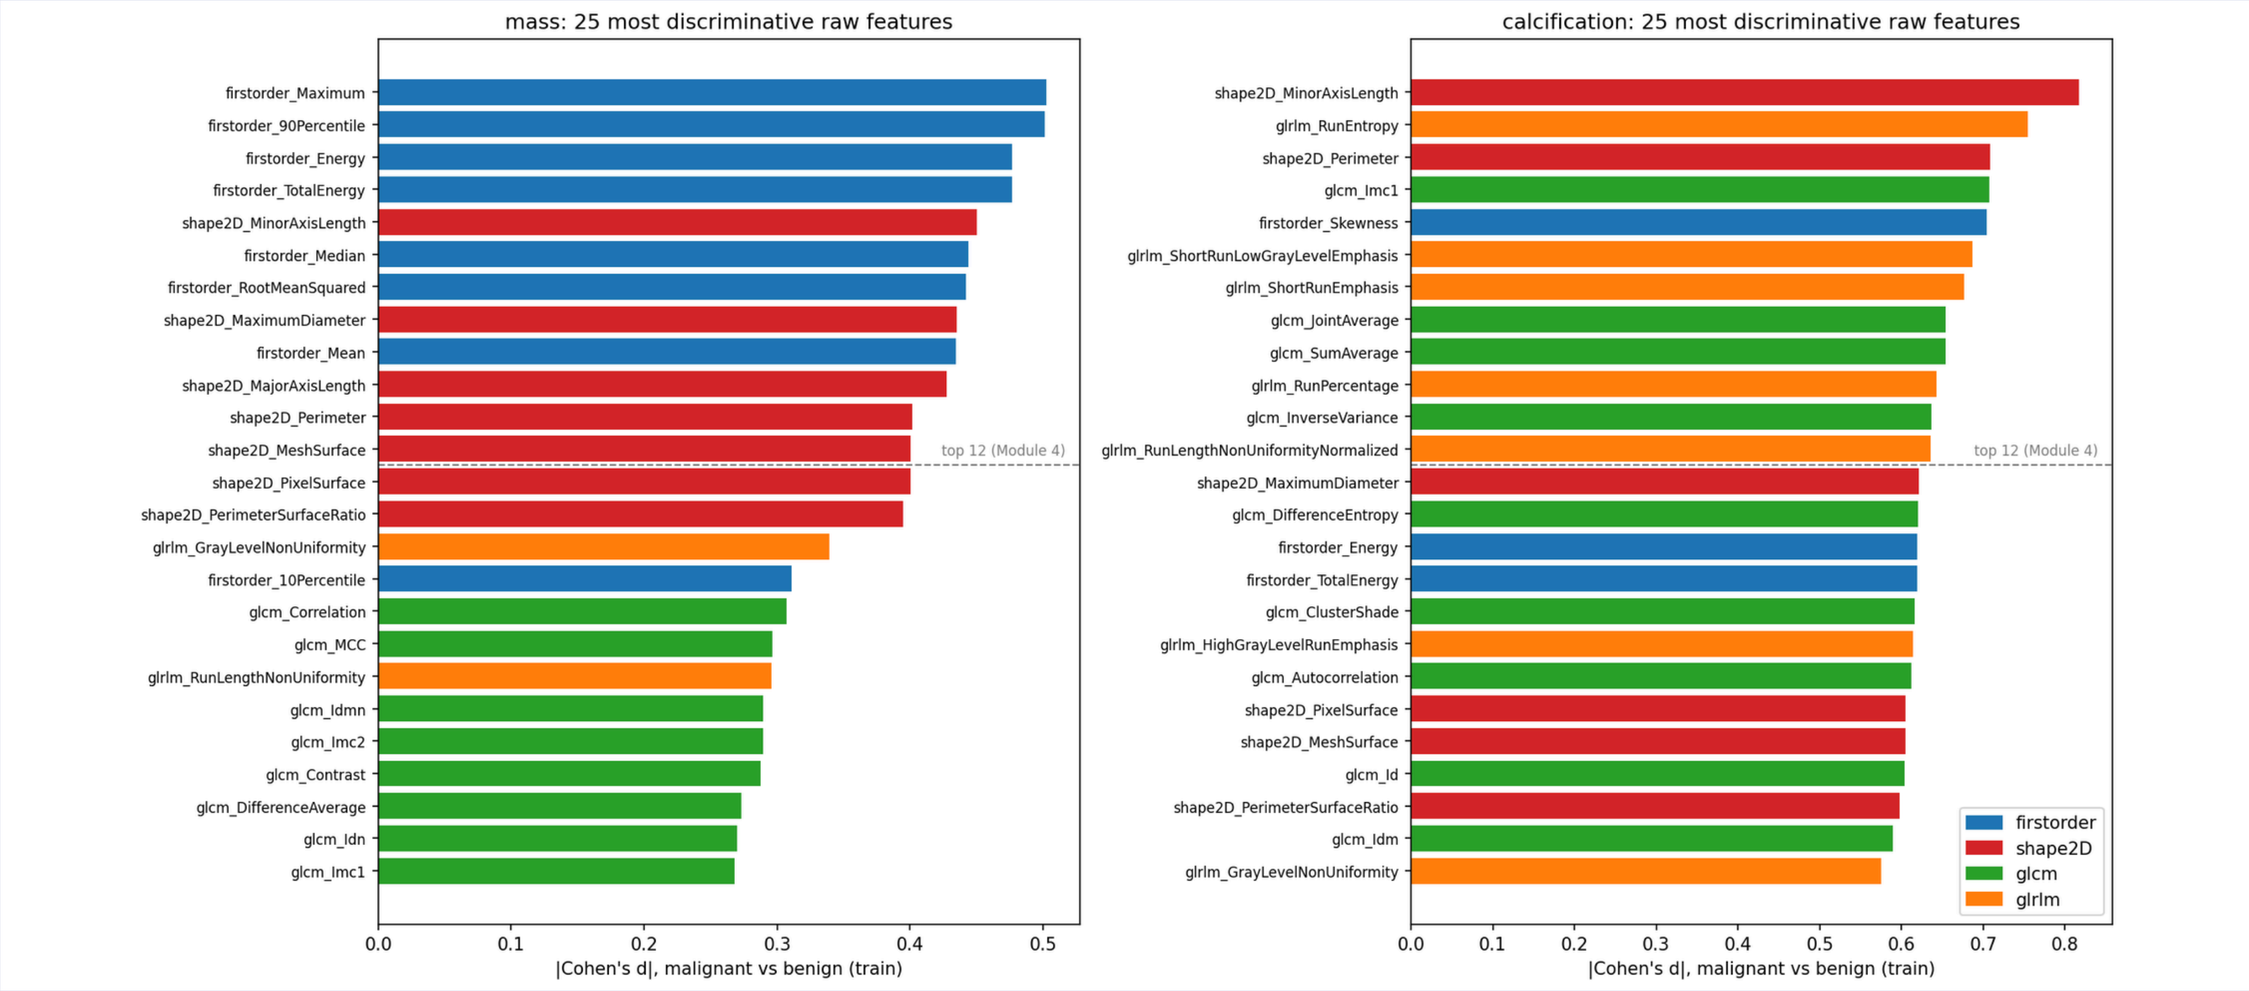

Figura 6.1.2 · Efecto de CLAHE en la capacidad discriminativa

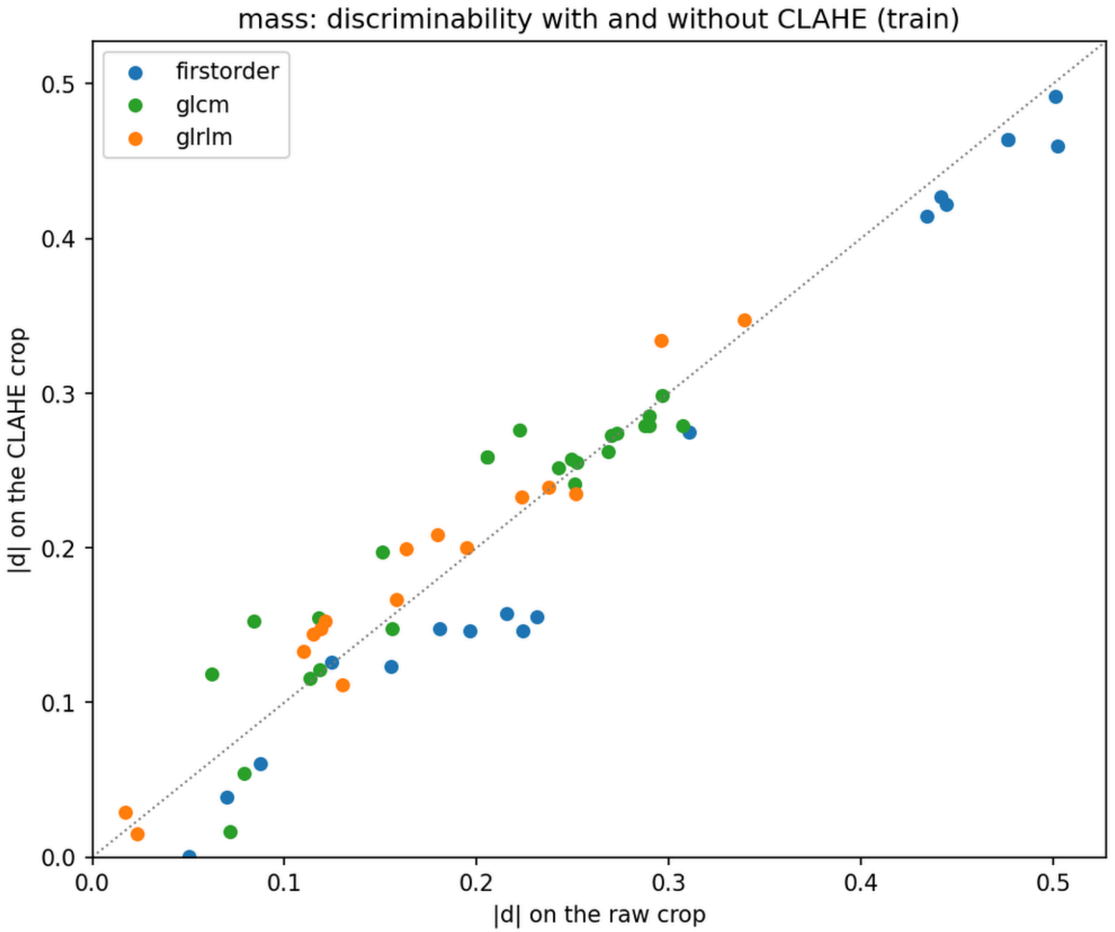

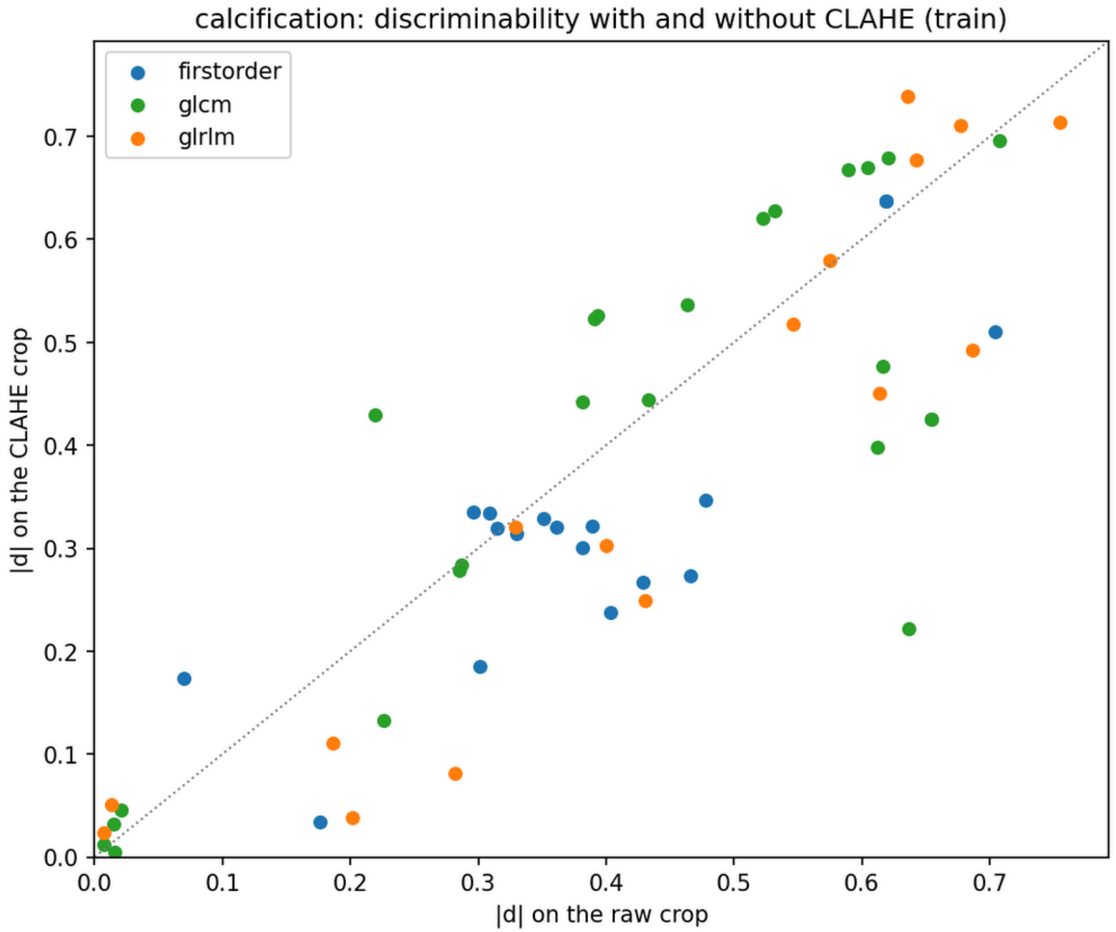

Figura 6.1.3 · Selección y escalado angular por cuantiles

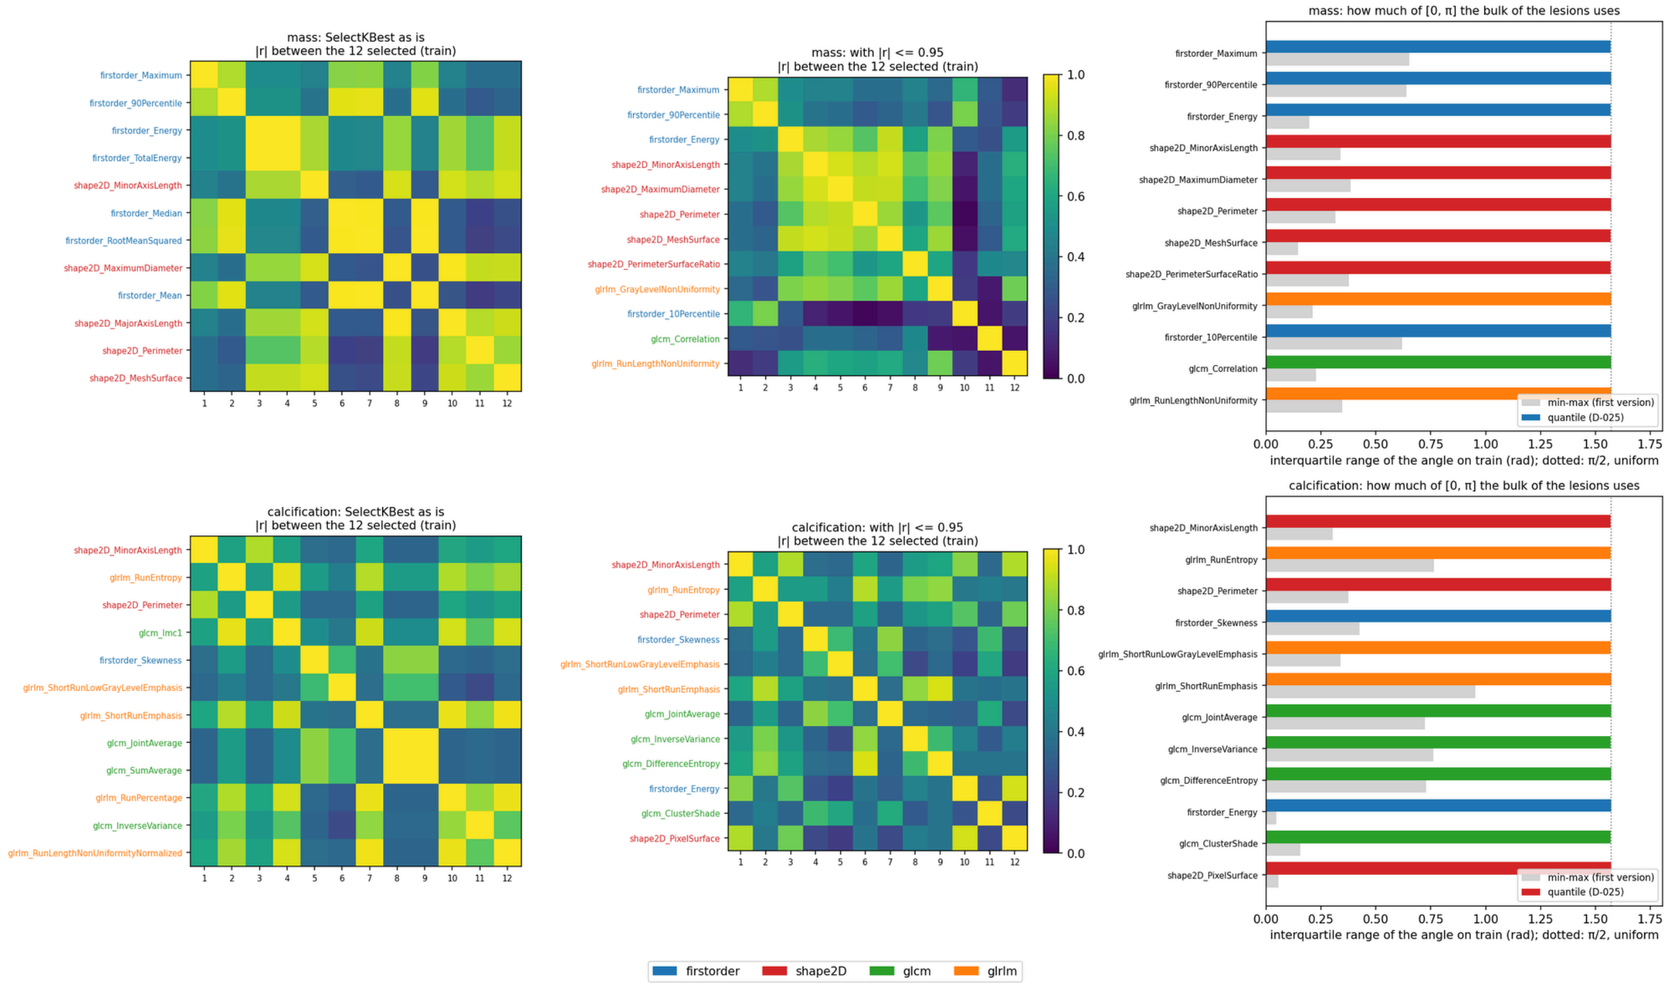

Figura 6.1.4 · AUC en función del número de características k

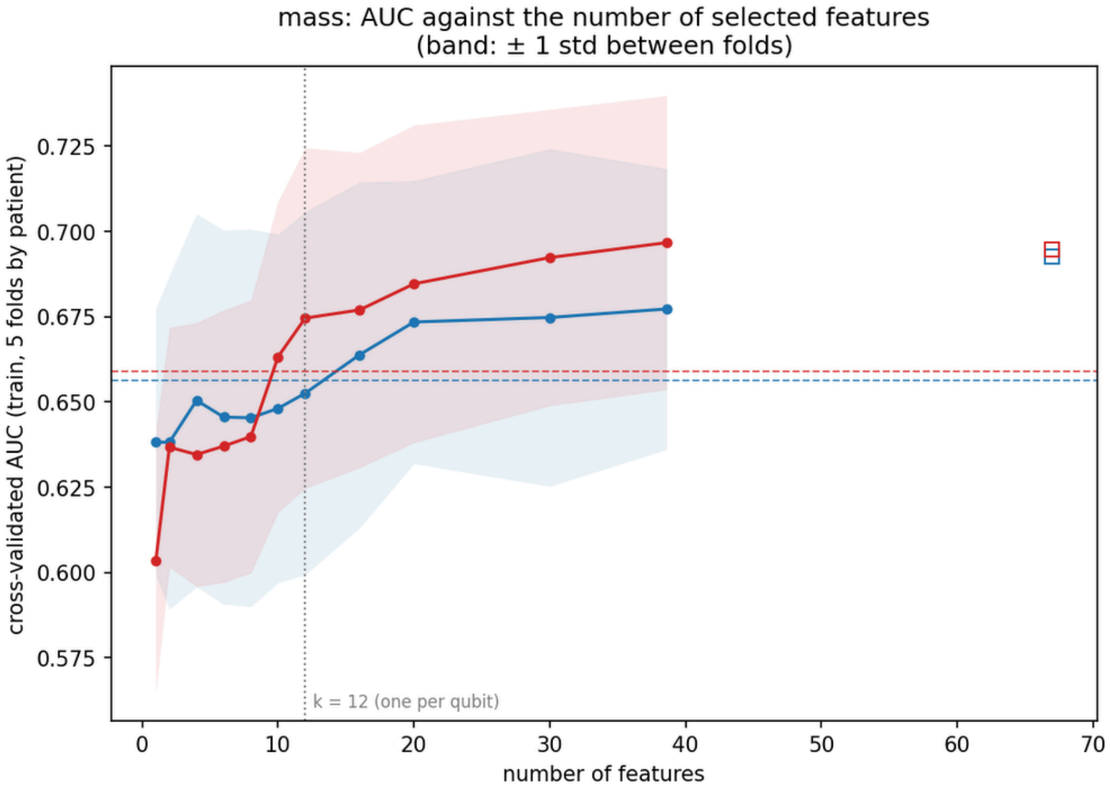

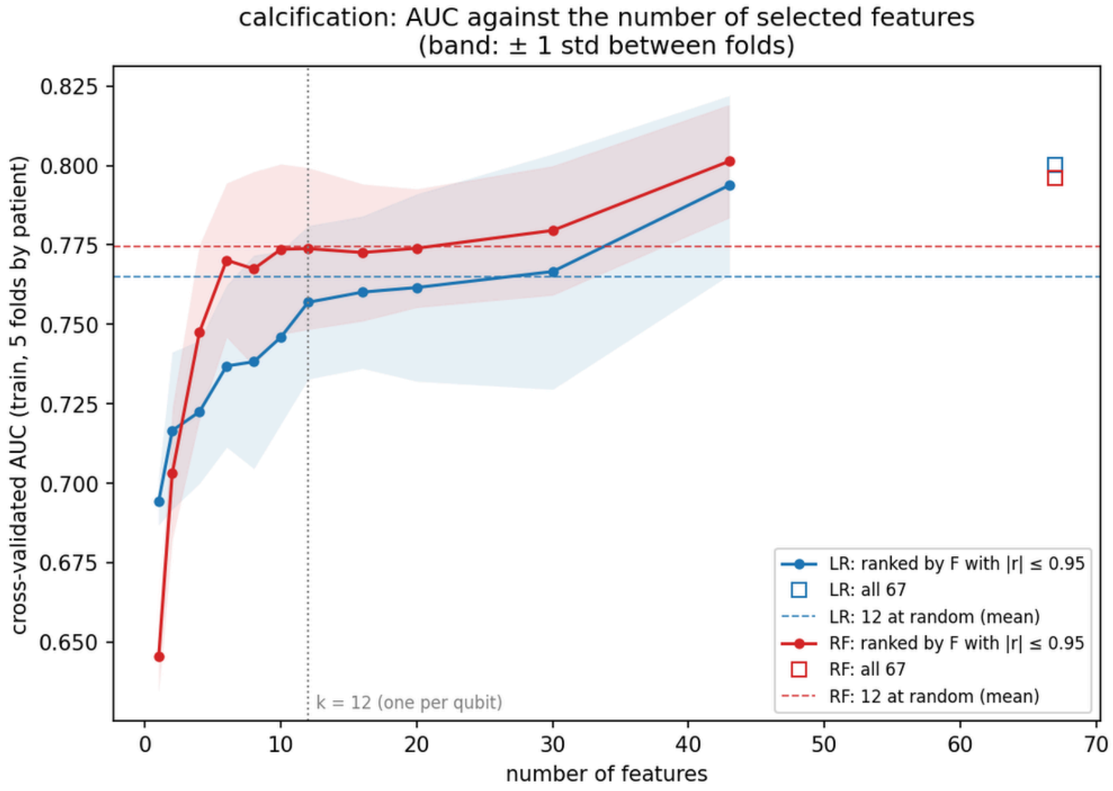

Figura 6.2.1 · Concentración de los kernels cuánticos

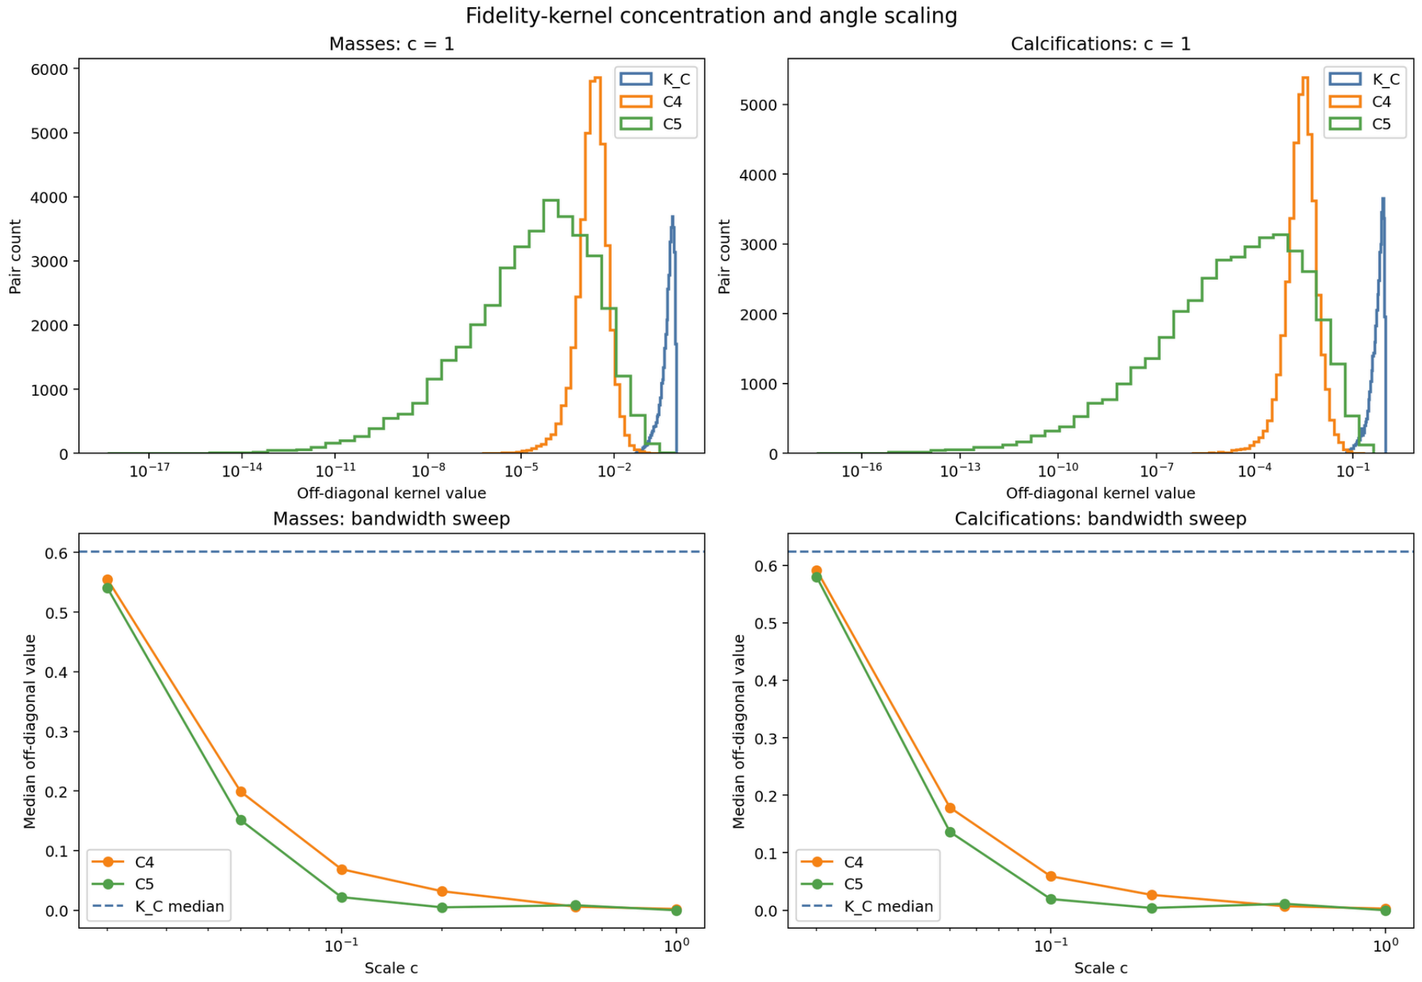

Figura 6.2.2 · Alineamiento y dimensión efectiva de los kernels

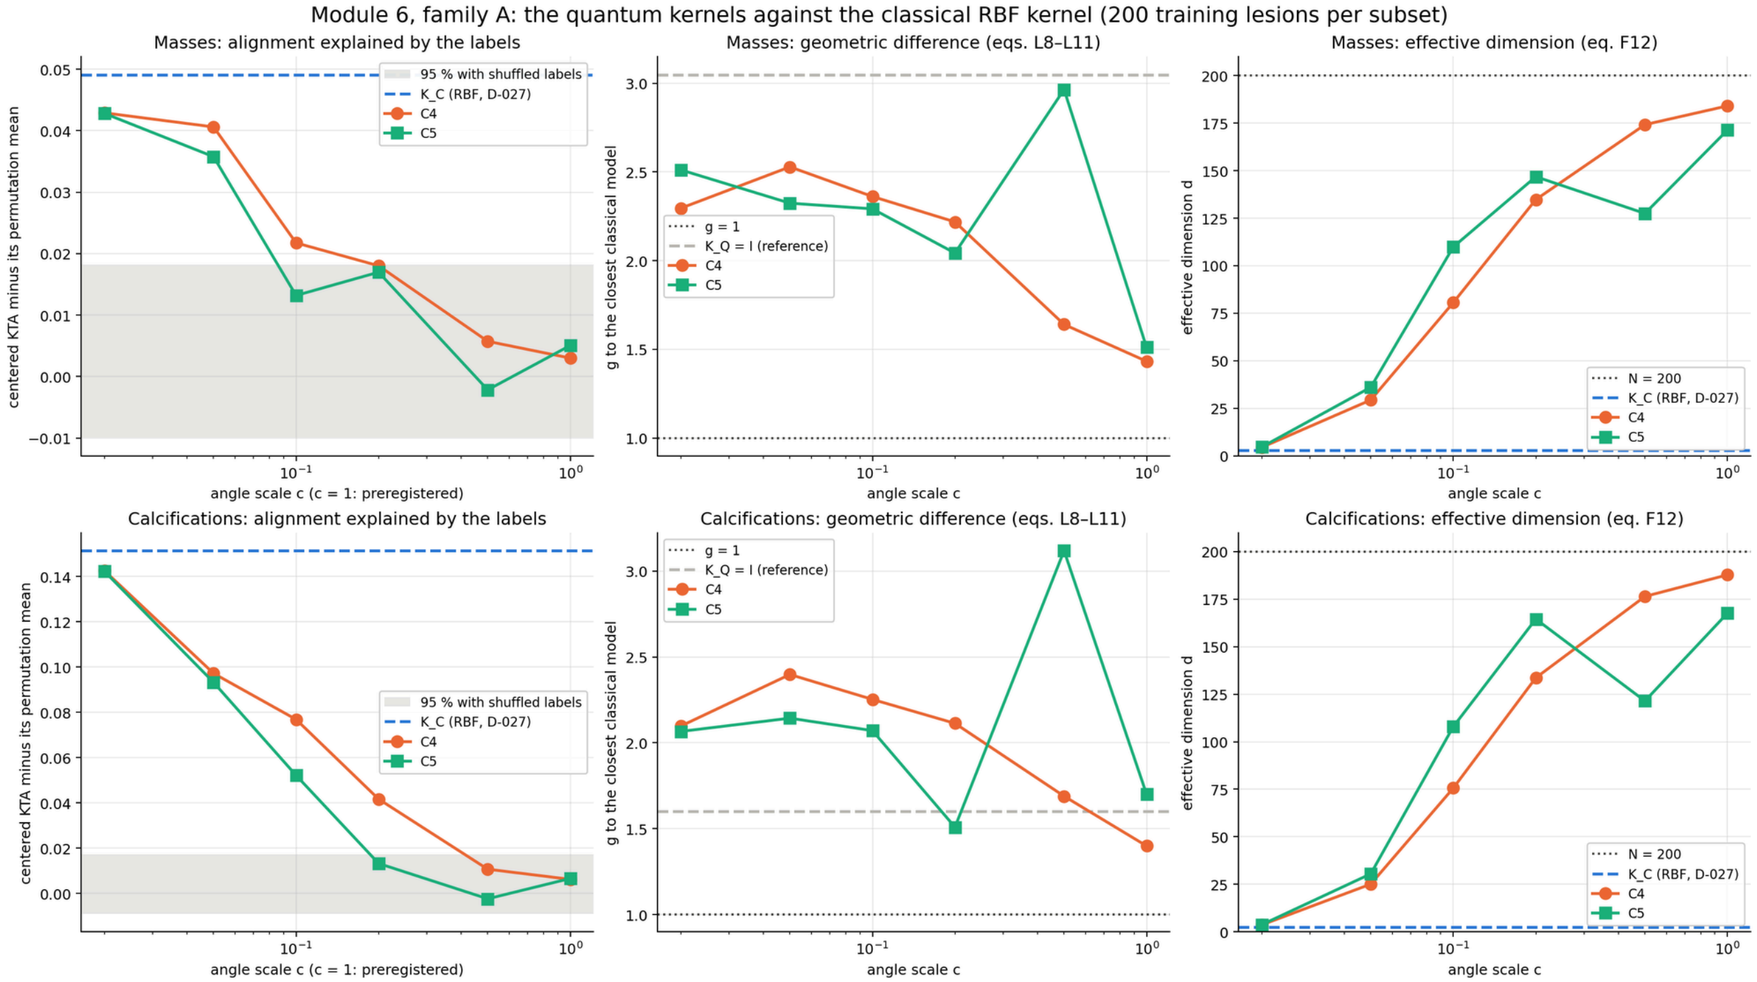

ANEXO 62

Figura 6.2.3 · Diferencia geométrica *g* frente a √N

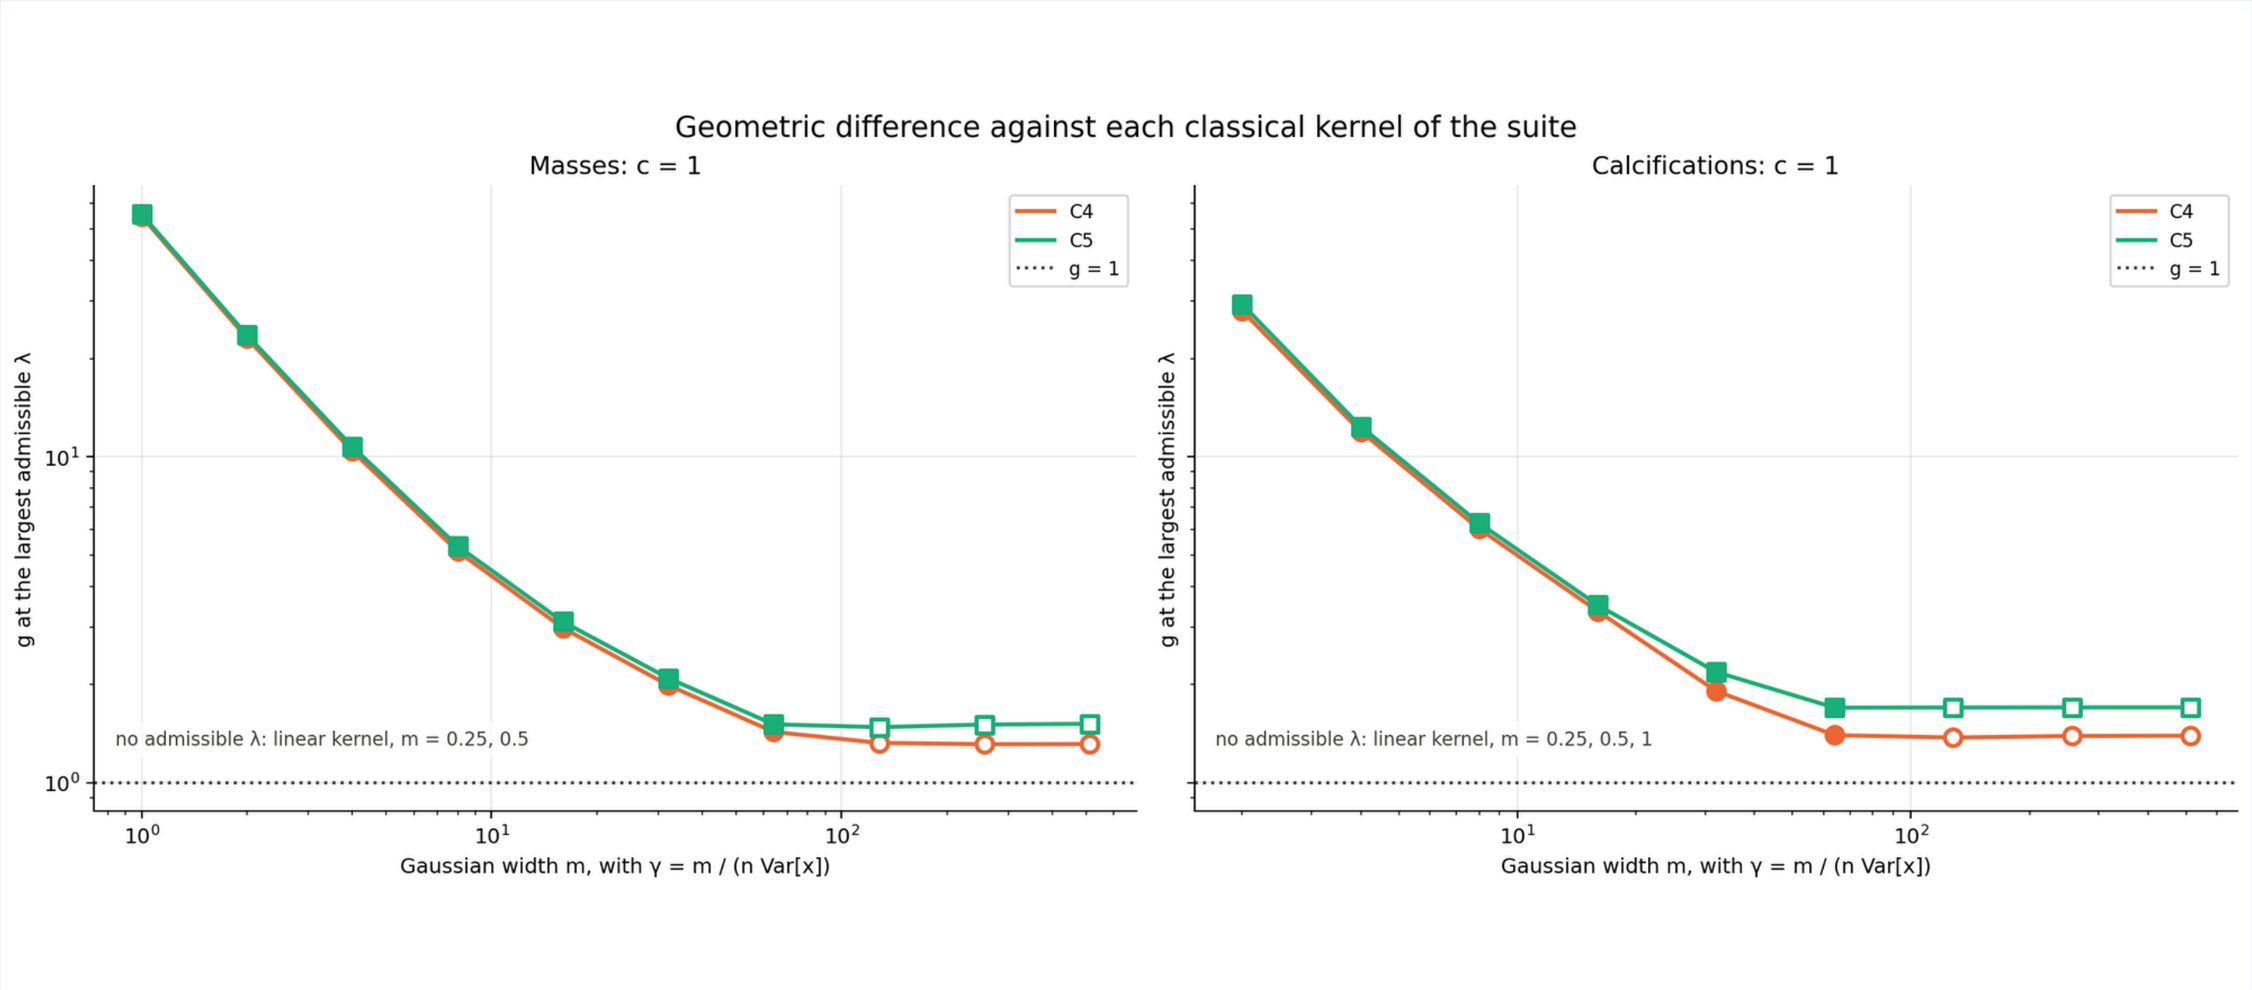

ANEXO 63

Figura 6.2.4 · Davies-Bouldin, Fisher y alineamiento lineal

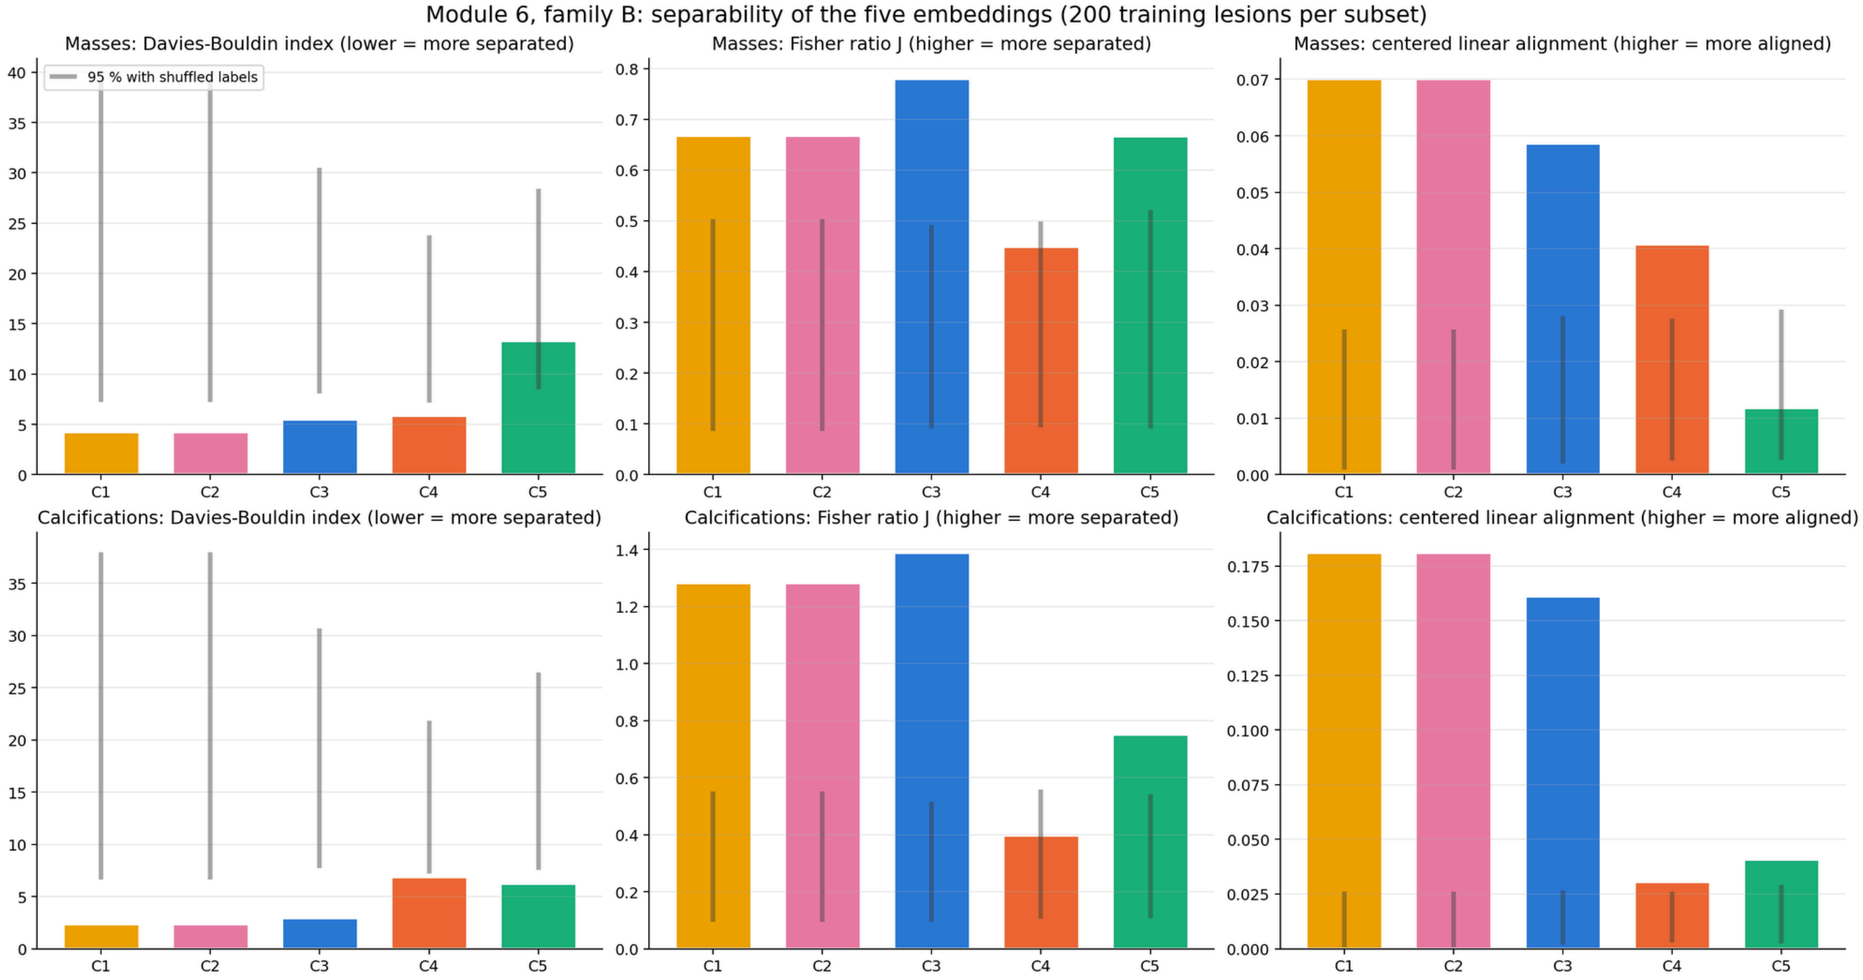

ANEXO 64

Figura 6.2.5 · t-SNE de las cinco representaciones

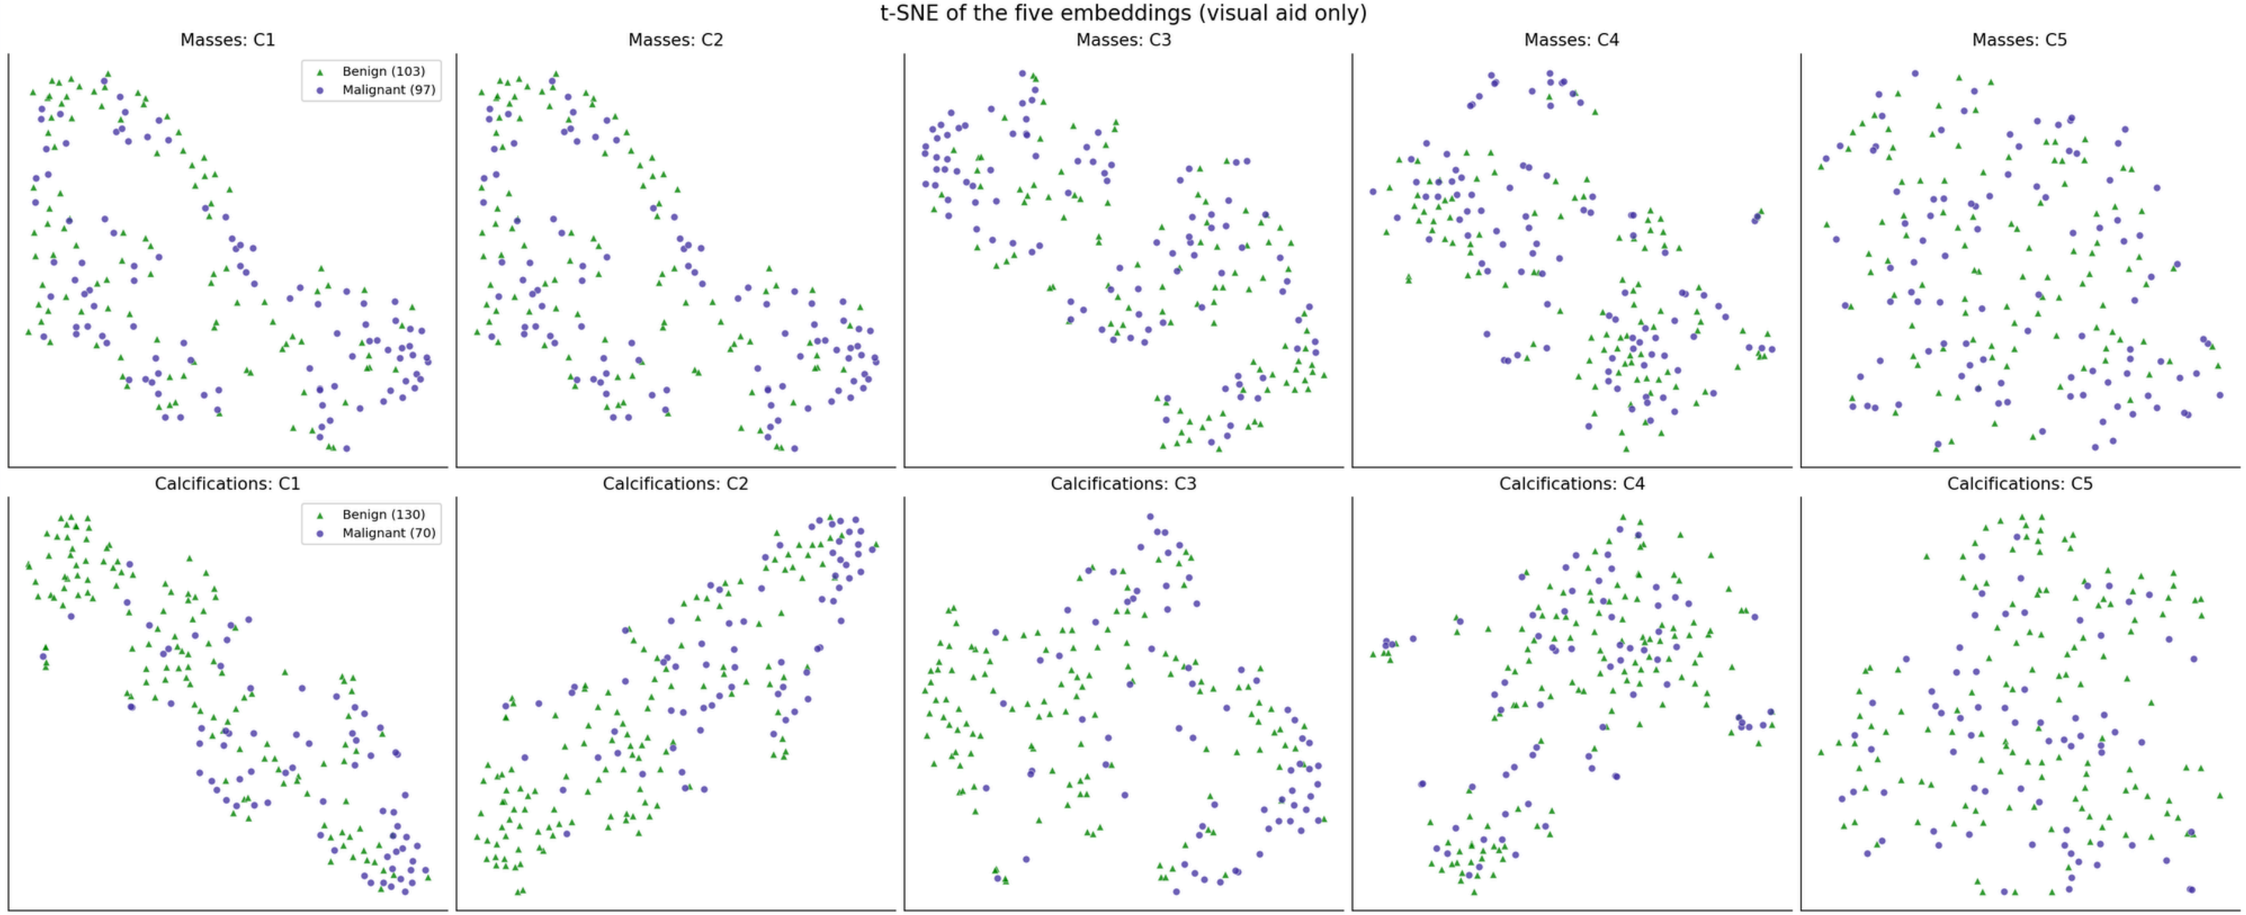

Figura 6.2.6 · Métricas en 20 submuestras y en todo el entrenamiento

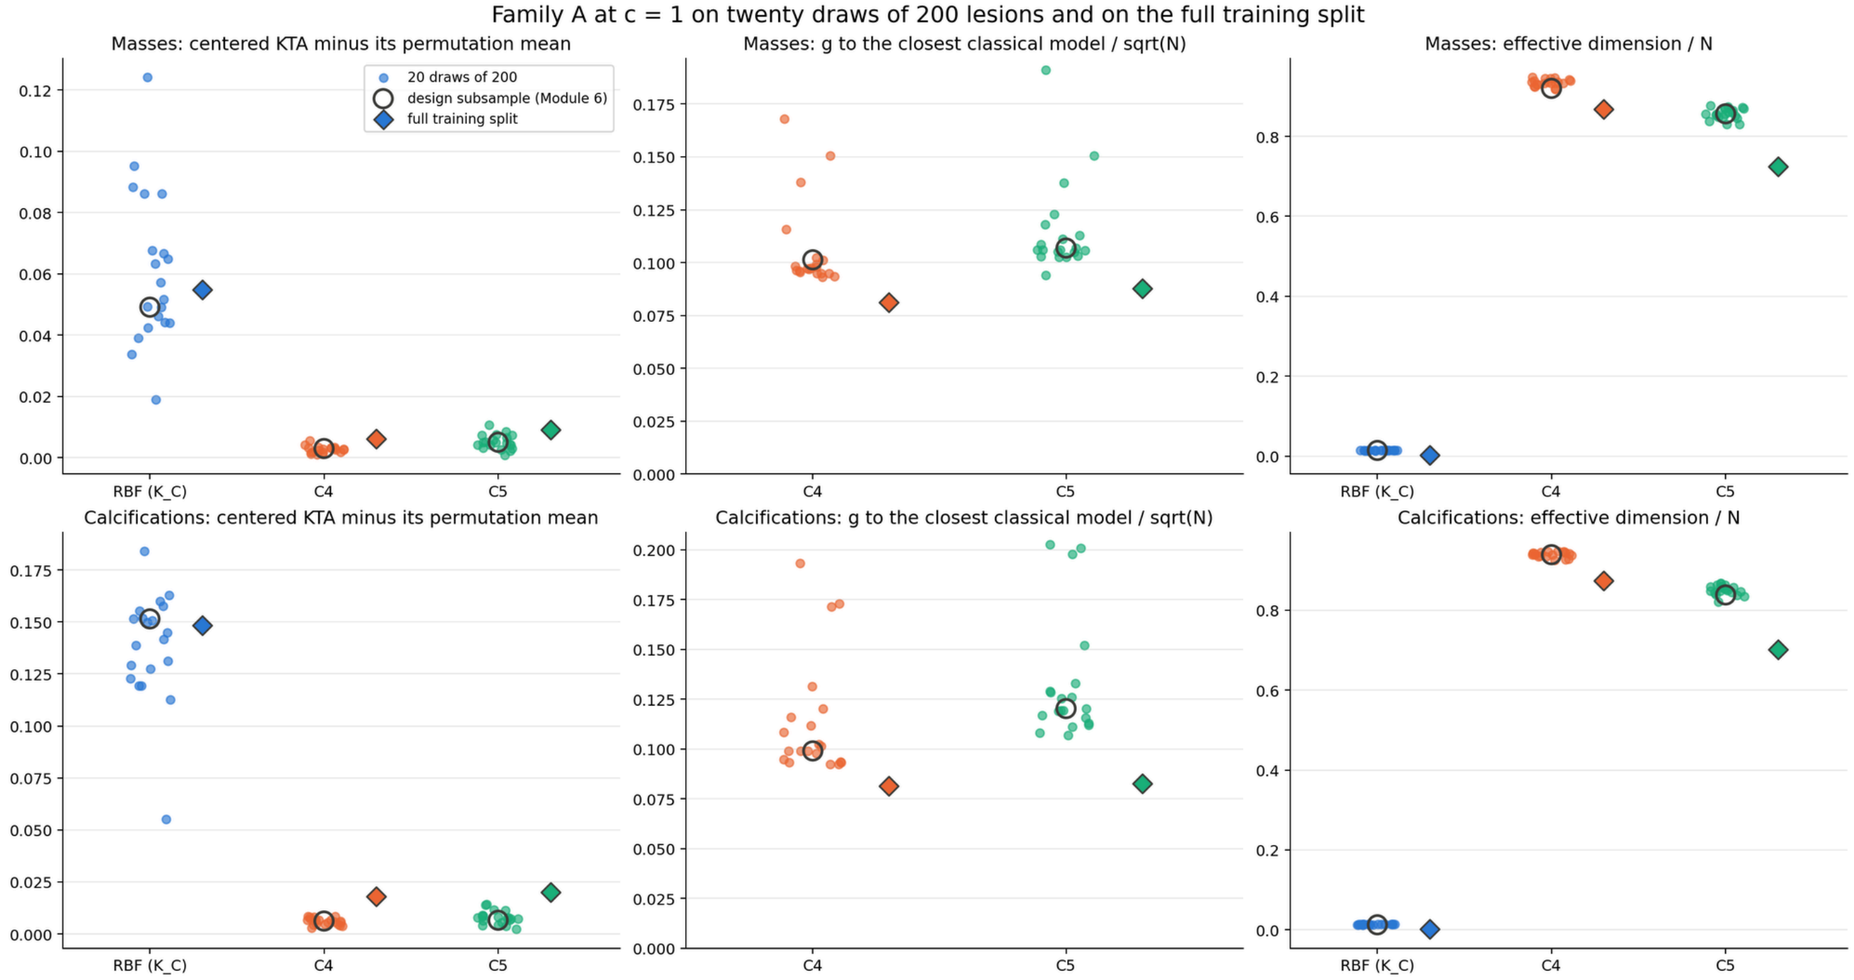

Figura 6.2.7 · AUC de pares contra la escala angular c

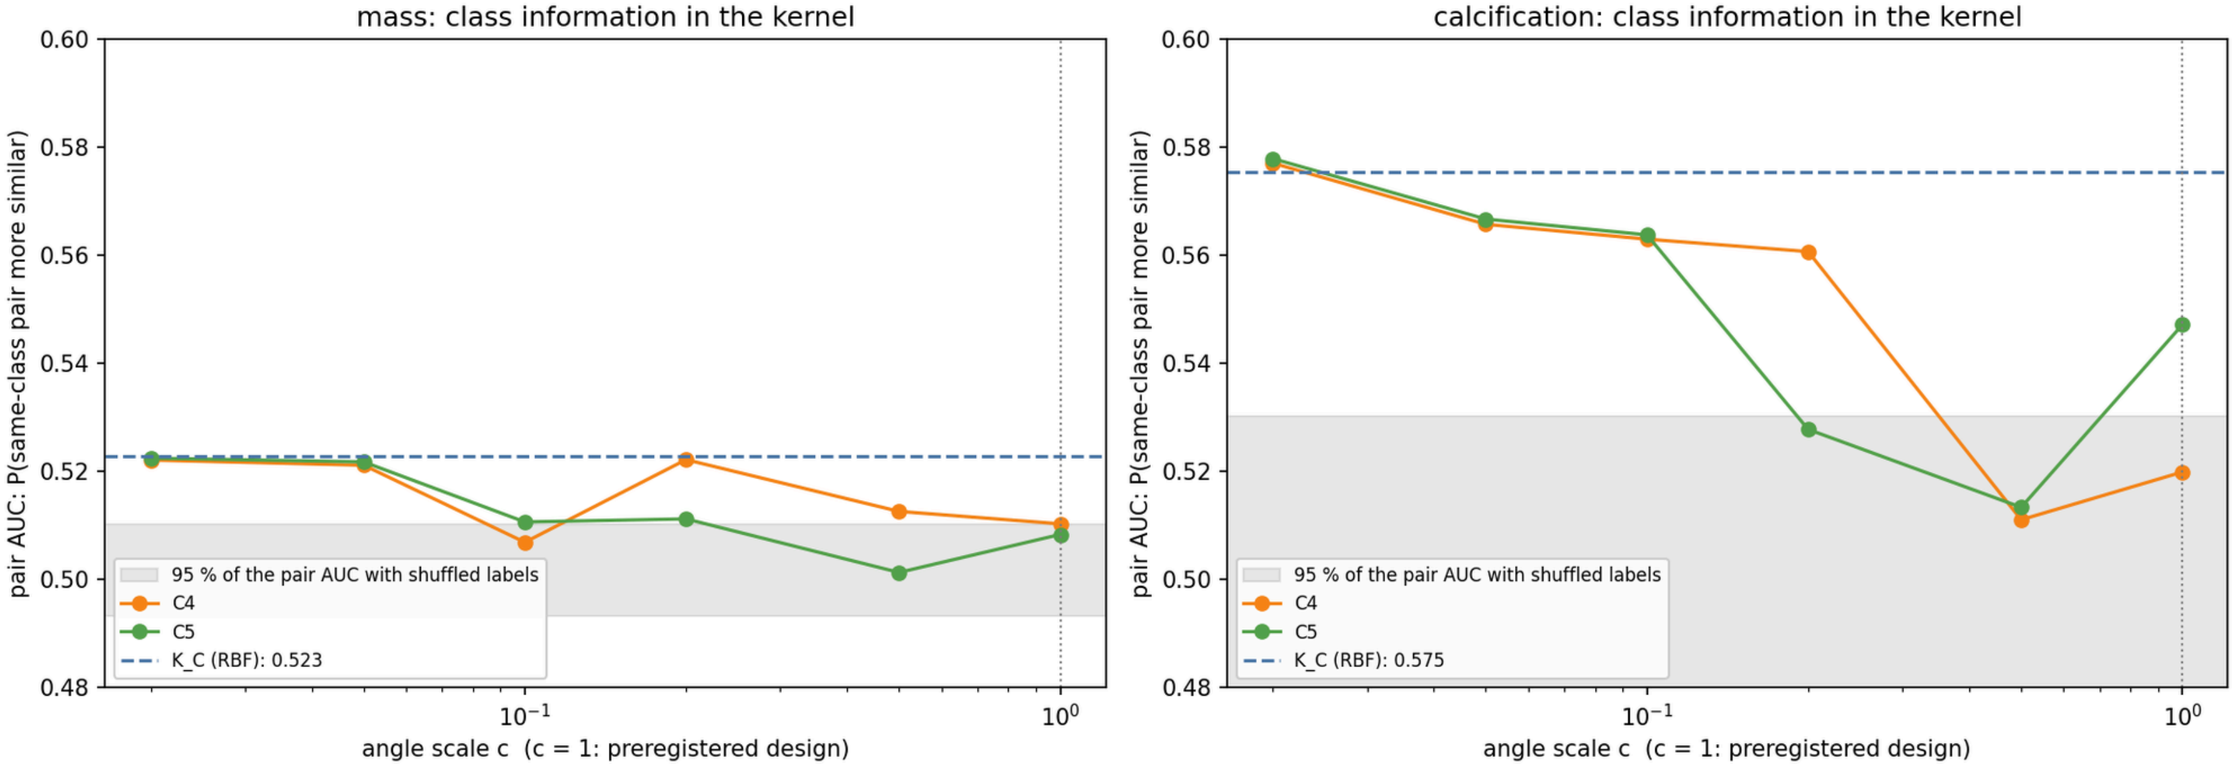

Figura 6.2.8 · Separabilidad con 12 y con 8 qubits

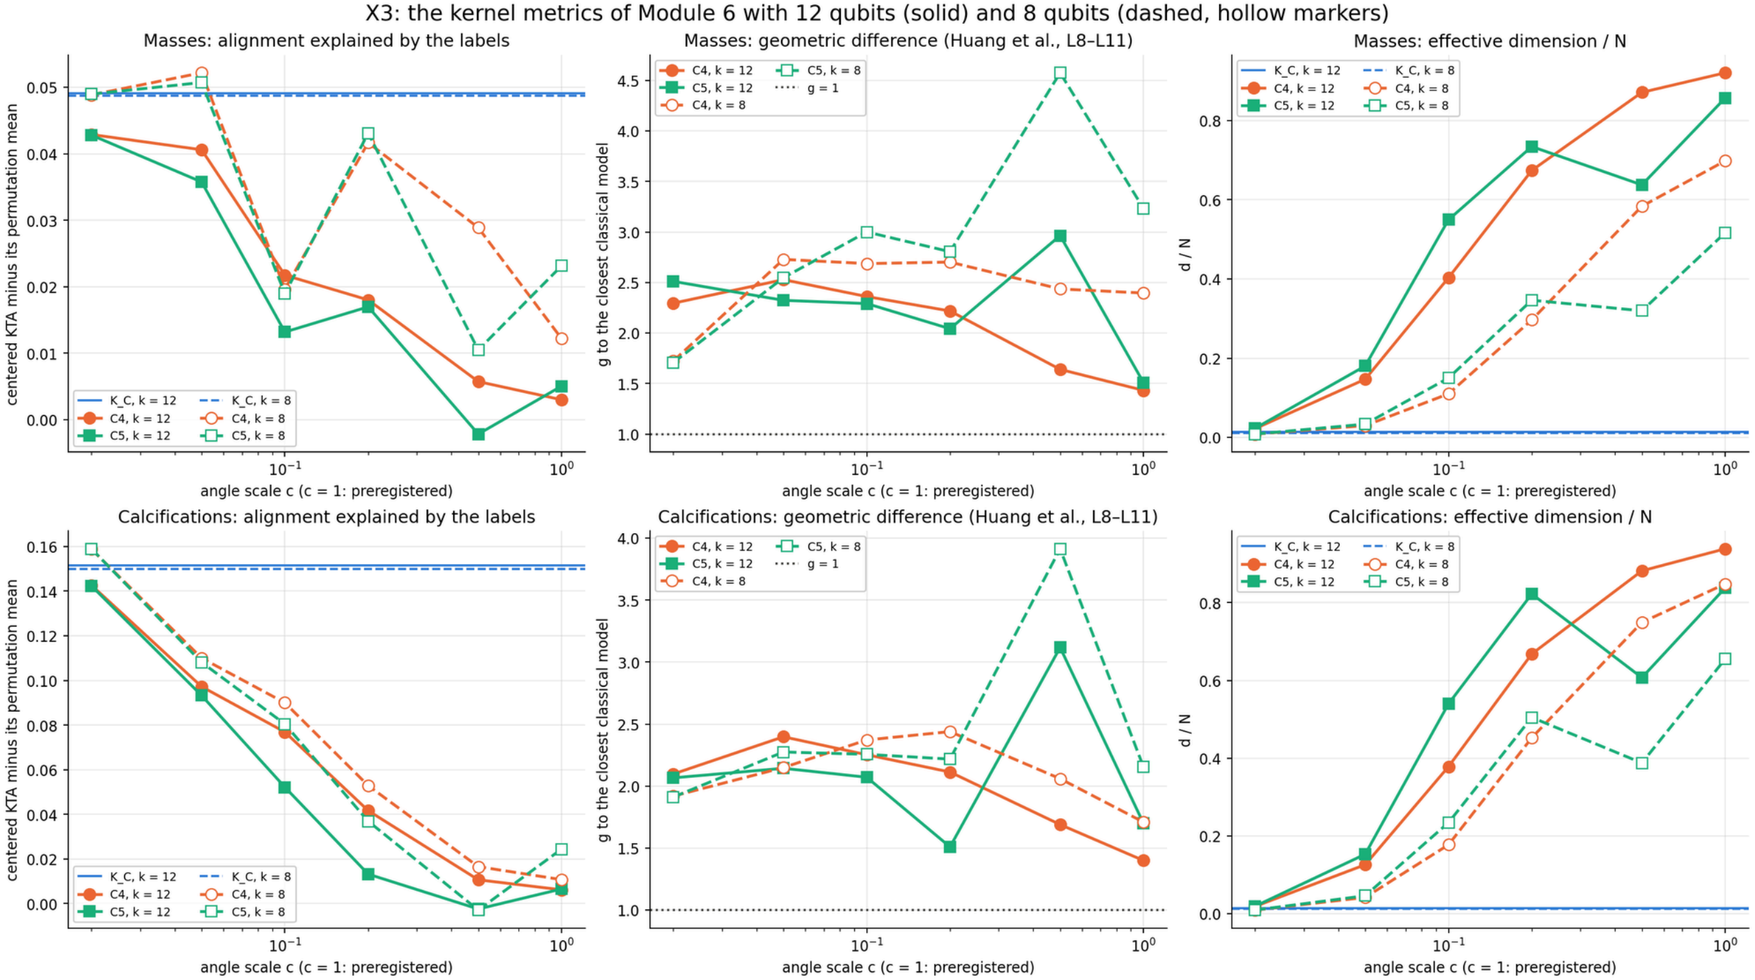

Figura 6.3.1 · AUC en validación cruzada y en prueba

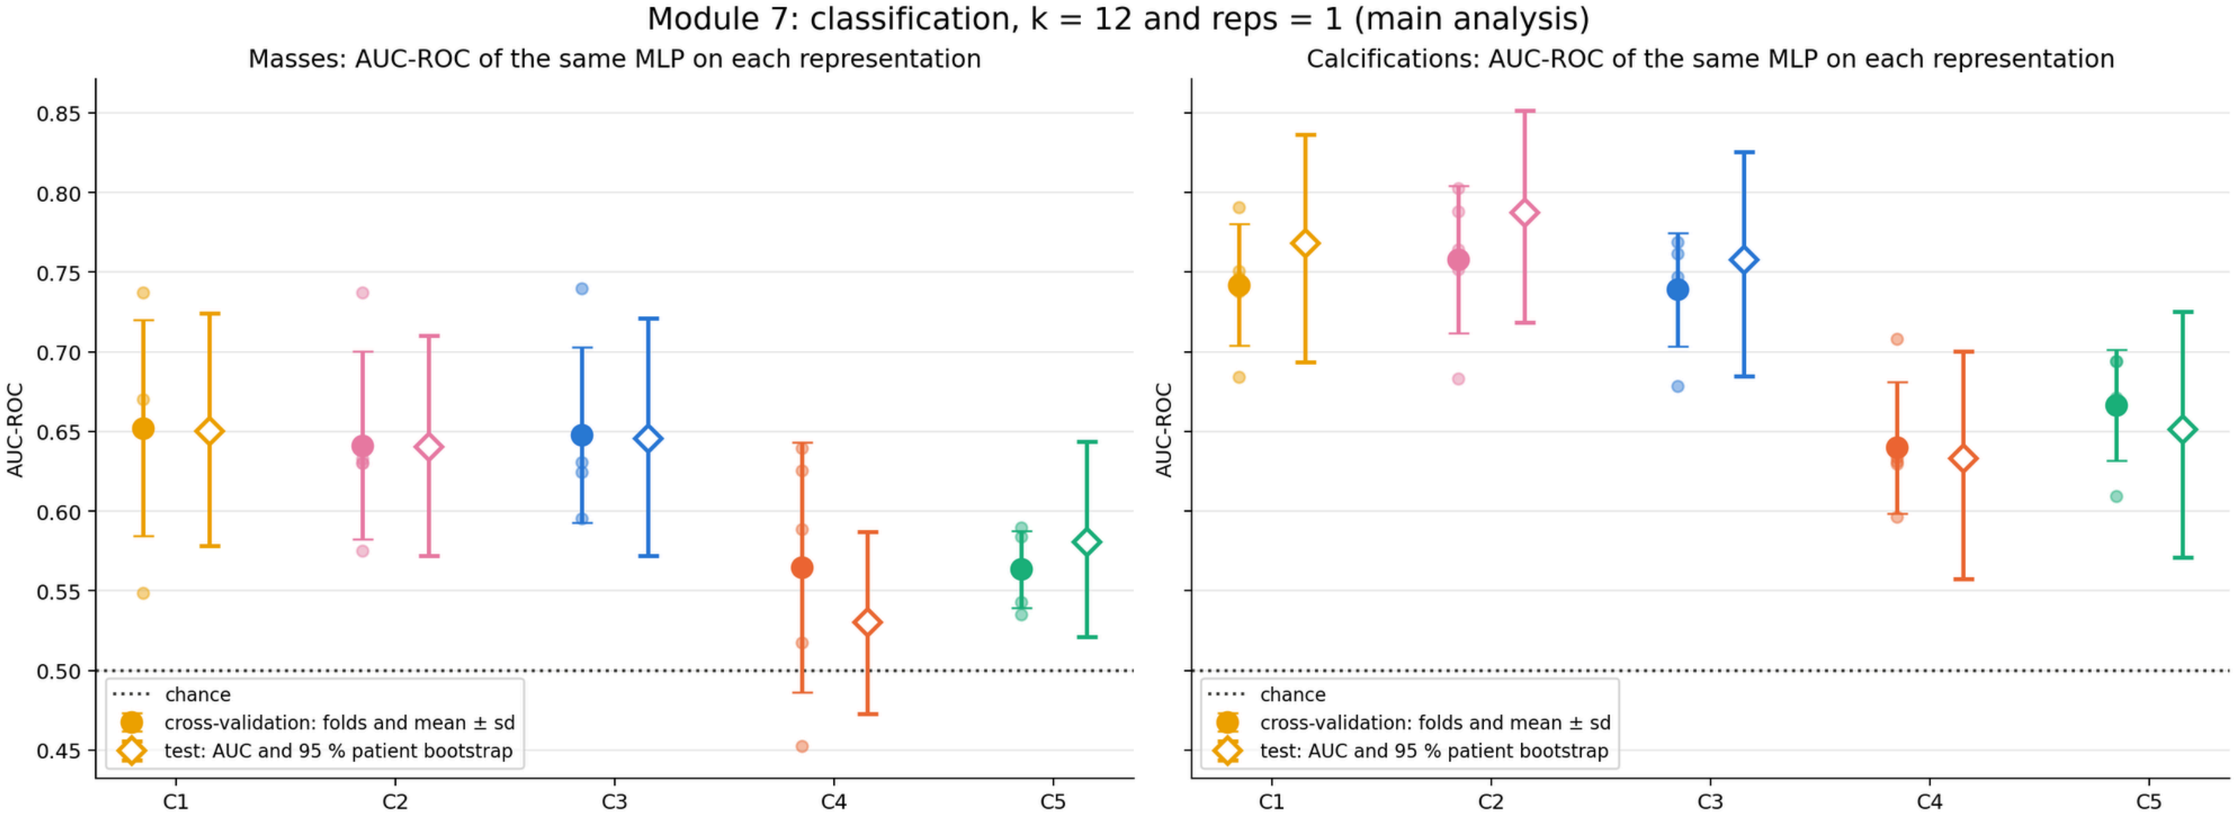

Figura 6.3.2 · Curvas ROC en el conjunto de prueba

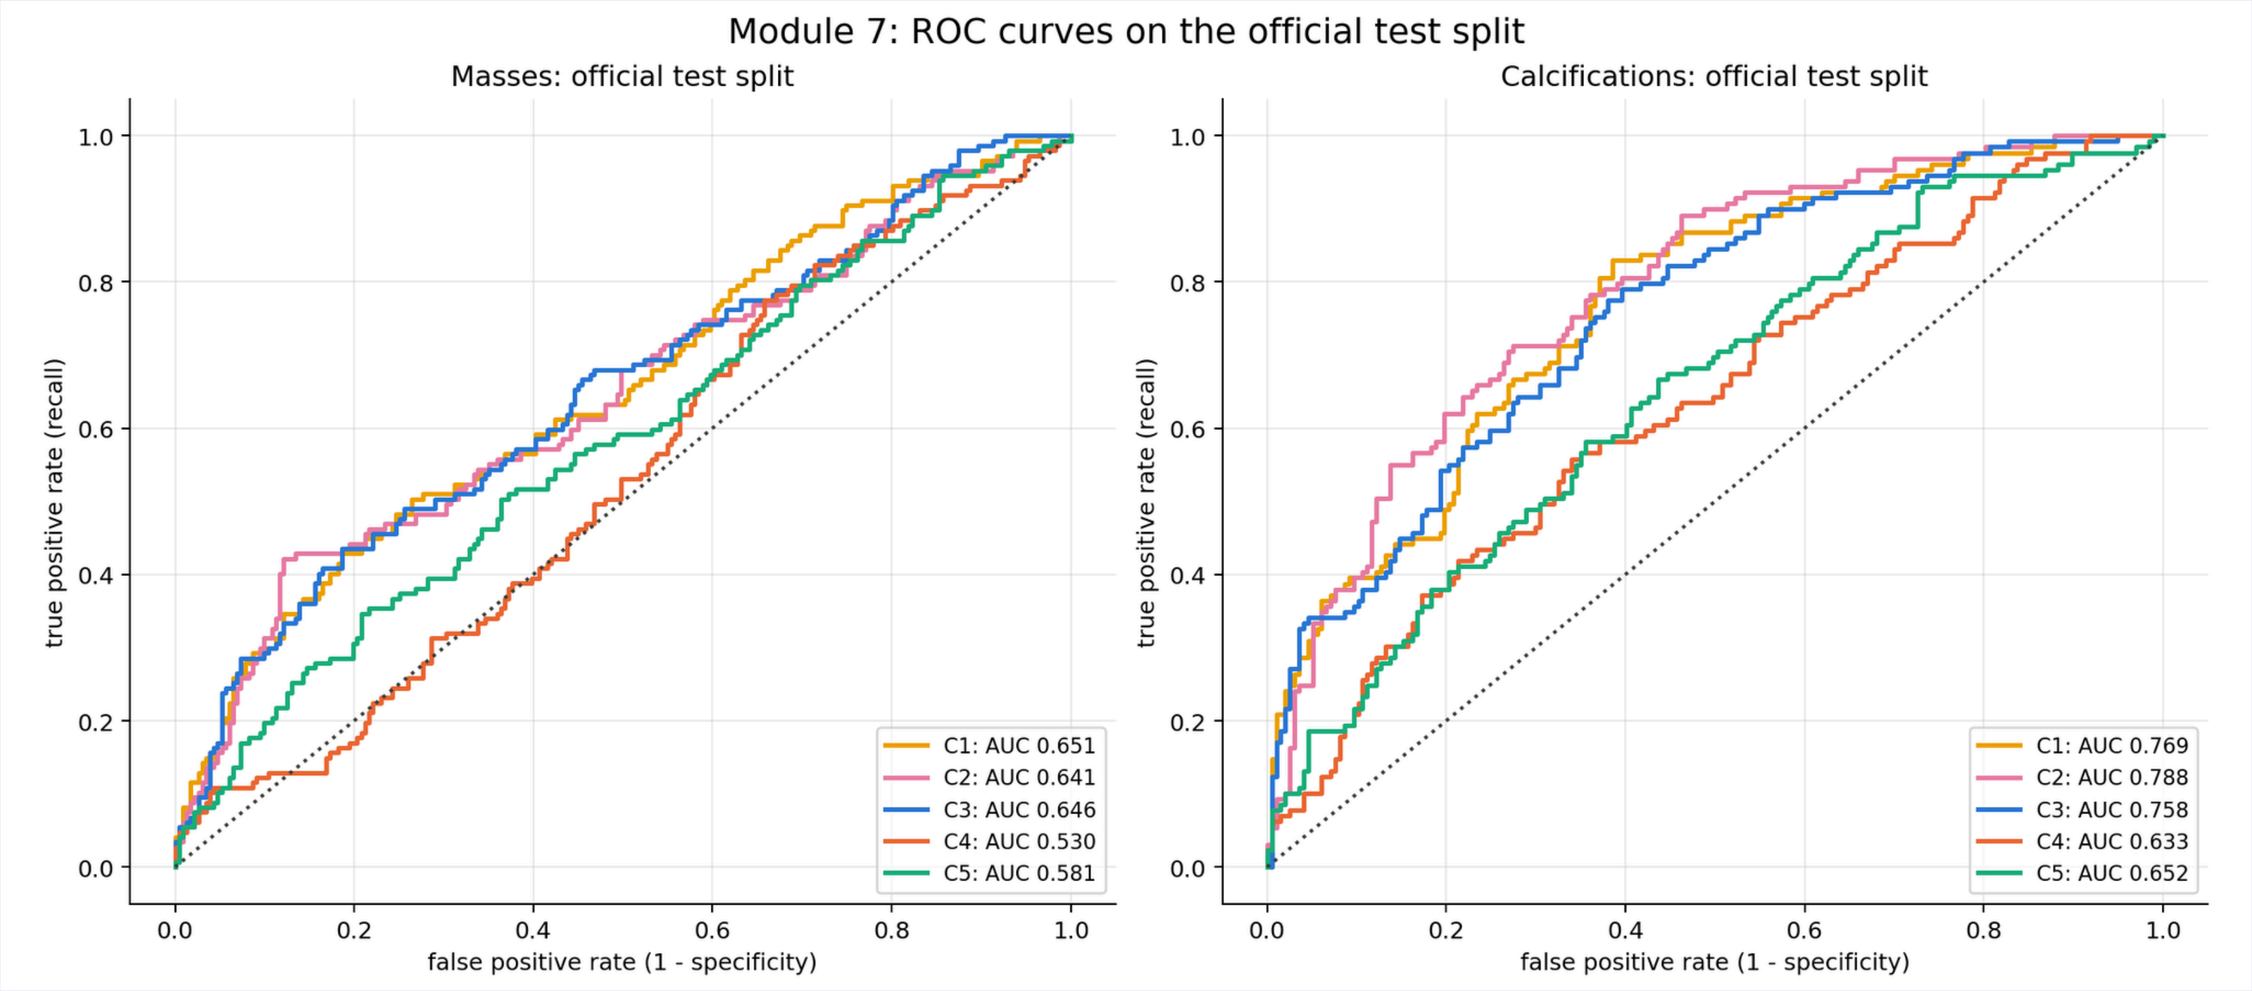

Figura 6.3.3 · Sensibilidad del MLP: semilla, red, escalado, reps y k

ANEXO 71

Figura 6.3.4 · Diez sorteos de θ

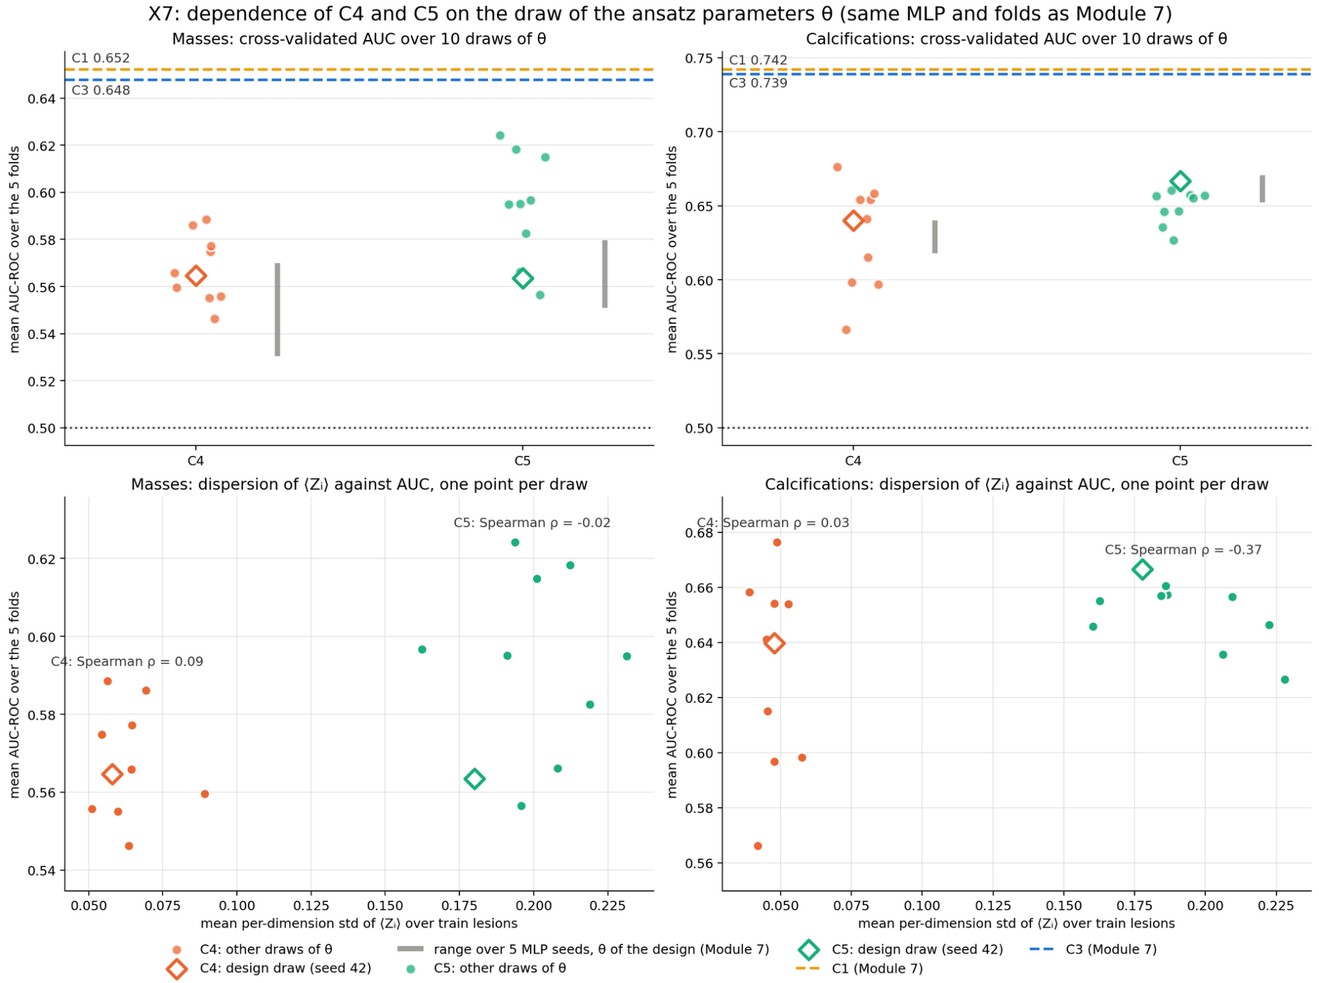

ANEXO 72

Figura 6.3.5 · θ entrenado frente a θ fijo

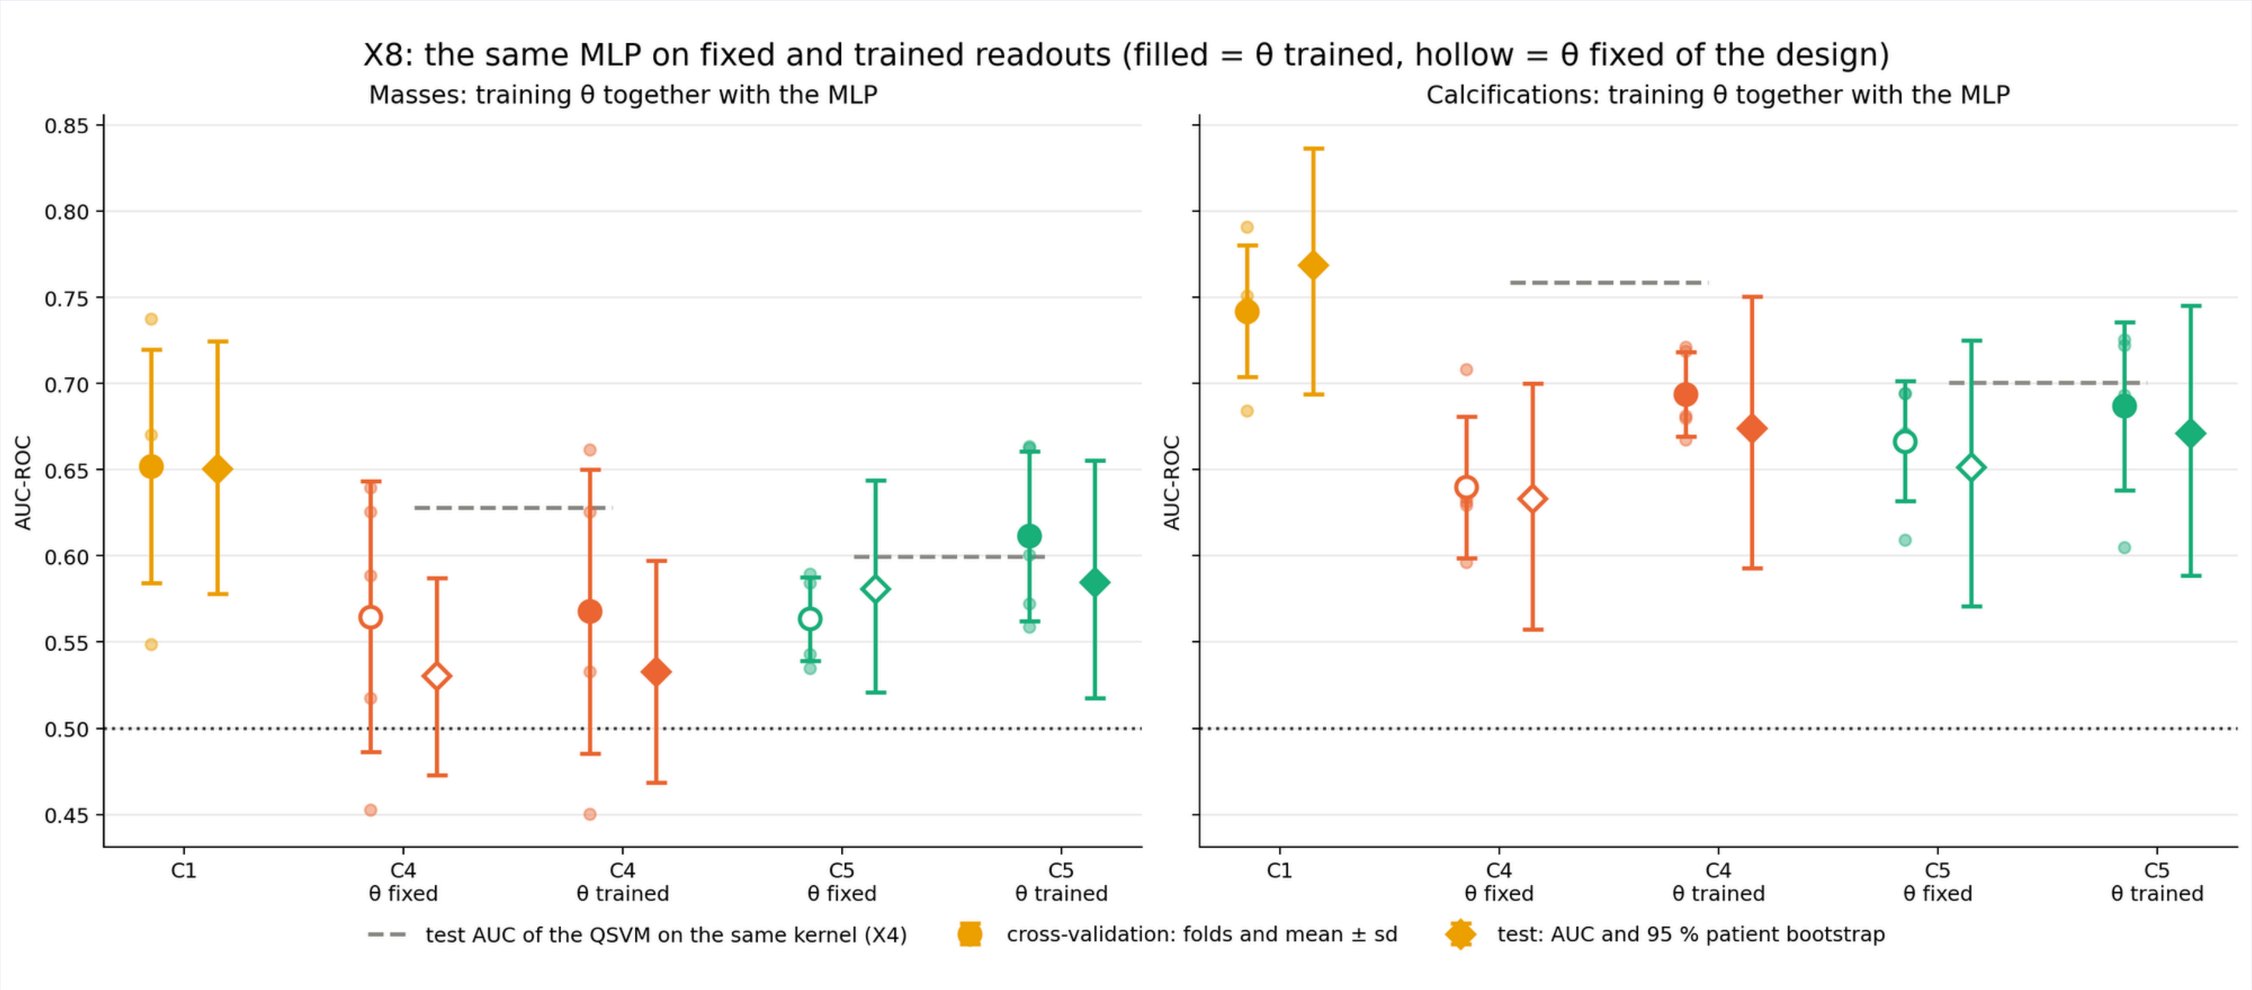

ANEXO 73

Figura 6.3.6 · Árboles, *random forest* y XGBoost sobre C1–C5

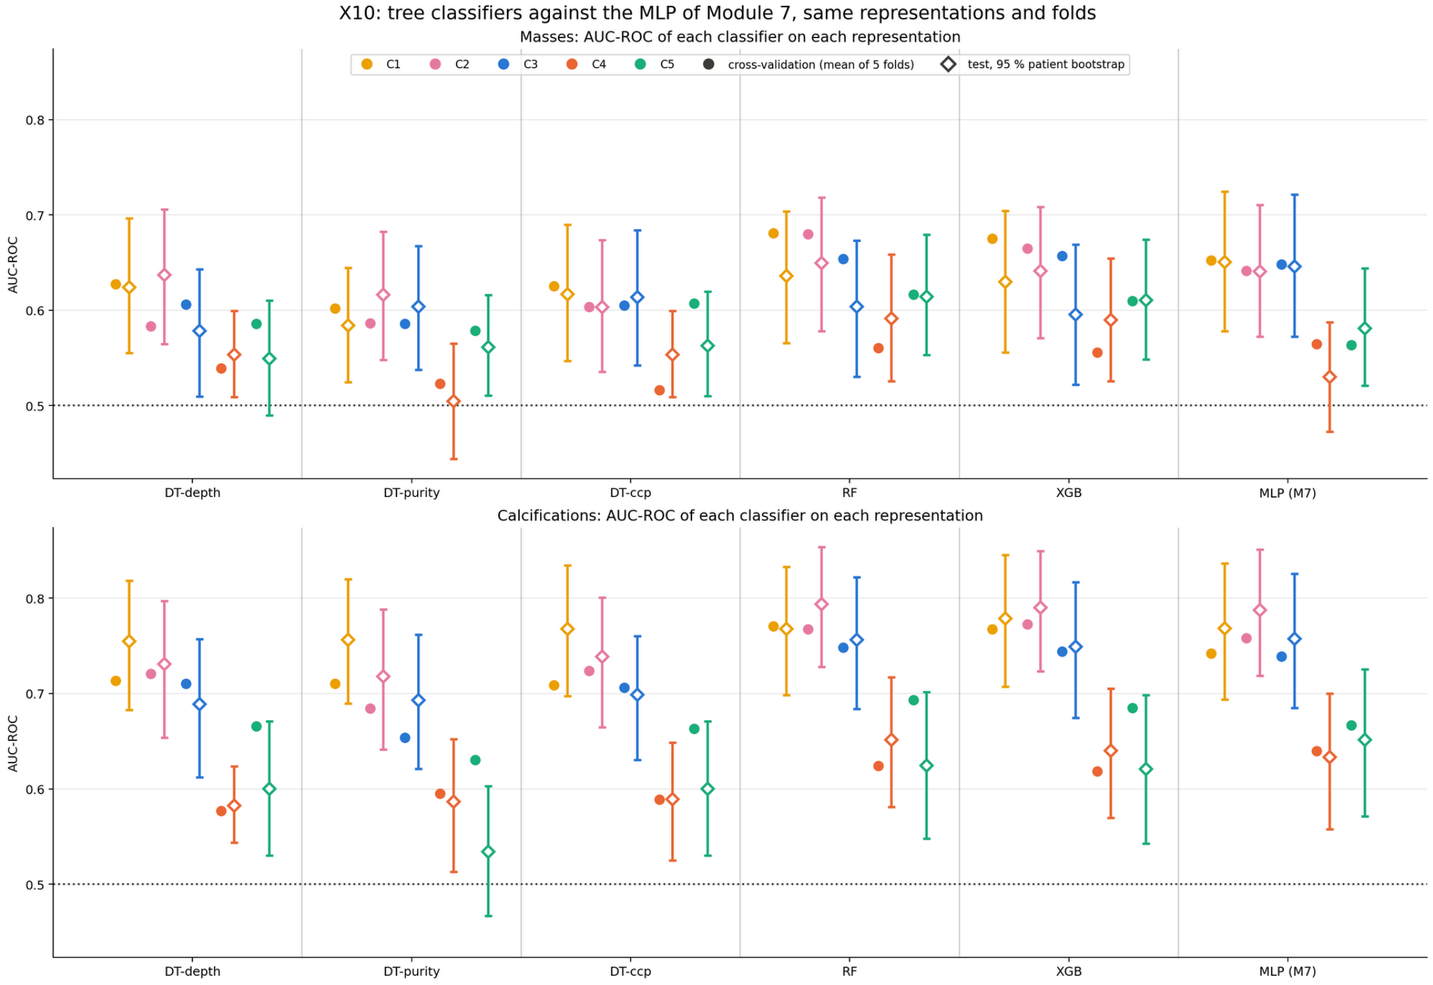

Figura 6.3.7 · Criterios de parada de un árbol

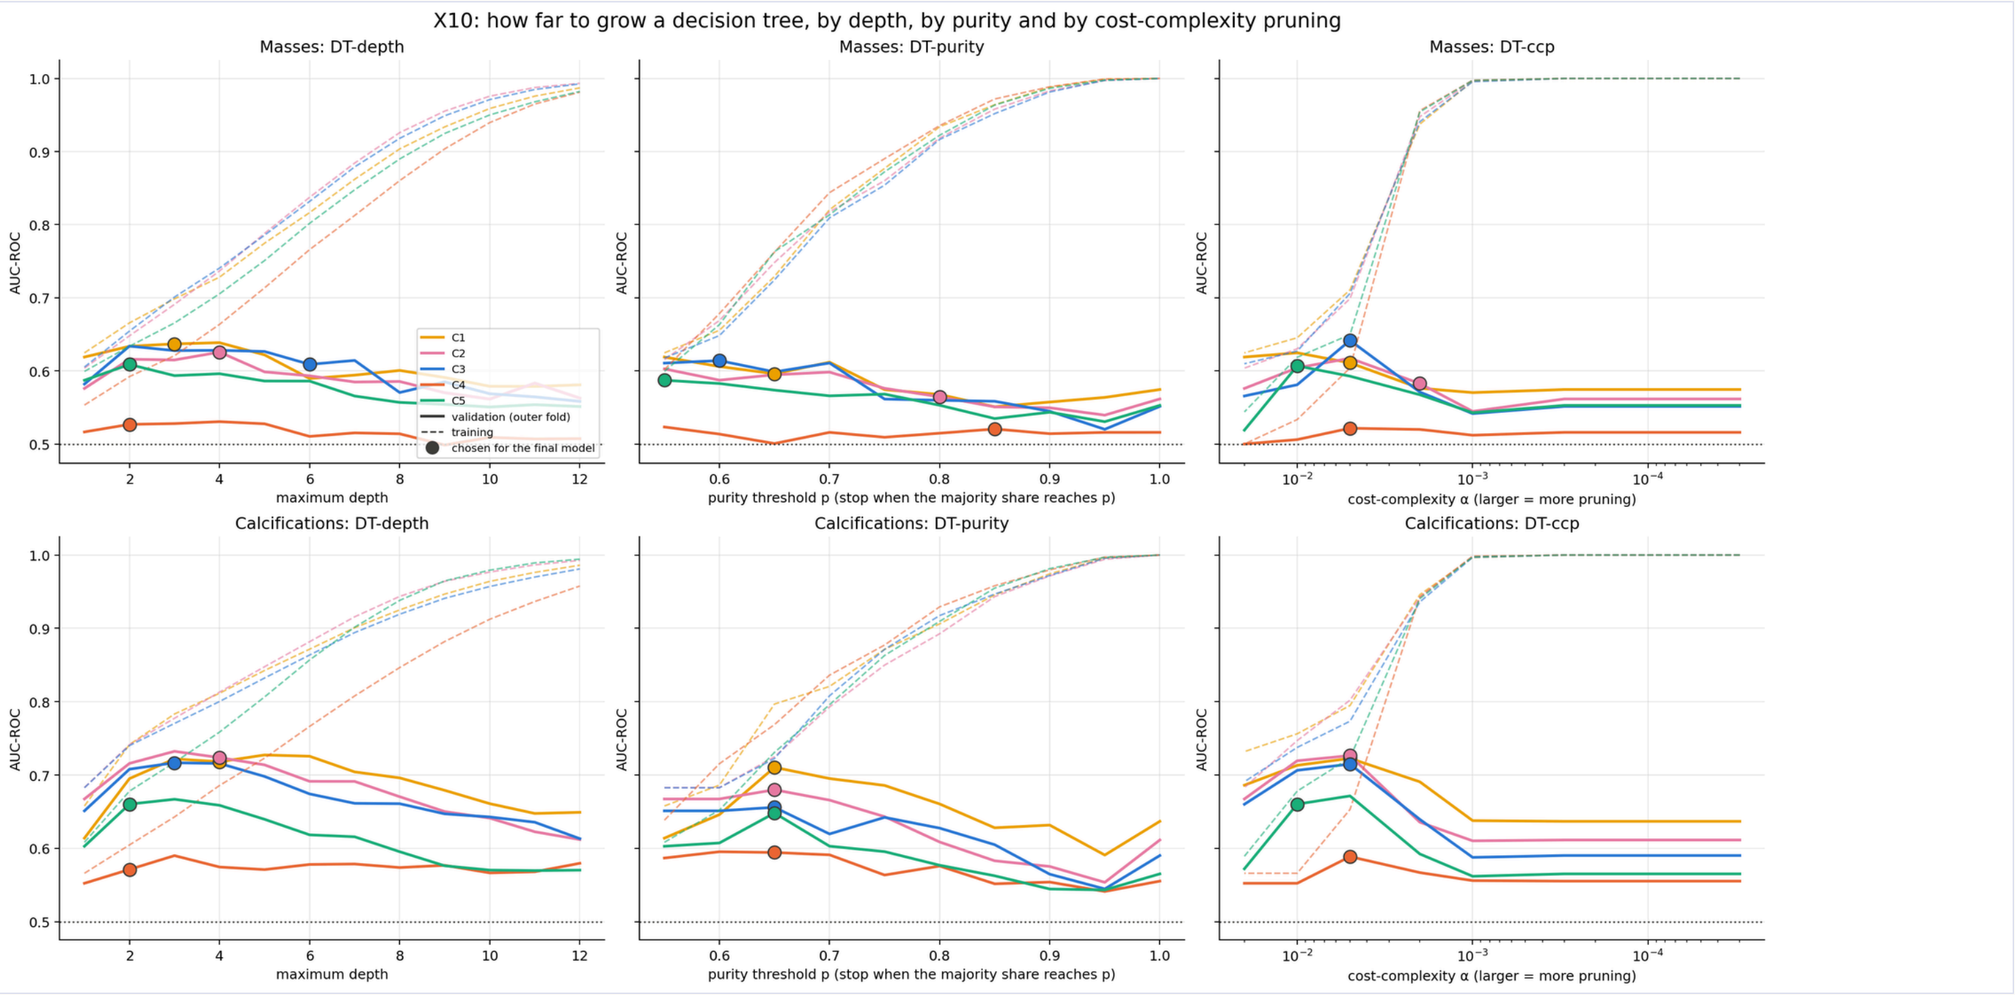

ANEXO 75

Figura 6.4.1 · QSVM, SVM RBF y MLP sobre $\langle Z_i \rangle$

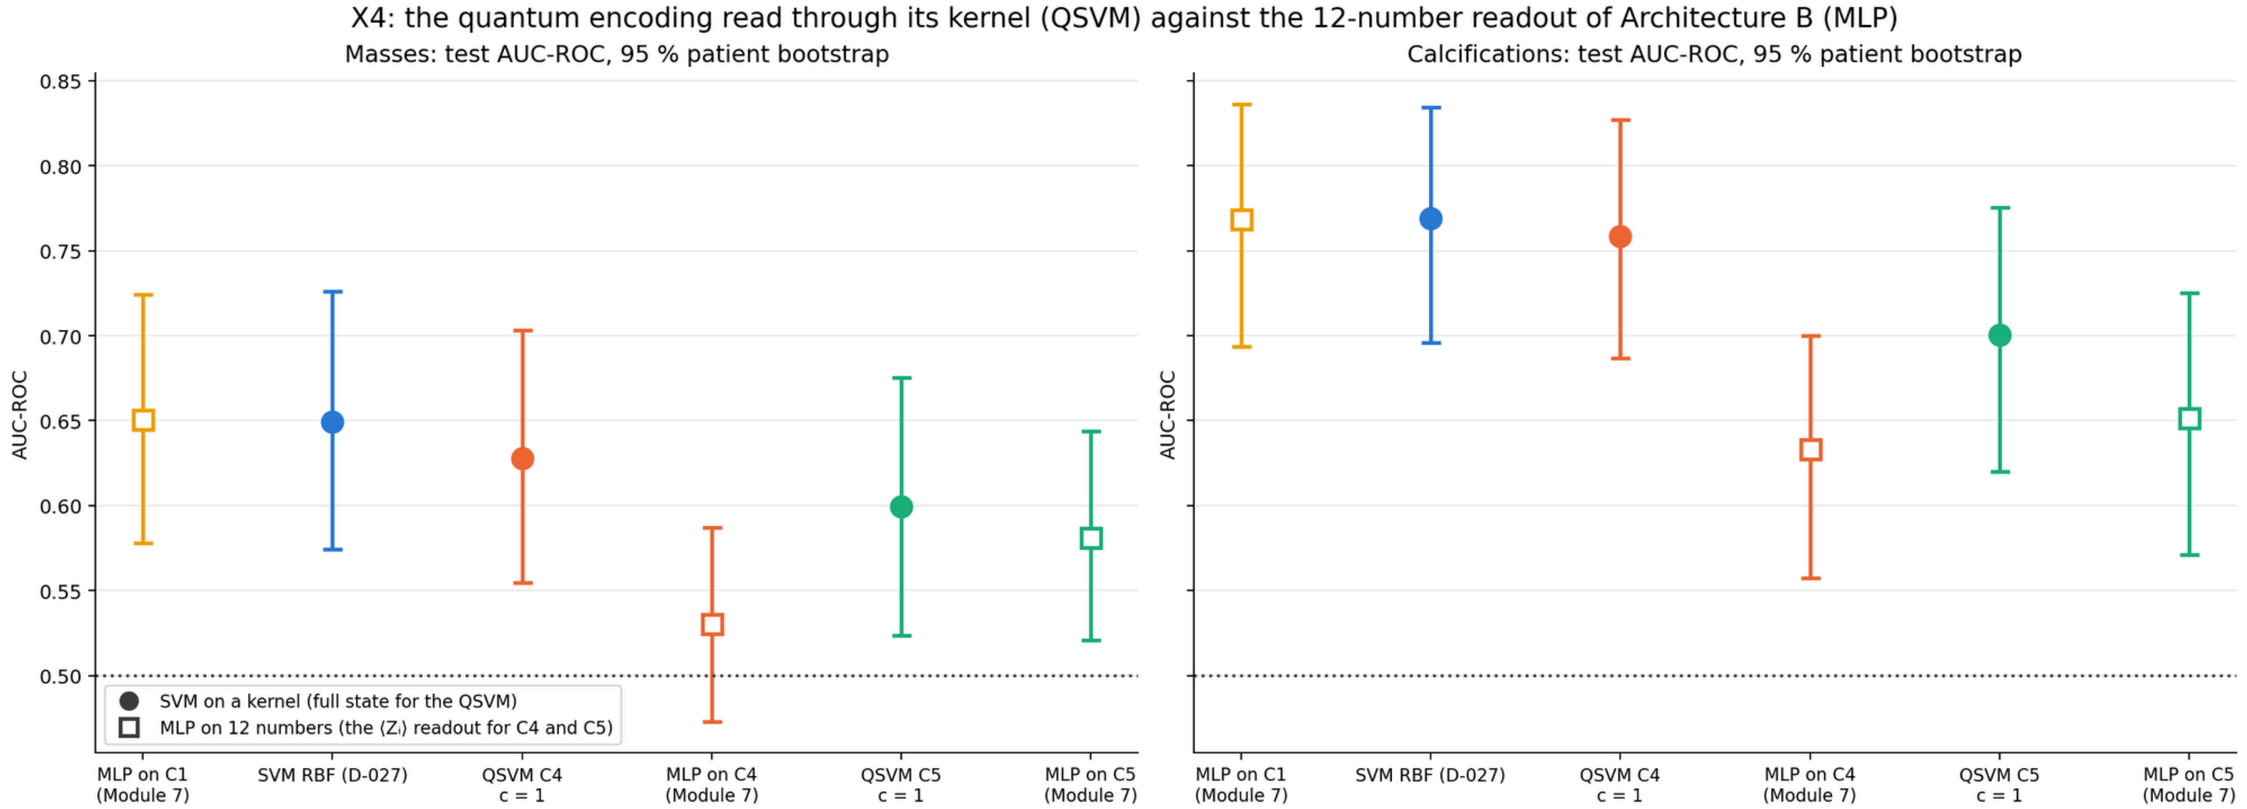

Figura 6.4.2 · Las 67 características con codificaciones alternativas

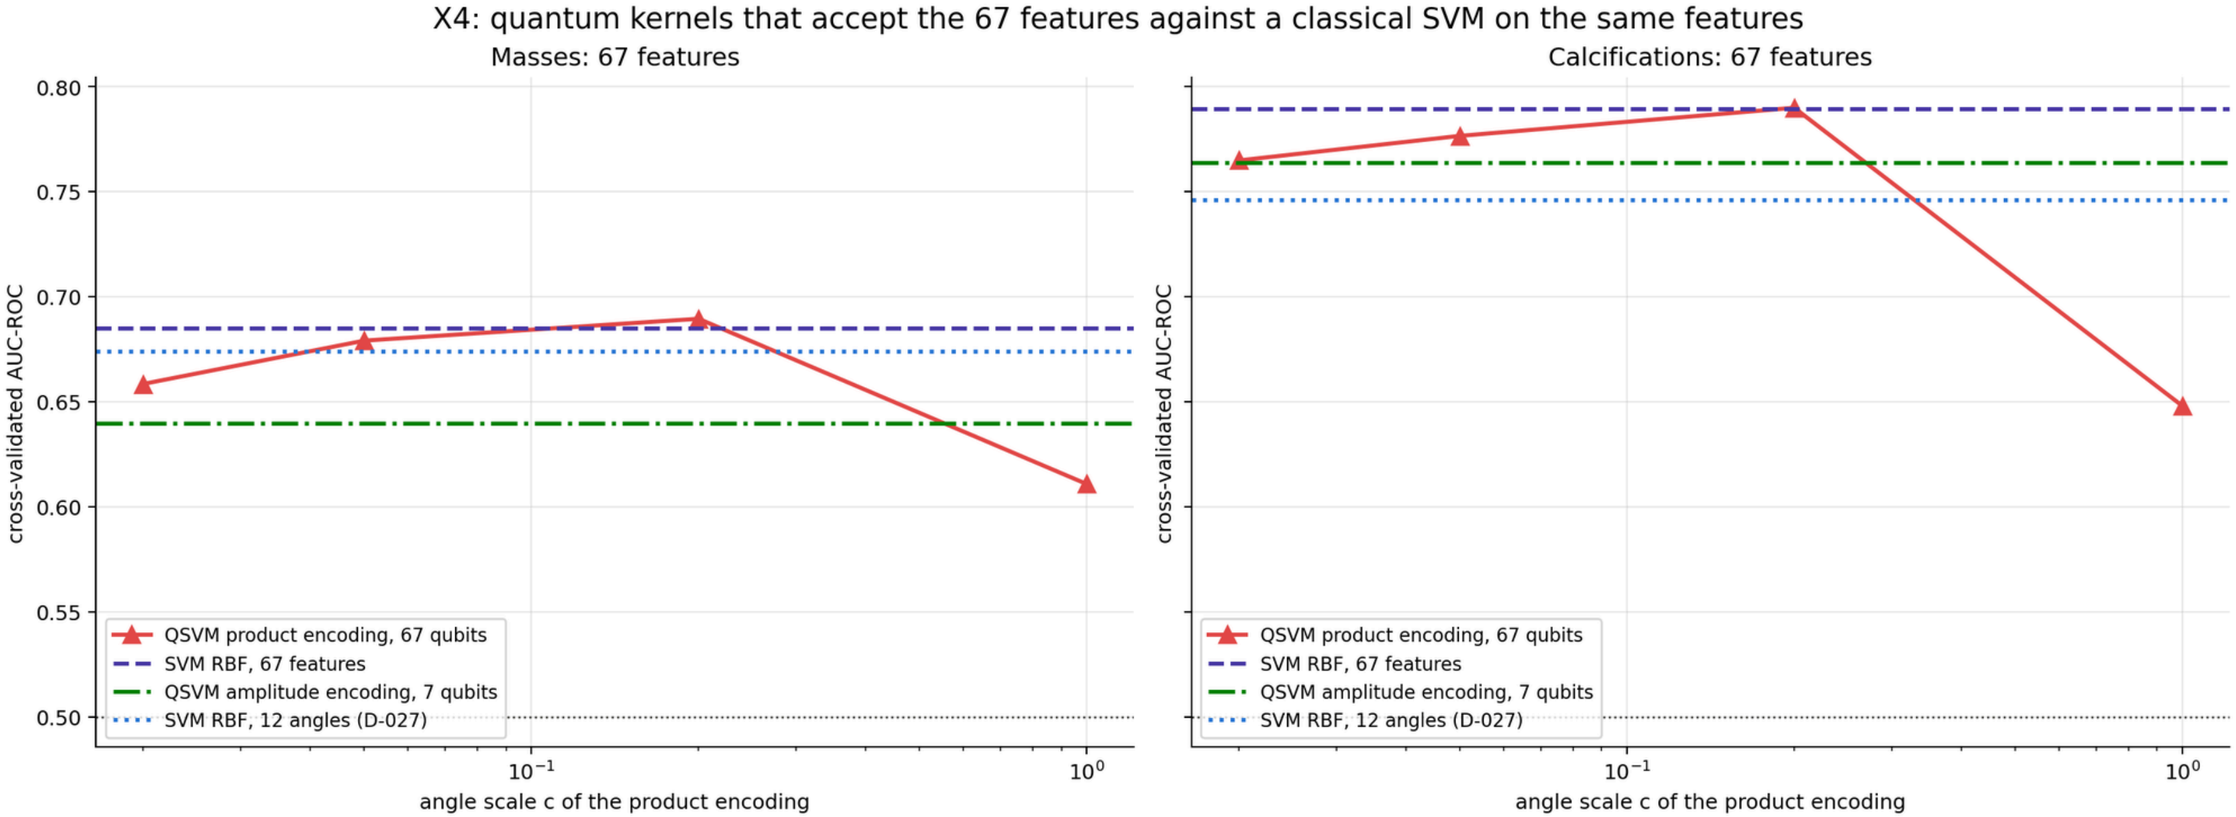

Figura 6.4.3 · Búsqueda anidada de ventaja cuántica

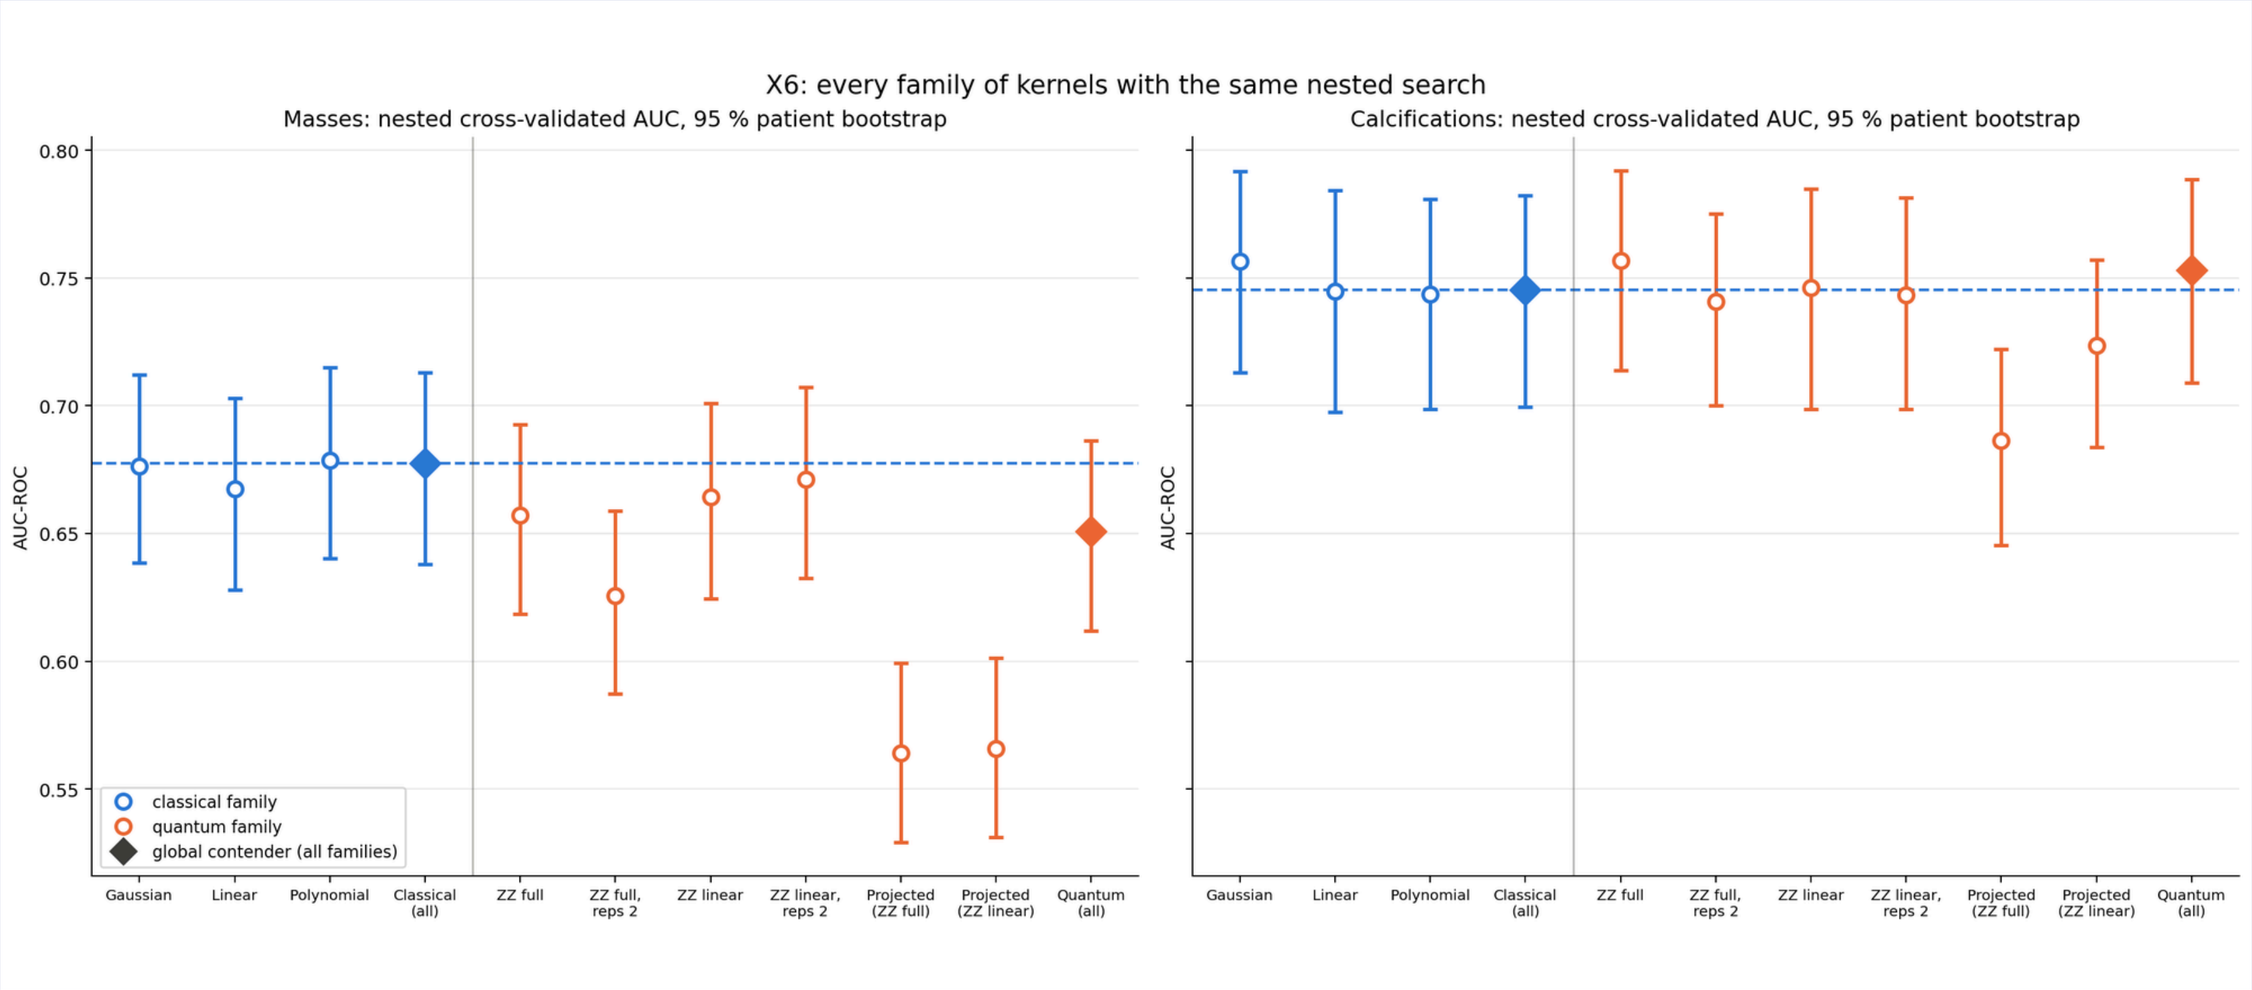

Figura 6.4.4 · Etiquetado diseñado según Huang et al.

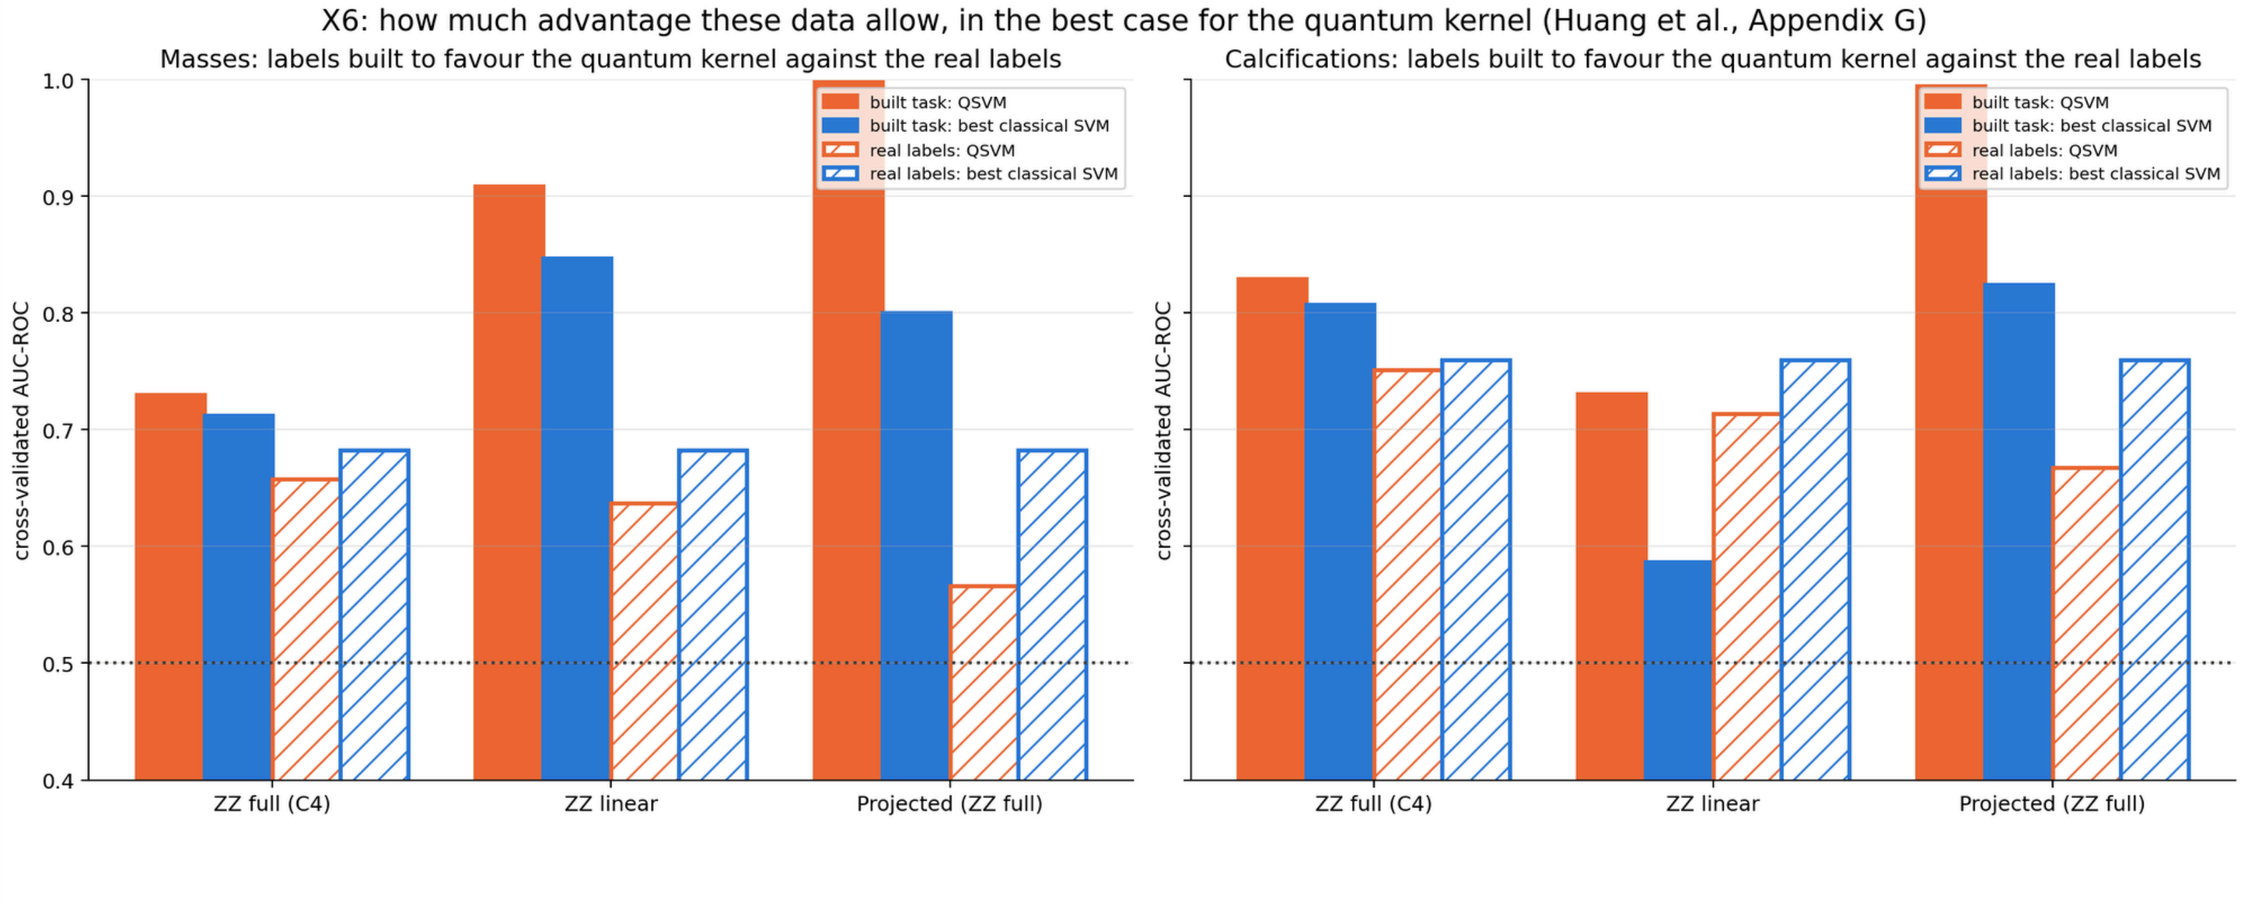

ANEXO 79

Figura 6.4.5 · Transición hacia las etiquetas diseñadas (X11)

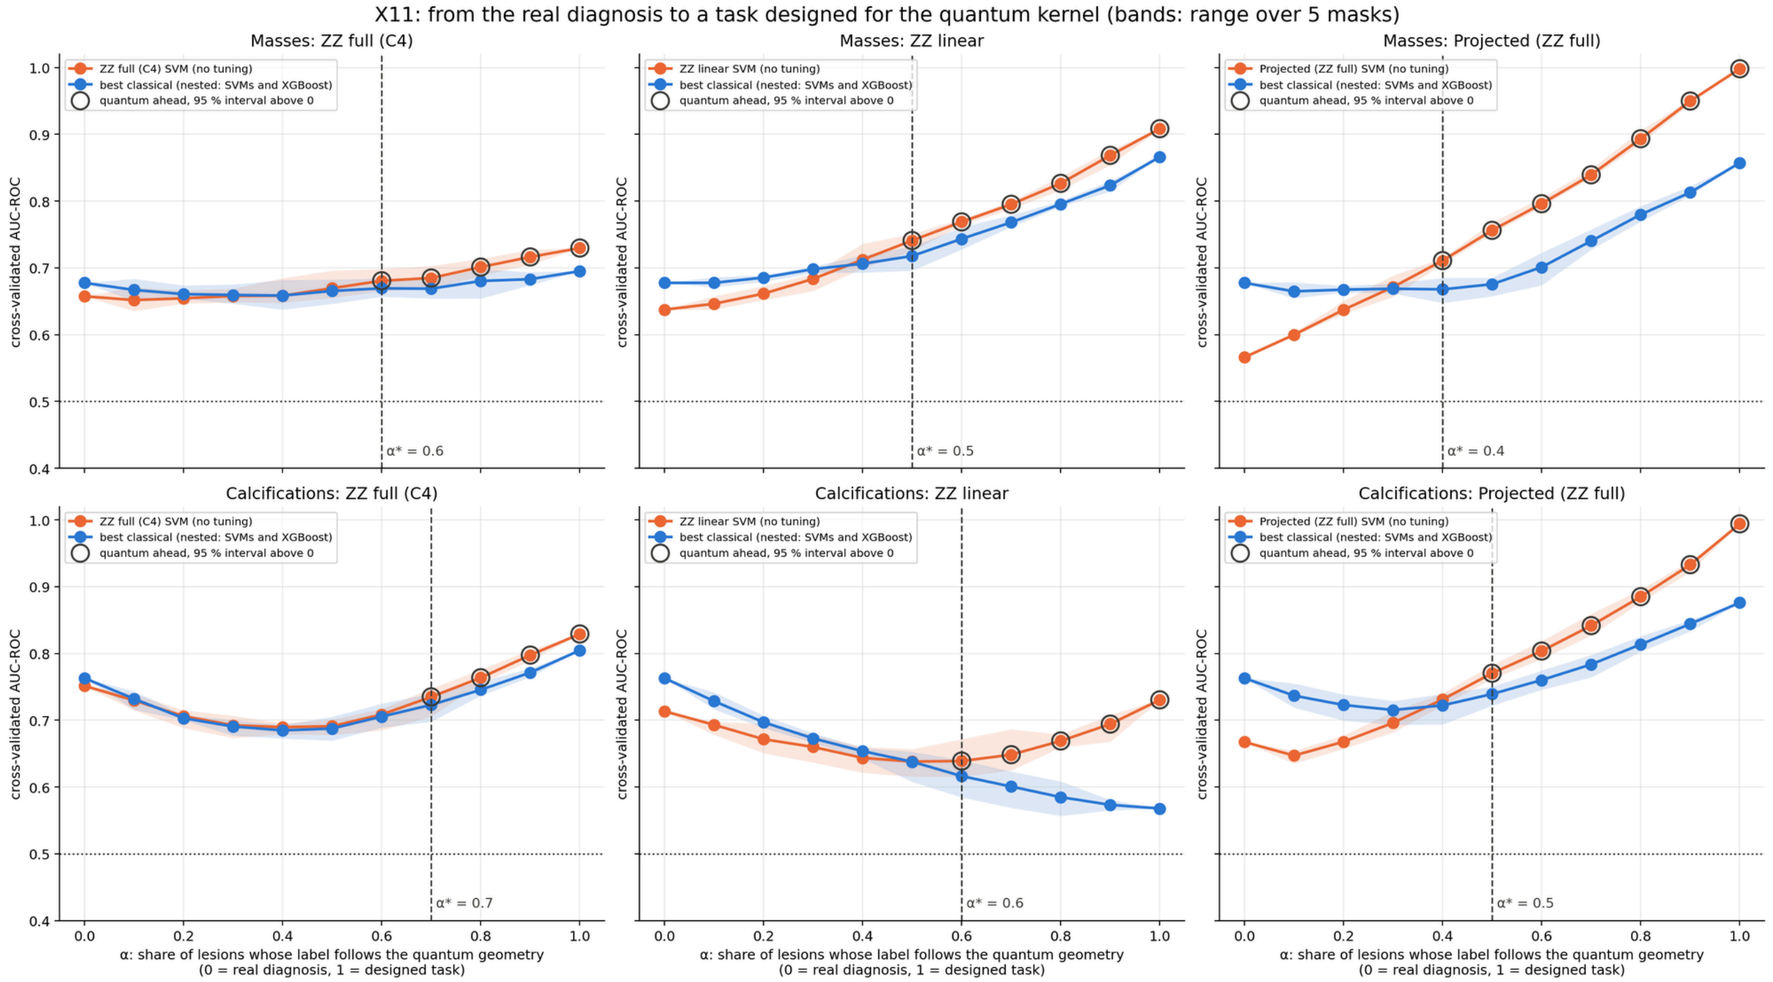

Figura 6.5.1 · Correlación de Spearman entre separabilidad y clasificación

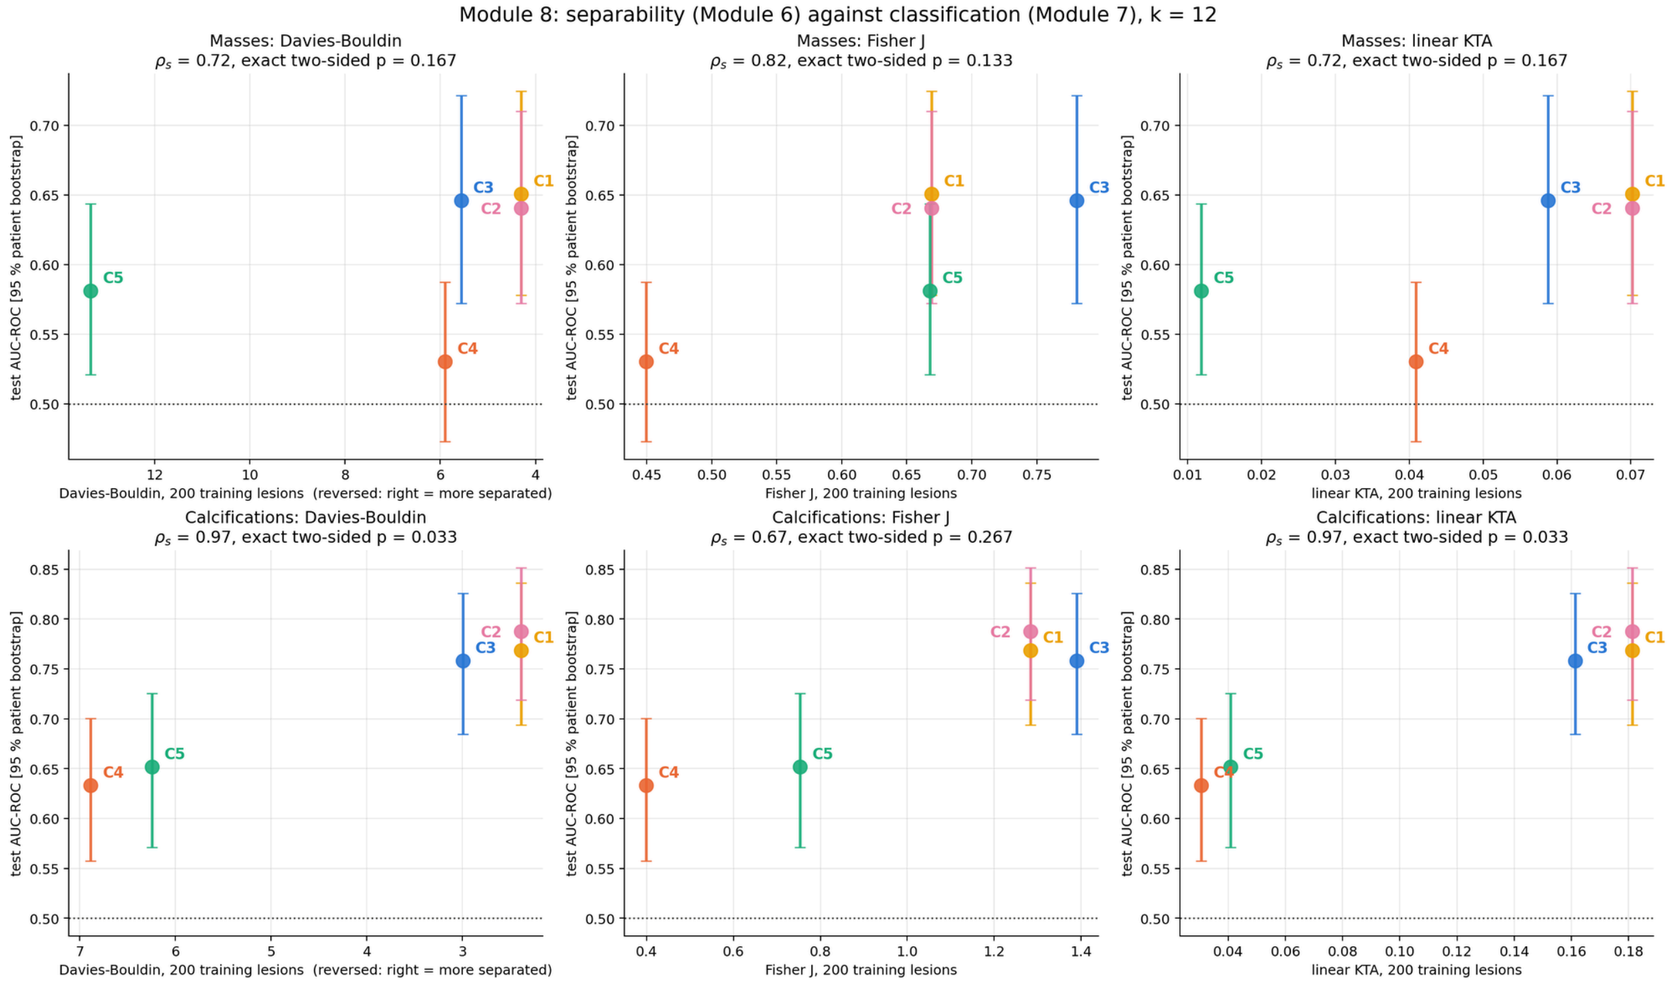

ANEXO 81

Figura 6.5.2 · Separabilidad frente a AUC, clásico y cuántico

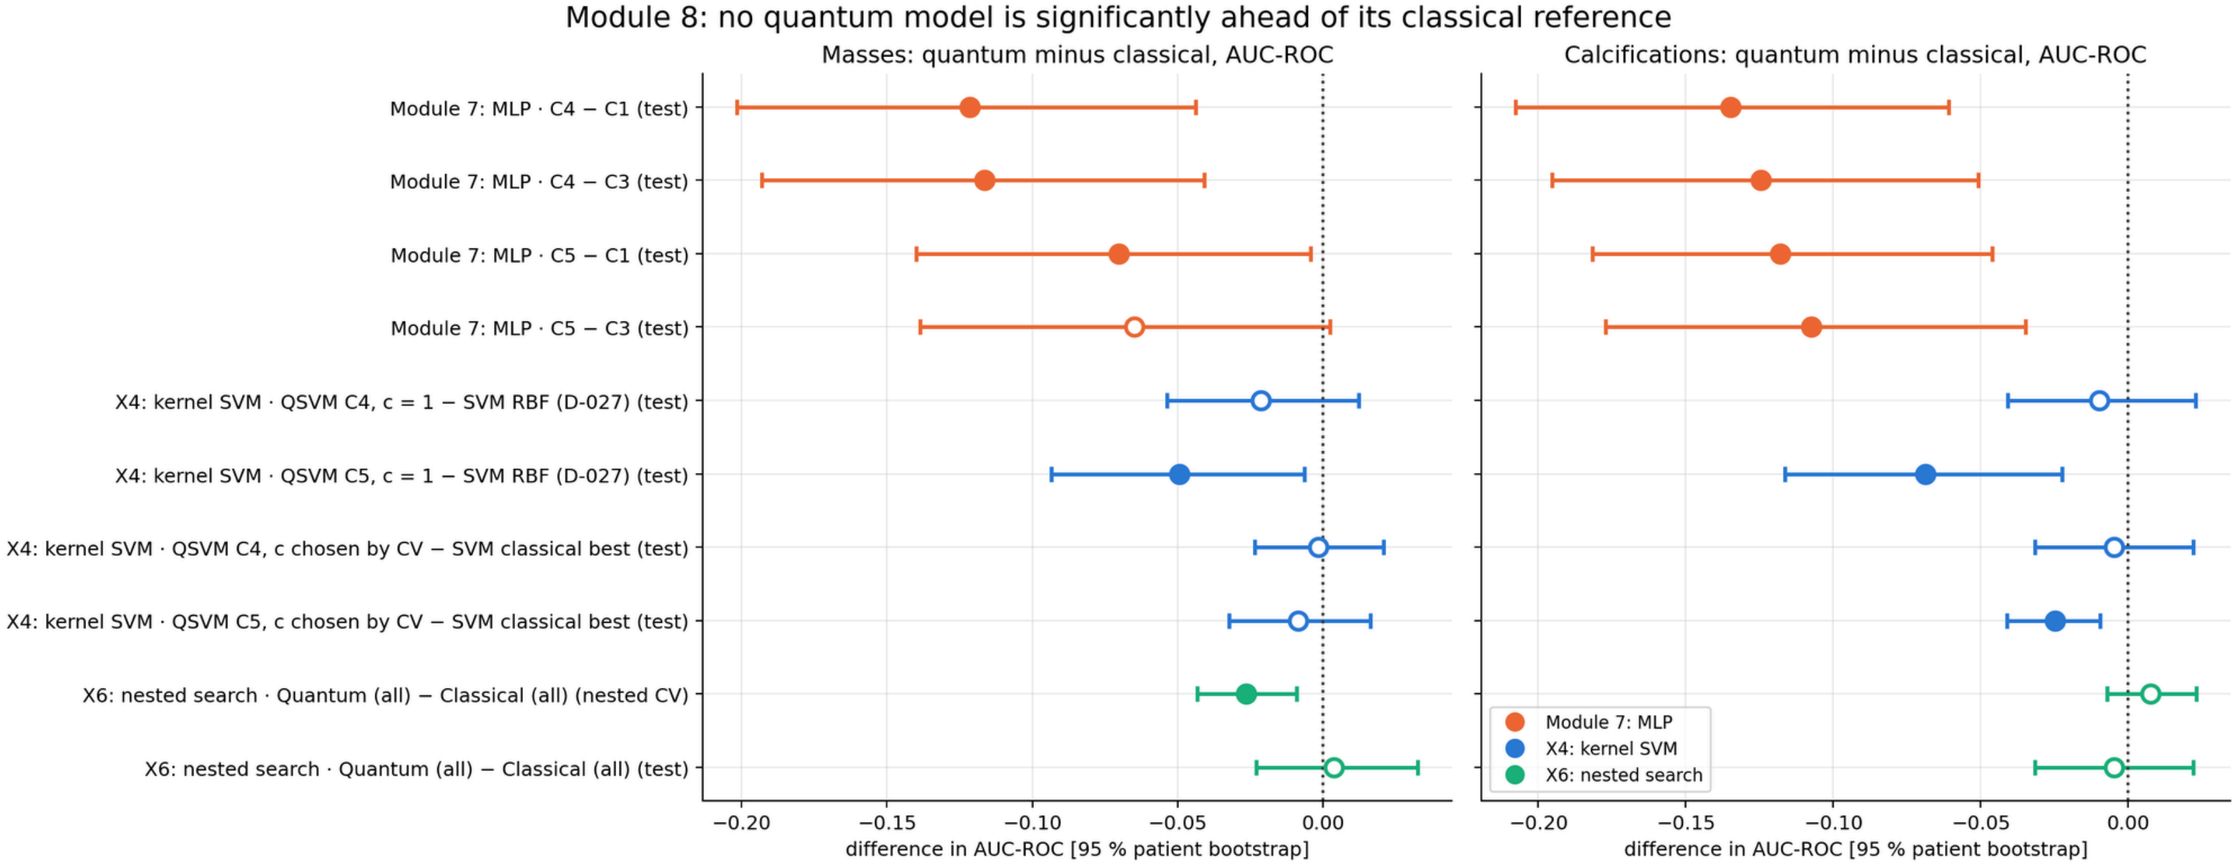

Figura 6.6.1 · Escalabilidad del simulador con el número de qubits

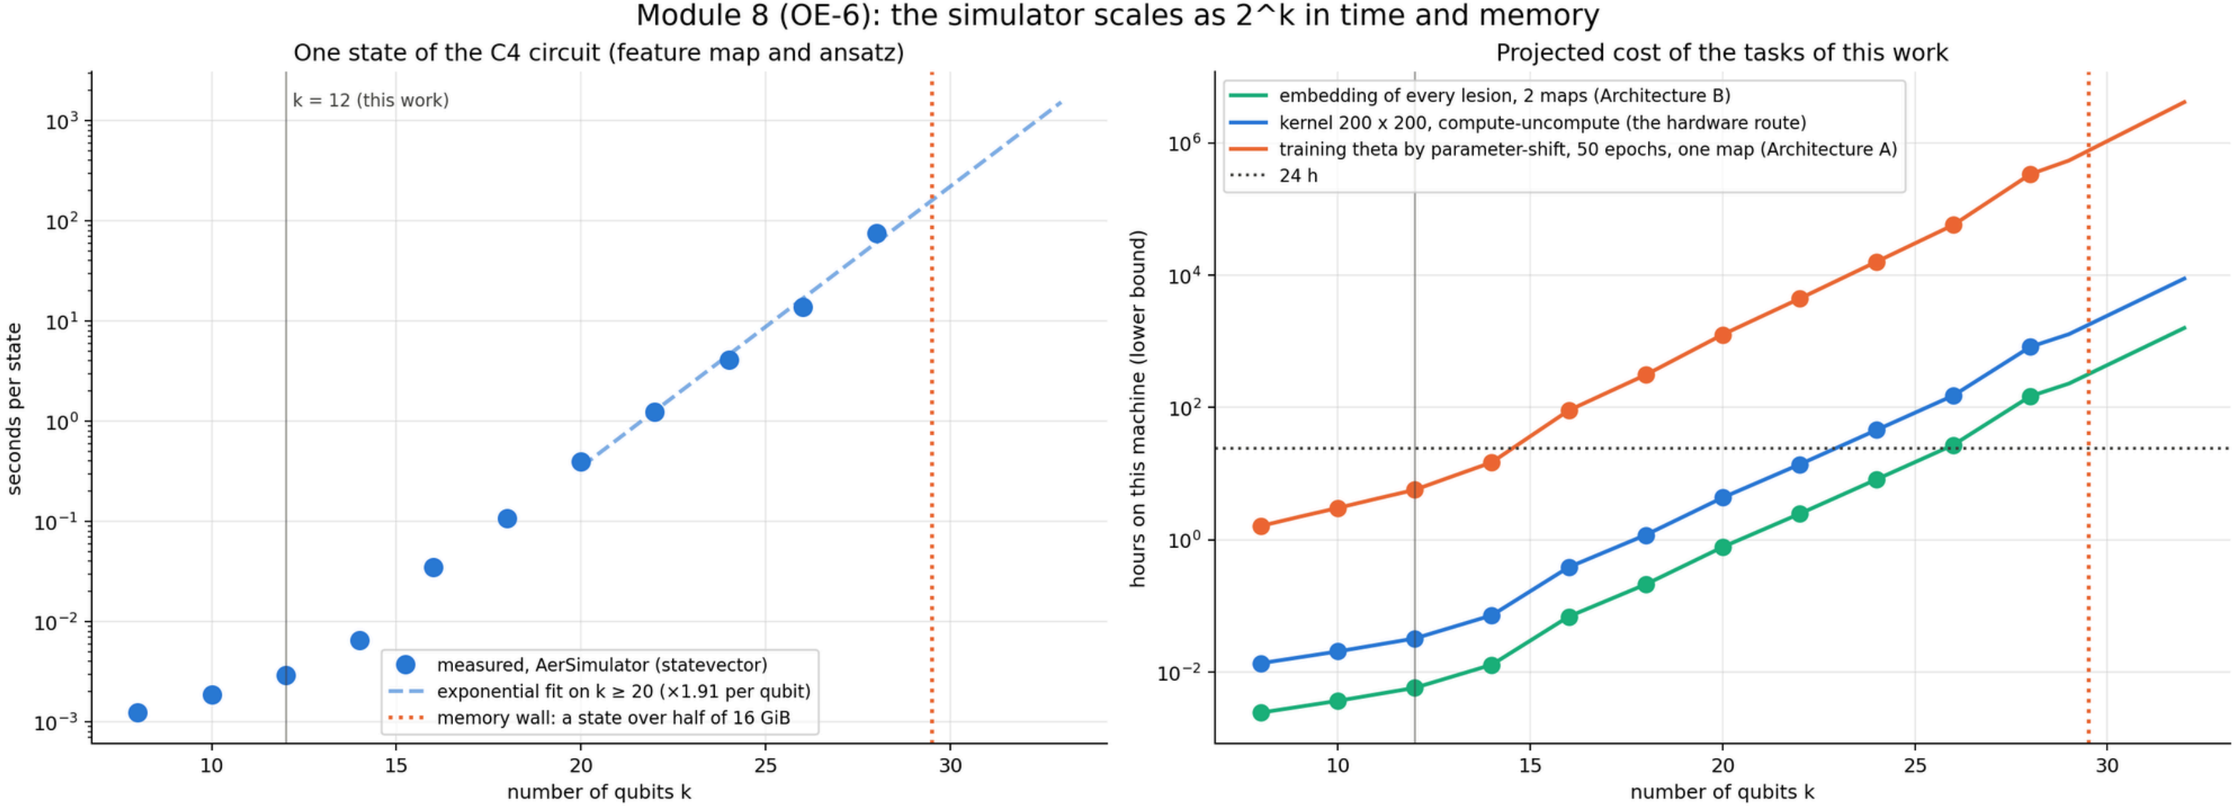

ANEXO 83

Figura 6.6.2 · Efecto del número de disparos

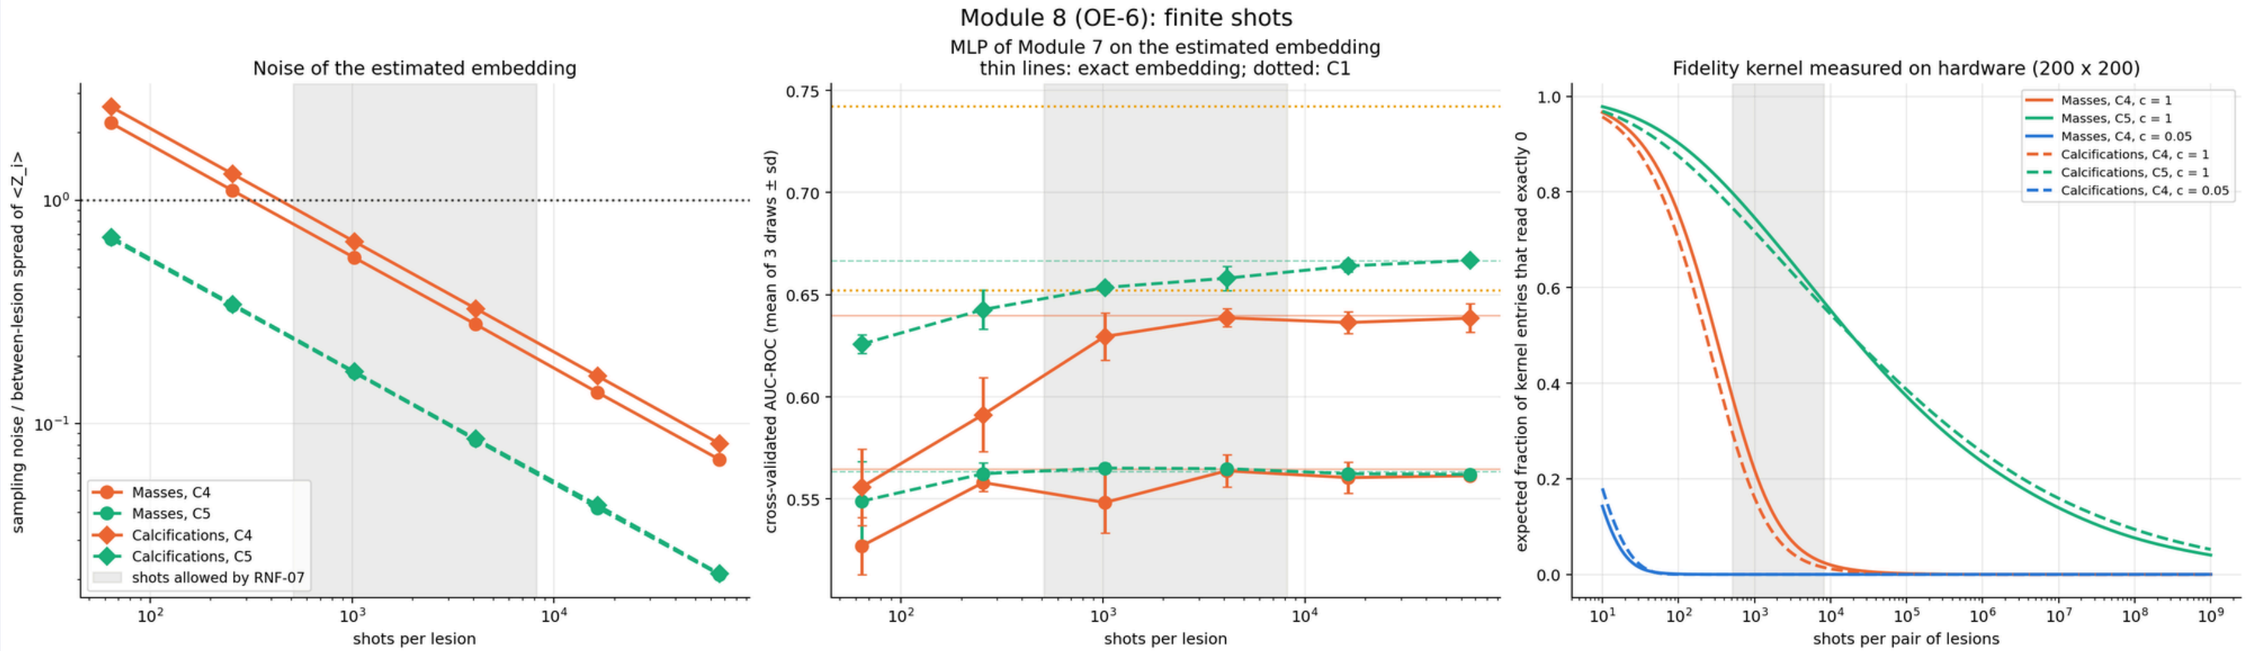

ANEXO 84

Figura C.1.1 · Alineación de las 80 máscaras desajustadas

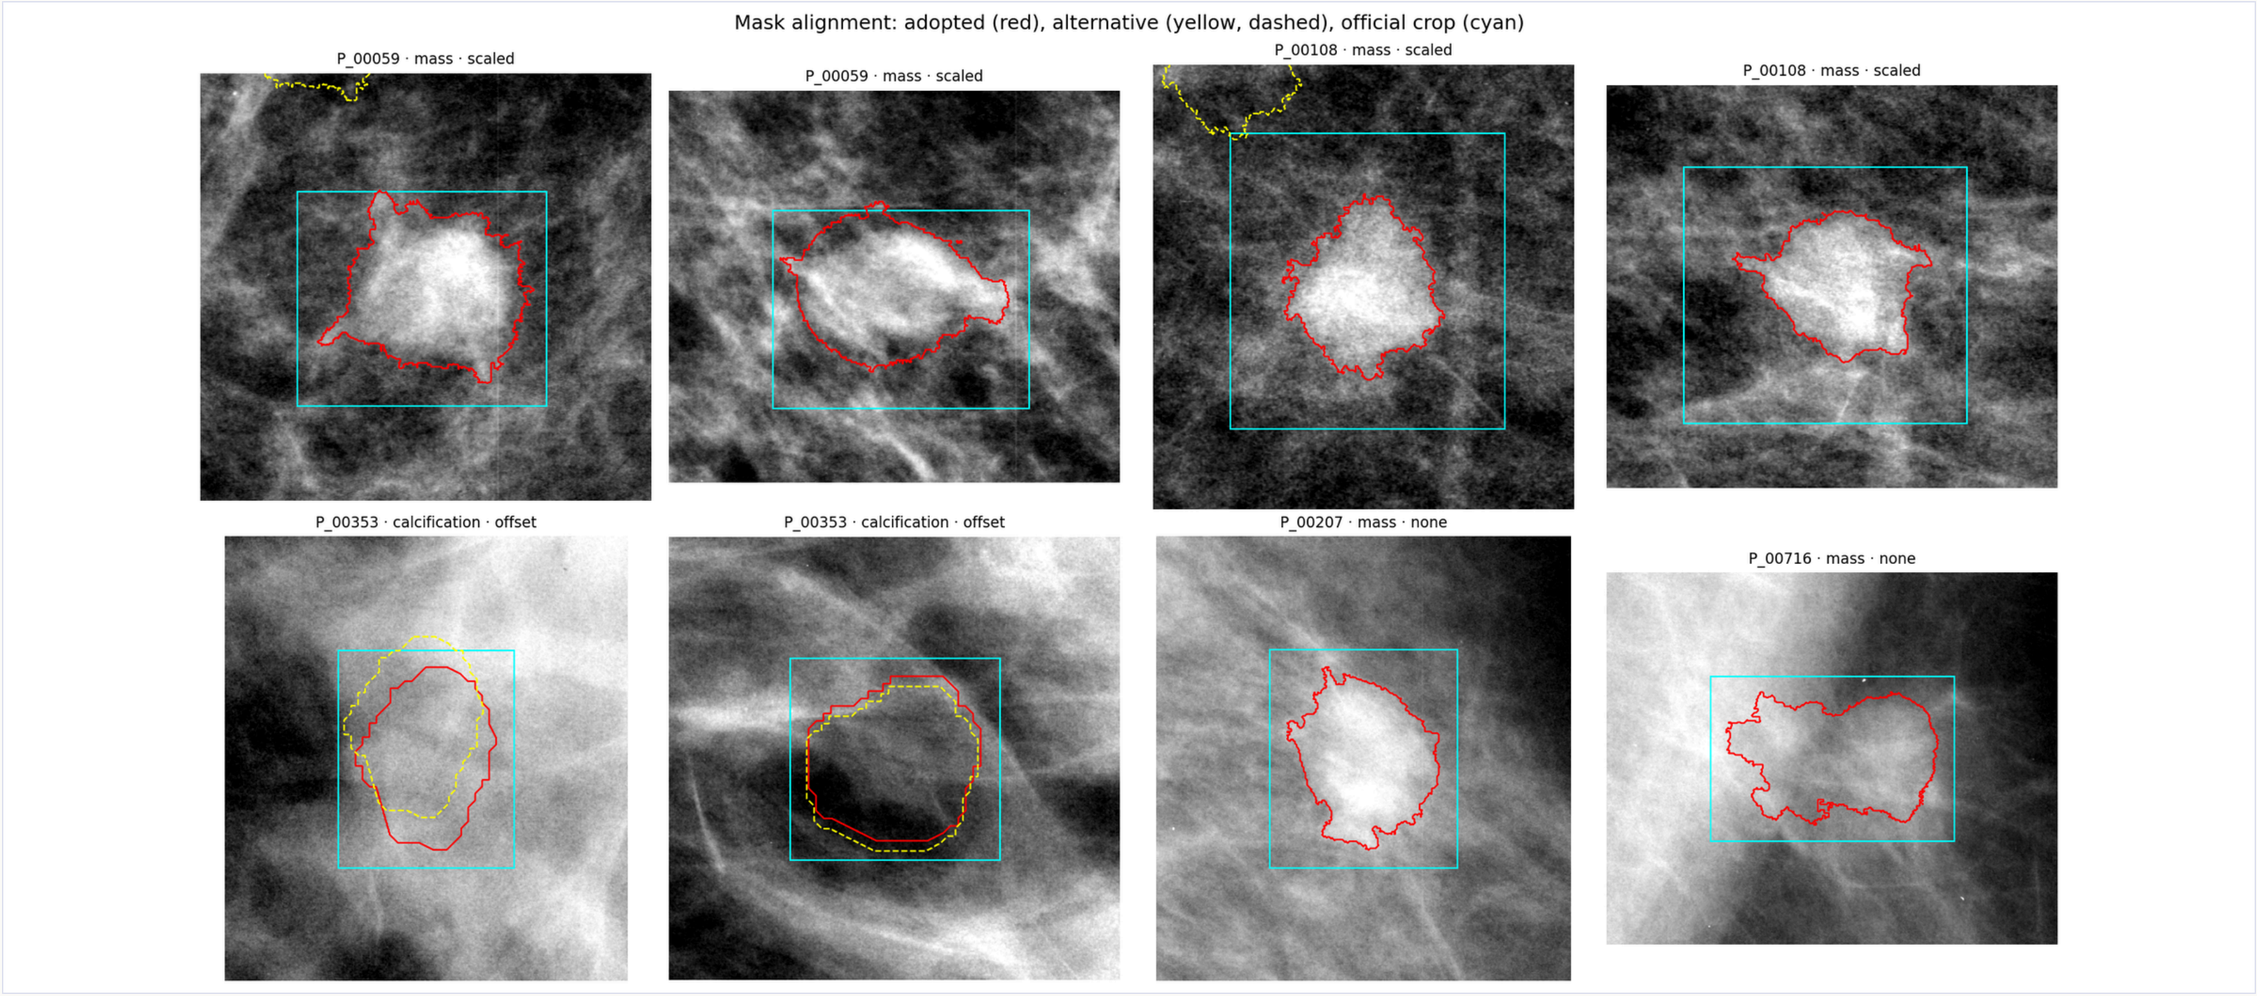

ANEXO 85

Figura C.1.2 · Etapas del preprocesamiento

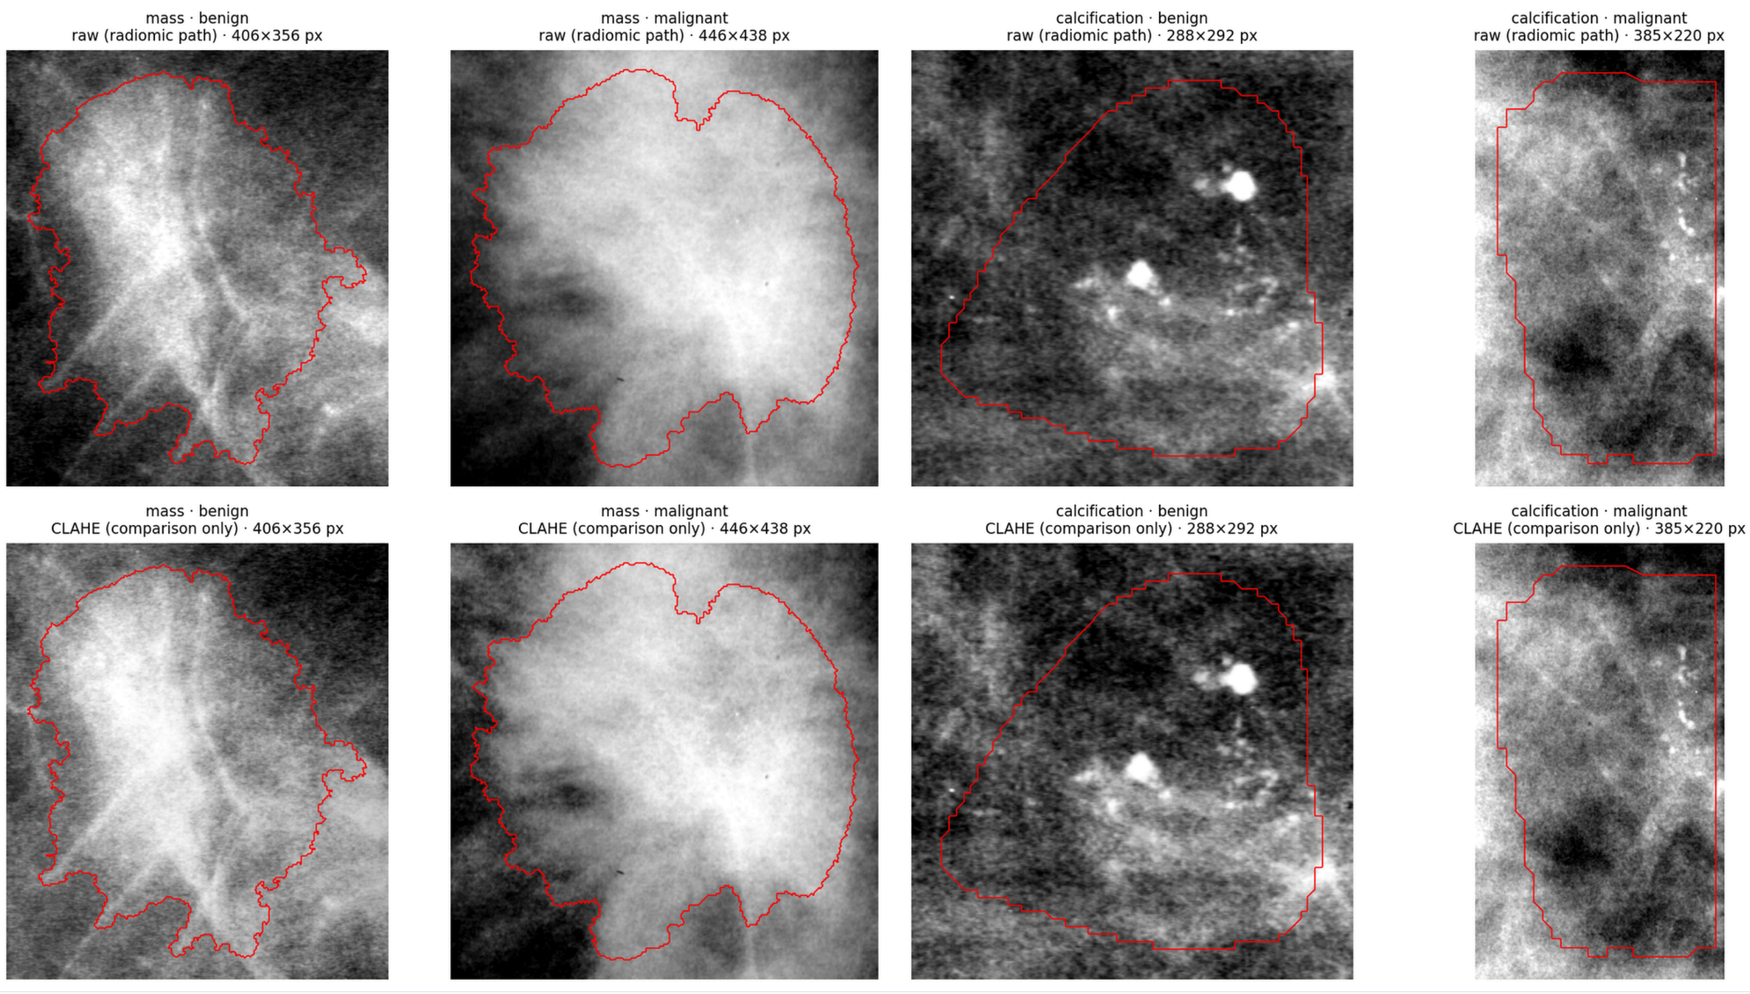

Figura C.4.1 · Valores del kernel dentro y entre clases