INSTITUTO POLITÉCNICO NACIONAL · ESCUELA SUPERIOR DE CÓMPUTO

Modelo de transformación cuántica variacional de características de cáncer de mama para un sistema híbrido de prediagnóstico

Trabajo Terminal 2026-B039

PRESENTA

Miguel Alexander Sánchez García

DIRECTORES

Dr. Jesús Yaljá Montiel Pérez

Dra. Ana María Winfield Reyes

24 de noviembre de 2026

Detectar a tiempo cambia la supervivencia de 33 % a más de 99 %

2.3 M

nuevos casos en el mundo, 2022

OMS

8,451

defunciones en México, 2024

INEGI

Supervivencia relativa a 5 años según la etapa al diagnóstico

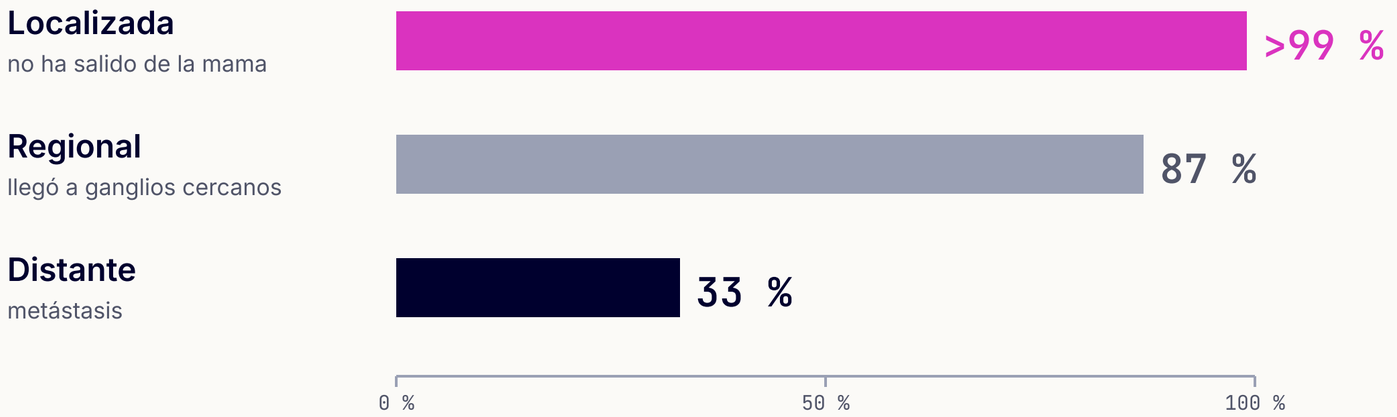

American Cancer Society · datos SEER (National Breast Cancer Foundation, 2026)

Mamografía de tamizaje
hasta 40 % menos mortalidad con tamizaje regular · ACR

→

La lectura varía entre radiólogos
Elmore et al., 1994

→

El aprendizaje automático clásico ya clasifica lesiones

→

¿Una codificación cuántica las representa de forma más separable?

Ningún trabajo previo había combinado codificación cuántica, CBIS-DDSM y análisis de separabilidad

	Trabajo	Datos	Circuito cuántico	CBIS-DDSM	Analiza separabilidad	Masas y calcs. por separado	Desempeño
Aprendizaje profundo en mamografía	Shen et al. (2019)	CBIS-DDSM	✗	✓	✗	✗	AUC 0.91
	Wang et al. (2020)	DDSM, INbreast, MIAS, UKy	✗	Parcial	✗	✗	AUC 0.88–0.95; externos 0.44–0.65
	Baccouche et al. (2022)	CBIS-DDSM, INbreast	✗	✓	✗	✗	Exactitud 0.95
Aprendizaje cuántico fuera de la mamografía	Xiang et al. (2024)	tabulares (GBSG, SEER, WDBC)	✓ sim.	✗	✗	—	Exactitud 0.70–0.96
	Toufah et al. (2025)	cáncer de pulmón (tabular)	✓ sim.	✗	✗	—	Exactitud 0.91–0.96 (RBF 0.95)
	Parigi et al. (2026)	MNIST, F-MNIST	✓ sim.	✗	✓	—	Exactitud 0.94–0.99
Aprendizaje cuántico en mamografía	Azevedo et al. (2022)	BCDR	✓ sim. y hardware	✗	✗	✗	AUC 0.77 (clásico 0.58)
	Este trabajo	CBIS-DDSM	✓ sim.	✓	✓	✓	AUC masas 0.53/0.58 (C1 0.65); calcs. 0.63/0.65 (C1 0.77)

la combinación que faltaba

Azevedo et al. (2022) dejaron como trabajo futuro...

- separar masas y calcificaciones
- probar otros conjuntos de datos
- ver cómo quedan las clases en el espacio de Hilbert
- probar otras codificaciones

→ este trabajo lo hace

Azevedo et al. (2022), pp. 12–13

La pregunta de investigación

¿En qué medida las transformaciones cuánticas variacionales implementadas mediante **ZZFeatureMap y PauliFeatureMap** en Qiskit ❶ **modifican la separabilidad** de clases benigno/maligno de características radiómicas extraídas de mamografías del CBIS-DDSM, y **hasta qué punto esa diferencia** ❷ **se refleja en la capacidad de clasificación** de una misma red neuronal clásica, en comparación con representaciones clásicas construidas a partir del **mismo vector de características**?

❶ **Separabilidad** · ¿la transformación cuántica separa mejor benignas y malignas?

❷ **Clasificación** · ¿se nota al clasificar con la misma red neuronal?

Objetivo: viabilidad, no superar a una CNN · Simulación ideal (Qiskit Aer)

Del mamograma a la comparación: el proceso del trabajo

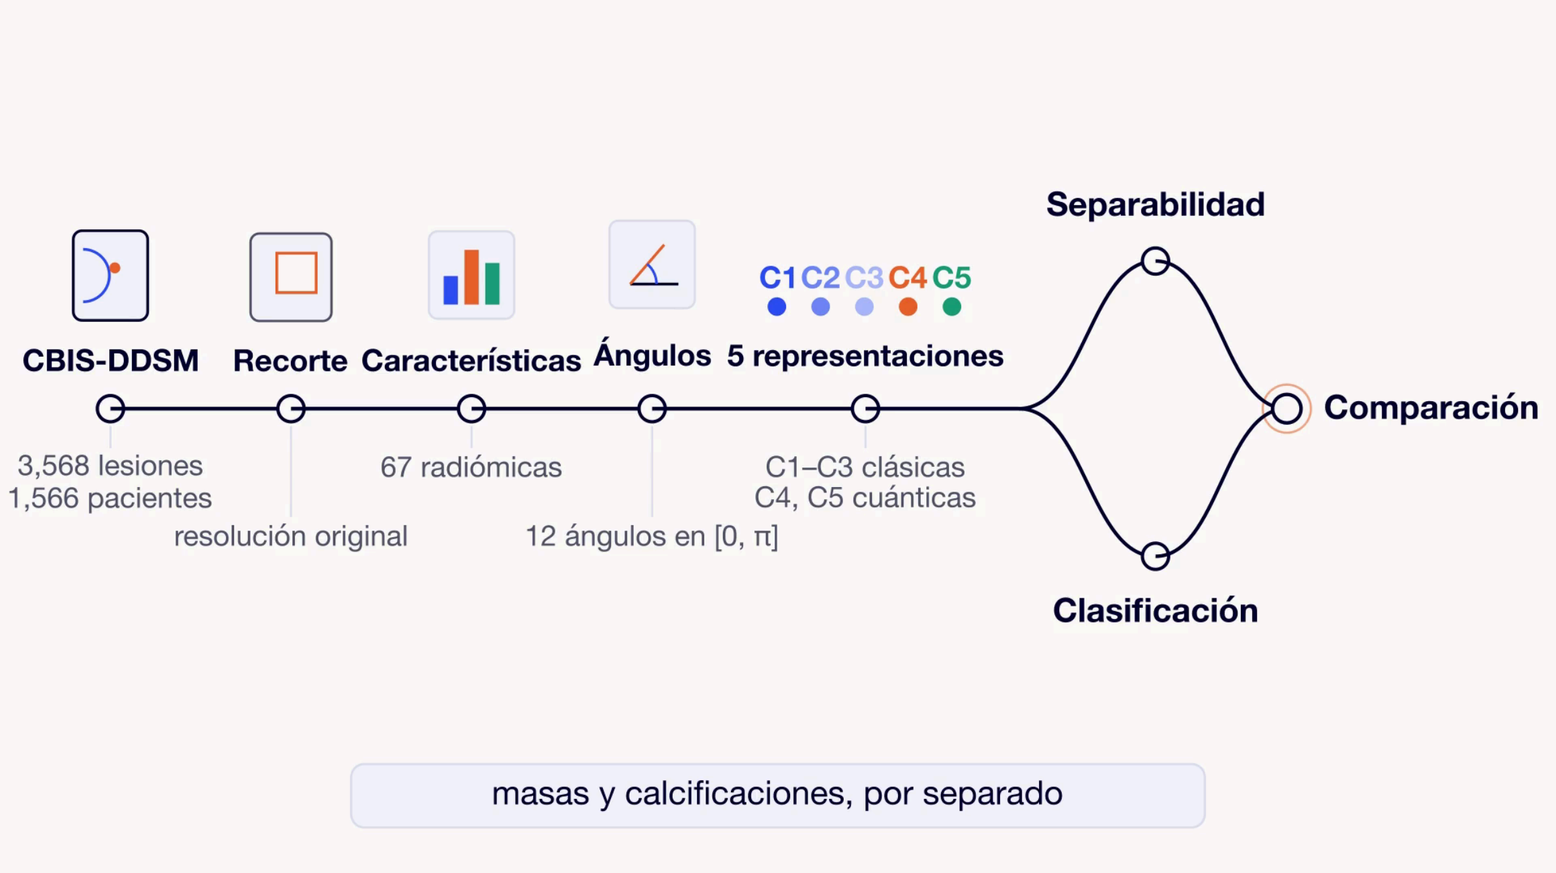

02 · DISEÑO

Cinco representaciones del mismo vector, un mismo clasificador

C1	**Sin transformación** · referencia		clásico
C2	**PCA lineal** · control nulo: rota, no añade información	girar no cambia la información	clásico
C3	**Kernel PCA con RBF** · no lineal clásico		clásico
C4	**ZZFeatureMap** + ansatz fijo		cuántico
C5	**PauliFeatureMap (Y, ZZ)** + ansatz fijo		cuántico

esquema ilustrativo

Misma entrada x, mismo MLP 12→32→16→1, mismos hiperparámetros y semilla. **La única variable es la transformación.**

Un qubit es una flecha en una esfera; 12 qubits combinan 4,096 posibilidades

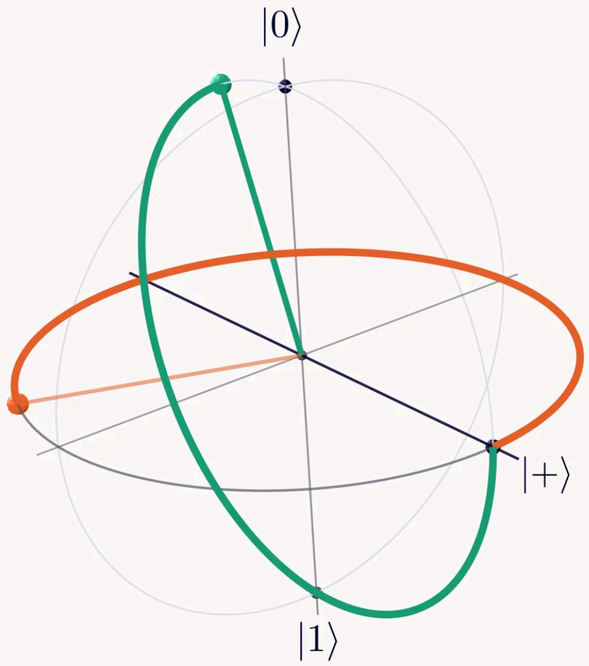

Hadamard

C4: giro en Z, se queda en el ecuador

C5: giro en Y, sale del ecuador

12 qubits = 2^{12} = 4,096 combinaciones

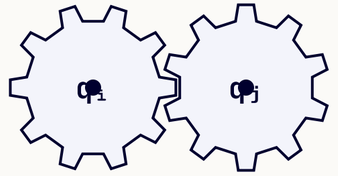

ZZ: cada par gira según sus dos características

esquema ilustrativo

Un circuito convierte 12 números en un estado de 12 qubits, y hay dos formas de leerlo

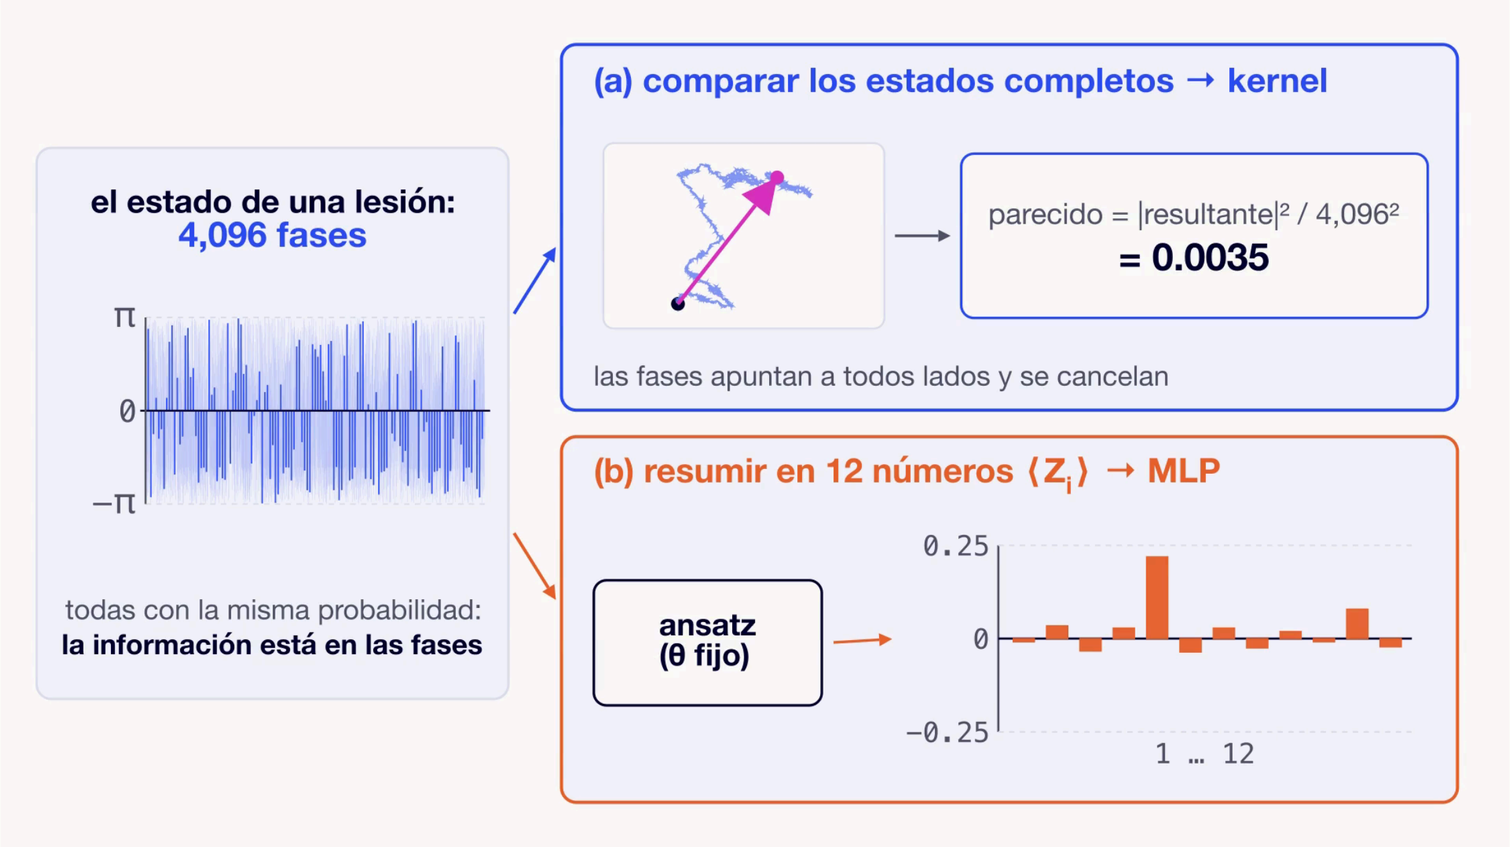

Arquitectura B: θ fijo; los 12 valores se calculan una vez

03 · RESULTADOS · ❶ Separabilidad

El kernel cuántico ve casi todos los pares de lesiones como ortogonales

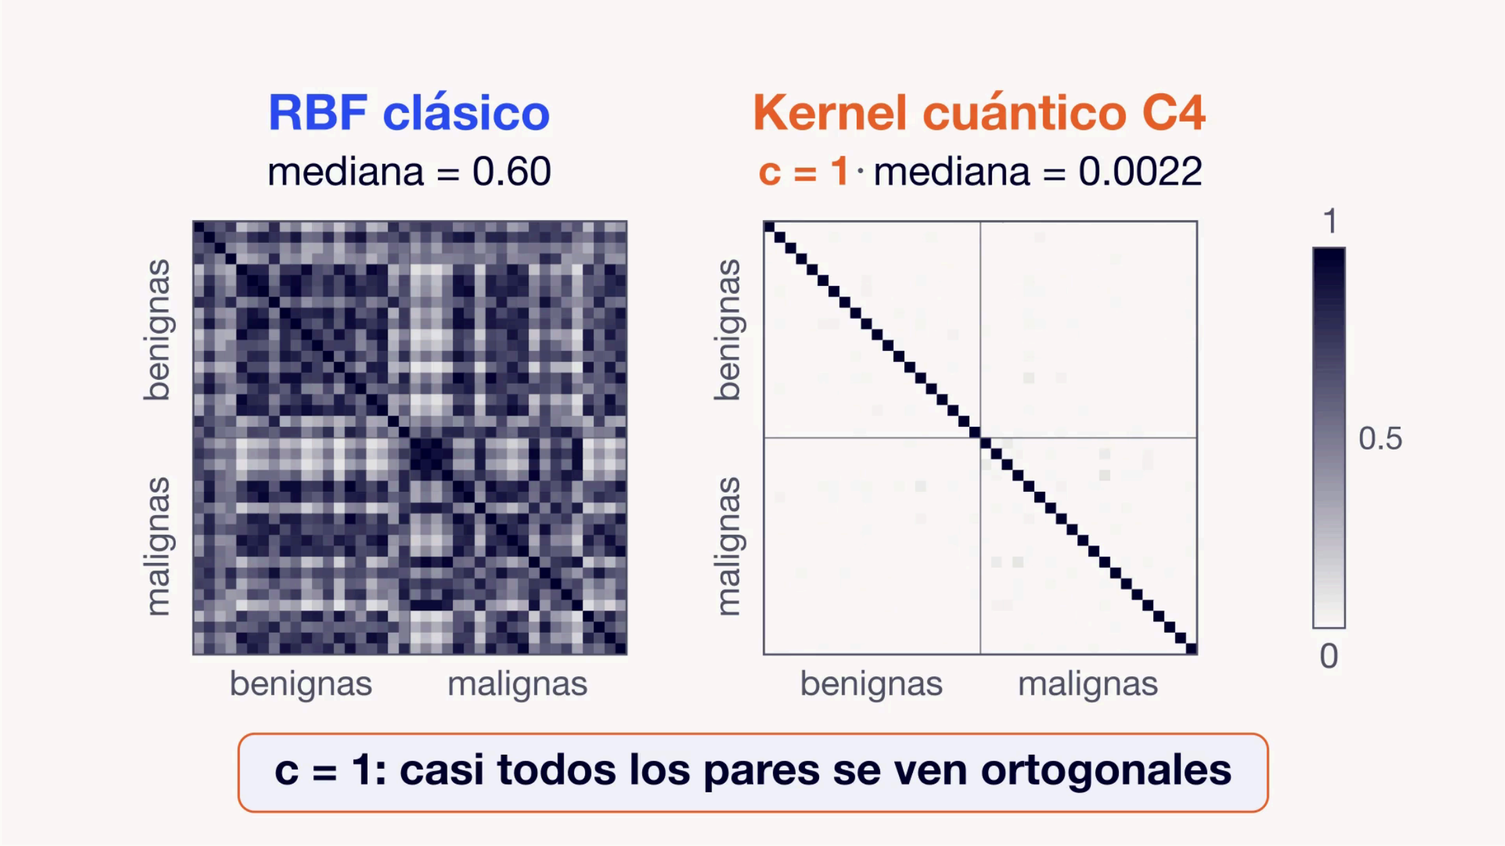

40 lesiones de masas de la submuestra de 200 · cada celda = parecido entre dos lesiones

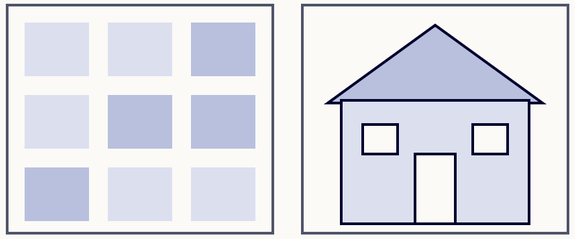

demasiado zoom: todo queda igual de lejos

esquema ilustrativo

Si todas las lesiones están igual de lejos, el parecido no distingue clases: concentración.

Los kernels cuánticos no separan mejor las clases

Alineamiento kernel-objetivo explicado por las etiquetas

¿el parecido entre lesiones coincide con el diagnóstico?

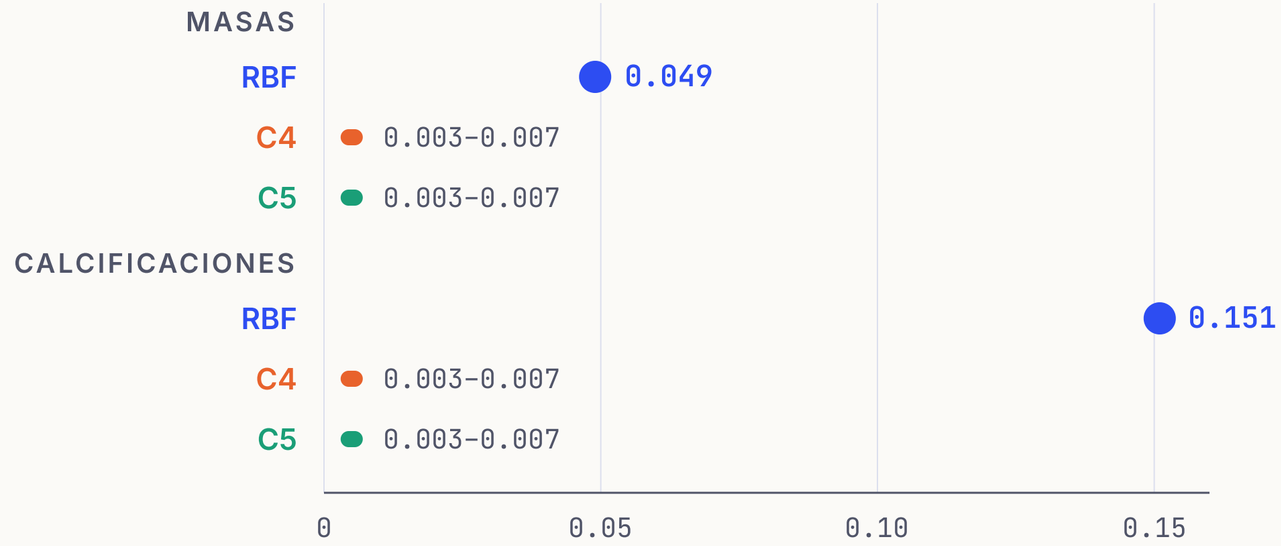

Diferencia geométrica

$$g = 1.40 - 1.70$$

umbral de ventaja potencial: $\sqrt{N} \approx 14.1$

¿el mapa cuántico tiene caminos que el clásico no puede trazar?

03 · RESULTADOS · ❶ Separabilidad

Las representaciones que recibe el clasificador tampoco separan mejor

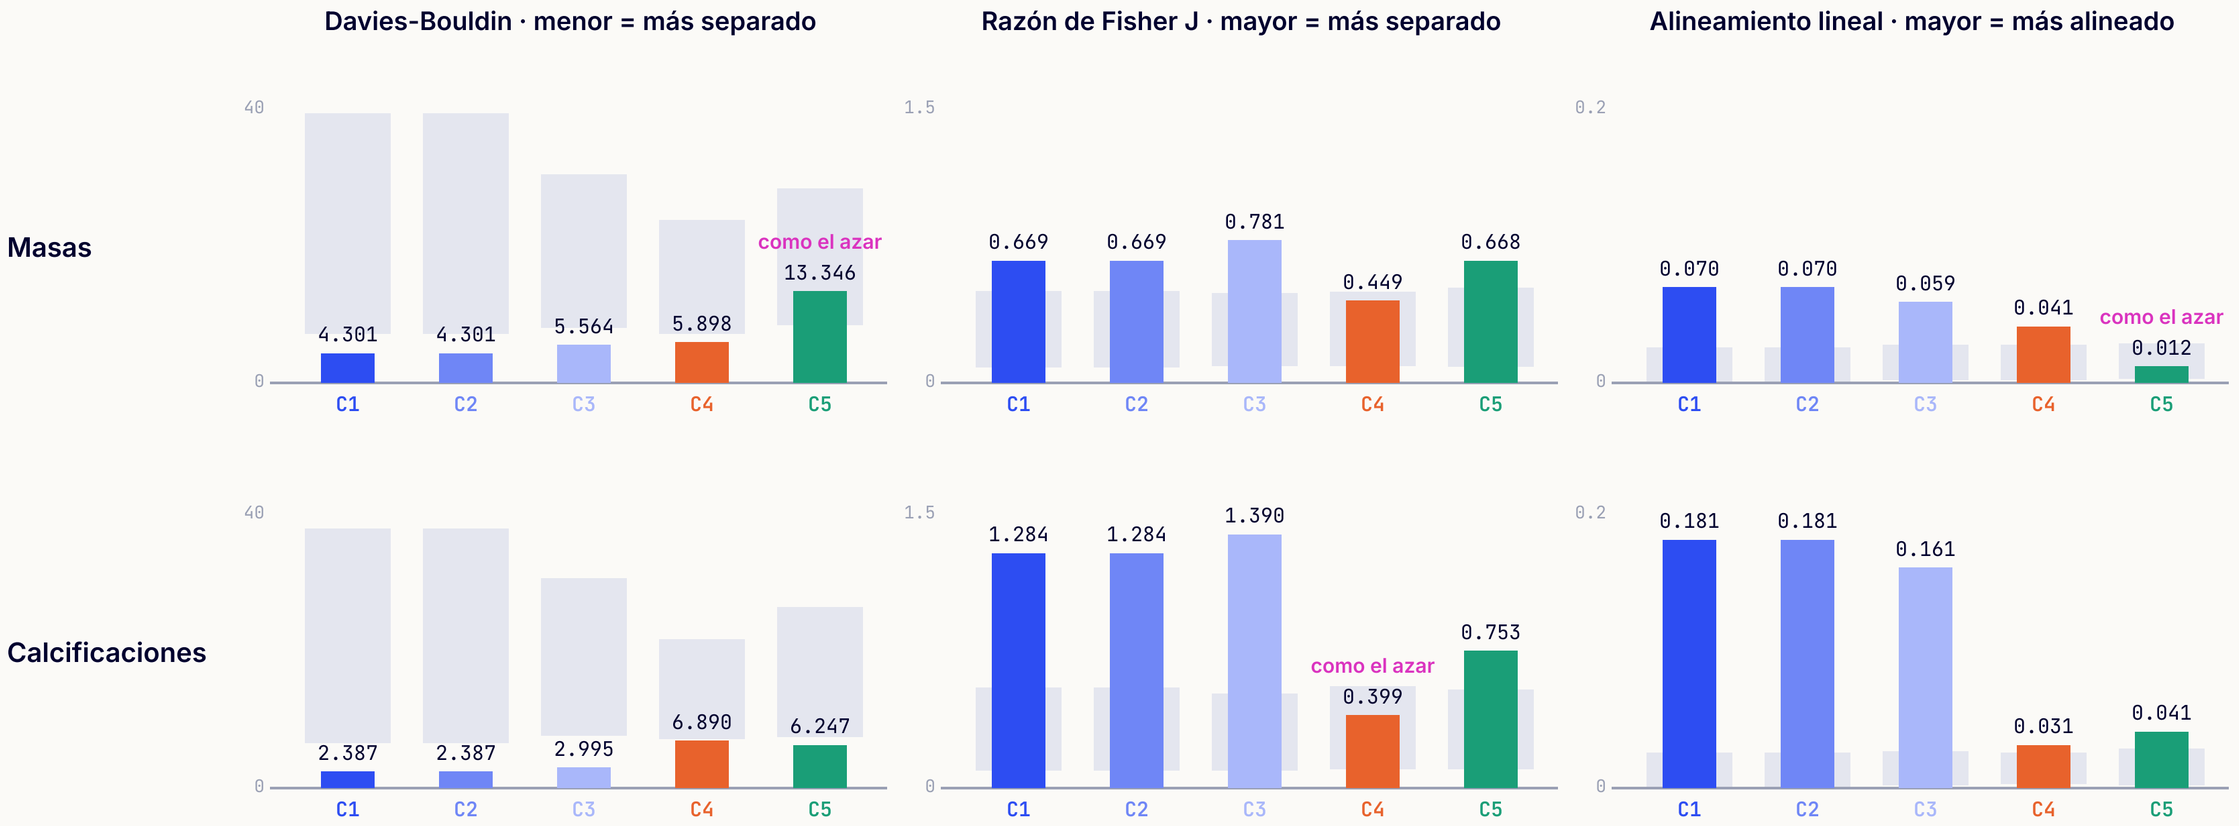

Franja gris = banda del 95 % con etiquetas permutadas (1,000 permutaciones)

Fig. 6.2.4 del reporte · 200 lesiones de entrenamiento por subconjunto

03 · RESULTADOS · ❶ Separabilidad

Las mismas representaciones vistas en dos dimensiones (t-SNE)

Fig. 6.2.5 del reporte · 200 lesiones de entrenamiento por subconjunto

Cómo se lee una curva ROC: un umbral recorre todas las puntuaciones

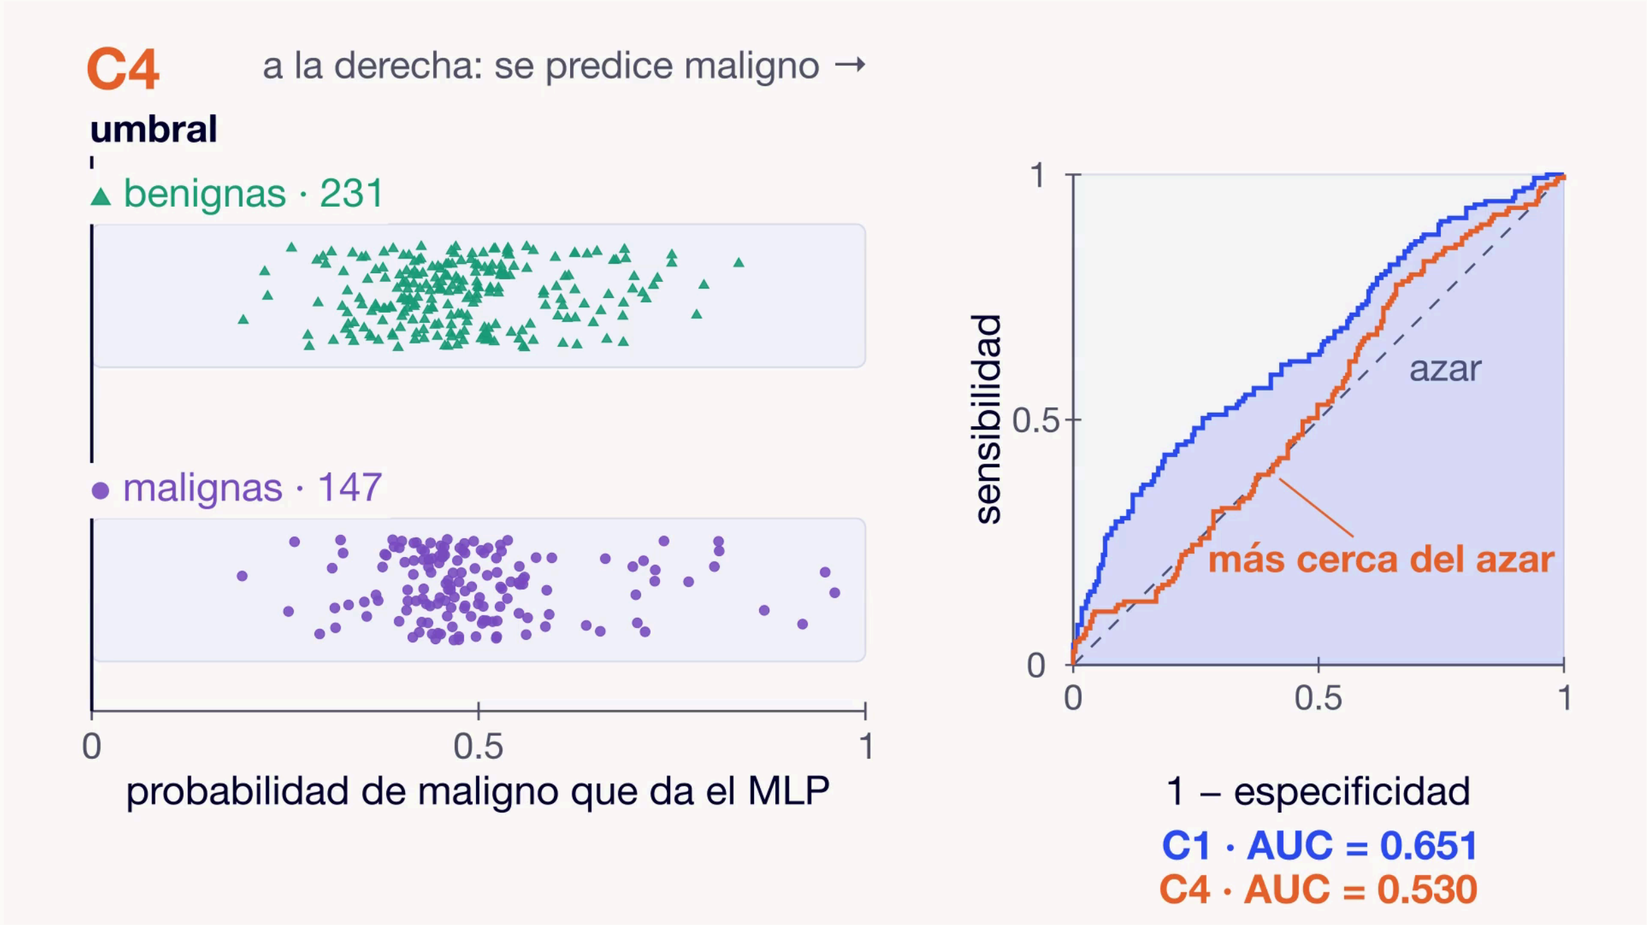

Predicciones reales del MLP · 378 masas de prueba, 147 malignas

03 · RESULTADOS ❷ Clasificación

El mismo MLP clasifica peor sobre los embeddings cuánticos

-0.07 a -0.14 de AUC frente a C1

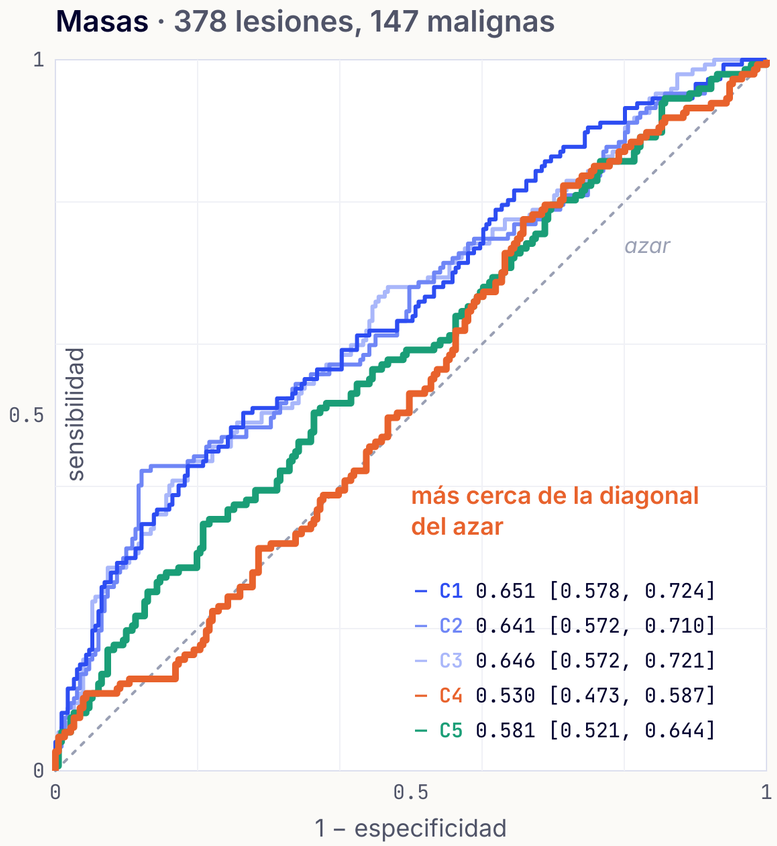

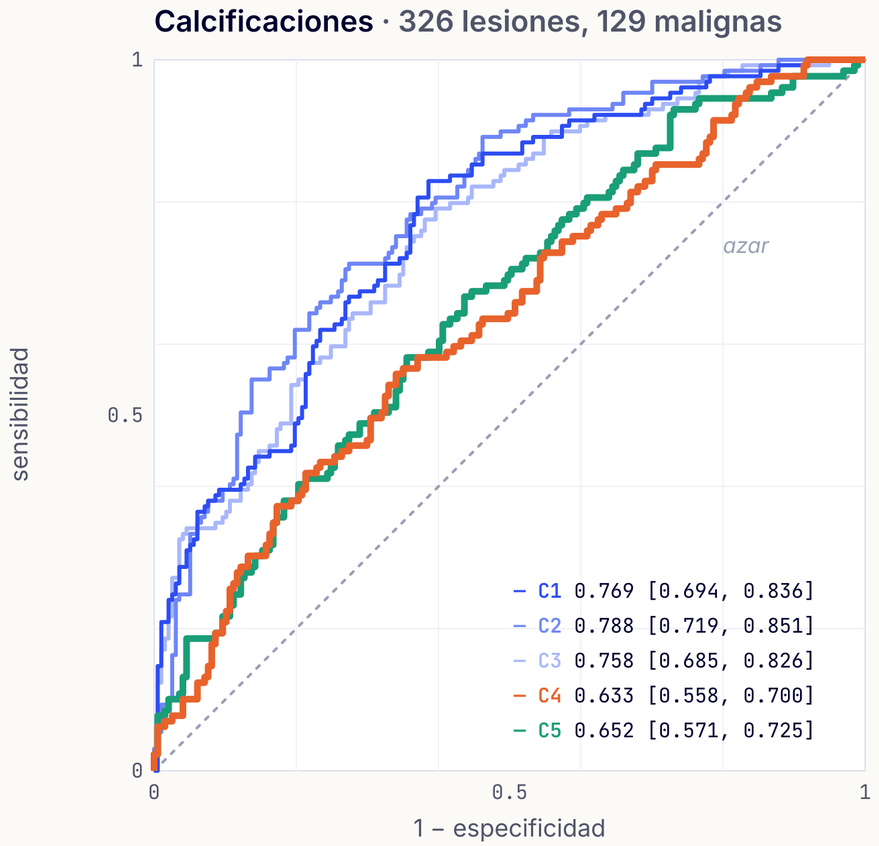

Fig. 6.3.2 del reporte · conjunto de prueba oficial, usado una vez

Con árboles, bosques y *boosting*, ninguna representación cuántica supera a C1

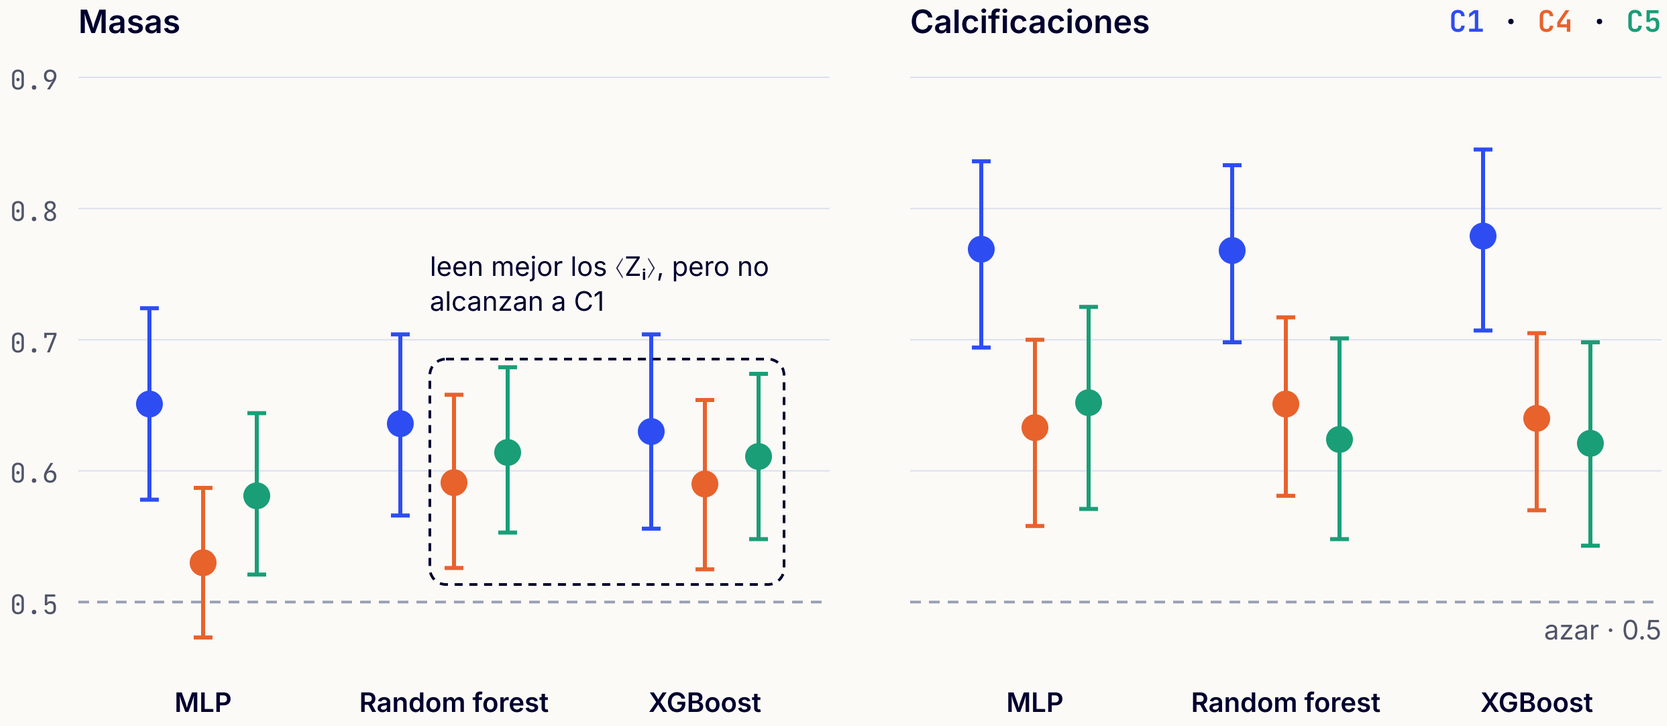

AUC-ROC en prueba · IC 95 %

0 de 24

comparaciones a favor de C4/C5

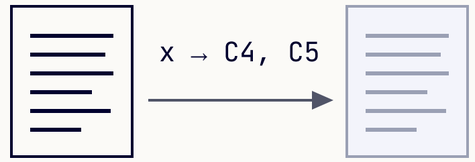

C4 y C5 se calculan a partir de x: no contienen más información que x

esquema ilustrativo

La pérdida está en la lectura de 12 números, no en la codificación

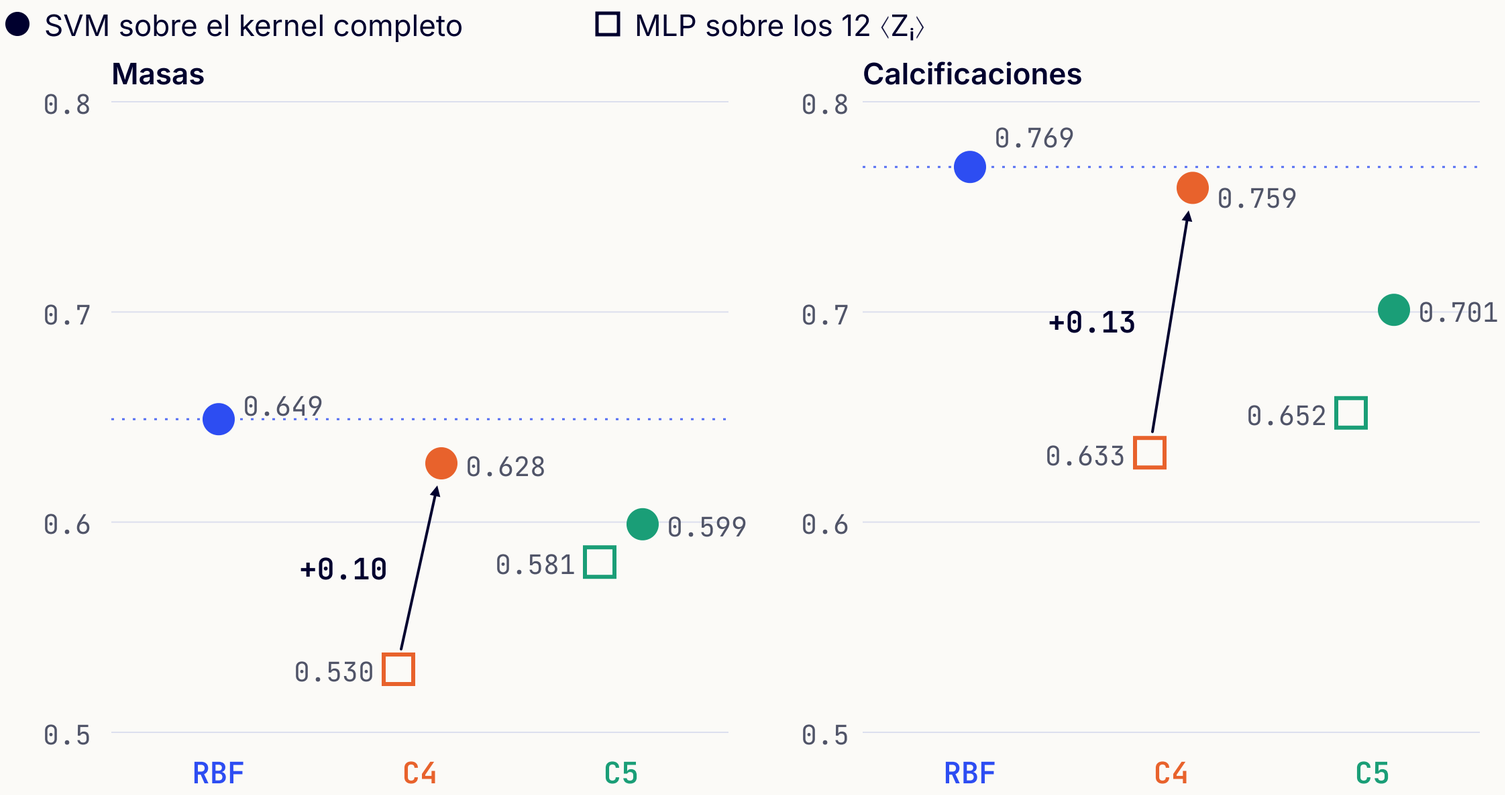

AUC-ROC en prueba · línea punteada azul = nivel de la SVM con RBF

Leído a través de su kernel, el estado cuántico iguala al clasificador clásico; resumido en 12 valores esperados, pierde información.

esquema ilustrativo

Análisis exploratorio

03 · RESULTADOS ❶ Separabilidad ❷ Clasificación

Resumen: lo clásico va delante en separabilidad y en clasificación; el QSVM solo empata

	Exceso de KTA ↑	*g*	Davies-Bouldin ↓	Fisher J ↑	AUC en prueba
C1 · sin transformar	–	–	**4.301 / 2.387**	0.669 / 1.284	**0.651** / 0.769
C2 · PCA (control nulo)	–	–	**4.301 / 2.387**	0.669 / 1.284	0.641 / **0.788**
C3 · Kernel PCA RBF	**0.049 / 0.151**	–	5.564 / 2.995	**0.781 / 1.390**	0.646 / 0.758
C4 · ZZ	0.003 / 0.006	1.433 / 1.400	5.898 / 6.890	0.449 / 0.399	0.530 / 0.633
C5 · Y + ZZ	0.005 / 0.007	1.511 / 1.701	13.346 / 6.247	0.668 / 0.753	0.581 / 0.652
SVM sobre el kernel RBF					0.649 / 0.769
QSVM sobre el kernel de C4					0.628 / 0.759

el QSVM empata con el SVM clásico: la información está en el estado, se pierde al leer 12 números

Exceso de KTA de C3 = kernel RBF. *g* muy por debajo de √N ≈ 14.1. AUC de C1–C5 con el mismo MLP; SVM y QSVM del experimento X4.

Cuadro 23 del reporte (versión completa en el Anexo 27) · cada celda: masas / calcificaciones

La ventaja cuántica sí existe: Huang et al. la construyeron y aquí se reproduce

Huang et al. (2021): con etiquetas diseñadas, el kernel cuántico supera a todos los clásicos

Nature Communications 12, 2631

¿Por qué no se usa siempre?

las etiquetas no se eligen

diseñadas = ventaja asegurada

0.566 vs 0.677

con etiquetas reales, pierde

Mismas lesiones y mismas 12 características, etiquetas diseñadas

AUC-ROC (validación cruzada)

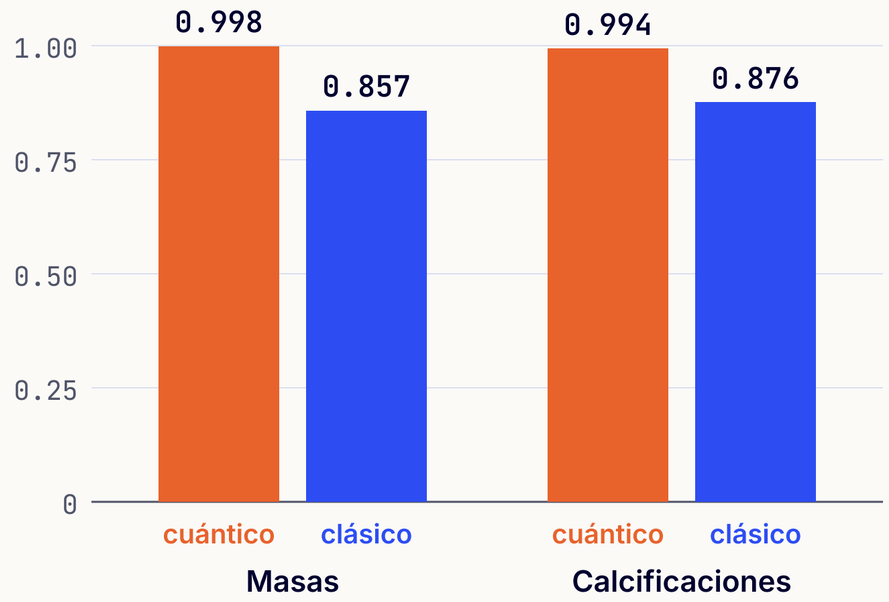

La pregunta deja de ser si la ventaja existe y pasa a ser si el diagnóstico es una de esas tareas.

La ventaja cuántica aparece cuando la tarea sigue la geometría del circuito; el diagnóstico no la sigue

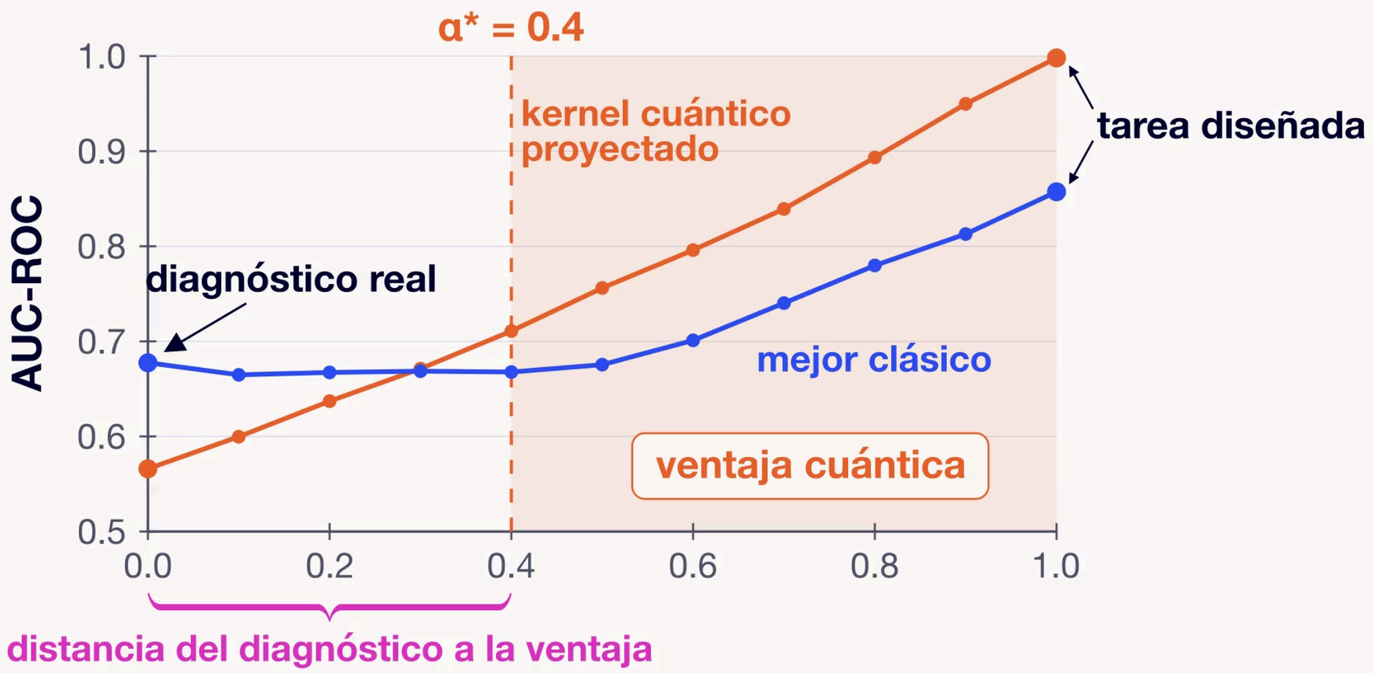

α = cuántas preguntas salen del libro del circuito

esquema ilustrativo

Etiquetas intermedias artificiales: instrumento de medida, no tarea clínica

Simular cabe; medir en hardware sería el problema

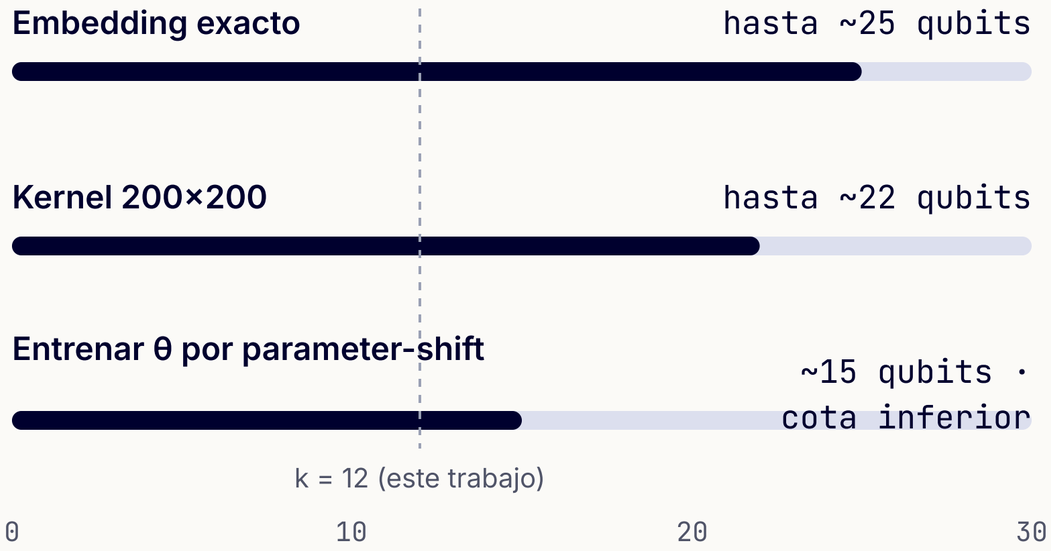

Qubits que caben en 24 h · Apple M3, 16 GiB

Los $\langle Z_i \rangle$ sí toleran 1,024 disparos: el MLP queda a menos de 0.02 del AUC exacto

05 · CONCLUSIONES

Los seis objetivos se cumplieron

> ❶ La codificación cuántica no aumentó la separabilidad; la redujo, ❷ y la diferencia se nota al clasificar.

Objetivo	Estado	Evidencia
General: efecto de la codificación cuántica en la separabilidad y la clasificación	✓ Cumplido	Sin mayor separabilidad; −0.07 a −0.14 de AUC con el mismo MLP
OE-1 · Pipeline de datos sobre CBIS-DDSM	✓ Cumplido	3,568 lesiones, 100 % DICOM; 67 → 12 características; sin fuga entre pacientes
OE-2 · Cinco representaciones del mismo vector	✓ Cumplido	C1–C5 con k = 12; θ fijo con semilla 42
OE-3 · Separabilidad con cuatro métricas	✓ Cumplido	Exceso de KTA 0.003–0.007 frente a 0.049/0.151 del RBF; g = 1.40–1.70 ≪ √N ≈ 14.1
OE-4 · El mismo MLP en las cinco condiciones	✓ Cumplido	12 → 32 → 16 → 1; validación cruzada de 5 folds por paciente
OE-5 · ¿La separabilidad se refleja al clasificar?	✓ Cumplido	Mismo orden en ambos (ρ = 0.67–0.97): C1–C3 delante de C4–C5
OE-6 · Viabilidad práctica	✓ Cumplido	Simulación viable hasta ~25 qubits; en hardware, del 16 al 74 % de los valores del kernel se leerían 0

Un resultado negativo, medido con rigor, es evidencia de viabilidad

Lo que sigue: de cada limitación, una línea de trabajo

	Lo que se observó	Línea de trabajo futuro
Codificación	El kernel se concentra a c = 1	**Codificaciones sin concentración**: ancho de banda por característica y conocimiento del problema
Lectura	12 valores esperados pierden información	**Lecturas intermedias**: correlaciones $\langle Z_i Z_j \rangle$ (66 valores) y lectores más profundos
Hardware	Todo fue simulación sin ruido	**Procesadores reales**: primero simular con el ruido de un dispositivo, luego medir en uno
Datos	Un solo conjunto, sin escala física	**Mamografía digital con escala conocida** y validación externa

Gracias

Miguel Alexander Sánchez García

DIRECTORES

Dr. Jesús Yaljá Montiel Pérez

Dra. Ana María Winfield Reyes

ANEXOS

Índice de respuestas

PREGUNTA Y RESPUESTA

1 · ¿Qué hicieron los trabajos previos?

10 · ¿Cuál es la pregunta completa?

24 · ¿Cuál es la respuesta?

PREGUNTAS DIFÍCILES

45 · ¿Vale un resultado negativo?

46 · ¿Por qué no una CNN?

47 · ¿Las intensidades no calibradas meten el efecto del digitalizador?

48 · ¿Cuánto se pierde al quedarse con 12 de 67 características?

49 · ¿El resultado se generaliza?

50 · ¿Cuándo valdría la pena el hardware?

FUNDAMENTOS

2 · ¿Qué es un qubit?

3 · ¿Qué es el entrelazamiento?

4 · ¿Qué hace un feature map?

5 · ¿Qué es un kernel y cómo separa una SVM?

6 · ¿Qué significa medir un qubit?

8 · ¿Qué mide el AUC-ROC?

9 · ¿Qué son las 67 características radiómicas?

DISEÑO

7 · ¿Por qué solo simulación sin ruido?

11 · ¿Por qué θ fijo?

12 · ¿Y si se entrenaba θ?

13 · ¿Cuáles son las tres arquitecturas?

14 · ¿Qué modelos se compararon y dónde?

15 · ¿Por qué 12 qubits? ¿Y con 8?

16 · ¿Por qué una sola repetición del circuito?

17 · ¿Por qué ángulos en [0, π] por cuantiles?

18 · ¿En qué se diferencian C4 y C5?

19 · ¿Para qué sirve C2?

20 · ¿Por qué 200 lesiones para la separabilidad?

21 · ¿Por qué 5 folds?

DATOS

22 · ¿Qué se corrigió en las máscaras?

23 · ¿Hay pacientes a la vez en entrenamiento y prueba?

35 · ¿Por qué las masas separan menos con radiómica?

RESULTADOS

25 · ¿Y las demás métricas de clasificación?

26 · ¿Con qué intervalos de confianza?

27 · ¿Dónde está el resumen completo (Cuadro 23)?

28 · ¿Son significativas las métricas de separabilidad?

29 · ¿Qué muestra el t-SNE?

30 · ¿Un QSVM lo haría mejor?

31 · ¿Se buscó la ventaja de forma justa?

32 · ¿La conclusión resiste cambios en θ, k y la muestra?

33 · ¿Separabilidad y clasificación ordenan igual?

34 · ¿Y si se reduce la escala de los ángulos?

36 · ¿Qué métricas de separabilidad se usaron?

37 · ¿Desde qué α aparece la ventaja?

FÓRMULAS

38 · La codificación

39 · Las dos lecturas

40 · Separabilidad: alineamiento, Fisher y Davies-Bouldin

41 · La diferencia geométrica y su cota

42 · Medición, disparos y parameter-shift

43 · Pérdida, AUC y Spearman

44 · Los kernels clásicos de referencia

ANEXOS

Índice de figuras

MARCO TEÓRICO

51 · Figura 3.4.1 · Geometría de los kernels clásico y cuántico

DATOS Y DISEÑO

52 · Figura 4.3.1 · Forma y margen de las masas por patología
53 · Figura 4.3.2 · Tipo y distribución de las calcificaciones por patología
54 · Figura 5.6.1 · Costo del número de folds
55 · Figura 5.7.1 · Circuitos de C4 y C5 dibujados para k = 4

RESULTADOS

56 · Figura 6.1.1 · Tamaños de efecto de las 67 características
57 · Figura 6.1.2 · Efecto de CLAHE en la capacidad discriminativa
58 · Figura 6.1.3 · Selección y escalado angular por cuantiles
59 · Figura 6.1.4 · AUC en función del número de características k
60 · Figura 6.2.1 · Concentración de los kernels cuánticos
61 · Figura 6.2.2 · Alineamiento y dimensión efectiva de los kernels
62 · Figura 6.2.3 · Diferencia geométrica g frente a √N
63 · Figura 6.2.4 · Davies-Bouldin, Fisher y alineamiento lineal
64 · Figura 6.2.5 · t-SNE de las cinco representaciones
65 · Figura 6.2.6 · Métricas en 20 submuestras y en todo el entrenamiento
66 · Figura 6.2.7 · AUC de pares contra la escala angular c
67 · Figura 6.2.8 · Separabilidad con 12 y con 8 qubits
68 · Figura 6.3.1 · AUC en validación cruzada y en prueba
69 · Figura 6.3.2 · Curvas ROC en el conjunto de prueba
70 · Figura 6.3.3 · Sensibilidad del MLP: semilla, red, escalado, reps y k
71 · Figura 6.3.4 · Diez sorteos de θ
72 · Figura 6.3.5 · θ entrenado frente a θ fijo
73 · Figura 6.3.6 · Árboles, random forest y XGBoost sobre C1–C5
74 · Figura 6.3.7 · Criterios de parada de un árbol
75 · Figura 6.4.1 · QSVM, SVM RBF y MLP sobre $\langle Z_i \rangle$
76 · Figura 6.4.2 · Las 67 características con codificaciones alternativas
77 · Figura 6.4.3 · Búsqueda anidada de ventaja cuántica
78 · Figura 6.4.4 · Etiquetado diseñado según Huang et al.
79 · Figura 6.4.5 · Transición hacia las etiquetas diseñadas (X11)
80 · Figura 6.5.1 · Correlación de Spearman entre separabilidad y clasificación
81 · Figura 6.5.2 · Separabilidad frente a AUC, clásico y cuántico
82 · Figura 6.6.1 · Escalabilidad del simulador con el número de qubits
83 · Figura 6.6.2 · Efecto del número de disparos

APÉNDICE C

84 · Figura C.1.1 · Alineación de las 80 máscaras desajustadas
85 · Figura C.1.2 · Etapas del preprocesamiento
86 · Figura C.4.1 · Valores del kernel dentro y entre clases

ANEXOS

Índice de tablas

MARCO Y DISEÑO

87 · Cuadro 1 · Estado del arte
88 · Cuadro 2 · Tres formas de leer el estado
89 · Cuadro 3 · Composición del CBIS-DDSM
90 · Cuadro 4 · Del EDA a las decisiones de diseño
91 · Cuadro 5 · Clasificadores del trabajo
92 · Cuadro 9 · Las cinco condiciones (M5)
93 · Cuadro 10 · Diseño de los experimentos X1 a X11

RESULTADOS

94 · Cuadro 11 · Las 12 características seleccionadas (M4)
95 · Cuadro 12 · Separabilidad de los kernels (M6)
96 · Cuadro 13 · Separabilidad de los embeddings (M6)
97 · Cuadro 14 · Separabilidad con k = 12 y k = 8
98 · Cuadro 15 · Clasificación con el mismo MLP (M7)
99 · Cuadro 16 · Diferencias pareadas de AUC (M7)
100 · Cuadro 17 · Diez sorteos de θ
101 · Cuadro 18 · θ entrenado frente a θ fijo
102 · Cuadro 19 · Árboles y MLP sobre C1–C5 (X10)
103 · Cuadro 20 · Tres lecturas del mapa ZZ
104 · Cuadro 21 · De las etiquetas reales a las diseñadas (X11)
105 · Cuadro 22 · Spearman entre separabilidad y clasificación (M8)
106 · Cuadro 23 · Resumen de resultados por condición
107 · Cuadro 24 · Mapa de las comparaciones
108 · Cuadro 25 · Evidencia por objetivo específico

APÉNDICES

109 · Cuadro 26 · Preprocesamiento y control de calidad (M2)
110 · Cuadro 27 · Características seleccionadas, conjunto completo (M4)
111 · Cuadro 28 · Características descartadas por redundancia (M4)
112 · Cuadro 29 · Balance por fold (M4)
113 · Cuadro 30 · Coste de los kernels cuánticos (M5)
114 · Cuadro 31 · Escalamiento con el número de qubits (OE-6)
115 · Cuadro 32 · Coste de los gradientes (X8)
116 · Cuadro 33 · Verificaciones automáticas
117 · Cuadro 34 · Auditoría independiente (X5)

ADMINISTRATIVOS

118 · Cuadro 6 · Requerimientos funcionales
119 · Cuadro 7 · Requerimientos no funcionales
120 · Cuadro 8 · Fases CRISP-DM y módulos
121 · Cuadro 35 · Versiones de los paquetes
122 · Cuadro 36 · Índice de decisiones de la bitácora

ANEXO 1

Estado del arte: la tabla completa

Trabajo	Datos	Cuántico	CBIS-DDSM	Separab.	Masas/calcs.	Desempeño	P1	P2	P3	P4
Profundo · mamografía										
Shen et al. (2019)	CBIS-DDSM	×	✓	×	×	AUC 0.91	—	—	—	—
Wang et al. (2020)	DDSM, INbreast, MIAS, UKy	×	Parcial	×	×	AUC 0.88–0.95; externos 0.44–0.65	—	—	—	—
Baccouche et al. (2022)	CBIS-DDSM, INbreast	×	✓	×	×	Exactitud 0.95	—	—	—	—
Cuántico · otros datos										
Xiang et al. (2024)	tabulares (GBSG, SEER, WDBC)	✓ sim.	×	×	—	Exactitud 0.70–0.96	Parcial	No	No	No
Toufah et al. (2025)	cáncer de pulmón (tabular)	✓ sim.	×	×	—	Exactitud 0.91–0.96 (RBF 0.95)	Sí	No	ND	No
Parigi et al. (2026)	MNIST, F-MNIST	✓ sim.	×	✓	—	Exactitud 0.94–0.99	Sí	Sí	Sí	No
Cuántico · mamografía										
Azevedo et al. (2022)	BCDR	✓ sim. y hardware	×	×	×	AUC 0.77 (clásico 0.58)	Parcial	No	No	No
Este trabajo	CBIS-DDSM	✓ sim.	✓	✓	✓	AUC masas 0.53/0.58 (C1 0.65); calcs. 0.63/0.65 (C1 0.77)	Sí	Sí	Sí	No

P1 paridad: el clásico recibe los mismos datos y ajuste · P2 incertidumbre reportada · P3 conjunto de prueba usado una vez · P4 circuito difícil de simular · ND: el trabajo no lo dice

Un qubit puede estar en una mezcla de 0 y 1

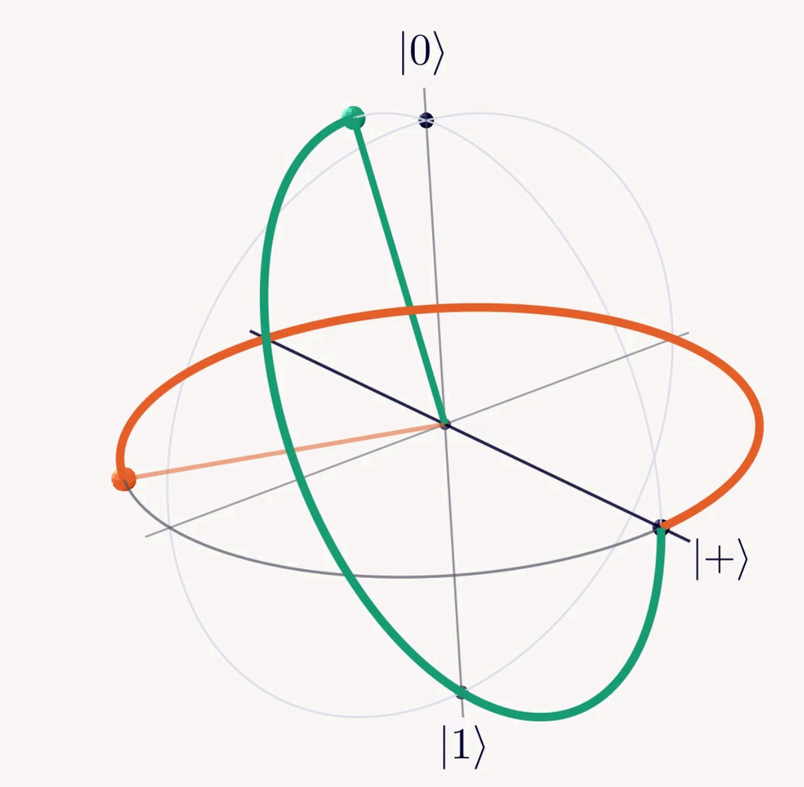

$$|\psi\rangle = \cos\frac{\theta}{2}|0\rangle + e^{i\varphi}\sin\frac{\theta}{2}|1\rangle$$

Entrelazar es acoplar los qubits: el todo no se describe por partes

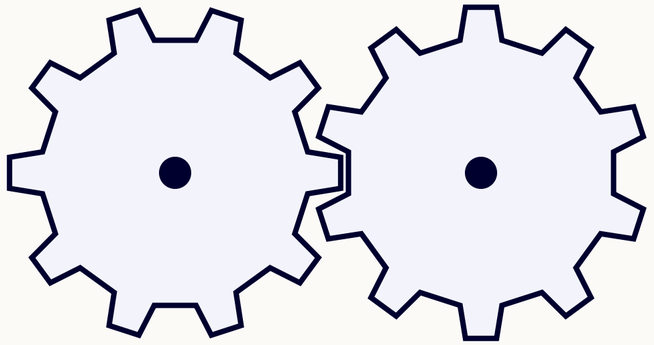

$12 \text{ qubits} \rightarrow 2^{12} = 4{,}096 \text{ dimensiones}$

esquema ilustrativo

ANEXO 4

Un *feature map* convierte un vector de números en un estado cuántico

ANEXO 5

Un kernel mide el parecido entre dos lesiones; una SVM separa con ese parecido

k = parecido

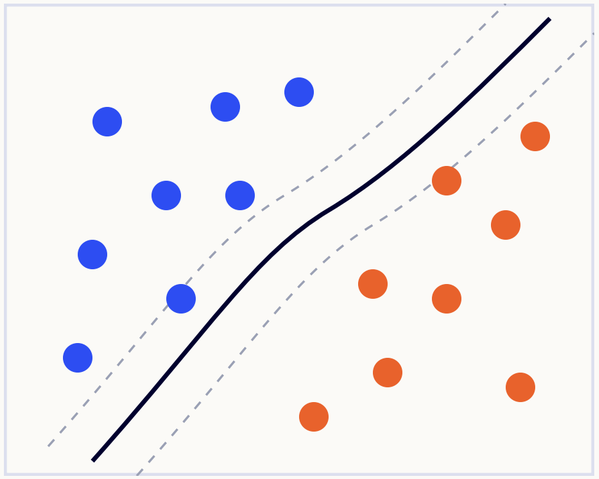

SVM: frontera

esquema ilustrativo

ANEXO 6

Medir un qubit es como hacer una encuesta

$$\mathrm{Var}(\hat{Z}_i) = \frac{1 - \langle Z_i \rangle^2}{n_{\mathrm{shots}}}$$

ANEXO 7

Todo se hizo en simulación exacta, a propósito

Simulador

exacto, sin ruido

Hardware

ruido y disparos

AUC-ROC: 0.5 es azar, 1 es perfecto

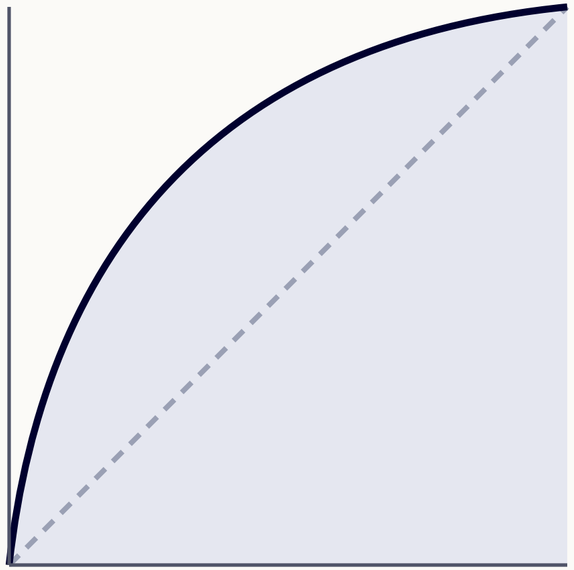

horizontal: FPR · vertical: TPR · punteada: azar

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}\, d\,\mathrm{FPR}$$

esquema ilustrativo

ANEXO 9

67 características radiómicas de forma, intensidad y textura

forma 2D	primer orden (intensidad)	GLCM (textura)	GLRLM (textura)

Las 12 elegidas en masas

- `Maximum`
- `MinorAxisLength`
- `MeshSurface`
- `10Percentile`
- `90Percentile`
- `MaximumDiameter`
- `PerimeterSurfaceRatio`
- `Correlation (GLCM)`
- `Energy`
- `Perimeter`
- `GrayLevelNonUniformity (GLRLM)`
- `RunLengthNonUniformity (GLRLM)`

ANEXO 10

La pregunta de investigación completa

> ¿En qué medida las transformaciones cuánticas variacionales implementadas mediante ZZFeatureMap y PauliFeatureMap en Qiskit modifican la separabilidad de clases benigno/maligno de características radiómicas extraídas de mamografías del CBIS-DDSM, y hasta qué punto esa diferencia se refleja en la capacidad de clasificación de una misma red neuronal clásica, en comparación con representaciones clásicas construidas a partir del mismo vector de características?

ANEXO 11

θ se fijó por tres razones: justicia, pregunta y costo

Justicia

C2 y C3 no ven las etiquetas; un θ entrenado sí. La comparación dejaría de ser pareja.

Pregunta

Se mide el efecto de la codificación, no de un modelo entrenado.

Costo

Entrenar θ por *parameter-shift* costaba 22.4 h a k = 8 y 2,689 h a k = 16, por condición.

ANEXO 12

¿Y si se entrenaba θ? Como mucho igualaría a lo clásico; en la práctica, ni eso

AUC en prueba

	θ fijo	θ entrenado	Entrenado - C1
Masas, C4	0.530	0.533	-0.118
Masas, C5	0.581	0.585	-0.066
Calcif., C4	0.633	0.674	-0.094
Calcif., C5	0.652	0.671	-0.098

C4 y C5 se calculan a partir de x: no pueden saber más que x

ANEXO 13

Las tres arquitecturas del trabajo

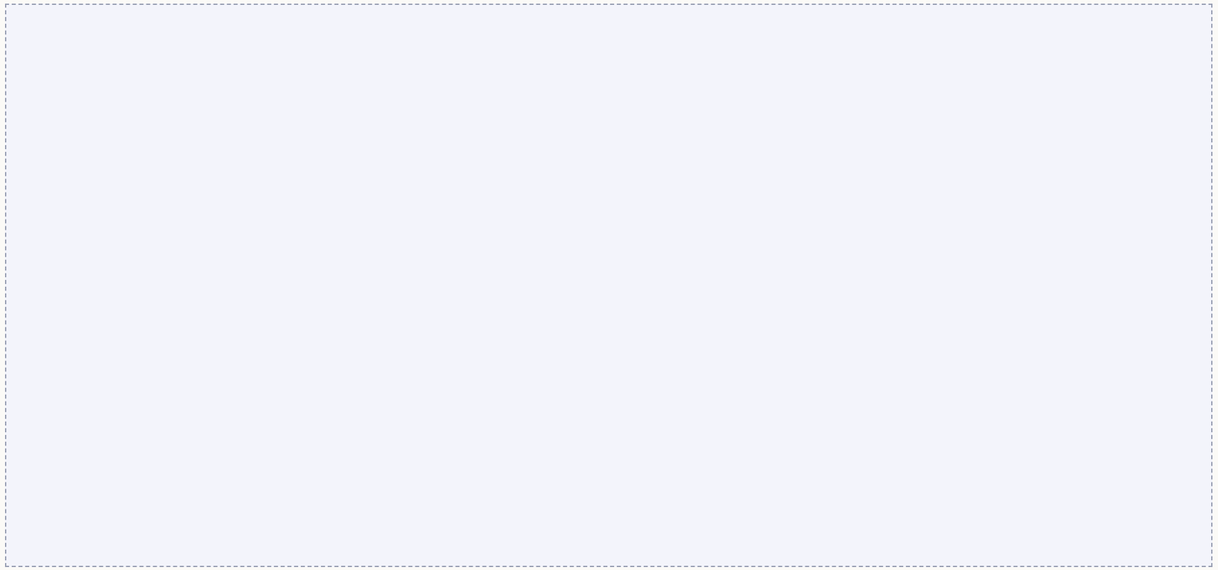

H · P(2x_i) · ZZ · real_amplitudes (reps = 1, 24 parámetros)

MLP

12 → 32 → 16 → 1

QSVM

kernel cuántico → SVM

ANEXO 14

Qué modelos se compararon y dónde

Modelo	Sobre	Dónde
MLP 12-32-16-1	C1–C5	M7 (principal), X7, X8, X10
SVM clásica (lineal, polinomial, RBF)	x	X4, X6, X11
QSVM (kernel de C4/C5, ZZ lineal, proyectado)	kernel cuántico	X4, X6, X11
Árbol de decisión, random forest, XGBoost	C1–C5	X10
Regresión logística	67 o 12 características, descriptores del radiólogo	X1, M8

12 qubits por costo y por diversidad de características; con 8, la conclusión es la misma

$$k = 12$$

k = 8: misma conclusión

Una repetición del circuito; con dos, C4 y C5 siguen por debajo

reps = 1

reps = 2: C4 y C5 siguen por debajo

Ángulos en [0, π] por cuantiles

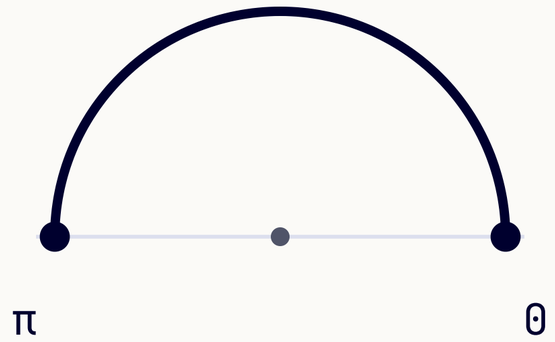

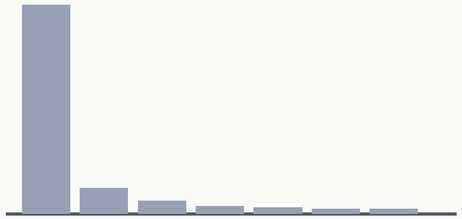

min-max: casi constante

cuantiles: uniforme

esquema ilustrativo

ANEXO 18

C4 y C5 comparten el entrelazamiento ZZ; difieren en el eje del giro de cada qubit

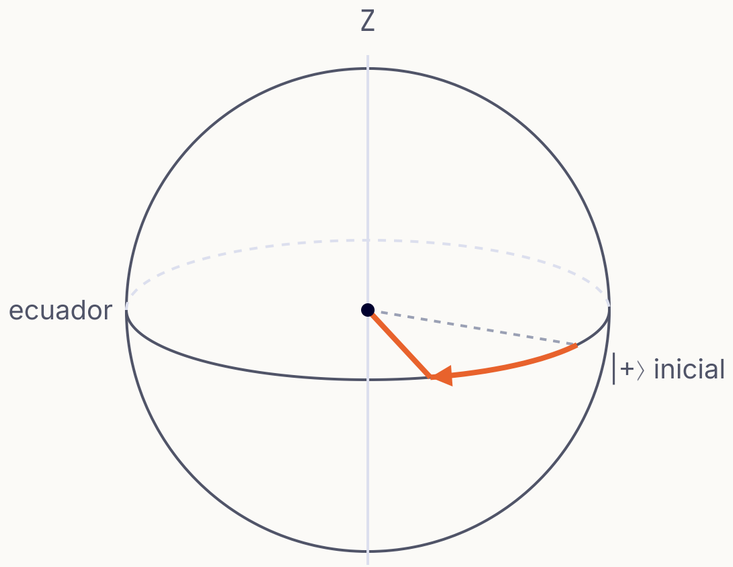

C4 · giro $P(2x_i)$ en Z

permanece en el ecuador

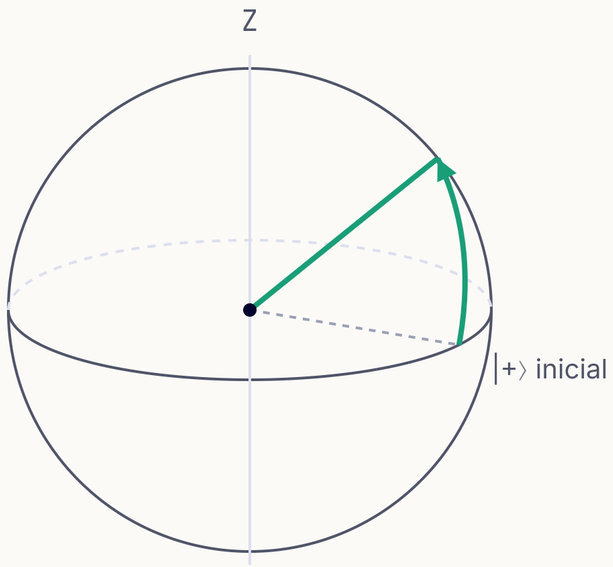

C5 · giro $RY(2x_i)$ en Y

sale del ecuador

Mismo bloque ZZ entre pares y mismo ansatz. Solo cambia el eje del giro por característica.

esquema ilustrativo

(Z, ZZ) es el mismo circuito que ZZ · (X, ZZ) no codifica nada con una repetición

ANEXO 19

C2 es un control nulo: rotar no cambia la información

girar no cambia la información

esquema ilustrativo

ANEXO 20

Separabilidad sobre 200 lesiones: el tamaño repetible en hardware

200 lesiones	→ 19,900 circuitos por matriz
todo el entrenamiento	→ 0.87–1.19 millones

ANEXO 21

¿Por qué 5 folds? Es el mayor número que mantiene equilibradas las clases

Folds	Entrena con	Desviación máx. de la proporción de malignas (masas / calc.)	Malignas en el fold más pobre (masas / calc.)	Peso del paciente más grande (calc.)
3	67 %	0.003 / 0.003	200 / 167	5 %
5	80 %	0.011 / 0.019	122 / 96	9 %
10	90 %	0.044 / 0.045	57 / 49	17 %

C4 − C1 y C5 − C1 en validación cruzada, con 5 y con 3 folds

	C4−C1 (5)	C4−C1 (3)	C5−C1 (5)	C5−C1 (3)
Masas	−0.087	−0.123	−0.089	−0.098
Calcificaciones	−0.102	−0.119	−0.075	−0.092

Con 3 folds la conclusión no cambia

ANEXO 22

Se corrigieron 80 máscaras y se conservó la escala original de cada lesión

80

máscaras desalineadas

78 masas escaladas ×0.870 y 2 calcificaciones desplazadas

1

componente conexa

se conserva la mayor de cada máscara

1:1

resolución original

sin CLAHE ni 224×224: destruyen las medidas de tamaño

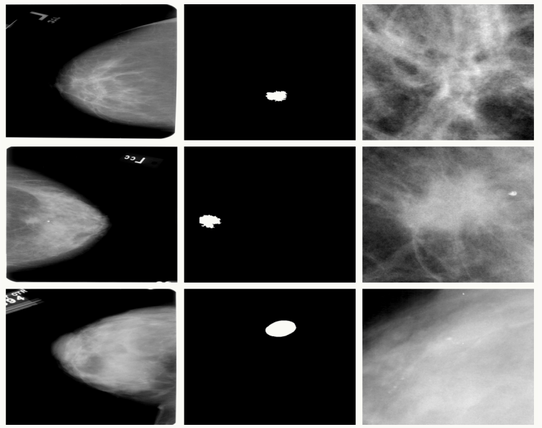

Completa · máscara · ROI recortada

ANEXO 23

Ningún paciente aparece a la vez en entrenamiento y en prueba

01

Particiones por paciente

StratifiedGroupKFold, 5 particiones, estratificadas por clase

02

Pérdida ponderada

entropía cruzada binaria ponderada por el desbalance de clases

03

Parada temprana

sobre el 15 % de los pacientes de entrenamiento

04

Prueba una sola vez

704 lesiones, evaluadas al final del estudio

ANEXO 24

Respuesta: la codificación cuántica no aumentó la separabilidad; la redujo

1. C4 y C5 separan peor que C1–C3 en todas las métricas
2. Se nota al clasificar: −0.07 a −0.14 de AUC; 0 de 24 a favor
3. Causa: concentración y lectura de 12 números
4. La ventaja existe con etiquetas diseñadas; el diagnóstico está en α = 0
5. Viable en simulación; en hardware, el kernel sería inmedible

> *Un resultado negativo, medido con rigor, es evidencia de viabilidad.*

ANEXO 25

Todas las métricas de clasificación, en prueba

	AUC	F1	Exactitud	Precisión	Sensibilidad
Masas C1	0.651	0.519	0.638	0.536	0.503
Masas C2	0.641	0.512	0.616	0.507	0.517
Masas C3	0.646	0.502	0.606	0.493	0.510
Masas C4	0.530	0.386	0.529	0.392	0.381
Masas C5	0.581	0.456	0.571	0.450	0.463
Calcif. C1	0.769	0.665	0.666	0.551	0.837
Calcif. C2	0.788	0.669	0.693	0.584	0.783
Calcif. C3	0.758	0.652	0.653	0.541	0.822
Calcif. C4	0.633	0.504	0.607	0.504	0.504
Calcif. C5	0.652	0.565	0.571	0.472	0.705

MLP del M7, umbral 0.5 · fuente: 8_tabla_clasificacion.csv

AUC en prueba con intervalos de confianza

-0.07 a -0.14 de AUC frente a C1

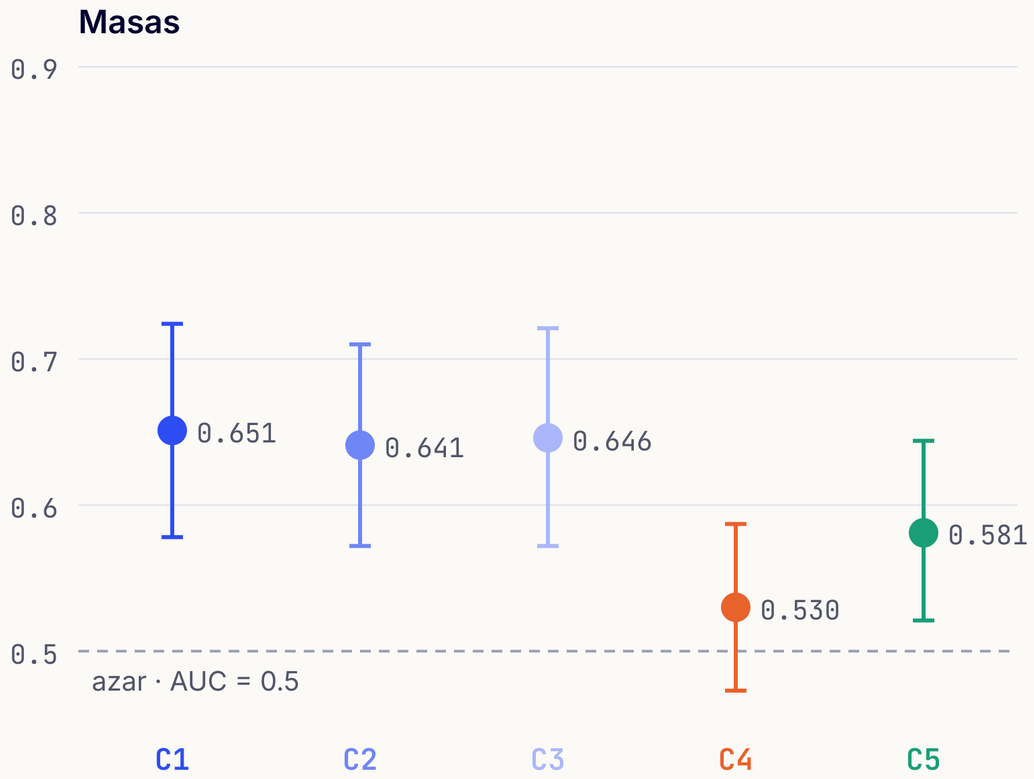

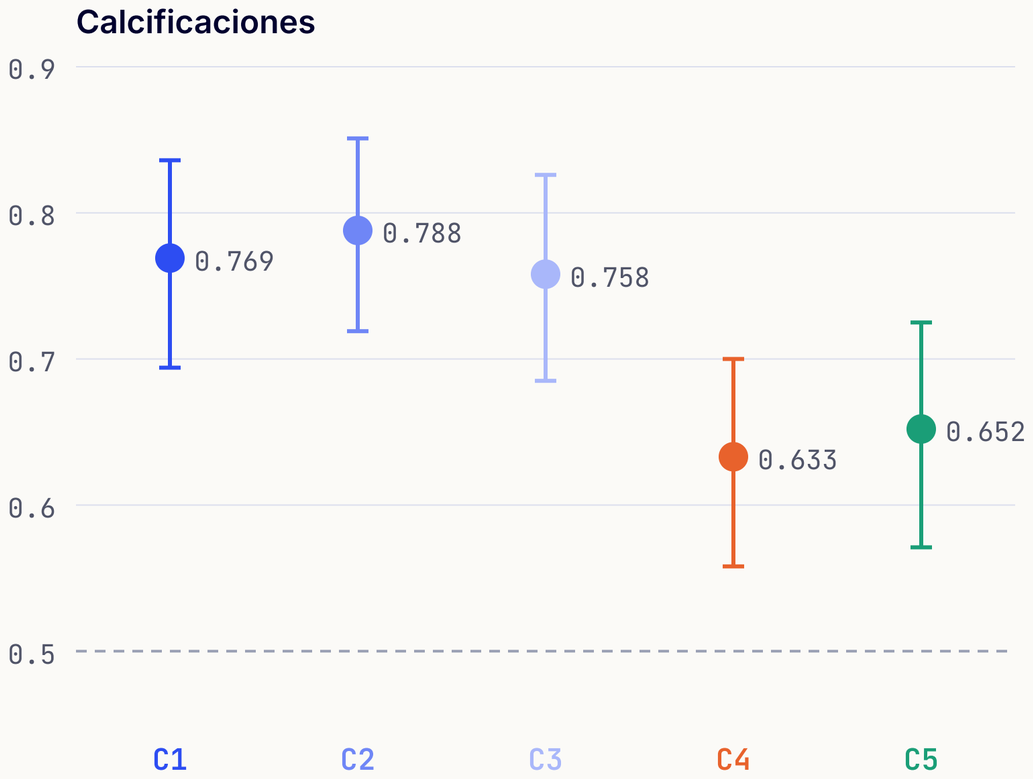

AUC-ROC en prueba · punto = estimación · barra = IC 95 % (bootstrap por paciente)

ANEXO 27

Resumen completo de resultados (Cuadro 23 del reporte)

	Exceso de KTA ↑	d_eff (de 200)	g	Davies-Bouldin ↓	Fisher J ↑	AUC en VC	AUC en prueba
C1 · sin transformar	—	—	—	4.301 / 2.387	0.669 / 1.284	0.652 / 0.742	0.651 / 0.769
C2 · PCA (control nulo)	—	—	—	4.301 / 2.387	0.669 / 1.284	0.641 / 0.758	0.641 / 0.788
C3 · Kernel PCA RBF	0.049 / 0.151	2.8 / 2.6	—	5.564 / 2.995	0.781 / 1.390	0.648 / 0.739	0.646 / 0.758
C4 · ZZ	0.003 / 0.006	184.0 / 187.7	1.433 / 1.400	5.898 / 6.890	0.449 / 0.399	0.565 / 0.640	0.530 / 0.633
C5 · Y + ZZ	0.005 / 0.007	171.3 / 167.6	1.511 / 1.701	13.346 / 6.247	0.668 / 0.753	0.563 / 0.667	0.581 / 0.652
SVM sobre el kernel RBF							0.649 / 0.769
QSVM sobre el kernel de C4							0.628 / 0.759
QSVM sobre el kernel de C5							0.599 / 0.701

Cada celda: masas / calcificaciones. Exceso de KTA de C3 = kernel RBF. g muy por debajo de $\sqrt{N} \approx 14.1$. d_eff: dimensión efectiva del kernel, de 200. AUC de C1–C5 con el mismo MLP; SVM y QSVM del experimento X4, en el conjunto de prueba.

ANEXO 28

Métricas de separabilidad con su significancia

	C1	C2	C3	C4	C5
Masas · Davies-Bouldin ↓	4.301 (p = 0.001)	4.301 (p = 0.001)	5.564 (p = 0.001)	5.898 (p = 0.002)	13.346 (p = 0.409)
Masas · Fisher J ↑	0.669 (p = 0.004)	0.669 (p = 0.004)	0.781 (p = 0.002)	0.449 (p = 0.050)	0.668 (p = 0.003)
Masas · Alineamiento lineal ↑	0.070 (p = 0.001)	0.070 (p = 0.001)	0.059 (p = 0.001)	0.041 (p = 0.001)	0.012 (p = 0.406)
Calcificaciones · Davies-Bouldin ↓	2.387 (p = 0.001)	2.387 (p = 0.001)	2.995 (p = 0.001)	6.890 (p = 0.018)	6.247 (p = 0.005)
Calcificaciones · Fisher J ↑	1.284 (p = 0.001)	1.284 (p = 0.001)	1.390 (p = 0.001)	0.399 (p = 0.152)	0.753 (p = 0.003)
Calcificaciones · Alineamiento lineal ↑	0.181 (p = 0.001)	0.181 (p = 0.001)	0.161 (p = 0.001)	0.031 (p = 0.010)	0.041 (p = 0.005)

Valor p frente a 1,000 permutaciones de las etiquetas · en magenta, p > 0.05 (no se distingue del azar) · 200 lesiones de entrenamiento por subconjunto · Fig. 6.2.4 del reporte

ANEXO 29

t-SNE: ninguna representación separa visualmente las clases

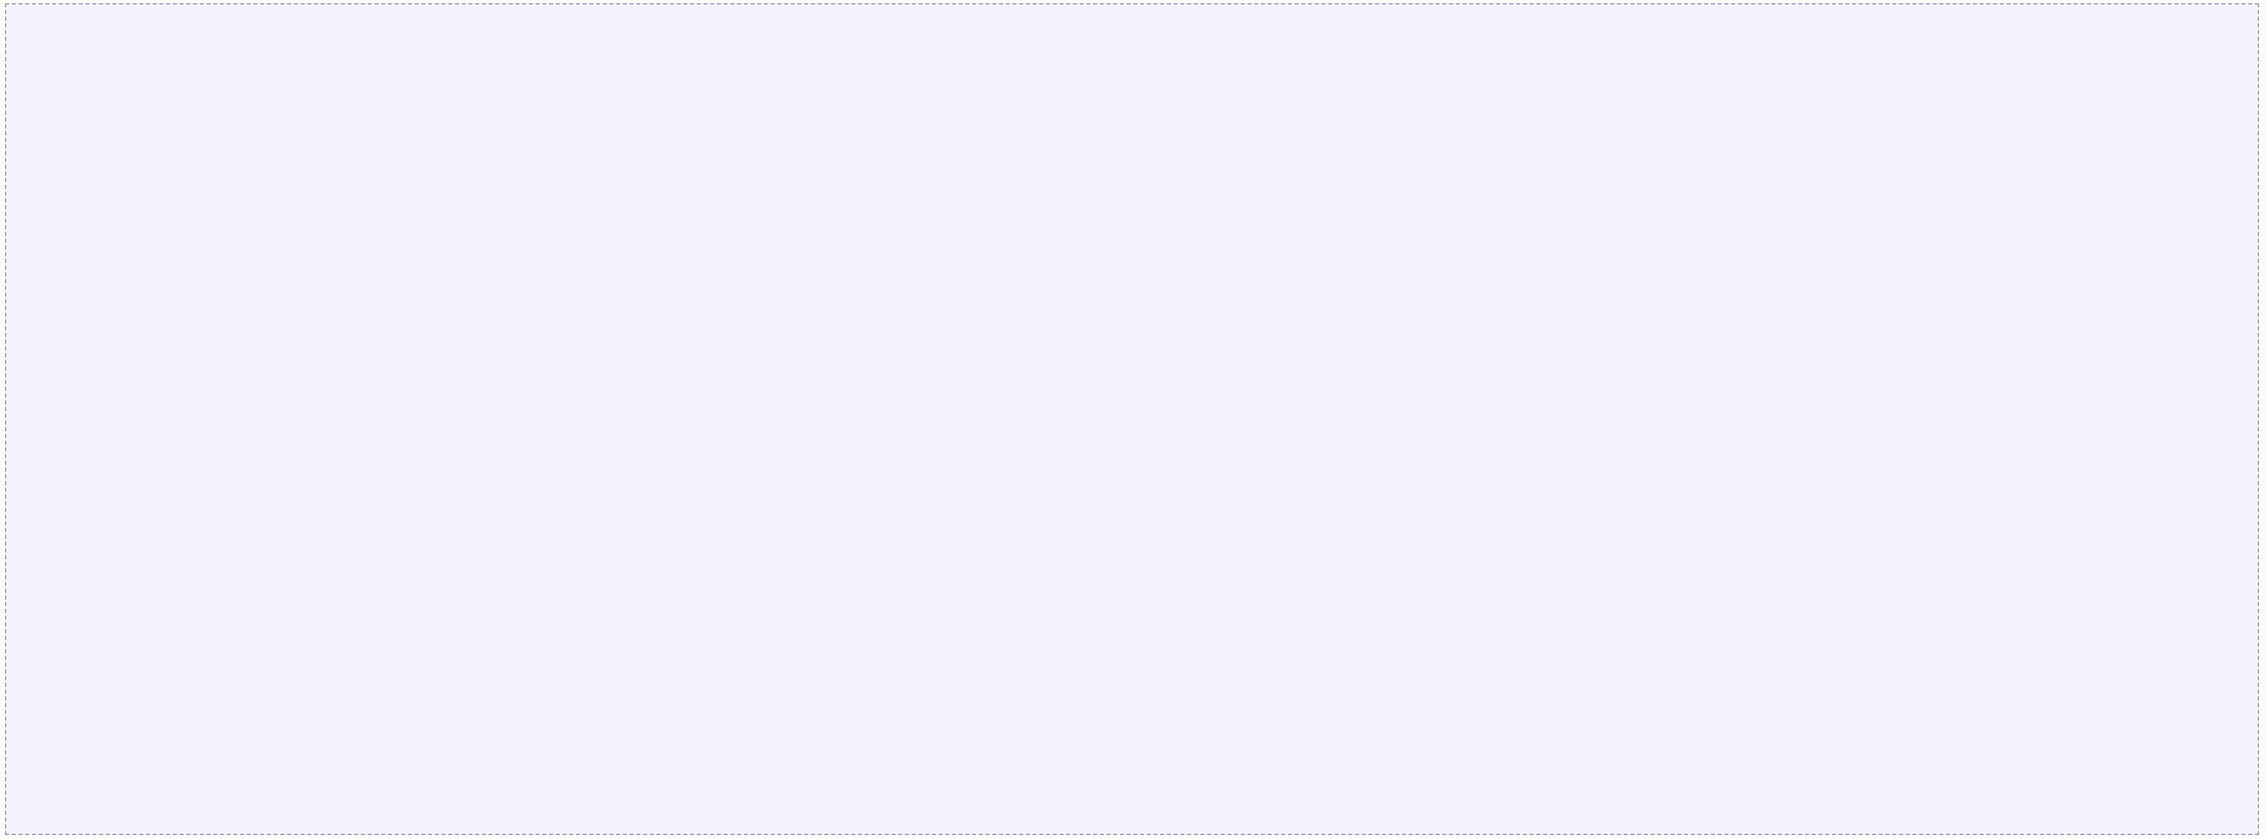

ANEXO 30

Un QSVM sobre el kernel de C4 iguala al SVM clásico

AUC en prueba

	Masas	Calcificaciones
SVM RBF	0.649	0.769
QSVM C4	0.628	0.759
QSVM C5	0.599	0.701
MLP sobre $\langle Z_i \rangle$ de C4	0.530	0.633

ANEXO 31

Buscando ventaja con la misma búsqueda en los dos lados: ninguna

Kernels clásicos

búsqueda anidada

=

Kernels cuánticos

la misma búsqueda

Con etiquetas reales, ningún kernel cuántico supera a los clásicos

ANEXO 32

La conclusión resiste cambios en θ, en k y en la muestra

10 sorteos de θ	déficit frente a C1 de 0.03 a 0.18 de AUC
θ entrenado	+0.05 como máximo, no significativo
k = 8 características	misma conclusión
20 submuestras	RBF delante en el 100 %
6 clasificadores (árboles, *random forest*, XGBoost, MLP)	0 de 24 comparaciones a favor de C4/C5

ANEXO 33

Separabilidad y clasificación ordenan las condiciones de forma parecida

$$\rho = 0.67 - 0.97$$

Spearman entre métricas de separabilidad y AUC · descriptivo, n = 5 condiciones

Delante — C1–C3

Detrás — C4–C5

en todos los rankings

ANEXO 34

Reducir la escala de los ángulos quita la concentración, pero también la interacción

Mediana del kernel C4, masas · escala logarítmica

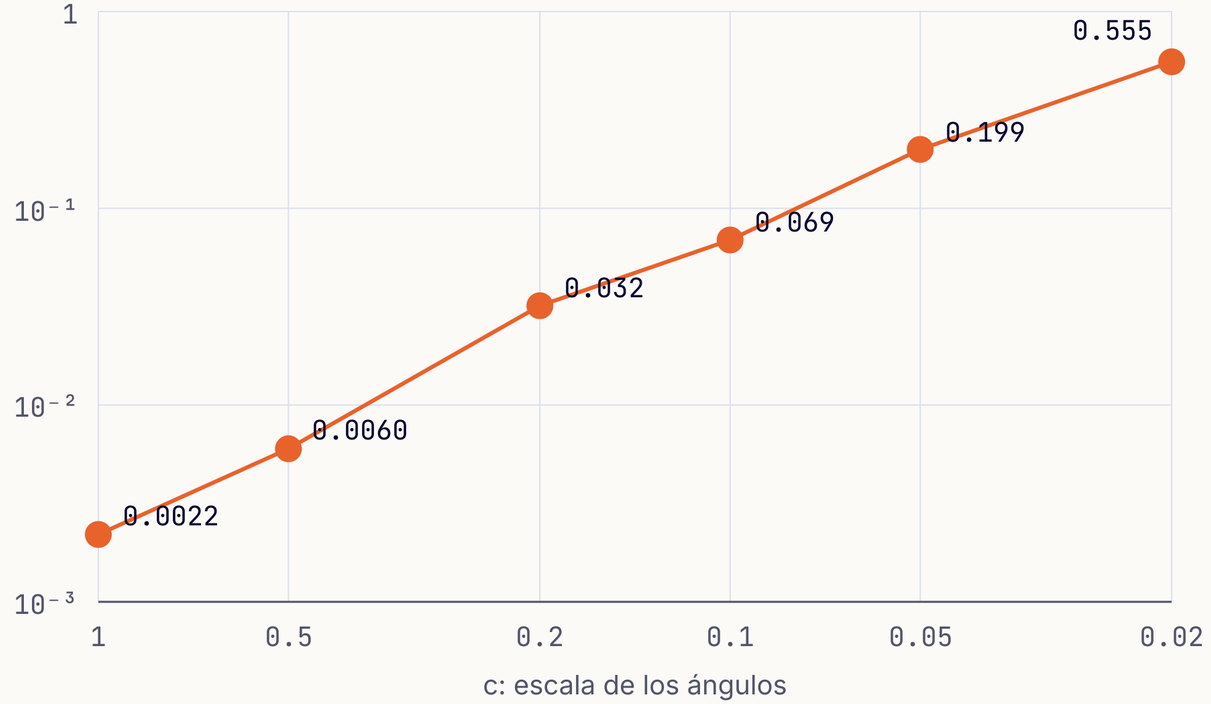

idéntico al kernel sin el término $x_i x_j$ (correlación 1.0000)

demasiado lejos: se pierden las calles (las interacciones)

esquema ilustrativo

Con descriptores del radiólogo las masas son más separables; con radiómica, menos

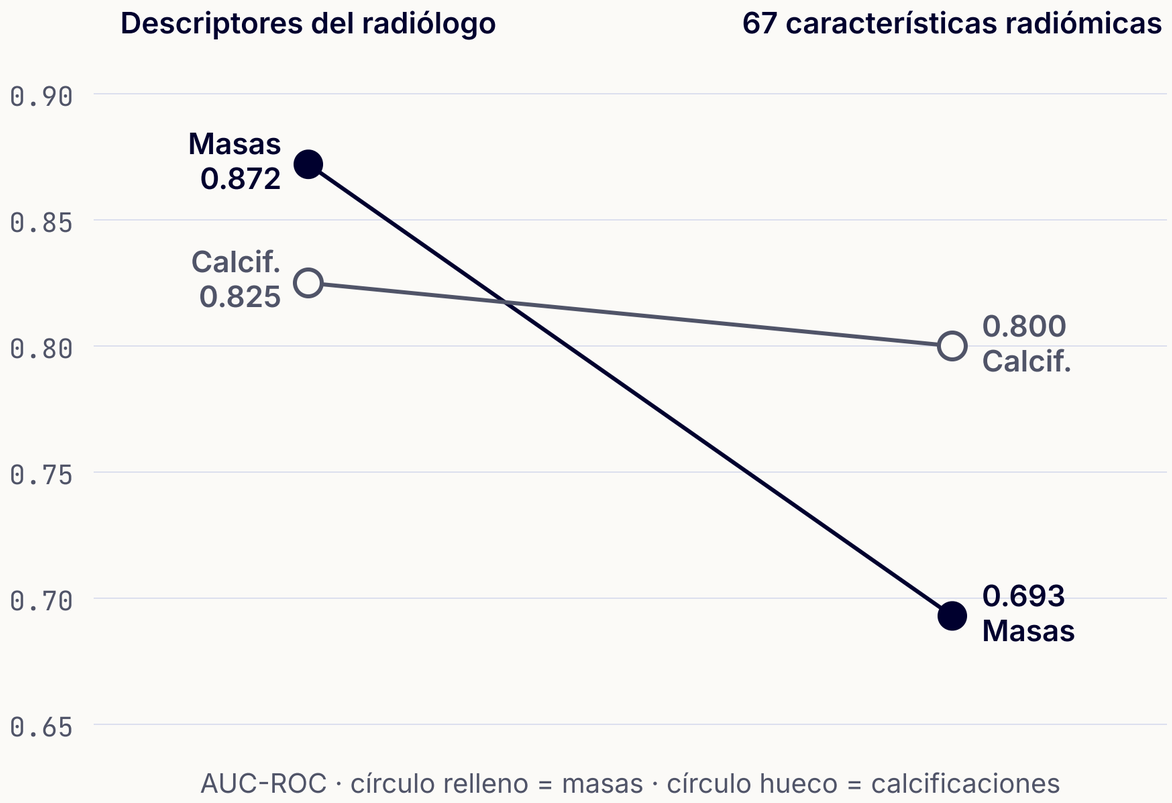

La dificultad relativa de masas y calcificaciones se invierte según la representación.

ANEXO 36

Separabilidad medida antes de clasificar

En el kernel

Alineamiento kernel-objetivo

exceso sobre etiquetas permutadas

Diferencia geométrica g

Huang et al., 2021 · ventaja potencial solo si g ≈ √N

En los vectores

Davies-Bouldin

↓ menor es mejor

Razón de Fisher

↑ mayor es mejor

t-SNE

cualitativo

Clasificación: AUC-ROC (principal), F1, exactitud, precisión, sensibilidad. Validación cruzada de 5 particiones por paciente.

ANEXO 37

Umbral α* de cada kernel

Kernel cuántico	Masas	Calcificaciones
ZZ completo (C4)	0.6	0.7
ZZ lineal	0.5	0.6
Proyectado	0.4	0.5

el diagnóstico real está en α = 0

ANEXO 38

La codificación

estado $$|\phi(\mathbf{x})\rangle = U(\mathbf{x})\,|0\rangle^{\otimes n}$$

mapa ZZ $$U_{\mathrm{ZZ}}(\mathbf{x}) = \left[\mathcal{U}_{\Phi}(\mathbf{x})\,H^{\otimes n}\right]^{r}$$

con $$\mathcal{U}_{\Phi}(\mathbf{x}) = \exp\left(-i \sum_{|S|\leq 2} \phi_S(\mathbf{x}) \bigotimes_{j\in S} Z_j\right)$$

fases $$\phi_{\{i\}}(\mathbf{x}) = x_i, \qquad \phi_{\{i,j\}}(\mathbf{x}) = (\pi - x_i)(\pi - x_j)$$

n: qubits · r: repeticiones · H: Hadamard · Z_j: Pauli Z en el qubit j · φ_S: fase del conjunto S de qubits

ANEXO 39

Las dos lecturas

kernel	$K_Q(\mathbf{x}, \mathbf{x}') = \left\lvert \langle \phi(\mathbf{x}) \rvert \phi(\mathbf{x}') \rangle \right\rvert^2$
valores esperados	$\langle Z_i \rangle = \langle \psi(\mathbf{x}, \boldsymbol{\theta}) \rvert Z_i \rvert \psi(\mathbf{x}, \boldsymbol{\theta}) \rangle \in [-1, 1]$
con	$\lvert \psi(\mathbf{x}, \boldsymbol{\theta}) \rangle = W(\boldsymbol{\theta})\, U(\mathbf{x})\, \lvert 0 \rangle^{\otimes n}$
parámetros del *ansatz*	$m = n\,(r+1) = 24$

W(θ): *ansatz* · θ: sus parámetros · Z_i: Pauli Z en el qubit i · n: qubits · r: repeticiones

ANEXO 40

Separabilidad

alineamiento	$\widehat{\mathrm{KTA}}_c(K,\mathbf{y}) = \dfrac{\langle K_c, (\mathbf{y}\mathbf{y}^\top)_c\rangle_F}{\|K_c\|_F \, \|(\mathbf{y}\mathbf{y}^\top)_c\|_F}$
piso	$\widehat{\mathrm{KTA}}_c(I,\mathbf{y}) = \dfrac{1}{\sqrt{N-1}}$
exceso	$\Delta\mathrm{KTA}_c = \widehat{\mathrm{KTA}}_c(K,\mathbf{y}) - \mathbb{E}_\pi[\widehat{\mathrm{KTA}}_c(K,\mathbf{y}_\pi)]$
Fisher	$J = \Delta\boldsymbol{\mu}^\top S_W^{-1} \Delta\boldsymbol{\mu}$
Davies-Bouldin	$\mathrm{DB} = \dfrac{1}{C}\sum_i \max_{j\neq i} \dfrac{s_i + s_j}{d(c_i,c_j)}$

K_c: kernel centrado · $\mathbf{y}$: etiquetas · π: permutación · S_W: dispersión intraclase · s_i: dispersión del grupo i · c_i: su centro

ANEXO 41

La diferencia geométrica acota la ventaja posible del kernel cuántico

sin regularizar

$$g_{CQ} = \sqrt{\left\| \sqrt{K_Q}\, K_C^{-1}\, \sqrt{K_Q} \right\|_\infty}$$

regularizada

$$g = \sqrt{\left\| \sqrt{K_Q}\, \sqrt{K_C}\, (K_C + \lambda I)^{-2}\, \sqrt{K_C}\, \sqrt{K_Q} \right\|_\infty}$$

condición

$$g_{\mathrm{tra}}(K_C, K_Q; \lambda) = \lambda \sqrt{\| \sqrt{K_Q} (K_C + \lambda I)^{-2} \sqrt{K_Q} \|_\infty} < 0.045$$

cota

$$s_C \leq g^2\, s_Q$$

(Huang et al., 2021, p. 5)

dimensión efectiva

$$d(K) = \sum_{k=1}^{N} \frac{1}{N-k+1} \sum_{l=k}^{N} t_l, \qquad 1 \leq d \leq N$$

K_Q: kernel cuántico de fidelidad · K_C: kernel clásico: lineal y 9 gaussianos; se toma el mínimo · λ: regularización · ‖·‖∞: norma espectral · s: complejidad del modelo

Protocolo de Huang et al. (2021), suplemento, sección 12 C. Ventaja potencial solo si g ≈ √N; aquí g = 1.40–1.70 frente a √N ≈ 14.1.

ANEXO 42

Medición y gradiente

ruido de un valor esperado	$\mathrm{Var}(\hat{Z}_i) = \dfrac{1 - \langle Z_i \rangle^2}{n_{\mathrm{shots}}}$
ruido de un valor del kernel	$\dfrac{K_Q(1 - K_Q)}{n_{\mathrm{shots}}}$
probabilidad de leer exactamente 0	$(1 - K_Q)^{n_{\mathrm{shots}}}$
parameter-shift	$\dfrac{\partial \langle Z_i \rangle}{\partial \theta_j} = \dfrac{1}{2}\left[\langle Z_i \rangle_{\theta_j + \frac{\pi}{2}} - \langle Z_i \rangle_{\theta_j - \frac{\pi}{2}}\right]$

n_shots: disparos · K_Q: valor del kernel · θ_j: parámetro j del *ansatz*

ANEXO 43

Clasificación

pérdida ponderada

$$\mathcal{L}_w = -\left[w_1\, y \log \hat{y} + w_0\, (1-y) \log(1-\hat{y})\right]$$

con

$$w_c = \frac{N}{C \cdot N_c}$$

AUC

$$\mathrm{AUC} = \int_0^1 \mathrm{TPR}(t)\, d\,\mathrm{FPR}(t)$$

Spearman con empates

$$\rho_s = \frac{\sum (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum (R_i - \bar{R})^2 \sum (S_i - \bar{S})^2}}$$

w_c: peso de la clase c · N_c: lesiones de la clase c · C: número de clases · R, S: rangos promedio

ANEXO 44

Los kernels clásicos de referencia

RBF

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2)$$

con

$$\gamma = \frac{1}{2 \, \mathrm{med}_{i<j} \, \|\mathbf{x}_i - \mathbf{x}_j\|^2}$$

PCA conserva distancias

$$\|\mathbf{z} - \mathbf{z}'\| = \|\mathbf{x} - \mathbf{x}'\|$$

kernel proyectado

$$k^{\mathrm{PQ}}(\mathbf{x}, \mathbf{x}') = \exp\left(-\gamma \sum_k \|\rho_k(\mathbf{x}) - \rho_k(\mathbf{x}')\|_F^2 \right)$$

γ: ancho de banda · z: vector tras PCA · ρ_k(x): estado del qubit k

¿Un resultado negativo vale? Sí: el método detecta la ventaja cuando existe

Objetivo: viabilidad →

control positivo

0.998 vs 0.857

diapositiva 18

¿Por qué no una CNN?

~~mamografía ~5,037 × 2,960 px → circuito de 12 qubits~~

mamografía → 67 características → 12 ángulos

¿Las intensidades no calibradas meten el efecto del digitalizador?

Un sesgo, si existe, afecta a las cinco por igual

ANEXO 48

¿Cuánto se pierde al quedarse con 12 de 67?

67 → 12

de 2 a 4 puntos de AUC

ANEXO 49

¿El resultado se generaliza?

un solo conjunto

CBIS-DDSM

sin escala física

PixelSpacing ausente

familias probadas

mapas ZZ y proyectados

ANEXO 50

¿Cuándo valdría la pena el hardware?

- ✓ etiquetas que siguen la geometría del circuito
- ✓ un kernel que no se concentre
- ✓ una codificación difícil de simular

Figura 3.4.1 · Geometría de los kernels clásico y cuántico (Huang et al., 2021)

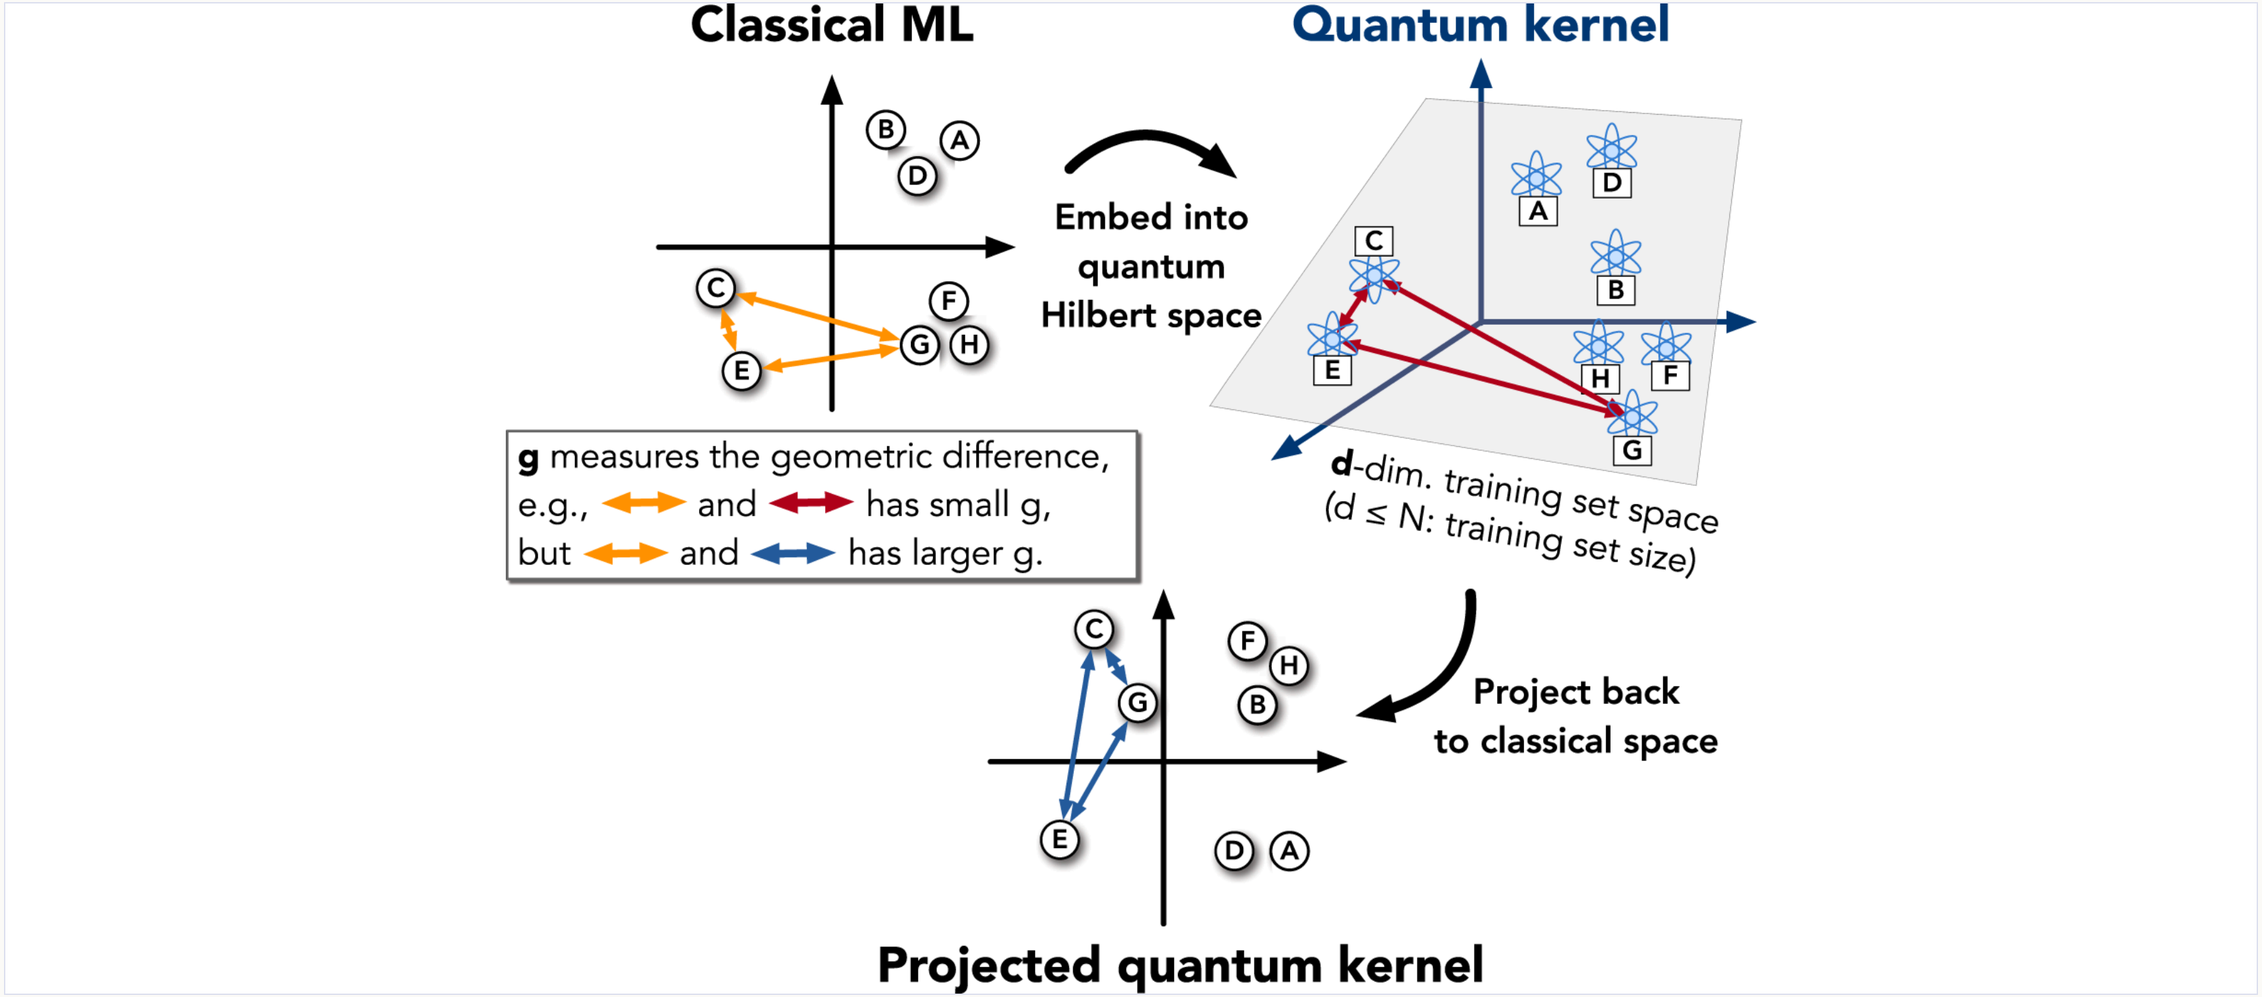

ANEXO 52

Figura 4.3.1 · Forma y margen de las masas por patología

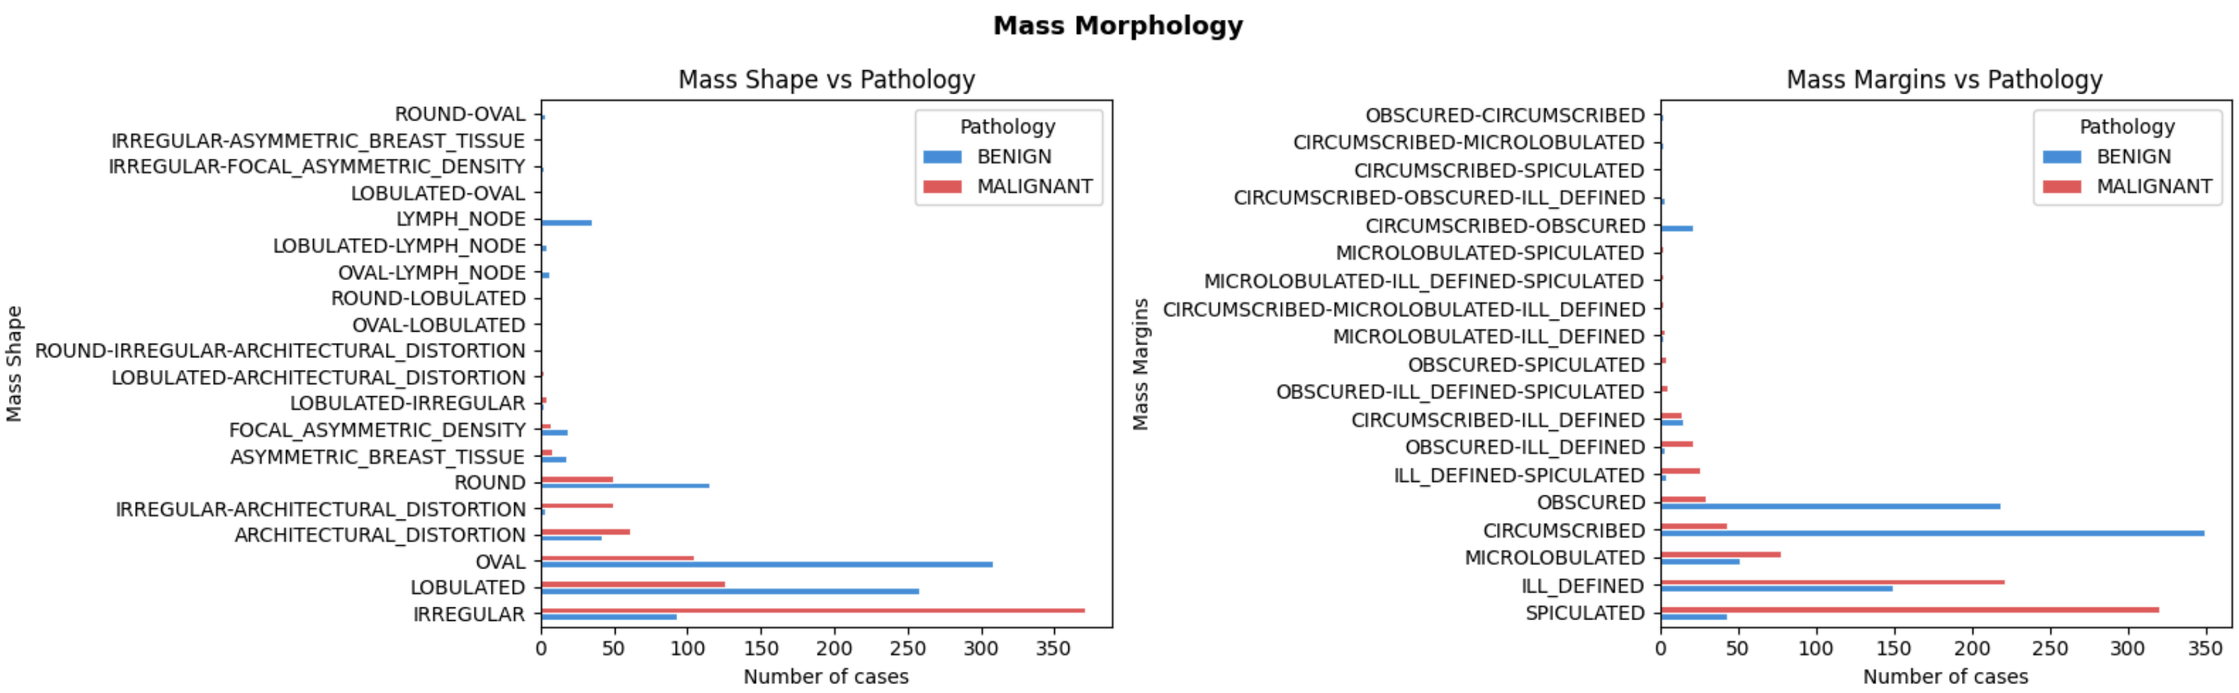

ANEXO 53

Figura 4.3.2 · Tipo y distribución de las calcificaciones por patología

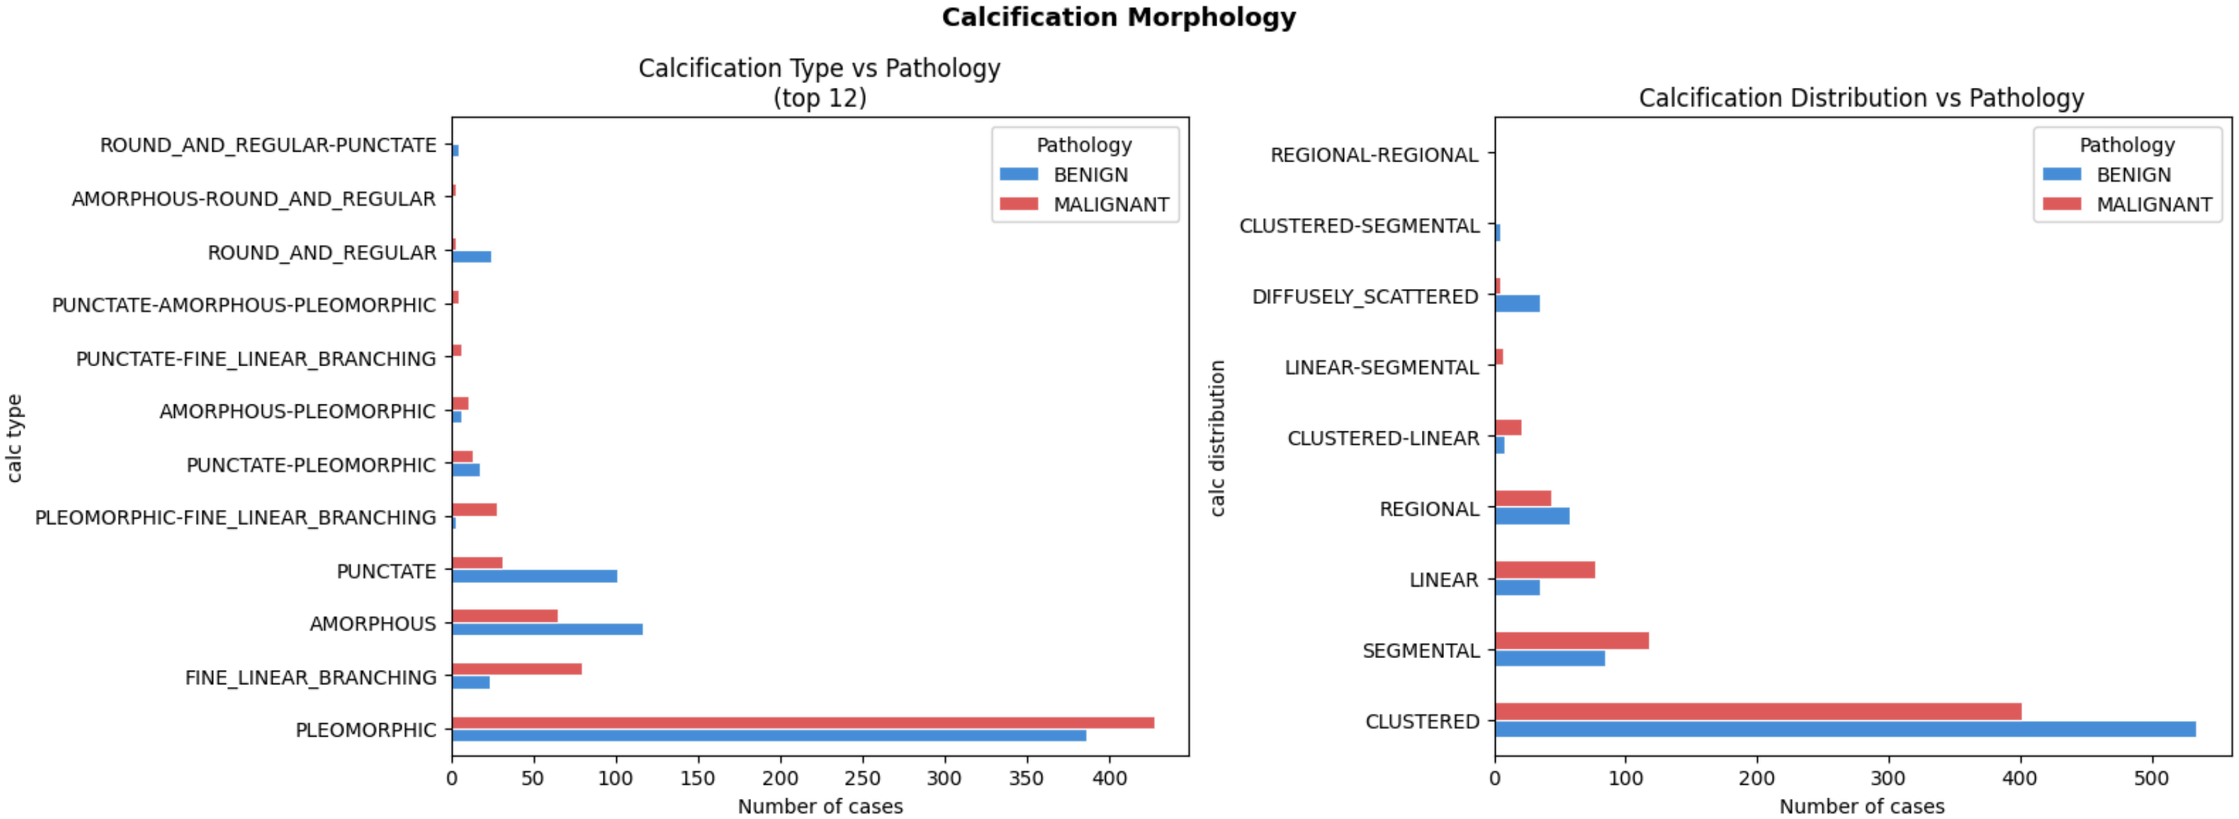

Figura 5.6.1 · Costo del número de *folds*

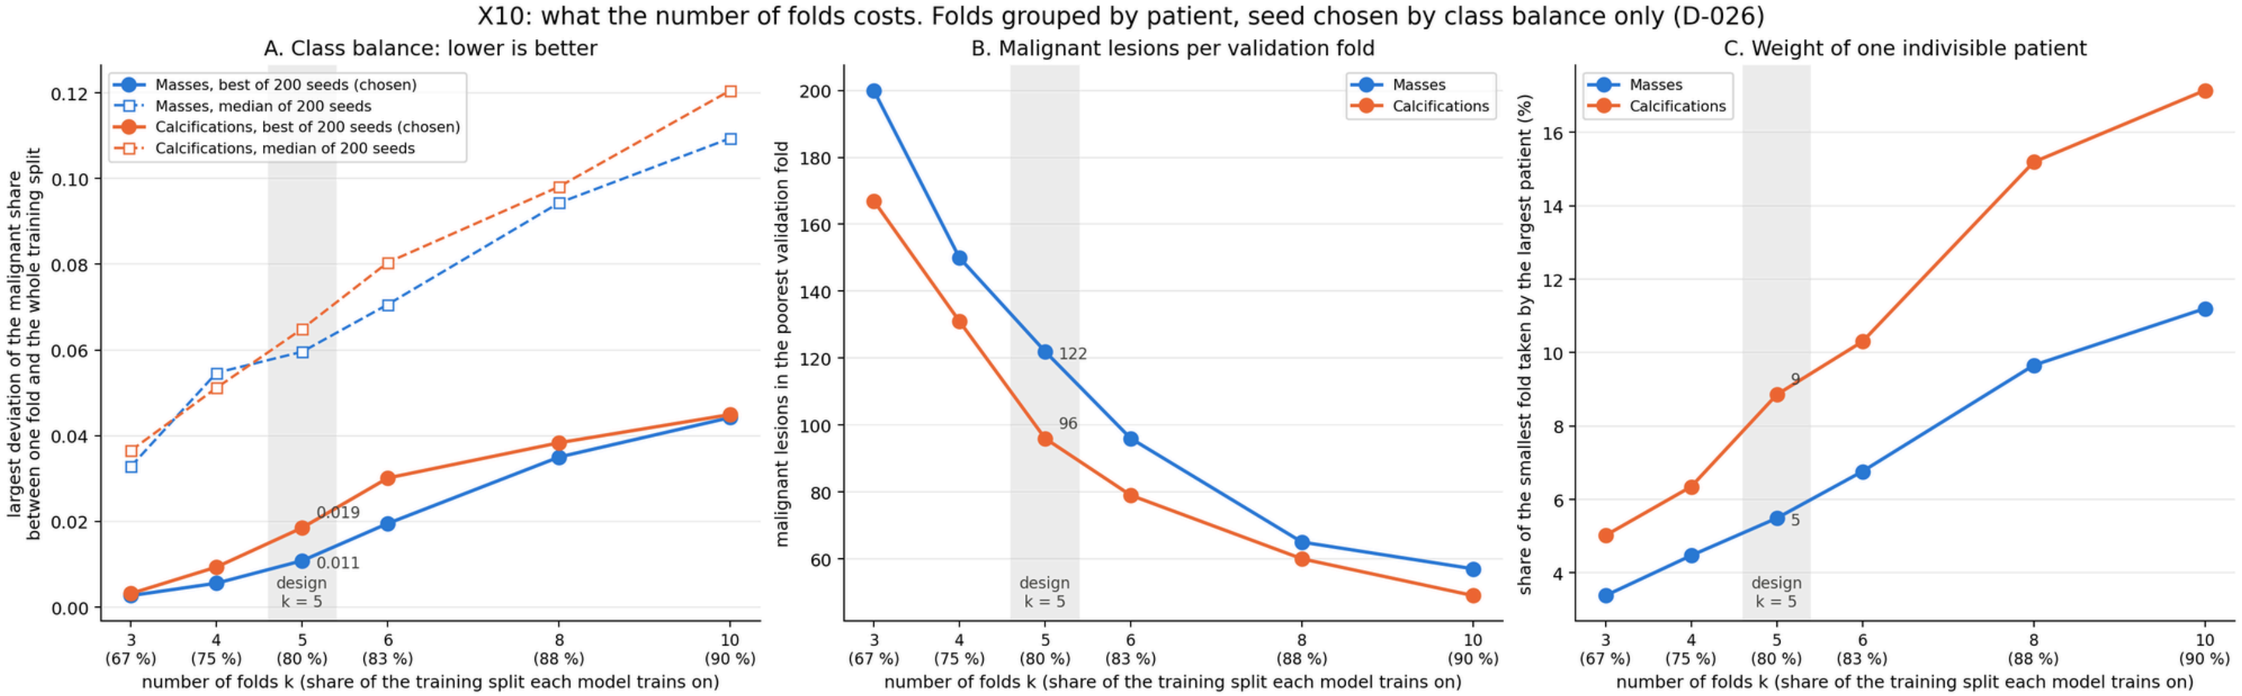

ANEXO 55

Figura 5.7.1 · Circuitos de C4 y C5 dibujados para k = 4

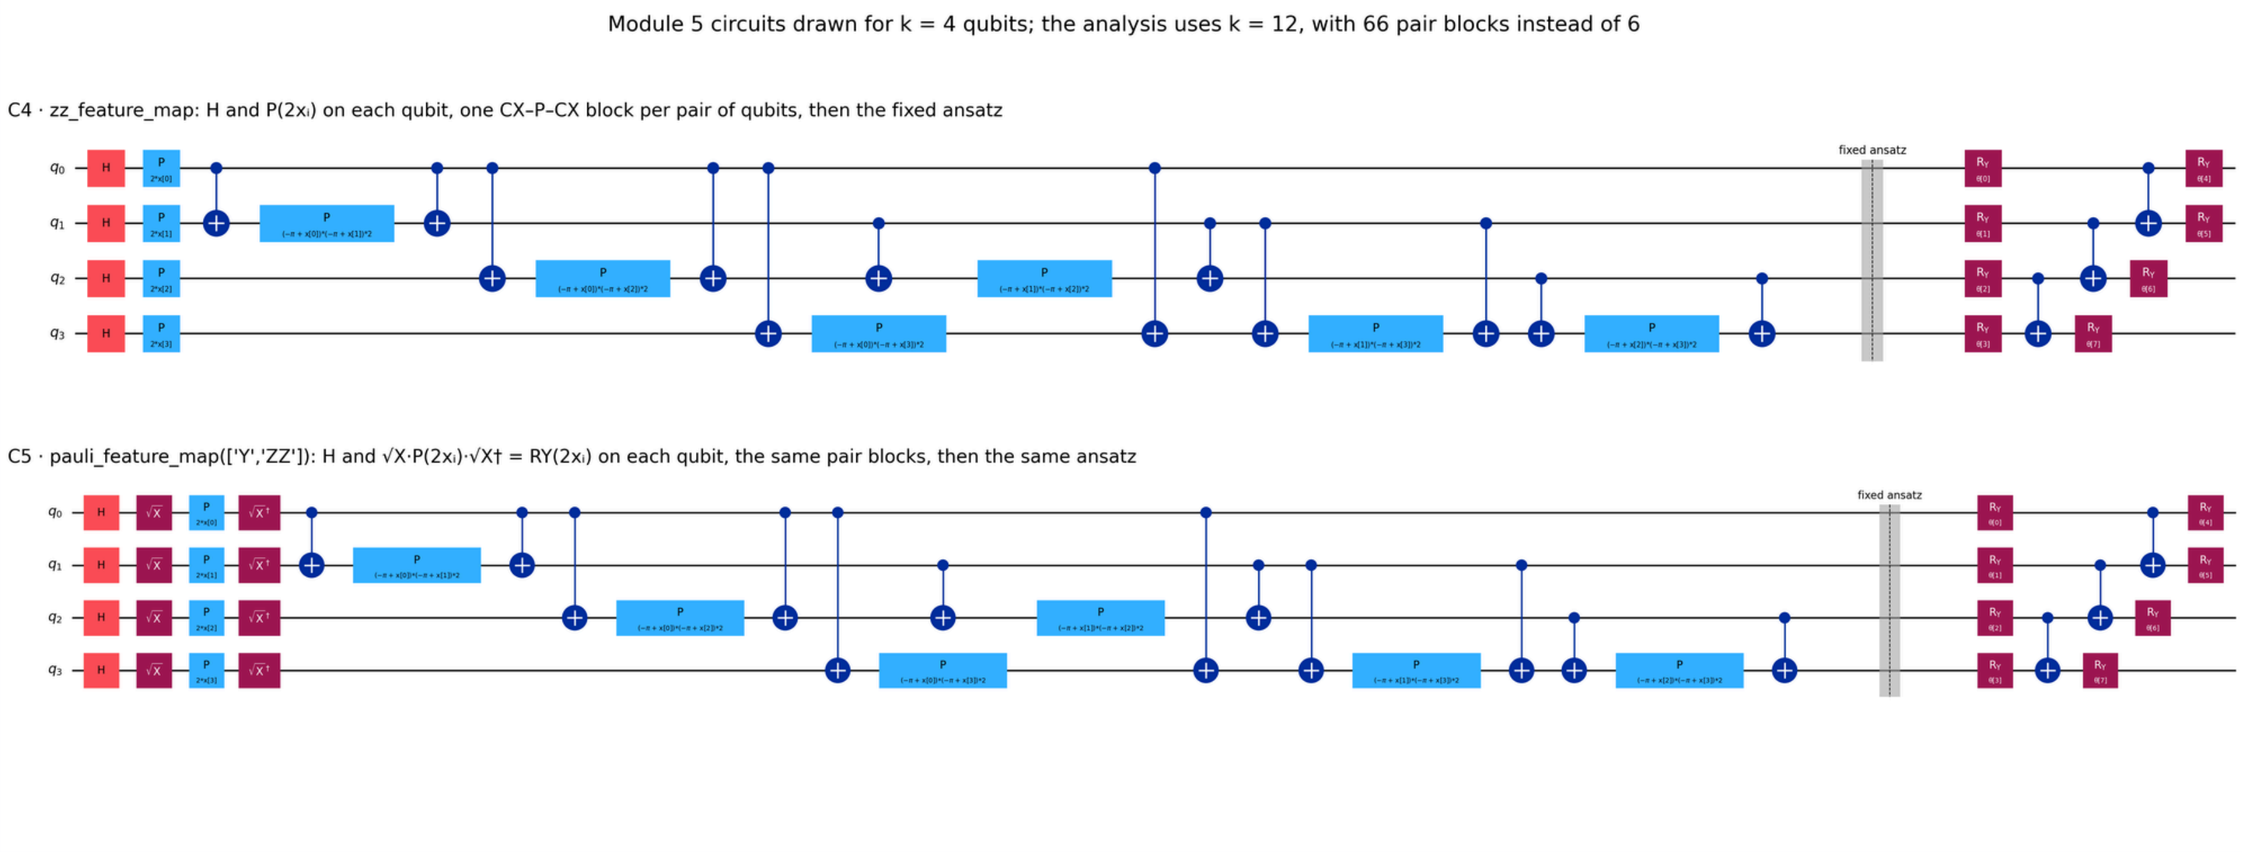

ANEXO 56

Figura 6.1.1 · Tamaños de efecto de las 67 características

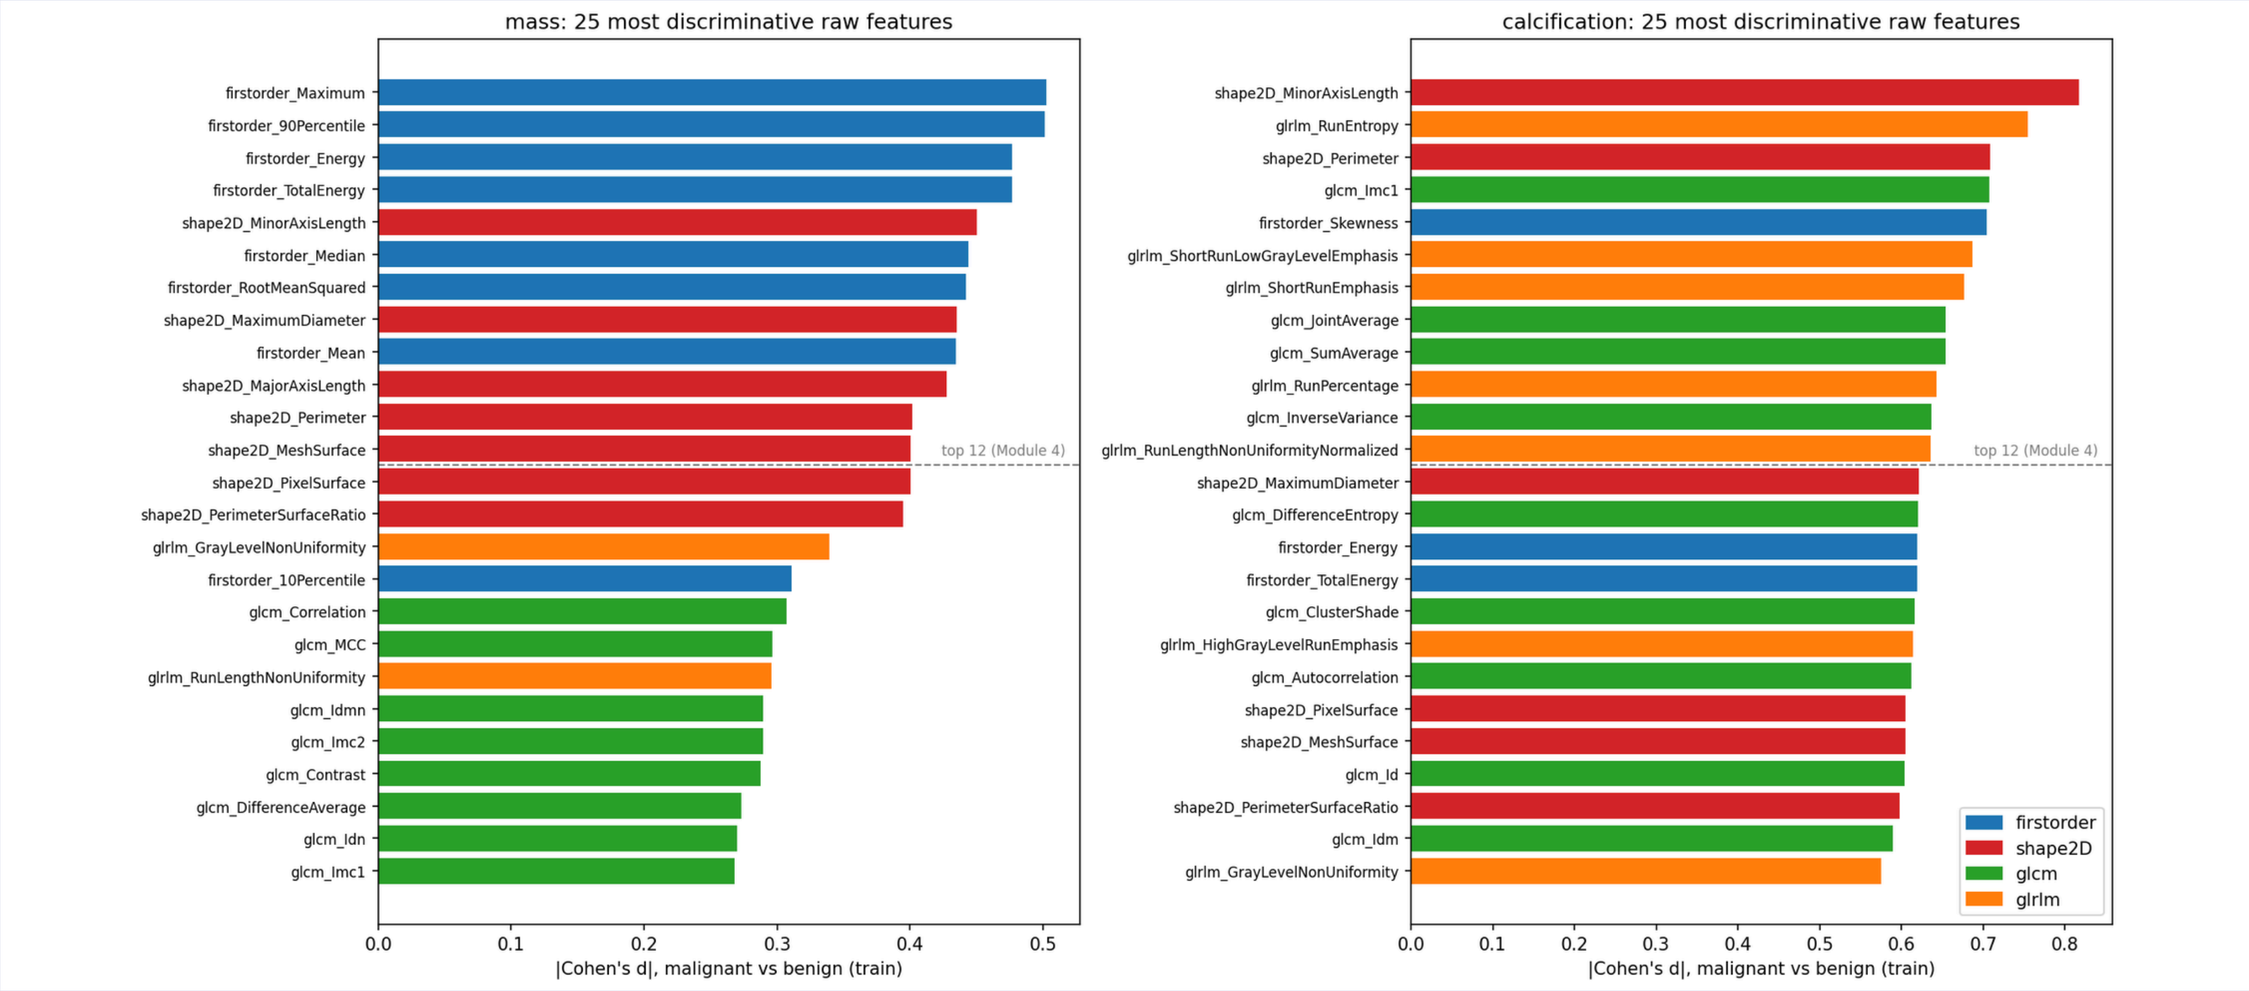

Figura 6.1.2 · Efecto de CLAHE en la capacidad discriminativa

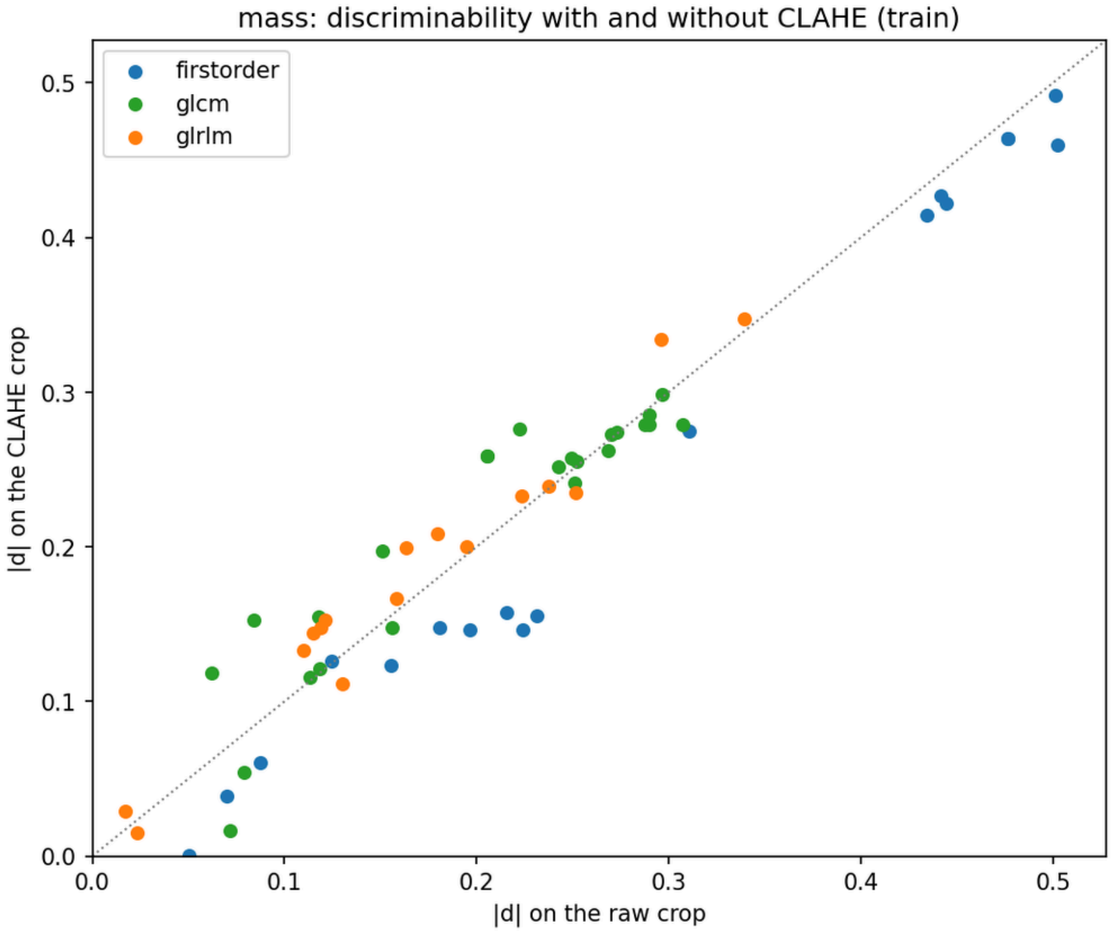

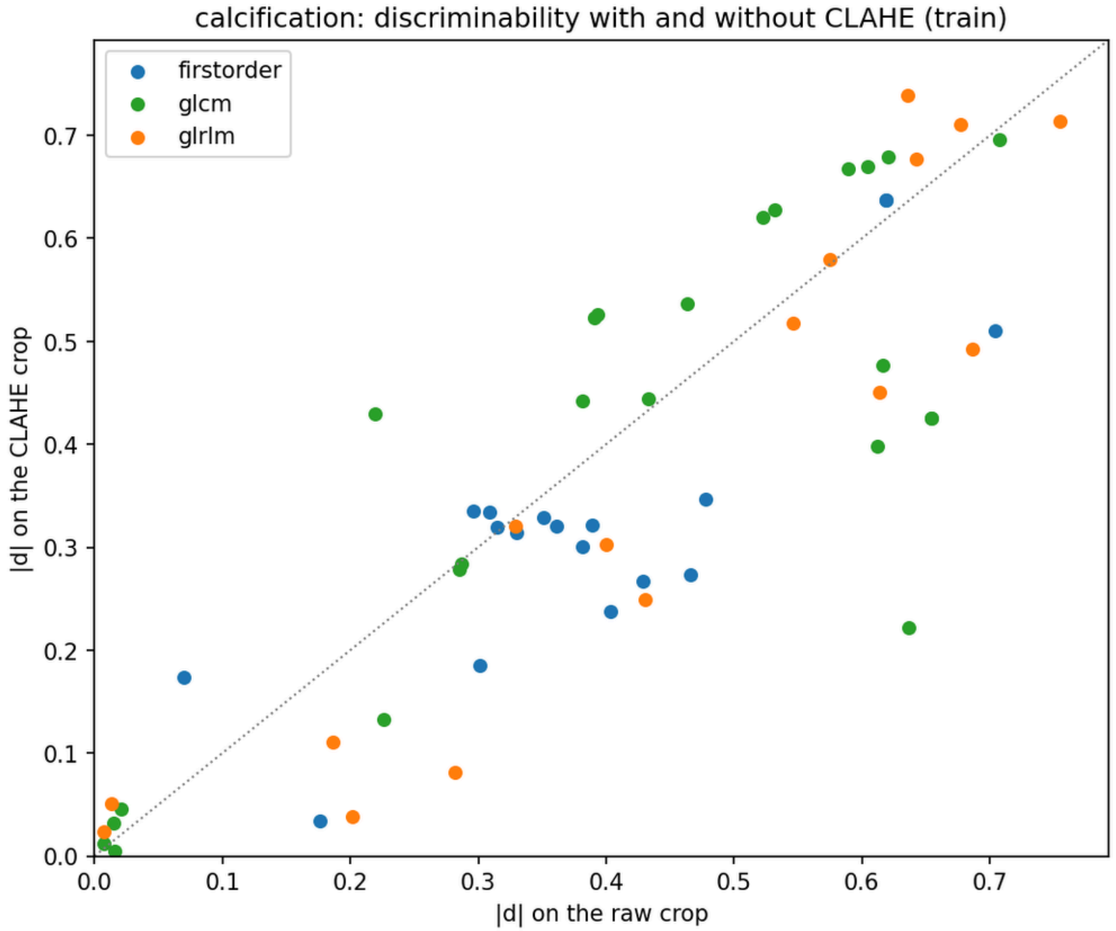

ANEXO 58

Figura 6.1.3 · Selección y escalado angular por cuantiles

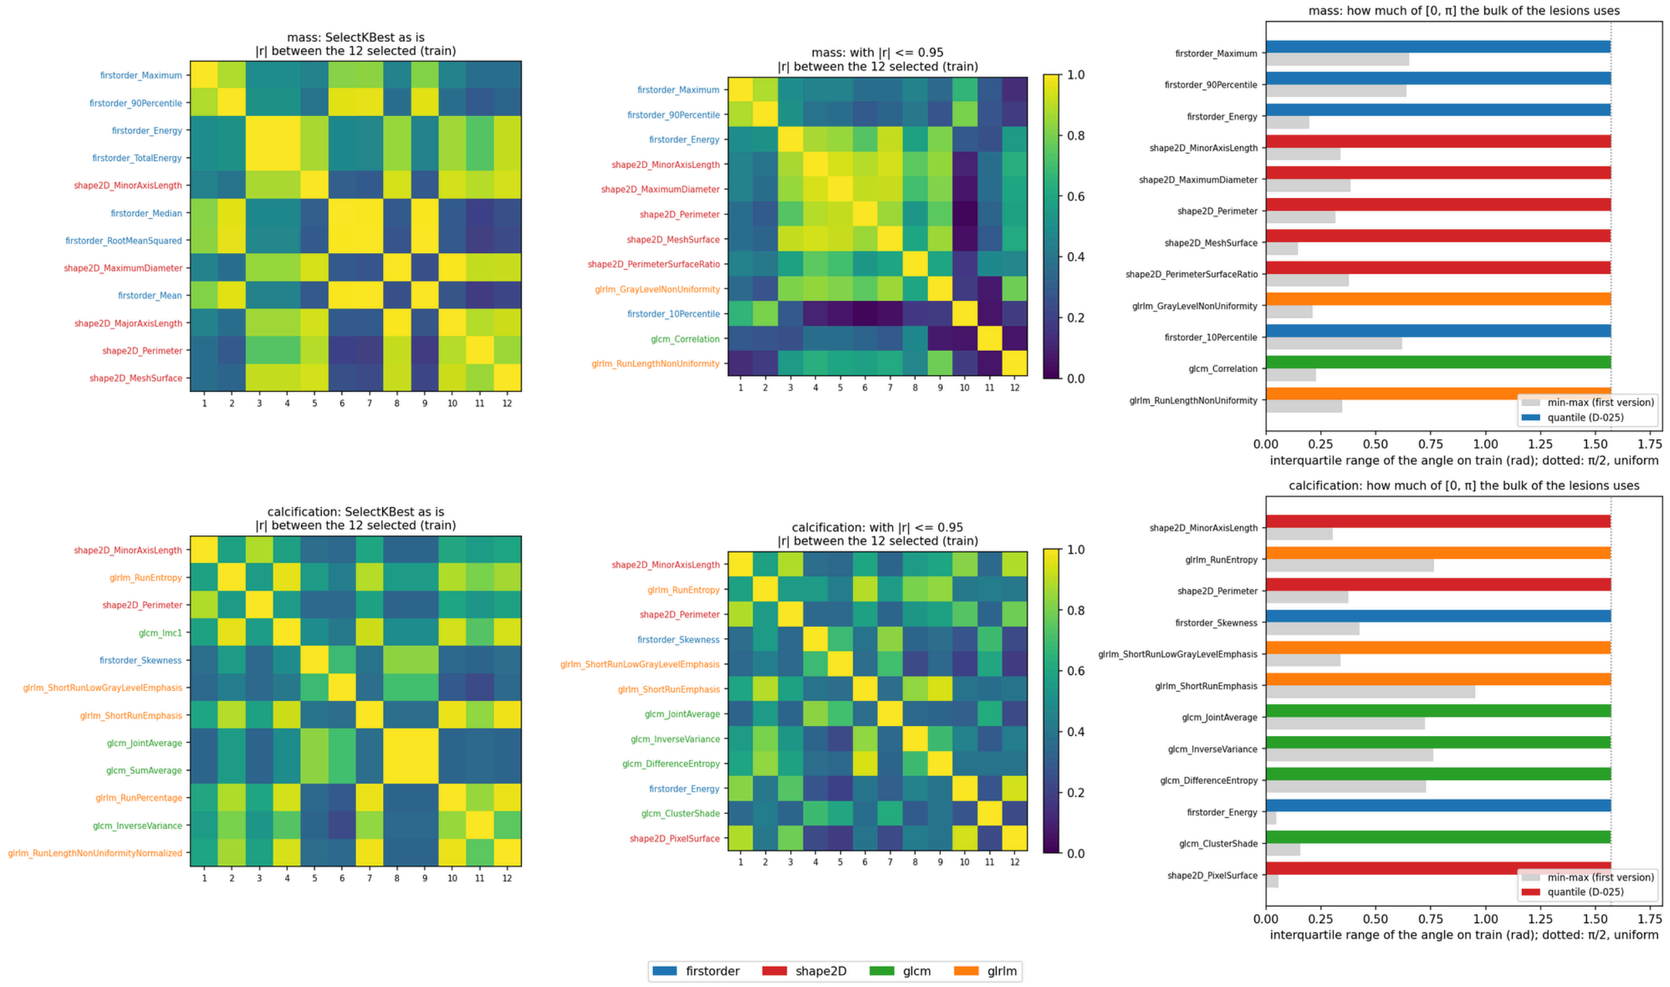

ANEXO 59

Figura 6.1.4 · AUC en función del número de características k

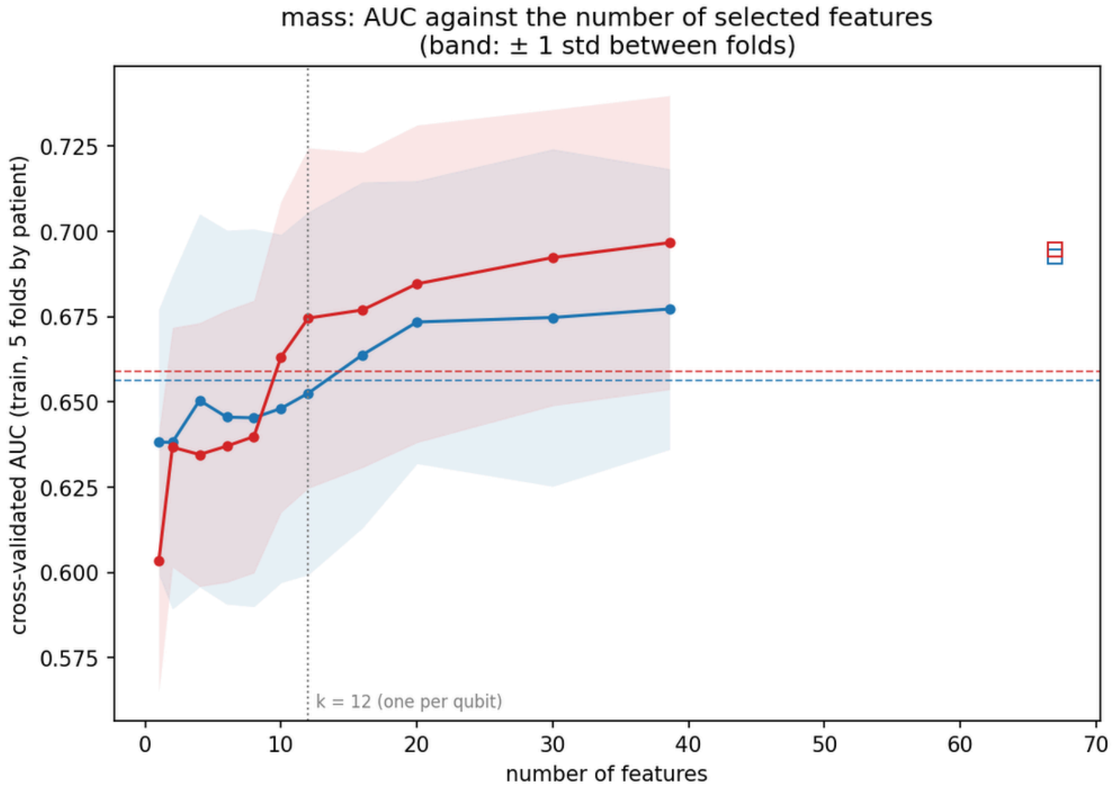

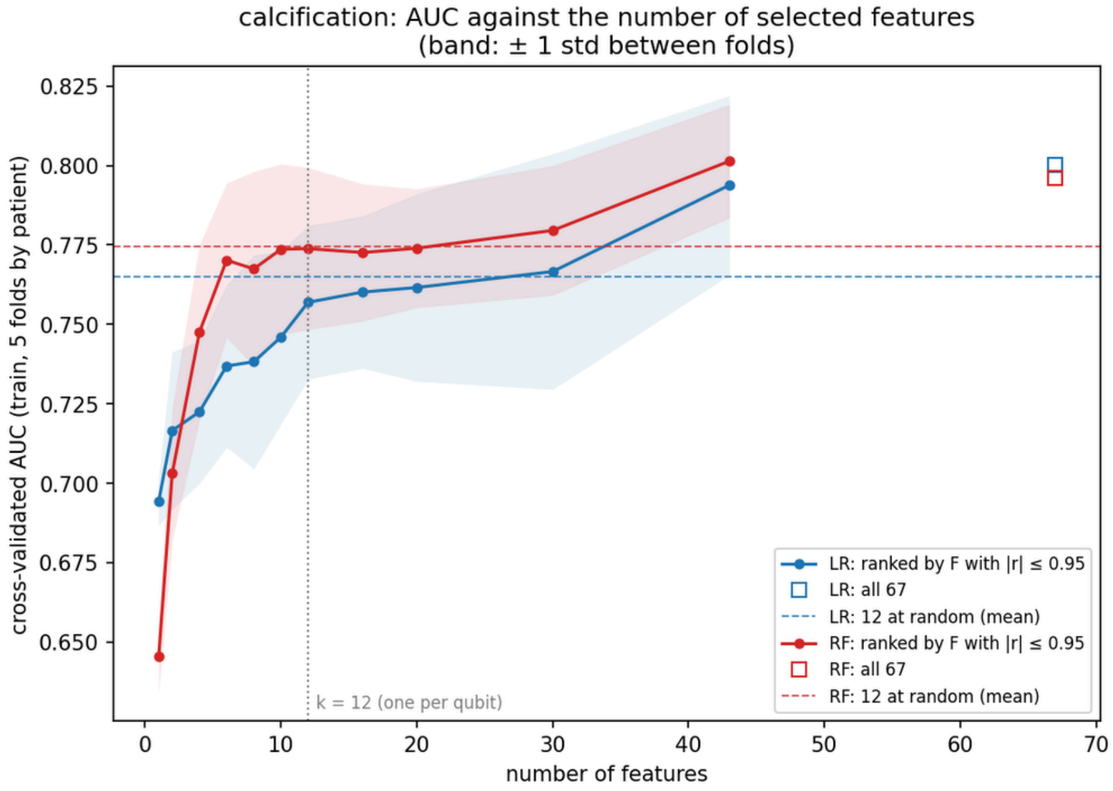

ANEXO 60

Figura 6.2.1 · Concentración de los kernels cuánticos

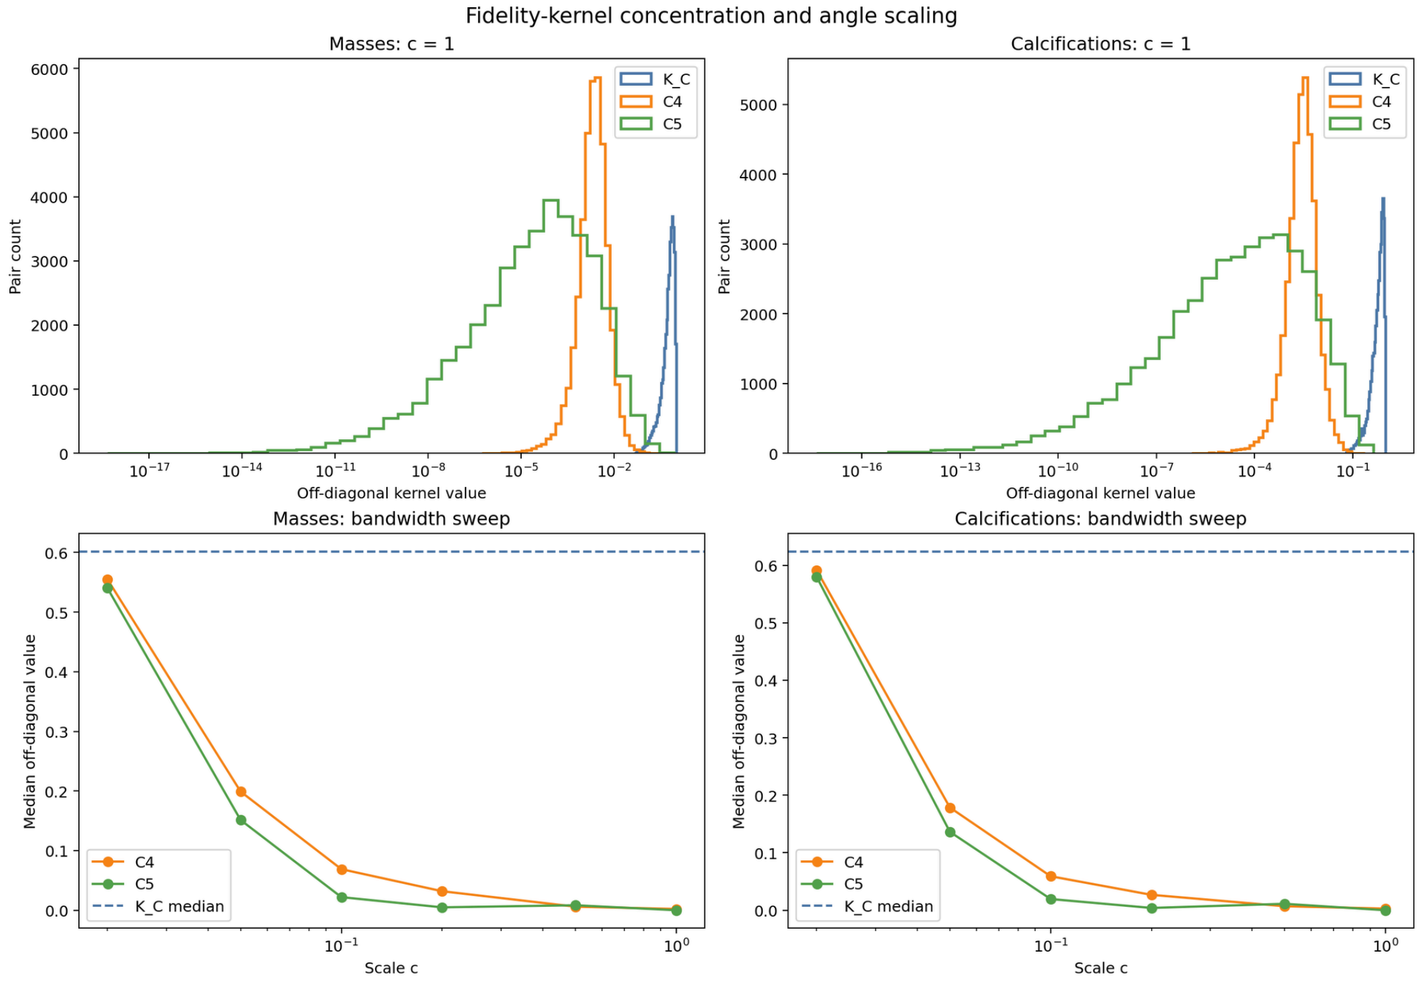

ANEXO 61

Figura 6.2.2 · Alineamiento y dimensión efectiva de los kernels

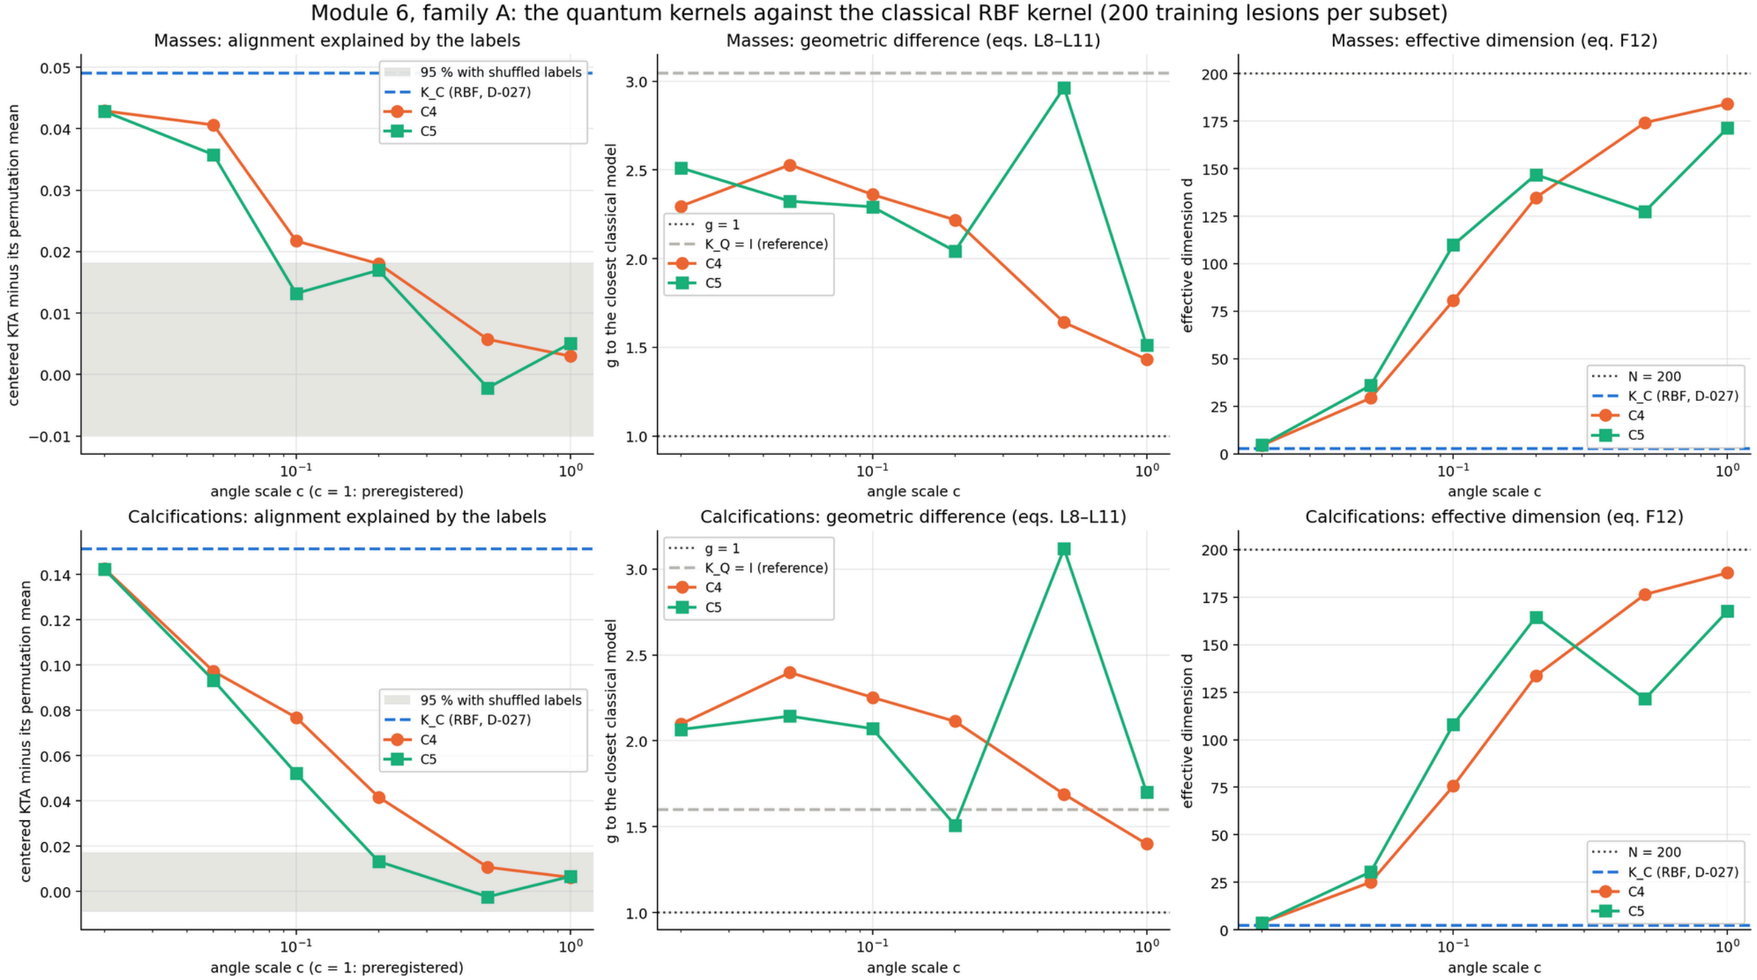

ANEXO 62

Figura 6.2.3 · Diferencia geométrica *g* frente a √N

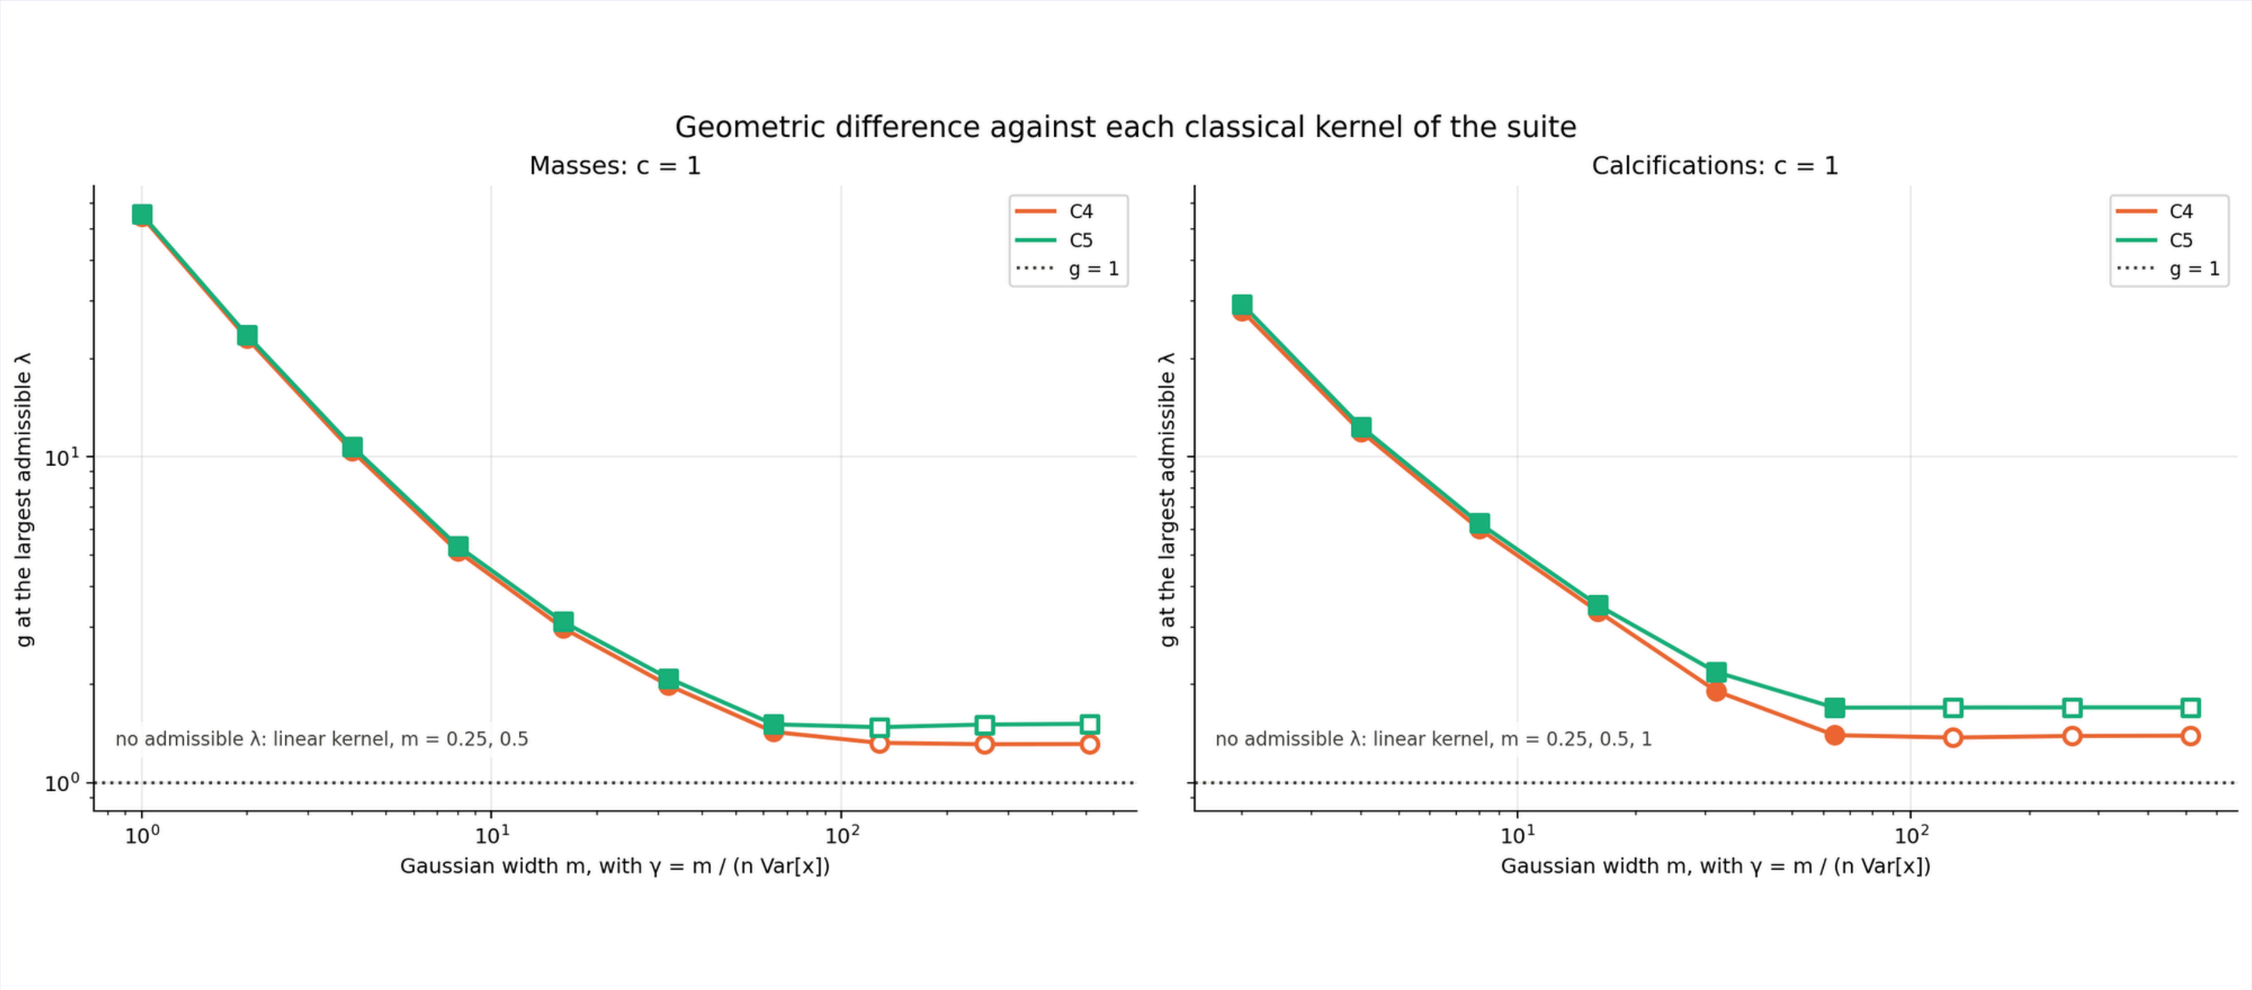

ANEXO 63

Figura 6.2.4 · Davies-Bouldin, Fisher y alineamiento lineal

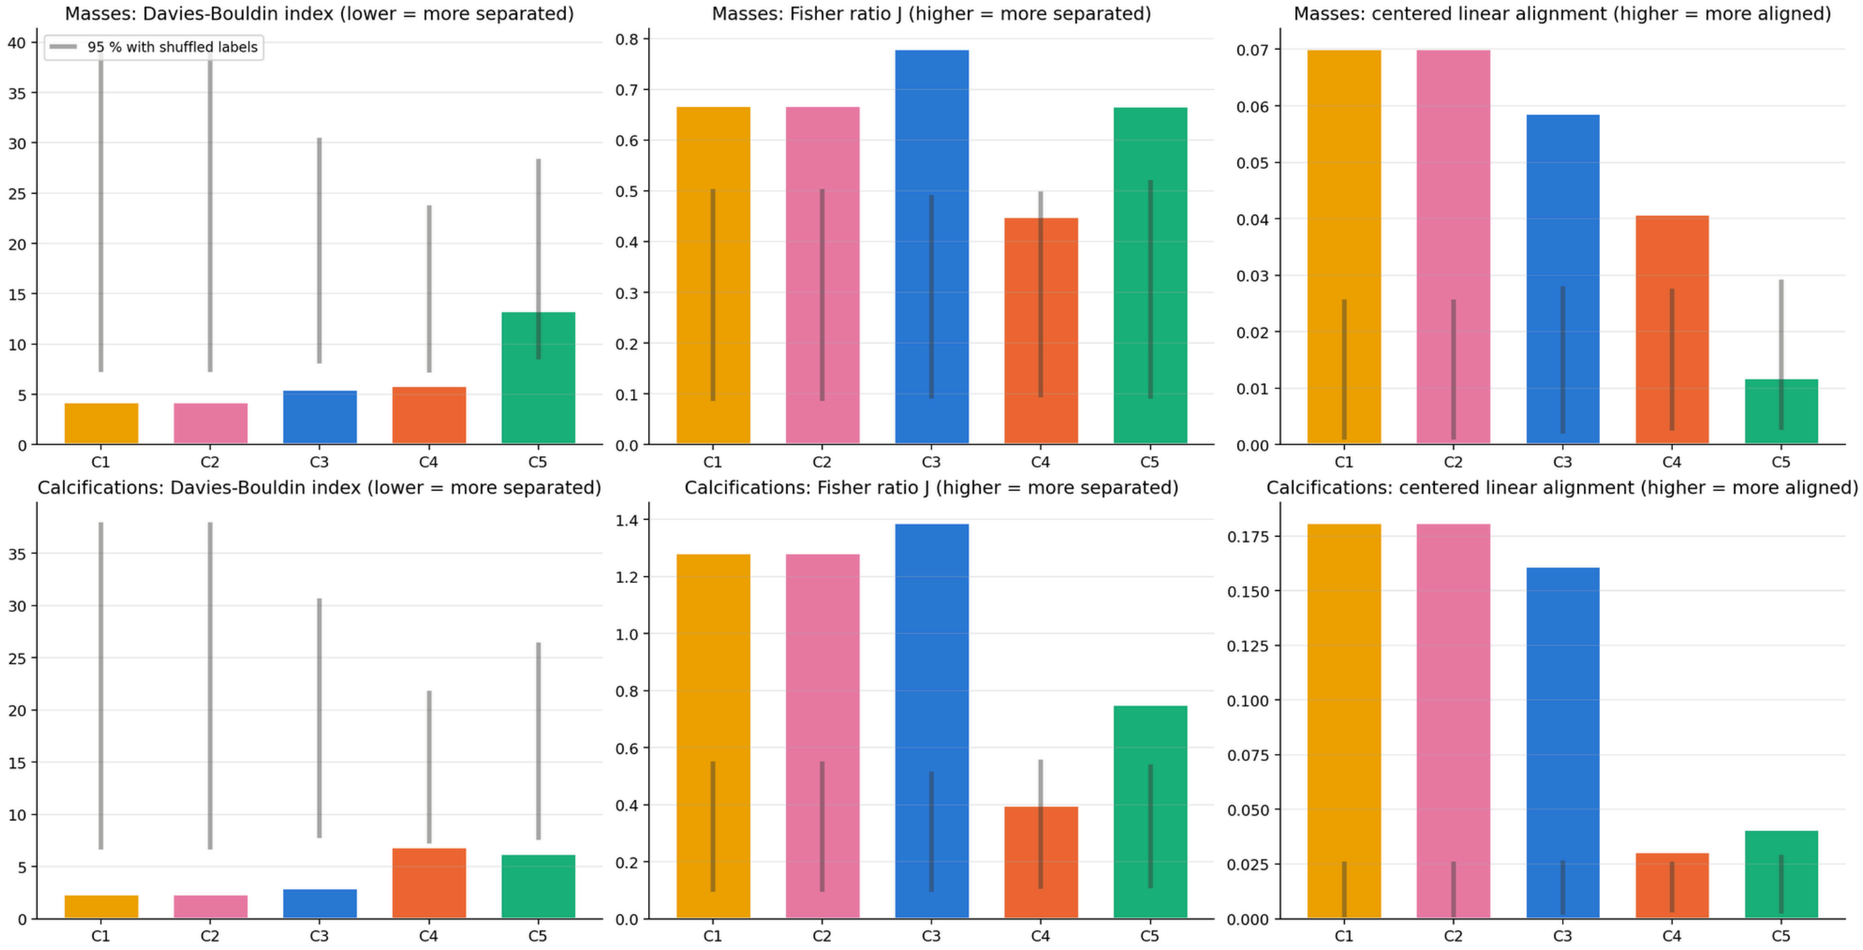

ANEXO 64

Figura 6.2.5 · t-SNE de las cinco representaciones

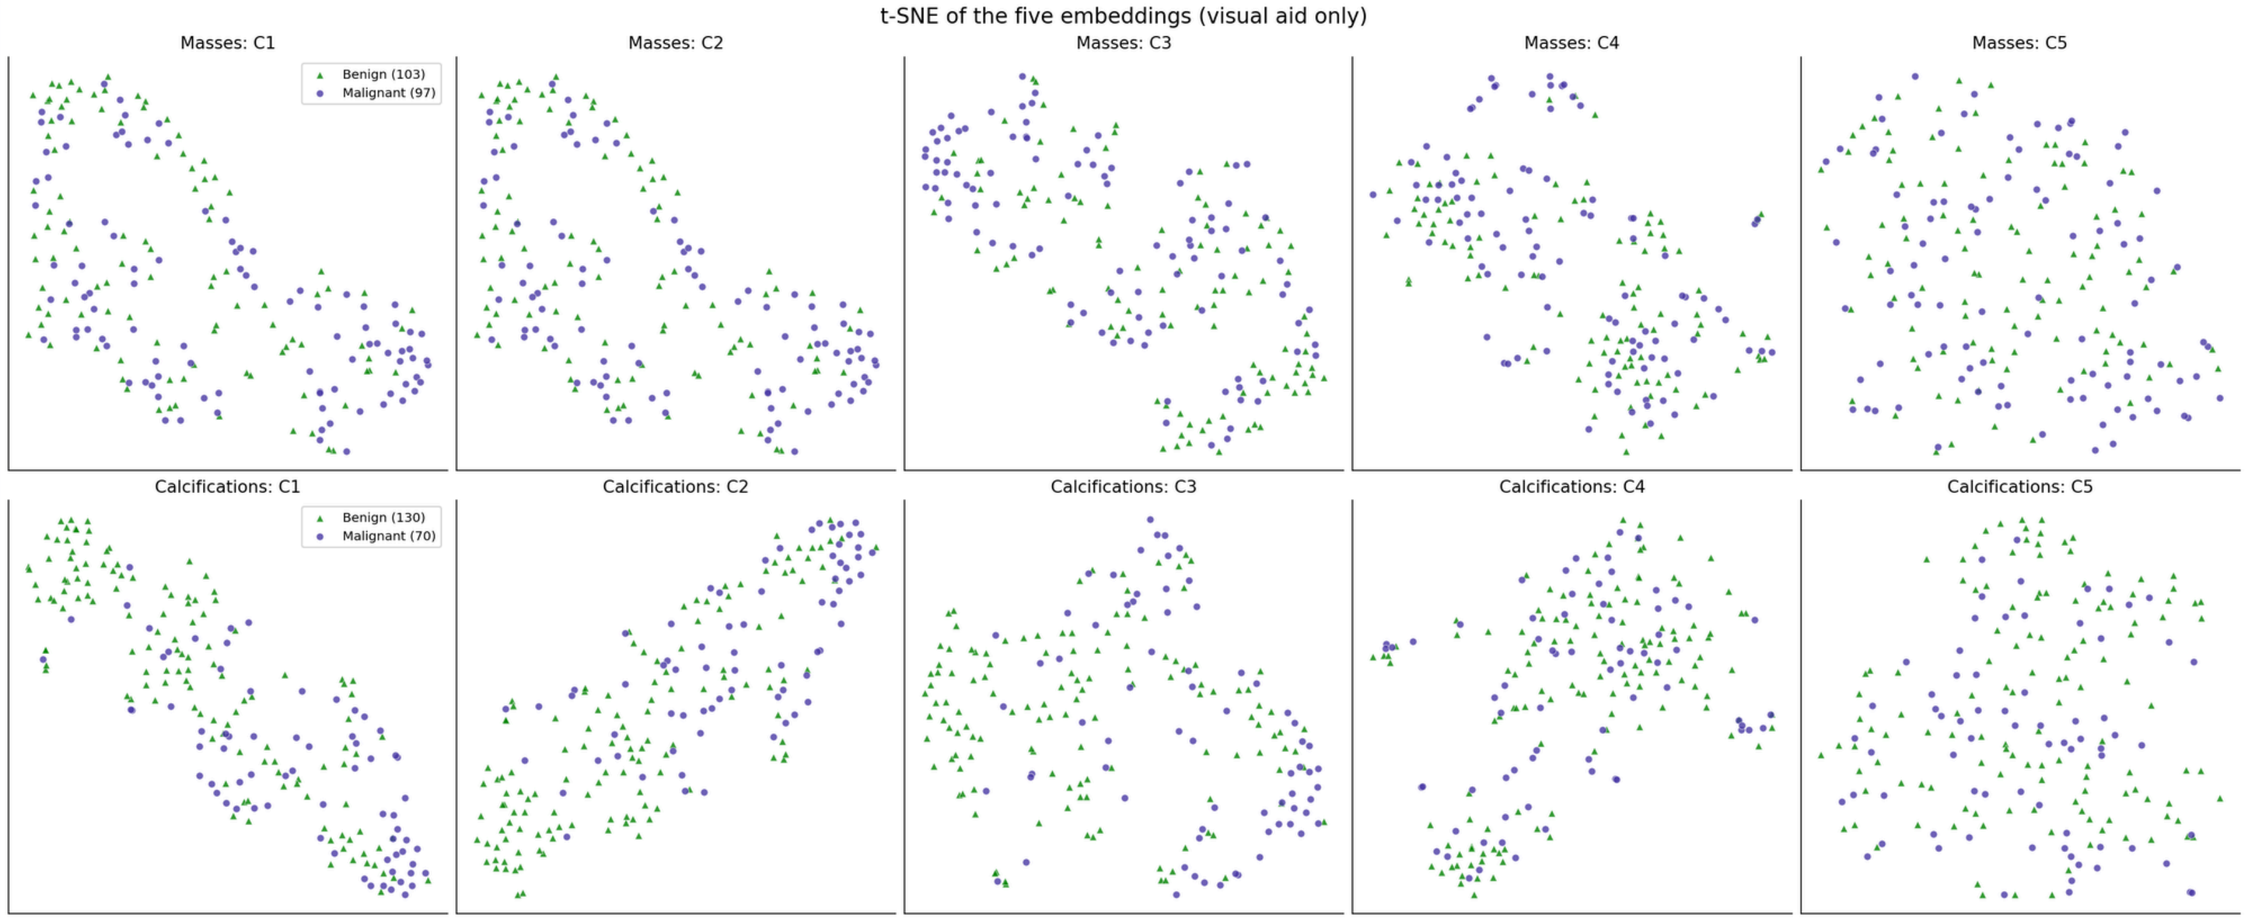

Figura 6.2.6 · Métricas en 20 submuestras y en todo el entrenamiento

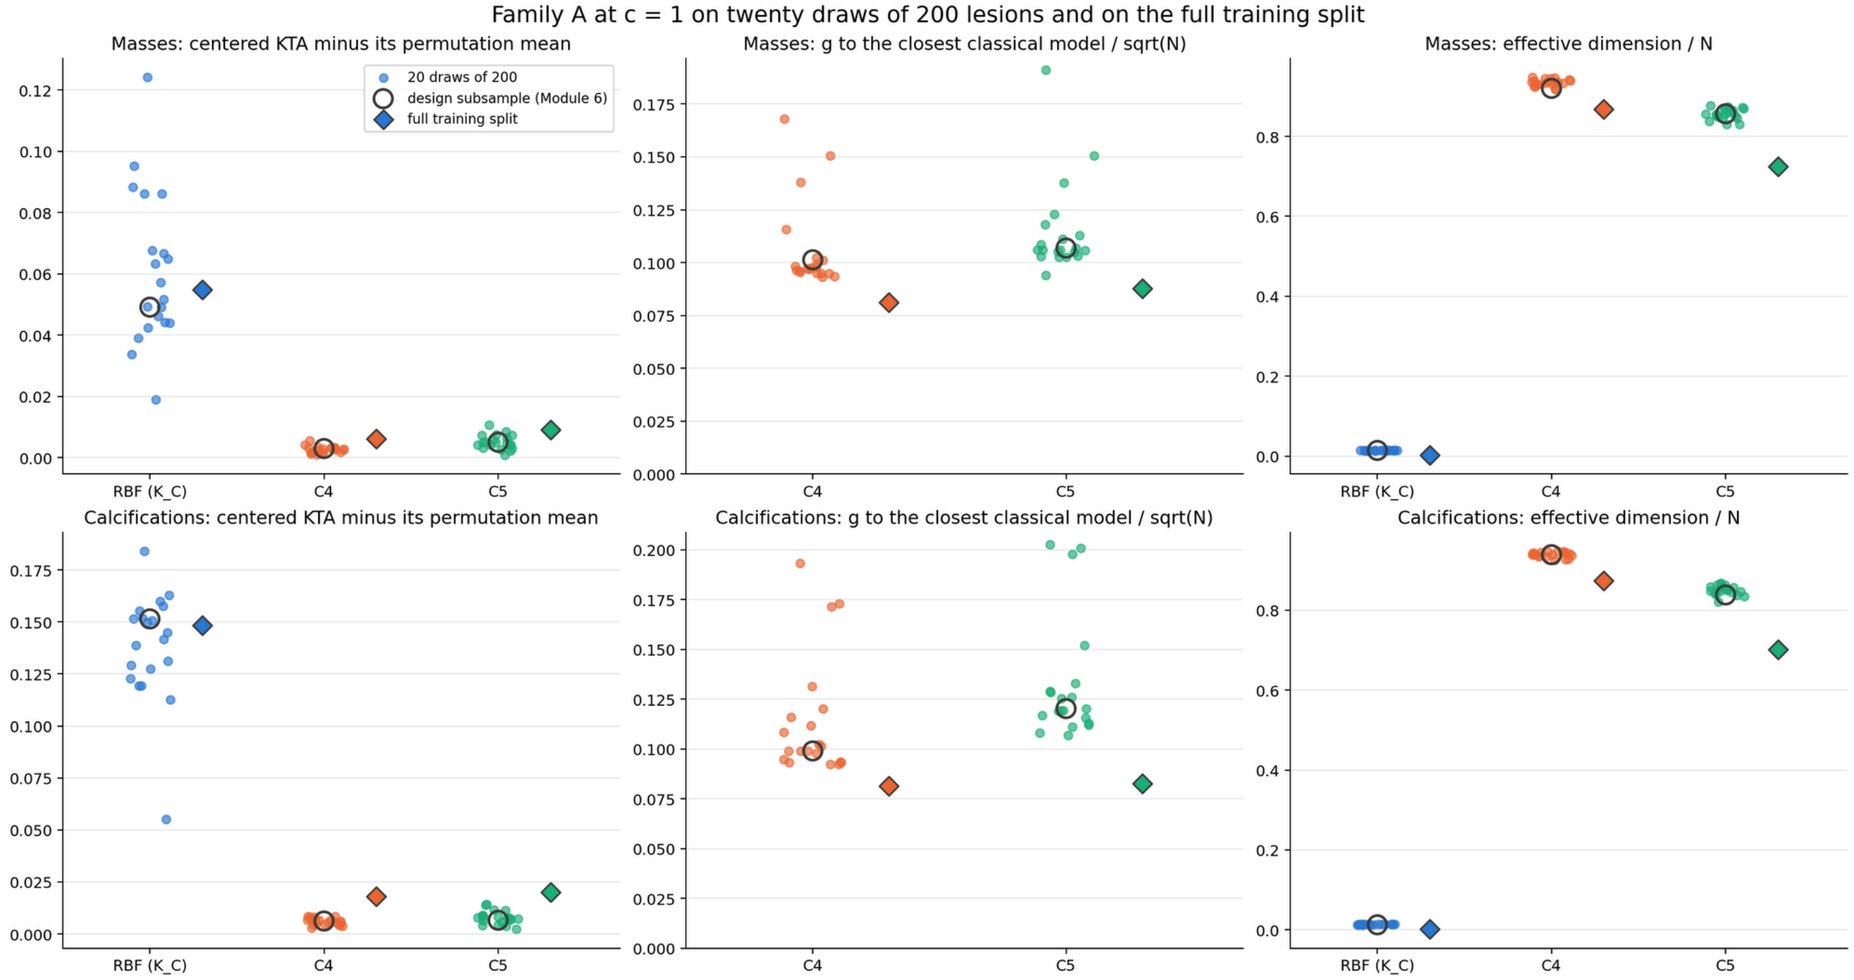

Figura 6.2.7 · AUC de pares contra la escala angular c

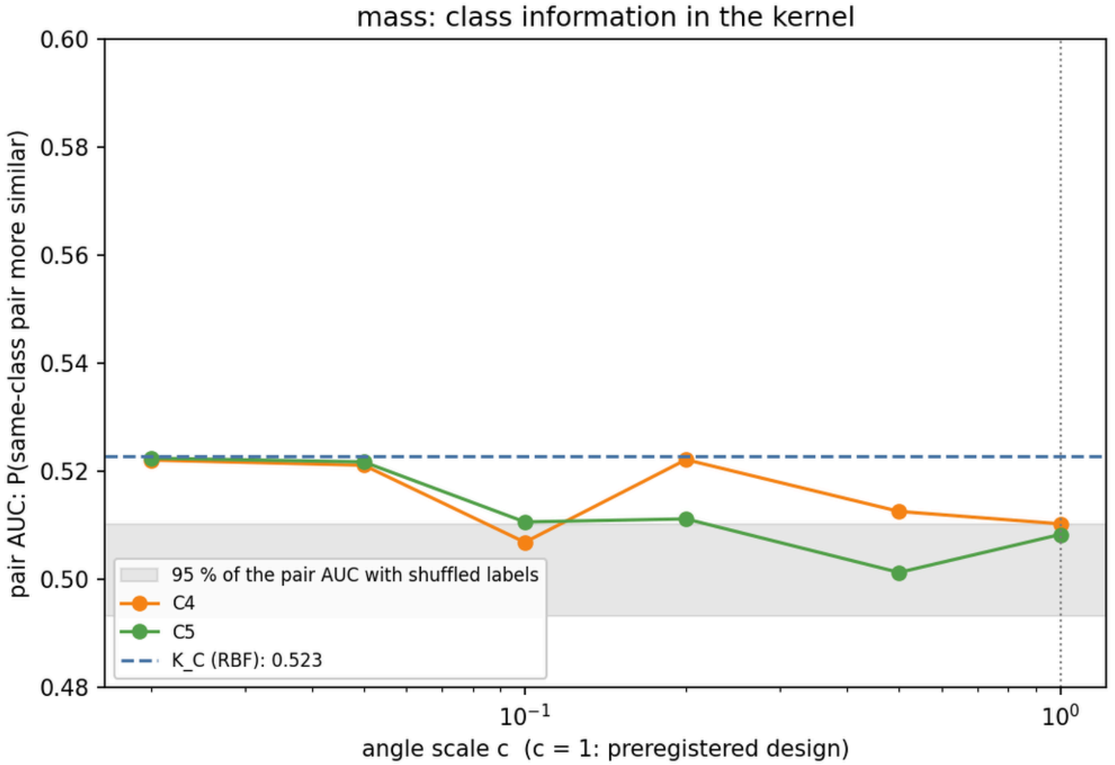

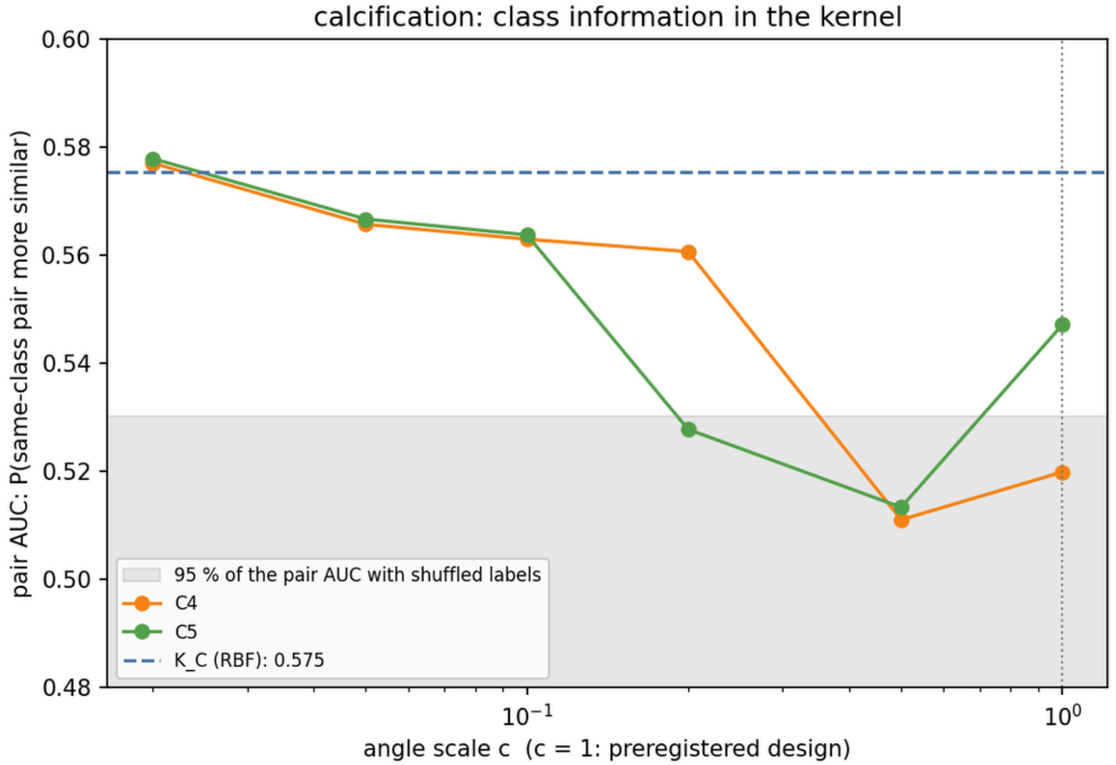

Figura 6.2.8 · Separabilidad con 12 y con 8 qubits

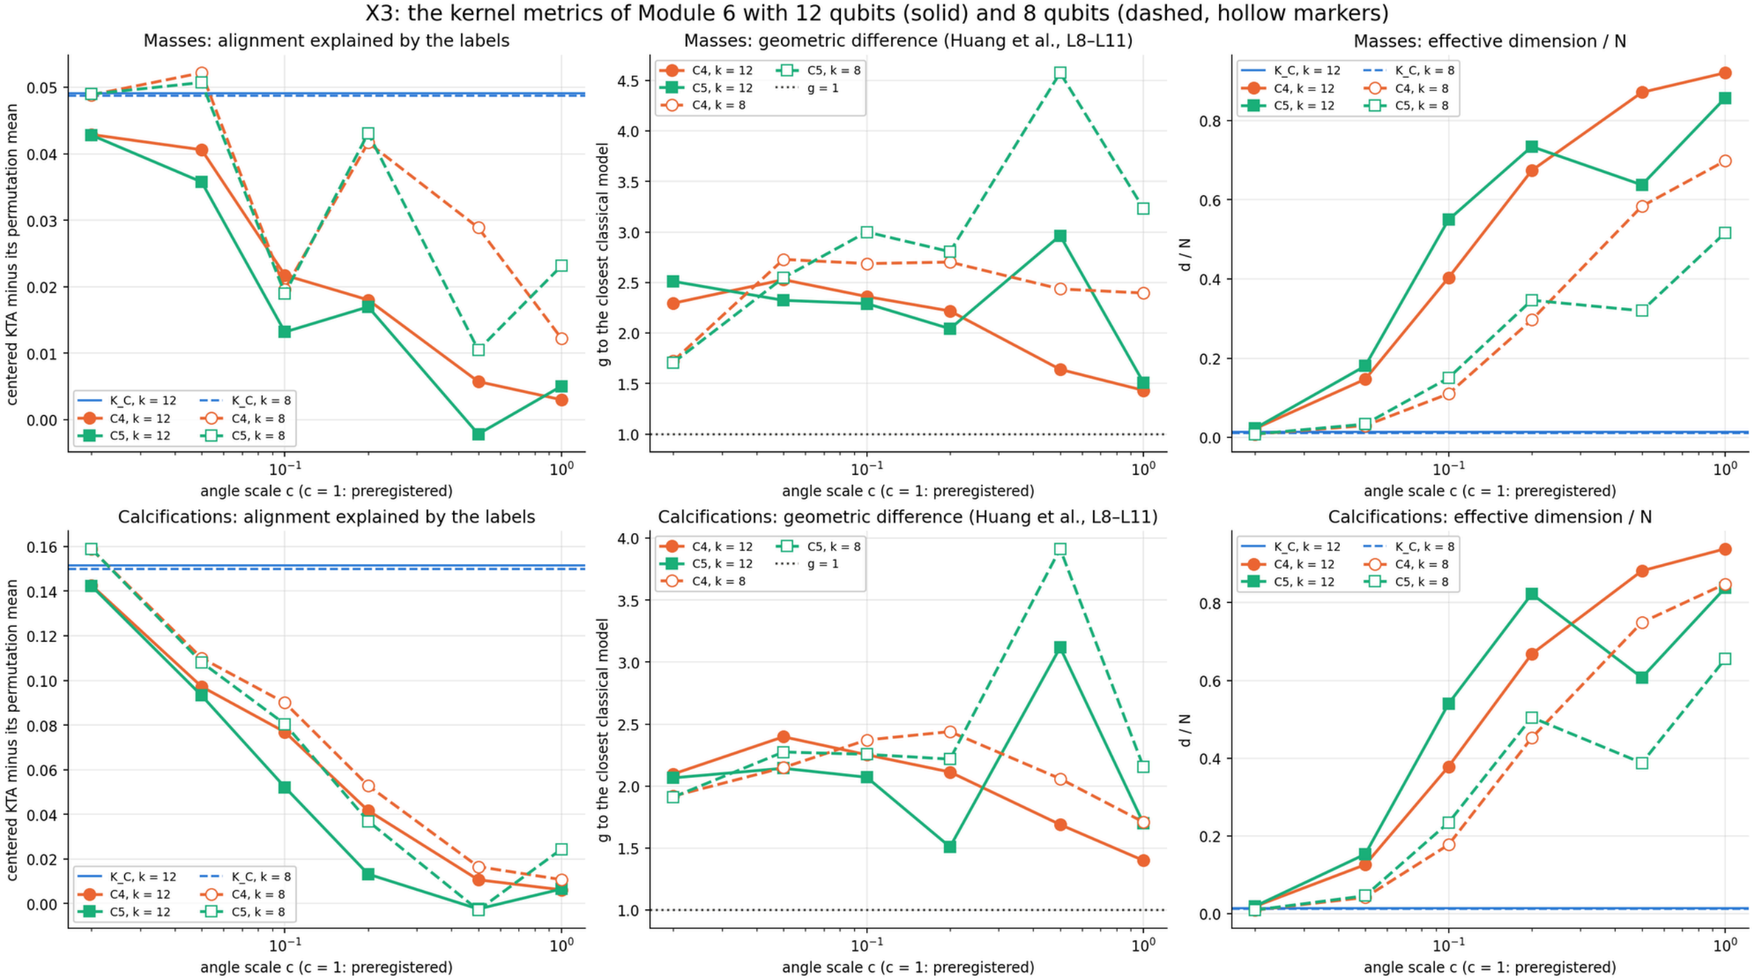

Figura 6.3.1 · AUC en validación cruzada y en prueba

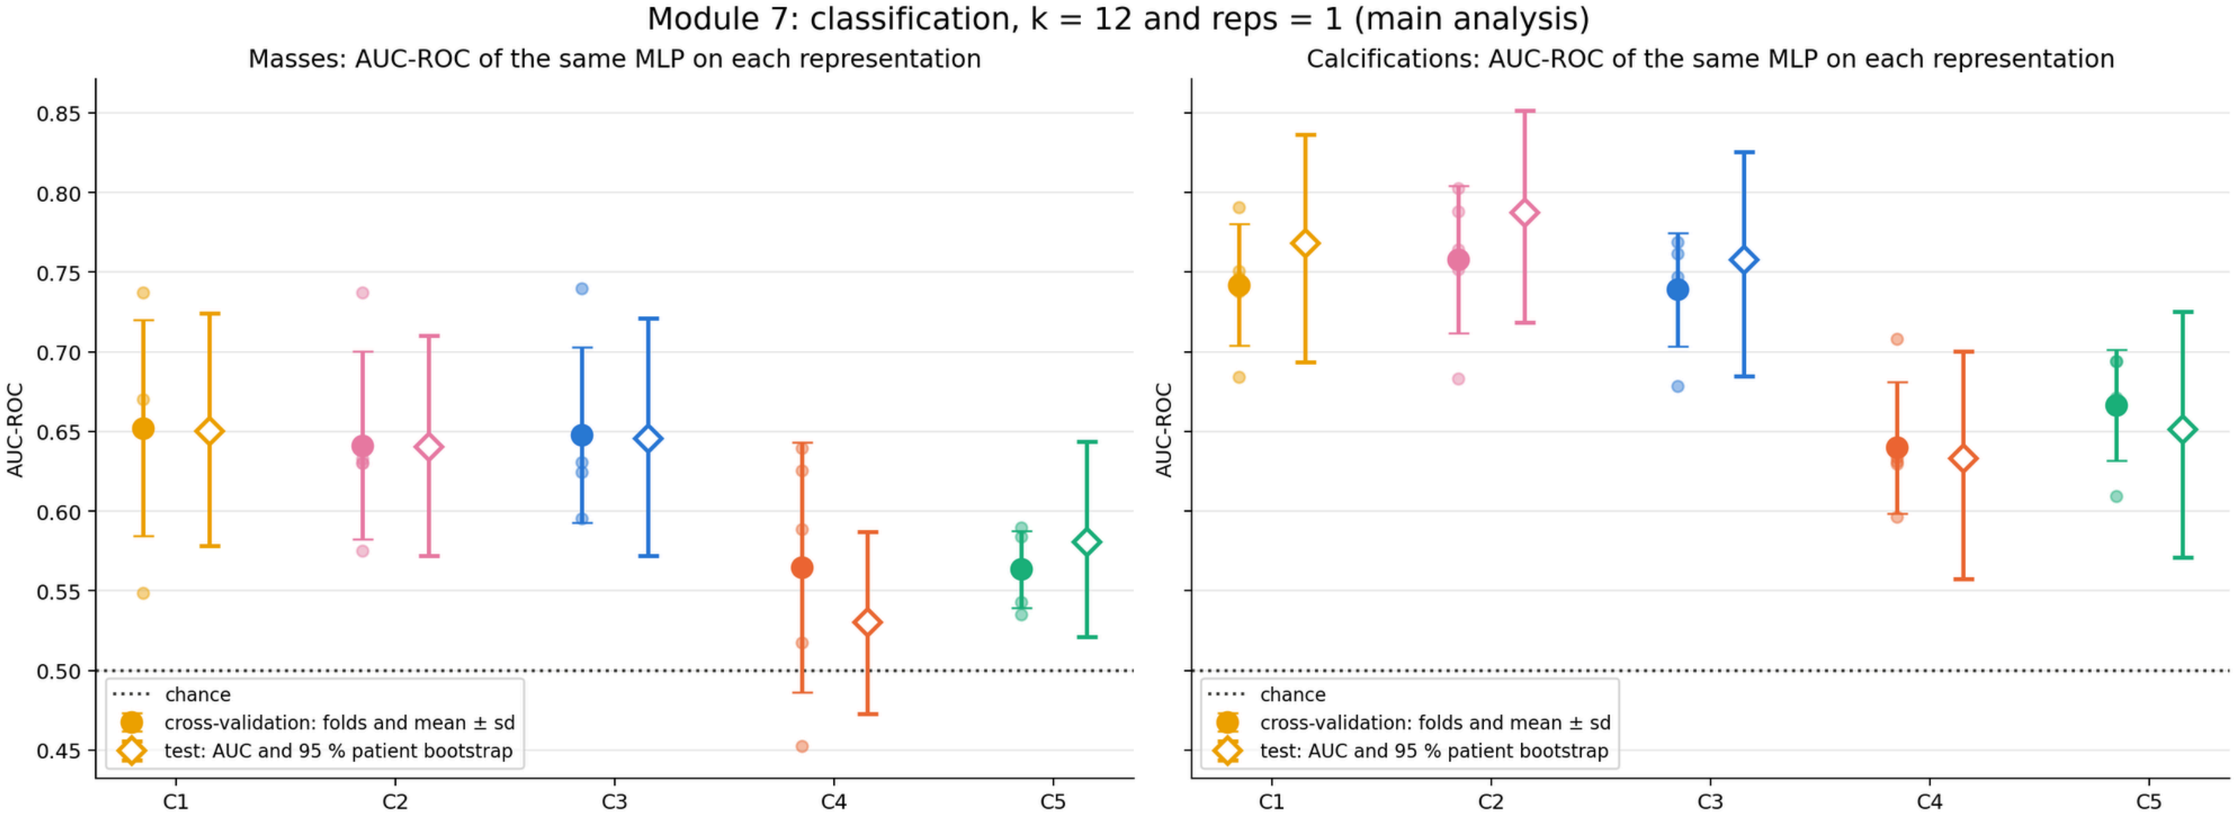

ANEXO 69

Figura 6.3.2 · Curvas ROC en el conjunto de prueba

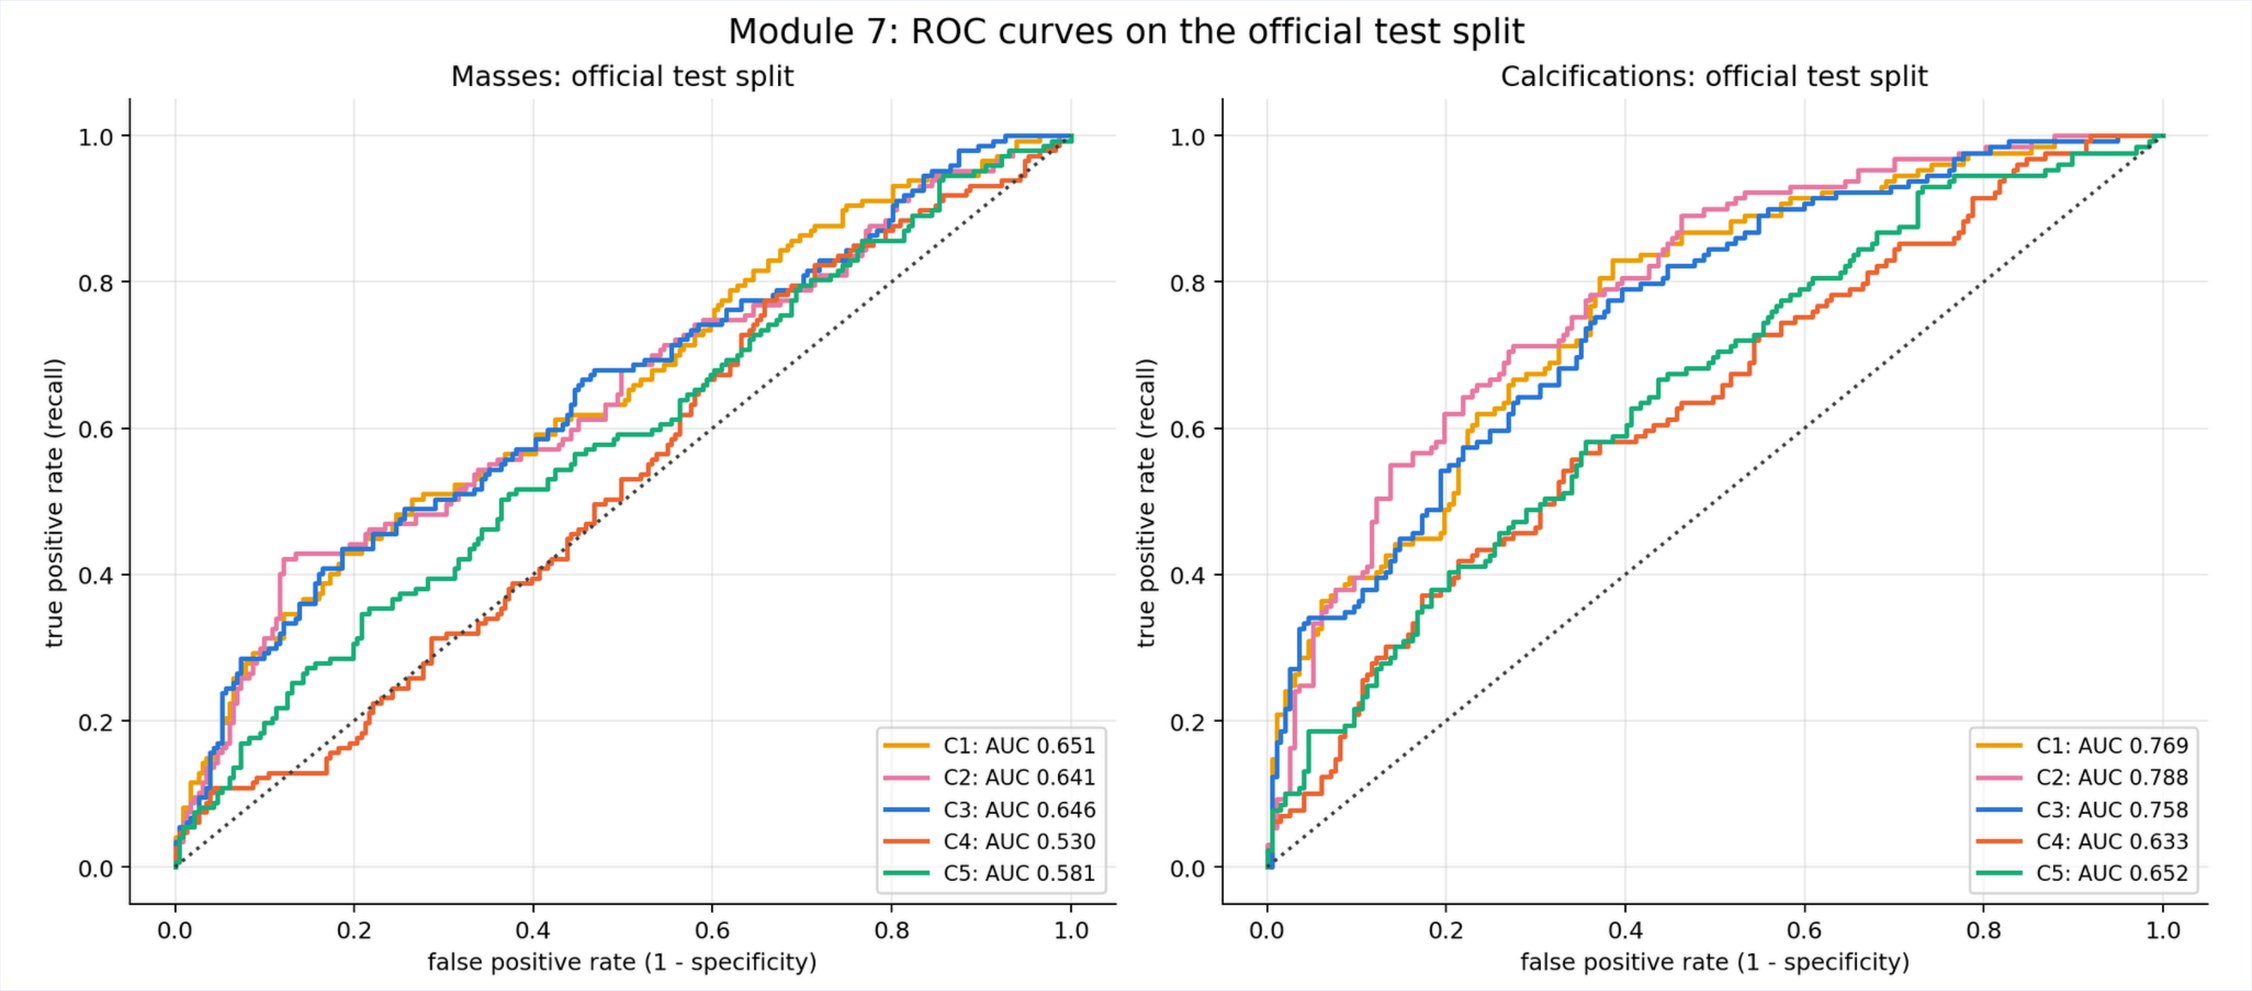

Figura 6.3.3 · Sensibilidad del MLP: semilla, red, escalado, reps y k

ANEXO 71

Figura 6.3.4 · Diez sorteos de θ

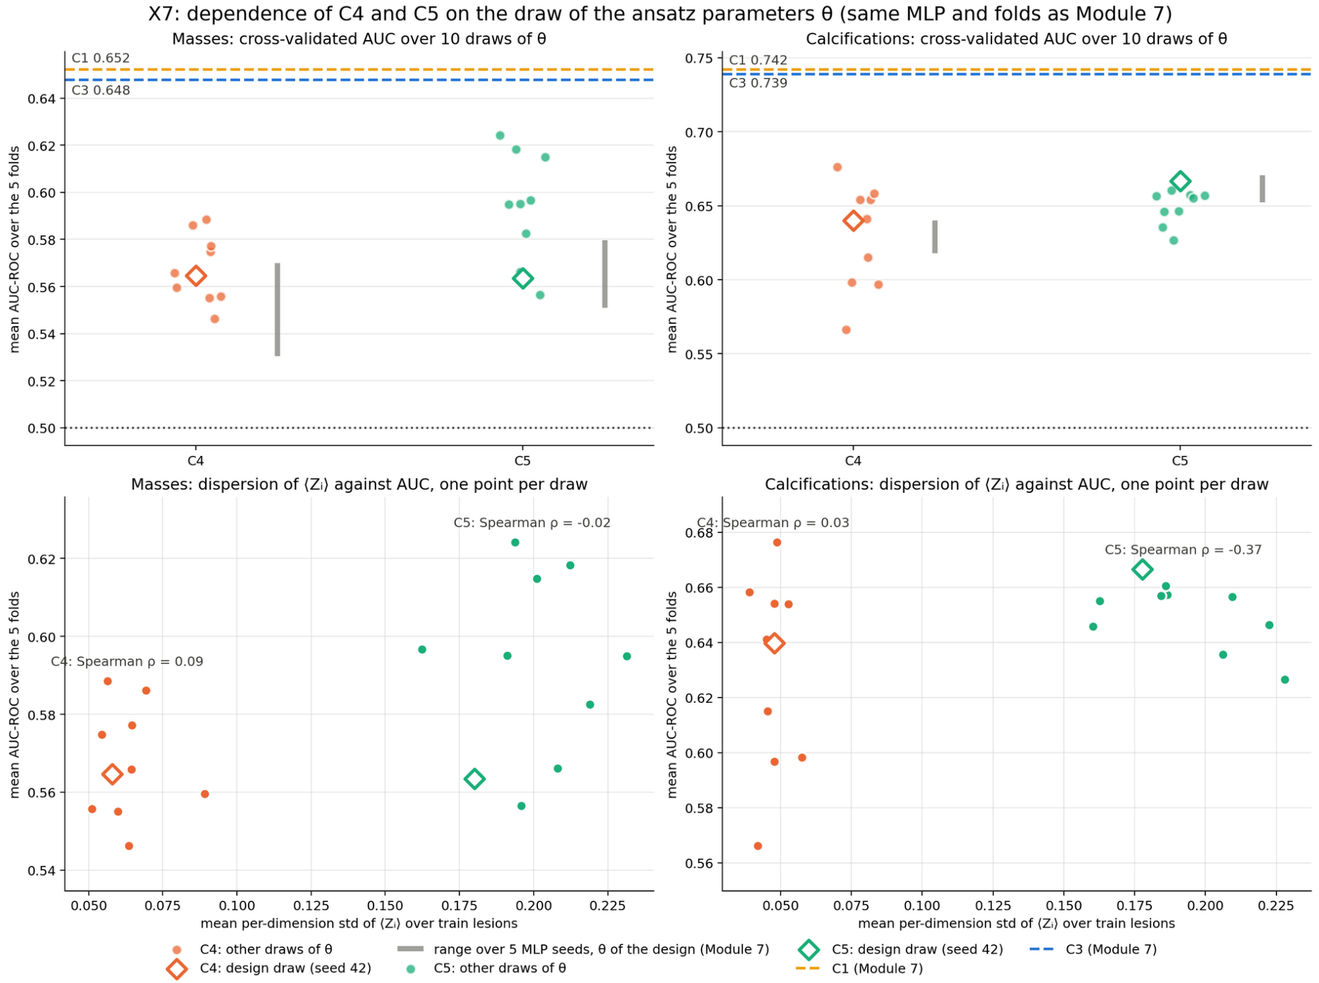

ANEXO 72

Figura 6.3.5 · θ entrenado frente a θ fijo

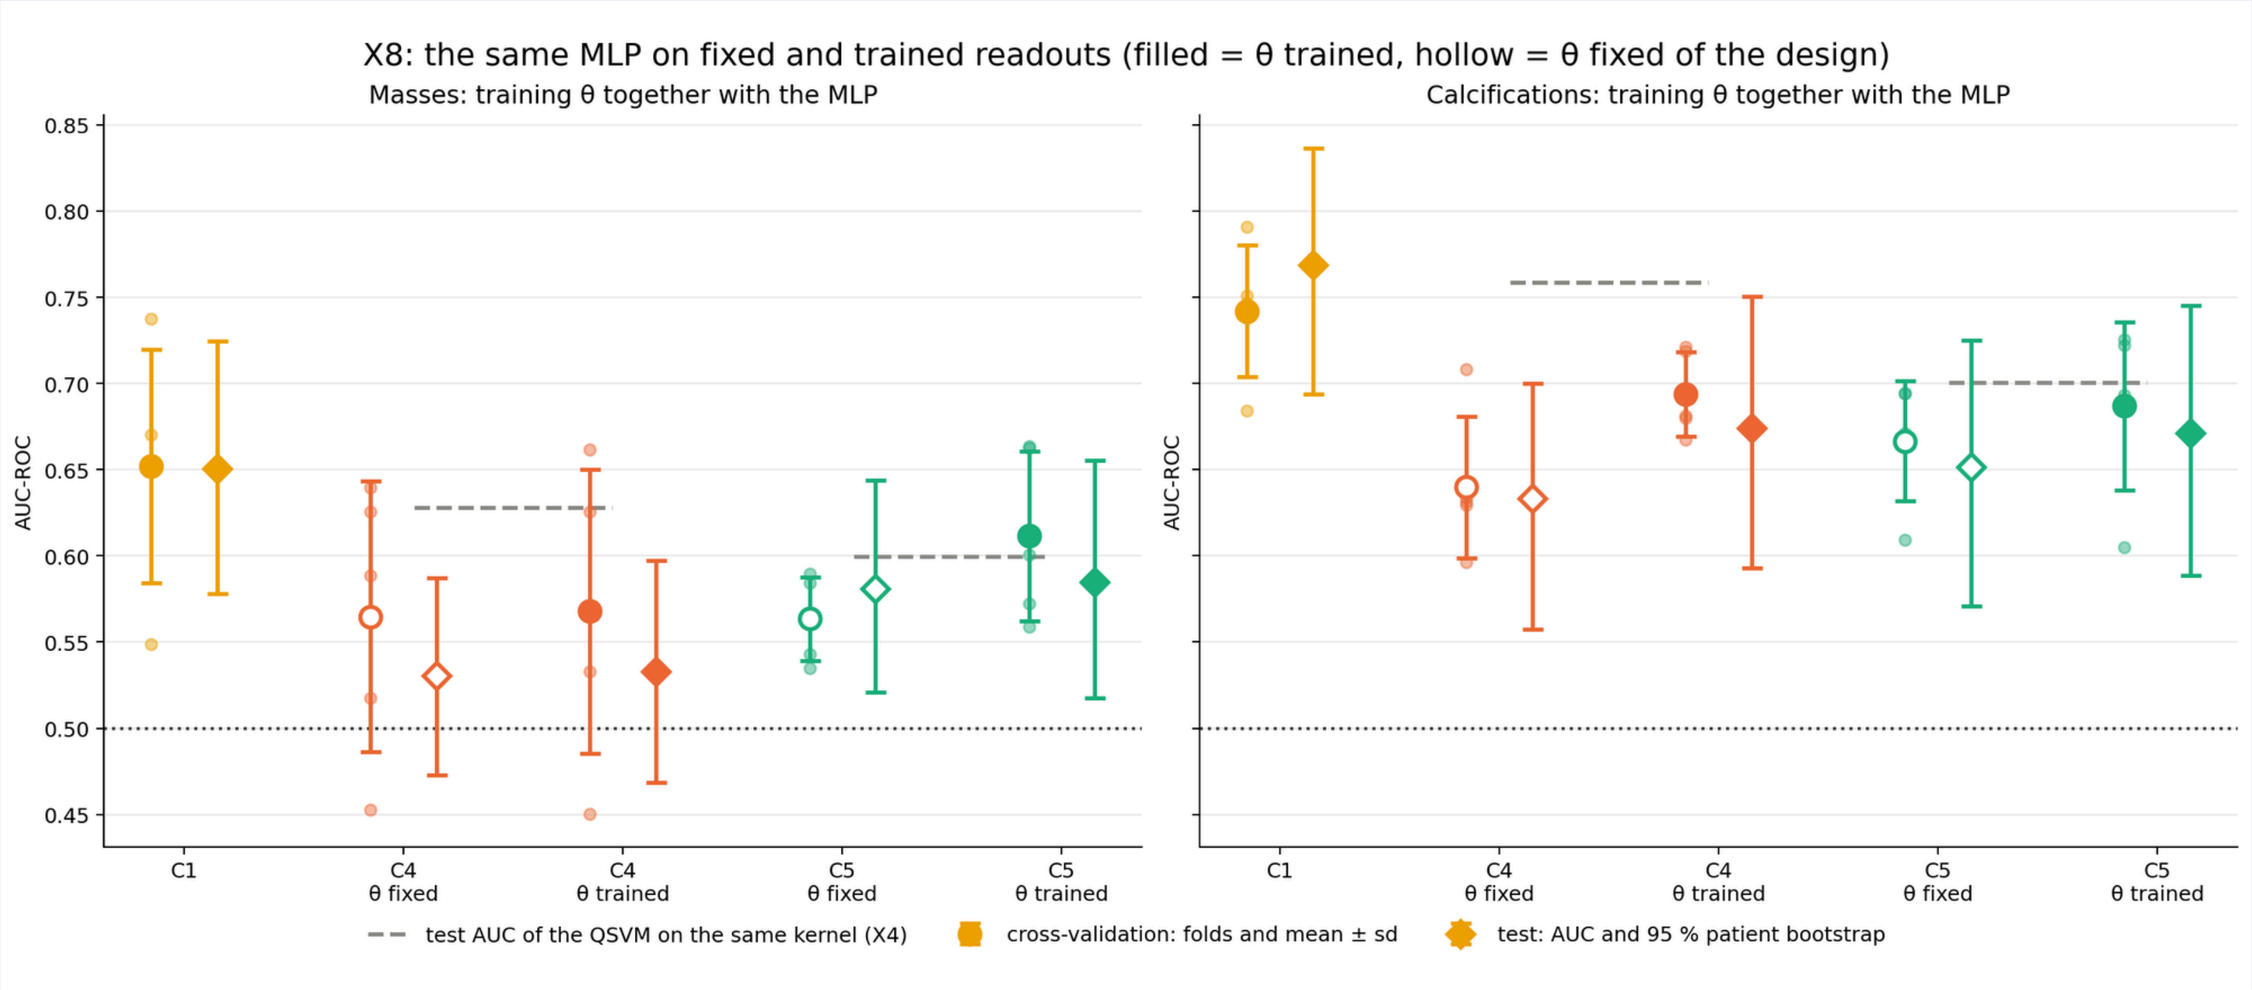

ANEXO 73

Figura 6.3.6 · Árboles, *random forest* y XGBoost sobre C1–C5

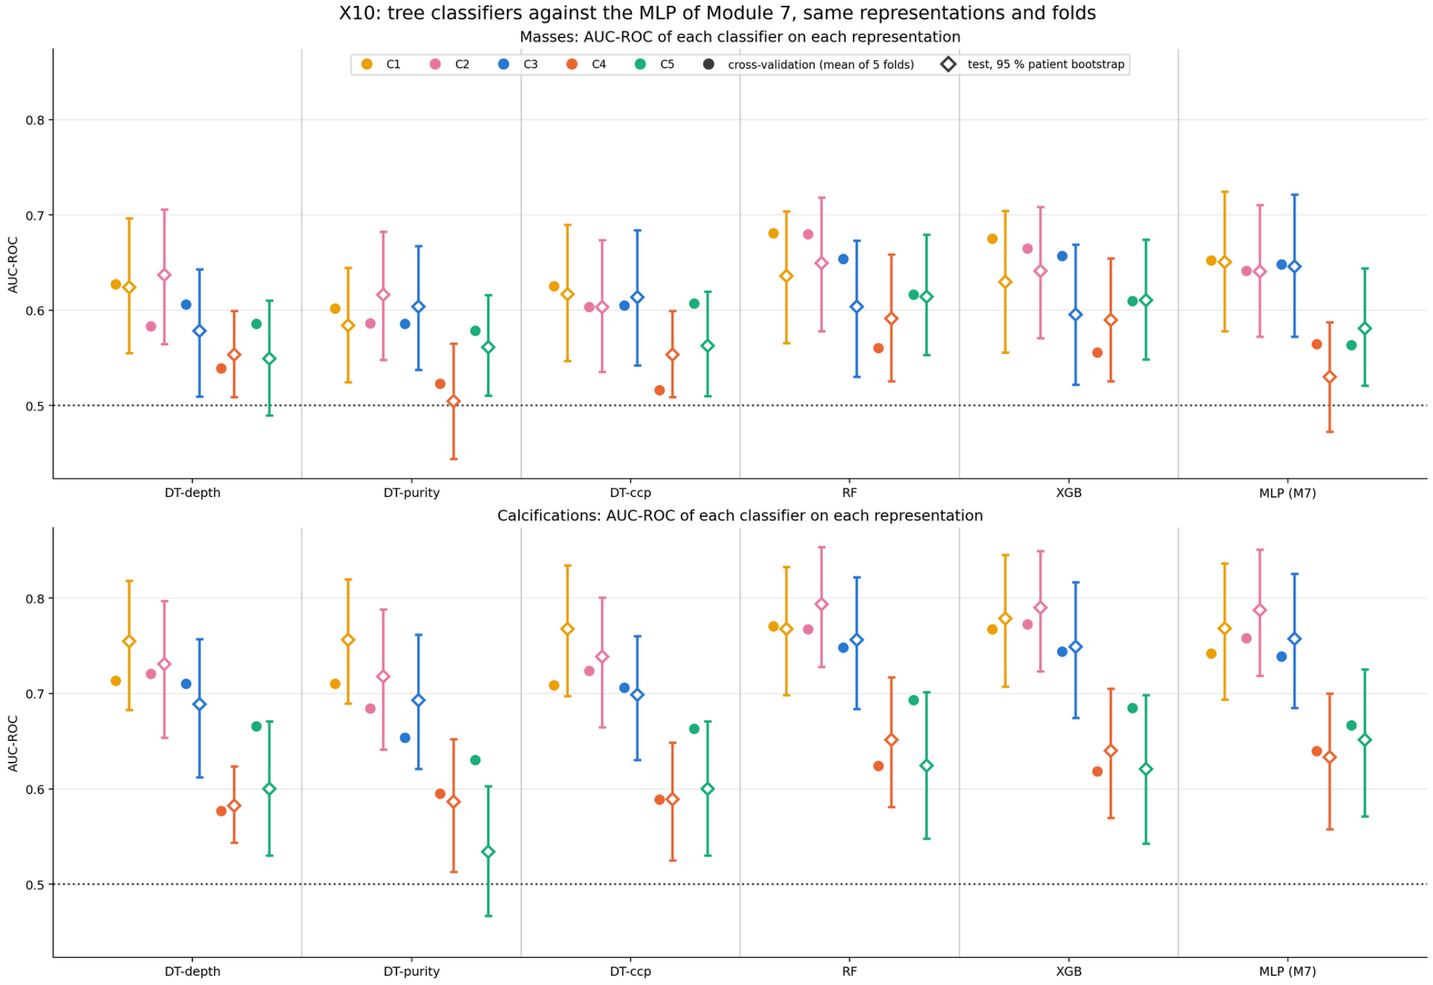

ANEXO 74

Figura 6.3.7 · Criterios de parada de un árbol

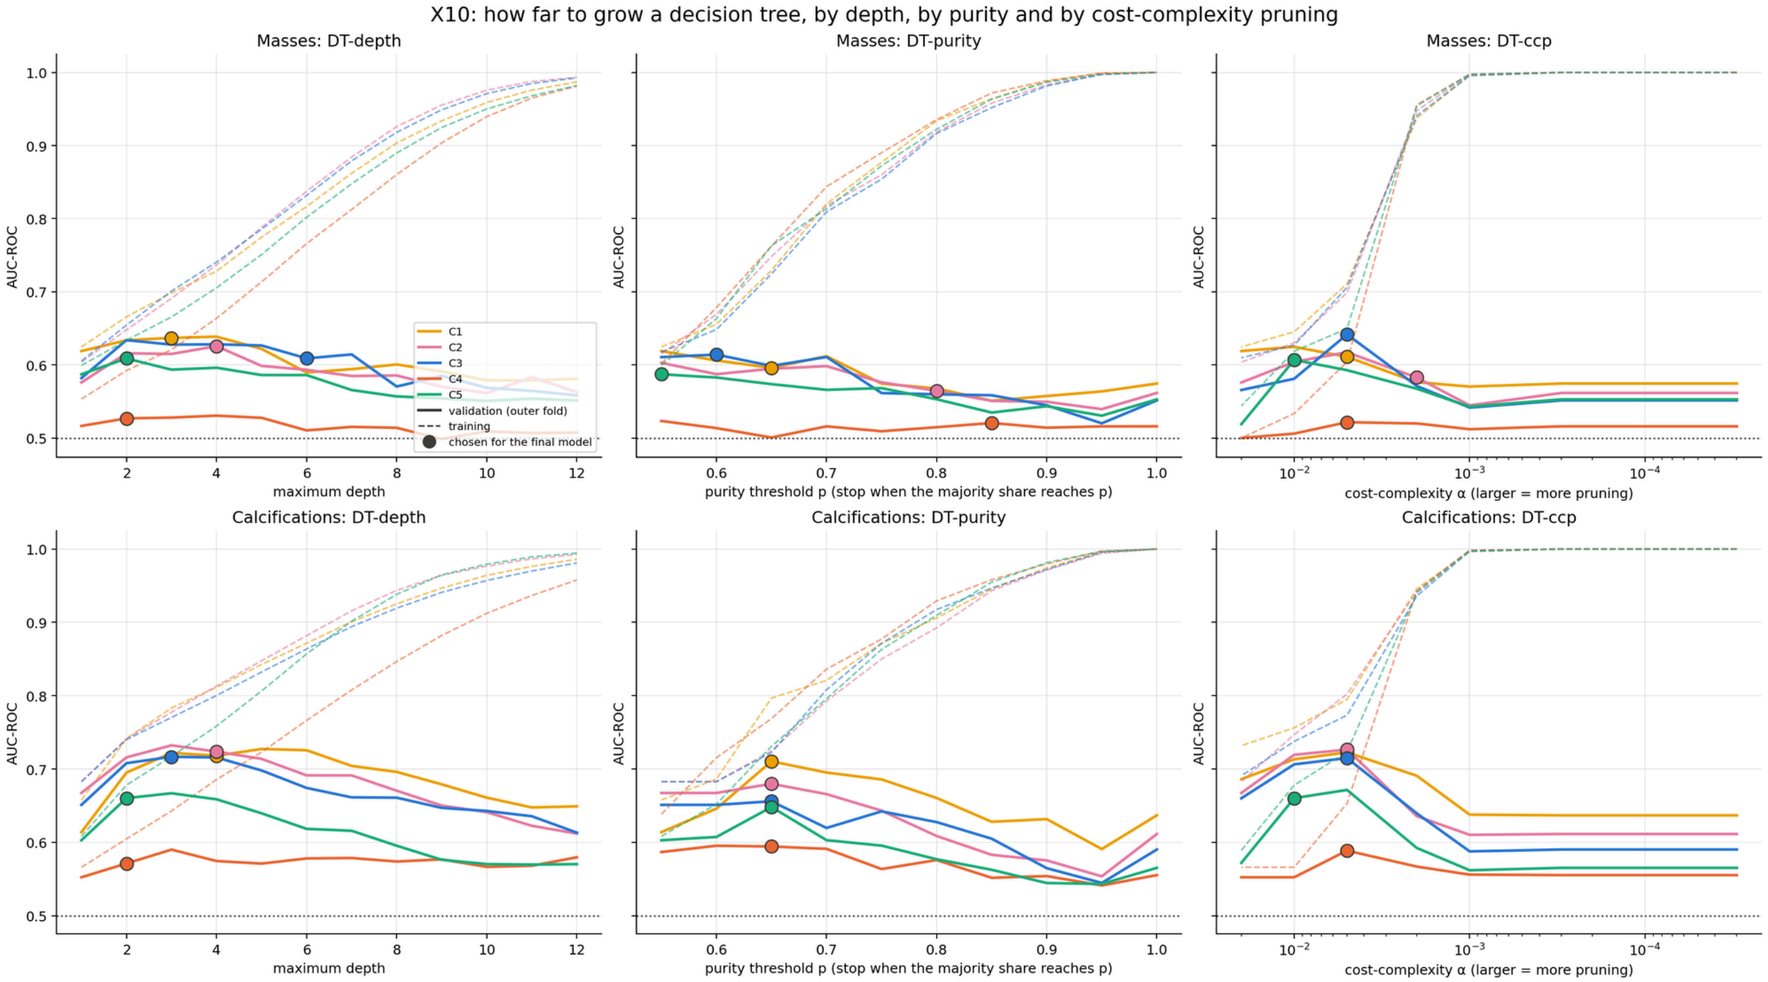

Figura 6.4.1 · QSVM, SVM RBF y MLP sobre $\langle Z_i \rangle$

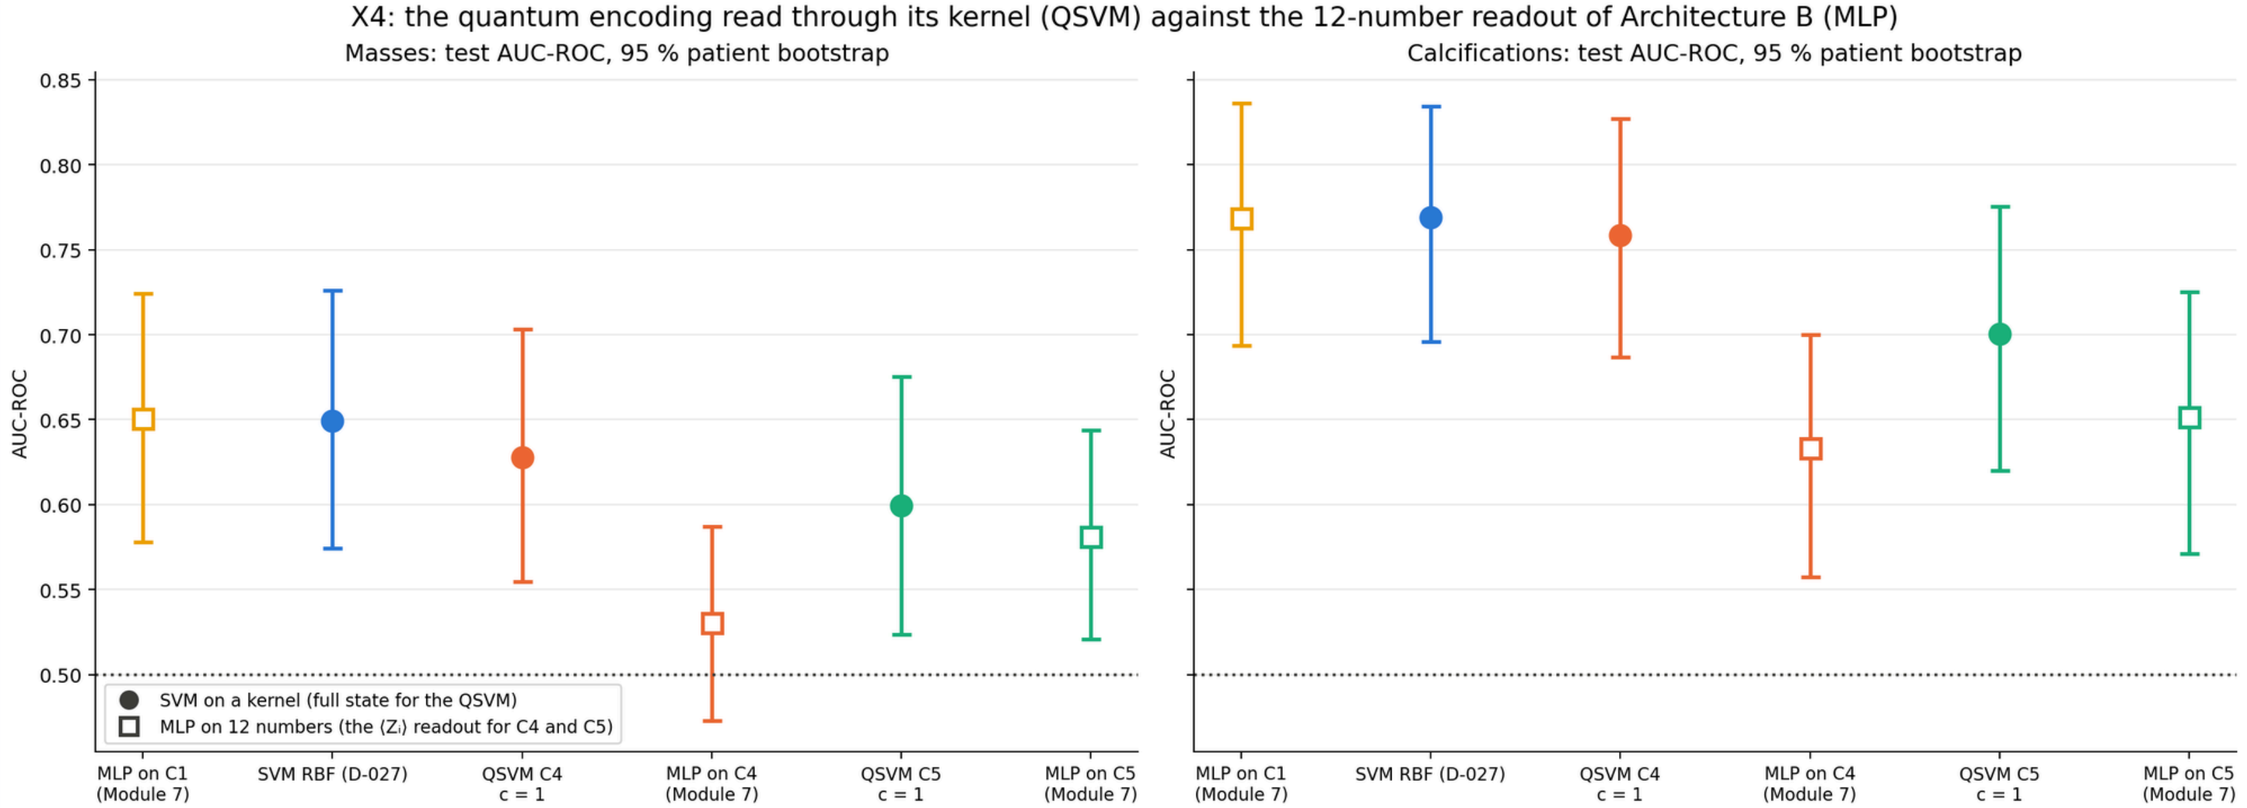

Figura 6.4.2 · Las 67 características con codificaciones alternativas

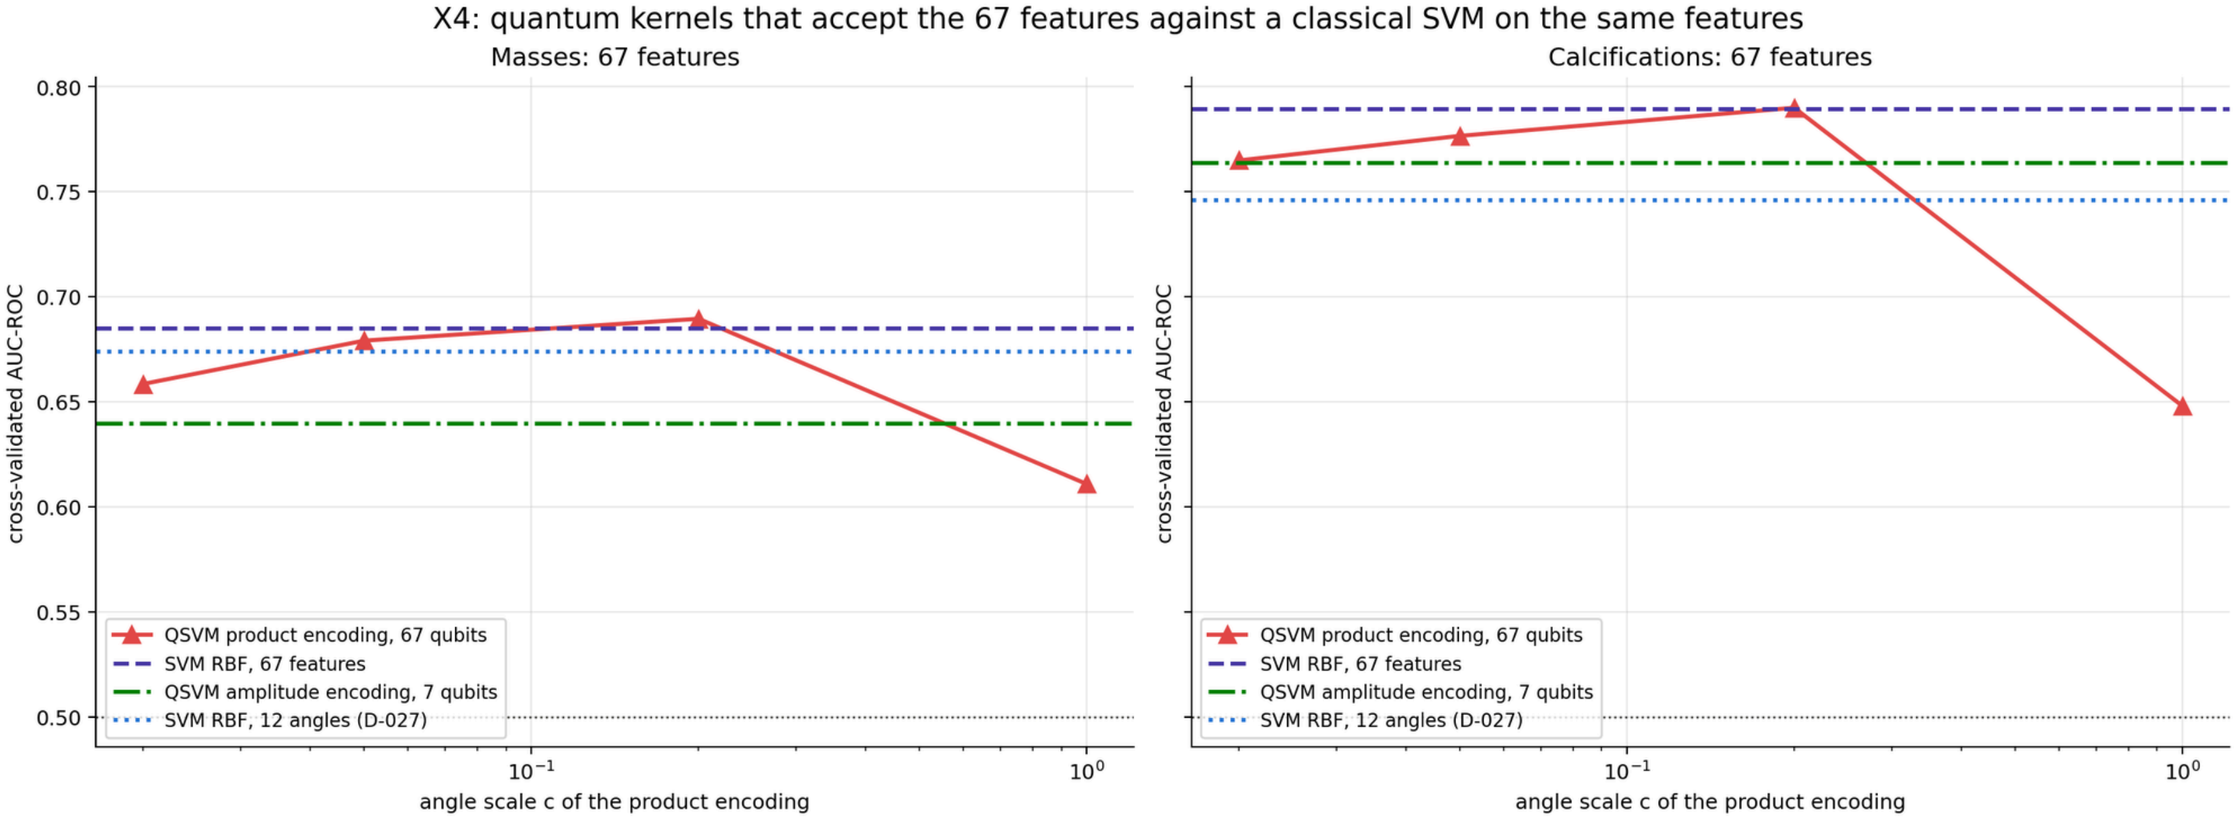

ANEXO 77

Figura 6.4.3 · Búsqueda anidada de ventaja cuántica

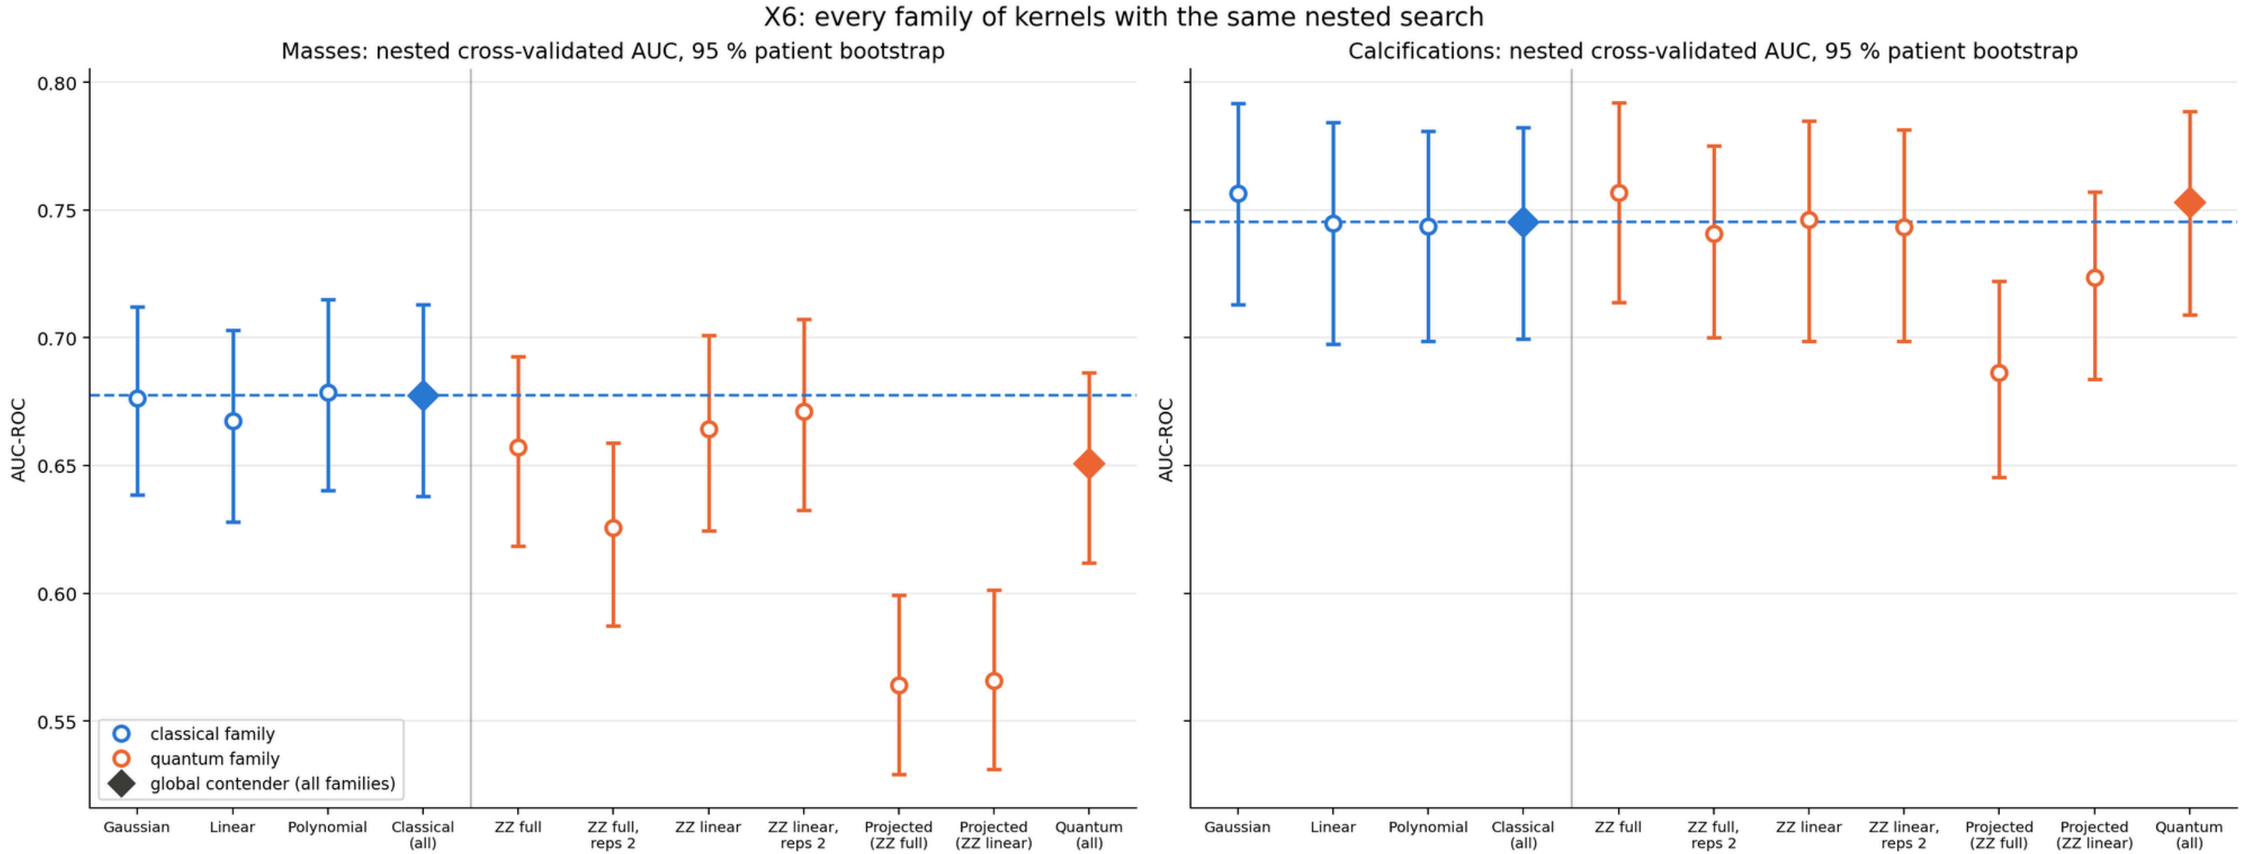

Figura 6.4.4 · Etiquetado diseñado según Huang et al.

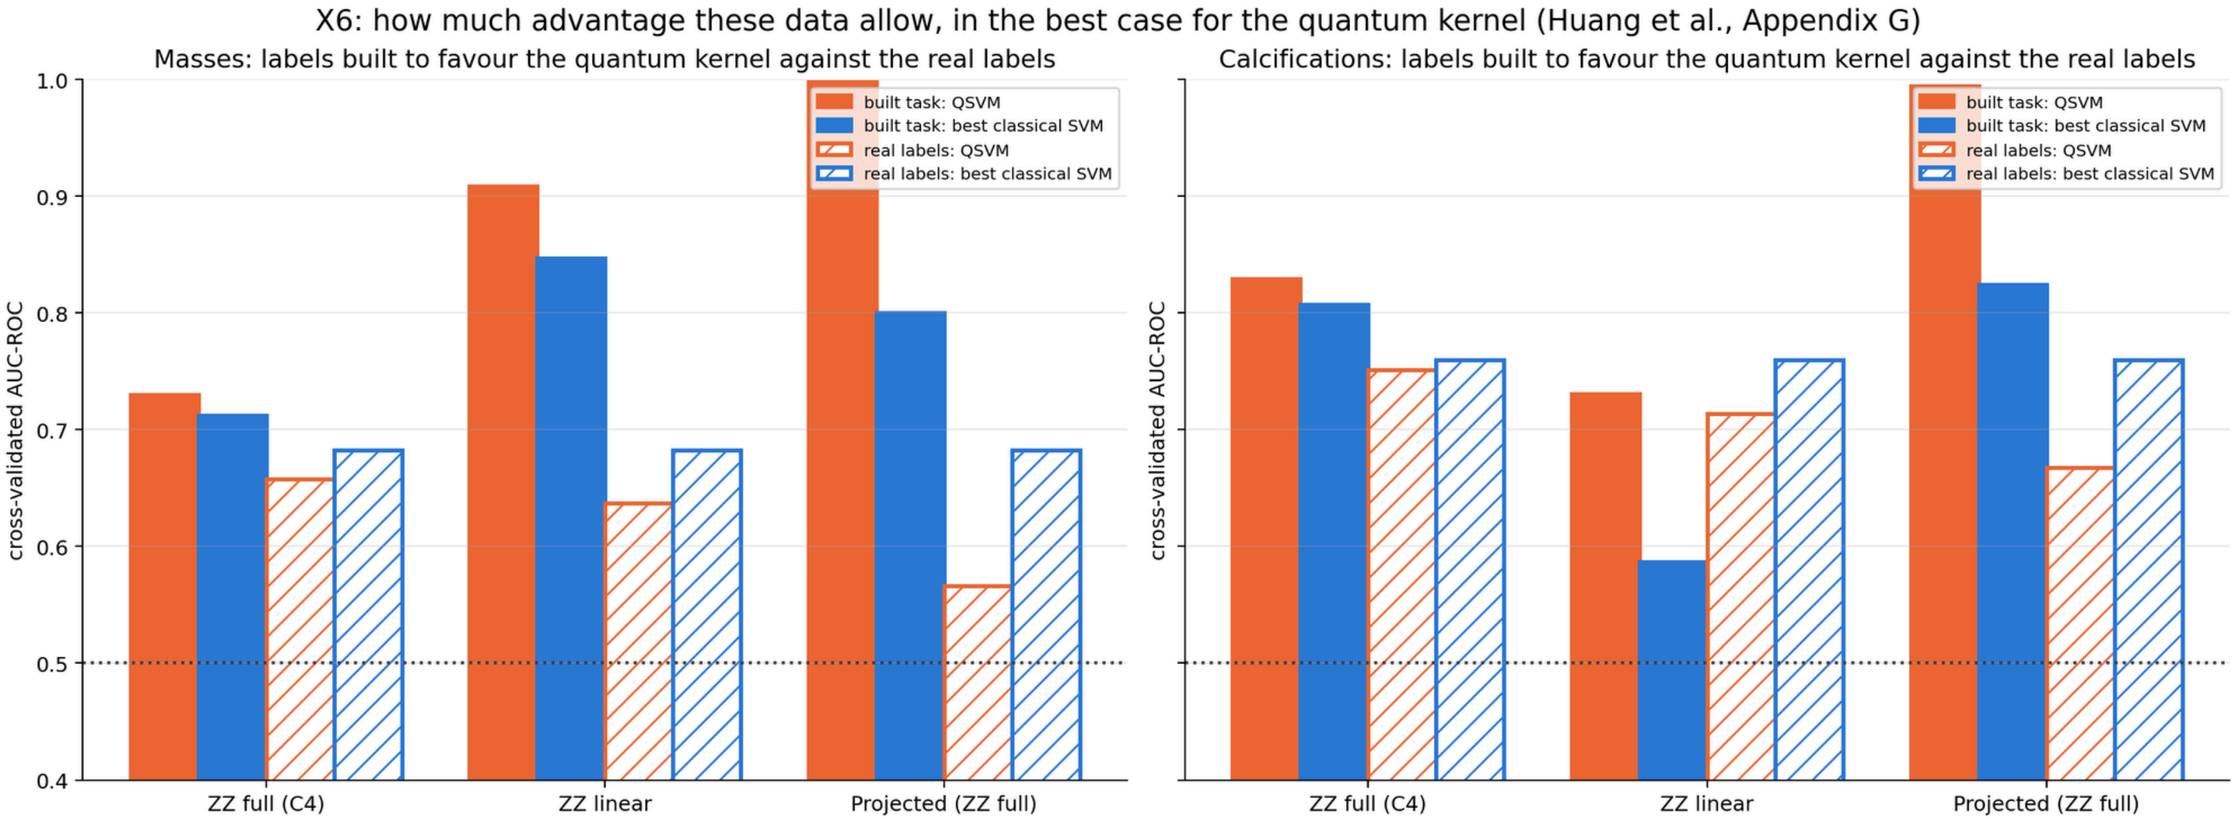

ANEXO 79

Figura 6.4.5 · Transición hacia las etiquetas diseñadas (X11)

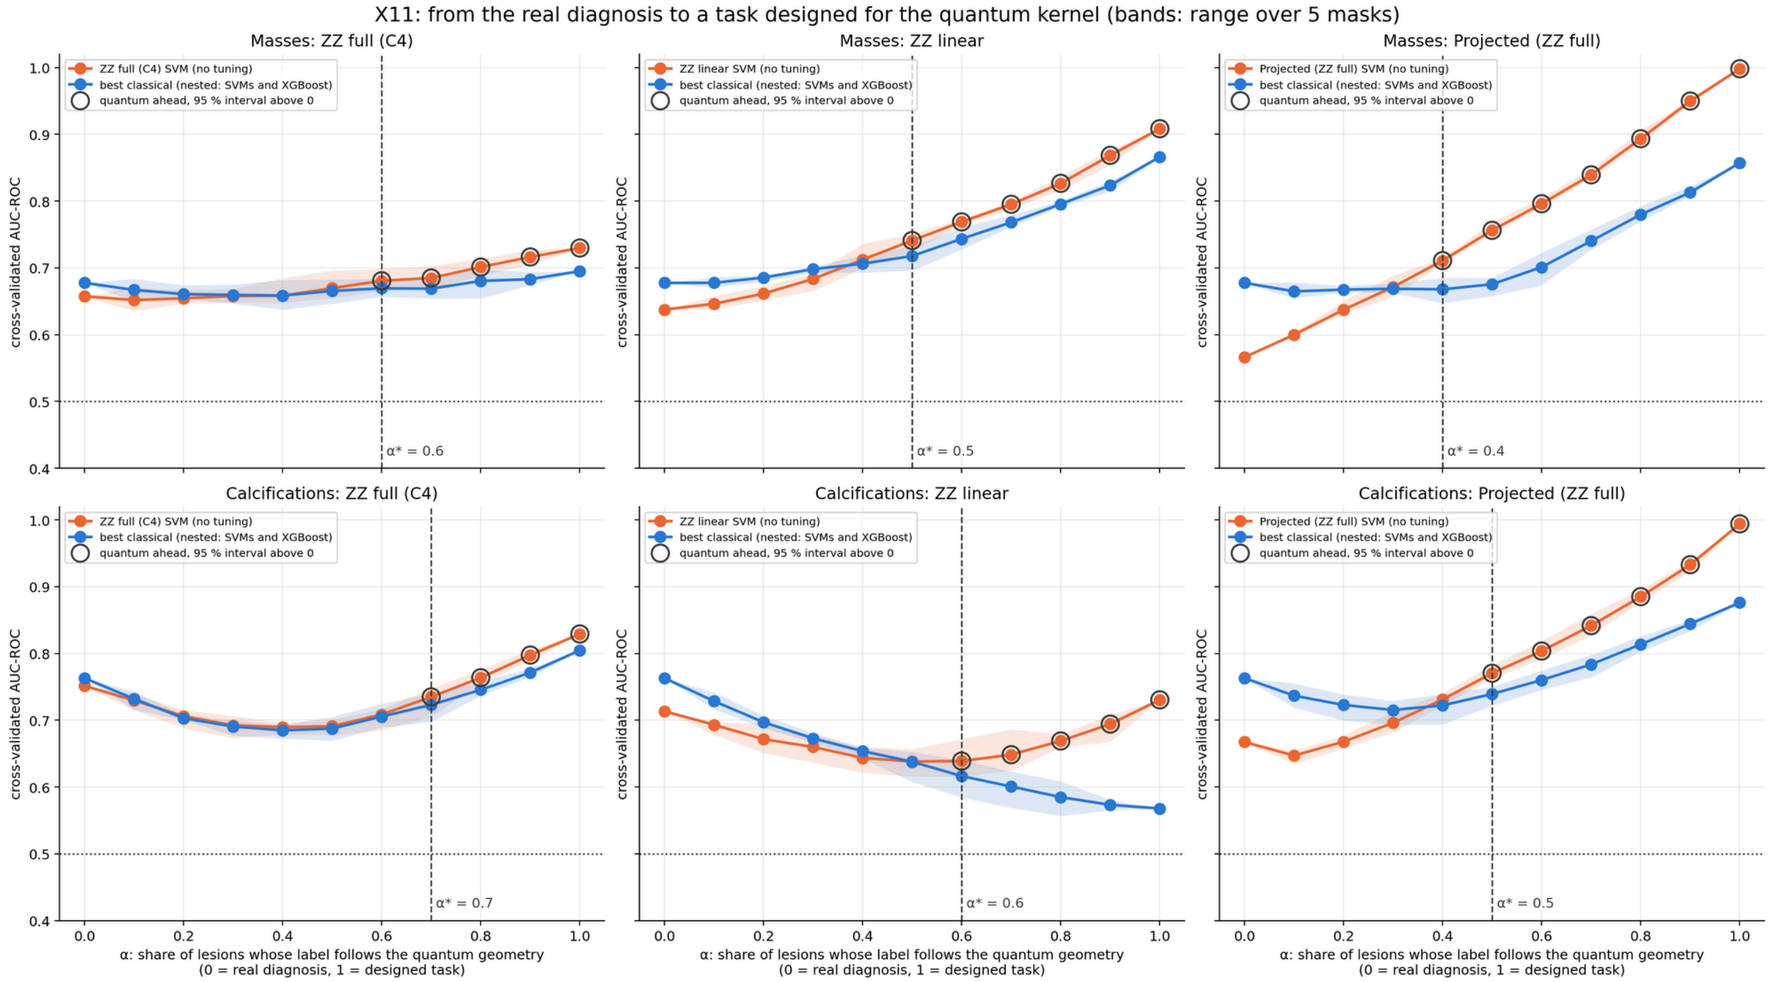

ANEXO 80

Figura 6.5.1 · Correlación de Spearman entre separabilidad y clasificación

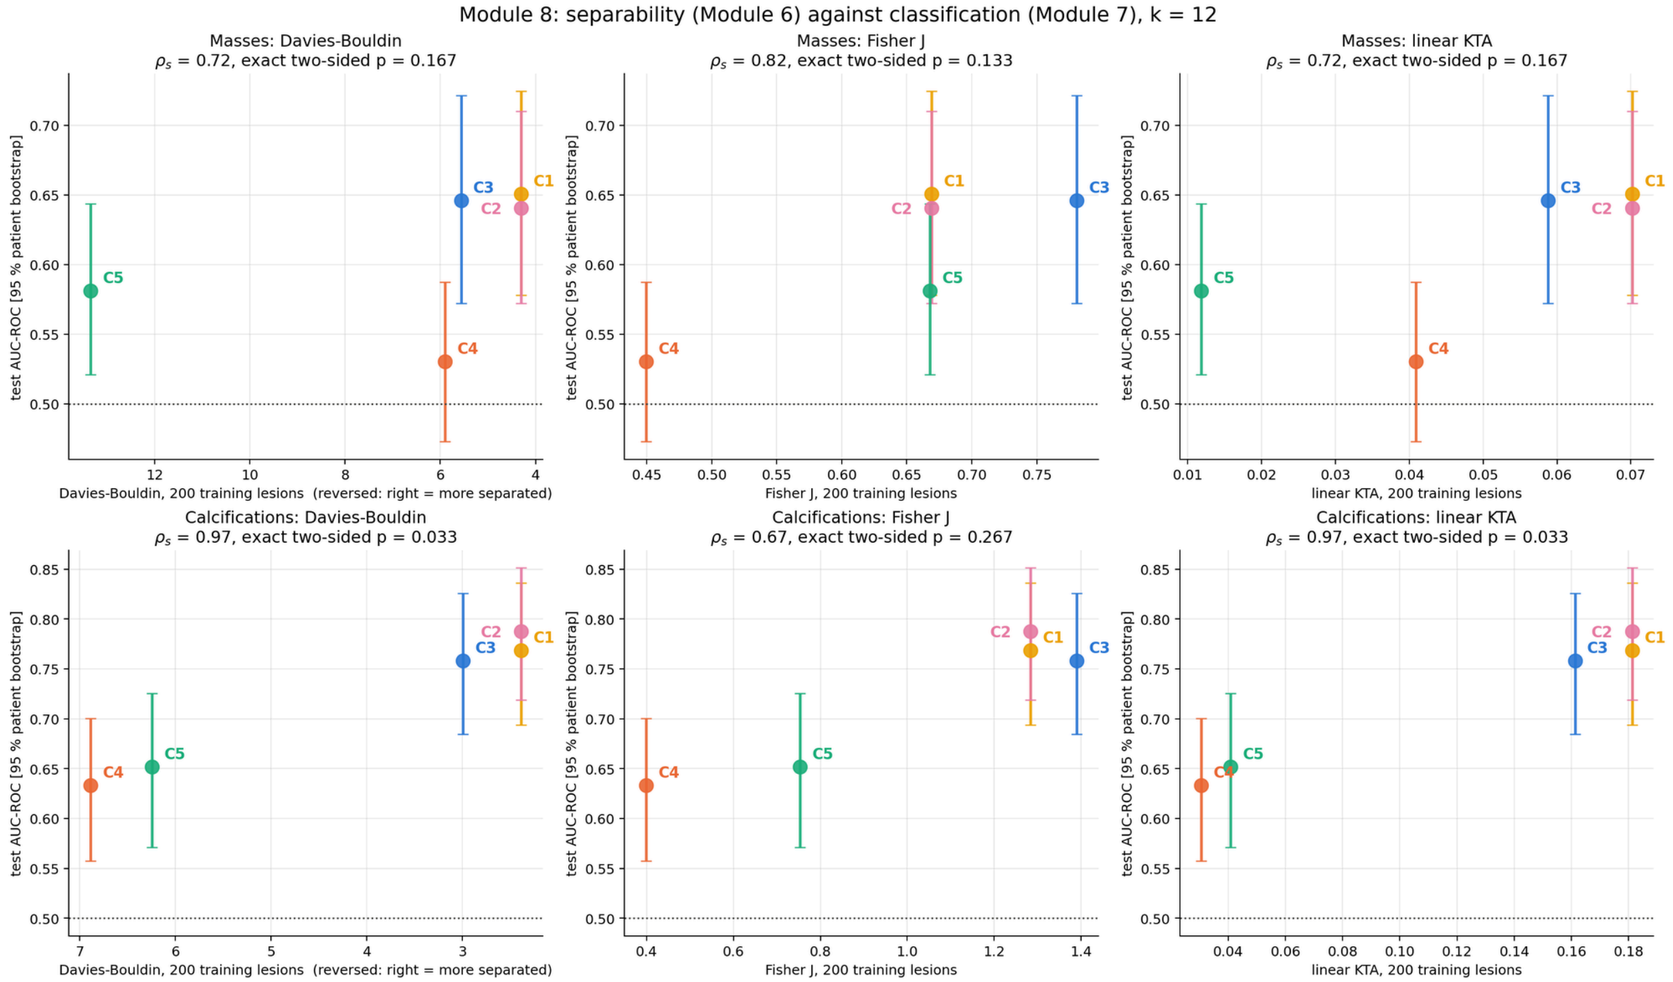

Figura 6.5.2 · Separabilidad frente a AUC, clásico y cuántico

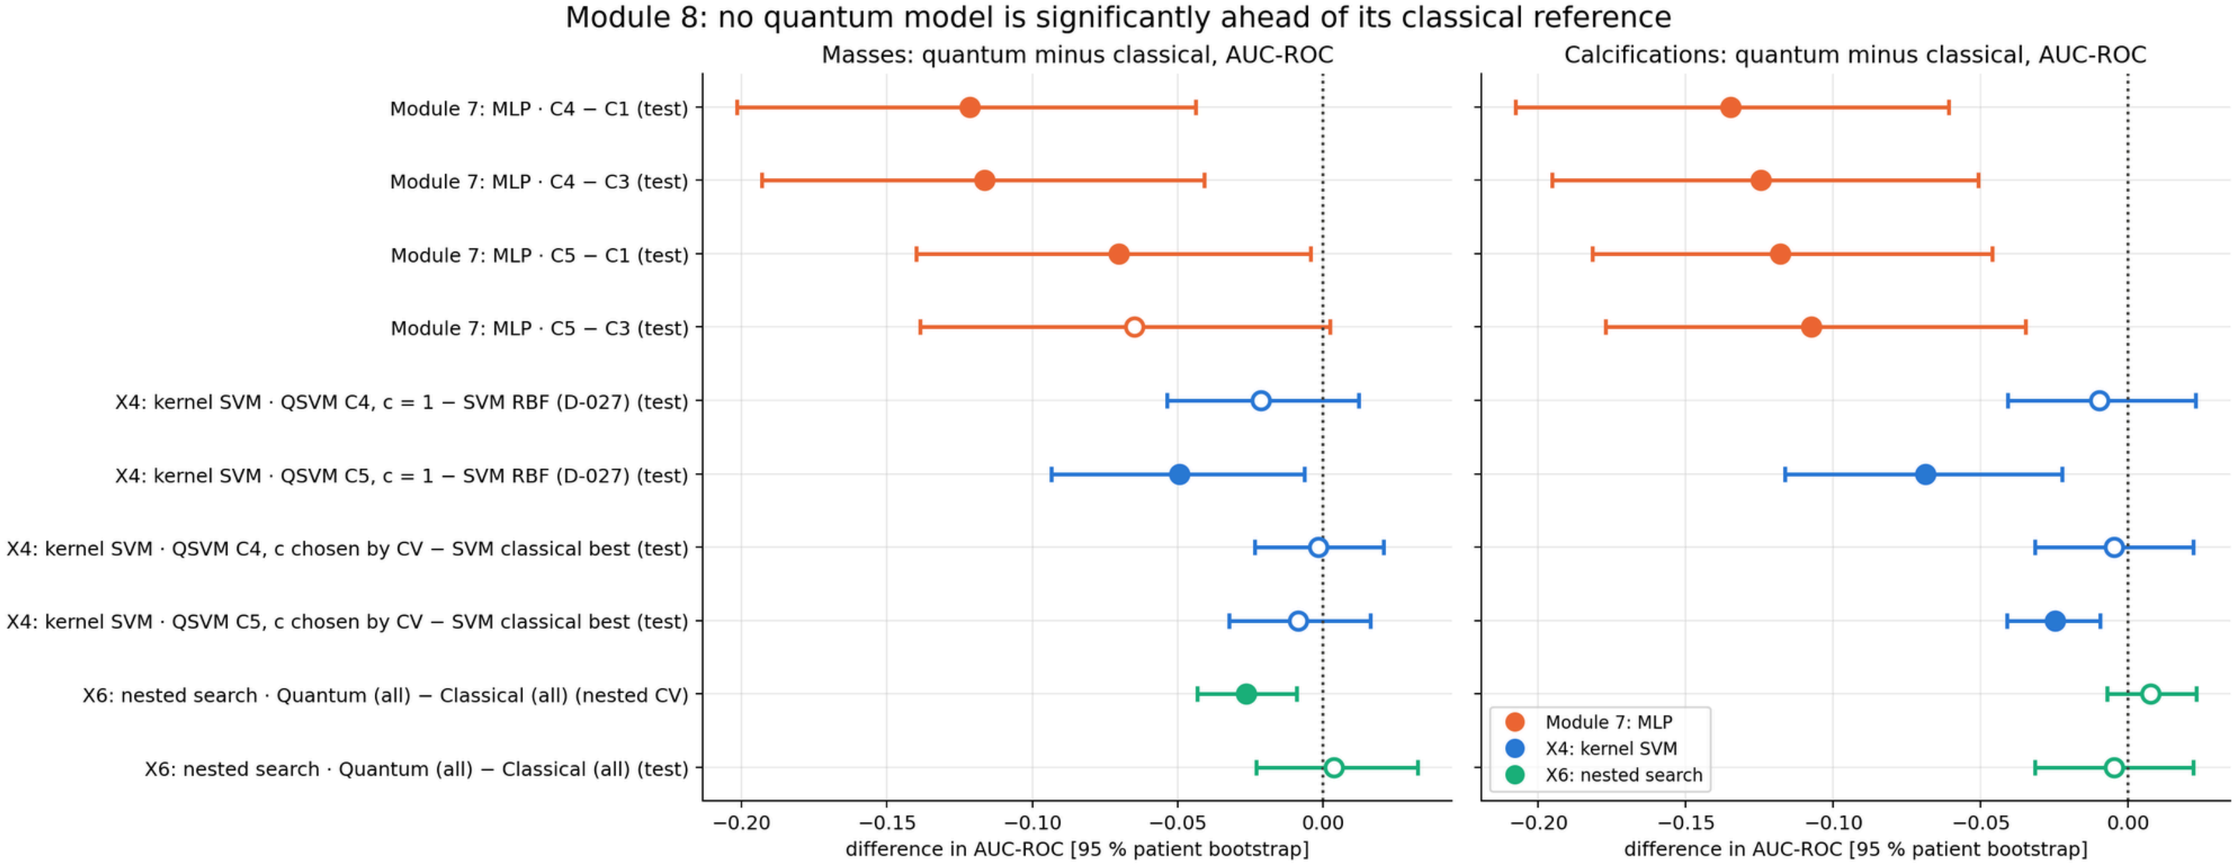

ANEXO 82

Figura 6.6.1 · Escalabilidad del simulador con el número de qubits

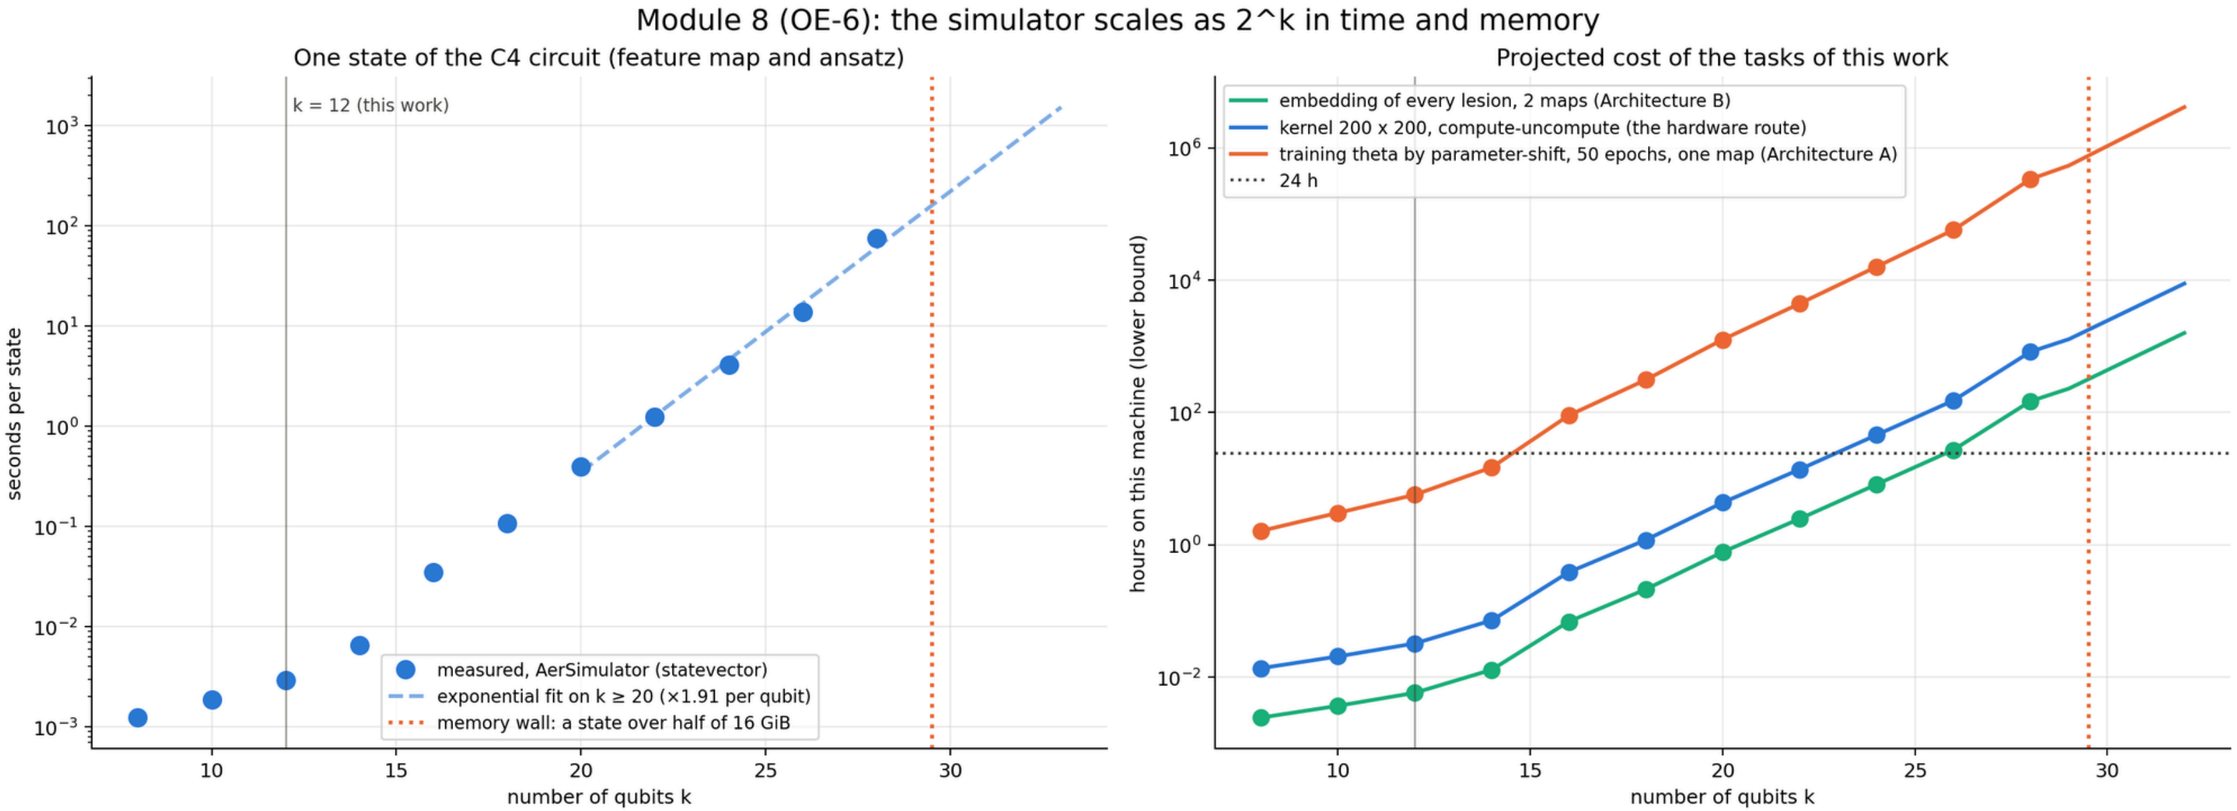

ANEXO 83

Figura 6.6.2 · Efecto del número de disparos

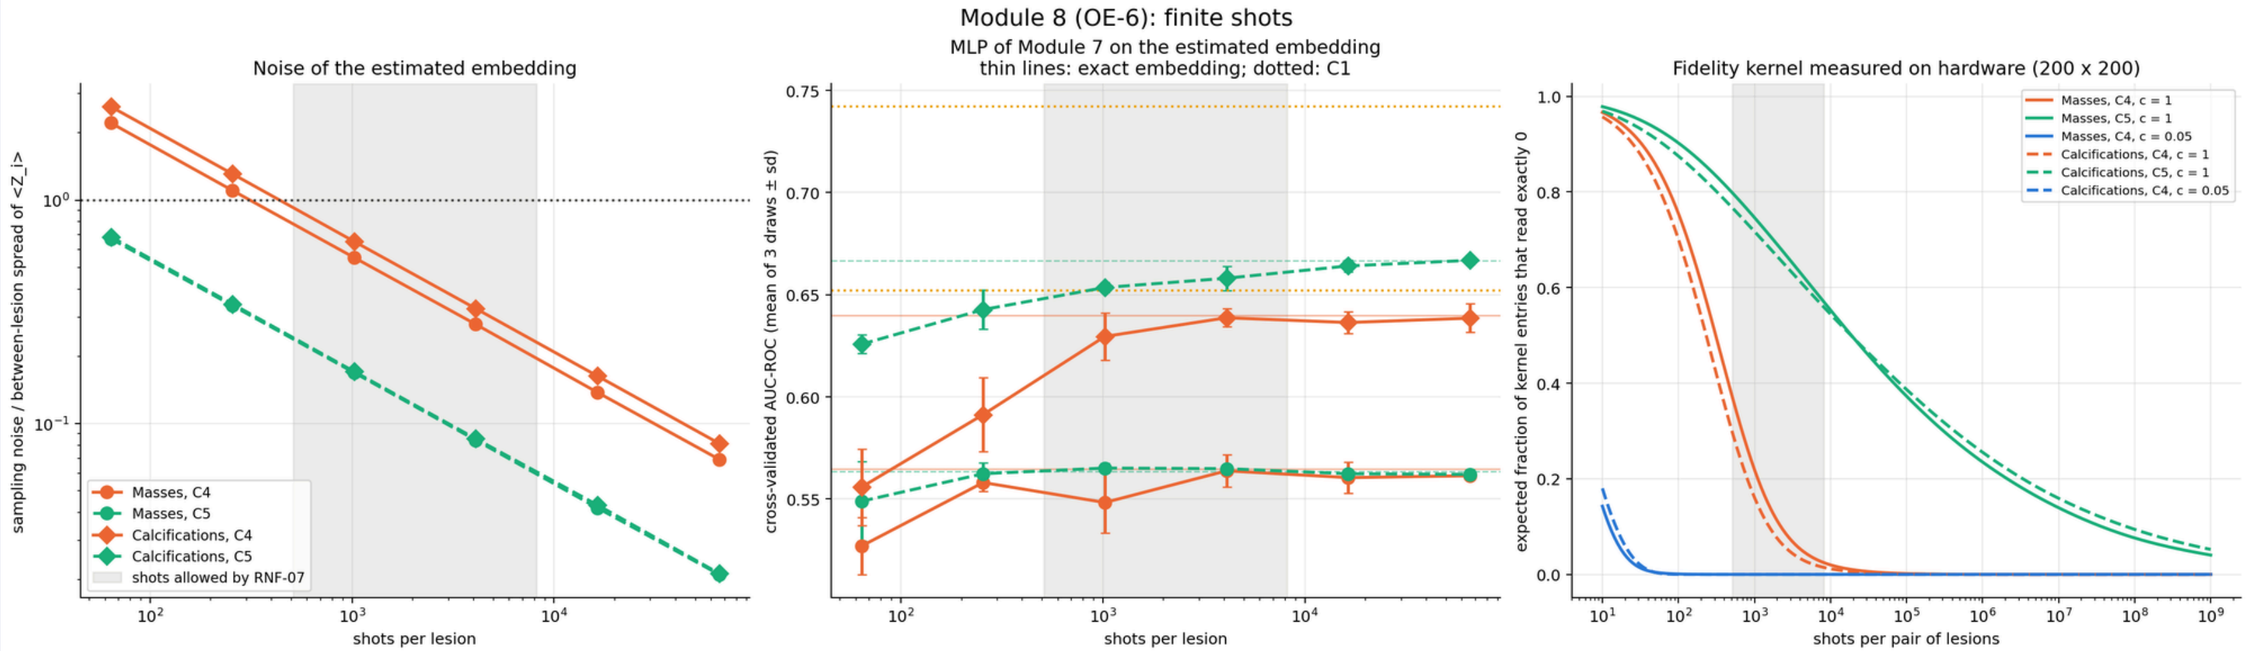

ANEXO 84

Figura C.1.1 · Alineación de las 80 máscaras desajustadas

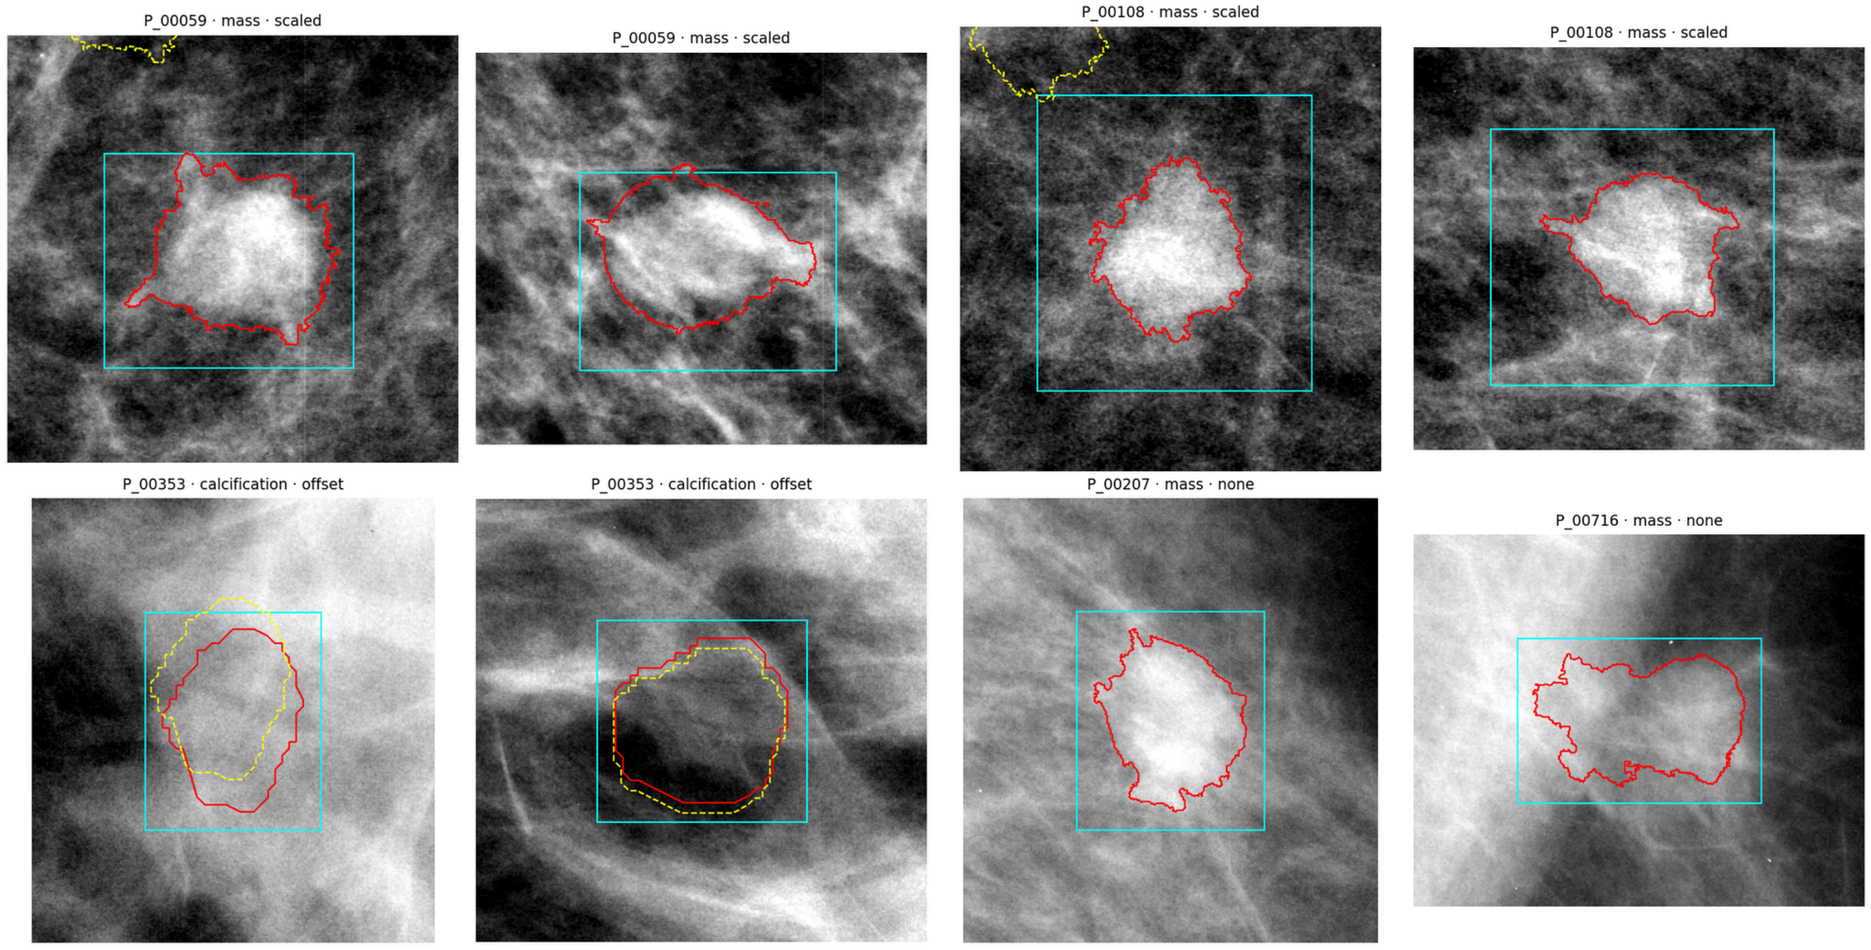

ANEXO 85

Figura C.1.2 · Etapas del preprocesamiento

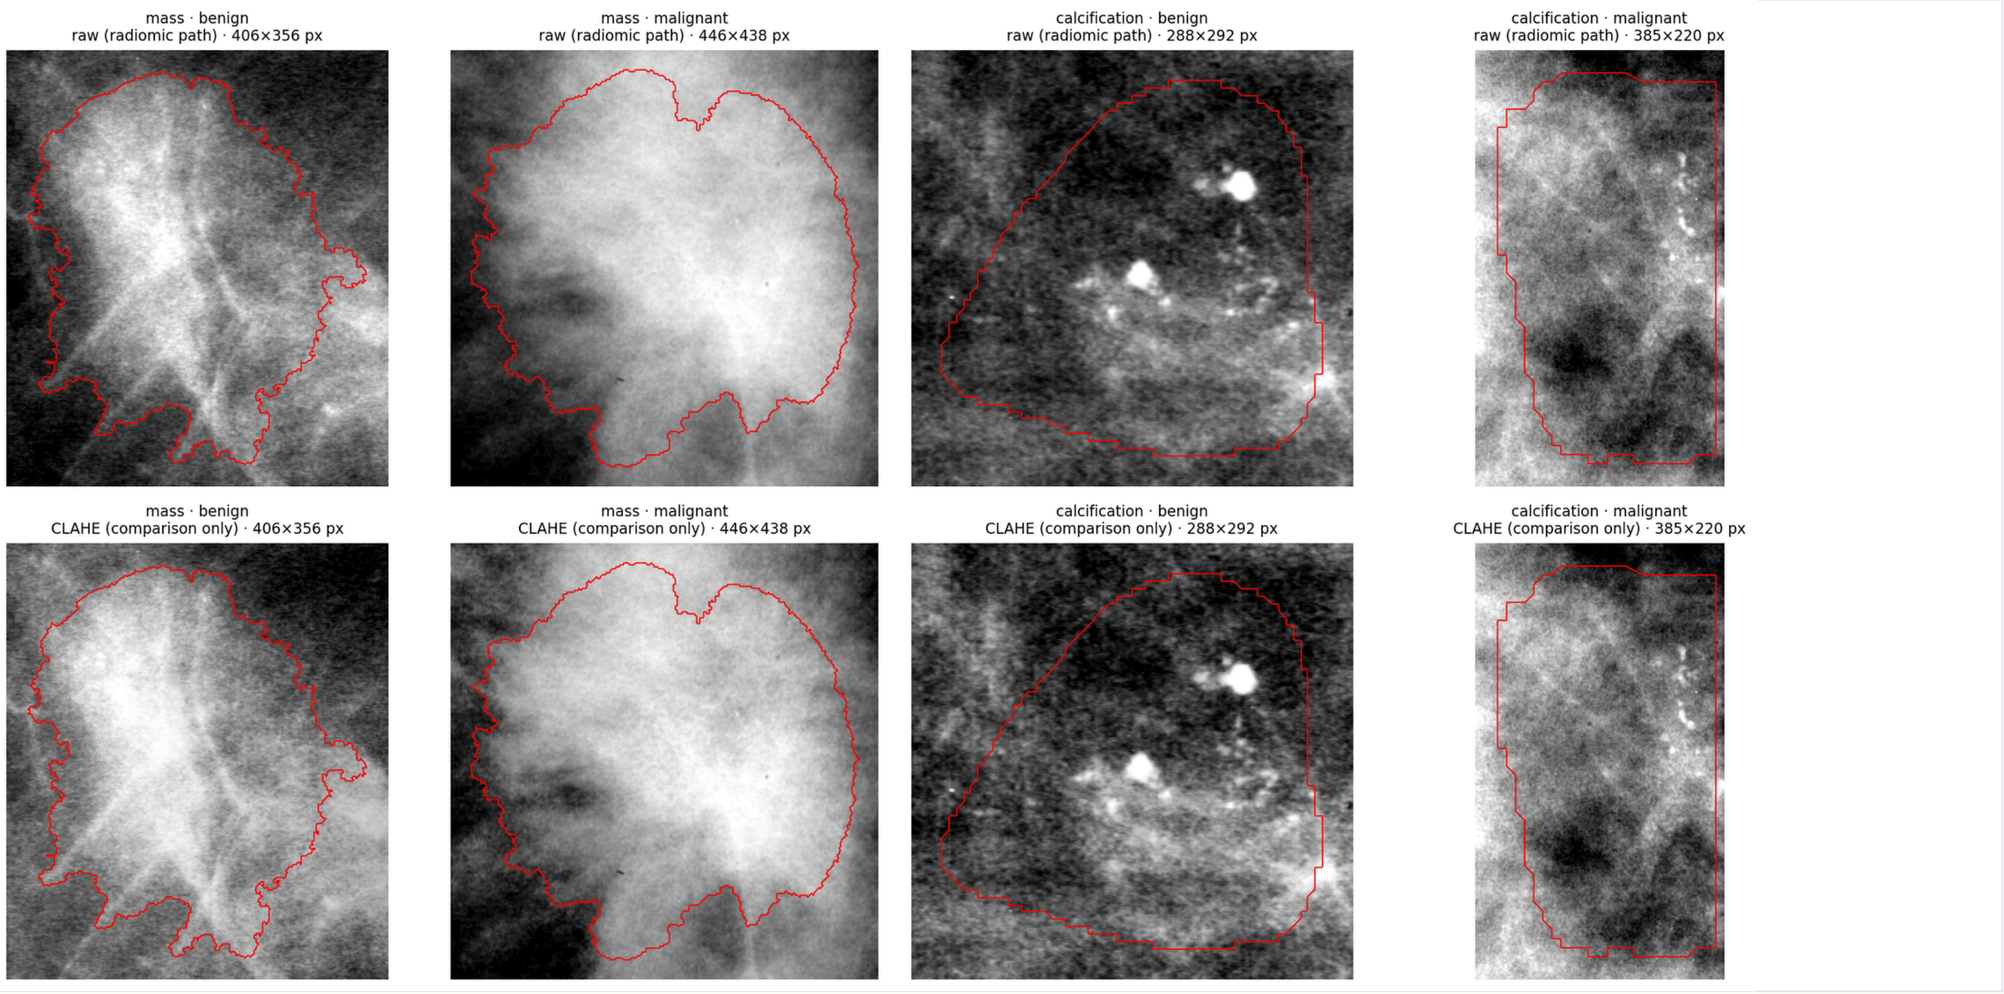

ANEXO 86

Figura C.4.1 · Valores del kernel dentro y entre clases

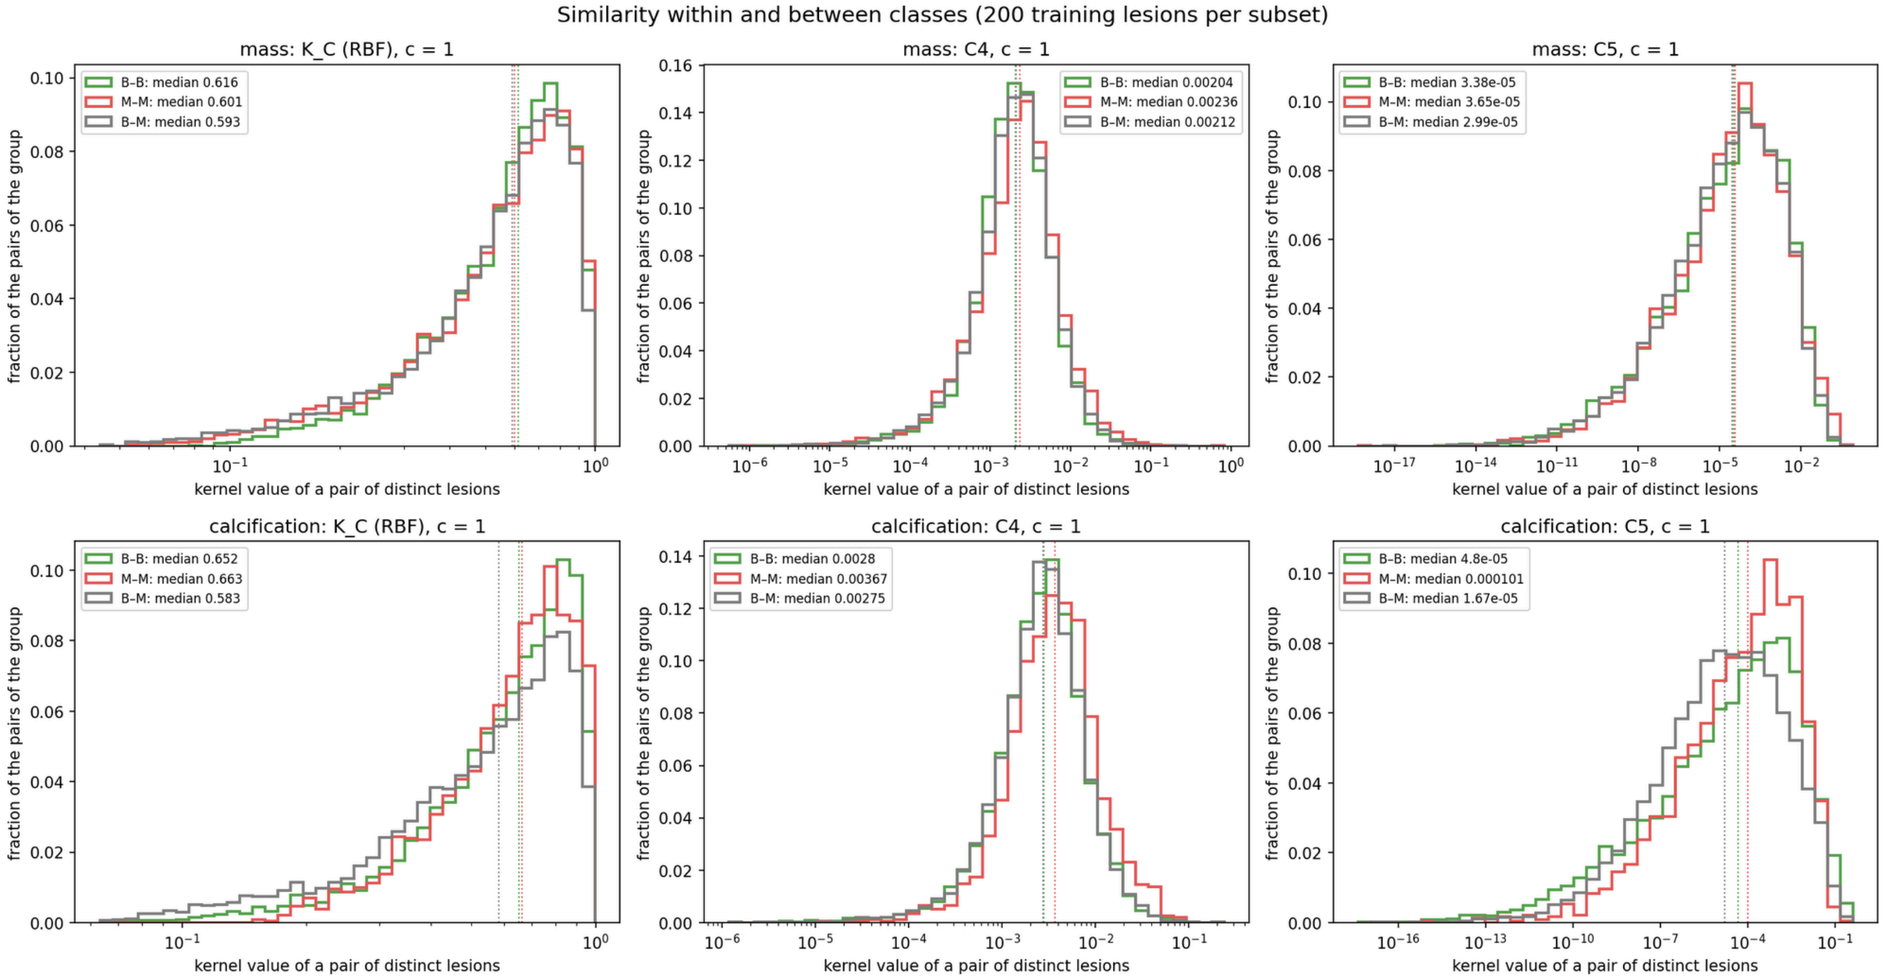

ANEXO 87

Cuadro 1 · Estado del arte

Cuadro 1: Comparativa de trabajos relacionados en el estado del arte

Trabajo	Datos	Circuito cuántico	Modelo / framework	Feature map	CBIS-DDSM	Análisis separab.	Masas/ calcs. sep.	P1	P2	P3	P4	Desempeño reportado
Aprendizaje profundo en mamografía												
Shen et al. (2019) [17]	CBIS-DDSM	✗	ResNet / VGG	—	✓	✗	✗	—	—	—	—	AUC: 0.91
Wang et al. (2020) [7]	DDSM / INbreast / MIAS / UKy	✗	CNN (6 modelos)	—	Parcial	✗	✗	—	—	—	—	AUC: 0.88–0.95 (valid.), 0.44–0.65 (externos)
Baccouche et al. (2022) [18]	CBIS-DDSM / INbreast	✗	Ensemble ResNet	—	✓	✗	✗	—	—	—	—	Acc.: 0.95 (patología)
Aprendizaje automático cuántico fuera de la mamografía												
Xiang et al. (2024) [9]	GBSG / SEER / WDBC (tabulares)	✓ (sim.)	QCCNN (PennyLane)	Capa cuántica conv.	✗	✗	—	Parc.	No	No	No	Acc. valid.: 0.70–0.96 (clás.: 0.61–0.93)
Toufah et al. (2025) [45]	Cáncer de pulmón (tabular)	✓ (sim.)	QSVM (Qiskit)	Z / ZZ / Pauli (sin cadenas)	✗	✗	—	Sí	No	ND	No	Acc.: 0.91–0.96 (RBF: 0.95)
Parigi et al. (2026) [65]	MNIST / F-MNIST (16×16)	✓ (sim.)	Kernels cuánticos / SVM	TNR / FRQI / NEQR / QPIE	✗	✓ (Gram)	—	Sí	Sí	Sí	No	Acc.: 0.94–0.99 (lineal: 0.96–0.99)
Aprendizaje automático cuántico en mamografía												
Azevedo et al. (2022) [10]	BCDR	✓ (sim. + QPU)	QTL (PennyLane)	Angle embedding	✗	✗	✗	Parc.	No	No	No	AUC: 0.77 (clás. TL: 0.58); acc.: 0.84 en ambos
Presente trabajo												
Presente trabajo	**CBIS-DDSM**	**✓ (sim. statevector)**	**MLP sobre $\langle Z_i \rangle$ (Qiskit)**	**C4: ZZ / C5: Pauli (Y, ZZ)**	✓	✓	✓	Sí	Sí	Sí	No	AUC masas: 0.530 / 0.581 (C1: 0.651); calcs.: 0.633 / 0.652 (C1: 0.769)

Notas: ✓ = cumple la condición; ✗ = no la cumple; — = no aplica; ND = el trabajo no lo dice; Parc. = parcialmente. P1–P4: paridad, incertidumbre, partición de prueba y simulabilidad (sección 2.1.8); no aplican a los trabajos sin componente cuántica. En el presente trabajo, los valores de C4 y C5 van separados por una barra; C1 es la condición sin transformación, con el mismo clasificador.

Cuadro 2 · Tres formas de leer el estado

Cuadro 2: Tres formas de leer el estado $|\phi(\mathbf{x})\rangle$ de un mismo *feature map*.

	Valores esperados $\langle Z_i \rangle$	**Kernel de fidelidad**	**Kernel proyectado**
Circuito	*Feature map* seguido del *ansatz* $V(\theta)$	*Feature map*	*Feature map*
Qué se obtiene	$\langle Z_i \rangle$ de cada qubit tras el *ansatz*	El solapamiento $\lvert\langle\phi(\mathbf{x})\rvert\phi(\mathbf{x}')\rangle\rvert^2$ entre los estados completos	$\langle X_k \rangle$, $\langle Y_k \rangle$ y $\langle Z_k \rangle$ de cada qubit
Resultado	Un vector de n valores por lesión	Un valor por par de lesiones	Un vector de $3n$ valores por lesión, comparado con un kernel gaussiano
Escala de la comparación	Local: un eje por qubit	Global: las 2^n amplitudes	Local: los tres ejes de cada qubit
Depende de θ	Sí	No: $V(\theta)$ se cancela	No: no hay *ansatz*
Clasificador	Perceptrón multicapa	SVM (QSVM)	SVM
Medición en un procesador	Una base (Z) para todos los qubits	Un circuito *compute-uncompute* por par de lesiones	Tres bases (X, Y, Z)
Dónde se usa	C4 y C5 (M5 y M7)	M6, X4 y X6	X6 y X11

Cuadro 3 · Composición del CBIS-DDSM

Cuadro 3: Composición del dataset CBIS-DDSM unificado

Subconjunto	Train	Test
Masas (mass)	1 318	378
Calcificaciones (calc)	1 546	326
Total	**2 864**	**704**

Cuadro 4 · Del EDA a las decisiones de diseño (parte 1 de 2)

Cuadro 4: Correspondencia entre hallazgos del EDA y decisiones de diseño del pipeline

Hallazgo del EDA	Decisión de diseño	Dónde se aplica
Masas y calcificaciones con morfología y desbalance distintos	Tratamiento como subproblemas totalmente independientes a lo largo de todo el pipeline experimental.	Sec. 5.1 y M1–M8
Desbalance 1.16:1 en masas y 1.78:1 en calcificaciones	Ponderación de clases (`class_weight=balanced`) en la pérdida de entropía cruzada del MLP.	Sec. 5.9 (M7)
`breast_density` y `subtlety` sin correlación con patología	La señal reside en la imagen: extracción directa de features radiómicas (PyRadiomics), sin metadatos.	Sec. 5.5 (M3)
Mamografías completas de $\sim 5\,037 \times 2\,960$ px	Recorte centrado en la ROI a resolución nativa y extracción radiómica; no se ingresa la imagen al circuito.	Sec. 5.4 y 5.5

Cuadro 4 · Del EDA a las decisiones de diseño (parte 2 de 2)

`PixelSpacing` ausente en todos los DICOM	Cálculo de features de forma en píxeles sin escala física dimensional (declarado como limitación).	Sec. 5.5 (M3)
80 máscaras con dimensiones discrepantes	Alineación en M2 según tipo: remuestreo para 78 masas escaladas (factor 0.870) y anclaje para 2 casos.	Sec. 5.4 (M2)
Todas `MONOCHROME2`, 16 bits de profundidad	Sin inversión fotométrica; discretización de histograma mediante `binCount=32` en PyRadiomics.	Sec. 5.4 y 5.5
Estructura agrupada por paciente	Partición de validación cruzada con folds agrupados por paciente (`StratifiedGroupKFold`).	Sec. 5.6 (M4)

Cuadro 5 · Clasificadores del trabajo (parte 1 de 2)

Cuadro 5: Clasificadores empleados en el trabajo.

Clasificador	Cómo decide	Configuración	Dónde
Perceptrón multicapa (MLP)	Combina las entradas en capas de neuronas con activación ReLU; los pesos se aprenden por descenso de gradiente	$12 \to 32 \to 16 \to 1$, Adam, parada temprana; el mismo modelo en C1–C5	M7; referencia en X7, X8 y X10
MLP con θ entrenado	El mismo perceptrón, que ajusta además los parámetros del *ansatz*	MLP de M7 y los 24 parámetros de `real_amplitudes`	X8
Regresión logística	Combinación lineal de las entradas seguida de una sigmoide	Pesos por clase balanceados	X1; descriptores del radiólogo (M8)
Máquina de vectores de soporte (SVM)	Frontera de máximo margen en el espacio que define un kernel de similitud entre lesiones (sección 3.5.4)	Kernels lineal, polinomiales y gaussianos; $C = 1$	X4, X6 y X11

Cuadro 5 · Clasificadores del trabajo (parte 2 de 2)

SVM con kernel cuántico (QSVM)	La misma frontera, con la similitud medida por el circuito: la fidelidad entre estados o el kernel proyectado (sección 3.5.5)	Kernels de C4 y C5, mapas ZZ y kernel proyectado; $C = 1$	X4, X6 y X11
Árbol de decisión	Preguntas sucesivas del tipo "¿la entrada j supera el umbral t?" hasta una hoja, que da la proporción de malignas de su región	Detenido por profundidad, por pureza del nodo o por poda de costo-complejidad	X10
Random forest	Promedia muchos árboles, cada uno entrenado sobre una muestra *bootstrap* y con un subconjunto aleatorio de entradas en cada corte	500 árboles	X1 y X10
XGBoost	Suma árboles poco profundos, cada uno ajustado a los errores de los anteriores (*gradient boosting*)	100 a 300 árboles de profundidad 2 a 6	X10 y X11

Cuadro 9 · Las cinco condiciones (M5)

Cuadro 9: Cinco condiciones experimentales del Módulo 5

ID	Nombre	Transformación	Tipo
C1	Sin transformación	El vector $\mathbf{x}$ pasa directamente al clasificador.	Clásico
C2	PCA lineal	Proyección sobre las 12 componentes principales. Es una rotación, así que actúa como control nulo.	Clásico
C3	Kernel PCA (RBF)	Proyección no lineal a 12 dimensiones con kernel gaussiano; γ por la heurística de la mediana.	Clásico
C4	`zz_feature_map`	Primer orden en Z y acoplamiento ZZ, seguidos de `real_amplitudes` con θ fijo. Salida: $\langle Z_i \rangle \in [-1,1]^{12}$.	Cuántico
C5	`pauli_feature_map`(Y,ZZ)	Primer orden en Y y el mismo acoplamiento ZZ, con el mismo *ansatz* y θ. Salida: $\langle Z_i \rangle \in [-1,1]^{12}$.	Cuántico

Cuadro 10 · Diseño de los experimentos X1 a X11 (parte 1 de 2)

Cuadro 10: Resumen de diseño de los experimentos complementarios X1 a X11.

Exp.	Nombre / Archivo	Pregunta metodológica	Variación vs. Fijo	Control	Uso de prueba
X1	`X1_Selection_Information_Loss`	¿Cuánta información se pierde al reducir de 67 a 12 variables?	Varía subconjunto de variables; fijos modelos clásicos.	67 variables y PCA con 12 componentes.	No (solo entrenamiento).
X2	`X2_Kernel_Class_Structure`	¿Conservan los kernels cuánticos similitud intra-clase?	Varía escala c; fijos kernels de C4 y C5.	Kernel RBF clásico y permutación.	No (submuestra de entrenamiento).
X3	`X3_Fewer_Qubits_k8`	¿Persiste la conclusión con un registro de $k = 8$ qubits?	Varía $k \in \{8, 12\}$; fijo protocolo de métricas.	Condiciones clásicas con 8 variables.	No en separabilidad; sensibilidad en M7.
X4	`X4_QSVM_and_67_Features`	¿Se pierde información en la codificación o en la lectura?	Varía clasificador (QSVM vs MLP) y variables ($k = 12$ vs 67).	SVM clásico RBF y MLP de M7.	Sí (una vez por configuración).
X5	`X5_Pipeline_Audit`	¿Existe algún fallo de implementación o fuga de datos?	Varía implementación de componentes; fijos datos.	Implementaciones alternativas y código Qiskit.	Sí (solo verificación de partición).
X6	`X6_Searching_for_Advantage`	¿Supera algún kernel cuántico al clásico en etiquetas reales?	Búsqueda anidada sobre familias cuánticas y clásicas.	Mejores modelos clásicos y etiquetado diseñado según Huang.	Sí con etiquetas reales (una vez por contendiente global); no con el etiquetado diseñado.
X7	`X7_Theta_Draws`	¿Introduce sesgo el sorteo único de θ?	Varía semilla de θ (10 sorteos); fijo MLP.	Variabilidad de MLP y condiciones clásicas.	No (solo validación cruzada).

Cuadro 10 · Diseño de los experimentos X1 a X11 (parte 2 de 2)

X8	`X8_Trained_Theta`	¿Mejora la representación al entrenar θ?	Varía optimización de θ (entrenado vs fijo); fijo MLP.	Modelo con θ fijo de M7 y C1 crudo.	Sí (una vez por subconjunto y mapa).
X9	`X9_Sample_Size`	¿Depende la separabilidad de la submuestra de 200 lesiones?	Varía la muestra (20 submuestras y todo el entrenamiento); fijas las métricas del M6.	Submuestra del M6 y kernel RBF.	No (solo entrenamiento).
X10	`X10_Tree_Classifiers`	¿Cambia la conclusión con clasificadores de árboles o con tres *folds*?	Varía el clasificador (árboles, *random forest*, XGBoost) y el número de *folds*; fijas las representaciones C1–C5.	Perceptrón de M7 sobre las mismas representaciones; XGBoost sin interacciones.	Sí (una vez por clasificador y representación).
X11	`X11_Designed_Label_Transition`	¿Cuánta estructura cuántica deben tener las etiquetas para que aparezca la ventaja?	Varía la fracción α de etiquetas diseñadas (0 a 1, cinco máscaras); fijos tres kernels cuánticos.	Mejor clasificador clásico con búsqueda anidada (SVM y XGBoost).	No (solo validación cruzada).

Cuadro 11 · Las 12 características seleccionadas (M4)

Cuadro 11: Las 12 características seleccionadas en cada subconjunto (M4): F-test ANOVA sobre el entrenamiento con restricción de redundancia $|r| \leq 0.95$.

	Masas			Calcificaciones		
#	Característica	Familia	F	Característica	Familia	F
1	firstorder_Maximum	firstorder	83.1	shape2D_MinorAxisLength	shape2D	235.4
2	firstorder_90Percentile	firstorder	82.6	glrlm_RunEntropy	glrlm	200.9
3	firstorder_Energy	firstorder	74.7	shape2D_Perimeter	shape2D	177.0
4	shape2D_MinorAxisLength	shape2D	66.7	firstorder_Skewness	firstorder	174.6
5	shape2D_MaximumDiameter	shape2D	62.3	glrlm_ShortRunLowGrayLevelEmphasis	glrlm	166.2
6	shape2D_Perimeter	shape2D	53.1	glrlm_ShortRunEmphasis	glrlm	161.5
7	shape2D_MeshSurface	shape2D	52.8	glcm_JointAverage	glcm	150.9
8	shape2D_PerimeterSurfaceRatio	shape2D	51.3	glcm_InverseVariance	glcm	142.8
9	glrlm_GrayLevelNonUniformity	glrlm	37.8	glcm_DifferenceEntropy	glcm	135.6
10	firstorder_10Percentile	firstorder	31.7	firstorder_Energy	firstorder	135.1
11	glcm_Correlation	glcm	31.0	glcm_ClusterShade	glcm	133.9
12	glrlm_RunLengthNonUniformity	glrlm	28.8	shape2D_PixelSurface	shape2D	129.1

Cuadro 12 · Separabilidad de los kernels (M6)

Cuadro 12: Separabilidad en la familia de kernels (M6), $c = 1$, 200 lesiones de entrenamiento por subconjunto.

Kernel	KTA centrada	Exceso sobre permutación ↑	p	d_{eff} (de 200)	g regularizada
Masas					
RBF (clásico)	0.059	**0.049**	<0.001	2.8	—
C4, ZZ	0.073	0.003	0.002	184.0	1.433
C5, Y–ZZ	0.075	0.005	0.003	171.3	1.511
Calcificaciones					
RBF (clásico)	0.161	**0.151**	<0.001	2.6	—
C4, ZZ	0.077	0.006	<0.001	187.7	1.400
C5, Y–ZZ	0.075	0.007	0.003	167.6	1.701

El exceso es la KTA centrada menos la media de 1,000 permutaciones de etiquetas; p es unilateral. g es el mínimo de la *geometric difference* regularizada sobre la batería de kernels clásicos del Apéndice L.3 de Huang et al. $\sqrt{N} \approx 14$. En negritas, el mayor exceso de cada subconjunto; la KTA cruda no es comparable entre kernels.

Cuadro 13 · Separabilidad de los embeddings (M6)

Cuadro 13: Separabilidad en la familia de embeddings (M6): 200 lesiones de entrenamiento por subconjunto.

Condición	Davies–Bouldin ↓	Fisher J ↑	KTA lineal ↑
Masas			
C1	**4.301**	0.669	**0.070**
C2	**4.301**	0.669	**0.070**
C3	5.564	**0.781**	0.059
C4	5.898	0.449	0.041
C5	13.346	0.668	0.012
Calcificaciones			
C1	**2.387**	1.284	**0.181**
C2	**2.387**	1.284	**0.181**
C3	2.995	**1.390**	0.161
C4	6.890	0.399	0.031
C5	6.247	0.753	0.041

Fisher $J = \Delta\mu^\top S_W^{-1}\Delta\mu$, con la covarianza intraclase combinada. C1 y C2 coinciden por construcción. En negritas, el mejor valor de cada métrica en cada subconjunto.

Cuadro 14 · Separabilidad con k = 12 y k = 8

Cuadro 14: Comparación de métricas de separabilidad entre las configuraciones con $k = 12$ y $k = 8$ qubits ($c = 1$, submuestra de 200 lesiones por subconjunto).

Métrica	Masas, $k = 12$	Masas, $k = 8$	Calcif., $k = 12$	Calcif., $k = 8$
Mediana del kernel (C4 / C5)	0.002 / 0.00003	0.010 / 0.0015	0.003 / 0.00003	0.008 / 0.0008
Dimensión efectiva (C4 / C5 de 200)	184.0 / 171.3	139.6 / 103.3	187.7 / 167.6	169.7 / 131.0
Exceso de KTA (C4 / C5)	0.003 / 0.005	0.012 / 0.023	0.006 / 0.007	0.011 / 0.024
Exceso de KTA del RBF	0.049	0.049	0.151	0.150
g mínima (C4 / C5; $\sqrt{N} \approx 14{,}1$)	1.43 / 1.51	2.40 / 3.23	1.40 / 1.70	1.71 / 2.16
Dispersión $\langle Z_i \rangle$ en todo el train (C4 / C5)	0.058 / 0.180	0.099 / 0.276	0.048 / 0.178	0.076 / 0.267
Fisher J en todo el train (C1 / C4 / C5)	0.45 / 0.13 / 0.21	0.37 / 0.09 / 0.17	1.06 / 0.42 / 0.31	0.98 / 0.29 / 0.37

Cuadro 15 · Clasificación con el mismo MLP (M7)

Cuadro 15: Clasificación con el mismo MLP sobre las cinco representaciones (M7, $k = 12$).

Condición	AUC en VC	AUC en prueba [IC 95 %]	F1	Exactitud	Precisión	Sensibilidad
Masas						
C1	**0.652** ± 0.068	**0.651** [0.578, 0.724]	0.519	0.638	0.536	0.503
C2	0.641 ± 0.059	0.641 [0.572, 0.710]	0.512	0.616	0.507	0.517
C3	0.648 ± 0.055	0.646 [0.572, 0.721]	0.502	0.606	0.493	0.510
C4	0.565 ± 0.079	0.530 [0.473, 0.587]	0.386	0.529	0.392	0.381
C5	0.563 ± 0.024	0.581 [0.521, 0.644]	0.456	0.571	0.450	0.463
Calcificaciones						
C1	0.742 ± 0.038	0.769 [0.694, 0.836]	0.665	0.666	0.551	0.837
C2	**0.758** ± 0.046	**0.788** [0.719, 0.851]	0.669	0.693	0.584	0.783
C3	0.739 ± 0.036	0.758 [0.685, 0.826]	0.652	0.653	0.541	0.822
C4	0.640 ± 0.041	0.633 [0.558, 0.700]	0.504	0.607	0.504	0.504
C5	0.667 ± 0.035	0.652 [0.571, 0.725]	0.565	0.571	0.472	0.705

VC: media ± desviación estándar sobre los 5 folds de M4. Prueba: el conjunto oficial, usado una sola vez por modelo; el intervalo es un *bootstrap* por paciente con 2,000 réplicas. Umbral de 0.5 para F1, exactitud, precisión y sensibilidad. En negritas, el mayor AUC de cada subconjunto, la métrica principal.

Cuadro 16 · Diferencias pareadas de AUC (M7) (parte 1 de 2)

Cuadro 16: Diferencias pareadas de AUC en el conjunto de prueba (M7).

Comparación	Diferencia	IC 95 %	p bilateral
Masas			
C4 − C1	**−0.122**	**[−0.202, −0.044]**	0.003
C4 − C3	**−0.116**	**[−0.193, −0.041]**	0.006
C5 − C1	**−0.070**	**[−0.140, −0.004]**	0.044
C5 − C3	−0.065	[−0.139, 0.002]	0.058
C2 − C1	−0.011	[−0.061, 0.038]	0.659
C3 − C1	−0.005	[−0.044, 0.032]	0.796
C5 − C4	0.051	[−0.027, 0.128]	0.180

Cuadro 16 · Diferencias pareadas de AUC (M7) (parte 2 de 2)

Calcificaciones			
C4 − C1	**−0.135**	**[−0.208, −0.061]**	0.001
C4 − C3	**−0.124**	**[−0.195, −0.051]**	0.001
C5 − C1	**−0.118**	**[−0.182, −0.046]**	<0.001
C5 − C3	**−0.108**	**[−0.177, −0.035]**	0.004
C2 − C1	0.020	[−0.026, 0.067]	0.377
C3 − C1	−0.010	[−0.034, 0.014]	0.377
C5 − C4	0.017	[−0.061, 0.098]	0.679

Las diferencias usan las mismas réplicas del *bootstrap* por paciente para ambas condiciones. $p \approx 2\,\text{mín}(q, 1-q)$, con q la fracción de réplicas con diferencia positiva; no está corregido por comparaciones múltiples. En negritas, las diferencias cuyo intervalo no contiene el cero.

Cuadro 17 · Diez sorteos de θ

Cuadro 17: Dependencia del AUC de C4 y C5 respecto al sorteo de θ: 10 sorteos, mismo MLP y mismos folds que el M7.

Subconjunto	Mapa	Semilla 42 (lugar)	Mín.–máx.	Rango (θ)	Rango (MLP)	C1 − mejor
Masas	C4	0.565 (6.º)	0.546–0.589	**0.042**	0.039	0.064
Masas	C5	0.563 (9.º)	0.557–0.624	**0.068**	0.029	0.028
Calcificaciones	C4	0.640 (6.º)	0.566–0.676	**0.110**	0.022	0.066
Calcificaciones	C5	0.667 (1.º)	0.627–0.667	**0.040**	0.018	0.075

AUC medio en validación cruzada; el conjunto de prueba no se usó. Rango (MLP): variación entre las 5 semillas del MLP con el θ del diseño. En negritas, la mayor de las dos fuentes de variación en cada fila. C1 − mejor es positivo en las cuatro filas: ningún sorteo alcanza a C1.

Cuadro 18 · θ entrenado frente a θ fijo

Cuadro 18: Efecto de entrenar θ junto con el MLP: de θ fijo (M7) a θ entrenado.

Mapa	AUC en VC	AUC en prueba	IC 95 % (entrenado)	Entrenado − C1 en prueba
Masas				
C4	0.565 → **0.568**	0.530 → **0.533**	[0.468, 0.598]	**−0.118 [−0.194, −0.043]**
C5	0.563 → **0.612**	0.581 → **0.585**	[0.518, 0.656]	**−0.066 [−0.116, −0.019]**
Calcificaciones				
C4	0.640 → **0.694**	0.633 → **0.674**	[0.593, 0.750]	**−0.094 [−0.154, −0.033]**
C5	0.667 → **0.687**	0.652 → **0.671**	[0.588, 0.745]	**−0.098 [−0.147, −0.048]**

Mismo protocolo que el M7; solo cambia que θ se entrena desde el sorteo del diseño, con gradientes exactos del simulador. En negritas, el mayor AUC de cada par y las diferencias frente a C1 cuyo intervalo no contiene el cero.

Cuadro 19 · Árboles y MLP sobre C1–C5 (X10)

Cuadro 19: AUC-ROC en el conjunto de prueba de los clasificadores de árboles y del perceptrón multicapa sobre las cinco representaciones (experimento X10).

Clasificador	C1	C2	C3	C4	C5
Masas					
Árbol, poda por profundidad	0.624	**0.637**	0.578	0.554	0.549
Árbol, poda por pureza	0.584	**0.616**	0.604	0.505	0.561
Árbol, poda por costo-complejidad	**0.617**	0.603	0.614	0.553	0.563
Random forest	0.636	**0.650**	0.604	0.591	0.614
XGBoost	0.630	**0.641**	0.596	0.590	0.611
Perceptrón multicapa (M7)	**0.651**	0.641	0.646	0.530	0.581
Calcificaciones					
Árbol, poda por profundidad	**0.755**	0.731	0.689	0.582	0.600
Árbol, poda por pureza	**0.757**	0.718	0.693	0.587	0.534
Árbol, poda por costo-complejidad	**0.768**	0.739	0.699	0.589	0.600
Random forest	0.768	**0.794**	0.756	0.651	0.624
XGBoost	0.779	**0.790**	0.749	0.640	0.621
Perceptrón multicapa (M7)	0.769	**0.788**	0.758	0.633	0.652

Hiperparámetros elegidos por validación cruzada anidada con los *folds* de M4; un ajuste por clasificador y representación, evaluado una sola vez. Con el mismo clasificador, ninguna representación cuántica supera a C1 con un intervalo pareado por encima de cero (sección 6.3). En negritas, la mejor representación para cada clasificador.

Cuadro 20 · Tres lecturas del mapa ZZ

Cuadro 20: Tres lecturas del estado del mapa ZZ completo: valores esperados $\langle Z_i \rangle$ con perceptrón (C4), kernel de fidelidad y kernel proyectado.

	$\langle Z_i \rangle$ y MLP (C4)		Fidelidad (QSVM)		Proyectado	
	Masas	Calcif.	Masas	Calcif.	Masas	Calcif.
Mediana del kernel fuera de la diagonal	—	—	0.002	0.003	0.607	0.607
g frente al modelo clásico más cercano	—	—	1.433	1.400	9.291	8.297
AUC, etiquetas diagnósticas	0.565	0.640	**0.657**	**0.752**	0.566	0.667
AUC, etiquetado diseñado	—	—	**0.730**	**0.829**	**0.998**	**0.994**
mejor SVM clásico con ese etiquetado	—	—	0.712	0.807	0.800	0.824

AUC en validación cruzada sobre el entrenamiento con los *folds* de M4. Mediana y g sobre las 200 lesiones del M6; en el kernel proyectado, la mediana de 0.607 ($e^{-1/2}$) es consecuencia de fijar el ancho de banda por la heurística de la mediana, no una propiedad del circuito. El etiquetado diseñado se construye para cada kernel, así que sus columnas no son comparables entre sí. En negritas: con las etiquetas diagnósticas, la mejor lectura de cada subconjunto; con el etiquetado diseñado, el mejor entre el kernel cuántico y el clásico.

Cuadro 21 · De las etiquetas reales a las diseñadas (X11)

Cuadro 21: Diferencia de AUC entre el kernel cuántico y el mejor clasificador clásico al pasar de las etiquetas diagnósticas ($\alpha = 0$) al etiquetado diseñado ($\alpha = 1$) (experimento X11).

Kernel cuántico	g	$\alpha = 0$	0.2	0.4	0.6	0.8	1	α^*
Masas								
ZZ completo (C4)	1.43	$-0.020^{\dagger}$	-0.006	0.000	**+0.011***	**+0.021***	**+0.035***	**0.6**
ZZ lineal	1.60	$-0.040^{\dagger}$	$-0.024^{\dagger}$	+0.006	**+0.025***	**+0.031***	**+0.042***	**0.5**
Proyectado (ZZ completo)	9.29	$-0.111^{\dagger}$	-0.030	**+0.043***	**+0.095***	**+0.114***	**+0.141***	**0.4**
Calcificaciones								
ZZ completo (C4)	1.40	-0.012	+0.003	+0.005	+0.003	**+0.018***	**+0.024***	**0.7**
ZZ lineal	1.31	$-0.050^{\dagger}$	$-0.025^{\dagger}$	-0.010	**+0.023***	**+0.084***	**+0.163***	**0.6**
Proyectado (ZZ completo)	8.30	$-0.096^{\dagger}$	$-0.055^{\dagger}$	+0.009	**+0.043***	**+0.071***	**+0.118***	**0.5**

α: fracción de lesiones con la etiqueta diseñada; media de cinco máscaras. Validación cruzada sobre el entrenamiento; lado clásico con búsqueda anidada entre SVM lineal, polinomiales, gaussianos y XGBoost. * intervalo bootstrap por paciente del 95 % por encima de cero; † por debajo. α^*: menor α con el intervalo por encima de cero. g: *geometric difference* regularizada sobre las 200 lesiones del M6. En negritas, las diferencias con ventaja cuántica significativa y el umbral.

Cuadro 22 · Spearman entre separabilidad y clasificación (M8)

Cuadro 22: Correlación de Spearman entre el orden de separabilidad y el de clasificación de las cinco condiciones (M8).

Subconjunto	Métrica de separabilidad	ρ_s	p exacto bilateral
Masas	Davies–Bouldin	0.718	0.167
Masas	Fisher J	**0.821**	0.133
Masas	KTA lineal	0.718	0.167
Calcificaciones	Davies–Bouldin	**0.975**	0.033
Calcificaciones	Fisher J	0.667	0.267
Calcificaciones	KTA lineal	**0.975**	0.033

Submuestra de 200 lesiones frente al AUC de prueba, $k = 12$. Con $n = 5$ hay 120 órdenes; ρ_s es la correlación de Pearson de los rangos promedio, porque C1 y C2 empatan. Es descriptivo: con el empate, el mejor orden alcanzable da $p = 4/120$. En negritas, la métrica con mayor ρ_s en cada subconjunto.

Cuadro 23 · Resumen de resultados por condición (parte 1 de 2)

Cuadro 23: Resumen de resultados por condición: separabilidad (M6), clasificación (M7 y X4) y tiempo de transformación (M5).

	Kernel			Representación		AUC-ROC		
Condición	Exceso KTA ↑	d_{eff}	g	DB ↓	Fisher ↑	VC	Prueba [IC 95 %]	Tiempo (s)
Masas								
C1	—	—	—	**4.301**	0.669	**0.652**	**0.651** [0.578, 0.724]	—
C2	—	—	—	**4.301**	0.669	0.641	0.641 [0.572, 0.710]	0.0002
C3	**0.049**	2.8	—	5.564	**0.781**	0.648	0.646 [0.572, 0.721]	0.14
C4	0.003	184.0	1.433	5.898	0.449	0.565	0.530 [0.473, 0.587]	13.3
C5	0.005	171.3	1.511	13.346	0.668	0.563	0.581 [0.521, 0.644]	14.3
SVM sobre el kernel RBF							0.649 [0.574, 0.726]	—
QSVM sobre el kernel de C4							0.628 [0.555, 0.703]	—
QSVM sobre el kernel de C5							0.599 [0.523, 0.675]	—
Calcificaciones								
C1	—	—	—	**2.387**	1.284	0.742	0.769 [0.694, 0.836]	—

Cuadro 23 · Resumen de resultados por condición (parte 2 de 2)

C2	—	—	—	**2.387**	1.284	**0.758**	**0.788** [0.719, 0.851]	0.0002
C3	**0.151**	2.6	—	2.995	**1.390**	0.739	0.758 [0.685, 0.826]	0.20
C4	0.006	187.7	1.400	6.890	0.399	0.640	0.633 [0.558, 0.700]	13.9
C5	0.007	167.6	1.701	6.247	0.753	0.667	0.652 [0.571, 0.725]	16.1
SVM sobre el kernel RBF							0.769 [0.696, 0.834]	—
QSVM sobre el kernel de C4							0.759 [0.687, 0.827]	—
QSVM sobre el kernel de C5							0.701 [0.620, 0.775]	—

Separabilidad sobre 200 lesiones de entrenamiento por subconjunto y $c = 1$. Las columnas de kernel de C3 corresponden al kernel RBF, con el mismo γ que C3; C1 y C2 no definen un kernel propio. g: mínimo de la *geometric difference* regularizada ($\sqrt{N} \approx 14$). AUC: el mismo MLP en C1–C5; las tres últimas filas de cada bloque son clasificadores de vectores de soporte sobre el kernel (experimento X4). Tiempo: transformación de todas las lesiones del subconjunto en la máquina del proyecto; en C2 y C3, mediana de cinco repeticiones; C1 es la identidad. Con el etiquetado diseñado según Huang et al., control positivo del protocolo (sección 6.4), el kernel cuántico proyectado alcanza en validación cruzada 0.998 en masas y 0.994 en calcificaciones, frente a 0.800 y 0.824 del mejor clasificador clásico. En negritas, el mejor valor de cada columna con dirección en cada subconjunto; en el AUC de prueba se comparan también las filas de X4.

Cuadro 24 · Mapa de las comparaciones (parte 1 de 2)

Cuadro 24: Mapa de las comparaciones del trabajo. AUC-ROC en el conjunto de prueba salvo que se indique validación cruzada (VC); masas / calcificaciones. En negritas, el mejor valor de cada comparación.

Exp.	Pregunta	Comparación	Resultado	Lectura
M6 (§6.2)	¿Separan mejor las clases las representaciones cuánticas?	Métricas de kernel y de representación en C1–C5	Exceso de KTA de 0.003 a 0.007 en C4 y C5, frente a **0.049 / 0.151** del RBF	Clásicas por delante en todas las métricas
M7 (§6.3)	¿Clasifica mejor el mismo perceptrón sobre C4 o C5?	MLP $12 \to 32 \to 16 \to 1$ en C1–C5	C1: **0.651 / 0.769**; C4: 0.530 / 0.633; C5: 0.581 / 0.652	Clásicas, de 0.07 a 0.14 por delante
M7, sensibilidad	¿Depende de la red, la semilla, `reps` o k?	Semillas, redes 16-8 y 64-32, sin estandarizar, 200 épocas, `reps` = 2, $k = 8$	La semilla mueve el AUC como mucho 0.039; la brecha se mantiene	Sin cambio
X1	¿Cuánto cuesta usar 12 de las 67 características?	Regresión logística con 67 y con 12	**0.693 / 0.800** frente a 0.650 / 0.758 (VC)	Pérdida de 2 a 4 puntos, igual para todas las condiciones
X4	¿Se pierde la información al codificar o al leer?	QSVM de C4, SVM RBF y MLP sobre $\langle Z_i \rangle$	0.628 / 0.759; **0.649 / 0.769**; 0.530 / 0.633	Empate entre QSVM y SVM; la pérdida está en la lectura

Cuadro 24 · Mapa de las comparaciones (parte 2 de 2)

X6	¿Gana algún kernel cuántico con la misma búsqueda en ambos lados?	28 candidatos cuánticos frente a 12 clásicos, búsqueda anidada	**0.656** frente a 0.652 / 0.755 frente a **0.760**	Empate
X7	¿Sesgó el sorteo de θ el resultado?	Diez sorteos de θ	Ninguno alcanza a C1; déficit de 0.03 a 0.18 (VC)	Clásicas
X8	¿Ayuda entrenar θ?	θ entrenado frente a fijo	Gana de $+0{,}003$ a $+0{,}041$; sigue entre $-0{,}066$ y $-0{,}118$ frente a C1	Clásicas
X10	¿Cambia con árboles o con tres *folds*?	Árboles, *random forest* y XGBoost en C1–C5; MLP con tres *folds*	*Random forest*, C1: **0.636** / **0.768**; C4: 0.591 / 0.651; C5: 0.614 / 0.624	Clásicas; en masas, empate con los ensambles
M8 (§6.5)	¿Cuánto separan los descriptores del radiólogo?	Regresión logística sobre forma y margen, o tipo y distribución	**0.872 / 0.825** (VC)	Referencia clínica, no competidor
X6, X11	¿Existe una tarea con ventaja cuántica sobre estas lesiones?	QSVM proyectado frente al mejor clásico con el etiquetado diseñado	**0.998** frente a 0.857 / **0.994** frente a 0.876 (VC); α^* de 0.4 a 0.7	Cuántico, solo con el etiquetado diseñado

Cuadro 25 · Evidencia por objetivo específico (parte 1 de 2)

Cuadro 25: Síntesis de resultados y evidencia empírica por objetivo específico.

Objetivo	Objetivo resumido	Evidencia principal	Sección	Resultado
OE-1	Construir pipeline sobre CBIS-DDSM (DICOM, ROI, 67 variables radiómicas, selección a $k = 12$ y escalado angular $[0, \pi]$ en subproblemas independientes).	3 568 registros con cobertura DICOM 100 %; 67 variables extraídas; 12 seleccionadas retienen 86.8 % (masas) y 90.2 % (calcificaciones) de varianza; 0 solapes entre train y test.	Sección 6.1	Pipeline validado sin fuga de pacientes; selección por prueba F con filtro de redundancia ($\lvert r\rvert \leq 0{,}95$) y escalado por cuantiles con IQR de $\pi/2$.
OE-2	Implementar cinco condiciones experimentales de dimensión $k = 12$ (C1 crudo, C2 PCA lineal, C3 Kernel PCA RBF, C4 ZZFeatureMap, C5 PauliFeatureMap).	5 condiciones simétricas sobre el mismo vector; θ fijo (semilla 42) en Arquitectura B; C5 diferenciado con compuertas Y y ZZ; extracción analítica en 0.20 h frente a 381.7 h estimadas en el benchmark de recursos para entrenar los dos mapas con Arquitectura A.	Secciones 5.7, 6.7	Condiciones implementadas; control nulo C2 preservado; Arquitectura B desacopla codificación de clasificación favoreciendo la reproducibilidad.
OE-3	Analizar y comparar separabilidad de clases en las cinco condiciones mediante KTA, diferencia geométrica g, Davies–Bouldin y razón de Fisher.	A $c = 1$, exceso de KTA de 0.003 a 0.007 en C4/C5 frente a 0.049 y 0.151 en RBF; d_{eff} cuántica de 167.6 a 187.7; g mínima de 1.40 a 1.70 ($\sqrt{N} \approx 14{,}1$); condiciones clásicas superan a cuánticas en Fisher.	Sección 6.2	Las transformaciones cuánticas a $c = 1$ no muestran mayor separabilidad que las clásicas en ninguna familia métrica; matrices de kernel concentradas próximas a la identidad.

Cuadro 25 · Evidencia por objetivo específico (parte 2 de 2)

OE-4	Entrenar un mismo clasificador MLP sobre las cinco representaciones bajo idéntica arquitectura, hiperparámetros y validación cruzada 5-fold por paciente.	Red $12 \to 32 \to 16 \to 1$, optimizador Adam, parada temprana; variación máxima por semilla de 0.039 en CV; 200 épocas sin parada temprana no mejora C4/C5 (AUC 0.533 y 0.557 en masas; 0.596 y 0.631 en calcificaciones).	Sección 6.3	Protocolo simétrico validado; convergencia uniforme; el déficit cuántico no es atribuible a subentrenamiento ni a sensibilidad de hiperparámetros.
OE-5	Evaluar si la separabilidad se traslada a clasificación binaria (AUC-ROC, F1, Accuracy, Precision, Recall) y correlación de Spearman entre rankings.	En test, AUC masas: C1 0.651, C3 0.646, C4 0.530, C5 0.581; calcificaciones: C1 0.769, C3 0.758, C4 0.633, C5 0.652. Diferencias frente a C1 entre $-0{,}07$ y $-0{,}14$. Coeficiente ρ_s descriptivo en el rango de 0.67 a 0.97.	Secciones 6.3, 6.5	El MLP clasifica peor sobre C4/C5; separabilidad y clasificación coinciden en su ordenamiento (C1–C3 delante de C4–C5), pero sin ganancia previa en separabilidad que trasladar.
OE-6	Evaluar restricciones prácticas y del simulador cuántico (recursos, escalabilidad en qubits, gradientes y shots) para determinar viabilidad en salud.	Simulación exacta viable hasta $k \approx 25$ en 24 h; gradiente por *parameter-shift* requiere 5.16 s/muestra ($\sim$ 205 h a $k = 12$); a 1 024 disparos, entre 15.7 % y 74.5 % de pares del kernel leen cero; MLP tolera disparos perdiendo $< 0{,}02$ de AUC.	Secciones 6.6, 6.7	Techo práctico impuesto por gradientes físicos y concentración del kernel; fidelidad experimentalmente inmedible con disparos realistas en NISQ; atajos de simulación no trasladables a hardware.

Cuadro 26 · Preprocesamiento y control de calidad (M2)

Cuadro 26: Resumen del preprocesamiento, alineación de máscaras y control de calidad (Módulo 2).

Subconjunto	Lesiones analizadas	Desalineadas (escal./offset)	Máscaras depuradas	Recortes coincidentes	Recortes oficiales con discrepancia/sin	Dimensión mediana de lesión (px)	Recortes en borde
Calcificaciones	1872	2	0	1663	209	273×289	120
Masas	1696	78	1464	1543	75	302×304	67

Auditoría y control de calidad de M2. Desalineadas: 78 por escala (0,870) en masas y 2 por traslación en calcificaciones. Depuradas: reducción a la componente conexa mayor eliminando artefactos menores aislados. Recortes coincidentes: concordancia exacta al píxel con los recortes oficiales del CBIS-DDSM.

Cuadro 27 · Características seleccionadas, conjunto completo (M4)

Cuadro 27: Conjunto completo de características radiómicas seleccionadas por subconjunto (Módulo 4).

	Masas					Calcificaciones				
#	Característica	Familia	F	p	$\lvert d\rvert$	Característica	Familia	F	p	$\lvert d\rvert$
1	firstorder_Maximum	firstorder	83.1	<0.001	0.502	shape2D_MinorAxisLength	shape2D	235.4	<0.001	0.817
2	firstorder_90Percentile	firstorder	82.6	<0.001	0.501	glrlm_RunEntropy	glrlm	200.9	<0.001	0.755
3	firstorder_Energy	firstorder	74.7	<0.001	0.476	shape2D_Perimeter	shape2D	177.0	<0.001	0.709
4	shape2D_MinorAxisLength	shape2D	66.7	<0.001	0.450	firstorder_Skewness	firstorder	174.6	<0.001	0.704
5	shape2D_MaximumDiameter	shape2D	62.3	<0.001	0.435	glrlm_ShortRunLowGrayLevelEmphasis	glrlm	166.2	<0.001	0.687
6	shape2D_Perimeter	shape2D	53.1	<0.001	0.402	glrlm_ShortRunEmphasis	glrlm	161.5	<0.001	0.677
7	shape2D_MeshSurface	shape2D	52.8	<0.001	0.400	glcm_JointAverage	glcm	150.9	<0.001	0.654
8	shape2D_PerimeterSurfaceRatio	shape2D	51.3	<0.001	0.395	glcm_InverseVariance	glcm	142.8	<0.001	0.636
9	glrlm_GrayLevelNonUniformity	glrlm	37.8	<0.001	0.339	glcm_DifferenceEntropy	glcm	135.6	<0.001	0.620
10	firstorder_10Percentile	firstorder	31.7	<0.001	0.311	firstorder_Energy	firstorder	135.1	<0.001	0.619
11	glcm_Correlation	glcm	31.0	<0.001	0.307	glcm_ClusterShade	glcm	133.9	<0.001	0.616
12	glrlm_RunLengthNonUniformity	glrlm	28.8	<0.001	0.296	shape2D_PixelSurface	shape2D	129.1	<0.001	0.605

Selección de las 12 características en cada subconjunto mediante ANOVA univariado (F-test) sobre el conjunto de entrenamiento con restricción de redundancia lineal $|r| \leq 0{,}95$. p reporta el nivel de significación estadística; $|d|$ es el tamaño del efecto (d de Cohen sobre intensidades crudas).

Cuadro 28 · Características descartadas por redundancia (M4)

Cuadro 28: Características radiómicas descartadas por restricción de redundancia (Módulo 4).

Característica candidata	Redundante con	$\lvert r\rvert$	Estado
Masas			
firstorder_TotalEnergy	firstorder_Energy	1.000	Descartada ($\lvert r\rvert > 0{,}95$)
firstorder_Median	firstorder_90Percentile	0.959	Descartada ($\lvert r\rvert > 0{,}95$)
firstorder_RootMeanSquared	firstorder_90Percentile	0.966	Descartada ($\lvert r\rvert > 0{,}95$)
firstorder_Mean	firstorder_90Percentile	0.955	Descartada ($\lvert r\rvert > 0{,}95$)
shape2D_MajorAxisLength	shape2D_MaximumDiameter	0.993	Descartada ($\lvert r\rvert > 0{,}95$)
shape2D_PixelSurface	shape2D_MeshSurface	1.000	Descartada ($\lvert r\rvert > 0{,}95$)
glcm_MCC	glcm_Correlation	0.986	Descartada ($\lvert r\rvert > 0{,}95$)
Calcificaciones			
glcm_Imc1	glrlm_RunEntropy	0.961	Descartada ($\lvert r\rvert > 0{,}95$)
glcm_SumAverage	glcm_JointAverage	1.000	Descartada ($\lvert r\rvert > 0{,}95$)
glrlm_RunPercentage	glrlm_ShortRunEmphasis	0.975	Descartada ($\lvert r\rvert > 0{,}95$)
glrlm_RunLengthNonUniformityNormalized	glrlm_ShortRunEmphasis	0.980	Descartada ($\lvert r\rvert > 0{,}95$)
shape2D_MaximumDiameter	shape2D_Perimeter	0.980	Descartada ($\lvert r\rvert > 0{,}95$)
firstorder_TotalEnergy	firstorder_Energy	1.000	Descartada ($\lvert r\rvert > 0{,}95$)
glrlm_HighGrayLevelRunEmphasis	glcm_JointAverage	0.972	Descartada ($\lvert r\rvert > 0{,}95$)
glcm_Autocorrelation	glcm_JointAverage	0.981	Descartada ($\lvert r\rvert > 0{,}95$)

Características candidatas con alto valor de F que fueron omitidas de la selección final para evitar colinealidad extrema ($\lvert r\rvert > 0{,}95$). En masas se descartaron 7 variables y en calcificaciones 8.

Cuadro 29 · Balance por fold (M4)

Cuadro 29: Balance de lesiones, pacientes y proporción de malignidad por fold (Módulo 4).

	Masas (semilla elegida: 125)			Calcificaciones (semilla elegida: 168)		
Fold	Lesiones	Pacientes	Malignas (%)	Lesiones	Pacientes	Malignas (%)
0	255	139	48.6 %	315	120	33.3 %
1	258	134	47.3 %	271	119	35.4 %
2	268	138	48.9 %	322	121	36.6 %
3	257	140	49.4 %	314	121	35.7 %
4	280	140	47.5 %	324	121	34.9 %
Total / media	1318	691	48.3 %	1546	602	35.2 %

Partición de validación cruzada 5-fold estratificada por paciente (`StratifiedGroupKFold`). Garantiza cero fuga de pacientes entre folds y balance de clases óptimo entre candidatos de semillas.

Cuadro 30 · Coste de los kernels cuánticos (M5)

Cuadro 30: Costes computacionales de evaluación de kernels cuánticos (Módulo 5).

Subconjunto	Kernel cuántico evaluado	Dimensión	Tiempo total (s)
Masas	`FidelityStatevectorKernel_C4`	200x200	1.468
Masas	`FidelityStatevectorKernel_C5`	200x200	1.590
Calcificaciones	`FidelityStatevectorKernel_C4`	200x200	1.569
Calcificaciones	`FidelityStatevectorKernel_C5`	200x200	1.574
Masas	`FidelityQuantumKernel_C4`	10x10	4.970
Masas	`FidelityQuantumKernel_C5`	10x10	4.985
Calcificaciones	`FidelityQuantumKernel_C4`	10x10	4.948
Calcificaciones	`FidelityQuantumKernel_C5`	10x10	5.041

Tiempos medidos en simulación exacta. `FidelityStatevectorKernel` calcula la matriz 200×200 en $\sim$1.5 s aprovechando vectores de estado precomputados. `FidelityQuantumKernel` evalúa el circuito cuántico directo requiriendo $\sim$5.0 s para una matriz reducida de solo 10×10.

Cuadro 31 · Escalamiento con el número de qubits (OE-6)

Cuadro 31: Escalamiento computacional con el número de qubits en simulación por vector de estado (OE-6).

k (qubits)	Tipo de dato	Memoria estado	Tiempo/estado (s)	Tiempo embedding (h)	Entrenamiento (h/mapa)
8	Medido	0.00 MiB	0.0012	0.002	1.6
10	Medido	0.02 MiB	0.0019	0.004	3.0
12	Medido	0.06 MiB	0.0029	0.006	5.7
14	Medido	0.25 MiB	0.0065	0.013	14.8
16	Medido	1.00 MiB	0.0349	0.069	90.3
18	Medido	4.00 MiB	0.1071	0.212	311
20	Medido	16.00 MiB	0.3924	0.778	1264
22	Medido	64.00 MiB	1.2	2.472	4415
24	Medido	256.00 MiB	4.1	8.194	15950
26	Medido	1.00 GiB	13.7	27.3	57421
28	Medido	4.00 GiB	74.8	148.2	336114
30	Extrapolado	16.00 GiB	221.0	438.0	1063514
32	Extrapolado	64.00 GiB	802.7	1591.1	4118952

Escalamiento del coste en simulación cuántica por vector de estado en función del número de qubits (k). Para $k \leq 28$ las cifras corresponden a ejecuciones empíricas en el hardware de referencia (Apple M3); para $k \geq 30$ corresponden a la extrapolación exponencial teórica.

Cuadro 32 · Coste de los gradientes (X8)

Cuadro 32: Coste computacional del cálculo de gradientes variacionales (Experimento X8).

Método de cálculo	Naturaleza del gradiente	Tiempo/lesión (s)	Coste estimado (50 épocas, h)
parameter shift (EstimatorQNN, exact)	Jacobian 12×24 (also needed for a scalar loss)	5.1589	205.21
automatic differentiation (state vector)	Jacobian 12×24	0.2369	9.42
automatic differentiation (state vector)	scalar loss, one backward pass	0.0014	0.06

Comparación de costes entre diferenciación exacta por *parameter-shift rule* y diferenciación automática directa sobre vector de estado en simulación (Experimento X8).

Cuadro 33 · Verificaciones automáticas

Cuadro 33: Resumen de la suite de verificaciones automáticas de consistencia y correctitud.

Módulo	Archivo de resultados	Pruebas	Superadas	Ámbito de verificación
Módulo 5a	`5a_verificaciones.csv`	18	18 (100 %)	Recomputación exacta, dispersión positiva y validación con SparsePauliOp
Módulo 5b	`5b_verificaciones.csv`	38	38 (100 %)	Simetría de matrices, diagonal unitaria y semidefinición positiva ($\lambda_{\text{mín}} \geq 0$)
Módulo 6	`6_verificaciones.csv`	20	20 (100 %)	Normalización de traza, identidades teóricas de g, KTA y control nulo C1=C2
Módulo 7	`7_verificaciones.csv`	16	16 (100 %)	Cero fuga de pacientes, convergencia por parada temprana y estabilidad de probabilidades
Módulo 8	`8_verificaciones.csv`	22	22 (100 %)	Reproducción de AUC en test y CV, nula exacta de Spearman y muestreo de $\langle Z_i \rangle$
Total suite	5 archivos CSV	114	114 (100 %)	Suite completa de aserciones automáticas

Todas las pruebas automáticas del pipeline ejecutan aserciones matemáticas estrictas sobre las estructuras de datos generadas. El 100 % de las verificaciones resultó exitoso, sin discrepancias numéricas tolerables más allá del error de redondeo de punto flotante.

Cuadro 34 · Auditoría independiente (X5) (parte 1 de 2)

Cuadro 34: Auditoría metodológica independiente de consistencia, datos y modelos (Experimento X5).

Propiedad auditada	Discrepancia máxima	Veredicto
Integridad de etiquetas y particiones		
mass: every lesion of Module 4 exists in the original CSV files	0.0	Superada
mass: labels equal MALIGNANT = 1 from the CSV files	0.0	Superada
mass: train/test split equals the file of origin	0.0	Superada
calcification: every lesion of Module 4 exists in the original CSV files	0.0	Superada
calcification: labels equal MALIGNANT = 1 from the CSV files	0.0	Superada
calcification: train/test split equals the file of origin	0.0	Superada
mass: class counts equal the EDA (912 benign, 784 malignant)	0.0	Superada
calcification: class counts equal the EDA (1199 benign, 673 malignant)	0.0	Superada
Ausencia de fuga de datos (escalado y folds)		
mass: angles refitted on train only equal Module 4, test included	0.0	Superada
mass: every angle lies in $[0, \pi]$, test included	0.0	Superada
mass: no patient split across folds nor across train and test	0.0	Superada
calcification: angles refitted on train only equal Module 4, test included	0.0	Superada
calcification: every angle lies in $[0, \pi]$, test included	0.0	Superada
calcification: no patient split across folds nor across train and test	0.0	Superada

Cuadro 34 · Auditoría independiente (X5) (parte 2 de 2)

Equivalencia física de kernels cuánticos		
mass: C4 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
mass: C5 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
calcification: C4 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
calcification: C5 compute-uncompute kernel equals statevector kernel (12 x 12)	0.0	Superada
Equivalencia de formulación QSVM (Qiskit vs dual)		
mass: QSVC of qiskit-machine-learning equals the precomputed-kernel SVM of X4	0.0	Superada
calcification: QSVC of qiskit-machine-learning equals the precomputed-kernel SVM of X4	0.0	Superada
Invarianza de rotación y transformaciones		
changing x_i changes only <Z_i>of C5, to -sin(2 x_i)	0.0	Superada
C4: the kernel is invariant under a reordering of the features	0.0	Superada
C5: the kernel is invariant under a reordering of the features	0.0	Superada
Consistencia de modelos de referencia clásicos		
mass: three classical models agree within one fold standard deviation	2.39e-02	Superada
calcification: three classical models agree within one fold standard deviation	1.63e-02	Superada

Auditoría metodológica independiente de extremo a extremo (Experimento X5). Comprueba rigurosamente la ausencia de fugas de datos entre particiones de pacientes, la correspondencia exacta de etiquetas patológicas con los metadatos clínicos de CBIS-DDSM y la consistencia matemática de los componentes cuánticos.

Cuadro 6 · Requerimientos funcionales (parte 1 de 7)

Cuadro 6: Requerimientos funcionales del sistema

ID	Descripción	OE
Módulo 1 – Lectura de datos		
RF-01	Leer archivos DICOM del dataset CBIS-DDSM mediante `pydicom`, extrayendo el arreglo de píxeles en 16 bits y los metadatos clínicos.	OE-1
RF-02	Unificar los cuatro archivos CSV del dataset en un DataFrame consolidado con etiqueta binaria (BENIGN = 0 / MALIGNANT = 1).	OE-1

Cuadro 6 · Requerimientos funcionales (parte 2 de 7)

RF-03	Tratar de forma independiente masas y calcificaciones como sub-problemas de clasificación independientes.	OE-1, OE-3
Módulo 2 – Preprocesamiento		
RF-04	Alinear cada máscara ROI con su mamografía según el tipo de desajuste (remuestreo por vecino más cercano o anclaje sin escalar) y reducirla a su componente conexa mayor.	OE-1

Continúa en la siguiente página

Cuadro 6 · Requerimientos funcionales (parte 3 de 7)

Tabla 6 – continuación

ID	Descripción	OE
RF-05	Generar una variante con CLAHE sobre la mamografía completa convertida a 8 bits, solo para cuantificar su efecto sobre las características; la ruta de extracción usa la imagen sin CLAHE.	OE-1
RF-06	Recortar la ROI con la caja de la máscara ampliada en 20 píxeles por lado, a resolución original y con las intensidades originales de 16 bits.	OE-1
Módulo 3 – Extracción de características		
RF-07	Extraer 67 características radiómicas con PyRadiomics (primer orden, forma 2D, GLCM y GLRLM) sobre la imagen original, con `binCount` = 32.	OE-1
Módulo 4 – Selección y escalado		

Cuadro 6 · Requerimientos funcionales (parte 4 de 7)

RF-08	Seleccionar $k = 12$ características por F-test ANOVA, aceptando una solo si su correlación absoluta con las ya elegidas es $\leq 0{,}95$, con el selector ajustado únicamente sobre el conjunto de entrenamiento.	OE-1, OE-2
RF-09	Transformar cada característica en un ángulo $\pi \hat{F}(r) \in [0, \pi]$, con $\hat{F}$ su distribución empírica, mediante una transformación por cuantiles ajustada sobre el conjunto de entrenamiento.	OE-1, OE-2
Módulo 5 – Transformación (5 condiciones)		
RF-10	*Baseline* crudo: vector seleccionado y escalado directo al MLP sin transformación adicional.	OE-2
RF-11	*Baseline* lineal: PCA sobre el vector seleccionado y escalado, conservando k componentes. Actúa como control nulo: una PCA de k a k dimensiones es una rotación.	OE-2
RF-12	*Baseline* no lineal: Kernel PCA con kernel RBF sobre el vector seleccionado, con el ancho de banda γ fijado por la heurística de la mediana sobre el entrenamiento.	OE-2

Continúa en la siguiente página

Cuadro 6 · Requerimientos funcionales (parte 5 de 7)

Tabla 6 – continuación

ID	Descripción	OE
RF-13	Condición C4: `zz_feature_map` de segundo orden seguido de `real_amplitudes` con parámetros θ fijos (semilla 42, sin entrenar), devolviendo los valores esperados exactos $\langle Z_i \rangle \in [-1,1]^k$.	OE-2
RF-14	Condición C5: `pauli_feature_map` con operadores (Y, ZZ), con el mismo *ansatz* y los mismos θ que C4.	OE-2
Módulo 6 – Análisis de separabilidad		
RF-15	Calcular el kernel cuántico de fidelidad, solo con el *feature map*, sobre 200 lesiones de entrenamiento por subconjunto (y, como robustez, sobre todo el entrenamiento), y su alineamiento centrado con las etiquetas, comparado contra una prueba de permutación.	OE-3
RF-16	Calcular la *geometric difference* regularizada entre el kernel cuántico y una batería de kernels clásicos, con el protocolo de Huang et al., junto con la dimensión efectiva: $g_{\text{gen}} = \sqrt{\left\| \sqrt{K_Q}\sqrt{K_C}\,(K_C + \lambda I)^{-2}\sqrt{K_C}\,\sqrt{K_Q} \right\|_\infty}$.	OE-3

Cuadro 6 · Requerimientos funcionales (parte 6 de 7)

RF-17	Medir el índice de Davies-Bouldin, la razón de Fisher multivariante y el alineamiento del kernel lineal sobre la representación de cada condición, separado para masas y calcificaciones.	OE-3
	Módulo 7 – Clasificación	
RF-18	Entrenar el mismo MLP ($k \to 32 \to 16 \to 1$) en las 5 condiciones, con idéntica arquitectura, hiperparámetros, protocolo y semilla.	OE-4
RF-19	Entrenar con ponderación de clases, con pesos $w_c = N/(CN_c)$ (ecuación (37)) en la entropía cruzada binaria para compensar el desbalance observado.	OE-4
	Módulo 8 – Evaluación comparativa	
RF-20	Reportar AUC-ROC, F1-Score, Accuracy, Precision y Recall por condición, separado para masas y calcificaciones.	OE-5

Continúa en la siguiente página

Cuadro 6 · Requerimientos funcionales (parte 7 de 7)

Tabla 6 – continuación

ID	Descripción	OE
RF-21	Analizar la correlación entre ranking de separabilidad (OE-3) y ranking de clasificación (OE-5) de forma descriptiva, con la distribución exacta de ρ_s para $n = 5$.	OE-5
RF-22	Documentar restricciones del simulador: tiempo por muestra, qubits máximos, impacto de *shots* y costo del *parameter-shift*.	OE-6

Cuadro 7 · Requerimientos no funcionales (parte 1 de 3)

Cuadro 7: Requerimientos no funcionales del sistema

ID	Categoría	Descripción
RNF-01	Reproducibilidad	Fijar semillas aleatorias en `numpy`, `PyTorch` y `Qiskit` al inicio de cada experimento (semilla 42). Las semillas de los *folds* (125 en masas y 168 en calcificaciones) se eligen por balance de clases.
RNF-02	Reproducibilidad	Declarar los parámetros de cada módulo en su *notebook* y guardar los parámetros ajustados junto a los datos procesados (`x_<tipo>.json` en M4, `emb_meta.json` en M5).
RNF-03	Reproducibilidad	Usar la partición oficial train/test sin reordenarla, que los autores del CBIS-DDSM estratificaron por categoría BI-RADS [52], con la partición real de 2 864 / 704 lesiones (80.3 % / 19.7 %); el test se evalúa una sola vez por modelo y la validación cruzada usa 5 *folds* agrupados por paciente dentro del train.

Continúa en la siguiente página

Cuadro 7 · Requerimientos no funcionales (parte 2 de 3)

Tabla 7 – continuación

ID	Categoría	Descripción
RNF-04	Reproducibilidad	Ajustar el selector, el escalador por cuantiles y la estandarización del MLP solo con datos de entrenamiento para transformar el conjunto de prueba, previniendo *data leakage*.
RNF-05	Rendimiento	Calcular los valores esperados de forma exacta para el experimento, y cuantificar aparte el efecto de los *shots* muestreando n disparos de las probabilidades exactas (de 64 a 65 536, incluido 1 024).

Cuadro 7 · Requerimientos no funcionales (parte 3 de 3)

RNF-06	Rendimiento	Calcular la matriz de kernel cuántico sobre una submuestra de 200 lesiones de entrenamiento por subconjunto, un tamaño que el protocolo *compute-uncompute* de un equipo cuántico admite ($N(N-1)/2$ circuitos por matriz), y repetir las métricas sobre todo el entrenamiento como análisis de robustez.
RNF-07	Escalabilidad	Circuito parametrizable en k, *feature map* y `reps`. Punto de operación $k = 12$ y `reps` = 1, con $k = 8$ y `reps` = 2 como análisis de sensibilidad.
RNF-08	Mantenibilidad	Código organizado en ocho módulos M1–M8, un *notebook* por módulo.
RNF-09	Propiedad intelectual	Registro del trabajo en INDAUTOR.

Cuadro 8 · Fases CRISP-DM y módulos

Cuadro 8: Correspondencia entre fases CRISP-DM y módulos del sistema

Fase CRISP-DM	Módulo	Actividad principal
1. Comprensión del negocio	—	Definición del problema de prediagnóstico, formulación de la pregunta de investigación y criterios de separabilidad.
2. Comprensión de los datos	M1	Lectura DICOM, análisis exploratorio del dataset CBIS-DDSM (EDA).
3. Preparación de los datos	M2, M3, M4	Preprocesamiento de imagen, extracción de features y selección/escalado.
4. Modelado	M5, M7	Implementación de las 5 condiciones de transformación y entrenamiento del MLP.
5. Evaluación	M6, M8	Análisis de separabilidad, métricas de clasificación, comparación clásico frente a cuántico y restricciones del simulador.
6. Despliegue	—	Documentación de hallazgos, reporte técnico y registro INDAUTOR.

Cuadro 35 · Versiones de los paquetes

Cuadro 35: Versiones de los paquetes de software fundamentales en los entornos de ejecución.

Paquete de software	Función en el pipeline	Entorno `radiomics`	Entorno `qml_cancer`
`python`	Lenguaje base del entorno	`3.10.20`	`3.10.19`
`numpy`	Cómputo matricial y vectores	`2.2.6`	`2.2.6`
`scipy`	Rutinas científicas y optimización	-	`1.15.3`
`pandas`	Estructuras de datos tabulares	`2.3.3`	`2.3.3`
`scikit-learn`	Modelos clásicos y métricas ML	-	`1.7.2`
`pyradiomics`	Extracción de características radiómicas	`0.1.dev1+g8ed579383`	`3.1.1.dev111+g8ed579383`
`pydicom`	Lectura de mamografías DICOM crudas	`3.0.2`	`3.0.1`
`SimpleITK`	Conversión y exportación espacial NRRD	`2.5.6`	`2.5.3`
`opencv-python`	Alineación de máscaras y CLAHE	`4.11.0.86`	`4.13.0.92`
`matplotlib`	Generación de gráficos y figuras	`3.10.9`	`3.10.8`
`torch`	Redes neuronales y optimización MLP	-	`2.10.0`
`qiskit`	Definición de circuitos cuánticos	-	`2.3.0`
`qiskit-aer`	Simulación cuántica de alto rendimiento	-	`0.17.2`
`qiskit-machine-learning`	Kernels y algoritmos cuánticos de aprendizaje	-	`0.9.0`

Versiones exactas de librerías en los dos entornos de ejecución reproducible gestionados con Conda. `pyradiomics` se encuentra anclado en ambos entornos al commit `8ed579383b44806651c463d5e691f3b2b57522ab`.

Cuadro 36 · Índice de decisiones de la bitácora (parte 1 de 6)

Cuadro 36: Índice cronológico de decisiones metodológicas documentadas en la bitácora.

Identificador	Estado	Título de la decisión	Sección en reporte
D-001	Firme	SelectKBest + MinMaxScaler en lugar de PCA antes del circuito	§ 5.6
D-002	**Revertida**	ZZFeatureMap y PauliFeatureMap como condiciones separadas	§ 5.7
D-003	Firme	Geometric difference como métrica de ventaja cuántica potencial	§ 5.8, § 3.4.2
D-004	Firme	Escalado angular a $[0,\pi]$ y no a $[0,2\pi]$	§ 5.6
D-005	Firme	Masas y calcificaciones como subproblemas independientes	§ 5.1

Cuadro 36 · Índice de decisiones de la bitácora (parte 2 de 6)

D-006	Firme	PyRadiomics (Estrategia A) en lugar de encoder CNN	§ 5.5
D-007	Firme	Entorno `radiomics` separado, compilado desde GitHub	§ D
D-008	Firme	`binCount=32` en lugar de `binWidth`	§ 5.5
D-009	Firme	Sin resize a 224×224 en la ruta radiómica	§ 5.4
D-010	Firme	CLAHE fuera de la ruta radiómica	§ 5.4
D-011	Firme	Unidad de análisis = lesión/ROI, no paciente	§ 5.6
D-012	Firme	Descargar por la API REST de TCIA, no con NBIA Data Retriever	§ 5.3
D-013	Firme	Punto de operación: k=12 qubits, reps=1	§ 5.6, § 5.7
D-014	Firme	Arquitectura B: embedding precomputado con θ fijo (semilla 42)	§ 5.7, § 5.9

Continúa en la siguiente página...

Cuadro 36 · Índice de decisiones de la bitácora (parte 3 de 6)

Cuadro 36 – *continuación de la página anterior*

Identificador	Estado	Título de la decisión	Sección en reporte
D-015	**Revertida**	C5 usa `pauli_feature_map(paulis=['X','ZZ'])`	§ 5.7
D-016	Firme	C2 se declara control nulo; se mantienen cinco condiciones	§ 5.7, § 5.8
D-017	Firme	La *geometric difference* se calcula con `FidelityQuantumKernel`	§ 5.8, § 3.4.2
D-018	Firme	Validación cruzada 5-fold estratificada sobre el conjunto de entrenamiento	§ 5.9
D-019	Firme	Las líneas de trabajo futuro se atribuyen a Azevedo et al. (2022)	§ 1.3, § 2.1.5
D-020	Firme	Alinear cada máscara según su tipo de desajuste, no remuestrear las 80	§ 5.4
D-021	Firme	Reducir cada máscara a su componente conexa mayor	§ 5.4

Cuadro 36 · Índice de decisiones de la bitácora (parte 4 de 6)

D-022	Firme	Contrato de salida de M2: caja + 20 px, intensidades crudas, NRRD	§ 5.4, § 5.5
D-023	Firme	M3 extrae 67 features: cuatro familias sobre la imagen original, sin filtros	§ 5.5
D-024	Firme	Selección por F-test con restricción de redundancia $\lvert r\rvert \leq 0.95$	§ 5.6
D-025	Firme	Escalado angular por cuantiles (uniforme $\times$ π) en lugar de min-max	§ 5.6
D-026	Firme	Semilla de los folds elegida por balance de clases	§ 5.6, § 5.9
D-027	Firme	γ del RBF por heurística de la mediana (C3 y kernel clásico de la *geometric difference*)	§ 5.7, § 5.8
D-028	Firme	Separabilidad sobre 200 lesiones de train por subconjunto, estratificadas	§ 5.7, § 5.8
D-029	Firme	Kernel concentrado: se mantiene el diseño fijado de antemano y se añade un barrido del factor de escala	§ 5.7, § 5.8

Continúa en la siguiente página…

Cuadro 36 · Índice de decisiones de la bitácora (parte 5 de 6)

Cuadro 36 – *continuación de la página anterior*

Identificador	Estado	Título de la decisión	Sección en reporte
D-030	Firme	La separabilidad pasa a ser el Módulo 6; la clasificación, el M7, y la evaluación comparativa, el M8	§ 5.1
D-031	Firme	C5 pasa a `pauli_feature_map(paulis=['Y','ZZ'])`	§ 5.7
D-032	Firme	La *geometric difference* sigue el protocolo de Huang et al. (Apéndice L.3)	§ 5.8, § 3.4.2
D-033	Firme	Definiciones de las demás métricas del M6	§ 5.8
D-034	Firme	Se reproduce la Fig. 2 de Huang et al. (2021) en el reporte	§ 3.4.2
D-035	Firme	Se compara contra k = 8 antes de concluir el OE-3, como experimento X3	§ 5.6, § 5.7, § 5.8
D-036	Firme	Protocolo de clasificación del M7: MLP 32-16, estandarización y parada temprana por paciente	§ 5.9

Cuadro 36 · Índice de decisiones de la bitácora (parte 6 de 6)

D-037	Firme	Análisis de sensibilidad del M7: reps = 2 en el ansatz, k = 8, semillas y configuraciones	§ 5.9
D-038	Firme	Análisis exploratorios X4 a X6: QSVM, auditoría y búsqueda de ventaja, con protocolo simétrico	§ 5.11
D-039	Firme	El Spearman del M8 se reporta como descriptivo: por subconjunto, con su distribución exacta para n = 5	§ 5.10, § 3.4
D-040	Firme	Contenido del M8: OE-6 medido (qubits, shots en el embedding y en el kernel) y referencia con los descriptores del radiólogo	§ 5.10
D-041	*Provisional*	Pregunta de investigación y objetivos reformulados en el reporte final, con cambio mínimo	§ 1.2, § 1.4, § 1.5
D-042	Firme	Las 200 lesiones siguen como análisis principal del M6, justificadas por el protocolo físico; X9 se reporta como robustez	§ 5.8