INSTITUTO POLITÉCNICO NACIONAL · ESCUELA SUPERIOR DE CÓMPUTO

Modelo de transformación cuántica variacional de características de cáncer de mama para un sistema híbrido de prediagnóstico

Trabajo Terminal 2026-B039

PRESENTA

Miguel Alexander Sánchez García

DIRECTORES

Dr. Jesús Yaljá Montiel Pérez · Dra. Ana María Winfield Reyes

24 de noviembre de 2026

Detectar a tiempo cambia la supervivencia de 33 % a más de 99 %

2.3 M

nuevos casos en el mundo, 2022

OMS

8,451

defunciones en México, 2024

INEGI

>99 % vs 33 %

supervivencia a 5 años: etapa temprana frente a metástasis

ACS · SEER

El aprendizaje automático clásico ya clasifica lesiones; la pregunta abierta es si una codificación cuántica las representa de forma más separable.

01 · PREGUNTA

¿Una codificación cuántica separa mejor lo benigno de lo maligno?

> ¿En qué medida las transformaciones cuánticas variacionales implementadas mediante ZZFeatureMap y PauliFeatureMap en Qiskit modifican la separabilidad de clases benigno/maligno de características radiómicas extraídas de mamografías del CBIS-DDSM, y hasta qué punto esa diferencia se refleja en la capacidad de clasificación de una misma red neuronal clásica, en comparación con representaciones clásicas construidas a partir del mismo vector de características?

Objetivo: viabilidad, no superar a una CNN.

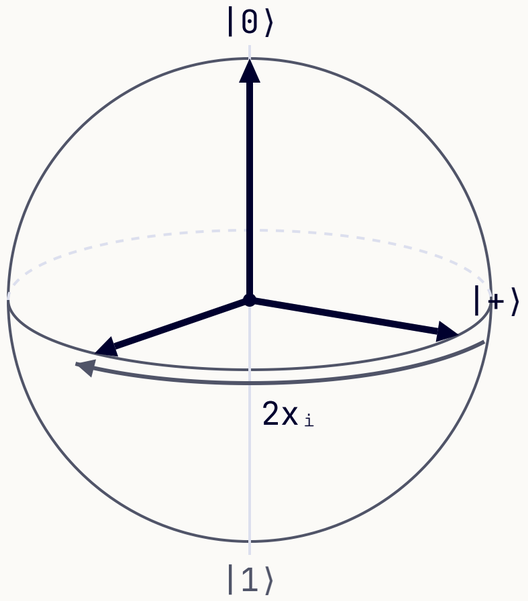
Todo en simulación ideal (Qiskit Aer), sin hardware cuántico.

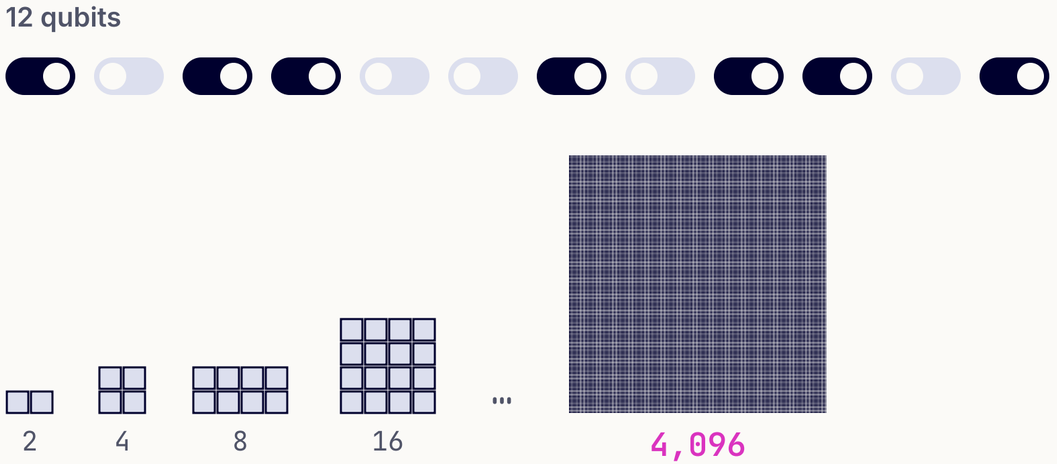
Un qubit es una flecha en una esfera; 12 qubits combinan 4,096 posibilidades

Hadamard: al ecuador

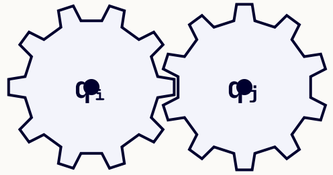
el giro es la característica

$x_i \in [0, \pi]$ → como mucho una vuelta





12 qubits = 2^{12} = 4,096 combinaciones



ZZ: cada par gira según sus dos características a la vez

esquema ilustrativo

Un circuito convierte 12 números en un estado de 12 qubits, y hay dos formas de leerlo

$x \in [0, \pi]^{12}$

12 características

Feature map U(x)

Hadamard + giros por característica + entrelazamiento ZZ por pares

C4 · C5

$|\psi(x)\rangle$

2^{12} = 4,096 dimensiones

(a) Kernel de fidelidad

$k(x, x') = |\langle\psi(x)|\psi(x')\rangle|^2$

Qué tan parecidas son dos lesiones → SVM · métricas de separabilidad



compara dos estados completos

(b) Valores esperados → MLP

resume el estado en 12 números



Ansatz

θ fijo · semilla 42

$\langle Z_i \rangle \in [-1, 1]$

12 valores esperados

MLP

12→32→16→1

Arquitectura B: θ no se entrena; los $\langle Z_i \rangle$ se calculan una vez y se guardan.

esquema ilustrativo

De 3,568 lesiones a un vector de 12 ángulos

M1

3,568

lesiones de 1,566 pacientes (CBIS-DDSM)

M2

ROI

recorte a resolución original, sin redimensionar

M3

67

características PyRadiomics: forma, primer orden, GLCM, GLRLM

M4

k = 12

selección F-ANOVA con $|r| \leq 0.95$

M5

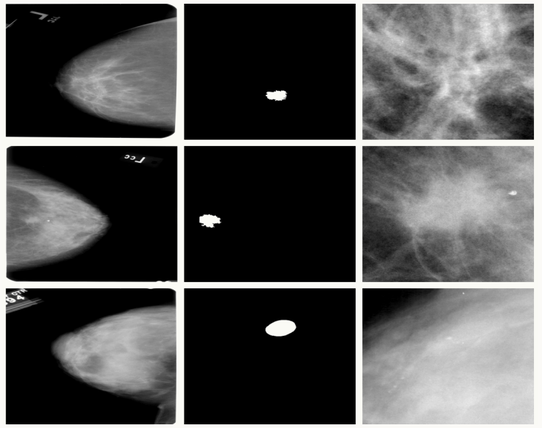
[0, π]

escalado por cuantiles

M6–M8

5

condiciones → separabilidad → MLP → comparación



Completa · máscara · ROI recortada

Masas (1,696) y calcificaciones (1,872) se procesan como dos problemas independientes. División por paciente: 2,864 entrenamiento / 704 prueba; la prueba se usa una sola vez.

Cinco representaciones del mismo vector, un mismo clasificador

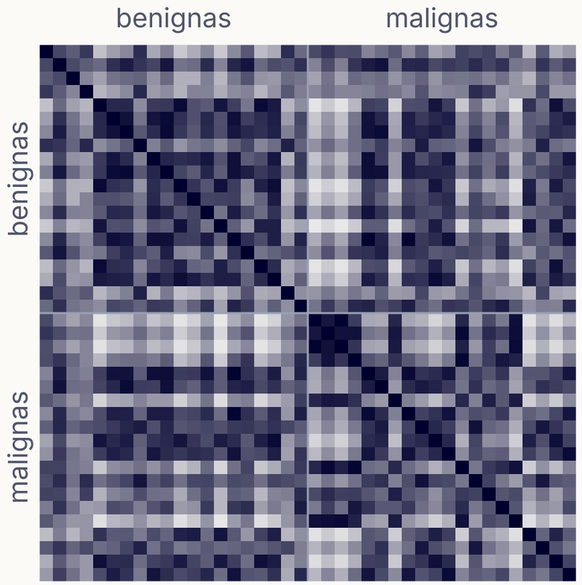
C1	**Sin transformación** · referencia		clásico
C2	**PCA lineal** · control nulo: rota, no añade información	 girar no cambia la información	clásico
C3	**Kernel PCA con RBF** · no lineal clásico		clásico
C4	**ZZFeatureMap** + ansatz fijo		cuántico
C5	**PauliFeatureMap (Y, ZZ)** + ansatz fijo		cuántico

Misma entrada x, mismo MLP 12→32→16→1, mismos hiperparámetros y semilla. **La única variable es la transformación.**

esquema ilustrativo

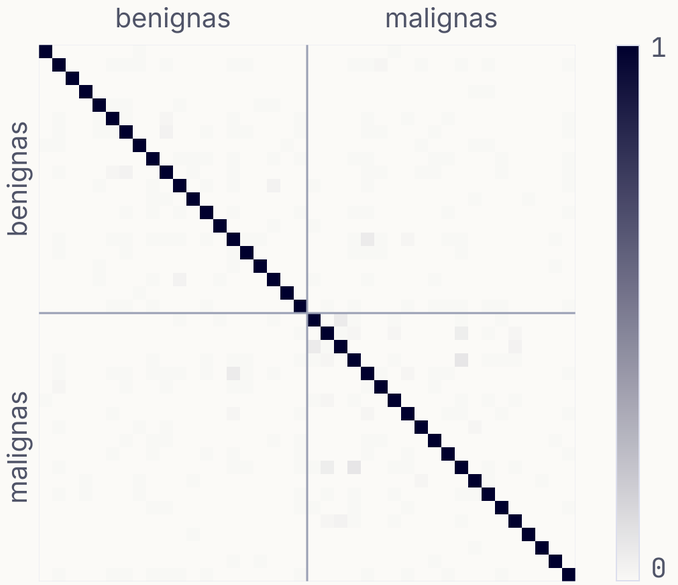
El kernel cuántico ve casi todos los pares de lesiones como ortogonales

RBF clásico



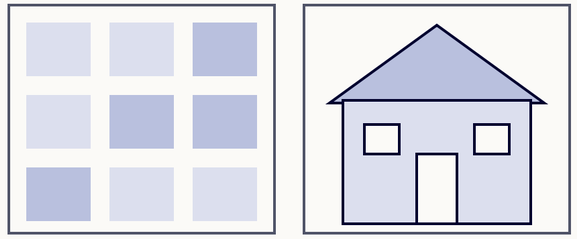
mediana fuera de la diagonal: **0.60**

C4 · ZZ



mediana fuera de la diagonal: **0.002**

C5 está aún más concentrado: mediana 0.00003; el 26–28 % de los pares queda por debajo de 10^{-6}



demasiado zoom: todo queda igual de lejos

esquema ilustrativo

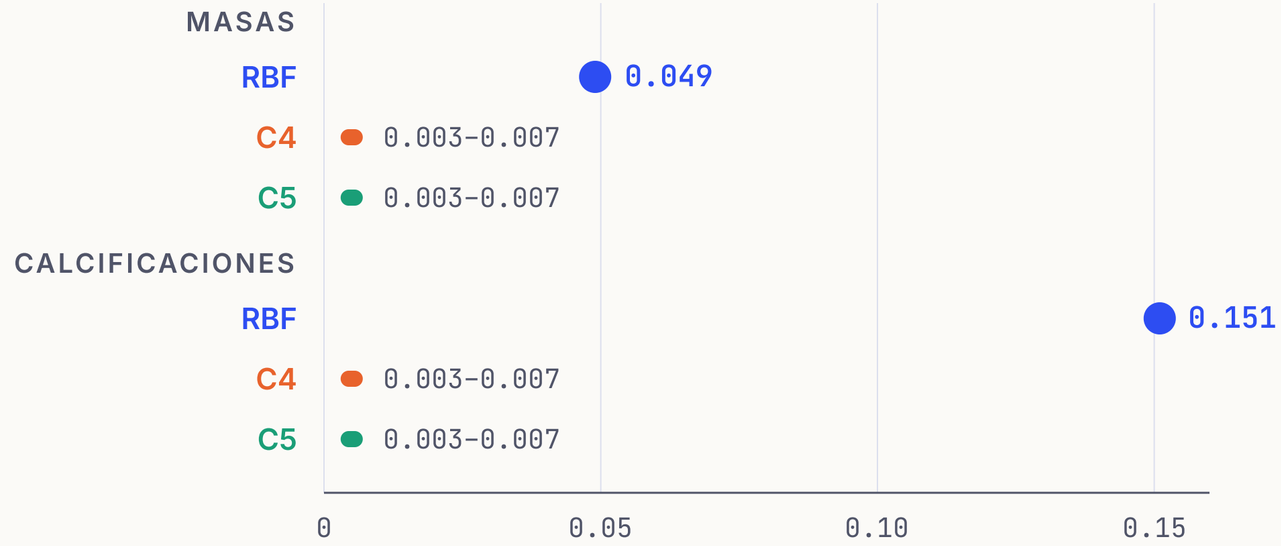
Si todas las lesiones están igual de lejos, el parecido no distingue clases: concentración.

40 lesiones de masas de la submuestra de 200 · cada celda = parecido entre dos lesiones

Ninguna representación cuántica aumentó la separabilidad

Alineamiento kernel-objetivo explicado por las etiquetas

¿el parecido entre lesiones coincide con el diagnóstico?



Diferencia geométrica

$$g = 1.40 - 1.70$$

umbral de ventaja potencial: $\sqrt{N} \approx 14.1$



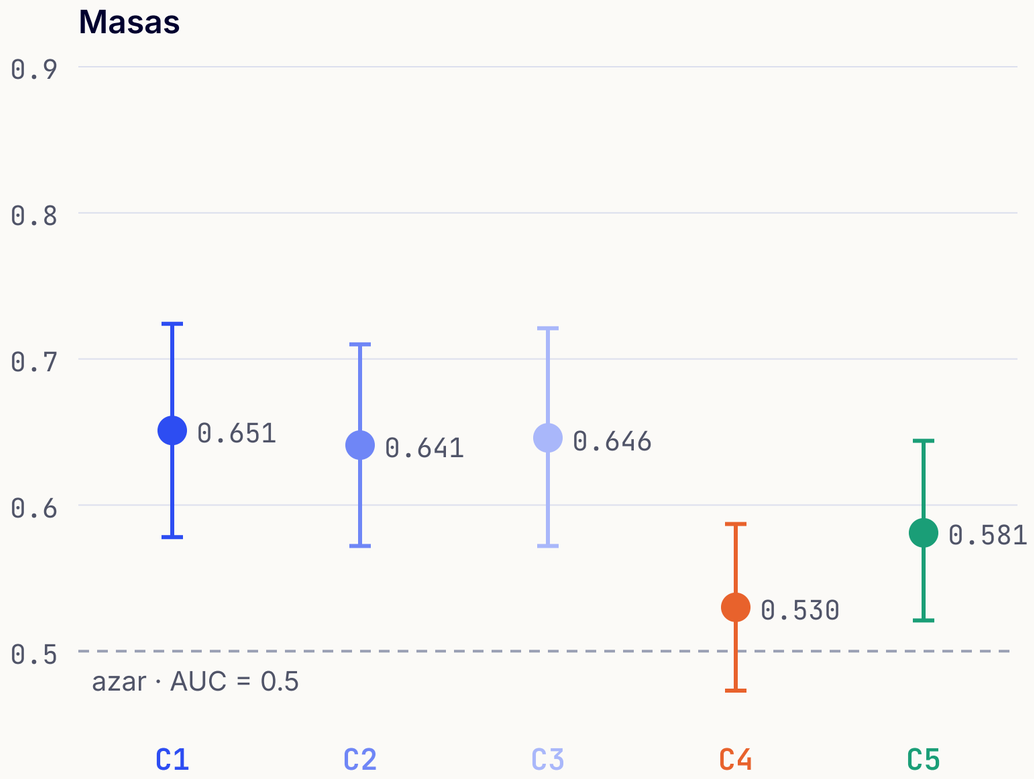
g queda casi un orden de magnitud por debajo del umbral.

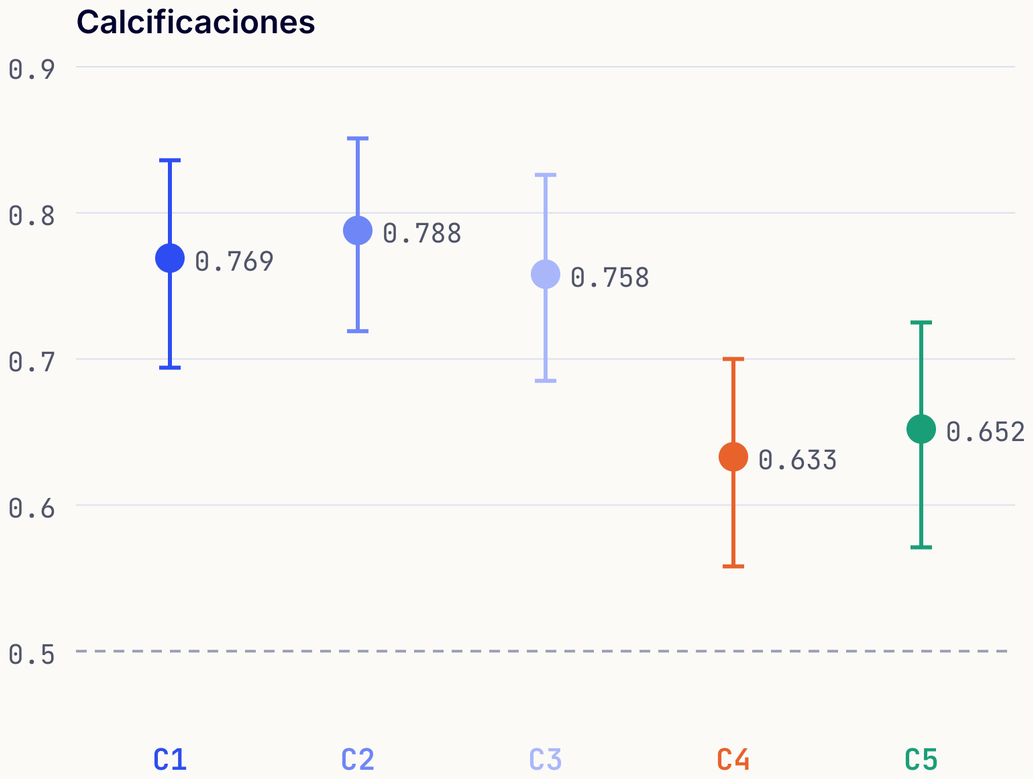
¿el mapa cuántico tiene caminos que el clásico no puede trazar?

C1–C3 también superan a C4–C5 en Davies-Bouldin y Fisher. Se mantiene en 20 submuestras y en todo el entrenamiento.

El mismo MLP clasifica peor sobre los embeddings cuánticos

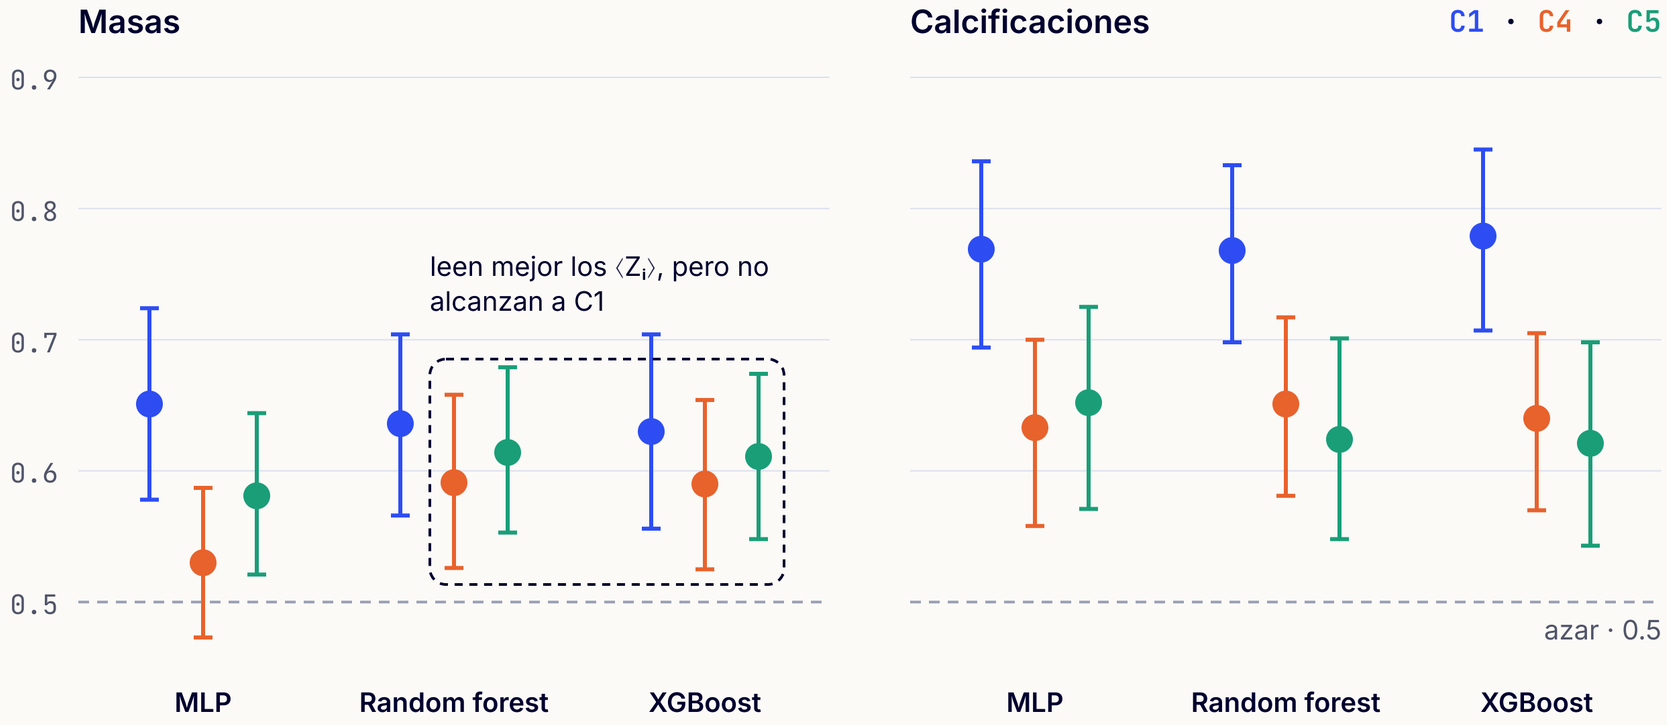
-0.07 a -0.14 de AUC frente a C1





AUC-ROC en prueba · punto = estimación · barra = IC 95 % (bootstrap por paciente)

Con árboles, bosques y *boosting*, ninguna representación cuántica supera a C1

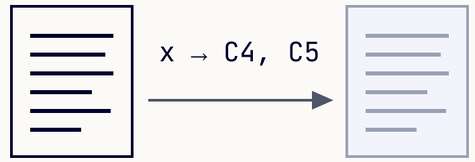


AUC-ROC en prueba · punto = estimación · barra = IC 95 % (bootstrap por paciente) · línea punteada = azar

0 de 24

comparaciones a favor de C4/C5

6 clasificadores × 2 subconjuntos × 2 condiciones cuánticas, mismo clasificador contra C1



C4 y C5 se calculan a partir de x: no contienen más información que x

esquema ilustrativo

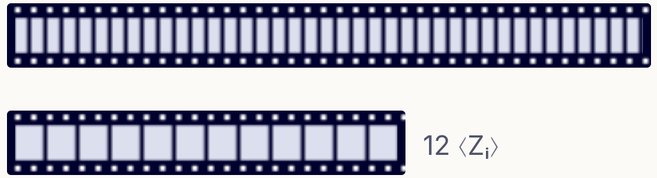
La pérdida está en la lectura de 12 números, no en la codificación



AUC-ROC en prueba · línea punteada azul = nivel de la SVM con RBF

Leído a través de su kernel, el estado cuántico iguala al clasificador clásico; resumido en 12 valores esperados, pierde información.

película completa = el estado



12 ⟨Zᵢ⟩

esquema ilustrativo

Análisis exploratorio

La ventaja cuántica sí existe: Huang et al. la construyeron y aquí se reproduce

Huang et al. (2021)

Con etiquetas diseñadas para seguir la geometría del circuito, los kernels cuánticos proyectados superan a todos los modelos clásicos probados.

la ventaja sigue a g y supera el 20 % en los sistemas más grandes · *Nature Communications* 12, 2631 (2021)



tarea diseñada: todas las preguntas salen del libro del circuito

esquema ilustrativo

¿Por qué no se usa siempre?

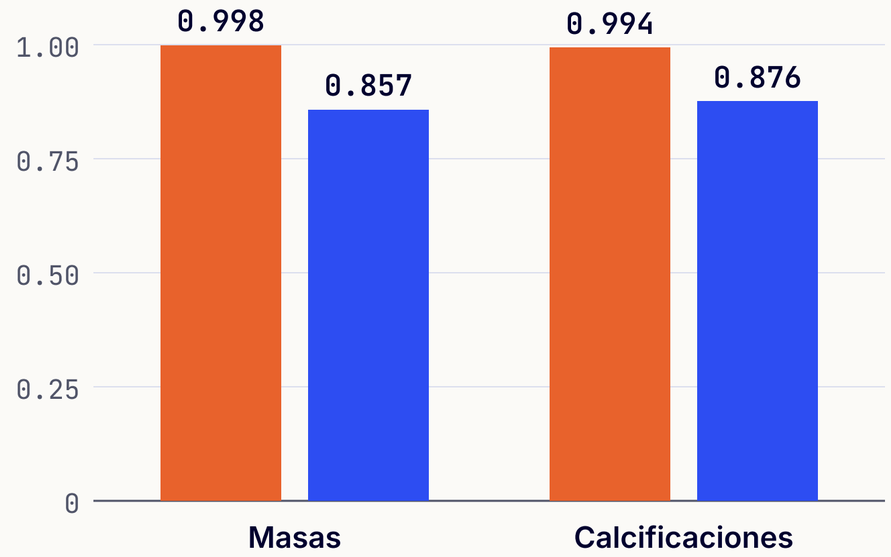
- En una tarea real las etiquetas no se eligen: las fija el diagnóstico.
- Las diseñadas se construyen con el propio kernel cuántico, así que la ventaja está asegurada de antemano.
- Con las etiquetas reales, ese mismo kernel proyectado es el que peor clasifica: **0.566** frente a **0.677** en masas y **0.667** frente a **0.763** en calcificaciones.

La pregunta deja de ser si la ventaja existe y pasa a ser si el diagnóstico es una de esas tareas.

Etiquetado diseñado según Huang et al. (2021), sección 7 del suplemento. Huang et al. miden exactitud de predicción; aquí, AUC-ROC en validación cruzada sobre el entrenamiento. No usa el conjunto de prueba.

Mismas lesiones y mismas 12 características, etiquetas diseñadas

AUC-ROC (validación cruzada)

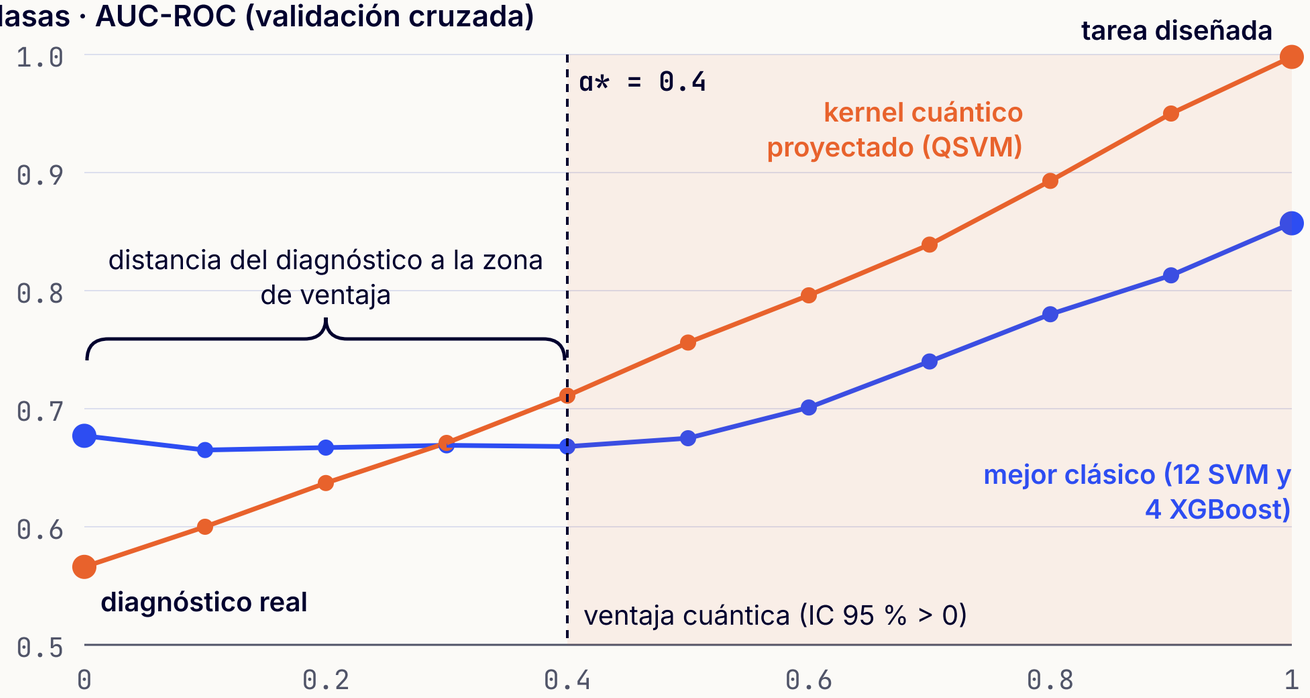


■ kernel cuántico proyectado (QSVM) · ■ mejor clásico (12 SVM y 4 XGBoost)

Con el kernel de fidelidad de C4 la ventaja es pequeña (+0.035 y +0.024): su g es pequeña, como anticipan Huang et al.

La ventaja cuántica aparece cuando la tarea sigue la geometría del circuito; el diagnóstico no la sigue

Masas · AUC-ROC (validación cruzada)

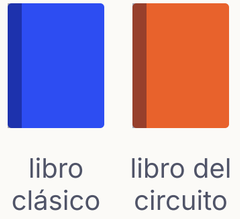


α: fracción de lesiones cuya etiqueta sigue la geometría del kernel cuántico

Umbral α* por kernel cuántico

Kernel cuántico	Masas	Calcif.
ZZ completo (C4)	0.6	0.7
ZZ lineal	0.5	0.6
Proyectado	0.4	0.5

el diagnóstico real está en α = 0



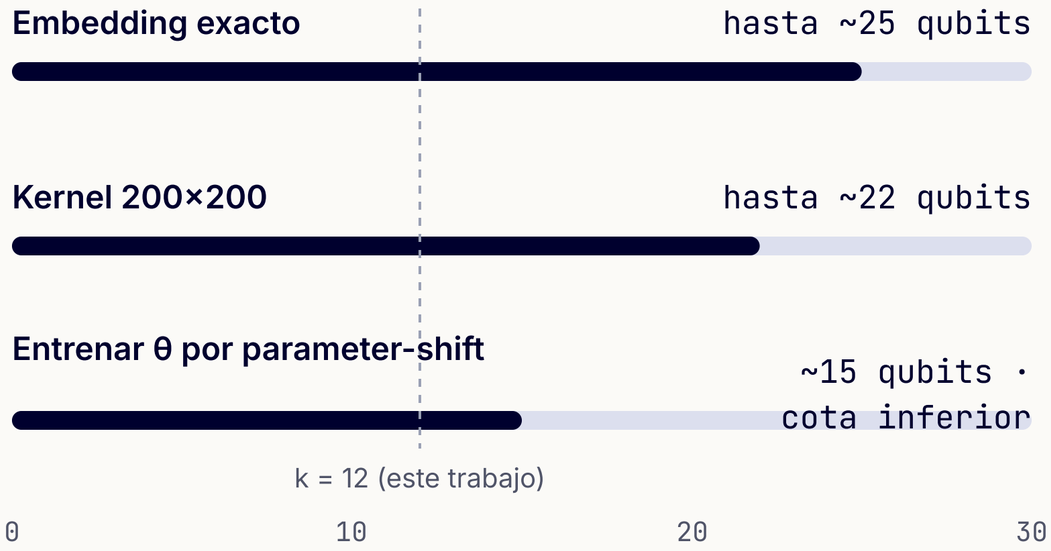


α = cuántas preguntas salen del libro del circuito

esquema ilustrativo

Etiquetas intermedias artificiales: instrumento de medida, no tarea clínica. Etiquetado diseñado según Huang et al. (2021), sección 7 del suplemento. 5 máscaras aleatorias por α; no usa el conjunto de prueba.

Simular cabe; medir en hardware sería el problema



Qubits que caben en 24 h de cómputo · Apple M3, 16 GiB. Entrenar θ deja de caber en un día desde ~15 qubits.

1,024 disparos



esquema ilustrativo

valor real ≈ 0.002 → se esperan ~2 “sí” de 1,024

a veces salen 0: el valor se lee como cero

C4 **21 %** masas **16 %** calcif.

C5 **74 %** masas **72 %** calcif.

de los pares se leen exactamente 0

Los $\langle Z_i \rangle$ sí toleran 1,024 disparos: el MLP queda a menos de 0.02 del AUC exacto

Respuesta: la codificación cuántica no aumentó la separabilidad; la redujo

1. Con k = 12, una repetición y c = 1, C4 y C5 separan peor que C1–C3 en todas las métricas.
2. La pérdida se refleja en la clasificación: −0.07 a −0.14 de AUC con el MLP; con 6 clasificadores, 0 de 24 comparaciones a favor de lo cuántico.
3. Causa identificada: concentración del kernel y lectura por 12 valores esperados.
4. La ventaja cuántica sí existe con etiquetas diseñadas (Huang et al.), y aparece cuando el 40–70 % de las etiquetas sigue la geometría del kernel cuántico; el diagnóstico real está en el 0 %.
5. Viable en simulación; en hardware, la concentración haría inmedible el kernel.

> *Un resultado negativo, medido con rigor, es evidencia de viabilidad.*

06 · CIERRE

Limitaciones y trabajo futuro

Limitaciones

- Simulación sin ruido.
- Intensidades no calibradas y sin escala física (PixelSpacing ausente).
- Separabilidad sobre 200 lesiones por subconjunto: el tamaño repetible en hardware (19,900 circuitos por matriz); la conclusión se mantiene con todo el entrenamiento.

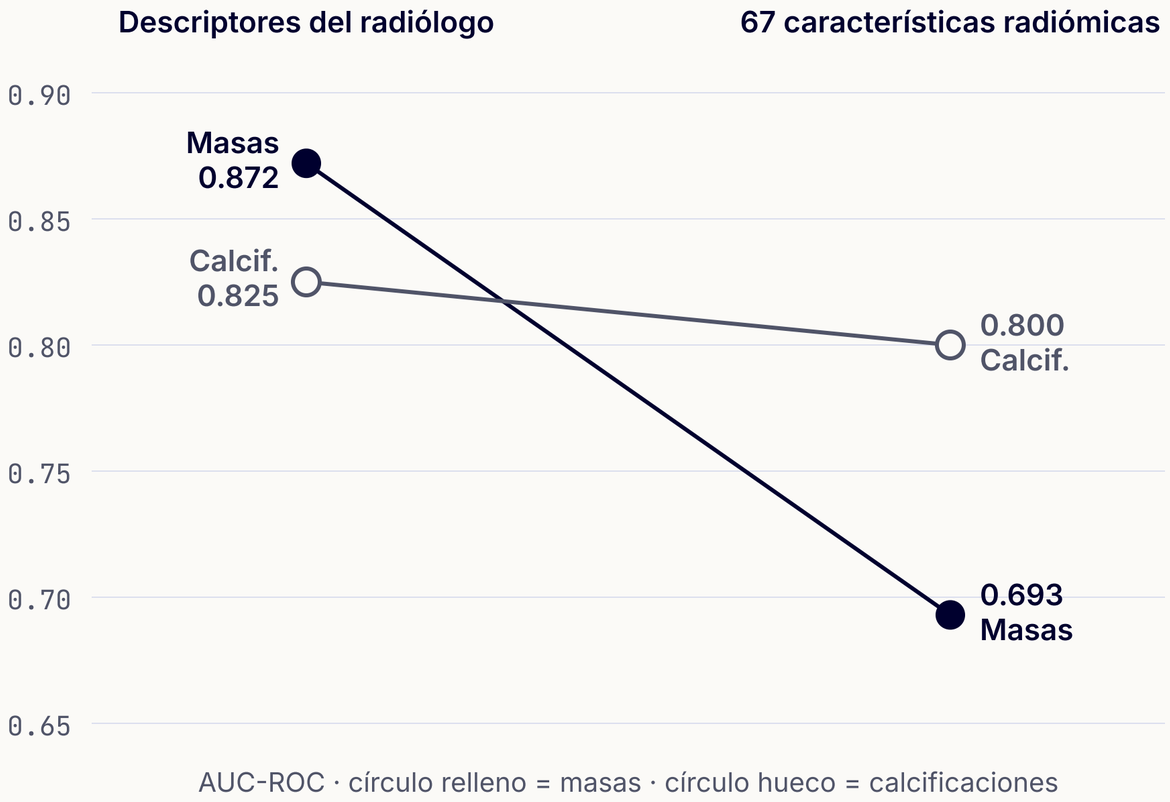
Trabajo futuro

- Codificaciones que eviten la concentración sin perder la interacción (ancho de banda por característica, conocimiento del problema).
- Lecturas intermedias del estado: correlaciones $\langle Z_i Z_j \rangle$ (66 valores) y lectores más profundos.
- Ejecución en procesadores cuánticos con mitigación de errores.

Gracias · ¿Preguntas?

Miguel Alexander Sánchez García

Con descriptores del radiólogo las masas son más separables; con radiómica, menos



La dificultad relativa de masas y calcificaciones se invierte según la representación.

RESPALDO · R2

Se corrigieron 80 máscaras y se conservó la escala original de cada lesión

80

máscaras desalineadas

78 masas escaladas ×0.870 y 2 calcificaciones desplazadas

1

componente conexa

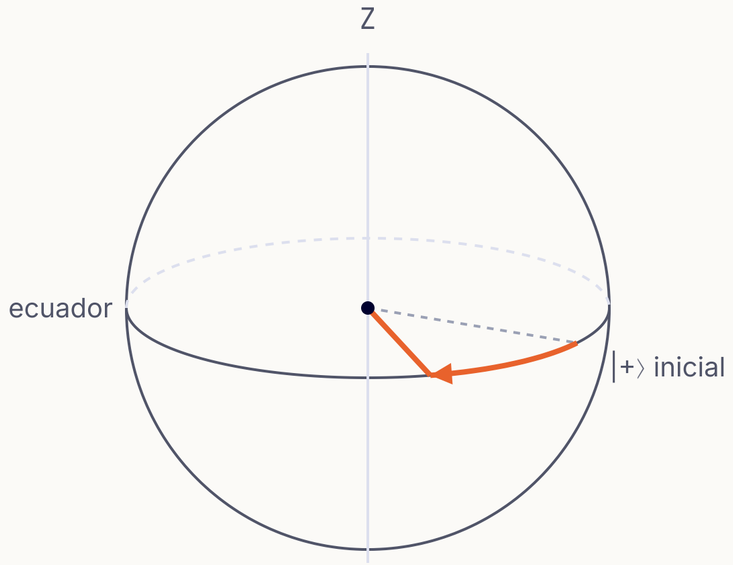
se conserva la mayor de cada máscara

1:1

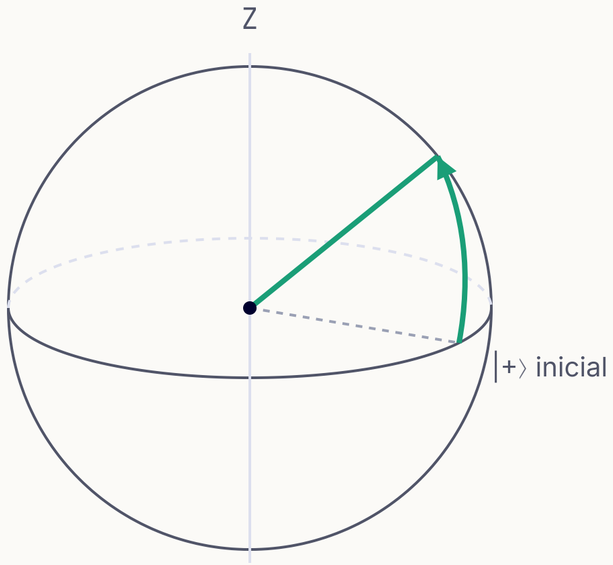
resolución original

sin CLAHE ni redimensionar a 224×224, porque destruyen las medidas de tamaño

C4 y C5 comparten el entrelazamiento ZZ; difieren en el eje del giro de cada qubit



C4 · giro $P(2x_i)$ en Z
permanece en el ecuador



C5 · giro $RY(2x_i)$ en Y
sale del ecuador

Mismo bloque ZZ entre pares y mismo ansatz. Solo cambia el eje del giro por característica.

esquema ilustrativo

La diferencia geométrica acota la ventaja posible del kernel cuántico

$$g = \sqrt{\| \sqrt{K_Q} \cdot \sqrt{K_C} \cdot (K_C + \lambda I)^{-2} \cdot \sqrt{K_C} \cdot \sqrt{K_Q} \|_\infty}$$

K_Q
kernel cuántico de fidelidad

K_C
kernel clásico: lineal y 9 gaussianos; se toma el mínimo

λ
regularización

$\|\cdot\|_\infty$
norma espectral

Protocolo de Huang et al. (2021), suplemento, sección 12 C. Ventaja potencial solo si $g \approx \sqrt{N}$; aquí $g = 1.40–1.70$ frente a $\sqrt{N} \approx 14.1$.

La conclusión resiste cambios en θ, en k y en la muestra

10 sorteos de θ	déficit frente a C1 de 0.03 a 0.18 de AUC
θ entrenado	+0.05 como máximo, no significativo
k = 8 características	misma conclusión
20 submuestras	RBF delante en el 100 %
6 clasificadores (árboles, *random forest*, XGBoost, MLP)	0 de 24 comparaciones a favor de C4/C5

Ningún paciente aparece a la vez en entrenamiento y en prueba

01

Particiones por paciente

StratifiedGroupKFold, 5 particiones, estratificadas por clase

02

Pérdida ponderada

entropía cruzada binaria ponderada por el desbalance de clases

03

Parada temprana

sobre el 15 % de los pacientes de entrenamiento

04

Prueba una sola vez

704 lesiones, evaluadas al final del estudio

Separabilidad y clasificación ordenan las condiciones de forma parecida

$$\rho = 0.67 - 0.97$$

Spearman entre métricas de separabilidad y AUC · descriptivo, n = 5 condiciones

Delante	C1–C3
Detrás	C4–C5

en todos los rankings

¿Por qué 5 folds? Es el mayor número que mantiene equilibradas las clases

Folds	Entrena con	Desviación máx. de la proporción de malignas (masas / calc.)	Malignas en el fold más pobre (masas / calc.)	Peso del paciente más grande (calc.)
3	67 %	0.003 / 0.003	200 / 167	5 %
5	80 %	0.011 / 0.019	122 / 96	9 %
10	90 %	0.044 / 0.045	57 / 49	17 %

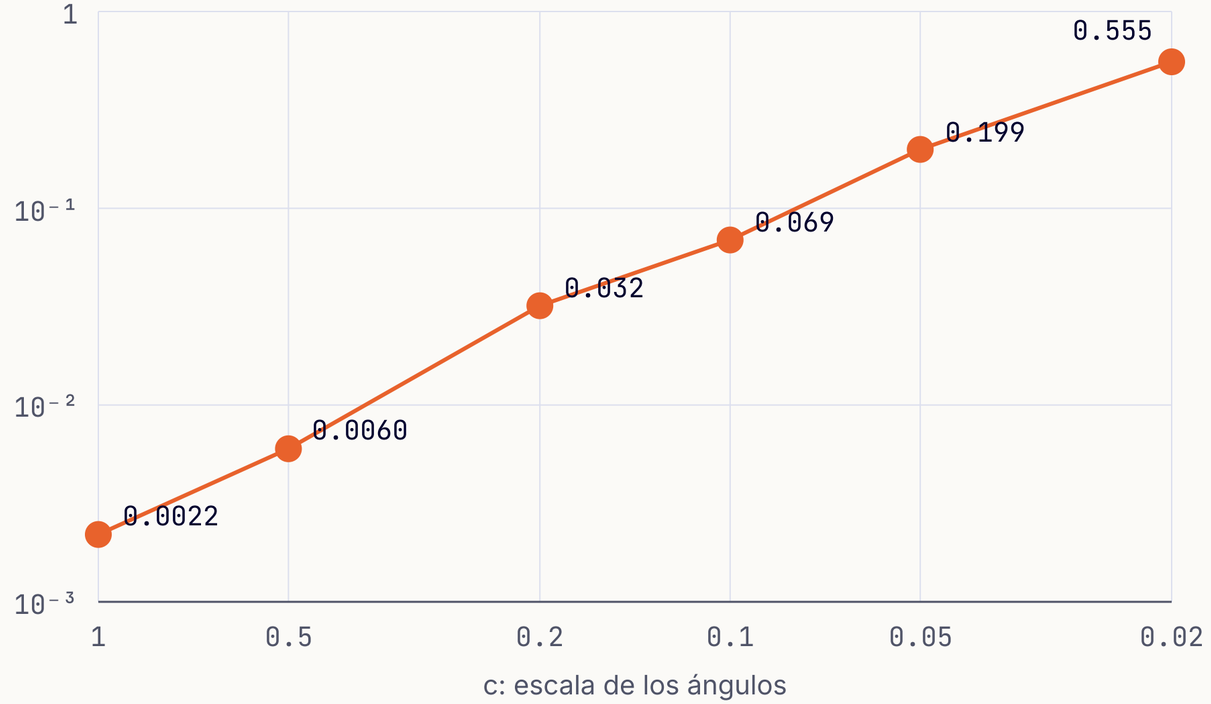
C4 − C1 y C5 − C1 en validación cruzada, con 5 y con 3 folds

	C4−C1 (5)	C4−C1 (3)	C5−C1 (5)	C5−C1 (3)
Masas	−0.087	−0.123	−0.089	−0.098
Calcificaciones	−0.102	−0.119	−0.075	−0.092

Con 3 folds la conclusión no cambia

Reducir la escala de los ángulos quita la concentración, pero también la interacción

Mediana del kernel C4, masas · escala logarítmica



idéntico al kernel sin el término $x_i x_j$ (correlación 1.0000)



demasiado lejos: se pierden las calles (las interacciones)

esquema ilustrativo

Separabilidad medida antes de clasificar

En el kernel

Alineamiento kernel-objetivo

exceso sobre etiquetas permutadas

Diferencia geométrica g

Huang et al., 2021 · ventaja potencial solo si g ≈ √N

En los vectores

Davies-Bouldin

↓ menor es mejor

Razón de Fisher

↑ mayor es mejor

t-SNE

cualitativo

Clasificación: AUC-ROC (principal), F1, exactitud, precisión, sensibilidad. Validación cruzada de 5 particiones por paciente.